ДИСЦИПЛИНА	Основы интеллектуального анализа данных
ИНСТИТУТ	Институт технологий управления
КАФЕДРА	Статистики и математических методов в управлении
ГРУППЫ	ГСБО-01-21, ГСБО-01-22,
ВИДЫ УЧЕБНОГО МАТЕРИАЛА	ПЗ 3. Тема – Критерии нормальности больших данных и их реализация в R-Studio
ПРЕПОДАВАТЕЛЬ	Бурцева Т.А.
СЕМЕСТР	5 семестр

Методические указания

Задание 1. На ресурсе Kaggle найти датасет в формате csv. (Можно воспользоваться прошлым датасетом, который Вы использовали в дисциплине «Программные средства анализа данных»).

Задание 2. Визуализируйте распределение переменных датасета и выбирайте ту переменную для дальнейшей работы, распределение которой наиболее похоже на нормальное.

Задание 3. Примените правило 3-сигм для проверки распределения выбранной переменной на согласованность с нормальным распределением, исключив грубые ошибки (выбросы), используя каждое правило нахождения грубых ошибок из методических указаний. Для проверки с помощью первого правила предположите, что у вас переменная представляет собой генеральную совокупность наблюдений, то есть содержит результаты сплошного обследования. Для проверки с помощью второго правила реализуйте 10% выборку из вашей переменной, причем выполните это не менее 30 раз. Для проверки по третьему правилу возьмите генеральное СКО, которое вы рассчитали ранее, используя все значения переменной. Сравните результаты, визуализируйте их.

Методические указания

На рис. 1 дана взаимосвязь между стандартным отклонением и формой нормального распределения, известная как правило 3-х сигм. Это простейший метод анализа данных на нормальность.

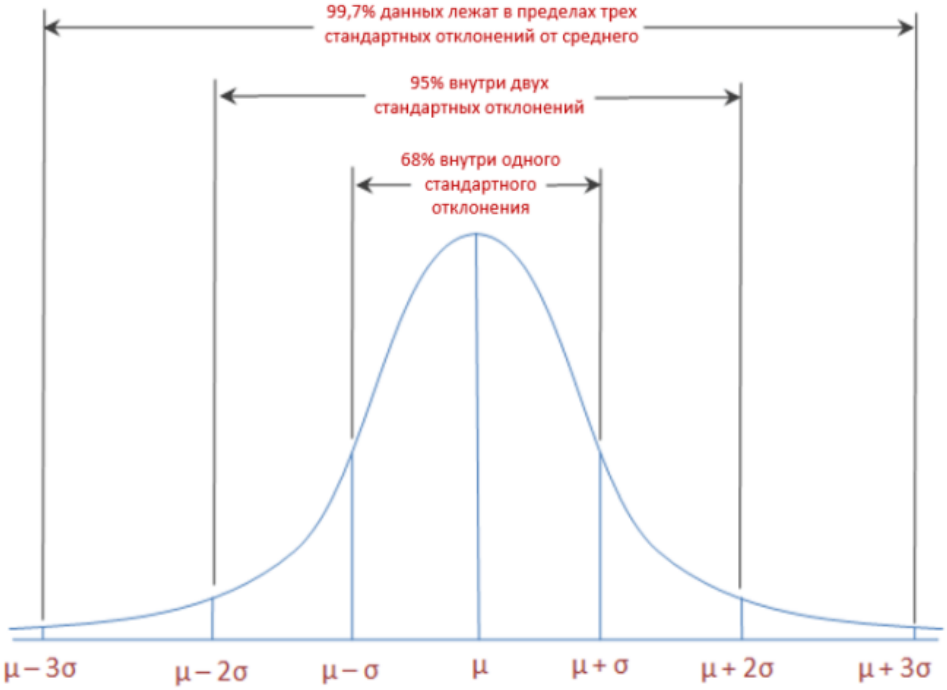


Рис. 1. Взаимосвязь между стандартным отклонением и формой нормального распределения

Правило трёх сигм формализуется так: отклонение значения нормально распределённой случайной величины X от её математического ожидания M(x) не превосходит утроенного среднеквадратического отклонения σ с вероятностью около 0,9973. Иначе говоря, с вероятностью 0,9973 значение нормально распределённой случайной величины X находится в интервале

[M(x) - 3σ ... M(x) + 3σ], где σ - среднеквадратическое отклонение случайной величины.

Таким образом, все значения, удовлетворяющие правилу| M(x) - xi| / σ > k =3 (1), являются грубыми ошибками (выбросами), то есть значения нормально распределённой случайной величины, отклоняющиеся от математического ожидания M(x) больше, чем на три сигмы, маловероятны (вероятность равна 1 – 0,9973 = 0,0027), и потому являются грубыми ошибками. Критерий трёх сигм также применяют обычно для быстрого приближённого определения грубых ошибок в выборке.

Преимуществами критерия трёх сигм считается то, что он прост, нагляден и легко запоминается, при его применении не нужны таблицы. Формализовать проверку на грубые ошибки по критерию трёх сигм с точки зрения статистической проверки гипотез можно так:

- нулевая гипотеза H_0: все значения выборки принадлежат одному и тому же нормальному распределению;

- конкурирующая (альтернативная) гипотеза H_1: значения выборки, отстоящие от математического ожидания больше, чем на три сигмы, принадлежат другому распределению.

Однако при многократных измерениях вероятность отклонения хотя бы одного значения выборки от математического ожидания не равна 0,0027 и зависит от объёма выборки n. Так, при известных параметрах нормального распределения вероятность того, что при отсутствии грубых ошибок хотя бы одно значение выборки удовлетворяет условию (1), равна $1-0{,}0973^n$. Эта вероятность соответствуют уровню значимости α – см. табл. 1

Таблица 1

Уровни значимости при известных параметрах нормального распределения, k = 3.

n	α	n	α
3	0,008	10	0,027
4	0,011	15	0,040
5	0,013	25	0,065
6	0,016	40	0,103
7	0,019	50	0,126
8	0,021	60	0,150

На практике параметры распределения чаще всего не известны с достаточной точностью, и используют их выборочные оценки – среднее значение $x_{ср}$ и выборочное СКО (среднеквадратическое отклонение) s. При этом уровни значимости заметно отличаются от тех, когда параметры распределения известны.

$$s = \sqrt{\frac{\sum_{i=1}^{n}(x_i - x_{cp})^2}{n-1}}$$

Здесь x_i - элементы выборки.

Тогда выражение (1), т.е. условие для определения грубых ошибок, превращается в $|x_{cp} - x_i| / s > k$ (2)

Все значения выборки, удовлетворяющие условию (2), считаются грубыми ошибками.

Возможны также ситуации, когда математическое ожидание оценивают по $x_{ср}$, а СКО известно с высокой точностью – например, при оценке дисперсии (и, соответственно, СКО) по сериям измерений. Тогда выражение (1), т.е. условие для определения грубых ошибок, превращается в (3):

$|x_{ср} - x_i| / \sigma > k$ (3)

Все значения выборки, удовлетворяющие условию (3), считаются грубыми ошибками.

Расчёт $x_{ср}$ и s в (2) и (3) может проводиться по двум вариантам:

1) С учётом всех значений выборки.

2) Без учёта сомнительных значений.

Второй вариант более сложен, что в значительной мере уменьшает преимущества критерия трёх сигм по сравнению с другими. Известны более обоснованные критерии выбросов при нормальном распределении, например критерии Граббса, Диксона, Ирвина и другие.

Задание 4. Выполните задание 3, если практически рекомендуется:

1. При неизвестной дисперсии определять грубые ошибки по (2) и значениях k:

k = 3, если n = 20...55

k = 3,5, если n = 56...250

k = 4, если n = 251...1700

k = 4,5, если n = 1701...10000

2.При известной дисперсии определять промахи по (3) и значениях k:

k = 3, если n = 8..40

k = 3,5, если n = 41..200

k = 4, если n = 201..1600

k = 4,5, если n = 1601..10000

Сравните полученные результаты с результатами прошлых заданий и сделайте выводы об эффективности правил, которые известны как правило 3-х сигм.