ДИСЦИПЛИНА	Основы интеллектуального анализа данных
ИНСТИТУТ	Институт технологий управления
КАФЕДРА	Статистики и математических методов в управлении
ГРУППЫ	ГСБО-01-21, ГСБО-01-22,
ВИДЫ УЧЕБНОГО МАТЕРИАЛА	П4. Тема – Решение задачи регрессии по панельным данным средствами языка R
ПРЕПОДАВАТЕЛЬ	Бурцева Т.А.
СЕМЕСТР	5 семестр

Методические указания

В моделях регрессии используются данные трёх типов: 1) пространственные данные (cross-sectional data); 2) временные ряды (time-series data); 3) панельные данные (panel data или longitudinal data). Пространственными данными называется совокупность информации, которая характеризует различные объекты, однако полученной за один и тот же период или момент времени. Пространственные данные являются *выборочной совокупностью* из некоторой генеральной совокупности. Примером пространственных данных может служить комплекс экономической информации по какому-либо предприятию (численность работников, объём производства, размер основных фондов), объёмах потребления продукции определённого вида, данные о ВВП различных стран в каком-либо конкретном году и т. д. Временными данными называется совокупность информации, которая характеризует один и тот же объект, но за разные периоды времени. Отдельно взятый временной ряд можно рассматривать как *выборку из бесконечного ряда значений показателей во времени*. Примером временных данных могут служить данные о динамике индекса потребительских цен, ежедневные обменные курсы валют. Отличия временных данных от пространственных данных:

1) единицы временных рядов подвержены явлению *автокорреляции* (зависимости между прошлыми и текущими наблюдениями временного ряда), т. е. они не являются статистически независимыми в отличие от единиц случайной пространственной выборки;

2) единицы временных рядов *не являются одинаково распределёнными величинами*;

3) в отличие от пространственных данных временные данные естественным образом упорядочены во времени.

Панельными данными называются данные, содержащие сведения об одном и том же множестве объектов за ряд последовательных периодов времени. Панельные данные являются обобщением или комбинацией пространственных и временных данных. Примером панельных данных могут служить показатели хозяйственной деятельности совокупности предприятий, которые собираются каждый год. В этом случае мы получим массив данных, в котором содержатся и данные об однородных объектах за один и тот же период времени, и последовательные значения одной экономической переменной в различные периоды времени. Но если совокупность предприятий из года в год будет различна, то такие данные уже не будут панельными. В отличие от пространственных данных, для обозначения наблюдений панельных данных используют два индекса задающих номер объекта (i) и номер момента или периода времени (t) x_{it}.

Есть несколько причин для использования панельных данных в прикладных исследованиях:

1. Благодаря специальной структуре панельные данные позволяют строить более гибкие и содержательные модели и получать ответы на вопросы, которые недоступны только в рамках, например, моделей, основанных на пространственных данных.

2. Возникает возможность учитывать и анализировать индивидуальные отличия между экономическими единицами, что нельзя сделать в рамках стандартных регрессионных моделей.

3. Увеличение числа наблюдений. Количество доступных наблюдений зависит от того, сбалансированная или несбалансированная панелью. Панель называется сбалансированной, если существует наблюдение для каждого объекта и для каждого момента времени. В этом случае общее число наблюдений равно nT, где n – число объектов, T – число периодов или моментов времени. Когда в данных есть пропуски, панель называется несбалансированной. В этом случае общее число наблюдений меньше, чем nT, однако все равно может оставаться достаточно большим.

4. Возможность отслеживать динамику для множества объектов. Использование панельных данных позволяет анализировать распределение тех или иных эффектов во времени. Например, постепенное изменение потребления сигарет в некоторой стране после принятия антитабачных законов в ряде её регионов.

5. Часто ненаблюдаемые факторы У коррелированы с другими переменными. В рамках моделей регрессии это означает, что ненаблюдаемый фактор является существенной переменной в модели и ее исключение приводит к *смещенным оценкам остальных параметров* модели, что ведет к росту ошибки. Иными словами, модели с панельными данными позволяют получать более точные оценки параметров. Поэтому панельные данные - дополнительный способ устранения эндогенности, так как дают возможность получить *состоятельные оценки коэффициентов* при интересующих нас переменных в условиях, когда на пространственной выборке это невозможно. Такой шанс появляется за счет учета *неоднородности моделируемых объектов*. Чтобы понять, как указанная неоднородность может затруднять оценивание, рассмотрим пример. Представим, что нас интересует ответ на такой вопрос: влияет ли закон, разрешающий гражданам носить с собой личное огнестрельное оружие, на уровень преступности? Ответ на него, действительно, вовсе не очевиден. Сторонники закона утверждают, что его введение позволяет снизить преступность, так как гражданские лица получат шанс защититься от злоумышленников. Их оппоненты возражают, что в результате введения такого закона преступность, наоборот, вырастет из-за избыточного количества огнестрельного оружия на руках у населения и его спонтанного использования. Пусть располагаем панельными данными о регионах некоторой страны, и уровень преступности в них описывается следующим уравнением:

$$Y_{it} = \beta X_{it} + \mu_i + e_{it}$$

Здесь Y_{it} — уровень преступности в регионе i в год t; X_{it} — бинарная переменная, которая равна единице, если в регионе i в год t введен закон, разрешающий гражданам носить личное огнестрельное оружие, и равная нулю в противном случае; e_{it} — это, как обычно, случайные ошибки модели; μ_i — ненаблюдаемая переменная, характеризующая специфические особенности каждого из регионов. Например, культурные или институциональные особенности, которые трудно поддаются измерению. Так как все регионы разные, почти нет шансов полностью учесть их специфику в наблюдаемых контрольных переменных. Поэтому такой фактор в модели наверняка останется. Обратите внимание, что у этой переменной нет индекса t, а есть только индекс i. Так указанные особенности не меняются во времени (или меняются очень медленно, поэтому в рамках исследования могут считаться постоянными). Присутствие переменной μ_i порождает следующую дилемму: с одной стороны, не можем включить её в модель непосредственно, так как она не является наблюдаемой, с другой стороны, если она коррелирована с интересующей нас переменной Y_{it}, то её невключение приведет к несостоятельности оценки коэффициента ß из-за пропуска существенной переменной. Таким образом, неоднородность объектов часто становится причиной эндогенности регрессоров (переменных x). К счастью, панельные данные дают возможность применить простой и хорошо работающий способ решения этой проблемы — использование моделей с фиксированными эффектами.

В данной работе ставится цель освоения функций пакета R, позволяющих строить модели регрессии на основе панельных данных. Основные модели анализа панельных данных:

1. *Объединенная модель панельных данных* (Pooled model) $Y_{it} = ß_{it}X_{it}+e_{it}$ - это обычная линейная модель регрессии, которая не учитывает панельную структуру данных, то есть просто увеличиваем с помощью панельных данных число наблюдений. Зависимая переменная линейно зависит от всех переменных в тот же момент времени. Для поиска оценок параметров можно использовать метод наименьших квадратов. $ß_{it}$ - измеряют частные эффекты вектора объясняющих переменных в момент или период t для x_i.

2. *Модель панельных данных с фиксированными эффектами* (Fixed effect model)

$Y_{it} = \propto_i + ßX_{it}+e_{it}$, где матрица X не включает константу. $\propto_i$ – улавливает эффекты от тех переменных, которые специфичны для i – го объекта, характеризующегося признаками y и $x_1..x_p$. $\propto_i$ рассматриваются как константы, которые разные для i – го объекта.

3. *Модель панельных данных со случайными эффектами* (Random effect model)

$Y_{it} = \propto_i + ßX_{it}+e_{it}+\mu$, μ - свободный член, а $\propto_i$ – случайные величины.

Для построения моделей рассматриваемых моделей используются функции из пакета plm. Данные должны быть подготовлены следующим образом, данные объекта последовательно включают значения переменных за все периоды. Например, мы имеем данные о динамике показателя разработанных передовых производственных технологии на 10000 используемых технологий по ФО (ед.), представленные в табл. 1. И данные о доле инвестиций в основной капитал в ВРП, представленные в табл. 2.

Табл. 1

ФО	СКФО	СЗФО	ЦФО	ЮФО	УФО	РФ	СФО	ПФО	ДФО
2008	47,9	85,2	56,8	28,4	31,0	46,3	70,8	29,9	47,9
2009	25,5	124,7	48,5	31,3	39,6	44,4	62,8	25,7	15,8
2010	30,5	90,2	52,4	34,9	36,5	42,5	39,5	24,7	21,5
2011	59,6	121,3	65,2	46,5	60,9	59,4	91,3	31,2	24,2
2012	43,2	183,1	60,8	47,1	58,3	69,1	101,9	46,6	38,1
2013	131,3	164,4	83,7	35,0	72,9	73,7	78,0	43,6	25,7
2014	120,9	153,0	65,4	39,0	79,7	68,9	69,2	47,6	43,3
2015	98,4	117,0	74,3	58,1	84,4	64,1	50,7	37,2	30,5
2016	55,4	110,4	74,1	61,7	94,8	66,0	51,3	41,6	33,1
2017	79,0	92,8	61,6	59,6	82,6	58,4	56,1	34,8	36,9
2018	97,5	76,4	69,4	80,5	90,6	61,4	59,9	34,6	45,5
2019	107,7	94,2	72,7	92,6	87,9	61,7	51,2	28,5	26,8
2020	179,7	108,5	98,5	107,1	105,2	81,9	55,0	46,1	76,7
2021	228,4	148,6	107,1	97,6	94,5	85,2	46,8	45,4	42,8

Табл. 2

ФО	СКФО	СЗФО	ЦФО	ЮФО	УФО	СФО	ПФО	ДФО
2008	35,7	30,7	18,0	35,2	30,8	27,5	27,9	36,4
2009	34,0	27,3	16,9	35,6	30,7	24,6	26,0	37,6
2010	35,1	28,8	15,6	38,8	29,1	23,5	25,2	35,9
2011	32,6	27,8	15,3	38,9	29,1	25,3	24,1	39,9
2012	33,3	28,3	17,0	39,4	28,7	28,2	25,6	34,9
2013	31,9	25,5	17,4	42,1	28,6	26,1	27,2	29,1
2014	31,3	23,7	17,1	33,4	29,2	24,1	26,0	25,2
2015	27,8	20,0	15,8	28,0	26,0	19,9	24,5	25,2
2016	24,7	20,7	14,6	21,2	27,5	19,0	22,0	25,0
2017	24,3	21,4	15,2	24,7	25,8	18,9	20,5	27,5

2018	25,2	23,4	16,0	23,0	22,8	18,1	18,7	25,8
2019	27,4	19,7	18,4	20,8	22,4	19,8	19,3	27,8
2020	29,8	20,3	19,3	21,3	26,5	21,1	20,7	27,6
2021	27,2	14,3	19,1	19,0	19,4	20,2	18,5	27,5

Сформируем панельные данные, см. табл. 3. У – показатель из табл. 1, Х – показатель из табл. 2.

Табл. 3

ФО	Годы	y	x
СКФО	2008	47,90419	35,7
СКФО	2009	25,51834	34
СКФО	2010	30,46923	35,1
СКФО	2011	59,64215	32,6
СКФО	2012	43,19654	33,3
СКФО	2013	131,3321	31,9
СКФО	2014	120,8594	31,3
СКФО	2015	98,37468	27,8
СКФО	2016	55,35055	24,7
СКФО	2017	79,01065	24,3
СКФО	2018	97,49756	25,2
СКФО	2019	107,6834	27,4
СКФО	2020	179,7386	29,8
СКФО	2021	228,3539	27,2
СЗФО	2008	85,20412	30,7
СЗФО	2009	124,6728	27,3
СЗФО	2010	90,24185	28,8
СЗФО	2011	121,2697	27,8
СЗФО	2012	183,1397	28,3
СЗФО	2013	164,3641	25,5
СЗФО	2014	152,9931	23,7
СЗФО	2015	117,026	20
СЗФО	2016	110,3773	20,7
СЗФО	2017	92,77608	21,4
СЗФО	2018	76,37073	23,4
СЗФО	2019	94,22432	19,7
СЗФО	2020	108,5328	20,3
СЗФО	2021	148,5884	14,3
ЦФО	2008	56,8399	18
ЦФО	2009	48,54369	16,9
ЦФО	2010	52,36058	15,6
ЦФО	2011	65,15742	15,3
ЦФО	2012	60,8319	17
ЦФО	2013	83,67719	17,4
ЦФО	2014	65,40531	17,1
ЦФО	2015	74,29442	15,8
ЦФО	2016	74,05572	14,60
ЦФО	2017	61,5653	15,2
ЦФО	2018	69,36719	16
ЦФО	2019	72,6685	18,4

ЦФО	2020	98,54623	19,3
ЦФО	2021	107,078	19,1
ЮФО	2008	28,36514	35,2
ЮФО	2009	31,30644	35,6
ЮФО	2010	34,87021	38,8
ЮФО	2011	46,53018	38,9
ЮФО	2012	47,14577	39,4
ЮФО	2013	34,98191	42,1
ЮФО	2014	38,97836	33,4
ЮФО	2015	58,06452	28
ЮФО	2016	61,74846	21,2
ЮФО	2017	59,55971	24,7
ЮФО	2018	80,50153	23
ЮФО	2019	92,59259	20,8
ЮФО	2020	107,076	21,3
ЮФО	2021	97,57497	19
УФО	2008	30,9548	30,8
УФО	2009	39,61542	30,7
УФО	2010	36,47505	29,1
УФО	2011	60,8931	29,1
УФО	2012	58,25243	28,7
УФО	2013	72,85438	28,6
УФО	2014	79,71268	29,2
УФО	2015	84,43359	26
УФО	2016	94,82566	27,5
УФО	2017	82,55212	25,8
УФО	2018	90,56452	22,8
УФО	2019	87,87016	22,4
УФО	2020	105,2045	26,5
УФО	2021	94,52363	19,4
СФО	2008	70,78453	27,5
СФО	2009	62,83729	24,6
СФО	2010	39,46488	23,5
СФО	2011	91,25806	25,3
СФО	2012	101,8734	28,2
СФО	2013	77,96122	26,1
СФО	2014	69,18315	24,1
СФО	2015	50,72995	19,9
СФО	2016	51,25143	19,0
СФО	2017	56,14797	18,9
СФО	2018	59,89111	18,1
СФО	2019	51,16834	19,8
СФО	2020	54,98372	21,1
СФО	2021	46,79457	20,2
ПФО	2008	29,9481	27,9
ПФО	2009	25,70259	26
ПФО	2010	24,74126	25,2
ПФО	2011	31,17051	24,1

ПФО	2012	46,56577	25,6
ПФО	2013	43,62604	27,2
ПФО	2014	47,61665	26
ПФО	2015	37,15035	24,5
ПФО	2016	41,56858	22,0
ПФО	2017	34,77512	20,5
ПФО	2018	34,63294	18,7
ПФО	2019	28,46522	19,3
ПФО	2020	46,07703	20,7
ПФО	2021	45,43594	18,5
ДФО	2008	47,92332	36,4
ДФО	2009	15,83873	37,6
ДФО	2010	21,49613	35,9
ДФО	2011	24,15152	39,9
ДФО	2012	38,13021	34,9
ДФО	2013	25,67237	29,1
ДФО	2014	43,32045	25,2
ДФО	2015	30,45133	25,2
ДФО	2016	33,08337	24,9
ДФО	2017	36,92101	27,5
ДФО	2018	45,48408	25,8
ДФО	2019	26,75448	27,8
ДФО	2020	76,70615	27,6
ДФО	2021	42,80822	27,5

Загружаем данные в R-Studio в датафрейм data1.

	ФО	Годы	y	x
1	СКФО	2008	47.90419	35.70000
2	СКФО	2009	25.51834	34.00000
3	СКФО	2010	30.46923	35.10000
4	СКФО	2011	59.64215	32.60000
5	СКФО	2012	43.19654	33.30000

Загружаем пакеты для работы:

```
install.packages("plm")
install.packages("knitr")
install.packages("ggplot2")
library("knitr") # используем Rmarkdown
library("ggplot2") # подключаем ggplot2 (графики), dplyr, tidyr, etc (манипуляции с данными)
library("plm") # работа с панельными данными
#Указываем R, какая переменная отвечает за i, какая — за t.
h <- pdata.frame(data1,
                 index = c("ФО", "Годы"),
                 row.names = TRUE)
```

Все три модели можно записать в виде: $y_{it}=\alpha+x'_{it}\beta+z'_{i\gamma}+c_i+u_{it}$, здесь z_i — вектор характеристик, не меняющихся во времени, а c_i и u_{it} — случайные составляющие, $M(c_i)=0$,

$M(u_{it})=0$. В модели со случайными эффектами (Random Effects, RE) предполагается, что $M(c_i|z_i,X_i)=0$. В модели с фиксированными эффектами (Fixed Effects, FE) допускается, что $M(c_i|X_i)$ зависит от X_i. Модель с фиксированными эффектами не позволяет оценить α и γ. В сквозной регресси (pooling) предполагается, что $c_i=0$.

Построим три модели:

```
m.pooled <- plm(h$y ~ h$x, data = h, model = "pooling")
m.re <- plm(h$y ~ h$x, data = h, model = "random")
m.fe <- plm(h$y ~ h$x, data = h, model = "within")
summary(m.pooled)
```

Ответ:

```
Pooling Model

Call:
plm(formula = h$y ~ h$x, data = h, model = "pooling")

Balanced Panel: n = 8, T = 14, N = 112

Residuals:
   Min.  1st Qu.   Median  3rd Qu.     Max.
-48.1893 -26.0008  -9.4059  18.1344 161.6474

Coefficients:
            Estimate Std. Error t-value Pr(>|t|)
(Intercept) 100.9578    14.7210  6.8581 4.27e-10 ***
h$x          -1.2592     0.5609 -2.2450  0.02677 *
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Total Sum of Squares:    160430
Residual Sum of Squares: 153400
R-Squared:      0.043813
Adj. R-Squared: 0.03512
F-statistic: 5.04021 on 1 and 110 DF, p-value: 0.026765
```

```
summary(m.re)
```

Ответ:

```
Oneway (individual) effect Random Effect Model
   (Swamy-Arora's transformation)

Call:
plm(formula = h$y ~ h$x, data = h, model = "random")

Balanced Panel: n = 8, T = 14, N = 112

Effects:
                  var std.dev share
idiosyncratic 756.53   27.51 0.478
individual    827.65   28.77 0.522
theta: 0.7524

Residuals:
    Min.  1st Qu.   Median  3rd Qu.     Max.
-52.6787 -16.6301  -6.2848  10.2565 138.1846

Coefficients:
             Estimate Std. Error z-value  Pr(>|z|)
(Intercept) 113.73339   17.81806  6.3830 1.736e-10 ***
h$x          -1.76063    0.56609 -3.1101   0.00187 **
---
```

```
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Total Sum of Squares:    89891
Residual Sum of Squares: 82625
R-Squared:      0.080829
Adj. R-Squared: 0.072473
Chisq: 9.67301 on 1 DF, p-value: 0.0018699
```

summary(m.fe)

Ответ:

```
Oneway (individual) effect Within Model

Call:
plm(formula = h$y ~ h$x, data = h, model = "within")

Balanced Panel: n = 8, T = 14, N = 112

Residuals:
    Min.  1st Qu.   Median  3rd Qu.     Max.
-60.4204 -14.3069  -3.5939  10.1053 129.9959

Coefficients:
    Estimate Std. Error t-value Pr(>|t|)
h$x  -1.8264     0.5854 -3.1198 0.002347 **
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Total Sum of Squares:    85286
Residual Sum of Squares: 77922
R-Squared:      0.08634
Adj. R-Squared: 0.015376
F-statistic: 9.73336 on 1 and 103 DF, p-value: 0.0023475
```

Вывод: все модели показали значимость переменной x для описания переменной y (есть *), но недостаточная надежность, которая предполагает поиск новых факторов.

Модель сквозной регрессии (обобщенная) и модель с фиксированными эффектами оцениваются обычным МНК, можно использовать функцию lm.

m.pooled.lm <- lm(h$y ~ h$x, data = h)

m.fe.lm <- lm(h$y ~ h$x + factor(ФО), data = h).

Проведём три теста на сравнение моделей.

1. Фиксированные эффекты против сквозной регрессии. Обычный F-тест.
2. Фиксированные эффекты против случайных эффектов. Тест Хаусмана.
3. Случайные эффекты против сквозной регрессии. Тест Бройша-Пагана, является одним из тестов множителей Лагранжа.

1. Фиксированные эффекты против сквозной регрессии. Обычный F-тест.

pFtest(m.fe, m.pooled)

Ответ:

```
F test for individual effects

data:  h$y ~ h$x
F = 14.252, df1 = 7, df2 = 103, p-value = 7.876e-13
alternative hypothesis: significant effects
```

Вывод: нулевая гипотеза о верной обобщенной модели отвергается в пользу модели с фиксированными эффектами (p-value<0,05).

2. Фиксированные эффекты против случайных эффектов. Тест Хаусмана.

phtest(m.fe, m.re)

Ответ:

```
Hausman Test

data:  h$y ~ h$x
chisq = 0.1943, df = 1, p-value = 0.6594
alternative hypothesis: one model is inconsistent
```

Вывод: нулевая гипотеза о состоятельности коэффициентов в обеих моделях (FE и RE) отвергается в пользу гипотезы о том, что в RE модели коэффициенты несостоятельны.

3. Случайные эффекты против сквозной регрессии. Тест Бройша-Пагана, является одним из тестов множителей Лагранжа.

```
plmtest(m.re, type = "bp")
```

Ответ:

```
Lagrange Multiplier Test - (Breusch-Pagan)

data:  h$y ~ h$x
chisq = 146.09, df = 1, p-value < 2.2e-16
alternative hypothesis: significant effects
```

Вывод: нулевая гипотеза о верности сквозной регрессии, то есть о том, что c_i тождественно равны 0, отвергается. Лучшая модель с фиксированными эффектами. Посмотрим расхождение по объектам эффектов с помощью функции `fixef`:

```
fixef(m.fe)
    ДФО     ПФО     СЗФО     СКФО     СФО      УФО      ЦФО      ЮФО
 91.833  79.518 162.573 148.035 104.431 121.897 101.490 113.489
```

Выполним функцию summary(fixef(m.fe))

Ответ:

```
      Estimate Std. Error t-value  Pr(>|t|)
ДФО    91.833     19.247  4.7714 6.056e-06 ***
ПФО    79.518     15.495  5.1319 1.357e-06 ***
СЗФО  162.573     15.706 10.3507 < 2.2e-16 ***
СКФО  148.035     19.049  7.7714 6.071e-12 ***
СФО   104.431     15.132  6.9013 4.314e-10 ***
УФО   121.897     17.379  7.0140 2.504e-10 ***
ЦФО   101.490     12.295  8.2545 5.400e-13 ***
ЮФО   113.489     19.091  5.9447 3.819e-08 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1
```

Вывод: влияние на У фиксированного эффекта больше всего в СКФО (отклонения от среднего).

Функция ranef показывает, на сколько выше или ниже находится регрессионная прямая в каждом округе ranef(m.re), то есть исследуем влияние случайных эффектов.

Ответ:

```
ranef(m.re)
       ДФО        ПФО        СЗФО        СКФО        СФО        УФО
-22.433412 -33.556318  44.383764  30.347037 -10.126660   6.003608
       ЦФО        ЮФО
-12.531506  -2.086514
```

Вывод: выше регрессионная прямая в СКФО и СЗФО, УФО, то есть в этих округах ситуация лучше, чем в среднем по всем ФО.

Задание:

1. Проверьте данные примера на выбросы с помощью критерия Ирвина.
2. Выполните очистку данных от выбросов.
3. Постройте модели по данным примера и исследуйте их на основе критериев, охарактеризованных в примере.
4. Предложите новые факторы в модель примера, выполнив его самостоятельно, которые улучшат одну из моделей или каждую, добейтесь R^2 больше 0,75.