МИНИСТЕРСТВО ОБРАЗОВАНИЯ РОССИЙСКОЙ ФЕДЕРАЦИИ

Московский государственный университет экономики, статистики и информатики
Московский международный институт эконометрики, информатики, финансов и права

Трошин Л.И.
Балаш В.А.
Балаш О.С.

Статистический анализ нечисловой информации

Москва 2001

Трошин Л.И., Балаш В.А., Балаш О.С. Статистический анализ нечисловой информации. / Московский государственный университет экономики, статистики и информатики. – М., 2001. – 67 с.

© Трошин Л.И., 2001 г.
© Балаш В.А., 2001 г.
©Балаш О.С., 2001 г.
©Московский государственный университет экономики, статистики и информатики, 2001 г.

Содержание

Введение 4

1. Исследование двумерной таблицы сопряженности 5

1.1 Таблица сопряженности 2×2 5

1.2 Проверка независимости таблицы 2×2 6

1.3 Тренировочный пример 9

1.4 Точный критерий Фишера 11

1.5 Тренировочный пример 12

2. Таблица сопряженности размером r×s 14

2.1 Тренировочный пример 22

2.2 Разбиение хи-квадрат 26

2.3 Тренировочный пример (продолжение 1.2.1.) 26

3. Таблица сопряженности 2×2×2 28

3.1 Методы анализа таблиц с тремя входами 28

3.2 Тренировочный пример 30

4. Логлинейный анализ 32

4.1 Модель логлинейного анализа 32

4.2 Оценка параметров насыщенной модели для таблиц 2×2 33

4.3 Оценка параметров ненасыщенных моделей для таблиц 2×2 34

4.4 Иерархические модели 37

4.5 Тренировочный пример 38

5. Логлинейные модели многомерных таблиц сопряженности 44

5.1 Основные понятия логлинейного анализа 44

5.2 Логлинейные модели для таблиц сопряженности 2×2×2 46

5.3. Тренировочный пример 56

6. Вопросы для повторения 62

Заключение 64

Список рекомендуемой литературы 65

Приложения 66

Введение

Измерение статистических показателей может производиться в шкалах различных типов. Отношения между изучаемыми объектами определяют шкалы показателей.

По функциональным особенностям различают следующие основные типы шкал измерения: номинальную, порядковую, количественную. Им соответствуют допустимые преобразования показателей, то есть такие, при которых фиксированные соотношения между объектами сохраняются. К числу преобразований, характеризующих основные типы шкал, относятся преобразования подобия, сдвига, линейное, монотонное и взаимно однозначное преобразования. Чем выше тип шкалы измерения, тем уже класс допустимых преобразований.

Номинальная шкала (шкала наименований) представляет собой простое перечисление различающихся между собой явлений или объектов. Объекты могут быть только пронумерованы, причем цифры, присваиваемые различным градациям, служат лишь для отличий их друг от друга. Единственными отношениями между объектами, располагаемыми по номинальной шкале, выступают отношения тождества и отличия. Номера градаций могут быть изменены произвольным образом. Например, переменная «овощ» может иметь наименования «картофель», «морковь», «капуста», которые можно записать в любом порядке.

Если категории признака можно упорядочить друг относительно друга, то в этом случае строится порядковая шкала. Присвоенные изучаемой переменной ранги должны соответствовать изменению у объектов интенсивности изучаемого признака. Однако порядковая шкала не устанавливает насколько одна градация отличается от другой. Например, переменная «возраст» может иметь категории «меньше 10 лет», «11– 20», «21–30» и «старше 30», которые не имеет смысла записывать в другом порядке.

Количественная шкала устанавливает не только отношения порядка, но и величину интервалов между градациями.

Каждому типу шкал соответствуют специфические методы исследования. Данное пособие посвящено рассмотрению способов изучения взаимосвязей показателей, измеренных в номинальной шкале.

1. Исследование двумерной таблицы сопряженности

1.1 Таблица сопряженности 2×2

При проведении социологических обследований массив данных содержит большое число вопросов. Так опрашивая респондентов по тем или иным событиям, происходящим в стране, выясняют их политические взгляды, социальный статус, пол, возраст и т.п. Однако на практике анализ начинается с рассмотрения пары признаков.

Две переменные X и Y называются ***дихотомическими,*** если они принимают по два различных значения X: A и не A, и два различных значения Y: B и не B соответственно. Следовательно, имеется четыре вида ответа (отклика) со следующими сочетаниями значений переменных: (не A, не B), (не A, B), (A, не B), (A, B).

Значениям дихотомического признака можно присвоить произвольные числовые метки. Будем обозначать наличие признака – единицей, а его отсутствие – нулем.

Распределение двух таких случайных величин X и Y при условии, что признаки дихотомические, можно изобразить в виде ***таблицы сопряженности*** **2×2.**

X \ Y	**0, не B**	**1, B**	$\mathbf{p_x}$
0, не A	p_{11}	p_{12}	p_{1*}
1, A	p_{21}	p_{22}	p_{2*}
$\mathbf{p_y}$	p_{*1}	p_{*2}	p_{**}

где: X – единица совокупности либо обладает признаком A, либо не обладает признаком A;

Y – единица совокупности либо обладает признаком B, либо не обладает признаком B;

p_{ij} – генеральная доля (вероятность) элементов совокупности, образующих i-категорию по признаку X и j-категорию (класс) по признаку Y;

i=1,2; j=1,2 номера классов, строк и столбцов таблицы;

p_{11} – вероятность случайно взятому элементу попасть в категории не A и не B;

p_{12} – вероятность случайно взятому элементу попасть в категории не A и B;

$p_{1*} = p_{11} + p_{12}$ – генеральная доля элементов, не обладающих свойством A (неважно, принадлежат ли элементы не B или B);

$p_{2*} = p_{21} + p_{22}$ – генеральная доля элементов, не обладающих свойством A; учитывая, что $p_{1*} + p_{2*}=1$, имеем

$p_{2*} = 1 - p_{1*}$.

Частное одномерное распределение по X имеет вид:

x	**0**	**1**
$\mathbf{p_x}$	p_{1*}	p_{2*}

Аналогично определяется частное одномерное распределение по Y.

y	**0**	**1**
$\mathbf{p_y}$	p_{*1}	p_{*2}

Возьмем выборку объемом n, каждое наблюдение занесем в соответствующие клетки таблицы.

n_{ij} – это наблюдаемая частота респондентов, попавших в ячейку (A_i,B_j).

Рассчитаем для этой таблицы частоты частных распределений, называемые ***маргинальными частотами*** n_{*1}, n_{*2}, n_{1*}, n_{2*}, общий объем выборки $n_{**} = n$.

В результате получим выборочную таблицу сопряженности:

X Y	не B	B	n_{i*}
не A	n_{11}	n_{12}	n_{1*}
A	n_{21}	n_{22}	n_{2*}
n_{*j}	n_{*1}	n_{*2}	$n_{**}=n$

При анализе такой таблицы возникают два вопроса:
1. Зависимы ли переменные X и Y друг от друга или нет.
2. Если они зависимы, то как определить силу этой связи.

1.2 Проверка независимости таблицы 2×2

Обычно на практике применяют три метода отбора в выборку. В результате этого проверяют три гипотезы о независимости.

1 схема. Называется *перекрестным (cross-sectional) отбором*. Состоит в том, что из некоторой совокупности выбирается n объектов и для каждого признака устанавливается присутствуют или отсутствуют у него признаки A и B. До сбора данных назначается размер выборки.

Например, при изучении зависимости между весом новорожденного и возрастом матери все роды в родильном доме классифицируют в зависимости от веса ребенка и возраста матери.

Если A и B независимы, то ожидаем, что доля в категории не B тех, кто одновременно принадлежит и категории не A, должна быть такой же, как и доля тех в категории B, кто принадлежит не A.

Математически это означает, что выполняются соотношения:

$$\frac{p_{11}}{p_{*1}} = \frac{p_{12}}{p_{*2}} = \frac{p_{1*}}{p_{**}} = p_{1*},$$

т.е. $p_{11}=p_{1*}p_{*1}$. Аналогично, генеральные доли элементов, принадлежащих к категории не В не должны зависеть от их расположения в категории А, то есть: $\frac{p_{11}}{p_{1*}} = \frac{p_{21}}{p_{2*}} = p_{*1}$ или $p_{11} = p_{*1}p_{1*}$.

Таким образом, проверяется нулевая гипотеза независимости

$$H_0:\{ \forall\ i, j\ \ p_{ij} = p_{i*}p_{*j} \}$$

против гипотезы $H_1:\{ \exists\ i, j : p_{ij} \neq p_{i*}p_{*j} \}$, i=1,2; j=1,2.

Иными словами, для i =1,2; j = 1,2 достаточно проверить нулевую гипотезу $H_0:\{ p_{11}=p_{1*}p_{*1} \}$ для левой верхней клетки или
$H_0:\{ p_{12} = p_{1*}p_{*2} \}$ для клетки (1,2) и т.д.

Для нашего примера гипотеза о независимости состоит в том, что вес ребенка независим от возраста матери.

2 схема. Называется *целевым отбором* и состоит в том, что для анализа отбирается заранее установленное число n_{1*} объектов, которые имеют признак А и заранее установленное число n_{2*} объектов, не имеющих признака А. В этом случае сравнивают генеральные доли элементов этих совокупностей, образующих один и тот же класс по всем подклассам.

Например, выбираем две группы людей, для которых заранее известно, что n_{1*} – количество здоровых людей и n_{2*} – больных людей. Далее выясняется, какое количество индивидуумов в каждой из групп ранее имело исследуемый фактор риска.

Проверяется *гипотеза однородности*:

$$H_0:\{ p_{ij} = p_{*j} = p_j \text{ для всех } i, j\}$$

против гипотезы $H_1:\{ p_{ij} \neq p_{*j}$ *, хотя бы для одного i, j; i,j=1,2}*.

3 схема. В этом случае противопоставляются две выборки заранее определенного размера, но при условии, что они формируются случайно (в отличии от схемы 2).

Например, из общего числа больных n_{1*} отбирают случайно и лечат обычным способом, а n_{2*} больных лечат способом, эффективность которого исследуется.

Проверяется *гипотеза мультипликативности*:

$$H_0:\{\forall i, j,\ \ n_{ij}^{*} = \frac{n_{i*} \cdot n_{*j}}{n_{**}}\}$$

против гипотезы $H_1: \{ \exists\ i, j,\ \ n_{ij}^{*} \neq \frac{n_{i*} \cdot n_{*j}}{n_{**}} \}$ i=1,2; j=1,2.

Теоретические частоты, то есть которые были бы при истинности гипотезы H_0 о независимости признаков X и Y, вычисляются:

$$n_{ij}^{*} = \frac{n_{i*} \cdot n_{*j}}{n_{**}}.$$

Для проверки независимости признаков X и Y при достаточно больших значениях n применяют χ^2 (хи-квадрат) критерий для числа степеней свободы ν=1, статистика распределения которого имеет вид:

$$\chi^2_{набл} = \sum_{i=1}^{2}\sum_{j=1}^{2}\frac{(n_{ij} - n^*_{ij})^2}{n^*_{ij}}\ , \qquad (1.1)$$

где n_{ij} – наблюдаемые частоты.

Если значение $\chi^2_{набл}$ попало в критическую область: $\chi^2 > \chi^2_{крит}(\alpha, \nu=1)$, нулевая гипотеза отвергается с вероятностью ошибки α и признаки считаются зависимыми.

В этом случае имеет смысл измерить полученную связь между χ и Y с помощью коэффициентов связи (сопряженности).

Рассмотрим коэффициенты связи.

Коэффициент ассоциации (коэффициент Юла):

$$Q = \frac{n_{11}n_{22} - n_{21}n_{12}}{n_{11}n_{22} + n_{21}n_{12}}. \qquad (1.2)$$

Коэффициент обладает свойствами коэффициента корреляции, т.е. изменяется от –1 до 1. Если Q > 0, то связь положительна – с увеличением χ признак Y увеличивается. Если Q < 0, то связь отрицательная. Коэффициент Юла равен нулю, если признаки независимы. Он равен единице, в случае полной связи признаков, то есть $n_{11} = n_{1*}$ и $n_{22} = n_{2*}$ и минус единице, если признаки взаимообратны, то есть $n_{21} = n_{2*}$ и $n_{12} = n_{1*}$.

***Коэффициент коллигации*:**

$$Y = \frac{\sqrt{n_{11}n_{22}} - \sqrt{n_{12}n_{21}}}{\sqrt{n_{11}n_{22}} + \sqrt{n_{12}n_{21}}} \qquad (1.3)$$

Коэффициенты ассоциации и коллигации связаны соотношением: $Q = \frac{2Y}{1+Y^2}$.

Коэффициенты ассоциации и коллигации не изменяются при умножении любой строки или столбца таблицы на произвольную положительную константу. Доказано, что подобным свойством обладают коэффициенты, являющиеся функцией лишь величины ***отношения преобладаний***:

$$O_n = \frac{n_{11}}{n_{21}} : \frac{n_{12}}{n_{22}} = \frac{n_{11}n_{22}}{n_{21}n_{12}}. \qquad (1.4)$$

Величину n_{11}/n_{21} можно называть ***преобладанием*** категории не А, над категорией А, в ответах индивидов из категории не В. Аналогично n_{12}/n_{22} есть ***преобладание*** ответов не А у индивидов из категории В. Отношение преобладаний также называют ***отношением перекрестных произведений*.**

Коэффициент контингенции:

$$V = \frac{n_{11}n_{22} - n_{12}n_{21}}{\sqrt{n_{1*}n_{2*}n_{*1}n_{*2}}}. \qquad (1.5)$$

Справедлива формула $\chi^2 = nV^2$. Коэффициент контингенции равен коэффициенту корреляции между X и Y. Его квадрат не больше квадрата коэффициента ассоциации.

Можно улучшить критерий χ^2 (с поправкой на непрерывность):

$$\chi^{2}_{*} = \frac{n(|n_{11}n_{22} - n_{12}n_{21}| - \frac{1}{2}n)^2}{n_{1*}n_{2*}n_{*1}n_{*2}} \qquad (1.6)$$

Поскольку критерий χ^2 служит основой для проверки независимости, то его значение используют в качестве меры связи.

Коэффициент Чупрова-Крамера:

$$\varphi = \sqrt{\frac{\chi^2}{n}} = |V| \ ; \qquad (1.7)$$

Коэффициент сопряженности Пирсона:

$$P = \sqrt{\frac{\chi^2}{\chi^2 + n}} = \sqrt{\frac{\varphi^2}{1 + \varphi^2}}. \qquad (1.8)$$

Эти коэффициенты изменяются от 0 до 1.

Для оценки силы связи для таблиц сопряженности 2×2 также применяют τ ***-коэффициент***, предложенный Гудменом и Краскалом:

$$\tau = \frac{(n_{11}n_{22} - n_{12}n_{21})^2}{n_{1*}n_{2*}n_{*1}n_{*2}} = V^2, \qquad (1.9)$$

являющийся коэффициентом детерминации между X и Y, τ изменяется от 0 до 1.

1.3 Тренировочный пример

Получено выборочное распределение отношения респондентов к покупке товара «А» в зависимости от пола. Результаты приведены в таблице:

	мужчины	**женщины**	$\mathbf{n_{i*}}$
Купили	35	15	50
Не купили	10	30	40
$\mathbf{n_{*j}}$	45	45	90

Для проверки независимости признаков «Пол» и «Покупка товара» проверяем нулевую гипотезу H_0:{ $p_{ij} = p_{i*}p_{*j}$ для всех i, j}. Вычислим статистику $\chi^2_{набл}$ по формуле (1.1).

Для этого рассчитаем теоретические частоты по формуле $n_{ij}^{*}=\frac{n_{i*}\cdot n_{*j}}{n_{**}}$ для всех клеток таблицы.

$$n_{11}^{*}=\frac{n_{1*}\cdot n_{*1}}{n_{**}}=\frac{50\cdot 45}{90}=25;$$

$$n_{12}^{*}=\frac{n_{1*}\cdot n_{*2}}{n_{**}}=\frac{50\cdot 25}{90}=25;$$

$$n_{21}^{*}=\frac{n_{2*}\cdot n_{*1}}{n_{**}}=\frac{40\cdot 45}{90}=20;$$

$$n_{22}^{*}=\frac{n_{2*}\cdot n_{*2}}{n_{**}}=\frac{40\cdot 25}{90}=20.$$

Получим таблицу сопряженности теоретических частот распределения:

	Мужчины	**Женщины**	$\mathbf{n_{i*}}$
Купили	25	25	50
Не купили	20	20	40
$\mathbf{n_{*j}}$	45	45	90

Вычислим статистику χ^2:

$$\chi^2_{набл}=\sum_{i=1}^{2}\sum_{j=1}^{2}\frac{(n_{ij}-n_{ij}^{*})^2}{n_{ij}^{*}}=\frac{(35-25)^2}{25}+\frac{(15-25)^2}{25}+\frac{(10-20)^2}{20}+$$

$$+\frac{(30-20)^2}{20}=18\ .$$

По таблице χ^2-распределения (прил. 2) находим:

$$\chi^2_{крит}(0{,}05;\ 1)=3{,}841.$$

Критическая область имеет вид $\chi^2 > \chi^2_{крит}$. Так как вычисленное значение хи-квадрат попадает в критическую область, то гипотеза о независимости отвергается с вероятностью ошибки 0,05.

Воспользуемся критерием χ^2_{*} (1.6):

$$\chi^2_{*}=\frac{n(|n_{11}n_{22}-n_{12}n_{21}|-\frac{1}{2}n)^2}{n_{1*}n_{2*}n_{*1}n_{*2}}=\frac{90(|35\cdot 30-15\cdot 30|-45)^2}{50\cdot 40\cdot 45\cdot 45}=16{,}245.$$

Сравнив $\chi^2_{*набл}$ с $\chi^2_{крит}$, 16,245>3,841, также отвергаем гипотезу о независимости.

Определим силу связи по формулам (1.2) и (1.3).

Коэффициент ассоциации:

$$Q=\frac{n_{11}n_{22}-n_{21}n_{12}}{n_{11}n_{22}+n_{21}n_{12}}=\frac{35\cdot 30-10\cdot 15}{35\cdot 30+10\cdot 15}=0{,}75\ .$$

Коэффициент коллигации:

$$Y=\frac{(n_{11}n_{22})^{1/2}-(n_{12}n_{21})^{1/2}}{(n_{11}n_{22})^{1/2}+(n_{12}n_{21})^{1/2}}=\frac{\sqrt{35\cdot 30}-\sqrt{10\cdot 15}}{\sqrt{35\cdot 30}+\sqrt{10\cdot 15}}=0{,}46.$$

Коэффициент контингенции возможно выразить через χ^2.

$$V=\frac{n_{11}n_{22}-n_{21}n_{12}}{\sqrt{n_{1*}n_{2*}n_{*1}n_{*2}}}=0{,}447.$$

Рассчитаем коэффициенты φ (1.7) и Пирсона (1.8):

$$\varphi=\sqrt{\frac{\chi^2}{n}}=\sqrt{\frac{18}{90}}=0{,}447;$$

$$P=\sqrt{\frac{\chi^2}{n+\chi^2}}=\sqrt{\frac{18}{90+18}}=0{,}408;$$

τ - коэффициент (1.9):

$$\tau=\frac{(35\cdot 30-10\cdot 15)^2}{45\cdot 45\cdot 50\cdot 40}=0{,}2.$$

Таким образом, связь между желанием приобрести товар «А» и полом средняя.

1.4 Точный критерий Фишера

Предложенные критерии относятся к критериям, имеющим лишь приближенное распределение χ^2. Ими можно пользоваться, когда ожидаемые частоты в ячейках велики, а также при относительно малых ожидаемых частотах. Однако, если частоты малы (5 или меньше), то критерий дает большую ошибку. В этом случае следует применить *точный критерий независимости Фишера*.

Пусть одна из фиксированных маргинальных частот n_{*1}, n_{*2}, n_{1*}, n_{2*} достаточно мала. Тогда следует ожидать, что соответствующие частоты, дающие сумму по строке или по столбцу эту маргинальную частоту, могут оказаться меньше 5. Для распределения этой частоты справедлив гипергеометрический закон. Согласно этому закону вычисляют вероятность того, что n_{ij} примет конкретное значение при фиксированных суммах по столбцам и строкам по формуле:

$$P\{n_{ij}\,|\,n_{1*},n_{2*},n_{*1},n_{*2}\}=\frac{n_{1*}!\cdot n_{2*}!\cdot n_{*1}!\cdot n_{*2}!}{n!\cdot n_{11}!\cdot n_{12}!\cdot n_{21}!\cdot n_{22}!} \qquad (1.10)$$

Критерий Фишера основан на рассмотрении всех случаев расположения данных, какие только возможны и вычисления вероятности каждого из них. При этом критическая область состоит из тех, близких к нулю или максимальному возможному для выбранной клетки значению наблюдаемых частот, для которых сумма вероятностей не превосходит α.

Применение критерия рассмотрим на примере.

1.5 Тренировочный пример

Установить, существует ли зависимость между невыходами автобусов на маршрут Y и работой коллективов двух автоколонн X на основании выборочных данных:

X Y	невыход	выход	n_{i*}
N1	1	49	50
N2	7	63	70
n_{*j}	8	112	120

Так как значение частоты для клетки таблицы (1,1) мало, то для проверки гипотезы о независимости невыходов автобусов для разных колонн применяем точный критерий Фишера (1.10).

Минимальная маргинальная частота

$$\text{Min}[(n_{*1}, n_{*2}, n_{1*}, n_{2*}) = (8, 112, 50, 70)] = 8.$$

Ей соответствует минимальное значение в клетке n_{11}. Поэтому в качестве случайной величины возьмем n_{11}.

Расчет вероятностей будем производить по формуле:

$$P\{n_{11} | n_{1*}, n_{2*}, n_{*1}, n_{*2}\} = \frac{n_{1*}! \cdot n_{2*}! \cdot n_{*1}! \cdot n_{*2}!}{n! \cdot n_{11}! \cdot n_{12}! \cdot n_{21}! \cdot n_{22}!}.$$

Вычислим вероятность $P_8(1)$ по исходной таблице:

$$P_8(1) = \frac{50! \cdot 70! \cdot 8! \cdot 112!}{1! \cdot 49! \cdot 7! \cdot 63! \cdot 120!} = 0{,}071333.$$

Исчислим соответствующие вероятности для частоты n_{11} изменяющейся от 0 до 8. При неизменных маргинальных частотах имеем следующее распределение частот (n_{11}=0):

X Y	невыход	выход	n_{i*}
N1	0	50	50
N2	8	62	70
n_{*j}	8	112	120

$$P_8(0) = \frac{50! \cdot 70! \cdot 8! \cdot 112!}{0! \cdot 50! \cdot 8! \cdot 62! \cdot 120!} = 0{,}0112350.$$

Изменим частоту в ячейке n_{11} на 2 и найдем соответствующую вероятность.

X Y	невыход	выход	n_{i*}
N1	2	48	50
N2	6	64	70
n_{*j}	8	112	120

$$P_8(2) = \frac{50! \cdot 70! \cdot 8! \cdot 112!}{2! \cdot 48! \cdot 6! \cdot 64! \cdot 120!} = 0{,}1911512.$$

Аналогично определим остальные вероятности.

X Y	невыход	выход	n_{i*}
N1	3	47	50
N2	5	65	70
n_{*j}	8	112	120

$P_8(3)=0, 2829156$ и т.п.

Получим следующее распределение:

N_{11}	0	1	2	3	4	5	6	7	8
$P(n_{11})$	0,0112	0,0713	0,1912	0,2830	0,2513	0,138	0,0457	0,0083	0,0000

Для n=0; 7; 8 сумма вероятностей меньше, чем α = 0,05. Таким образом, критическая область состоит из точек: {0; 7; 8}.

Наблюдаемое значение n_{11} = 1 не попадает в критическую область.

Следовательно, нулевая гипотеза о том, что парки работают одинаково, не отвергается, то есть не существует зависимости между невыходами автобусов на маршрут и работой коллективов автоколонн.

При вычислении вероятностей с помощью точного критерия Фишера при больших значениях факториалов сталкиваются с трудностями вычислительного характера. Чтобы этого избежать, при некоторых условиях, можно воспользоваться приближениями, основанными на том, что гипергеометрический закон можно заменить нормальным законом распределения вероятностей со следующими параметрами:

математическим ожиданием $\mu = M(n_{ij}) = \dfrac{n_{i*}n_{*j}}{n_{**}}$

и дисперсией $D(n_{ij}) = \dfrac{n_{1*}n_{*1}n_{2*}n_{*2}}{n^2(n-1)}$.

Тогда стандартизованная нормальная величина T имеет вид:

$$T = \frac{n_{ij} - n_{ij}^*}{\sqrt{\dfrac{n_{1*}n_{*1}n_{2*}n_{*2}}{n^2(n-1)}}}.$$

В результате для двухсторонней критической области можно воспользоваться формулой:

$$n_{кр1} = \mu - t_{крит}\sigma = \frac{n_{i*}n_{*j}}{n} - t_{крит}\sqrt{\frac{n_{1*}n_{*1}n_{2*}n_{*2}}{n^2(n-1)}},$$

$$n_{кр2} = \mu + t_{крит}\sigma = \frac{n_{i*}n_{*j}}{n} + t_{крит}\sqrt{\frac{n_{1*}n_{*1}n_{2*}n_{*2}}{n^2(n-1)}},$$

где $t_{крит} = \Phi^{-1}(1-\alpha)$ – аргумент функции нормального закона распределения вероятности (прил. 1).

2. Таблица сопряженности размером r×s

Пусть признак X имеет r категорий, а признак Y s категорий. Тогда теоретическая или генеральная таблица сопряженности будет иметь вид:

Таблица 2.1

X \ Y	1	2	... j ...	s	p_{i*}
1	p_{11}	p_{12}	... p_{1j} ...	p_{1s}	p_{1*}
2	p_{21}	p_{22}	... p_{2j} ...	p_{2s}	p_{2*}
.					
.					
.					
I	p_{i1}	p_{i2}	... p_{ij} ...	p_{is}	p_{i*}
.					
.					
.					
R	p_{r1}	p_{r2}	... p_{rj} ...	p_{rs}	p_{r*}
p_{*j}	p_{*1}	p_{*2}	. .. p_{*j} ...	p_{*s}	p_{**}

x_i - i -ая категория признака X;

y_j - j- ая категория признака Y;

p_{ij} - вероятность случайно выбранному элементу совокупности попасть в клетку $(x_i ; y_j)$.

Вместо вероятностных таблиц сопряженности можно использовать ***выборочную таблицу сопряженности размером r×s*** в следующем виде:

Таблица 2.2

X \ Y	1	2	... j ...	s	n_{i*}
1	n_{11}	n_{12}	... n_{1j} ...	n_{1s}	N_{1*}
2	n_{21}	n_{22}	... n_{2j} ...	n_{2s}	N_{2*}
.					
.					
.					
I	n_{i1}	n_{i2}	... n_{ij} ...	n_{is}	n_{i*}
.					
.					
.					
R	n_{r1}	n_{r2}	... n_{rj} ...	n_{rs}	n_{r*}
N_{*j}	n_{*1}	n_{*2}	... n_{*j} ...	n_{*s}	n_{**}

Частоты в ячейках таблицы обозначим n_{ij},а суммы по строкам и столбцам n_{i*} ,n_{*j} соответственно, $n = n_{**}$ – общее число наблюдений.

По аналогии с таблицами сопряженности 2×2 возможны различные схемы построения таблиц сопряженности и проверки гипотез о независимости.

Схема 1 – проверка независимости.

Проверяется гипотеза независимости

$$H_0:\{ p_{ij} = p_{i*}p_{*j} \text{ для всех } i, j\}$$

против гипотезы $H_1:\{ p_{ij} \neq p_{i*}p_{*j}$,*если* $\exists\ i, j\}$.

Схема 2 – проверка однородности.

Проверяется гипотеза однородности:

$$H_0:\{ p_{ij} = p_{*j} = p_j \text{ для всех } i, j\}$$

против гипотезы $H_1:\{ p_{ij} \neq p_{*j}$, *если* $\exists\ i, j\}$.

Схема 3. Проверяется гипотеза мультипликативности:

$H_0:\{\forall i, j\ n_{ij} = \frac{n_{i*}n_{*j}}{n}\}$ против гипотезы H_1: $\{ \exists\ i, j,\ n_{ij} \neq \frac{n_{i*}n_{*j}}{n}\}$.

В этом случае общее число наблюдений рассматривается как случайная величина.

Все три гипотезы проверяются с помощью критерия χ^2, который основан на следующих предположениях.

Если бы два изучаемых показателя были статистически независимы, то частота в клетке на пересечении i-ой строки и j-го столбца была бы равна $n_{ij}^* = \frac{n_{i*}n_{*j}}{n}$. На измерении отклонений фактических частот от теоретических n^*_{ij} построены критерии проверки гипотезы независимости номинальных признаков, применяемых для всех схем построения таблиц.

В общем случае проверяется гипотеза о независимости:

$$H_0 :\{ n_{ij}^* = \frac{n_{i*}n_{*j}}{n};\ i=1,...r;\ j=1,...s\}.$$

Отклонение от независимости в каждой клетке таблицы может быть вычислено: $D_{ij} = n_{ij} - \frac{n_{i*}n_{*j}}{n}$.

Если верна гипотеза о независимости, то величина

$$\chi^2 = \sum_{ij} \frac{D_{ij}^2}{n_{i*} \cdot n_{*j} / n} = n \cdot \left(\sum_{ij} \frac{n_{ij}^2}{n_{i*} \cdot n_{*j}} - 1\right) \qquad (2.1)$$

имеет хи-квадрат распределение с $(r - 1)(s - 1)$ степенями свободы.

Для проверки независимости может также использоваться *информационный критерий (критерий максимального правдоподобия)*:

$$\chi^2_{И'тм} = 2 \cdot \sum_{ij} n_{ij} \ln(n_{ij} / \frac{n_{i*}n_{*j}}{n}), \qquad (2.2)$$

также имеющий закон распределения χ^2 с тем же числом степеней свободы (r–1)(s–1).

На практике редко встречаются большие расхождения между χ^2 и $\chi^2_{инф}$. Данные критерии основаны на предположении о достаточной заполненности ячеек таблицы, каждое из чисел в ячейках должно быть больше 5.

После выбора уровня значимости, т.е. вероятности того, что при гипотезе независимости величина $\chi^2_{факт}$ превысит конкретное число $\chi^2_{крит}$, определяемое уровнем значимости α и числом степеней свободы ν, необходимо найти по таблице хи-квадрат распределения $\chi^2_{крит}$ и сравнить вычисленную по формуле (2.1) или (2.2) величину $\chi^2_{факт}$ с $\chi^2_{крит}$ (α,ν). Если $\chi^2_{факт}$ больше $\chi^2_{крит}$, то с заданным уровнем значимости гипотеза отвергается, если меньше, то принимается.

Существует приближенный графический тест для проверки гипотезы H_0. Для каждой градации первого признака j, j=1,.., s, на графике откладываются точки с координатами (n_{i*}, n_{*j}). Если гипотеза верна, то нанесенные точки группируются вокруг линии, проходящей через начало координат с наклоном n_{*j} /n. Вероятность выхода некоторой точки за пределы интервала

$$\pm 2(n_{i*} \cdot \frac{n_{*j}}{n}(1-\frac{n_{*j}}{n}))^{1/2}$$

не более 0,05. Использование такого графического представления позволяет локализовать пары (i, j), в которых наблюдаемые частоты значимо отличаются от величин n^*_{ij}.

Если гипотеза о независимости признаков отвергнута, то есть признаки связаны между собой, необходимо количественно измерить силу этой взаимосвязи. Применение для этого величины критерия χ^2 неудобно, так как, во-первых, она зависит от числа строк и столбцов таблицы, и, во-вторых, изменяется на интервале от нуля до бесконечности.

Для таблиц r×s наиболее часто используются коэффициенты Пирсона, Крамера, Чупрова, λ и τ-меры Гудмена-Краскела.

Коэффициент Пирсона определяется по формуле:

$$P=\sqrt{\frac{\chi^2}{\chi^2+n}}. \qquad (2.3)$$

Максимальное значение данного коэффициента зависит от числа строк и столбцов таблицы. Чтобы исправить указанный недостаток предложен ***коэффициент Чупрова*:**

$$C=\sqrt{\frac{\chi^2}{n\sqrt{(r-1)(s-1)}}}, \qquad (2.4)$$

который, если число строк таблицы равно числу столбцов, может, в пределе, достигать единицы.

Коэффициент Крамера задается формулой:

$$K = \sqrt{\frac{\chi^2}{n \cdot \min\{r-1, s-1\}}}, \qquad (2.5)$$

где $\min\{(r-1),(s-1)\}$ равно наименьшему из двух чисел (r–1) и (s–1). Предел коэффициента Крамера при росте числа наблюдений стремится к единице независимо от числа строк и столбцов таблицы сопряженности.

Для квадратных таблиц сопряженности К = С, в остальных случаях К> С.

В случае отклонения гипотезы о независимости признаков по величине приведенных коэффициентов судят о силе связи между показателями.

Для нахождения интервальных оценок коэффициентов сопряженности определим приближенное значение ***стандартных ошибок коэффициентов С, Р, К*** по формулам:

$$S_c = \sqrt{\frac{D\chi^2}{4 \cdot n^2 \cdot (r-1) \cdot (s-1) \cdot C^2}}; \qquad (2.6)$$

$$S_k = \sqrt{\frac{D\chi^2}{4 \cdot n^2 \cdot \min\{r-1, s-1\}^2 \cdot K^2}}; \qquad (2.7)$$

$$S_p = \sqrt{\frac{n^2 \cdot D\chi^2}{4 \cdot X^2 \cdot (n + X^2)^3}}, \qquad (2.8)$$

где $D\chi^2$ – оценка дисперсии статистики χ^2:

$$D\chi^2 = 4\chi^2.$$

Согласно закону больших чисел статистики φ, Р, С, К подчиняются нормальному закону распределения. Следовательно, с надежностью γ можно получить интервальные оценки для генеральных коэффициентов сопряженности:

$$\Theta - \Delta_\Theta \le \Theta_{ген} \le \Theta + \Delta_\Theta;$$

где: $\Theta_{ген}$ – любой коэффициент сопряженности генеральной совокупности;

Θ – его оценка, полученная по выборке на основании выборочной (частотной) таблицы сопряженности.

Нижние и верхние границы доверительного интервала с надежностью γ определяются по формулам:

$$C \pm \Phi^{-1}(\gamma) \cdot \hat{S}_c;$$

$$K \pm \Phi^{-1}(\gamma) \cdot \hat{S}_k;$$

$$P \pm \Phi^{-1}(\gamma) \cdot \hat{S}_p,$$

где значение $\Phi^{-1}(\gamma)$ – находится по таблице интегральной функции распределения Лапласа.

Если интервальная оценка включает нулевое значение коэффициента сопряженности, то для указанного уровня значимости этот коэффициент скорее всего незначим.

Квадрат коэффициента связи, выраженный в процентах, указывает на процент связи зависимости признака X от Y (или Yот X), т.е. $(1-\Theta^2_{\text{ген}})\cdot 100\%$ – это процент зависимости изменения любого признака X или Y под влиянием других признаков невключаемых в модель (случайных факторов).

Коэффициенты сопряженности, основанные на X^2, не позволяют описать зависимость категорий признака Y от категорий признака X (или наоборот) в терминах теории вероятности.

Явную теоретико-вероятностную интерпретацию имеют ***коэффициенты Гудмана-Краскала.*** Эти коэффициенты основаны на том, что если рассматриваемые показатели зависимы, то информация о том, какое значение принял первый из них, должна улучшать точность предсказания значения второго признака.

Коэффициент λ_b:

$$\lambda_b = \frac{\sum_{i=1}^{r} n_{i\max} - n_{*\max}}{n - n_{*\max}}, \qquad (2.9)$$

где: $n_{i\max}$ – максимальная частота i строки;

$n_{*\max}$ – максимальный элемент итоговой строки.

Коэффициент λ_b асимметричный коэффициент, т.к. изучает зависимость Y от X.

Статистика λ_b основана на сравнении двух ситуаций. Для случайно взятого наблюдения мы угадываем его Y-категорию, что, во-первых, если нет никакой дополнительной информации о его категории в X, и, во-вторых, если известен его класс в категории X.

В первом случае для того, чтобы максимизировать вероятность угадать категорию признака Y, мы должны выбрать градацию с максимальной маргинальной частотой n_{*j}, то есть выбрать $\max_j n_{*j}$.

Если известна категория признака X, то необходимо выбирать максимальное число в этой строке.

Ясно, что если признаки взаимосвязаны, то знание категории X позволяет достигать лучшего предсказания.

Коэффициент λ_b оценивает снижение вероятности ошибки предсказания признака Y при известной информации о принадлежности наблюдения к классу признака X по сравнению с ситуацией, когда такой информации нет.

Для получения интервальных оценок для мер Гудмена-Краскала предложена следующая величина, имеющая приближенное единичное нормальное распределение:

$$(\lambda_b - \lambda_{b\ ген}) \sqrt{\frac{(n - n_{*\max})^3}{(n - \sum_{i=1}^{r} n_{i\max})(\sum_{i=1}^{r} n_{i\max} + n - 2\sum_{i}^{*} n_{i\max})}}, \qquad (2.10)$$

где: $\lambda_{bген} = \dfrac{\sum_{i=1}^{r} p_{i\max} - p_{*\max}}{1 - p_{*\max}}$ – генеральная оценка коэффициента λ_b;

$\sum_{i}^{*} n_{i\max}$ – сумма только таких максимальных элементов строк n_{imax}, для которых значения i обеспечивают попадание как раз в тот столбец, где находится наибольший итог.

С надежностью γ можно утверждать, что генеральная мера связи $\lambda_{bген}$ будет находиться в интервале от $\lambda_b - \Delta_{\lambda_b}$ до $\lambda_b + \Delta_{\lambda_b}$.

Ширина доверительного интервала определяется следующим образом:

$$\Delta_{\lambda_b} = \frac{t}{\sqrt{\frac{(n - n_{*\max})^3}{(n - \sum_{i=1}^{r} n_{i\max})(\sum_{i=1}^{r} n_{i\max} + n - 2\sum_{i}^{*} n_{i\max})}}}, \qquad (2.11)$$

где t – аргумент функции нормального закона распределения

$\gamma = \Phi^{-1}(t)$.

Коэффициент $\lambda_{bген}$ обладает следующими свойствами:

1. Если $\lambda_{bген}=1$, то существует однозначная или взаимооднозначная зависимость X от Y, то есть Y жестко связан с X или связан по вероятности.
2. Если $\lambda_{bген}=0$, то признак Y не зависит от признака X, то есть информация о X не улучшает случайного прогноза, а также в том случае, когда все n_{imax} принадлежат столбцу, которому принадлежит и n_{imax}.

Последнее свойство является существенным недостатком для этой меры связи, потому что на практике модальное значение признака Y часто наблюдается в одном и том же столбце.

Поэтому вместо меры λ_b употребляют меру λ_b^*. По сравнению с мерой λ_b мера λ_b^* строится по схеме: случайно взятое наблюдение с

равной вероятностью 1/r принадлежит к одному из классов признака X и для вычисления $\lambda^*_{\text{вген}}$ p_{ij} заменяют на $p_{ij}/(rp_{i*}.)$

$$\lambda_b^* = \frac{\sum_{i=1}^{r} \max_j \frac{n_{ij}}{n_{i*}} - \max_j \sum_{i=1}^{r} \frac{n_{ij}}{n_{i*}}}{r - \max_j \sum_{i=1}^{r} \frac{n_{ij}}{n_{i*}}}. \qquad (2.12)$$

Коэффициент λ_a эквивалентен коэффициенту λ_b, с учетом перемены строк и столбцов между собой, является ассиметричным коэффициентом и определяет степень зависимости X от Y.

$$\lambda_a = \frac{\sum_{j=1}^{s} n_{\max\, j} - n_{\max\, *}}{n - n_{\max\, *}} \quad . \qquad (2.13)$$

Коэффициент λ_a измеряет улучшение средней величины относительного изменения вероятности ошибки предсказания категории признака, располагающегося по столбцам таблицы, при изменении категорий признака, располагающегося по строкам.

Коэффициент λ_a обращается в нуль, если максимальные частоты по строкам расположены в одном столбце, а $\lambda_b = 0$, если максимальные частоты расположены в одной строке. Для получения интервальных оценок в формуле (2.10) следует поменять строки и столбцы местами.

Аналогично строится мера зависимости X от Y – коэффициент λ_a^*:

$$\lambda_a^* = \frac{\sum_{j=1}^{s} \max_i \frac{n_{ij}}{n_{*j}} - \max_i \sum_{j=1}^{s} \frac{n_{ij}}{n_{*j}}}{s - \max_i \sum_{j=1}^{s} \frac{n_{ij}}{n_{*s}}}.$$

Если при анализе таблиц сопряженности не интересует последовательность расположения классов по признакам, т.е. неважно зависит X от Y или наоборот, то используется коэффициент λ. Этот коэффициент находит усредненную величину прогноза между переменными.

$$\lambda = \frac{\sum_{i=1}^{r} n_{i\max} - n_{*\max} + \sum_{j=1}^{s} n_{\max j} - n_{\max *}}{2n - n_{\max *} - n_{*\max}}, \qquad (2.15)$$

где:

$n_{i\max} = \max_j n_{ij}$; $n_{\max j} = \max_i n_{ij}$;

$n_{*\max} = \max_i n_{i*}$; $n_{\max *} = \max_j n_*$

Коэффициент λ удовлетворяет неравенству:

$$\min(\lambda_a, \lambda_b) \le \lambda \le \max(\lambda_a, \lambda_b).$$

При построении коэффициентов Гудмена-Краскала возникают трудности, связанные с неравномерным расположением условных сумм (обращение коэффициентов λ в нуль).

Коэффициенты τ_a, τ_b, τ лишены указанных недостатков. Их отличие от коэффициентов λ_a, λ_b , λ состоит в ином методе предсказания одного показателя при известном значении другого. Вместо того, чтобы предсказывать наиболее вероятную категорию, τ-меры предсказывают различные категории в пропорции, которая имеет место для их наблюдаемых итогов. Эти меры больше похожи на χ^2, чем на λ.

Коэффициент τ_b сравнивает случайный, пропорциональный прогноз признака Y со вторым признаком X и рассчитывает условное, пропорциональное предсказание класса Y, при предположении, что имеется информация о принадлежности объекта к одному из классов признака X. Этот коэффициент связи является асимметричным коэффициентом.

$$\tau_b = \frac{\sum_{i=1}^{r}\sum_{j=1}^{s}\frac{(n\cdot n_{ij} - n_{i*}n_{*j})^2}{n_{i*}}}{n(n^2 - \sum_{j=1}^{s} n_{*j}^2)} \quad . \tag{2.16}$$

При прогнозировании категорий признака X в зависимости от Y, то есть строк таблицы сопряженности в зависимости от столбцов, применяется коэффициент τ_a :

$$\tau_a = \frac{\sum_{i=1}^{r}\sum_{j=1}^{s}\frac{(n\cdot n_{ij} - n_{i*}n_{*j})^2}{n_{*j}}}{n(n^2 - \sum_{i=1}^{s} n_{i*}^2)}. \tag{2.17}$$

Данная мера, умноженная на 100%, показывает, на сколько процентов уменьшится неправильный прогноз категории признака X для случайно взятого объекта при условном пропорциональном прогнозировании по сравнению с безусловным пропорциональным прогнозом.

Для получения симметричной меры τ случайно выбранный объект с вероятностью 1/2 прогнозируется по признаку X или по признаку Y. Этот симметричный коэффициент получается в виде усредненных коэффициентов τ_a, τ_b:

$$\tau = \frac{\sum_{i=1}^{r}\sum_{j=1}^{s}\frac{(n\cdot n_{ij} - n_{i*}n_{*j})^2}{(1/n_{*j} + 1/n_{*j})}}{n(2n^2 - \sum_{i=1}^{r} n_{i*}^2 - \sum_{j=1}^{s} n_{*j}^2)}. \tag{2.18}$$

Коэффициенты τ_a, τ_b, τ удовлетворяют неравенству:

$$\min(\tau_a, \tau_b) \le \tau \le \max(\tau_a, \tau_b).$$

2.1 Тренировочный пример

В результате проведенного опроса учащихся девятых классов городских общеобразовательных школ относительно их планов о дальнейшем обучении и фактической их реализации, получена следующая комбинационная таблица:

Планы опрошенных	Фактическое распределение			
	1.10-й класс	2. Колледж	3. Лицей	Итого
1.10-й класс	120	40	5	165
2. Колледж	10	35	10	55
3. Лицей	15	25	40	80
Итого	145	100	55	300

Проверим гипотезу о независимости двух изучаемых признаков "планы опрошенных" и "фактическое распределение" на уровне значимости α=0,05 , т.е.

$$H_0:\{\forall i,j; p_{ij} = p_{i*}\cdot p_{*j}\}$$

против

$$H_1:\{\exists\ i_0, j_0; p_{i_0 j_0} \neq p_{i*}\cdot p_{*j} \text{ для } i,j = 1,2,3\}\ .$$

Рассчитаем теоретические частоты двумерного распределения в предположении о статистической независимости рассматриваемых переменных, то есть справедливости гипотезы:

$$H_0:\left\{n^*_{ij} = \frac{n_{i*}n_{*j}}{n}\right\}.$$

Имеем маргинальные частоты: n_{1*} = 165; n_{2*} =55; n_{3*} =80; n_{*1} =145; n_{*2} =100; n_{*3} =55; $n=n_{**}$=300.

Так как число степеней свободы в нашем примере равно ν = (3 – 1)(3 – 1) = 4, сделаем расчет лишь четырех независимых частот:

$$n^*_{11}=\frac{165\cdot 145}{300} = 79{,}75;\quad n^*_{12}=\frac{165\cdot 100}{300} = 55;$$

$$n^*_{21}=\frac{55\cdot 145}{300} = 26{,}58;\quad n^*_{22}=\frac{55\cdot 100}{300} = 18{,}3.$$

Оставшиеся частоты рассчитаем, используя равенства:

$$\sum_i n^*_{ij} = \sum_i n_{ij} = n_{*j};\quad \sum_j n^*_{ij} = \sum_j n_{ij} = n_{i*}.$$

n^*_{13}=165 – (79,75 + 55) = 30,25; n^*_{23}=55 – (28,58 + 18,3) = 10,1;

n^*_{31}=145 – (79,75 + 26,58) = 38,7; n^*_{32}=100 – (18,3 + 55) = 26,7;

n^*_{33} =80 – (38,67 + 26,67) = 55 – (30,25 + 10,08) = 14,67.

Расчеты удобно оформить в виде таблицы 2,3 где в правых верхних углах каждой клетки (i, j) помещены исходные эмпирические частоты, а в нижних левых углах – соответствующие рассчитанные точные теоретические частоты.

Таблица 2.3

X \ Y	1	2	3	n_{i*}
1	120 79,8	40 55	5 30,3	165
2	10 26,6	35 18,3	10 10,1	55
3	15 38,7	25 26,7	40 14,7	80
n_{*j}	145	100	55	300=n=n_{**}

Воспользуемся критерием хи-квадрата для проверки гипотезы независимости признаков. Расчет хи-квадрат производится по формуле (1.1):

$$\chi^2 = \sum_i \sum_j \frac{(n_{ij} - n_{ij}^*)^2}{n_{ij}^*} = \frac{(120-79,8)^2}{80} + \frac{(40-55)^2}{55} + \frac{(5-30,3)^2}{30} +$$
$$+ \frac{(10-26,6)^2}{27} + \frac{(35-18,3)^2}{18} + \frac{(10-10,1)^2}{10} + \frac{(15-38,7)^2}{38} +$$
$$+ \frac{(25-26,7)^2}{38} + \frac{(40-14,7)^2}{15} = 129,326.$$

Критическая область при проверке указанной гипотезы имеет вид:

$$\chi^2_{\text{набл}} > \chi^2_{\text{кр}} = \chi^2_{\text{табл}}(\alpha, \nu) = \chi^2_{\text{табл}}(0,05;4) = 9,488.$$

Так как $\chi^2_{набл}$=129,326 попадает в критическую область, гипотеза H_0 отвергается с вероятностью ошибки 0,05. Следовательно, можно считать доказанной связь между планами продолжения образования и их фактической реализацией.

Далее воспользуемся информационным критерием проверки гипотезы независимости признаков планируемого и фактического распределения учащихся по формам образования.

$$\chi_I^2 = 2\sum_i \sum_j n_{ij} \ln \frac{n_{ij}}{n_{ij}^*}.$$

Для удобства вычисления можно применить следующую формулу:

$$\chi_I^2 = 2\left(\sum_i \sum_j n_{ij} \ln n_{ij} - \sum_i n_{i*} \ln n_{i*} - \sum_j n_{*j} \ln n_{*j} + n_{**} \ln n_{**}\right),$$

учитывая, что теоретические значения частот n^*_{ij} находятся по формуле: $n_{ij}^* = \frac{n_{i*} n_{*j}}{n}$ и свойства логарифмов.

$$\chi_I^2 = 2(120 \cdot \ln 120 + 40 \cdot \ln 40 + 5 \ln 5 + 10 \cdot \ln 10 + 35 \cdot \ln 35 +$$
$$+ 10 \cdot \ln 10 + 15 \cdot \ln 15 + 25 \cdot \ln 25 + 40 \cdot \ln 40 - 165 \cdot \ln 165 -$$
$$- 55 \cdot \ln 55 - 80 \cdot \ln 80 - 145 \cdot \ln 145 - 100 \cdot \ln 100 - 55 \cdot \ln 55 +$$
$$+ 300 \cdot \ln 300) = 128,759.$$

В результате вычисления получили χ^2_I=128,759.

Критическая область при проверке указанной гипотезы

$$\chi_I^2 > \chi^2_{\text{кр}\,U} = 9,488.$$

Так как $\chi^2_{набл}$=128,759 попадает в критическую область, гипотеза H_0 отвергается с вероятностью ошибки 0,05.

Для оценки силы связи вычислим точечные оценки коэффициентов Чупрова, Крамера и Пирсона:

$$C = \sqrt{\frac{129{,}326}{300 \cdot \sqrt{(3-1)\cdot(3-1)}}} = 0{,}464;$$

$$K = \sqrt{\frac{129{,}326}{300 \cdot \min\{(3-1);(3-1)\}}} = 0{,}464;$$

$$P = \sqrt{\frac{129{,}326}{300 + 129{,}326}} = 0{,}549 \cdot$$

Так как эти коэффициенты достаточно велики (далеко отстоят от нуля) и объем выборки достаточно большой (n>100), связь можно считать достаточно сильной.

Рассчитаем интервальные оценки для коэффициентов Крамера, Чупрова и Пирсона с надежностью $\gamma = 0{,}95$. Для этого вычислим предварительно оценку дисперсии статистики:

$$D\chi^2 = 4\{\sum_i \sum_j \left(\frac{n_{ij} - n^*_{ij}}{n^*_{ij}}\right)^2 + X^2 - \frac{(X^2)^2}{n_{**}}\} =$$

$$= 4 \cdot (5{,}47 + 129{,}326 - 54{,}119) = 315{,}029.$$

Стандартная ошибка коэффициентов определяется по формулам:

$$S_C = \sqrt{\frac{315{,}029}{4 \cdot 300^2 \cdot 2 \cdot 2 \cdot 0{,}464^2}} = 0{,}032;$$

$$S_K = \sqrt{\frac{315{,}029}{4 \cdot 300^2 \cdot 2 \cdot 2 \cdot 0{,}464^2}} = 0{,}032;$$

$$S_P = \sqrt{\frac{315{,}029 \cdot 300^2}{4 \cdot 129{,}326 \cdot (300 + 129{,}326)^3}} = 0{,}027.$$

Нижние и верхние доверительные границы составляют для коэффициента Чупрова:

$$C \pm \Phi^{-1}(\gamma) \cdot S_{..} = 0{,}464 \pm \Phi^{-1}(0{,}95) \cdot 0{,}032 =$$

$$= 0{,}461 \pm 1{,}96 \cdot 0{,}032 = 0{,}461 \pm 0{,}063;$$

для коэффициента Крамера:

$$K \pm \Phi^{-1}(\gamma) \cdot S_K = 0{,}464 \pm \Phi^{-1}(0{,}95) \cdot 0{,}032 =$$

$$= 0{,}461 \pm 1{,}96 \cdot 0{,}032 = 0{,}461 \pm 0{,}063;$$

для коэффициента Пирсона:

$$P \pm \Phi^{-1}(\gamma) \cdot S_P = 0{,}549 \pm \Phi^{-1}(0{,}95) \cdot 0{,}032 =$$

$$= 0{,}546 \pm 1{,}96 \cdot 0{,}027 = 0{,}546 \pm 0{,}053.$$

Рассчитаем точечные оценки коэффициентов $\tau_\alpha, \tau_\beta, \tau$.

$$\tau_a = \frac{\frac{(300\cdot 120 - 165\cdot 145)^2}{165} + \frac{(300\cdot 40 - 165\cdot 100)^2}{165} + \frac{(300\cdot 5 - 165\cdot 55)^2}{165}}{300\cdot(300^2 - 145^2 - 100^2 - 55^2)} +$$

$$+ \frac{\frac{(300\cdot 10 - 55\cdot 145)^2}{55} + \frac{(300\cdot 35 - 55\cdot 100)^2}{55} + \frac{(300\cdot 10 - 55\cdot 55)^2}{55}}{300\cdot(300^2 - 145^2 - 100^2 - 55^2)} +$$

$$+ \frac{\frac{(300\cdot 15 - 145\cdot 80)^2}{80} + \frac{(300\cdot 25 - 80\cdot 100)^2}{80} + \frac{(300\cdot 40 - 55\cdot 80)^2}{80}}{300\cdot(300^2 - 145^2 - 100^2 - 55^2)} =$$

$$= 0{,}2153;$$

Аналогично находим коэффициенты:

$\tau_\beta = 0{,}2426;$

$\tau = 0{,}2344.$

Для расчетов точечных оценок мер Гудмена-Краскала удобно воспользоваться таблицей 2.4.

В последнем столбце содержатся максимальные элементы по каждой строке комбинационной таблицы, в последней строке – максимальные элементы по каждому из столбцов.

Таблица 2.4

X \ Y	1	2	3	$n_{i\,max}$
1	120	40	5	120
2	10	35	10	35
3	15	25	40	40
$n_{max\,j}$	120	40	40	$n_{max*} = 145$ $n_{*max} = 165$

Получим:

$$\lambda_\alpha = \frac{\sum_{i=1}^{l} n_{i\max} - n_{*\max}}{n - n_{*\max}} = \frac{195-165}{300\text{-}165} = \frac{30}{135} = 0{,}222;$$

$$\lambda_b = \frac{\sum_{j=1}^{m} n_{\max j} - n_{\max *}}{n - n_{\max *}} = \frac{200\text{-}145}{300\text{-}145} = \frac{55}{135} = 0{,}355;$$

$$\lambda_\alpha = \frac{\sum_{i=1}^{l} n_{i\max} - n_{*\max} - \sum_{j=1}^{m} n_{\max j} - n_{\max *}}{2n - n_{*\max} - n_{\max *}} = \frac{195\text{-}165 + 200\text{-}145}{2\cdot 300\text{-}165\text{-}145} =$$

$$= 0{,}293.$$

Таким образом, зафиксировав планы учеников о продолжении образования, возможно на 22% точнее предсказать форму их дальнейшего обучения, отклонения реализации планов составляет 35%, симметричная мера связи равна 29%.

2.2 Разбиение хи-квадрат

По критерию χ^2 можно выявить вклады, вносимые каждой клеткой, каждым столбцом и строкой в $\chi^2_{набл}$ и, в случае отклонения гипотезы независимости H_0, делать соответствующие выводы, интерпретируя большие и маленькие значения слагаемых в $\chi^2_{набл}$.

Возможно разбиение χ^2 по следующим правилам:

1. Если в исходной таблице есть m степеней свободы, то ее можно разбить не более чем на m подтаблиц.
2. Каждая из наблюдаемых частот ячеек должна встретиться в подтаблице один раз.
3. Любая условная сумма в подтаблице должна быть либо частотой в другой таблице, либо условной суммой исходной таблицы.

2.3 Тренировочный пример (продолжение 1.2.1.)

Рассмотрим вклады в критерий χ^2 в примере 2.1. Обозначим градации признака χ - A_1, A_2, A_3, признак Y - B_1, B_2, B_3. Получим таблицу:

χ \ Y	B_1	B_2	B_3
A_1	20,134	4,09	21,076
A_2	10,345	15,15	0,0007
A_3	14,486	0,104	43,757

Как видно, основной вклад в критерий χ^2 дает ячейка (3,3). Число степеней свободы для данной таблицы равно (3 – 1)(3 – 1) = 4.

Для анализа таблицы, дихотоминизируем переменные, причем вход (3,3) выбираем в качестве одного из входов новой таблицы. Получим:

χ Y	не B_3	B_3	n_{i*}
не A_3	205	15	220
A_3	40	40	80
n_{*j}	245	55	300

Для этой таблицы критерий χ^2 = 73,05 и $\chi^2_{инф}$= 65,422 и число степеней свободы равно (2 - 1)(2 - 1) = 1.

Осталось три степени свободы. Разложение таблицы можно сделать следующим образом.

Представим исходную таблицу в виде трех таблиц.

Первая получена при вычеркивании третьей строки:

χ Y	неB_3	B_3	n_{i*}
A_1	160	5	165
A_2	45	10	55
n_{*j}	205	15	220

Критерий χ^2 = 14,905 и $\chi^2_{инф}$=12,553, число степеней свободы равно 1.

Вторая таблица получена из исходной вычеркиванием третьего столбца:

Y	B_1	B_2	n_{i*}
не A_3	130	75	205
A_3	15	25	40
n_{*j}	145	100	245

Для числа степеней свободы равным 1 критерий $\chi^2 = 9{,}305$ и $\chi^2_{\text{инф}} = 9{,}153$.

Третья таблица получается вычеркиванием третьей строки и третьего столбца:

χ Y	B_1	B_2	n_{i*}
A_1	120	40	160
A_2	10	35	45
N_{*j}	130	75	205

Критерий $\chi^2 = 42{,}168$ и $\chi^2_{\text{инф}} = 41{,}631$ с одной степенью свободы.

Для $\chi^2_{\text{инф}}$ выполняется разложение критерия хи-квадрат, т.е. $\chi^2_{\text{инф}} = 65{,}422 + 12{,}553 + 9{,}153 + 41{,}631 = 128{,}759$ и равно вычисленному ранее в примере 2.1.

Так как наибольший вклад в χ^2 вносит ячейка (3,3), то лицеисты наиболее точно спрогнозировали свое будущее.

3. Таблица сопряженности 2×2×2

3.1 Методы анализа таблиц с тремя входами

Рассмотрим генеральную таблицу сопряженности 2×2×2, то есть таблицу сопряженности с тремя входами, задаваемую случайными величинами X, Y, Z.

Данные представляют собой вероятности, объединенные в i×j×k ячейках.

Таблица 3.1

	Z_1			Z_2		
	Y_1	Y_2	Всего	Y_1	Y_2	Всего
X_1	p_{111}	p_{121}	p_{1*1}	p_{112}	p_{122}	p_{1*2}
X_2	p_{211}	p_{221}	p_{2*1}	p_{212}	p_{222}	p_{2*2}
Всего	p_{*11}	p_{*21}	p_{**1}	p_{*12}	p_{*22}	p_{**2}

p_{ijk} – вероятность попадания случайного наблюдения в i–категорию признака X, в j – категорию по признаку Y и в k– категорию по признаку Z.

$$\sum_i \sum_j \sum_k p_{ijk} = p_{***} = 1$$

Из этого распределения можно получить три соответствующих частных распределения, суммируя исходное распределение вероятностей по одному признаку. В результате получим таблицу сопряженности 2×2 для вероятностей:

$$p_{1**} = p_{1*1} + p_{1*2} = p_{11*} + p_{12*};$$
$$p_{2**} = p_{2*1} + p_{2*2} = p_{21*} + p_{22*}.$$

Аналогичную таблицу сопряженности можно составить для наблюдаемых частот.

Рассмотрим выборочную таблицу сопряженности:

Таблица 3.2

	Z_1			Z_2		
	Y_1	Y_2	Всего	Y_1	Y_2	Всего
X_1	n_{111}	n_{121}	n_{1*1}	n_{112}	n_{122}	n_{1*2}
X_2	n_{211}	n_{221}	n_{2*1}	n_{212}	n_{222}	n_{2*2}
Всего	n_{*11}	n_{*21}	n_{**1}	n_{*12}	n_{*22}	n_{**2}

В такой таблице сопряженности существуют два класса условных сумм. Первый – условные суммы, которые представляют собой итоги по строкам, столбцам, то есть:

$$n_{*jk} = \sum_i n_{ijk}; \quad n_{i*k} = \sum_j n_{ijk}; \quad n_{ij*} = \sum_k n_{ijk}.$$

Второй класс – условные суммы, представляющие полные срезы таблицы с тремя входами, например,

$$n_{**k} = \sum_i n_{i*k} = \sum_j n_{*jk} = \sum_i \sum_j n_{ijk};$$
$$n_{i**} = \sum_k n_{i*k} = \sum_j n_{ij*} = \sum_k \sum_j n_{ijk};$$
$$n_{*j*} = \sum_i n_{ij*} = \sum_k n_{*jk} = \sum_i \sum_k n_{ijk}.$$

В соответствии, получим два частных распределения:
1) распределение X и Y при фиксированном Z_1:

	Y_1	Y_2	Всего
X_1	n_{111}	n_{121}	n_{1*1}
X_2	n_{211}	n_{221}	n_{2*1}
Всего	n_{*11}	n_{*21}	n_{**1}

2) распределение X и Y при фиксированном Z_2.

	Y_1	Y_2	Всего
X_1	n_{112}	n_{122}	n_{1*2}
X_2	n_{212}	n_{222}	n_{2*2}
Всего	n_{*12}	n_{*22}	n_{**2}

При объединении распределений для двумерной таблицы сопряженности получим:

	Y_1	Y_2	Всего
X_1	n_{11*}	n_{12*}	n_{1**}
X_2	n_{21*}	n_{22*}	n_{2**}
Всего	n_{*1*}	n_{*2*}	n_{***}

Для анализа таблицы сопряженности гипотезу независимости для случая трех переменных формулируется следующим образом:

H_0:{ $p_{ijk} = p_{i**}\, p_{*j*}\, p_{**k}$ для всех i, j, k}

против гипотезы H_1: { $p_{ijk} \neq p_{i**}\, p_{*j*}\, p_{**k}$, если $\exists$ i, j,k}.

Если соотношение $p_{ijk} = p_{i**}\, p_{*j*}\, p_{**k}$ выполняется для вероятностей всех ячеек, то говорят, что переменные X, Y, Z взаимно независимы.

Аналогично таблицам сопряженности 2×2 для условного распределения можно проверить гипотезу о независимости X и Y при заданном значении Z. Таким образом, проверяется гипотеза:

H_0: { для всех i, j, k выполняется $p_{ijk} = \frac{p_{i*k}\, p_{*jk}}{p_{**k}}$ }.

Аналогично строятся гипотезы независимости для других пар признаков.

Независимость Y и Z при заданном значении X:

$$H_0: \{ \text{для всех i, j, k выполняется } p_{ijk} = \frac{p_{i*k} p_{ij*}}{p_{i**}} \};$$

и независимость X и Z при заданном значении Y:

$$H_0: \{ \text{для всех i, j, k выполняется } p_{ijk} = \frac{p_{ij*} p_{*jk}}{p_{*j*}} \}.$$

Другой способ удостовериться в независимости связан с вычислением отношения преобладаний (1.4) для условных распределений.

Если признаки независимы, то отношение преобладаний Q_n равно единице. Если $Q_n > 1$, то признаки связаны положительно, если $Q_n < 1$, то наблюдается отрицательная связь.

3.2 Тренировочный пример

Рассмотрим трехвходовую таблицу сопряженности, полученную в результате опроса студенческих групп по следующим признакам:

X – пол (X_1 – мужской, X_2 – женский);

Y – выбранная специальность студента (Y_1 – статистики; Y2 – информатики);

Z – успеваемость (Z_1 – учатся на «удовлетворительно»; Z_2 – учатся на «хорошо и отлично».

	Z_1			Z_2		
	Y_1	Y_2	Всего	Y_1	Y_2	Всего
X_1	15	5	20	28	12	40
X_2	15	5	20	42	18	60
Всего	30	10	40	70	30	100

Рассчитаем отношение преобладаний для левой и правой подтаблиц:

$$O_n = \frac{n_{111} n_{222}}{n_{212} n_{121}} = \frac{15 \cdot 5}{15 \cdot 5} = 1$$

и

$$O_n = \frac{n_{112} n_{222}}{n_{212} n_{122}} = \frac{28 \cdot 18}{42 \cdot 12} = 1 \cdot$$

Отношение преобладаний равно единице для двух таблиц, это значит, что X и Y независимы, то есть признаки «пол» и «выбранная специальность» не зависимы.

Перестроим таблицу следующим образом:

	Y_1			Y_2		
	Z_1	Z_2	Всего	Z_1	Z_2	Всего
X_1	15	28	43	5	12	17
X_2	15	42	57	5	18	23
Всего	30	70	100	10	30	40

Аналогично найдем отношение преобладаний:

$$O_{\text{П}}=\frac{n_{111}n_{212}}{n_{211}n_{112}}=\frac{15\cdot 42}{15\cdot 28}=1{,}5$$

$$O_{\text{П}}=\frac{n_{121}n_{222}}{n_{221}n_{122}}=\frac{5\cdot 18}{5\cdot 12}=1{,}5\,.$$

Отношение преобладаний равно 1,5, что означает, что признак X и Z зависимы, связь положительна. То есть признаки «пол» и «успеваемость» зависимы.

Аналогично можно показать, что Y и Z также взаимозависимы.

Построим таблицу сопряженности:

	X_1			X_2		
	Z_1	Z_2	Всего	Z_1	Z_2	Всего
Y_1	15	28	43	15	42	57
Y_2	5	12	17	5	18	23
Всего	20	40	60	20	60	80

Найдем отношение преобладаний для левой и правой таблицы:

$$O_{\text{П}}=\frac{n_{111}n_{212}}{n_{211}n_{112}}=\frac{15\cdot 12}{5\cdot 28}=1{,}28;$$

$$O_{\text{П}}=\frac{n_{121}n_{222}}{n_{221}n_{122}}=\frac{15\cdot 18}{5\cdot 42}=1{,}28\,.$$

Отношение преобладаний равно 1,28, т.е. признак Y и X зависимы, то есть признаки «выбранная специальность» и «успеваемость» студентов.

Для определения взаимодействия трех факторов следует рассмотреть следующее отношение вероятностей:

$$\frac{p_{111}p_{221}}{p_{121}p_{211}}=\frac{p_{112}p_{222}}{p_{122}p_{212}}\,.$$

В этом случае имеет место отношение отношения преобладаний. Это отношение определяет так называемое *взаимодействие второго порядка или трехфакторное взаимодействие.*

Анализом связей между признаками, определением взаимодействий между ними занимается логлинейный анализ.

4. Логлинейный анализ

4.1 Модель логлинейного анализа

Рассмотрим двумерную таблицу сопряженности r×s.

Представим теоретические частоты в ячейках такой таблицы в виде:

$$n_{ij}^{*}=e^{u_0+u_i^a+u_j^b+u_{ij}^{ab}}; \qquad (4.1)$$

или, в другой форме:

$$\ln n_{ij}^{*}=u_0+u_i^a+u_j^b+u_{ij}^{ab}, \qquad (4.2)$$

где: n^{*}_{ij} –теоретическая частота в ячейке;

u – неизвестные параметры, называемые:

u^{a}_{i} – эффект i-ой градации первого признака;

u^{b}_{j} – эффект j-ой градации второго признака;

u^{ab}_{ij} – эффект взаимодействия двух признаков;

u_0 – общий эффект;

i = 1,...r ; j = 1,...., s.

Параметры должны удовлетворять ограничениям:

$$\sum_i u_{ij}^{ab}=\sum_j u_{ij}^{ab}=\sum_i u_i^a=\sum_j u_j^b=0. \qquad (4.3)$$

Подобные модели называют ***логлинейными моделями*** таблиц сопряженности.

В логлинейной модели теоретические ожидаемые частоты n^{*}_{ij} преобразуются в их логарифмы, представляющие собой сумму из четырех параметров модели.

Параметры логлинейной модели иногда называют также вкладами, вносимыми различными эффектами в теоретическую частоту.

Логлинейный анализ – это статистический анализ связи таблиц сопряженности с помощью логлинейных моделей. Он позволяет в сжатой форме с помощью относительно небольшого числа параметров записать информацию, содержащуюся в таблице сопряженности. Кроме того, логлинейная модель поддается содержательной интерпретации получаемых результатов.

В общем виде наблюдаемую частоту n_{ij} можно представить в виде логлинейной модели:

$$n_{ij}=e^{u_0+u_i^a+u_j^b+u_{ij}^{ab}+\varepsilon_{ij}},$$

где $e^{\varepsilon_{ij}}=\frac{n_{ij}}{n_{ij}^{*}}$ и i = 1,...r ; j = 1,...., s.

Таким образом, $\ln e^{\varepsilon_{ij}}=\ln n_{ij}-\ln n_{ij}^{*}$ является отклонением логарифма наблюдаемой частоты от логарифма теоретической частоты, а $e^{\varepsilon_{ij}}$ показывает относительное отклонение наблюдаемой, эмпирической, частоты от ожидаемой теоретической, то есть определяет во сколько раз n_{ij} больше или меньше n^{*}_{ij}.

Для проверки гипотезы о независимости признаков:

$$H_0^*:\{u_{ij}^{ab}=0;i=1,...,r;j=1,...,s\}$$

вместо критерия χ^2 применяется критерий $\chi^2_{\text{инф}}$, статистика которого имеет вид:

$$\chi_I^2=2\sum_i\sum_j n_{ij}\ln\frac{n_{ij}}{n_{ij}^*}. \quad (4.4)$$

При расчете статистики $\chi^2_{\text{инф}}$ следует иметь в виду, что таблица сопряженности не должна иметь нулевые или пустые клетки. Если такие существуют, то для такой таблицы в пустые клетки добавляют числа, заключенные в интервал от нуля до единицы, чаще 0,5, что помогает избежать неопределенности.

При большом объеме выборки n статистики χ^2 и $\chi^2_{\text{инф}}$ мало отличаются друг от друга, поэтому вместо $\chi^2_{\text{инф}}$ можно применить χ^2, однако при небольших объемах выборки желательно употреблять информационный критерий.

Модель называется ***насыщенной***, если она включает все факторы и взаимодействия.

Число независимых параметров модели равно разности числа всех параметров модели и числа ограничений, накладываемых на параметры модели.

Число степеней свободы при проверке гипотез в таблице сопряженности с помощью критерия χ^2 и $\chi^2_{\text{инф}}$ определяются следующим образом:

число степеней свободы ν	=	число клеток	–	число независимых параметров модели	=

=	число клеток таблицы	–	число всех параметров	+	число ограничений на параметры

4.2 Оценка параметров насыщенной модели для таблиц 2×2

Пусть имеется выборочная таблица сопряженности 2×2.

X Y	не B	B	n_{i*}
не A	n_{11}	n_{12}	n_{1*}
A	n_{21}	n_{22}	n_{2*}
n_{*j}	n_{*1}	n_{*2}	$n_{**}=n$

Будем предполагать, что частоты во всех ячейках таблицы не равны нулю.

Насыщенная модель имеет вид:

$$\ln n_{ij}^{*}=u_0+u_i^a+u_j^b+u_{ij}^{ab},\ \text{i}=1,2;\ \text{j}=1,2. \qquad (4.5)$$

Число всех параметров, с учетом того, что i и j принимает по два значения, а u_{ij}^{ab} – четыре значения, равно: 1 + 2 + 2 + 4 = 9.

Число ограничений определяется из соотношения (4.3):

$$u_2^a=-u_1^a;u_2^b=-u_1^b;u_{11}^{ab}=-u_{12}^{ab};u_{11}^{ab}=-u_{21}^{ab};u_{11}^{ab}=u_{22}^{ab}.$$

Число независимых параметров равно 9 – 5 = 4 и совпадает с числом клеток таблицы 2×2. Следовательно, рассматриваемая модель является насыщенной.

Для насыщенной модели число степеней свободы равно нулю для таблиц сопряженности любых размеров. Вследствие этого теоретические частоты не отличаются от наблюдаемых, то есть $n^{*}_{ij} = = n_{ij}$. Значение критерия хи-квадрат должно быть равно нулю. Обычно вместо критерия χ^2 используют критерий $\chi^2_{\text{инф}}$ (4.4).

С учетом ограничений, накладываемых на параметры, для таблицы сопряженности можно записать следующую систему уравнений:

$$\begin{cases}\ln n_{11}^{*}=u_0+u_1^a+u_1^b+u_{11}^{ab}\\ \ln n_{12}^{*}=u_0+u_1^a-u_1^b-u_{11}^{ab}\\ \ln n_{21}^{*}=u_0-u_1^a+u_1^b-u_{11}^{ab}\\ \ln n_{22}^{*}=u_0-u_1^a-u_1^b+u_{11}^{ab}\end{cases}. \qquad (4.6)$$

Решая данную систему относительно u, получим:

$$u_{11}^{ab}=\frac{1}{4}\ln\frac{n_{11}^{*}n_{22}^{*}}{n_{12}^{*}n_{21}^{*}};\qquad u_1^a=\frac{1}{4}\ln\frac{n_{11}^{*}n_{12}^{*}}{n_{21}^{*}n_{22}^{*}};$$
$$u_1^b=\frac{1}{4}\ln\frac{n_{11}^{*}n_{21}^{*}}{n_{12}^{*}n_{22}^{*}};\qquad u_0=\frac{1}{4}\ln(n_{11}^{*}n_{12}^{*}n_{21}^{*}n_{22}^{*}). \qquad (4.7)$$

Взаимодействие u_{11}^{ab} равно логарифму отношения преобладаний (1.4).

4.3 Оценка параметров ненасыщенных моделей для таблиц 2×2

Модель, у которой хотя бы один из параметров равен нулю, называется ***ненасыщенной.***

Для проверки гипотезы об адекватности любой ненасыщенной модели применяется критерий (4.4).

а) Модель независимости

Если в насыщенной модели $u_{ij}^{ab}=0$, следовательно, и $u_{12}^{ab}=u_{21}^{ab}=u_{22}^{ab}=0$, то полученная ненасыщенная модель называется ***моделью независимости*** или ***независимой моделью***.

Модель независимости в общем случае имеет вид:

$$\ln n_{ij}^{*} = u_0 + u_i^a + u_j^b ,$$

где теоретические частоты равны

$$n_{ij}^{*} = \frac{n_{i*} n_{*j}}{n} .$$

Если признаки независимы, то отношение преобладаний для теоретических частот равно единице:

$$O_{\text{П}} = \frac{n_{11}^{*} n_{22}^{*}}{n_{21}^{*} n_{12}^{*}} = 1 .$$

Получаем следующие оценки параметров модели независимости:

$$\begin{aligned} u_{11}^{ab} &= 0; & u_1^a &= \frac{1}{4}\ln\frac{n_{11}^{*} n_{12}^{*}}{n_{21}^{*} n_{22}^{*}}; \\ u_1^b &= \frac{1}{4}\ln\frac{n_{11}^{*} n_{21}^{*}}{n_{12}^{*} n_{22}^{*}}; & u_0 &= \frac{1}{4}\ln(n_{11}^{*} n_{12}^{*} n_{21}^{*} n_{22}^{*}). \end{aligned} \qquad (4.8)$$

Если $X^2_{\text{инф}} < X^2_{\text{крит}}$, то модель считается адекватной и возможно дальнейшее упрощение модели.

Число степеней свободы равно 4 – 3 = 1.

б) Модель с отсутствием влияния одного фактора

Модель с отсутствием влияния фактора B имеет вид:

$$\ln n_{ij}^{*} = u_0 + u_i^a .$$

Параметры $u_{ij}^{ab} = 0,\ u_j^b = 0$ и, следовательно, теоретические частоты можно рассчитать как $n_{11}^{*} = \frac{n_{1*}}{2};\ n_{21}^{*} = \frac{n_{2*}}{2}$.

Таблица сопряженности теоретических частот для данной модели имеет вид:

X Y	не B	B	n_{i*}
не A	$n_{1*}/2$	$n_{1*}/2$	n_{1*}
A	$n_{2*}/2$	$n_{2*}/2$	n_{2*}
n_{*j}	n/2	n/2	$n_{**}=n$

Из таблицы видно, что частное распределение категорий признака B равновероятно, то есть фактор B не оказывает влияние на распределение теоретических частот или вероятностей клеток таблицы. Эффект фактора B равен нулю.

Параметры логлинейной модели:

$$\begin{aligned} u_{11}^{ab} &= 0; & u_1^a &= \frac{1}{4}\ln\frac{n_{11}^{*} n_{12}^{*}}{n_{21}^{*} n_{22}^{*}}; \\ u_1^b &= 0; & u_0 &= \frac{1}{4}\ln(n_{11}^{*} n_{12}^{*} n_{21}^{*} n_{22}^{*}). \end{aligned} \qquad (4.9)$$

Аналогично строится *модель с отсутствием влияния фактора A*:

$$\ln n_{ij}^{*} = u_0 + u_j^b .$$

Таблица теоретических частот соответственно имеет вид:

X Y	не B	B	n_{i*}
не A	$n_{*1}/2$	$n_{*2}/2$	n/2
A	$n_{*1}/2$	$n_{*2}/2$	n/2
n_{*j}	n_{*1}	n_{*2}	n_{**}=n

Параметры логлинейной модели:

$$\begin{aligned} u_{11}^{ab} &= 0; & u_1^a &= 0; \\ u_1^b &= \frac{1}{4}\ln\frac{n_{11}^{*} n_{21}^{*}}{n_{12}^{*} n_{22}^{*}}; & u_0 &= \frac{1}{4}\ln(n_{11}^{*} n_{12}^{*} n_{21}^{*} n_{22}^{*}). \end{aligned} \qquad (4.10)$$

Число степеней свободы равно 4 – 2 = 2.

в) Равновероятная модель

Для этой модели отсутствует влияние фактора A и фактора B:

$$\ln n_{ij}^{*} = u_0 .$$

Таблица теоретических частот в этом случае:

X Y	не B	B	n_{i*}
не A	n/4	n/4	n/2
A	n/4	n/4	n/2
n_{*j}	n/2	n/2	n_{**}=n

Параметры логлинейной модели:

$$\begin{aligned} u_{11}^{ab} &= 0; & u_1^a &= 0; \\ u_1^b &= 0; & u_0 &= \frac{1}{4}\ln(n_{11}^{*} n_{12}^{*} n_{21}^{*} n_{22}^{*}). \end{aligned} \qquad (4.11)$$

Число степеней свободы равно 4 – 1 = 3.

На практике анализ логлинейных моделей можно проводить начиная с насыщенной модели, постепенно ее упрощая.

Все виды логлинейных моделей представлены в табл. 4.1.

Таблица 4.1

Виды логлинейных моделей

Номер модели	Название модели	Вид модели
1.	Насыщенная	$\ln n_{ij}^{*} = u_0 + u_i^a + u_j^b + u_{ij}^{ab}$
2.	Независимости	$\ln n_{ij}^{*} = u_0 + u_i^a + u_j^b$
3.	Нет фактора В	$\ln n_{ij}^{*} = u_0 + u_i^a$
4.	Нет фактора А	$\ln n_{ij}^{*} = u_0 + u_j^b$
5.	Равновероятная	$\ln n_{ij}^{*} = u_0$

Для проверки значимости параметров модели, следует вычесть $\chi^2_{\text{инф}}$ из модели с высоким номером $\chi^2_{\text{инф}}$ модели с низким номером.

Если значение некоторых параметров при оценке параметров оказывается близкими к нулю, то они из модели исключаются.

4.4 Иерархические модели

Рассмотренные модели входят в класс ***иерархических***, которые подчиняются правилу, выполняемому в многомерном случае. Допустим в модель включен параметр, зависящий от множества S факторов. Тогда модель должна включать также и все параметры, зависящие от любого подмножества из этого множества факторов.

Например, если в какую-нибудь иерархическую модель включен параметр u_{ij}^{ab}, то в нее обязательно должны входить и параметры u_0, u_i^a, u_j^b.

Пример неиерархической модели: $\ln n_{ij}^{*} = u_0 + u_{ij}^{ab}$. В модель включен фактор u_{ij}^{ab}, однако отсутствуют главные влияния обоих факторов А и В.

Таблица сопряженности такой модели может иметь вид:

X Y	не В	В	n_{i*}
не А	80	20	100
А	20	80	100
n_{*j}	100	100	200

Из таблицы видно, что связь между А и В существует, однако отсутствует влияние фактора А и фактора В отдельно.

4.5 Тренировочный пример

В результате маркетингового исследования, проведенного с целью изучения эффективности рекламы среди 800 покупателей, получена следующая таблица сопряженности по признакам:

A – пол (1– мужской; 2 – женский);

B – информация о рекламе товара (1 – знакомы; 2 – не знакомы).

A B	1- знакомы	2 - не знакомы	n_{i*}
1-мужской	298	142	440
2- женский	210	150	360
n_{*j}	508	292	800

Найдем параметры всех логлинейных моделей, рассчитаем статистику $X^2_{\text{инф}}$ для каждой модели и проверим адекватность полученной модели эмпирическим данным.

1. *Насыщенная модель*:

$$\ln m^*_{ij} = u_0 + u^a_i + u^b_j + u^{ab}_{ij},$$

i = 1, 2; j = 1, 2.

Для нахождения параметров и теоретических частот составим таблицу логарифмов наблюдаемых частот: $y_{ij} = \ln n_{ij}$.

A B	1 - знакомы	2 - не знакомы
1-мужской	5,69	4,96
2- женский	5,35	5,01

Затем по формулам (4.5) находим параметры логлинейной модели, пользуясь свойствами логарифмов:

$$u^{ab}_{11} = \frac{1}{4}\ln\frac{n^*_{11}n^*_{22}}{n^*_{12}n^*_{21}} = \frac{1}{4}(\ln n^*_{11} + \ln n^*_{22} - \ln n^*_{12} - \ln n^*_{21});$$

$$u^a_1 = \frac{1}{4}\ln\frac{n^*_{11}n^*_{12}}{n^*_{21}n^*_{22}} = \frac{1}{4}(\ln n^*_{11} + \ln n^*_{12} - \ln n^*_{21} - \ln n^*_{22});$$

$$u^b_1 = \frac{1}{4}\ln\frac{n^*_{11}n^*_{21}}{n^*_{12}n^*_{22}} = \frac{1}{4}(\ln n^*_{11} + \ln n^*_{21} - \ln n^*_{12} - \ln n^*_{22});$$

$$u_0 = \frac{1}{4}\ln(n^*_{11}n^*_{12}n^*_{21}n^*_{22}) = \frac{1}{4}(\ln n^*_{11} + \ln n^*_{21} + \ln n^*_{12} + \ln n^*_{22}).$$

Получим:

$$u_{11}^{ab} = \frac{1}{4}(5{,}69 + 5{,}01 - 5{,}35 - 4{,}96) = 0{,}101;$$

$$u_1^a = \frac{1}{4}(5{,}69 - 5{,}01 + 5{,}35 - 4{,}96) = 0{,}269;$$

$$u_1^b = \frac{1}{4}(5{,}69 - 5{,}01 - 5{,}35 + 4{,}96) = 0{,}073;$$

$$u_0 = \frac{1}{4}(5{,}69 + 5{,}01 + 5{,}35 + 4{,}96) = 5{,}25.$$

Так как для насыщенной модели теоретические частоты равны фактическим, то статистика $X^2_{\text{инф}} = 0$.

2. *Модель независимости*:

$$\ln n_{ij}^* = u_0 + u_i^a + u_j^b.$$

Для этой модели теоретические частоты находятся по формуле:

$$n_{ij}^* = \frac{n_{i*} n_{*j}}{n}.$$

Рассчитаем теоретические частоты:

$$n_{11}^* = \frac{440 \cdot 508}{800} = 279{,}4; \qquad n_{12}^* = \frac{440 \cdot 292}{800} = 160{,}6;$$

$$n_{21}^* = \frac{360 \cdot 508}{800} = 228{,}6; \qquad n_{22}^* = \frac{360 \cdot 292}{800} = 131{,}4.$$

Таблица теоретических частот:

A B	1- знакомы	2 - не знакомы	n_{i*}
1-мужской	279,4	160,6	440
2- женский	228,6	131,4	360
n_{*j}	508	292	800

Составим таблицу логарифмов теоретических частот:

A B	1 - знакомы	2- не знакомы
1-мужской	5,63	5,08
2- женский	5,43	4,87

Найдем параметры логлинейной модели по формулам (4.5):

$$u_0 = 5{,}255; \quad u_1^b = 0{,}1; \quad u_1^a = 0{,}28; \quad u_{11}^{ab} = 0.$$

Найдем значение $X^2_{инф}$ по формуле (4.4):

$$X_I^2 = 2(\sum_i \sum_j n_{ij} \ln n_{ij} - \sum_i n_{i*} \ln n_{i*} - \sum_j n_{*j} \ln n_{*j} + n_{**} \ln n_{**}).$$

$$X_I^2 = 2(298 \cdot \ln 298 + 142 \cdot \ln 142 + 210 \ln 210 + 150 \cdot \ln 150 -$$
$$- 508 \cdot \ln 508 - 292 \cdot \ln 292 - 440 \cdot \ln 440 - 360 \cdot \ln 360 +$$
$$+ 800 \cdot \ln 800) = 7{,}52.$$

Число степеней свободы для этой модели равно $\nu = 4 - 3 = 1$ (число клеток минус число параметров модели).

По таблице распределения хи-квадрат находим

$$X^2_{крит}\ (\nu = 1;\ \alpha = 0{,}05) = 3{,}841.$$

Так как $X^2_I > X^2_{крит}$, то модель независимости неадекватна. Дальнейшее ее упрощение не имеет смысла. Однако в целях дальнейшей иллюстрации проведем остальные расчеты.

3. *Модели с отсутствием влиянием одного фактора.*

Модель с отсутствием влияния фактора B:

$$\ln n_{ij}^* = u_0 + u_i^a.$$

Рассчитаем теоретические частоты, получим таблицу:

A B	1- знакомы	2 - не знакомы	n_{i*}
1-мужской	220	220	440
2- женский	180	180	360
n_{*j}	400	400	800

Таблица логарифмов теоретических частот:

A B	1 - знакомы	2 - не знакомы
1-мужской	5,39	5,39
2- женский	5,19	5,19

Параметры логлинейной модели: $u_0 = 5{,}29$; $u_1{}^b = 0$; $u_1{}^a = 0{,}1$;

$$u_{11}{}^{ab} = 0.$$

Для этой таблицы критерий $X^2_{инф} = 66{,}577$.

4. *Модель с отсутствием влияния фактора A:*

$$\ln n_{ij}^* = u_0 + u_j^b.$$

Таблица теоретических частот:

A B	1- знакомы	2 - не знакомы	n_{i*}
1-мужской	254	146	400
2- женский	254	146	400
n_{*j}	508	292	800

Таблица логарифмов теоретических частот:

A B	1 - знакомы	2 - не знакомы
1-мужской	5,53	4,98
2- женский	5,53	4,98

Параметры логлинейной модели:

$$u_0 = 5{,}26; \quad u_1{}^b = 0; \quad u_1{}^a = 0{,}276; \quad u_{11}{}^{ab} = 0.$$

Значение $X^2_{\text{инф}} = 15{,}54$.

5. *Равновероятная модель*:

$$\ln n_{ij}^* = u_0 .$$

В этом случае теоретические частоты равны:

A B	1- знакомы	2 - не знакомы	n_{i*}
1-мужской	200	200	400
2- женский	200	200	400
n_{*j}	400	400	800

Значения логарифмов теоретических частот:

A B	1 - знакомы	2 - не знакомы
1-мужской	5,29	5,29
2- женский	5,29	5,29

Параметры модели: $u_0 = 5{,}29$; $u_1{}^b = 0$; $u_1{}^a = 0$; $u_{11}{}^{ab} = 0$.

$\chi^2_{\text{инф}} = 74{,}59$.

Для сравнения всех моделей составим таблицу 4.2.

Таблица 4.2

Результаты построения логлинейных моделей

Модель	Название	Теоретические частоты				Параметры логлинейной модели				ν	χ^2
		n_{11}^*	n_{12}^*	n_{21}^*	n_{22}^*	u_0	u_1^a	u_1^b	u_{11}^{ab}		
1	Насыщенная	298	142	210	150	5.25	0.27	0.07	0.1	0	0
2	Независимости	279	161	229	131	5.25	0.28	0.1	0	1	7.53
3	Нет эффекта В	220	220	180	180	5.29	0.1	0	0	2	15.5
4	Нет эффекта А	254	146	254	146	5.26	0	0.27	0	2	66.6
5	Равновероятная	200	200	200	200	5.29	0	0	0	3	74.6

Различие между моделями 1 и 2 состоит в наличии члена u_{11}^{ab}.

Проверка значимости этого параметра осуществляется сравнением значений $\chi^2_{инф}$: находим разность 7,53 – 0 = 7,53 при 2 – 1 = 1 степенях свободы. $\chi^2_{набл} = 7{,}53 > \chi^2_{крит}(0{,}05;\ 1) = 3{,}381$. Следовательно, параметр u_{11}^{ab} значим.

Таким образом, возможно сравнение моделей по приращению $\chi^2_{инф}$ с учетом приращения числа степеней свободы. По найденной разности $\chi^2_{инф}$ делают вывод о том, значим или нет этот параметр и можно ли его исключить из модели.

Если значения параметров модели близко к нулю, то такие параметры из модели исключаются.

В нашем примере сравним независимую модель с моделью без эффекта В (табл 4.3).

Таблица 4.3

Сравнение независимой модели с моделью без эффекта В

Модель	Включенные параметры	4.5.1 Степень свободы	$\chi^2_{инф}$
Независимая	u_0, u_1^a, u_1^b	1	7,59
Без эффекта В	u_0, u_1^a	2	15,5
Различие	u_1^b	1	7,91

Так как вклад в $\chi^2_{инф}$ параметра u_1^b равен 7,91 при числе степеней свободы ν = 1, то делаем вывод что параметр u_1^b значим.

Приращение $\chi^2_{инф}$ приведено в таблице 4.4.

Таблица 4.4

Приращения $\chi^2_{инф}$

	Модель	Включенные параметры	$\chi^2_{инф}$	Сравнение моделей	Разность $\chi^2_{инф}$
5	Равновероятная	u_0	74,6		
4	Без эффекта А	u_0, u_1^b	66,6	(5) с (4)	8
3	Без эффекта В	u_0, u_1^a	15,5	(5) с (3)	59,1
2	Независимая	u_0, u_1^a, u_1^b	7,59	(4) с (2)	59,01
				(3) с (2)	7,91
1	Насыщенная	$u_0, u_1^a, u_1^b, u_{11}^{ab}$	0	(1) с (2)	7,59

Из таблицы 4.4 видно, что наиболее значим параметр u_1^b.

Отметим, что логлинейные модели позволяют проверить ряд дополнительных гипотез, например, о симметричности таблицы сопряженности, т.е. выполнения равенства $n^*_{ij} = n^*_{ji}$. Составив соответствующую систему уравнений, можно получить оценки параметров модели и теоретических частот, а затем с помощью информационного критерия проверить выдвинутую гипотезу.

5. Логлинейные модели многомерных таблиц сопряженности

5.1 Основные понятия логлинейного анализа

До сих пор мы рассматривали связи между двумя категоризованными признаками. Естественно обобщить задачу на случай числа признаков k > 2. Соответствующие таблицы называются таблицами с несколькими входами, или ***многомерными таблицами сопряженности.***

С увеличением числа признаков, рассматриваемых одновременно, число ячеек в таблице возрастает в геометрической прогрессии. Визуальное исследование взаимосвязей основывается на рассмотрении процентных соотношений по строкам, столбцам, "слоям" таблицы, и изменения этих соотношений по градациям признаков. Однако, из-за большого числа ячеек таблица становится труднообозримой, что затрудняет изучение взаимосвязей показателей.

Рассмотрим многовходовую, таблицу сопряженности

$$N = \{n_\alpha\},$$

где n_α – количество объектов (или частота), попавших в ячейку $\alpha = (i_1, i_2,...,i_k)$ таблицы.

Для любого подмножества признаков может быть составлена частная (маргинальная) таблица сопряженности. В такой таблице каждое число получается суммированием по всем клеткам исходной таблицы с заданными значениями признаков, то есть число в ячейке

$$b=(i_1, i_2,...,i_k)$$

маргинальной таблицы равно:

$$n_b = \sum_i n_{i_1,...,i_k} .$$

Логлинейные модели легко обобщаются для случая нескольких переменных. Они позволяют проверить гипотезу о наличии взаимосвязей между признаками, и с помощью как можно меньшего числа параметров позволяют представить в сжатом виде информацию, содержащуюся в таблице и дать интерпретацию взаимодействий любого порядка в одинаковых терминах.

Математическая задача многомерного логлинейного анализа состоит в том, чтобы для сформулированной гипотезы о структуре связей признаков, получить по выборочным частотам оценки ожидаемых частот и, затем по степени соответствия выборочных и модельных частот, проверить выдвинутую гипотезу.

Например, в случае проверки гипотезы о независимости всех признаков ожидаемые частоты получаются на основе распределений частот по градациям каждого из признаков. Если выдвинутая гипотеза предполагает существование какой-то взаимосвязи, то при оценке ожидаемых частот учитывается соответствующая маргинальная таблица.

Пусть есть три фактора A, B, C, классифицированных на r, s, t категорий соответственно. Таким образом, данные можно записать в виде трехмерной таблицы сопряженности наблюдаемых частот n_{ijk} где i = 1,... r; j = 1,..., s; k = 1,..., t.

В этом случае логлинейная насыщенная модель будет иметь вид:

$$\ln n^*_{ijk} = u_0 + u^a_{i_1} + u^b_j + u^c_k + u^{ab}_{ij} + u^{ac}_{ik} + u^{bc}_{jk} + u^{abc}_{ijk}. \quad (5.1)$$

Чтобы число параметров не превысило числа ячеек r×s×t, то на параметры модели накладываются ограничения:

$$\sum_i u^a_i = \sum_j u^b_j = \sum_k u^c_k = \sum_i u^{ab}_{ij} = \sum_i u^{ab}_{ij} = \sum_j u^{ac}_{ik} = \sum_k u^{ac}_{jk} = \sum_j u^{bc}_{jk} = \sum_k u^{bc}_{jk} = \sum_j u^{bc}_{ijk} = \sum_j u^{abc}_{ijk} = \sum_k u^{abc}_{ijk}. \quad (5.2)$$

Параметры модели называются:

u_0 – общее среднее;

u_i^a – главное влияние, эффект i-категории фактора A;

u_j^b – главное влияние, эффект j-категории фактора B;

u_k^c – главное влияние, эффект k-категории фактора C;

u_{ij}^{ab} – взаимодействие первого порядка i и j категорий, влияние конъюнкции факторов A и B, взаимодействие двух факторов A и B i и j категорий;

u_{ik}^{ac} – взаимодействие первого порядка i и k категорий, влияние конъюнкции факторов A и C, взаимодействие двух факторов A и C i и k категорий;

u_{jk}^{bc} – взаимодействие первого порядка влияние j и k категорий, конъюнкции факторов B и C, взаимодействие двух факторов B и C j и k категорий;

u_{ijk}^{abc} – трехфакторное взаимодействие категорий факторов A, B и C i, j, k - категорий, взаимодействие второго порядка.

Для нахождения параметров модели, обозначим $y_{ijk} = \ln n^*_{ijk}$.

Определим средние значения по строкам и столбцам таблицы:

1. Общая средняя:

$$y_{***} = \frac{1}{rst}\sum_i\sum_j\sum_k y_{ijk}. \quad (5.3)$$

2. Средняя уровня фактора:

$$y_{i**} = \frac{1}{st}\sum_j\sum_k y_{ijk} \text{ – фактора A;} \quad (5.4)$$

$$y_{*j*} = \frac{1}{rt}\sum_i\sum_k y_{ijk} \text{ – фактора B;} \quad (5.5)$$

$$y_{**k} = \frac{1}{rs}\sum_i\sum_j y_{ijk} \text{ – фактора C.} \quad (5.6)$$

Средняя уровня взаимодействия двух факторов:

$$y_{ij*} = \frac{1}{t}\sum_k y_{ijk} \text{ – A и B,} \quad (5.7)$$

$$y_{i*k} = \frac{1}{s}\sum_j y_{ijk} \text{ – A и C,} \quad (5.8)$$

$$y_{*jk} = \frac{1}{r}\sum_i y_{ijk} \text{ – B и C.} \quad (5.9)$$

Подставляя выражения (5.1) в правые части уравнений (5.3)–(5.9) и учитывая (5.2), получим выражения параметров через средние для логарифмов теоретических частот:

$$u_i^a = y_{i**} - y_{***};$$
$$u_j^b = y_{*j*} - y_{***};$$
$$u_k^c = y_{**k} - y_{***};$$
$$u_{ij}^{ab} = y_{ij*} - y_{i**} + y_{***} - y_{*j*};$$
$$u_{ik}^{ac} = y_{i*k} - y_{i**} + y_{***} - y_{**k};$$
$$u_{jk}^{bc} = y_{*jk} - y_{*j*} + y_{***} - y_{**k};$$
$$u_{ijk}^{abc} = y_{ijk} - y_{ij*} - y_{i*k} - y_{*jk} + y_{i**} + y_{*j*} + y_{**k} - y_{***}.$$

Модель полностью воспроизводит таблицу сопряженности наблюдаемых частот.

5.2 Логлинейные модели для таблиц сопряженности 2×2×2

1. *Насыщенная модель (модель ABC).*

Когда все три фактора A, B, C дихотомические, то есть r=s=t=2, то модель (5.1) можно записать:

$$y_{ijk} = u_0 + u_i^a + u_j^b + u_k^c + u_{ij}^{ab} + u_{ik}^{ac} + u_{jk}^{bc} + u_{ijk}^{abc}$$

для i = 1,2; j = 1,2; k = 1,2.

В этой модели имеется восемь параметров, которые являются независимыми, остальные параметры зависят от них по следующим формулам:

$$u_2^a = -u_1^a; \quad u_2^b = -u_1^b; \quad u_2^c = -u_1^c;$$
$$u_{11}^{ab} = -u_{12}^{ab}; \quad u_{21}^{ab} = -u_{11}^{ab}; \quad u_{11}^{ab} = u_{22}^{ab};$$
$$u_{12}^{ac} = -u_{11}^{ac}; \quad u_{12}^{bc} = -u_{11}^{bc}; \quad u_{21}^{ac} = -u_{11}^{ac};$$
$$u_{21}^{bc} = -u_{11}^{bc}; \quad u_{22}^{ac} = u_{11}^{ac}; \quad u_{22}^{bc} = u_{11}^{bc};$$
$$u_{112}^{abc} = -u_{111}^{abc}; \quad u_{121}^{abc} = -u_{111}^{abc}; \quad u_{211}^{abc} = -u_{111}^{abc};$$
$$u_{222}^{abc} = -u_{111}^{abc}; \quad u_{122}^{abc} = u_{111}^{abc}; \quad u_{212}^{abc} = u_{111}^{abc}; \quad u_{221}^{abc} = u_{111}^{abc}.$$

Число степеней свободы определяется аналогично двумерной таблицы сопряженности:

$$\nu = K_K - K_П + K_O,$$

где: K_K – число клеток таблицы;

$K_П$ – число параметров модели;

K_O – число ограничений на параметры.

Для данной модели число клеток K_K=8.

Общее число параметров = число параметров(u_0) + число параметров (u_i^a) + число параметров (u_j^b) + число параметров (u_k^c) + число параметров (u_{ij}^{ab}) + число параметров (u_{ik}^{ac}) + число параметров (u_{jk}^{bc}) + число параметров (u_{ijk}^{abc}) = 1 + 2 + 2 + 2 + 4 + 4 + 4 + 8 = 27.

$K_П = 27$.

Число ограничений на параметры: $K_O = 19$.

$$\nu = K_K - K_П + K_O = 8 - 27 + 19 = 0.$$

Для проверки соответствия модели данным используются критерий хи-квадрат или информационный критерий хи-квадрат.

В случае насыщенной модели как и для таблиц сопряженности 2×2 значение критерия $X^2_{инф} = 0$, так как наблюдаемые частоты равны теоретическим, то есть $n^*_{ijk} = n_{ijk}$.

Обозначим:

$$y_{ijk} = \ln n^*_{ijk} = \ln n_{ijk}.$$

Для таблицы сопряженности 2×2×2 получим следующие оценки средних:

$$y_{ij*} = \frac{1}{2}\ln(n^*_{ij1} n^*_{ij2});$$

$$y_{i*k} = \frac{1}{2}\ln(n^*_{i1k} n^*_{i2k});$$

$$y_{*jk} = \frac{1}{2}\ln(n^*_{1jk} n^*_{2jk});$$

для i = 1,2; j = 1,2; k = 1,2.

Параметры логлинейной модели можно вычислить следующим образом:

$$u_0 = \frac{1}{8}\sum_{i,j,k} \ln n^*_{ijk};$$

$$u_1^a = -u_2^a = \frac{1}{8}\ln\frac{n^*_{111} n^*_{112} n^*_{121} n^*_{122}}{n^*_{211} n^*_{212} n^*_{221} n^*_{222}};$$

$$u_1^b = -u_2^b = \frac{1}{8}\ln\frac{n^*_{111} n^*_{112} n^*_{211} n^*_{212}}{n^*_{121} n^*_{122} n^*_{221} n^*_{222}};$$

$$u_1^c = -u_2^c = \frac{1}{8}\ln\frac{n^*_{111} n^*_{121} n^*_{211} n^*_{221}}{n^*_{112} n^*_{122} n^*_{212} n^*_{222}}.$$

$$u^{ac}_{11} = -u^{ac}_{12} = -u^{ab}_{21} = u^{ab}_{22} = \frac{1}{8}\ln\frac{n^*_{111} n^*_{112} n^*_{221} n^*_{222}}{n^*_{121} n^*_{122} n^*_{211} n^*_{212}};$$

$$u^{ac}_{11} = -u^{ac}_{12} = -u^{ac}_{21} = u^{ac}_{22} = \frac{1}{8}\ln\frac{n^*_{111} n^*_{121} n^*_{212} n^*_{222}}{n^*_{112} n^*_{122} n^*_{211} n^*_{212}};$$

$$u^{bc}_{11} = -u^{bc}_{12} = -u^{bc}_{21} = u^{bc}_{22} = \frac{1}{8}\ln\frac{n^*_{111} n^*_{211} n^*_{122} n^*_{222}}{n^*_{112} n^*_{212} n^*_{211} n^*_{221}};$$

$$u_{111}^{abc} = \frac{1}{8}\ln\frac{n^*_{111}n^*_{122}n^*_{212}n^*_{221}}{n^*_{112}n^*_{121}n^*_{211}n^*_{222}}.$$

Число степеней свободы насыщенной модели ν = 0.

2. Модель условной независимости AB, AC, BC (AB/AC/BC).
В модели параметр $u_{ijk}^{abc} = 0$:

$$y_{ijk} = u_0 + u_i^a + u_j^b + u_k^c + u_{ij}^{ab} + u_{ik}^{ac} + u_{jk}^{bc}. \qquad (5.10)$$

Следовательно, необходимо проверить гипотезу

H_0:{∀i, j, k, $u_{ijk}^{abc} = 0$} против гипотезы H_1: {∃i, j, k, $u_{ijk}^{abc} \neq 0$}.

Эту гипотезу можно записать в равносильном виде:

$$H_0^8: \{ \frac{n^*_{111}n^*_{122}n^*_{212}n^*_{221}}{n^*_{112}n^*_{121}n^*_{211}n^*_{222}} = 1\} .$$

В компьютерных программах, как правило, реализован итерационный алгоритм нахождения теоретических частот для произвольной модели.

Для вычисления теоретической частоты n^*_{111} вручную необходимо найти корень многочлена относительно неизвестного $x = n^*_{111}$.

Выразим n^*_{ijk} в равенстве:

$$n^*_{111}n^*_{122}n^*_{212}n^*_{221} = n^*_{112}n^*_{121}n^*_{211}n^*_{222}$$

через n^*_{111} и маргинальные частоты, получим

$$n^*_{112} = n_{11*} - n^*_{111};$$
$$n^*_{121} = n_{1*1} - n^*_{111};$$
$$n^*_{211} = n_{*11} - n^*_{111};$$
$$n^*_{122} = n_{12*} - n^*_{121} = n_{12*} - n_{1*1} + n^*_{111}.$$
$$n^*_{212} = n_{*12} - n^*_{112} = n_{*12} - n_{11*} + n^*_{111} = n_{*12} - n_{11*} + n^*_{111};$$
$$n^*_{221} = n_{*21} - n^*_{121} = n_{*21} - n_{1*1} + n^*_{111} = n_{*21} - n_{1*1} + n^*_{111};$$
$$n^*_{222} = n_{*22} - n^*_{122} = n_{*22} - n_{12*} + n_{1*1} - n^*_{111} = n_{*22} - n_{12*} + n_{1*1} - n^*_{111}.$$

Имеем многочлен четвертой степени относительно неизвестной частоты n^*_{111}. Для нахождения корня этого многочлена возможно применить метод деления отрезка пополам.

Для проверки нулевой гипотезы вычисляют наблюдаемое значение информационного критерия:

$$X^2_{инф} = 2\sum_i\sum_j\sum_k n_{ijk}\ln\frac{n_{ijk}}{n^*_{ijk}}. \qquad (5.11)$$

Если $X^2_{инф}$ попало в критическую область, то есть $X^2_{инф} > X^2_{крит}$ то гипотеза

$$H_0:\{\forall i, j, k, u_{ijk}^{abc} = 0\}$$

отвергается с вероятностью ошибки α, параметр модели u_{ijk}^{abc} не равен нулю, то есть трехфакторное взаимодействие существенно влияет на частоты в генеральной совокупности, а сама модель практически непригодна. В этом случае выбираем насыщенную модель.

Если $\chi^2_{инф}$ не попала в критическую область, то есть $\chi^2_{инф}<\chi^2_{крит}$, то гипотеза H_0 не отвергается. При принятии этой гипотезы отсутствует влияние трехфакторного взаимодействия на теоретические частоты. Выборочные частоты можно объяснить с помощью принимаемой модели (5.10).

Информационный критерий позволяет оценить значимость конкретной взаимосвязи в модели. Если есть две гипотезы H_1 и H_2 отличающиеся лишь одной взаимосвязью, то величина

$$g^2=\left|\chi_I^2(H_1)-\chi_I^2(H_2)\right|$$

характеризует вклад этой взаимосвязи, и также имеет хи-квадрат распределение с $\nu=\left|\nu_{H_1}-\nu_{H_2}\right|$ числом степеней свободы.

Вклад, вносимый в $\chi^2_{инф}$ параметром u_{ijk}^{abc}, равен $\chi^2_{инф}$ для модели с отсутствием трехфакторного взаимодействия минус $\chi^2_{инф}$ насыщенной модели.

Число степеней свободы для этой модели равно 1.

Параметры находятся по формулам (5.8) и (5.9).

3. *Модель с отсутствием взаимодействия BC (AB/AC)* имеет вид:

$$y_{ijk}=u_0+u_i^a+u_j^b+u_k^c+u_{ij}^{ab}+u_{ik}^{ac}\ . \qquad (5.12)$$

Это модель условной независимости между факторами B и C при каждой фиксированной категории фактора A.

Проверяем нулевую гипотезу H_0:$\{\forall i, j, k, u_{ijk}^{abc} = 0$ и $u_{jk}^{bc} = 0\}$ против гипотезы H_1: $\{\exists i, j, k, u_{ijk}^{abc} \neq 0$ или $u_{jk}^{bc} \neq 0\}$.

Для теоретических частот необходимо проверить нулевую гипотезу:

$$H_0:\{n_{ijk}^*=\frac{n_{ij*}\cdot n_{i*k}}{n_{i**}},\forall i,j,k\}$$

против гипотезы

$$H_1:\{n_{ijk}^*\neq\frac{n_{ij*}\cdot n_{i*k}}{n_{i**}},\exists i,j,k\}.$$

Для проверки нулевой гипотезы вычисляют статистику (5.11), для которой теоретические частоты определяются по формуле:

$$n_{ijk}^*=\frac{n_{ij*}\cdot n_{i*k}}{n_{i**}}$$ для i = 1, 2; j=1, 2; k=1, 2.

Число степеней свободы для этой модели равно 2.

Если вычисленное значение $\chi^2_{инф}$ не попадает в критическую область, то модель считается адекватной и по разности значений $\chi^2_{инф}$

для данной модели и $\chi^2_{\text{инф}}$ для модели независимости AB, AC, BC определяют вклад, вносимый параметром u_{11}^{bc} для числа степеней свободы равному разности 2 – 1 = 1.

Если наблюдаемое значение $\chi^2_{\text{инф}} < \chi^2_{\text{крит}}$, то гипотеза H_0 не отвергается, то есть оба параметра u_{ijk}^{abc} и u_{jk}^{bc} можно принять равными нулю.

В этом случае вместо модели AB/AC/BC для объяснения исходных данных удобнее применить модель AB/BC, так как последняя содержит меньше параметров и может более удовлетворительно объяснить исходную информацию.

Параметры модели определяют по формуле (5.9).

4. *Модель с отсутствием взаимодействия AC (AB/BC)* имеет вид:

$$y_{ijk} = u_0 + u_i^a + u_j^b + u_k^c + u_{ij}^{ab} + u_{jk}^{bc} \ . \qquad (5.13)$$

Это модель условной независимости между факторами A и C при каждой фиксированной категории фактора B.

Проверяем нулевую гипотезу H_0:$\{\forall$i, j, k, $u_{ijk}^{abc} = 0$ и $u_{ik}^{ac} = 0\}$ против гипотезы H_1: $\{\exists$i, j, k, $u_{ijk}^{abc} \neq 0$ или $u_{ik}^{ac} \neq 0\}$.

Число степеней свободы ν = 8 – 6 = 2.

Гипотезу можно переписать в виде:

$$H_0: \{n_{ijk}^* = \frac{n_{ij*} \cdot n_{*jk}}{n_{*j*}}, \forall i, j, k\}.$$

Для проверки гипотезы применяют критерий хи-квадрат (5.11), где теоретические частоты рассчитывают:

$$n_{ijk}^* = \frac{n_{ij*} \cdot n_{*jk}}{n_{*j*}} \text{ для всех i, j, k.}$$

Проверка адекватности осуществляется аналогично предыдущей модели.

5. *Модель с отсутствием взаимодействия AB (AC/BC)* имеет вид:

$$y_{ijk} = u_0 + u_i^a + u_j^b + u_k^c + u_{ik}^{ac} + u_{jk}^{bc} \ . \qquad (5.14)$$

Это модель условной независимости между факторами A и B при каждой фиксированной категории фактора C.

Проверяем нулевую гипотезу H_0:$\{\forall$i, j, k, $u_{ijk}^{abc} = 0$ и $u_{ik}^{ab} = 0\}$ против гипотезы H_1: $\{\exists$i, j, k, $u_{ijk}^{abc} \neq 0$ или $u_{ik}^{ab} \neq 0\}$.

Число степеней свободы ν = 8 – 6 = 2.

Гипотезу перепишем в виде:

$$H_0: \{n_{ijk}^* = \frac{n_{i*k} \cdot n_{*jk}}{n_{**k}}, \forall i, j, k\}.$$

Вычисляем наблюдаемое значение $\chi^2_{\text{инф}}$ (5.11). Значения теоретических частот для модели:

$$n^*_{ijk} = \frac{n_{i*k} \cdot n_{*jk}}{n_{**k}}.$$

Параметры модели находятся по формулам (5.8) и (5.9).

6. Модель независимости AB и C (AB/C):

$$y_{ijk} = u_0 + u^a_i + u^b_j + u^c_k + u^{ab}_{ij} \quad . \tag{5.15}$$

Это модель условной независимости между факторами A и B от фактора C.

Проверяем нулевую гипотезу

$$H_0: \{\forall i, j, k, u_{ijk}{}^{abc} = 0 \ , u_{ik}{}^{ac} = 0, u_{jk}{}^{bc} = 0\}$$

против гипотезы H_1: $\{\exists i, j, k, u_{ijk}{}^{abc} \neq 0$ или $u_{ik}{}^{ac} \neq 0$, или $u_{jk}{}^{bc} \neq 0\}$.

Или, в терминах теоретических частот, проверяется гипотеза:

$$H_0: \{n^*_{ijk} = \frac{n_{ij*} \cdot n_{**k}}{n_{***}}, \forall i, j, k\}.$$

Наблюдаемое значение $\chi^2_{\text{инф}}$ вычисляется по формуле (5.11). Значение теоретических частот для этой модели:

$$n^*_{ijk} = \frac{n_{ij*} \cdot n_{**k}}{n_{***}}.$$

Число степеней свободы $\nu = 8 - 5 = 3$.

7. *Модель независимости AC и B (AC/B)*:

$$y_{ijk} = u_0 + u^a_i + u^b_j + u^c_k + u^{ac}_{ik} \quad . \tag{5.16}$$

Это модель условной независимости между факторами A и C от фактора B.

Проверяем нулевую гипотезу

$$H_0: \{\forall i, j, k, u_{ijk}{}^{abc} = 0 \ , u_{ij}{}^{ab} = 0, u_{jk}{}^{bc} = 0\}$$

против гипотезы H_1: $\{\exists i, j, k, u_{ijk}{}^{abc} \neq 0$ или $u_{ij}{}^{ab} \neq 0$, или $u_{jk}{}^{bc} \neq 0\}$.

Проверяется гипотеза:

$$H_0: \{n^*_{ijk} = \frac{n_{i*k} \cdot n_{*j*}}{n_{***}}, \forall i, j, k\}$$

Число степеней свободы $\nu = 8 - 5 = 3$.

Теоретические частоты рассчитываются по формуле:

$$n^*_{ijk} = \frac{n_{ij*} \cdot n_{**k}}{n_{***}}.$$

8. *Модель независимости BC и A (BC/A)*:

$$y_{ijk} = u_0 + u_i^a + u_j^b + u_k^c + u_{jk}^{bc} \ . \qquad (5.17)$$

Это модель условной независимости между факторами B и C от фактора A.

Проверяем нулевую гипотезу

$$H_0: \{\forall i, j, k, u_{ijk}^{abc} = 0 \ , u_{ij}^{ab} = 0, u_{ik}^{ac} = 0\}$$

против гипотезы H_1: $\{\exists i, j, k, u_{ijk}^{abc} \neq 0$ или $u_{ij}^{ab} \neq 0$,или $u_{ik}^{ac} \neq 0\}$.

Проверяется гипотеза:

$$H_0: \{n_{ijk}^* = \frac{n_{*jk} \cdot n_{i**}}{n_{***}}, \forall i, j, k\}$$

Число степеней свободы ν = 8 – 5 = 3.

Теоретические частоты рассчитываются по формуле:

$$n_{ijk}^* = \frac{n_{*jk} \cdot n_{i**}}{n_{***}}.$$

9. *Модель главных эффектов трех факторов (A/B/C)*:

$$y_{ijk} = u_0 + u_i^a + u_j^b + u_k^c \ . \qquad (5.18)$$

Проверяем нулевую гипотезу

$$H_0: \{\forall i, j, k, u_{ijk}^{abc} = 0 \ , u_{ij}^{ab} = 0, u_{ik}^{ac} = 0, u_{jk}^{bc} = 0\}$$

против гипотезы:

H_1: $\{\exists i, j, k, u_{ijk}^{abc} \neq 0$ или $u_{ij}^{ab} \neq 0$,или $u_{ik}^{ac} \neq 0$, или $u_{jk}^{bc} \neq 0\}$.

Проверяем гипотезу:

$$H_0 : \{n_{ijk}^* = \frac{n_{i**}}{n_{***}} \cdot \frac{n_{*j*}}{n_{***}} \cdot n_{**k} = \frac{n(A)}{n_{***}} \cdot \frac{n(B)}{n_{***}} n(C); i = 1,2; j = 1,2; k = 1,2\}.$$

Теоретические частоты для критерия (5.11) рассчитываются:

$$n_{ijk}^* = \frac{n_{i**}}{n_{***}} \cdot \frac{n_{*j*}}{n_{***}} \cdot n_{**k}.$$

Число степеней свободы ν = 8 – 4 = 4.

10. *Модель с отсутствием влияния главного эффекта фактора A (AB)*:

$$y_{ijk} = u_0 + u_i^a + u_j^b + u_{ij}^{ab} \ . \qquad (5.19)$$

Проверяем нулевую гипотезу:

$$H_0: \{\forall i, j, k, u_{ijk}^{abc} = 0, u_{ik}^{ac} = 0, u_{jk}^{bc} = 0, u_k^{c} = 0\}$$

против гипотезы:

$$H_1: \{\exists i, j, k, u_{ijk}^{abc} \neq 0 \text{ или } u_{ik}^{ac} \neq 0, \text{ или } u_{jk}^{bc} \neq 0, \text{ или } u_k^{c} \neq 0\}.$$

Следует проверить гипотезу:

$$H_0: \{n_{ijk}^{*} = \frac{n_{ij*}}{2} \ \forall i, j, k\}.$$

Теоретические частоты определяются:

$$n_{ijk}^{*} = \frac{n_{ij*}}{2} \ .$$

Число степеней свободы равно 4.

11. *Модель с отсутствием влияния главного эффекта фактора B (AC)*:

$$y_{ijk} = u_0 + u_i^a + u_k^c + u_{ik}^{ac} \ . \qquad (5.20)$$

Проверяем нулевую гипотезу

$$H_0: \{\forall i, j, k, u_{ijk}^{abc} = 0 \ , u_{ij}^{ab} = 0, u_{jk}^{bc} = 0, u_j^{b} = 0\}$$

против гипотезы:

$$H_1: \{\exists i, j, k, u_{ijk}^{abc} \neq 0 \text{ или } u_{ij}^{ab} \neq 0, \text{ или } u_{jk}^{bc} \neq 0, \text{ или } u_j^{b} \neq 0\}.$$

Следует проверить гипотезу:

$$H_0: \{n_{ijk}^{*} = \frac{n_{i*k}}{2} \ \forall i, j, k\}.$$

Теоретические частоты для критерия (5.11) определяются:

$$n_{ijk}^{*} = \frac{n_{i*k}}{2} \ .$$

Число степеней свободы равно 4.

12. *Модель с отсутствием влияния главного эффекта фактора A (BC)*:

$$y_{ijk} = u_0 + u_j^b + u_k^c + u_{jk}^{bc} \ . \qquad (5.21)$$

Проверяем нулевую гипотезу

$$H_0: \{\forall i, j, k, u_{ijk}^{abc} = 0 \ , u_{ij}^{ab} = 0, u_{ik}^{ac} = 0, u_i^{a} = 0\}$$

против гипотезы:

$$H_1: \{\exists i, j, k, u_{ijk}^{abc} \neq 0 \text{ или } u_{ij}^{ab} \neq 0, \text{или } u_{ik}^{ac} \neq 0, \text{ или } u_i^{a} \neq 0\}.$$

Проверяем гипотезу:

$$H_0: \{n_{ijk}^{*} = \frac{n_{*jk}}{2} \ \forall i, j, k\}.$$

Теоретические частоты для критерия (5.11) определяются:

$$n_{ijk}^{*} = \frac{n_{*jk}}{2} \ .$$

Число степеней свободы равно 4.

13. *Модель с отсутствием влияния главного эффекта фактора C и независимость между факторами A и B (A/B)*:

$$y_{ijk} = u_0 + u_i^a + u_j^b \ . \qquad (5.22)$$

Проверяем нулевую гипотезу

$$H_0: \{\forall i, j, k,\ u_{ijk}^{abc} = 0\ ,\ u_{ij}^{ab} = 0,\ u_{ik}^{ac} = 0,\ u_{jk}^{bc} = 0,\ u_k^c = 0\}$$

против гипотезы:

$$H_1: \{\exists i, j, k,\ u_{ijk}^{abc} \neq 0 \text{ или } u_{ij}^{ab} \neq 0, \text{или } u_{ik}^{ac} \neq 0, \text{ или } u_{jk}^{bc} \neq 0, \text{ или } u_k^c \neq 0\}.$$

Следует проверить гипотезу:

$$H_0: \{n_{ijk}^* = \frac{n_{i**} \cdot n_{*j*}}{4} \ \forall i, j, k\}.$$

Теоретические частоты для критерия (5.11) определяются:

$$n_{ijk}^* = \frac{n_{i**} \cdot n_{*j*}}{4} \ .$$

Число степеней свободы равно 5.

14. *Модель с отсутствием влияния главного эффекта фактора B и независимость между факторами A и C (A/C)*:

$$y_{ijk} = u_0 + u_i^a + u_k^c \ . \qquad (5.23)$$

Проверяем нулевую гипотезу

$$H_0: \{\forall i, j, k,\ u_{ijk}^{abc} = 0\ ,\ u_{ij}^{ab} = 0,\ u_{ik}^{ac} = 0,\ u_{jk}^{bc} = 0,\ u_j^b = 0\}$$

против гипотезы:

$$H_1: \{\exists i, j, k,\ u_{ijk}^{abc} \neq 0 \text{ или } u_{ij}^{ab} \neq 0, \text{или } u_{ik}^{ac} \neq 0, \text{ или } u_{jk}^{bc} \neq 0, \text{ или } u_j^b \neq 0\}.$$

Проверяем гипотезу:

$$H_0: \{n_{ijk}^* = \frac{n_{i**} \cdot n_{**k}}{4} \ \forall i, j, k\}.$$

Теоретические частоты для критерия (5.11) определяются:

$$n_{ijk}^* = \frac{n_{i**} \cdot n_{**k}}{4} \ .$$

Число степеней свободы равно 5.

15. *Модель с отсутствием влияния главного эффекта фактора A и независимость между факторами B и C (B/C)*:

$$y_{ijk} = u_0 + u_j^b + u_k^c \ . \qquad (5.24)$$

Проверяем нулевую гипотезу

$$H_0: \{\forall i, j, k,\ u_{ijk}^{abc} = 0\ ,\ u_{ij}^{ab} = 0,\ u_{ik}^{ac} = 0,\ u_{jk}^{bc} = 0,\ u_i^a = 0\}$$

против гипотезы:

$$H_1: \{\exists i, j, k,\ u_{ijk}^{abc} \neq 0 \text{ или } u_{ij}^{ab} \neq 0, \text{или } u_{ik}^{ac} \neq 0, \text{ или } u_{jk}^{bc} \neq 0, \text{ или } u_i^a \neq 0\}.$$

Проверяем гипотезу:

$$H_0 : \{n^*_{ijk} = \frac{n_{*j*} \cdot n_{**k}}{4} \forall i, j, k\} .$$

Теоретические частоты для критерия (5.11) определяются:

$$n^*_{ijk} = \frac{n_{*j*} \cdot n_{**k}}{4} \ .$$

Число степеней свободы равно 5.

16. *Однофакторная модель с отсутствием действия фактов A и C (B)*:

$$y_{ijk} = u_0 + u^b_j \ . \qquad (5.25)$$

Проверяем нулевую гипотезу

H_0:{$\forall$i, j, k, $u_{ijk}{}^{abc} = 0$, $u_{ij}{}^{ab} = 0$, $u_{ik}{}^{ac} = 0$, $u_{jk}{}^{bc} = 0$, $u_i{}^a = 0$, $u_k{}^c = 0$}

против гипотезы:

H_1: {$\exists$i, j, k, $u_{ijk}{}^{abc} \neq 0$ или $u_{ij}{}^{ab} \neq 0$,или $u_{ik}{}^{ac} \neq 0$, или $u_{jk}{}^{bc} \neq 0$,

или $u_i{}^a \neq 0$ или $u_k{}^c \neq 0$}.

Проверяем гипотезу:

$$H_0 : \{n^*_{ijk} = \frac{n_{*j*}}{4} \ \forall i, j, k\} .$$

Теоретические частоты для критерия (5.11) определяются:

$$n^*_{ijk} = \frac{n_{*j*}}{4} \ .$$

Число степеней свободы равно 6.

17. *Однофакторная модель с отсутствием действия факторов A и B (C)*:

$$y_{ijk} = u_0 + u^c_k \ . \qquad (5.26)$$

Проверяем нулевую гипотезу

H_0:{$\forall$i, j, k, $u_{ijk}{}^{abc} = 0$, $u_{ij}{}^{ab} = 0$, $u_{ik}{}^{ac} = 0$, $u_{jk}{}^{bc} = 0$, $u_i{}^a = 0$, $u_j{}^b = 0$}

против гипотезы:

H_1: {$\exists$i, j, k, $u_{ijk}{}^{abc} \neq 0$ или $u_{ij}{}^{ab} \neq 0$,или $u_{ik}{}^{ac} \neq 0$, или $u_{jk}{}^{bc} \neq 0$,

или $u_i{}^a \neq 0$ или $u_j{}^b \neq 0$}.

Проверяем гипотезу:

$$H_0 : \{n^*_{ijk} = \frac{n_{**k}}{4} \ \forall i, j, k\} .$$

Теоретические частоты для критерия (5.11) определяются:

$$n^*_{ijk} = \frac{n_{**k}}{4} \ .$$

Число степеней свободы равно 6.

18. *Однофакторная модель с отсутствием действия факторов B и C (A)*:

$$y_{ijk} = u_0 + u_i^a \ . \qquad (5.27)$$

Проверяем нулевую гипотезу

H_0:{∀i, j, k, $u_{ijk}^{abc} = 0$, $u_{ij}^{ab} = 0$, $u_{ik}^{ac} = 0$, $u_{jk}^{bc} = 0$, $u_k^c = 0$, $u_j^b = 0$}

против гипотезы:

H_1: {∃i, j, k, $u_{ijk}^{abc} \neq 0$ или $u_{ij}^{ab} \neq 0$,или $u_{ik}^{ac} \neq 0$, или $u_{jk}^{bc} \neq 0$, или $u_k^c \neq 0$ или $u_j^b \neq 0$}.

Проверяем гипотезу:

$$H_0: \{n_{ijk}^* = \frac{n_{i**}}{4} \ \forall i, j, k\} .$$

Теоретические частоты для критерия (5.11) определяются:

$$n_{ijk}^* = \frac{n_{i**}}{4} \ .$$

Число степеней свободы равно 6.

19. *Равновероятная модель:*

$$y_{ijk} = u_0 \ . \qquad (5.28)$$

Проверяем нулевую гипотезу

H_0:{∀i, j, k, $u_{ijk}^{abc} = 0$, $u_{ij}^{ab} = 0$, $u_{ik}^{ac} = 0$, $u_{jk}^{bc} = 0$, $u_k^c = 0$, $u_j^b = 0$, $u_i^a = 0$}

против гипотезы:

H_1: {∃i, j, k, $u_{ijk}^{abc} \neq 0$ или $u_{ij}^{ab} \neq 0$,или $u_{ik}^{ac} \neq 0$, или $u_{jk}^{bc} \neq 0$, или $u_k^c \neq 0$ или $u_j^b \neq 0$, или $u_i^a \neq 0$}.

Проверяем гипотезу:

$$H_0: \{n_{ijk}^* = \frac{n_{***}}{8} \ \forall i, j, k\} .$$

Теоретические частоты для критерия (5.11) определяются:

$$n_{ijk}^* = \frac{n_{***}}{8} \ .$$

Число степеней свободы равно 7.

5.3. Тренировочный пример

Была получена следующая таблица распределения студентов по признакам:

A – Пол (1 – мужской, 2 – женский);

B – Форма обучения (1– дневная, 2 – вечерняя);

C – Удовлетворенность избранной специальностью (1 – да, 2 – нет).

Таблица 5.1

Пол	Форма обучения	Удовлетворенность	
		1. Да	2. Нет
1. Мужской	1.Дневная	100	60
	2.Вечерняя	70	30
2. Женский	1.Дневная	80	40
	2.Вечерняя	50	70

Рассчитав ожидаемые частоты в ячейках таблицы с помощью информационного критерия, можно проверить сформулированную гипотезу о связях признаков.

Введем следующие обозначения для частных (маргинальных) таблиц:

$$n(A)=n_{i**}=\begin{pmatrix}250\\240\end{pmatrix};\ n(B)=n_{*j*}=\begin{pmatrix}280\\220\end{pmatrix};\quad n(C)=n_{**k}=\begin{pmatrix}300\\200\end{pmatrix};$$

$$n(AB)=n_{ij*}=\begin{pmatrix}160 & 100\\120 & 120\end{pmatrix};\ n(AC)=n_{i*k}=\begin{pmatrix}170 & 90\\130 & 110\end{pmatrix};$$

$$n(BC)=n_{*jk}=\begin{pmatrix}180 & 100\\120 & 100\end{pmatrix}.$$

В случае трех признаков сформулируем восемь вариантов гипотез о взаимосвязях. В зависимости от формулируемой гипотезы ожидаемые частоты будут рассчитываться на основе соответствующего набора маргинальных таблиц. Иногда ожидаемые частоты могут быть вычислены аналитически, но в общем случае необходимо использовать итерационный алгоритм.

Гипотеза взаимной независимости признаков:

$$H_0^1:\{n_{ijk}^*=\frac{n_{i**}}{n_{***}}\cdot\frac{n_{*j*}}{n_{***}}\cdot n_{**k}=\frac{n(A)}{n_{***}}\cdot\frac{n(B)}{n_{***}}n(C);i=1,2;j=1,2;k=1,2.\}$$

Выполняются равенства n(A) = n* (A), n(B) = n*(B), n(C) = n*(C). Параметры логлинейной модели могут быть найдены по формулам (5.8) и (5.9):

$$u_0=\frac{1}{8}\sum_{i,j,k}\ln n_{ijk}^*;$$

$$u_1^a=-u_2^a=\frac{1}{8}\ln\frac{n_{111}^*n_{112}^*n_{121}^*n_{122}^*}{n_{211}^*n_{212}^*n_{221}^*n_{222}^*};$$

$$u_1^b=-u_2^b=\frac{1}{8}\ln\frac{n_{111}^*n_{112}^*n_{211}^*n_{212}^*}{n_{121}^*n_{122}^*n_{221}^*n_{222}^*};$$

$$u_1^c=-u_2^c=\ln\frac{n_{111}^*n_{121}^*n_{211}^*n_{221}^*}{n_{112}^*n_{122}^*n_{212}^*n_{222}^*}.$$

Ожидаемые частоты для перечисленных ниже гипотез приведены в таблице 5.3.

Значение информационного критерия составило 30,1 при ν= 4 степенях свободы, превосходит $\chi^2_{крит}(0{,}05;\ 4) = 9{,}49$. Таким образом, гипотеза о независимости отвергается.

Гипотезы об одной парной связи:

$H_0^2: \{n^*_{ijk} = \frac{n_{ij*}}{n_{***}} n_{**k}, \forall i,j,k\}$ – связь признаков АВ (независимость А и В от С);

$H_0^3: \{n^*_{ijk} = \frac{n_{i*k}}{n_{***}} n_{*j*}, \forall i,j,k\}$ – связь признаков АС (независимость А и С от В);

$H_0^4: \{n^*_{ijk} = \frac{n_{*jk}}{n_{***}} n_{i**}, \forall i,j,k\}$ – связь признаков ВС (независимость В и С от А).

Для H_0^2 выполняется равенство n(AB)= n* (AB), и т.д. Из независимости признаков В и С следует равенство $\frac{n^*_{111}}{n^*_{112}} = \frac{n^*_{211}}{n^*_{212}}$, то есть $\frac{96}{64} = \frac{60}{40} = \frac{72}{48} = 1{,}5$.

Аналогичные равенства верны и для признаков А и С.

Параметры логлинейной модели, соответствующие взаимодействию для гипотез H_0^1, H_0^2, H_0^3, H_0^4 вычисляются по следующим формулам:

$$u_{11}^{ab} = -u_{12}^{ab} = -u_{21}^{ab} = u_{22}^{ab} = \frac{1}{8}\ln\frac{n^*_{111}n^*_{112}n^*_{221}n^*_{222}}{n^*_{121}n^*_{112}n^*_{211}n^*_{212}};$$

$$u_{11}^{ac} = -u_{12}^{ac} = -u_{21}^{ac} = u_{22}^{ac} = \frac{1}{8}\ln\frac{n^*_{111}n^*_{121}n^*_{212}n^*_{222}}{n^*_{112}n^*_{122}n^*_{211}n^*_{212}};$$

$$u_{11}^{bc} = -u_{12}^{bc} = -u_{21}^{bc} = u_{22}^{bc} = \frac{1}{8}\ln\frac{n^*_{111}n^*_{211}n^*_{122}n^*_{222}}{n^*_{112}n^*_{212}n^*_{121}n^*_{211}}.$$

Величины информационного критерия приведены в табл. 5.3. Число степеней свободы равно ν = 8 – 5 = 3. Величина $\chi^2_{табл}(0.05\ ;\ 3) = 7.81$, то есть ни одна из перечисленных гипотез не принимается.

Гипотезы о двух парных связях:

$H_0^5: \{n^*_{ijk} = \frac{n_{ij*} \cdot n_{i*k}}{n_{i**}}, \forall i,j,k\}$ – связь АВ, АС (взаимная независимость В и С);

$H_0^6: \{n^*_{ijk} = \frac{n_{ij*} \cdot n_{*jk}}{n_{*j*}}, \forall i,j,k\}$ – связь АВ, ВС (взаимная независимость А и С);

$H_0^7: \{n^*_{ijk} = \frac{n_{i*k} \cdot n_{*jk}}{n_{**k}}, \forall i,j,k\}$ – связь АС, ВС (взаимная независимость А и В).

Например, для H_5^0 выполняются равенства n(AB)=n^* (AB), n(AC)= n^*(AC).

Параметры логлинейных моделей вычисляются аналогично.

Гипотезу о трех парных связях AB, AC, BC (условной независимости признаков) можно записать в виде:

$$H_0^8: \{ \frac{n^*_{111}n^*_{122}n^*_{212}n^*_{221}}{n^*_{112}n^*_{121}n^*_{211}n^*_{222}} = 1 \} .$$

Разработаны универсальные алгоритмы, позволяющие найти теоретические частоты как для данной, так и любой другой модели и произвольного числа признаков.

Мы же воспользуемся для нахождения неизвестного $x = n^*_{111}$ следующим приемом.

Заменим в равенстве:

$$n^*_{111}n^*_{122}n^*_{212}n^*_{221} = n^*_{112}n^*_{121}n^*_{211}n^*_{222}$$

теоретические частоты на их выражения через $x=n^*_{111}$.

$$n^*_{112} = n_{11*} - n^*_{111} = n_{11*} - x = 170 - x$$
$$n^*_{121} = n_{1*1} - n^*_{111} = n_{1*1} - x = 180 - x$$
$$n^*_{211} = n_{*11} - n^*_{111} = n_{*11} - x = 160 - x$$
$$n^*_{122} = n_{12*} - n^*_{121} = n_{12*} - n_{1*1} + n^*_{111} = -50 + x$$
$$n^*_{212} = n_{*12} - n^*_{112} = n_{*12} - n_{11*} + n^*_{111} = n_{*12} - n_{11*} + x = -70 + x$$
$$n^*_{221} = n_{*21} - n^*_{121} = n_{*21} - n_{1*1} + n^*_{111} = n_{*21} - n_{1*1} + x = -50 + x$$
$$n^*_{222} = n_{*22} - n^*_{122} = n_{*22} - n_{12*} + n_{1*1} - n^*_{111} = n_{*22} - n_{12*} + n_{1*1} - x = 170 - x.$$

Получим уравнение четвертой степени относительно x:

$$F(x) = x \cdot (x - 50) \cdot (x - 70) \cdot (x - 50) -$$
$$- (160 - x) \cdot (170 - x) \cdot (180 - x) \cdot (170 - x) = 0$$

Для нахождения x применим метод половинного деления интервала.

Так как x и все выражения в скобках по смыслу задачи положительны, то должны выполняться соотношения x≥max(0;50;70;50) и x≤min(160;170;180;170).

Поэтому возьмем в качестве границ интервала x_1=70, x_2=160. На концах интервала функция F(x) имеет следующие значения

F(70)= –99000000<0, F(160)= 158400000>0.

Найдем середину отрезка: $x_3 = \frac{x_2 + x_1}{2} = 115.$

Если при x_3 многочлен положителен $F(x_3)>0$, то корень находится на отрезке $(x_1;x_3)$.

Если при x_3 многочлен отрицателен $F(x_3)<0$, то корень находится на отрезке $(x_3;x_2)$.

Процесс деления продолжаем до тех пор пока длина интервала станет меньше заранее выбранной величины (1 или 0.1) (см. Табл. 5.2).

Таблица 5.2

N	x_1	x_2	x_3	$F(x_1)$	$F(x_2)$	$F(x_3)$
1	70	160	115	–99000000	158400000	9652500
2	70	115	92,5	–99000000	9652500	–32599688
3	92,5	115	103,75	–32599688	9652500	–10590820
4	103,75	115	109,37	–10590820	9652500	–515434
5	109,375	115	112,18	–515435	9652500	4523593
6	109,375	112,18	110,78	–515435	4523593	1997016
7	109,375	110,78	110,07	–515435	1997016	739546
8	109,375	110,07	109,72	–515435	739546	111809

Таким образом, искомая величина n^*_{111}=109,7. Остальные теоретические частоты можно получить, используя приведенные выше выражения.

Величина $\chi^2_{набл}$= 13,1 > $\chi^2_{табл}$ (0,05; 1) = 3,84.

Следовательно, для данной таблицы существует трехфакторное взаимодействие показателей. То есть изменения доли удовлетворенных выбранной специальностью для мужчин и женщин различны на дневном и вечернем отделениях.

Таблица 5.3.

Гипотеза	Теоретические частоты					Величина	Параметры	
		A.1		A.2			логлинейной модели	
		B.1	B.2	B.1	B.2	X^2_1		
H^1_0	C.1	87,4	68,6	80,6	63,4	30.1	u_0=4.11	u^a_1=0.04
	C.2	58,2	45,8	53,7	42,2	ν=4	u^b_1=0.12	u^c_1=0.20
H^2_0	C.1	96,0	60,0	72,0	72,0	23,4	u_0=4.1	u^a_1=0.02
	C.2	64,0	40,0	48,0	48,0	ν=3	u^b_1=0.12	u^c_1=0.20
							u^{ab}_{11}=0.12	
H^3_0	C.1	95,2	74,8	72,8	57,2	23.6	u_0=4.101	u^a_1=0.017
	C.2	50,4	39,6	61,6	48,4	ν=3	u^b_1=0.121	u^c_1=0.201
							u^{ac}_{11}=0.117	
H^4_0	C.1	93,6	62,4	86,4	57,6	25.2	u_0=4.104	u^a_1=0.040
	C.2	52,0	52,0	48,0	48,0	ν=3	u^b_1=0.101	u^c_1=0.193
							u^{bc}_{11}=0.101	
H^5_0	C.1	102,9	54,6	77,1	65,5	18.5	u_0=4.09	u^a_1=0.027
	C.2	57,1	45,5	42,9	54,5	ν=2	u^b_1=0.098	u^c_1=0.19

Гипотеза	Теоретические частоты				Величина	Параметры	
						логлинейной	
						u^{ab}_{11}=-0.117	3 u^{bc}_{11}=0.10
H^6_0	C.1	102,0	68,0	78,0	52,0	18.1	u_0=4.1	u^a_1=0.017
	C.2	45,0	45,0	55,0	55,0	ν=2	u^b_1=0.101	u^c_1=0.191
							u^{ac}_{11}=-0.117	u^{bc}_{11}=1.01
H^7_0	C.1	104,6	55,4	65,0	65,0	16.9	u_0=4.07	u^a_1=0.018
	C.2	55,4	34,6	55,0	55,0	ν=2	u^b_1=0.138	u^c_1=0.180
							u^{ab}_{11}=0.138	u^{ac}_{11}=0.097
H^8_0	C.1	109,7	50.3	70,3	49,7	13.1	u_0=4.09	u^a_1=0.006
	C.2	60,3		39.7	60.3	ν=1	u^b_1=0.192	u^c_1=0.101
							u^{ab}_{11}=0.108	u^{bc}_{11}=0.09
							u^{ac}_{11}=0.108	
H^9_0	C.1	100	70	80	50	0	u_0=4.073	u^a_1=0.015
	C.2	60	30	40	70	ν=0	u^b_1=0.214	u^c_1=0.120
							u^{ab}_{11}=0.125	u^{bc}_{11}=0.09
							u^{ac}_{11}=0.142	u^{abc}_{111} = = - 0.17

6. Вопросы для повторения

1. По результатам социологического опроса получена следующая таблица:

Пол	Вопрос: "Регулярно ли Вы читаете журнал "Буги-Вуги"	
	Да	Нет
Мужчины	57	223
Женщины	346	78

Вычислите теоретические частоты гипотезы независимости.

2. По данным задачи 1 вычислить значение хи-квадрат.
3. По данным задачи 1 проверить гипотезу о независимости признаков на уровне значимости $\alpha=0,05$.
4. По данным задачи 1 вычислить коэффициент ассоциации.
5. По данным задачи 1 вычислить коэффициент коллигации.
6. По данным задачи 1 вычислить коэффициент контингенции.
7. По данным задачи 1 вычислить коэффициент Чупрова.
8. По данным задачи 1 вычислить коэффициент Пирсона.
9. По данным задачи 1 вычислить τ-коэффициент Гудмена-Краскела.
10. Дайте определение таблицы сопряженности.
11. Дайте определение и приведите формулу расчета статистики хи-квадрат для таблицы r×s.
12. Дайте определение и приведите формулу расчета статистики хи-квадрат информационного для таблицы r×s.
13. По данным маркетингового исследования была получена следующая таблица сопряженности:

Кофе какой марки Вы предпочитаете?	Как Вы оцениваете уровень своего благосостояния?		
	низкий	средний	выше среднего
Кофе "*"	525	89	12
Кофе "**"	47	241	59
Кофе "***"	58	158	138

Вычислить теоретические частоты гипотезы независимости.

14. По данным задачи 13 вычислить значение хи-квадрат.
15. По данным задачи 13 вычислить значение хи-квадрат информационного.
16. По данным задачи 13 проверить гипотезу о независимости признаков.
17. По данным задачи 13 вычислить точечные и интервальные оценки коэффициента Чупрова.
18. По данным задачи 13 вычислить точечные и интервальные оценки коэффициента Чупрова.

19. По данным задачи 13 вычислить точечные и интервальные оценки коэффициента Пирсона.
20. По данным задачи 13 вычислить точечные и интервальные оценки коэффициента Крамера.
21. По данным задачи 13 вычислить точечные оценки коэффициентов τ, τ_a, τ_b.
22. По данным задачи 13 вычислить точечные оценки коэффициентов λ, λ_a, λ_b.
23. Дайте определение таблицы сопряженности трех признаков.

24. Какая логлинейная модель называется насыщенной?
25. Выпишите логлинейную модель, включающую парные взаимодействия AB/BC.
26. Каким образом вычисляются теоретические частоты для модели A/B/C?
27. Выпишите формулу для вычисления теоретических частот для модели AB/BC.
28. Сколько степеней свободы соответствует моделям а) A/BC, б) A/B/C, в) AB/AC для таблицы $2\times2\times2$.
29. Наблюдаемое значение хи-квадрат составило 14,28 для модели A/B/C. Адекватна ли модель на уровне значимости $\alpha=0,05$?
30. Наблюдаемое значение хи-квадрат составило 2,28 для модели AB/C. Адекватна ли модель на уровне значимости $\alpha=0,05$?

Заключение

В учебном пособии рассматриваются основные теоретические вопросы исследования взаимосвязей признаков, замеренных в номинальной шкале. В этом случае основным инструментом анализа являются парные и многомерные таблицы сопряженности.

Значительное внимание уделено измерению связи между парой признаков. Приведены методы расчета наиболее часто используемых коэффициентов.

Далее рассмотрена методика использования логлинейных моделей для анализа связей между несколькими признаками.

В пособии имеются типовые примеры и задачи, взятые из практики анализа данных социологических опросов и решенных с помощью ЭВМ.

Учебное пособие предназначено для студентов, изучающих многомерные статистические методы анализа нечисловой информации, и специалистов, желающих повысить свою квалификацию по современным методам статистики.

Список рекомендуемой литературы

1. Айвазян С.А., Енюков И.С., Мешалкин Л.Д. Прикладная статистика: Исследование зависимостей. –М.: Финансы и статистика, 1985.
2. Аптон Г. Анализ таблиц сопряженности. /Пер. с англ. –М.: Финансы и статистика, 1982.
3. Афифи А., Эйзен С. Статистический анализ. Подход с использованием ЭВМ /Пер. с англ. –М.: Мир, 1982.
4. Кендал М. Дж, Стьюарт А. Статистические выводы и связи. /Пер. с англ. –М.: Наука, 1973.

Таблицы математической статистики

Таблица 1

Нормальный закон распределения

Значения функции $\Phi(t)=P(|T|\le t_{табл.}) = \frac{2}{\sqrt{2\pi}}\int_0^t e^{-\frac{x^2}{2}}dx$

Целые и десятые доли t	Сотые доли t									
	0	**1**	**2**	**3**	**4**	**5**	**6**	**7**	**8**	**9**
0,0	0,0000	0,0080	0,0160	0,0239	0,0319	0,0399	0,0478	0,0558	0,0638	0,0717
0,1	0,0797	0,0876	0,0955	0,1034	0,1113	0,1192	0,1271	0,1350	0,1428	0,1507
0,2	0,1585	0,1663	0,1741	0,1819	0,1897	0,1974	0,2051	0,2128	0,2205	0,2282
0,3	0,2358	0,2434	0,2510	0,2586	0,2661	0,2737	0,2812	0,2886	0,2961	0,3035
0,4	0,3108	0,3182	0,3255	0,3328	0,3401	0,3473	0,3545	0,3616	0,3688	0,3759
0,5	0,3829	0,3899	0,3969	0,4039	0,4108	0,4177	0,4245	0,4313	0,4381	0,4448
0,6	0,4515	0,4581	0,4647	0,4713	0,4778	0,4843	0,4907	0,4971	0,5035	0,5098
0,7	0,5161	0,5223	0,5285	0,5346	0,5407	0,5467	0,5527	0,5587	0,5646	0,5705
0,8	0,5763	0,5821	0,5878	0,5935	0,5991	0,6047	0,6102	0,6157	0,6211	0,6265
0,9	0,6319	0,6372	0,6424	0,6476	0,6528	0,6579	0,6629	0,6680	0,6729	0,6778
1,0	0,6827	0,6875	0,6923	0,6970	0,7017	0,7063	0,7109	0,7154	0,7199	0,7243
1,1	0,7287	0,7330	0,7373	0,7415	0,7457	0,7499	0,7540	0,7580	0,7620	0,7660
1,2	0,7699	0,7737	0,7775	0,7813	0,7850	0,7887	0,7923	0,7959	0,7995	0,8029
1,3	0,8064	0,8098	0,8132	0,8165	0,8198	0,8230	0,8262	0,8293	0,8324	0,8355
1,4	0,8385	0,8415	0,8444	0,8473	0,8501	0,8529	0,8557	0,8584	0,8611	0,8638
1,5	0,8664	0,8690	0,8715	0,8740	0,8764	0,8789	0,8812	0,8836	0,8859	0,8882
1,6	0,8904	0,8926	0,8948	0,8969	0,8990	0,9011	0,9031	0,9051	0,9070	0,9090
1,7	0,9109	0,9127	0,9146	0,9164	0,9181	0,9199	0,9216	0,9233	0,9249	0,9265
1,8	0,9281	0,9297	0,9312	0,9328	0,9342	0,9357	0,9371	0,9385	0,9399	0,9412
1,9	0,9426	0,9439	0,9451	0,9464	0,9476	0,9488	0,9500	0,9512	0,9523	0,9534
2,0	0,9545	0,9556	0,9566	0,9576	0,9586	0,9596	0,9606	0,9615	0,9625	0,9634
2,1	0,9643	0,9651	0,9660	0,9668	0,9676	0,9684	0,9692	0,9700	0,9707	0,9715
2,2	0,9722	0,9729	0,9736	0,9743	0,9749	0,9756	0,9762	0,9768	0,9774	0,9780
2,3	0,9786	0,9791	0,9797	0,9802	0,9807	0,9812	0,9817	0,9822	0,9827	0,9832
2,4	0,9836	0,9840	0,9845	0,9849	0,9853	0,9857	0,9861	0,9865	0,9869	0,9872
2,5	0,9876	0,9879	0,9883	0,9886	0,9889	0,9892	0,9895	0,9898	0,9901	0,9904
2,6	0,9907	0,9909	0,9912	0,9915	0,9917	0,9920	0,9922	0,9924	0,9926	0,9929
2,7	0,9931	0,9933	0,9935	0,9937	0,9939	0,9940	0,9942	0,9944	0,9946	0,9947
2,8	0,9949	0,9950	0,9952	0,9953	0,9955	0,9956	0,9958	0,9959	0,9960	0,9961
2,9	0,9963	0,9964	0,9965	0,9966	0,9967	0,9968	0,9969	0,9970	0,9971	0,9972
3,0	0,9973	0,9974	0,9975	0,9976	0,9976	0,9977	0,9978	0,9979	0,9979	0,9980
3,1	0,9981	0,9981	0,9982	0,9983	0,9983	0,9984	0,9984	0,9985	0,9985	0,9986
3,2	0,9986	0,9987	0,9987	0,9988	0,9988	0,9988	0,9989	0,9989	0,9990	0,9990
3,3	0,9990	0,9991	0,9991	0,9991	0,9992	0,9992	0,9992	0,9992	0,9993	0,9993
3,4	0,9993	0,9994	0,9994	0,9994	0,9994	0,9994	0,9995	0,9995	0,9995	0,9995
3,5	0,9995	0,9996	0,9996	0,9996	0,9996	0,9996	0,9996	0,9996	0,9997	0,9997
3,6	0,9997	0,9997	0,9997	0,9997	0,9997	0,9997	0,9997	0,9998	0,9998	0,9998
3,7	0,9998	0,9998	0,9998	0,9998	0,9998	0,9998	0,9998	0,9998	0,9998	0,9998
3,8	0,9999	0,9999	0,9999	0,9999	0,9999	0,9999	0,9999	0,9999	0,9999	0,9999
3,9	0,9999	0,9999	0,9999	0,9999	0,9999	0,9999	0,9999	0,9999	0,9999	0,9999
4,0	0,9999	0,9999	0,9999	0,9999	0,9999	0,9999	0,9999	0,9999	0,9999	0,9999

Таблица 2

Распределение Пирсона (X^2-распределение)
Значения $X^2_{табл}$ для вероятностей $P(X^2 > X^2_{табл})$

	Вероятность $Pi(X^2,\nu)=\alpha$						
ν	0,1	0,05	0,025	0,02	0,01	0,005	0,001
1	2,706	3,841	5,024	5,412	6,635	7,879	10,827
2	4,605	5,991	7,378	7,824	9,210	10,597	13,815
3	6,251	7,815	9,348	9,837	11,345	12,838	16,266
4	7,779	9,488	11,143	11,668	13,277	14,860	18,466
5	9,236	11,070	12,832	13,388	15,086	16,750	20,515
6	10,645	12,592	14,449	15,033	16,812	18,548	22,457
7	12,017	14,067	16,013	16,622	18,475	20,278	24,321
8	13,362	15,507	17,535	18,168	20,090	21,955	26,124
9	14,684	16,919	19,023	19,679	21,666	23,589	27,877
10	15,987	18,307	20,483	21,161	23,209	25,188	29,588
11	17,275	19,675	21,920	22,618	24,725	26,757	31,264
12	18,549	21,026	23,337	24,054	26,217	28,300	32,909
13	19,812	22,362	24,736	25,471	27,688	29,819	34,527
14	21,064	23,685	26,119	26,873	29,141	31,319	36,124
15	22,307	24,996	27,488	28,259	30,578	32,801	37,698
16	23,542	26,296	28,845	29,633	32,000	34,267	39,252
17	24,769	27,587	30,191	30,995	33,409	35,718	40,791
18	25,989	28,869	31,526	32,346	34,805	37,156	42,312
19	27,204	30,144	32,852	33,687	36,191	38,582	43,819
20	28,412	31,410	34,170	35,020	37,566	39,997	45,314
21	29,615	32,671	35,479	36,343	38,932	41,401	46,796
22	30,813	33,924	36,781	37,659	40,289	42,796	48,268
23	32,007	35,172	38,076	38,968	41,638	44,181	49,728
24	33,196	36,415	39,364	40,270	42,980	45,558	51,179
25	34,382	37,652	40,646	41,566	44,314	46,928	52,619
26	35,563	38,885	41,923	42,856	45,642	48,290	54,051
27	36,741	40,113	43,195	44,140	46,963	49,645	55,475
28	37,916	41,337	44,461	45,419	48,278	50,994	56,892
29	39,087	42,557	45,722	46,693	49,588	52,335	58,301
30	40,256	43,773	46,979	47,962	50,892	53,672	59,702