# Прогнозирование: принципы и практика

Роб Хайндман
Джордж Атанасопулос

ДМК Пресс
издательство

Какими бы ни были обстоятельства или временные горизонты, прогнозирование является важным подспорьем в эффективном планировании. Потребность в прогнозировании возникает во многих ситуациях:

– для принятия решения о строительстве новой электростанции в ближайшие пять лет требуются прогнозы будущего спроса;
– для планирования персонала в колл-центре на следующую неделю требуется прогноз количества звонков;
– для пополнения запасов требуются прогнозы потребностей в запасах;
– для маршрутизации телекоммуникационных соединений требуется прогноз трафика на несколько минут вперед.

Данная книга представляет собой всестороннее введение в методы прогнозирования и содержит достаточно информации о каждом из них, помогая читателям разумно их использовать. Примеры с многочисленными наборами данных авторы заимствовали из собственного опыта консультирования. Материал книги содержит новейшие методы исследования и прогнозирования. В конце глав приводятся упражнения по пройденной теме.

**В числе рассматриваемых тем:**

- базовые шаги в задаче прогнозирования;
- графика временных рядов;
- инструментарий прогнозиста;
- экспоненциальное сглаживание;
- модели ARIMA;
- модели на основе динамической регрессии;
- продвинутые методы прогнозирования.

Издание адресовано специалистам, занимающимся прогнозированием в бизнесе, науке, на производстве, а также может быть полезно студентам и преподавателям.

Все примеры даны на языке R.

ISBN 978-5-93700-151-1

**Интернет-магазин:**
www.dmkpress.com

**Оптовая продажа:**
КТК «Галактика»
books@alians-kniga.ru

ДМК ПРЕСС
ИЗДАТЕЛЬСТВО
www.дмк.рф

Рон Хайндман и Джордж Атанасопулос

# Прогнозирование: принципы и практика

# Forecasting: Principles and Practice

*Rob J Hyndman and George Athanasopoulos*

# Прогнозирование: принципы и практика

*Рон Хайндман и Джордж Атанасопулос*

ДМК Пресс
издательство
Москва, 2023

**УДК 332.14**
**ББК 65.054**
**Х15**

**Рон Хайндман и Джордж Атанасопулос**

**Х15** Прогнозирование: принципы и практика / пер. с англ. А. В. Логунова. – М.: ДМК Пресс, 2023. – 458 с.: ил.

**ISBN 978-5-93700-151-1**

Данная книга представляет собой всестороннее введение в методы прогнозирования и содержит достаточно информации о каждом из них, помогая читателям разумно их использовать. Примеры с многочисленными наборами данных на языке R авторы заимствовали из собственного опыта консультирования. В конце глав приводятся упражнения по пройденной теме.

Издание адресовано специалистам, занимающимся прогнозированием в бизнесе, науке, на производстве, а также может быть полезно студентам и преподавателям.

УДК 332.14
ББК 65.054

Copyright Forecasting: Principles and Practice, ISBN 9780987507136, published by OTexts.

Все права защищены. Любая часть этой книги не может быть воспроизведена в какой бы то ни было форме и какими бы то ни было средствами без письменного разрешения владельцев авторских прав.

ISBN (анг.) 978-0-98750-713-6
ISBN (рус.) 978-5-93700-151-1

Copyright © 2020 by Rob J Hyndman and George Athanasopoulos
© Оформление, издание, перевод, ДМК Пресс, 2023

# Оглавление

Предисловие от издательства ..... 16
Об авторах ..... 17
Предисловие ..... 18

**Глава 1. Приступая к работе ..... 21**

1.1 Что можно прогнозировать? ..... 22
1.2 Прогнозирование, цели и планирование ..... 23
Прогнозирование ..... 24
Цели ..... 24
Планирование ..... 24
Краткосрочные прогнозы ..... 24
Среднесрочные прогнозы ..... 24
Долгосрочные прогнозы ..... 24
1.3 Определение того, что следует прогнозировать ..... 24
1.4 Данные и методы прогнозирования ..... 25
Прогнозирование временных рядов ..... 26
Индикаторные переменные и прогнозирование временных рядов ..... 27
1.5 Несколько тематических исследований ..... 28
Случай 1 ..... 28
Случай 2 ..... 29
Случай 3 ..... 29
Случай 4 ..... 30
1.6 Базовые шаги в задаче прогнозирования ..... 30
Шаг 1: определение задачи ..... 30
Шаг 2: сбор информации ..... 30
Шаг 3: предварительный (разведывательный) анализ ..... 30
Шаг 4: выбор и подгонка моделей ..... 31
Шаг 5: использование и оценивание модели прогнозирования ..... 31
1.7 Перспектива статистического прогнозирования ..... 31
1.8 Упражнения ..... 33
1.9 Дальнейшее чтение ..... 34
Библиография ..... 34

**Глава 2. Графика временных рядов ..... 35**

2.1 Объекты twibble ..... 35
Переменная-индекс ..... 35
Переменные-ключи ..... 37
Работа с объектами twibble ..... 38
Прочитать csv-файл и конвертировать его в twibble ..... 41
Сезонный период ..... 42
2.2 Графики времени ..... 43

2.3 Закономерности временных рядов ..... 45
Тренд ..... 45
Сезонный ..... 45
Циклический ..... 46
2.4 Сезонные графики ..... 47
Несколько сезонных периодов ..... 48
2.5 Графики сезонных подрядов ..... 50
Пример: туристический отдых в Австралии ..... 50
2.6 Диаграммы рассеяния ..... 54
Корреляция ..... 56
Матрицы диаграмм рассеяния ..... 57
Библиография ..... 60
2.7 Графики лагов ..... 60
2.8 Автокорреляция ..... 61
Тренды и сезонность на ACF-графиках ..... 63
2.9 Белый шум ..... 63
2.10 Упражнения ..... 65
2.11 Дальнейшее чтение ..... 67
Библиография ..... 68

**Глава 3. Разложение временных рядов ..... 69**

3.1 Преобразования и корректировки ..... 69
Календарные корректировки ..... 69
Корректировки по численности населения ..... 70
Корректировки на инфляцию ..... 71
Математические преобразования ..... 72
Библиография ..... 74
3.2 Компоненты временных рядов ..... 75
Пример: занятость в секторе розничной торговли США ..... 75
Сезонно скорректированные данные ..... 79
3.3 Скользящие средние ..... 80
Сглаживание скользящей средней ..... 80
Скользящие средние скользящих средних ..... 83
Оценивание тренда-цикла с сезонными данными ..... 85
Пример: занятость в секторе розничной торговли США ..... 85
Взвешенные скользящие средние ..... 86
3.4 Классическое разложение ..... 87
Аддитивное разложение ..... 87
Мультипликативное разложение ..... 88
Комментарии к классическому разложению ..... 89
3.5 Методы, используемые официальными статистическими агентствами ..... 89
Метод X-11 ..... 90
Метод SEATS ..... 93
Библиография ..... 94
3.6 STL-разложение ..... 95
Библиография ..... 97
3.7 Упражнения ..... 97

3.8 Дальнейшее чтение ..... 100
Библиография ..... 100

**Глава 4. Признаки временных рядов ..... 101**

4.1 Несколько простых статистик ..... 101
4.2 Признаки ACF ..... 102
4.3 Признаки STL ..... 104
4.4 Другие признаки ..... 107
4.5 Разведывательный анализ данных о туризме в Австралии ..... 108
Библиография ..... 114
4.6 Упражнения ..... 114
4.7 Дальнейшее чтение ..... 114
Библиография ..... 114

**Глава 5. Инструментарий прогнозиста ..... 115**

5.1 Чистый рабочий поток прогнозирования ..... 115
Подготовка данных (очистка) ..... 115
Построение графика данных (визуализация) ..... 116
Определение модели (формулирование) ..... 116
Тренировка модели (вычисление) ..... 117
Проверка результативности модели (оценивание) ..... 118
Генерирование прогнозов (прогнозирование) ..... 118
5.2 Несколько простых методов прогнозирования ..... 119
Средне-арифметический метод ..... 120
Наивный метод ..... 120
Сезонный наивный метод ..... 121
Дрейфовый метод ..... 122
Пример: ежеквартальное производство пива в Австралии ..... 123
Пример: ежедневная цена акций Google на момент закрытия торгового периода ..... 124
5.3 Подогнанные значения и остатки ..... 125
Подогнанные значения ..... 125
Остатки ..... 126
5.4 Диагностика остатков ..... 127
Пример: прогнозирование цен акций Google на момент закрытия торгового периода ..... 128
Тесты портманто на автокорреляцию ..... 131
5.5 Распределительные прогнозы и предсказательные интервалы ..... 133
Прогнозные распределения ..... 133
Предсказательные интервалы ..... 134
Одношаговые предсказательные интервалы ..... 135
Многошаговые предсказательные интервалы ..... 135
Эталонные методы ..... 135
Предсказательные интервалы из бутстрапированных остатков ..... 137
5.6 Прогнозирование с использованием преобразований ..... 142
Предсказательные интервалы с преобразованиями ..... 142
Поправки на смещение ..... 142

5.7 Прогнозирование с разложением ... 144
Пример: занятость в секторе розничной торговли США ... 145
5.8 Оценивание точности точечного прогноза ... 147
Тренировочный и тестовый наборы ... 147
Функции для взятия подмножеств из временных рядов ... 148
Ошибки прогнозов ... 149
Ошибки, зависимые от шкалы ... 149
Процентные ошибки ... 149
Шкалированные ошибки ... 150
Примеры ... 151
Библиография ... 154
5.9 Оценивание точности распределительного прогноза ... 154
Квантильные баллы ... 154
Балл Винклера ... 155
Непрерывный рангово-вероятностный балл ... 156
Бесшкальные сравнения с использованием баллов навыков ... 157
Библиография ... 158
5.10 Перекрестная валидация временных рядов ... 158
Пример: точность прогнозного горизонта с помощью перекрестной валидации ... 161
5.11 Упражнения ... 162
5.12 Дальнейшее чтение ... 165
Библиография ... 165

**Глава 6. Прогнозы на основе суждений ... 166**

Библиография ... 167
6.1 Остерегайтесь ограничений ... 167
Библиография ... 168
6.2 Ключевые принципы ... 168
Четко и кратко формулировать задачу прогнозирования ... 168
Внедрять систематический подход ... 168
Документировать и обосновывать ... 169
Систематически оценивать прогнозы ... 169
Сегрегировать прогнозистов и пользователей ... 169
Пример: схема фармацевтических льгот (PBS) ... 170
6.3 Дельфийский метод ... 172
Эксперты и анонимность ... 173
Постановка задачи прогнозирования в дельфийском методе ... 173
Обратная связь ... 174
Итерация ... 174
Окончательные прогнозы ... 174
Ограничения и вариации ... 174
Куратор ... 174
Библиография ... 175
6.4 Прогнозирование по аналогии ... 175
Пример: разработка учебной программы средней школы ... 175
Структурированная аналогия ... 176

Библиография ... 176
6.5 Сценарное прогнозирование ... 177
6.6 Прогнозирование новых продуктов ... 177
Композитный прогноз торгового отдела ... 177
Мнение руководства ... 178
Намерения клиентов ... 178
Библиография ... 179
6.7 Сужденческие корректировки ... 179
Использовать корректировки экономно ... 179
Применять структурированный подход ... 180
Пример: комитет по прогнозированию туризма (TFC) ... 180
Библиография ... 181
6.8 Дальнейшее чтение ... 182
Библиография ... 182

**Глава 7. Модели регрессии временных рядов ... 184**

7.1 Линейная модель ... 184
Простая линейная регрессия ... 184
Пример: потребительские расходы в США ... 185
Множественная линейная регрессия ... 188
Пример: потребительские расходы в США ... 188
Допущения ... 190
7.2 Оценивание методом наименьших квадратов ... 191
Пример: потребительские расходы в США ... 191
Подогнанные значения ... 192
Качество подгонки ... 194
Пример: потребительские расходы в США ... 195
Стандартная ошибка регрессии ... 195
7.3 Оценивание регрессионной модели ... 195
График ACF остатков ... 196
Гистограмма остатков ... 196
Графики остатков в сопоставлении с предсказателями ... 197
Графики остатков в сопоставлении с подогнанными значениями ... 198
Выбросы и влиятельные наблюдения ... 199
Мнимая регрессия ... 200
7.4 Несколько полезных предсказателей ... 202
Тренд ... 202
Фиктивные переменные ... 203
Сезонные фиктивные переменные ... 203
Пример: ежеквартальное производство пива в Австралии ... 204
Переменные вмешательства ... 207
Торговые дни ... 207
Распределенные лаги ... 208
Пасха ... 208
Ряд Фурье ... 208
7.5 Отбор предсказателей ... 209
Скорректированный $R^2$ ... 210

Перекрестная валидация ..... 211
Информационный критерий Акаике ..... 211
Исправленный информационный критерий Акаике ..... 212
Байесов информационный критерий Шварца ..... 212
Какую меру мы должны использовать? ..... 212
Пример: потребление в США ..... 213
Регрессия наилучшего подмножества ..... 214
Пошаговая регрессия ..... 214
Остерегайтесь статистического вывода после отбора предсказателей ..... 215
Библиография ..... 215
7.6 Прогнозирование с помощью регрессии ..... 215
Антефактумные прогнозы в сопоставлении с постфактумными прогнозами ..... 215
Пример: ежеквартальное производство пива в Австралии ..... 216
Прогнозирование на основе сценариев ..... 217
Строительство предсказательной регрессионной модели ..... 218
Предсказательные интервалы ..... 219
7.7 Нелинейная регрессия ..... 221
Прогнозирование с нелинейным трендом ..... 222
Пример: времена побед в Бостонском марафоне ..... 222
7.8 Корреляция, каузация и прогнозирование ..... 225
Корреляция – это не каузация ..... 225
Прогнозирование с использованием коррелированных предсказателей ..... 226
Мультиколлинеарность и прогнозирование ..... 226
7.9 Матричная формулировка ..... 227
Оценивание методом наименьших квадратов ..... 228
Подогнанные значения и перекрестная валидация ..... 228
Прогнозы и предсказательные интервалы ..... 229
7.10 Упражнения ..... 229
7.11 Дальнейшее чтение ..... 232
Библиография ..... 233

**Глава 8. Экспоненциальное сглаживание ..... 234**

Библиография ..... 234
8.1 Простое экспоненциальное сглаживание ..... 235
Средневзвешенная форма ..... 237
Компонентная форма ..... 238
Плоские прогнозы ..... 238
Оптимизация ..... 239
Пример: экспорт из Алжира ..... 239
8.2 Методы с трендом ..... 241
Метод линейного тренда Хольта ..... 241
Пример: население Австралии ..... 242
Методы демпфируемого тренда ..... 244
Пример: численность населения Австралии (продолжение) ..... 245

Пример: используемость интернета ... 246
Библиография ... 248
8.3 Методы с сезонностью ... 249
Аддитивный метод Хольта–Винтерса ... 249
Мультипликативный метод Хольта–Винтерса ... 250
Пример: внутренние поездки с ночевкой в Австралии ... 250
Демпфирующий метод Хольта–Винтерса ... 254
Пример: метод Хольта–Винтерса с ежедневными данными ... 255
Библиография ... 255
8.4 Таксономия методов экспоненциального сглаживания ... 256
Библиография ... 257
8.5. Модели пространства состояний инноваций для экспоненциального сглаживания ... 257
ETS(A,N,N): простое экспоненциальное сглаживание с аддитивными ошибками ... 258
ETS(M,N,N): простое экспоненциальное сглаживание с мультипликативными ошибками ... 259
ETS(A,A, N): линейный метод Хольта с аддитивными ошибками ... 260
ETS(M,A, N): линейный метод Хольта с мультипликативными ошибками ... 260
Другие модели ETS ... 261
8.6 Оценивание и отбор модели ... 261
Оценивание моделей ETS ... 261
Отбор модели ... 262
Пример: гостевые ночи праздничных туристов в Австралии ... 263
Библиография ... 265
8.7 Прогнозирование с использованием моделей ETS ... 265
Предсказательные интервалы ... 266
Библиография ... 267
8.8 Упражнения ... 268
8.9 Дальнейшее чтение ... 271
Библиография ... 271

**Глава 9. Модели ARIMA ... 272**

9.1 Стационарность и дифференцирование ... 272
Дифференцирование ... 274
Модель случайного блуждания ... 275
Дифференцирование второго порядка ... 276
Сезонное дифференцирование ... 276
Тесты на единичные корни ... 279
Библиография ... 281
9.2 Нотация обратного сдвига ... 281
9.3 Авторегрессионные модели ... 282
9.4 Модели скользящих средних ... 283
9.5 Несезонные модели ARIMA ... 285
Пример: экспорт из Египта ... 286

Понимание моделей ARIMA ..... 288
Графики ACF и PACF ..... 288
9.6 Оценивание и выбор порядка ..... 291
Оценивание максимального правдоподобия ..... 291
Информационные критерии ..... 291
9.7 Моделирование ARIMA в fable ..... 292
Как работает функция ARIMA()? ..... 292
Процедура моделирования ..... 294
Пример: экспорт из Центральноафриканской Республики ..... 296
Понимание констант в R ..... 300
Построение графика характеристических корней ..... 300
Библиография ..... 301
9.8 Прогнозирование ..... 301
Точечные прогнозы ..... 301
Предсказательные интервалы ..... 303
Библиография ..... 304
9.9 Сезонные модели ARIMA ..... 304
ACF/PACF ..... 304
Пример: ежемесячная занятость в сфере досуга и гостиничного бизнеса в США ..... 305
Пример: продажа кортикостероидных препаратов в Австралии ..... 309
Оценивание на тестовом наборе ..... 313
9.10 ARIMA в сопоставлении с ETS ..... 314
Сравнение ARIMA() и ETS() на несезонных данных ..... 316
Сравнение ARIMA() и ETS() на сезонных данных ..... 317
9.11 Упражнения ..... 321
9.12 Дальнейшее чтение ..... 325
Библиография ..... 326

**Глава 10. Модели на основе динамической регрессии ..... 327**

10.1 Оценивание ..... 328
Библиография ..... 329
10.2 Регрессия с ошибками ARIMA с использованием fable ..... 329
Пример: личное потребление и доход в США ..... 330
10.3 Прогнозирование ..... 333
Пример: личное потребление и доход в США ..... 333
Пример: прогнозирование спроса на электроэнергию ..... 334
10.4 Стохастические и детерминированные тренды ..... 339
Пример: пассажиры воздушного транспорта Австралии ..... 339
10.5 Динамическая гармоническая регрессия ..... 342
Пример: расходы австралийцев на питание вне дома ..... 343
Библиография ..... 344
10.6 Лагированные предсказатели ..... 344
Пример: телевизионная реклама и страховые котировки ..... 345
10.7 Упражнения ..... 348
10.8 Дальнейшее чтение ..... 351
Библиография ..... 351

**Глава 11. Прогнозирование иерархических и сгруппированных временных рядов ..... 352**

11.1 Иерархические и сгруппированные временные ряды ..... 353
Иерархические временные ряды ..... 353
Пример: иерархия туризма в Австралии ..... 354
Сгруппированные временные ряды ..... 358
Пример: тюремное население Австралии ..... 359
Смешанная иерархическая и групповая структура ..... 362
11.2 Одноуровневые подходы ..... 364
Подход «снизу вверх» ..... 364
Пример: генерирование восходящих прогнозов ..... 364
Рабочий поток прогнозирования агрегационных структур ..... 366
Подходы «сверху вниз» ..... 366
Средние исторические пропорции ..... 366
Пропорции исторических средних ..... 367
Прогнозные пропорции ..... 367
Подход «от середины наружу» ..... 369
Библиография ..... 369
11.3 Увязывание прогнозов ..... 369
Матричная нотация ..... 369
Отображающие матрицы ..... 370
Увязывание ..... 371
Метод оптимальной увязки MinT ..... 372
Библиография ..... 374
11.4 Прогнозирование внутреннего туризма в Австралии ..... 374
11.5 Увязанные распределительные прогнозы ..... 377
Библиография ..... 378
11.6 Прогнозирование тюремного населения Австралии ..... 378
Библиография ..... 383
11.7 Упражнения ..... 383
11.8 Дальнейшее чтение ..... 384
Библиография ..... 384

**Глава 12. Продвинутые методы прогнозирования ..... 386**

12.1 Сложная сезонность ..... 386
STL с несколькими сезонными периодами ..... 387
Динамическая гармоническая регрессия с несколькими сезонными периодами ..... 390
Пример: спрос на электроэнергию ..... 392
Библиография ..... 395
12.2 Модель Prophet ..... 396
Пример: ежеквартальное производство цемента ..... 396
Пример: получасовой спрос на электроэнергию ..... 398
Библиография ..... 400
12.3 Векторные авторегрессии ..... 400
Пример: модель VAR для прогнозирования потребления в США ..... 403
Библиография ..... 405

12.4 Нейросетевые модели ..... 405
Архитектура нейронной сети ..... 405
Нейросетевая авторегрессия ..... 407
Пример: пятна на Солнце ..... 407
Предсказательные интервалы ..... 408
12.5 Бутстрапирование и бутстрап-агрегирование ..... 410
Бутстрапирование временного ряда ..... 410
Бутстрап-агрегированные прогнозы ..... 412
Библиография ..... 414
12.6 Упражнения ..... 415
12.7 Дальнейшее чтение ..... 415
Библиография ..... 415

**Глава 13. Некоторые практические вопросы прогнозирования ..... 417**

13.1 Еженедельные, ежедневные и субдневные данные ..... 417
Еженедельные данные ..... 417
Ежедневные и субдневные данные ..... 419
13.2 Временные ряды счетных данных ..... 420
Пример: продажа фармацевтических препаратов ..... 421
Библиография ..... 423
13.3 Обеспечение того, чтобы прогнозы оставались в пределах допустимых значений ..... 424
Положительные прогнозы ..... 424
Прогнозы, ограниченные интервалом ..... 425
13.4 Комбинации прогнозов ..... 427
Прогнозные распределения комбинаций ..... 429
Библиография ..... 431
13.5 Предсказательные интервалы для агрегатов ..... 431
13.6 Ретрополяция ..... 432
13.7 Очень длинные и очень короткие временные ряды ..... 433
Прогнозирование очень коротких временных рядов ..... 433
Прогнозирование очень длинных временных рядов ..... 435
13.8 Прогнозирование на тренировочном и тестовом наборах ..... 435
Многошаговые прогнозы на тренировочных данных ..... 436
Одношаговые прогнозы на тестовых данных ..... 437
13.9 Работа с выбросами и пропущенными значениями ..... 438
Выбросы ..... 438
Пропущенные значения ..... 441
13.10 Дальнейшее чтение ..... 443
Библиография ..... 443

**Приложение А. Использование языка R ..... 444**

Инсталлирование R и RStudio ..... 444
Примеры на R в этой книге ..... 444
Начало работы с R ..... 445

**Приложение B. Для преподавателей.....446**
Решения упражнений.....446
Слайды.....446

**Приложение C. Рецензии и отзывы .....447**
Отзывы коллег-преподавателей.....447
Отзывы практикующих специалистов и студентов.....448
Библиография.....450

# Предисловие от издательства

## Отзывы и пожелания

Мы всегда рады отзывам наших читателей. Расскажите нам, что вы думаете об этой книге – что понравилось или, может быть, не понравилось. Отзывы важны для нас, чтобы выпускать книги, которые будут для вас максимально полезны.

Вы можете написать отзыв на нашем сайте *www.dmkpress.com*, зайдя на страницу книги и оставив комментарий в разделе «Отзывы и рецензии». Также можно послать письмо главному редактору по адресу *dmkpress@gmail.com*; при этом укажите название книги в теме письма.

Если вы являетесь экспертом в какой-либо области и заинтересованы в написании новой книги, заполните форму на нашем сайте по адресу *http://dmkpress.com/authors/publish_book/* или напишите в издательство по адресу *dmkpress@gmail.com*.

## Список опечаток

Хотя мы приняли все возможные меры для того, чтобы обеспечить высокое качество наших текстов, ошибки все равно случаются. Если вы найдете ошибку в одной из наших книг – возможно, ошибку в основном тексте или программном коде, – мы будем очень благодарны, если вы сообщите нам о ней. Сделав это, вы избавите других читателей от недопонимания и поможете нам улучшить последующие издания этой книги.

Если вы найдете какие-либо ошибки в коде, пожалуйста, сообщите о них главному редактору по адресу *dmkpress@gmail.com*, и мы исправим это в следующих тиражах.

## Нарушение авторских прав

Пиратство в интернете по-прежнему остается насущной проблемой. Издательство «ДМК Пресс» очень серьезно относится к вопросам защиты авторских прав и лицензирования. Если вы столкнетесь в интернете с незаконной публикацией какой-либо из наших книг, пожалуйста, пришлите нам ссылку на интернет-ресурс, чтобы мы могли применить санкции.

Ссылку на подозрительные материалы можно прислать по адресу *dmkpress@gmail.com*.

Мы высоко ценим любую помощь по защите наших авторов, благодаря которой мы можем предоставлять вам качественные материалы.

# Об авторах

Роб Джей Хайндман (*https://robjhyndman.com/*) – профессор статистики и заведующий кафедрой эконометрики и бизнес-статистики Университета Монаш, Австралия. В 2005–2018 годах был главным редактором журнала International Journal of Forecasting (Международного журнала прогнозирования). Он является автором 6 книг и более 200 научных работ, а также избранным членом Австралийской академии наук, Академии социальных наук Австралии и Международного института прогнозистов. На протяжении более 35 лет Роб ведет активную консалтинговую практику, помогая сотням компаний и организаций в решении задач прогнозирования. За свои исследования, преподавание, консультирование и руководство выпускниками он по достоинству оценен наградами.

Джордж Атанасопулос (*https://research.monash.edu/en/persons/george-athanasopoulos*) – профессор, директор по образованию и заместитель заведующего кафедрой эконометрии и бизнес-статистики Университета Монаш, Австралия. Он также является президентом Международного института прогнозистов. За свои исследования и преподавание Джордж имеет множество наград и отличий. Он входит в состав редакционных советов Journal of Travel Research и International Journal of Forecasting.

# Предисловие

Добро пожаловать в наш онлайновый учебник по прогнозированию.

Цель этого учебника – дать всестороннее введение в методы прогнозирования и представить достаточно информации о каждом методе, чтобы читатели имели возможность разумно их использовать. Мы не пытаемся подробно обсуждать теоретические детали, лежащие в основе каждого метода, хотя ссылки в конце каждой главы будут содержать многие из этих деталей.

Книга написана для трех аудиторий: (1) людей, которые занимаются прогнозированием в бизнесе, хотя у них, возможно, не было никакого формального обучения в этой области; (2) студентов бакалавриата, изучающих бизнес; (3) студентов по программе MBA, изучающих факультатив по прогнозированию. Мы сами используем этот учебник для студентов магистратуры и студентов третьего курса бакалавриата в Университете Монаш, Австралия.

В большинстве разделов мы предполагаем, что читатели лишь слегка знакомы с вводной статистикой и с алгеброй средней школы. Есть пара разделов, которые также требуют знания матриц, но они помечены.

В конце каждой главы мы приводим список «дальнейшего чтения». В целом эти списки включают предлагаемые учебники, которые обеспечивают более углубленное или подробное рассмотрение предмета. Там, где нет подходящего учебника, мы предлагаем журнальные статьи, содержащие больше информации.

На протяжении всей книги мы используем язык программирования R и хотим, чтобы студенты научились делать прогнозы с помощью R. Язык R бесплатен и доступен практически в любой операционной системе. Это прекрасный инструмент для любого статистического анализа, а не только для прогнозирования. Инструкции по инсталлированию и использованию R см. в приложении A «Использование языка R».

Все примеры на R в книге основаны на допущении, что вы сначала скачали пакет `fpp3`:

```
library(fpp3)
#> ── Attaching packages ─────────────────────────────────── fpp3 0.4.0 ──
#> ✓ tibble      3.1.6     ✓ tsibble     1.1.1
#> ✓ dplyr       1.0.8     ✓ tsibbledata 0.4.0
#> ✓ tidyr       1.2.0     ✓ feasts      0.2.2
#> ✓ lubridate   1.8.0     ✓ fable       0.3.1
#> ✓ ggplot2     3.3.5
#> ── Conflicts ────────────────────────────────────── fpp3_conflicts ──
#> ✖ lubridate::date()    masks base::date()
#> ✖ dplyr::filter()      masks stats::filter()
#> ✖ tsibble::intersect() masks base::intersect()
```

```
#> ✖ tsibble::interval()  masks lubridate::interval()
#> ✖ dplyr::lag()         masks stats::lag()
#> ✖ tsibble::setdiff()   masks base::setdiff()
#> ✖ tsibble::union()     masks base::union()
```

Это позволит загружать соответствующие наборы данных и прикреплять несколько пакетов, как указано выше. К ним относятся несколько пакетов `tidyverse` и пакеты для обработки временных рядов и прогнозирования в рамках «чистой» (tidy) структуры.

В приведенной выше распечатке также показаны версии пакетов, которые мы использовали при составлении этого издания книги. Некоторые примеры в книге не будут работать с более ранними версиями пакетов.

Наконец, в распечатке перечислены некоторые конфликты, показывающие, какая функция будет предпочтительнее, когда функция с тем же именем находится в нескольких пакетах.

Эта книга несколько отличается от других учебников по прогнозированию:

- она бесплатна и доступна онлайн, что делает ее доступной для широкой аудитории;
- в ней используется язык R, являющийся бесплатным, имеющим открытый исходный код и представляющий чрезвычайно мощное программное обеспечение;
- онлайновая версия постоянно обновляется. Вам не нужно ждать следующего выпуска, чтобы устранить ошибки или обсудить новые методы. Мы будем обновлять книгу часто;
- есть десятки примеров реальных данных, взятых из нашей собственной консалтинговой практики. Мы работали с сотнями предприятий и организаций, помогая им в вопросах прогнозирования, и этот опыт внес непосредственный вклад во многие приведенные здесь примеры, а также определил нашу общую философию прогнозирования;
- мы уделяем графическим методам больше внимания, чем большинство прогнозистов. Мы используем графики для проведения разведывательного анализа данных, анализа валидности подогнанных моделей и представления результатов прогнозирования.

## Изменения в третьем издании

Наиболее важным изменением в 3-м издании книги является то, что мы используем пакеты `tsibble` и `fable` вместо пакета `forecast`. Это позволяет нам тесно интегрироваться с коллекцией пакетов `tidyverse`. Как следствие мы заменили многие образцы, чтобы воспользоваться преимуществами новых возможностей.

Мы также добавили некоторые новые материалы по признакам временных рядов и реорганизовали содержание таким образом, чтобы в главах 2–4 обсуждался разведывательный анализ временных рядов, перед тем как представлять какие-либо методы прогнозирования. Это связано с тем, что сначала мы должны хорошо понимать наши временные ряды, их закономерности и признаки, прежде чем пытаться строить какие-либо модели и делать какие-либо прогнозы.

Внимательные читатели предыдущих версий книги сообщали нам о любых обнаруженных ими опечатках или ошибках. Они немедленно обновлялись в онлайновом режиме. Без сомнения, мы допустили несколько новых ошибок, и мы исправим их онлайн, как только они будут обнаружены. Пожалуйста, продолжайте сообщать нам о таких вещах (*https://bit.ly/fpptypo*).

Если у вас есть вопросы об использовании пакетов R, обсуждаемых в этой книге, или о прогнозировании в целом, то, пожалуйста, задайте их на вебсайте сообщества RStudio (*https://bit.ly/fpp3help*).

Счастливого прогнозирования!

Роб Джей Хайндман и Джордж Атанасопулос

Май 2021 года

Для цитирования онлайновой версии этой книги, пожалуйста, используйте следующее:

*Хайндман Р. Дж. и Атанасопулос Дж.* (2021) Прогнозирование: принципы и практика. 3-е изд. OTexts: Мельбурн, Австралия. OTexts.com/fpp3.

Эта онлайновая версия книги в последний раз обновлялась 15 июня 2022 года.

Печатная версия книги (доступна на Amazon, *https://otexts.com/fpp3/buy-a-print-version.html*) в последний раз обновлялась 31 мая 2021 года.

# Глава 1

# Приступая к работе

Предсказание очаровывало людей на протяжении тысячелетий, иногда считаясь признаком божественного вдохновения, а иногда рассматриваясь как преступная деятельность. Еврейский пророк Исайя написал примерно в 700 году до нашей эры:

*Скажите, что произойдёт в будущем, и мы будем знать, что вы боги.*
(Исаия 41:23)

Сто лет спустя, в древнем Вавилоне, предсказатели предвещали будущее, основываясь на распределении личинок по гнилой овечьей печени. Примерно в то же время люди, желающие получить прогнозы, отправлялись в Дельфы в Греции, чтобы посоветоваться с Оракулом, который давал свои предсказания, находясь в состоянии алкогольного опьянения парами этилена. Предсказателям пришлось труднее при императоре Константине, который в 357 году нашей эры издал указ, запрещающий кому бы то ни было «справляться у провидца, математика или предсказателя… Пусть любопытство к предсказанию будущего умолкнет навсегда». Аналогичный запрет на предсказания был введен в Англии в 1736 году, когда мошенничество путем взимания денег за предсказания стало преступлением. Наказанием было трехмесячное тюремное заключение с каторжными работами!

Переменчивая судьба прогнозистов возникает из-за того, что хорошие прогнозы могут казаться почти волшебными, в то время как плохие прогнозы могут быть опасными. Рассмотрим следующие известные предсказания о вычислительной технике.

- Я думаю, что на мировом рынке существует, может быть, пять компьютеров. (Председатель правления IBM, 1943)
- Компьютеры в будущем могут весить не более 1.5 т. (Популярная механика, 1949)
- Нет никаких причин, по которым кто-то хотел бы иметь компьютер в своем доме. (Президент компании DEC, 1977 года)

Последний из них был сделан всего за три года до того, как IBM выпустила первый персональный компьютер. Неудивительно, что вы больше не можете купить компьютер DEC. Очевидно, что прогнозирование – это сложная деятельность, и компании, которые делают это хорошо, имеют большое преимущество перед теми, чьи прогнозы терпят неудачу.

В этой книге мы разведаем наиболее надежные методы генерирования прогнозов. Акцент будет сделан на методах, которые можно воспроизводить и тестировать и которые, как было доказано, работают на практике.

## 1.1 Что можно прогнозировать?

Прогнозирование требуется во многих ситуациях: для принятия решения о строительстве еще одной электростанции в ближайшие пять лет требуются прогнозы будущего спроса; для составления расписания персонала в центре обработки звонков на следующей неделе требуются прогнозы объемов звонков; для пополнения запасов требуются прогнозы потребностей в запасах. Прогнозы могут требоваться на несколько лет вперед (в случае капитальных вложений) или всего на несколько минут (для маршрутизирования телекоммуникаций). Какими бы ни были обстоятельства или временные горизонты, прогнозирование является важным подспорьем для эффективного и результативного планирования.

Некоторые вещи легче предсказывать, чем другие. Время восхода солнца завтра утром можно точно предсказать. С другой стороны, завтрашние лотерейные номера невозможно предсказать с какой-либо точностью. Предсказуемость события или количества зависит от нескольких факторов, включая:

1) насколько хорошо мы понимаем способствующие этому факторы;
2) каков объем доступных данных;
3) как будущее похоже на прошлое;
4) могут ли прогнозы повлиять на то, что мы пытаемся спрогнозировать.

Например, краткосрочные прогнозы спроса на электроэнергию в жилых домах могут быть очень точными, поскольку обычно удовлетворяются все четыре условия.

1. У нас есть хорошее представление о способствующих факторах: спрос на электроэнергию в основном зависит от температуры, с меньшим влиянием календарных изменений, таких как праздники, и экономических условий.
2. Обычно есть данные о спросе на электроэнергию за несколько лет и данные о погодных условиях за многие десятилетия.
3. В случае краткосрочного прогнозирования (до нескольких недель) можно с уверенностью предположить, что поведение спроса будет аналогичным тому, что наблюдалось в прошлом.
4. Для большинства бытовых потребителей цена на электроэнергию не зависит от спроса, и поэтому прогнозы спроса практически не влияют на поведение потребителей.

При условии что у нас есть навыки разработки хорошей модели, связывающей спрос на электроэнергию с ключевыми факторами, прогнозы могут быть удивительно точными.

С другой стороны, при прогнозировании курсов обмена валют удовлетворяется только одно из условий: есть достаточно данных. Однако у нас ограниченное понимание факторов, влияющих на обменные курсы, будущее вполне может отличаться от прошлого, если в одной из стран произойдет финансовый или политический кризис, а прогнозы обменного курса оказывают прямое влияние на сами курсы. Если есть широко разрекламированные прогнозы о том, что обменный курс будет расти, то люди немедленно скорректируют цену, которую они готовы заплатить, и поэтому прогнозы самореализуются.

В некотором смысле обменные курсы становятся их собственными прогнозами. Это пример «гипотезы эффективного рынка». Следовательно, прогнозирование повышения или падения завтрашнего обменного курса примерно так же предсказуемо, как прогнозирование выпадения подброшенной монеты орлом или решкой. В обеих ситуациях вы будете правы примерно в 50 % случаев, что бы вы ни прогнозировали. В подобных ситуациях прогнозисты должны осознавать свои собственные ограничения и не требовать больше, чем возможно.

Часто при прогнозировании ключевым шагом является знание того, когда что-то можно точно спрогнозировать, а когда прогнозы будут не лучше подбрасывания монетки. Хорошие прогнозы отражают подлинные закономерности и взаимосвязи, существующие в исторических данных, но не повторяют прошлые события, которые больше не повторятся. В этой книге мы узнаем, как отличать случайную флуктуацию в прошлых данных, которую следует игнорировать, от подлинной закономерности, которую следует смоделировать и экстраполировать.

Многие люди ошибочно полагают, что в меняющихся условиях прогнозы невозможны. Любая среда меняется, и хорошая модель прогнозирования улавливает то, как все меняется. Прогнозы редко строят на том, что окружающая среда остается неизменной. Обычно исходят из того, что характер изменения окружающей среды будет продолжаться и в будущем. То есть сильно изменчивая среда будет оставаться очень изменчивой; бизнес с колеблющимися объемами продаж будет продолжать иметь колеблющиеся объемы продаж, а экономика, которая пережила подъемы и спады, будет продолжать переживать подъемы и спады. Модель прогнозирования предназначена для того, чтобы улавливать то, как движутся события, а не только то, где они находятся. Как сказал Авраам Линкольн: «Если бы мы могли прежде узнать, где мы находимся и куда мы движемся, то мы могли бы лучше судить, что делать и как это делать».

Ситуации прогнозирования сильно различаются по своим временным горизонтам, факторам, определяющим фактические результаты, типам моделей данных и многим другим аспектам. Методы прогнозирования бывают простыми, такими как использование самого последнего наблюдения в качестве прогноза (который называется наивным методом), или очень сложными, такими как нейронные сети и эконометрические системы одновременных уравнений. Иногда данные вообще будут отсутствовать. Например, у нас может возникнуть потребность спрогнозировать продажи нового продукта в первый год его выпуска, но очевидно, что данных для работы нет. В подобных ситуациях мы используем сужденческое (или рассудочное) прогнозирование, рассмотренное в главе 6. Выбор метода зависит от имеющихся данных и предсказуемости прогнозируемой величины.

## 1.2 Прогнозирование, цели и планирование

Прогнозирование – это обычная статистическая задача в бизнесе, где оно помогает принимать обоснованные решения о планировании производства, транспортировки и персонала, а также служит руководством для долгосрочного стратегического планирования. Однако бизнес-прогнозирование часто выполняется слабо, и его нередко путают с планированием и целями. Это три разные вещи.

### Прогнозирование

заключается в максимально точном предсказании будущего с учетом всей доступной информации, включая исторические данные и знания о любых будущих событиях, которые могут повлиять на прогнозы.

### Цели

– это то, что вы хотели бы, чтобы произошло. Цели должны быть увязаны с прогнозами и планами, но это происходит не всегда. Слишком часто цели ставятся без какого-либо плана их достижения и без каких-либо прогнозов относительно того, насколько они реалистичны.

### Планирование

– это реакция на прогнозы и цели. Планирование включает в себя определение надлежащих действий, необходимых для того, чтобы ваши прогнозы соответствовали вашим целям.

Прогнозирование должно быть неотъемлемой частью деятельности руководства по принятию решений, поскольку оно может играть важную роль во многих областях деятельности компании. Современным организациям требуются краткосрочные, среднесрочные и долгосрочные прогнозы, в зависимости от конкретного применения.

### Краткосрочные прогнозы

необходимы для планирования персонала, производства и транспортировки. В рамках процесса планирования часто также требуются прогнозы спроса.

### Среднесрочные прогнозы

необходимы для определения будущих потребностей в ресурсах, для закупки сырья, найма персонала или покупки машин и оборудования.

### Долгосрочные прогнозы

используются в стратегическом планировании. Такие решения должны принимать во внимание рыночные возможности, факторы окружающей среды и внутренние ресурсы.

От организации требуется разработка системы прогнозирования, которая включает в себя несколько подходов к прогнозированию неопределенных событий. Такие системы прогнозирования требуют развития экспертных знаний в области выявления задач прогнозирования, применения ряда методов прогнозирования, выбора подходящих методов для каждой задачи, а также оценивания и совершенствования методов прогнозирования с течением времени. Также важно иметь сильную организационную поддержку по использованию формальных методов прогнозирования, если мы хотим, чтобы они применялись успешно.

## 1.3 Определение того, что следует прогнозировать

На ранних стадиях проекта прогнозирования необходимо принять решения о том, что следует прогнозировать. Например, если прогнозы требуются для

изделий в производственной среде, то необходимо спросить, нужны ли прогнозы:

1) для каждой продуктовой линейки или для групп продуктов?
2) для каждой торговой точки, или для торговых точек, сгруппированных по регионам, или только для суммарного объема продаж?
3) еженедельные данные, ежемесячные данные или годовые данные?

Также необходимо учитывать прогнозный горизонт. Потребуются ли прогнозы на один месяц вперед, на шесть месяцев или на десять лет? Потребуются различные типы моделей, в зависимости от того, какой прогнозный горизонт является наиболее важным.

Как часто требуются прогнозы? Прогнозы, которые необходимо производить часто, лучше делать с помощью автоматизированной системы, чем с помощью методов, требующих тщательной ручной работы.

Стоит потратить время на разговоры с людьми, которые будут использовать прогнозы, дабы убедиться, что вы понимаете их потребности и то, как следует использовать прогнозы, прежде чем приступать к обширной работе по генерированию прогнозов.

После того как было определено, какие прогнозы требуются, необходимо найти или собрать данные, на которых прогнозы будут основываться. Необходимые для прогнозирования данные, возможно, уже существуют. В наши дни регистрируется много данных, и задача прогнозиста нередко состоит в том, чтобы определить, где и как хранятся необходимые данные. Данные могут включать данные о продажах компании, исторический спрос на продукт или уровень безработицы в географическом регионе. Значительная часть времени прогнозиста может быть потрачена на поиск и сопоставление имеющихся данных до разработки подходящих методов прогнозирования.

## 1.4 Данные и методы прогнозирования

Подходящие методы прогнозирования во многом зависят от имеющихся данных.

Если данных нет или если располагаемые данные не имеют отношения к прогнозам, то необходимо использовать методы **качественного прогнозирования**. Эти методы не являются чисто догадками – существуют хорошо разработанные структурированные подходы к получению хороших прогнозов без использования исторических данных. Эти методы обсуждаются в главе 6.

**Количественное прогнозирование** может применяться при соблюдении двух условий:

1) доступна числовая информация о прошлом;
2) разумно допустить, что некоторые аспекты прошлых закономерностей продолжатся и в будущем.

Существует широкий спектр методов количественного прогнозирования, часто разработанных в рамках конкретных дисциплин для конкретных целей. Каждый метод имеет свои собственные свойства, точность и затраты, которые необходимо учитывать при выборе конкретного метода.

В большинстве задач количественного прогнозирования используются либо данные временных рядов (собираемые через регулярные промежутки време-

ни), либо данные поперечного сечения (собранные в один момент времени). В этой книге мы занимаемся прогнозированием будущих данных и концентрируемся на области временных рядов.

## Прогнозирование временных рядов

Примеры данных временных рядов таковы:

- годовая прибыль Google;
- квартальные результаты продаж Amazon;
- месячное количество осадков;
- еженедельные розничные продажи;
- ежедневные цены на акции IBM;
- почасовая потребность в электроэнергии;
- объемы 5-минутного дорожного движения на автостраде;
- данные с метками времени о биржевых транзакциях.

Все, что наблюдается последовательно с течением времени, является временным рядом. В этой книге мы будем рассматривать только те временные ряды, которые наблюдаются через регулярные промежутки времени (например, ежечасно, ежедневно, еженедельно, ежемесячно, ежеквартально, ежегодно). Временные ряды с неравномерным интервалом также могут встречаться, но они выходят за рамки этой книги.

При прогнозировании данных временных рядов цель состоит в том, чтобы оценить, как последовательность наблюдений будет продолжаться в будущем. На рис. 1.1 показано ежеквартальное производство пива в Австралии с 2000-го по второй квартал 2010 года.

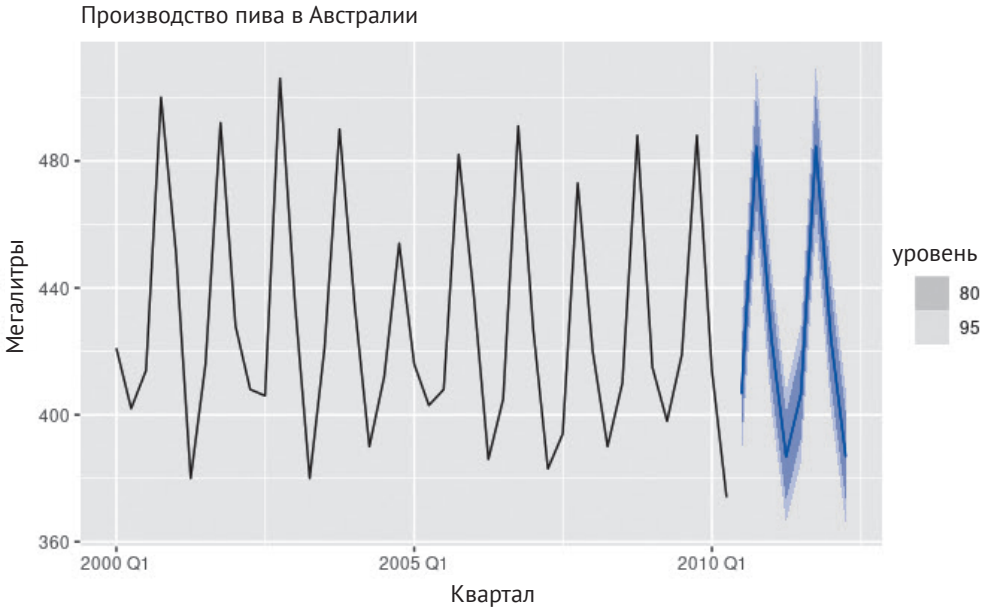


**Рисунок 1.1:** Квартальное производство пива в Австралии: 2000Q1–2010Q2, с прогнозами на два года

Синие линии показывают прогнозы на ближайшие два года. Обратите внимание, как прогнозы отражают сезонную закономерность, наблюдаемую в исторических данных, и воспроизводят ее в течение следующих двух лет. Темная заштрихованная область показывает 80%-ные предсказательные интервалы. То есть ожидается, что каждое будущее значение будет находиться в темном заштрихованном участке с вероятностью 80 %. Участок со светлым оттенком показывает 95%-ные предсказательные интервалы. Эти предсказательные интервалы являются полезным способом изображения неопределенности в прогнозах. В данном случае ожидается, что прогнозы будут точными, и, следовательно, предсказательные интервалы довольно узки.

В простейших методах прогнозирования временных рядов используется информация только о переменной, подлежащей прогнозированию, не пытаясь обнаруживать факторы, влияющие на ее поведение. Поэтому они будут экстраполировать трендовые и сезонные закономерности, но игнорировать всю остальную информацию, такую как маркетинговые инициативы, активность конкурентов, изменения экономических условий и т. д.

Методы разложения полезны для изучения трендовых и сезонных закономерностей во временных рядах; они обсуждаются в главе 3. Используемые для прогнозирования популярные модели временных рядов включают модели экспоненциального сглаживания и модели ARIMA, обсуждаемые соответственно в главах 8 и 9.

## Индикаторные переменные и прогнозирование временных рядов

При прогнозировании временных рядов широко используются предсказательные переменные. Например, предположим, что мы хотим спрогнозировать почасовую потребность в электроэнергии (ED) в жарком регионе в летний период. Модель с предсказательными переменными может иметь следующую форму:

$$\text{ED} = f(\text{текущая температура, прочность экономики, население, время дня, день недели, ошибка}).$$

Взаимосвязь не является точной – в спросе на электроэнергию всегда будут изменения, учесть которые предсказательные переменные не смогут. Член «ошибка» справа учитывает случайную вариацию и влияние релевантных переменных, которые не включены в модель. Мы называем эту модель **объяснительной моделью**, потому что она помогает объяснять факторы, которые вызывают изменение спроса на электроэнергию.

Поскольку данные спроса на электроэнергию формируют временные ряды, мы также могли бы использовать модель временных рядов для прогнозирования. В этом случае подходящее уравнение прогнозирования временных рядов имеет форму

$$\text{ED}_{t+1} = f(\text{ED}_t, \text{ED}_{t-1}, \text{ED}_{t-2}, \text{ED}_{t-3}, \ldots, \text{ошибка}),$$

где $t$ – это текущий, $t + 1$ – следующий час, $t - 1$ – предыдущий час, $t - 1$ – два часа назад и т. д. Здесь прогнозирование будущего основано на прошлых значениях переменной, но не на внешних переменных, которые могут влиять

на систему. Опять же, член «ошибка» справа допускает случайную вариацию и влияние релевантных переменных, которые не включены в модель.

Кроме того, существует и третий тип моделей, который сочетает в себе особенности двух вышеупомянутых моделей. Например, ее можно задать следующей ниже формулой:

$$ED_{t+1} = f(ED_t, \text{текущая температура, время дня, день недели, ошибка}).$$

Указанные выше типы «смешанных моделей» в разных дисциплинах получили различные названия. Они называются моделями динамической регрессии, моделями панельных данных, продольными моделями, моделями передаточных функций и моделями линейных систем (при условии что *f* является линейной). Указанные модели обсуждаются в главе 10.

Объяснительная модель полезна тем, что она включает информацию о других переменных, а не только исторические значения переменной, подлежащей прогнозированию. Однако существует несколько причин, по которым прогнозист выберет именно модель временных рядов, а не объяснительную или смешанную модель. Во-первых, система может быть непонятна, и даже если бы она была понятной, бывает чрезвычайно трудно измерить взаимосвязи, которые, как предполагается, управляют ее поведением. Во-вторых, для того чтобы иметь возможность прогнозировать интересующую переменную, необходимо знать или прогнозировать будущие значения различных предсказателей, а это бывает слишком сложно делать. В-третьих, главная озабоченность может быть сконцентрирована только на том, чтобы предсказывать, что произойдет, а не на том, чтобы узнавать, почему это происходит. Наконец, модель временных рядов может давать более точные прогнозы, чем объяснительная или смешанная модель.

Модель, которая будет использоваться при прогнозировании, зависит от имеющихся ресурсов и данных, точности конкурирующих моделей и способа использования модели прогнозирования.

## 1.5 Несколько тематических исследований

Следующие четыре примера взяты из нашей консалтинговой практики и демонстрируют различные типы ситуаций прогнозирования и связанные с ними проблемы, которые нередко возникают.

### Случай 1

Клиентом была крупная компания, производящая одноразовую посуду, такую как салфетки и бумажные тарелки. Им нужны были прогнозы по каждому из сотен пунктов каждый месяц. Данные временных рядов показали целый ряд закономерностей: некоторые с трендами, некоторые сезонные, а некоторые ни с тем, ни с другим. В то время они использовали свое собственное программное обеспечение, написанное собственными силами, но оно часто давало прогнозы, которые не выглядили разумными. Использовались следующие методы:

- среднее значение данных за последние 12 месяцев;
- среднее значение данных за последние 6 месяцев;
- прогноз на основе прямой регрессии за последние 12 месяцев;

- прогноз на основе прямой регрессии за последние 6 месяцев;
- прогноз, полученный с помощью прямой линии через последнее наблюдение с наклоном, равным среднему наклону линий, соединяющих значения за прошлый и текущий годы;
- прогноз, полученный с помощью прямой линии через последнее наблюдение с наклоном, равным среднему наклону линий, соединяющих значения за прошлый и текущий годы, где среднее значение берется только за последние 6 месяцев.

Им нужно было, чтобы мы рассказали им, что происходит не так, и модифицировали программное обеспечение, чтобы оно давало более точные прогнозы. Программное обеспечение было написано на языке COBOL, что затрудняло выполнение каких-либо сложных численных вычислений.

## Случай 2

В данном случае заказчиком выступило федеральное правительство Австралии, которому необходимо было спрогнозировать годовой бюджет Программы фармацевтических льгот (PBS). PBS предоставляет субсидии на многие фармацевтические продукты, продаваемые в Австралии, и расходы зависят от того, что люди покупают в течение года. В 2009 году суммарные расходы составили около 7 млрд австралийских долларов и занижались почти на 1 млрд долларов за каждые два года, прежде чем нас попросили помочь в разработке более точного подхода к прогнозированию.

Для того чтобы спрогнозировать суммарные расходы, необходимо спрогнозировать объемы продаж сотен групп фармацевтических продуктов, используя ежемесячные данные. Почти все группы имеют трендовые и сезонные закономерности. Объемы продаж многих групп резко увеличиваются или уменьшаются из-за изменений в том, какие лекарства субсидируются. Расходы для многих групп также претерпевают внезапные изменения из-за появления более дешевых препаратов конкурентов.

Таким образом, нам нужно было найти метод прогнозирования, который учитывал бы тренды и сезонность, если они присутствовали, и в то же время был устойчив к внезапным изменениям в базовых моделях. Кроме того, необходимо было иметь возможность автоматического применения к большому числу временных рядов.

## Случай 3

Крупная компания, занимающаяся автопарком, обратилась к нам с просьбой помочь им спрогнозировать стоимость перепродажи автомобилей. Они покупают новые автомобили, сдают их в аренду на три года, а затем продают. Более точные прогнозы стоимости продаж транспортных средств означали бы лучший контроль над прибылью; понимание того, что влияет на стоимость перепродажи, может позволить разработать политику лизинга и продаж с целью максимизации прибыли.

В то время стоимость перепродажи прогнозировалась группой специалистов. К сожалению, они рассматривали любую статистическую модель как угрозу своей работе и отказывались сотрудничать в предоставлении информации. Тем не менее компания предоставила большое количество данных о предыдущих автомобилях и их возможной стоимости при перепродаже.

### Случай 4

В этом проекте нам нужно было разработать модель для прогнозирования еженедельного пассажиропотока на основных внутренних маршрутах для одной из ведущих авиакомпаний Австралии. Компании требовались прогнозы числа пассажиров для каждого основного внутреннего маршрута и для каждого класса пассажиров (эконом-класс, бизнес-класс и первый класс). Компания предоставила еженедельные данные о трафике за предыдущие шесть лет.

На число авиапассажиров влияют школьные каникулы, крупные спортивные мероприятия, рекламные кампании, поведение конкурентов и т. д. Школьные каникулы в разных городах Австралии часто не совпадают, а спортивные мероприятия иногда переносятся из одного города в другой. В период исторических данных произошла крупная забастовка пилотов, во время которой в течение нескольких месяцев не было движения. Также была запущена и закрыта новая авиакомпания со сниженными ценами. Ближе к концу исторических данных авиакомпания опробовала перераспределение некоторых мест эконом-класса в бизнес-класс, а некоторых мест бизнес-класса – в первый класс. Однако через несколько месяцев классификация мест вернулась к первоначальному распределению.

## 1.6 Базовые шаги в задаче прогнозирования

Задача прогнозирования обычно включает в себя пять базовых шагов.

### Шаг 1: определение задачи

Нередко это самая сложная часть прогнозирования. Тщательное определение задачи требует понимания того, как прогнозы будут использоваться, кому прогнозы требуются и как функция прогнозирования вписывается в организацию, требующую прогнозов. Прогнозисту необходимо потратить время на общение со всеми, кто будет заниматься сбором данных, ведением баз данных и использованием прогнозов для будущего планирования.

### Шаг 2: сбор информации

Всегда требуется по крайней мере два вида информации: (а) статистические данные и (б) накопленный опыт людей, которые собирают данные и используют прогнозы. Нередко бывает трудно получить достаточное количество исторических данных, чтобы иметь возможность выполнить подгонку хорошей статистической модели. В этом случае можно использовать методы сужденческого прогнозирования, описанные в главе 6. Иногда старые данные будут менее полезны из-за структурных изменений в прогнозируемой системе; тогда мы можем выбрать использование только самых последних данных. Однако помните, что хорошие статистические модели будут учитывать эволюционные изменения в системе; не выбрасывайте хорошие данные без необходимости.

### Шаг 3: предварительный (разведывательный) анализ

Всегда следует начинать с построения графиков данных. Существуют ли неуклонные закономерности? Есть ли какой-то существенный тренд? Важна ли

сезонность? Есть ли подтверждающие данные о наличии бизнес-циклов? Есть ли какие-либо отклонения в данных, которые должны быть объяснены теми, кто обладает экспертными знаниями? Насколько сильны взаимосвязи между переменными, доступными для анализа? Для проведения этого анализа были разработаны различные инструменты. Они обсуждаются в главах 2 и 3.

### Шаг 4: выбор и подгонка моделей

Наилучшая для использования модель зависит от наличия исторических данных, силы взаимосвязей между прогнозной переменной и любыми объясняющими переменными, а также от способа использования прогнозов. Обычно сравнивают две или три потенциальные модели. Каждая модель сама по себе является искусственной конструкцией, основанной на наборе допущений (явных и неявных), и обычно включает в себя один или несколько параметров, которые должны быть оценены с использованием известных исторических данных. Мы обсудим регрессионные модели (глава 7), методы экспоненциального сглаживания (глава 8), модели ARIMA Бокса–Дженкинса (глава 9), динамические регрессионные модели (глава 10), иерархическое прогнозирование (глава 11) и несколько продвинутых методов, включая нейронные сети и векторную авторегрессию (глава 12).

### Шаг 5: использование и оценивание модели прогнозирования

После выбора модели и оценивания ее параметров модель используется для продуцирования прогнозов. Результативность модели можно надлежаще оценить только после того, как станут доступны данные за прогнозируемый период. Был разработан ряд методов, помогающих оценивать точность прогнозов. Кроме того, при использовании прогнозов и принятии мер в соответствии с ними есть организационные проблемы. Краткое обсуждение некоторых из этих вопросов приведено в главе 5. При использовании модели прогнозирования на практике возникает целый ряд практических проблем, таких как то, как обрабатывать пропущенные значения и выбросы или как работать с короткими временными рядами. Они обсуждаются в главе 13.

## 1.7 Перспектива статистического прогнозирования

То, что мы пытаемся спрогнозировать, неизвестно (иначе мы бы не прогнозировали это), и поэтому о нем можно думать как о случайной величине. Например, суммарный объем продаж за следующий месяц может принимать различные возможные значения, и пока мы не сложим фактические продажи в конце месяца, мы не узнаем, каким будет значение. Поэтому, пока мы не узнаем объем продаж за следующий месяц, это случайная величина.

Поскольку следующий месяц относительно близок, у нас обычно есть хорошее представление о том, какими могут быть вероятные показатели продаж. С другой стороны, если мы прогнозируем продажи за тот же месяц в следующем году, то возможные значения, которые он может принять, гораздо более изменчивы. В большинстве ситуаций прогнозирования вариа-

ции, связанные с тем, что мы прогнозируем, будут уменьшаться по мере приближения события. Другими словами, чем дальше мы прогнозируем, тем больше у нас сомнений.

Можно представить себе множество вариантов возможного будущего, каждое из которых дает разную стоимость того, что мы хотим спрогнозировать. На рис. 1.2 черным цветом показано общее число международных прибытий в Австралию с 1980 по 2015 год. Также показаны десять вариантов возможного будущего на 2016–2025 годы.

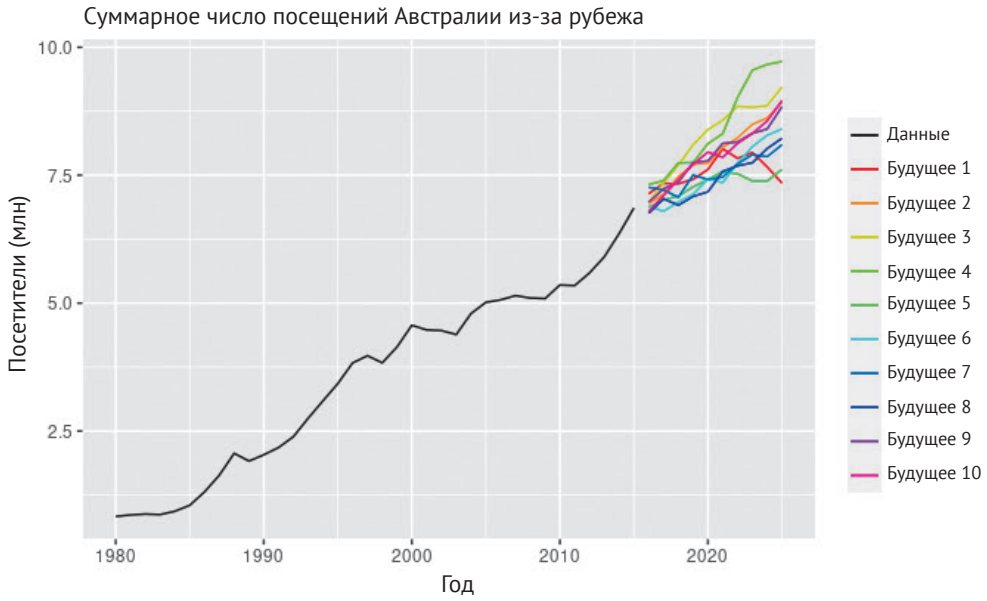


**Рисунок 1.2:** Общее число иностранных туристов, посетивших Австралию (1980–2015 гг.), а также десять вариантов возможного будущего

Когда мы получаем прогноз, мы оцениваем середину диапазона возможных значений, которые случайная величина может принимать. Нередко прогноз сопровождается предсказательным интервалом, дающим диапазон значений, которые случайная величина может принимать с относительно высокой вероятностью. Например, 95%-ный предсказательный интервал содержит диапазон значений, который должен включать фактическое будущее значение с вероятностью 95 %.

Вместо нанесения на график отдельных вариантов возможного будущего, как показано на рис. 1.2, мы обычно показываем эти предсказательные интервалы. На рис. 1.3 показаны интервалы между 80 % и 95 % в отношении будущих иностранных посетителей Австралии. Синяя линия – это среднее значение возможных будущих значений, которые мы называем **точечными прогнозами**.

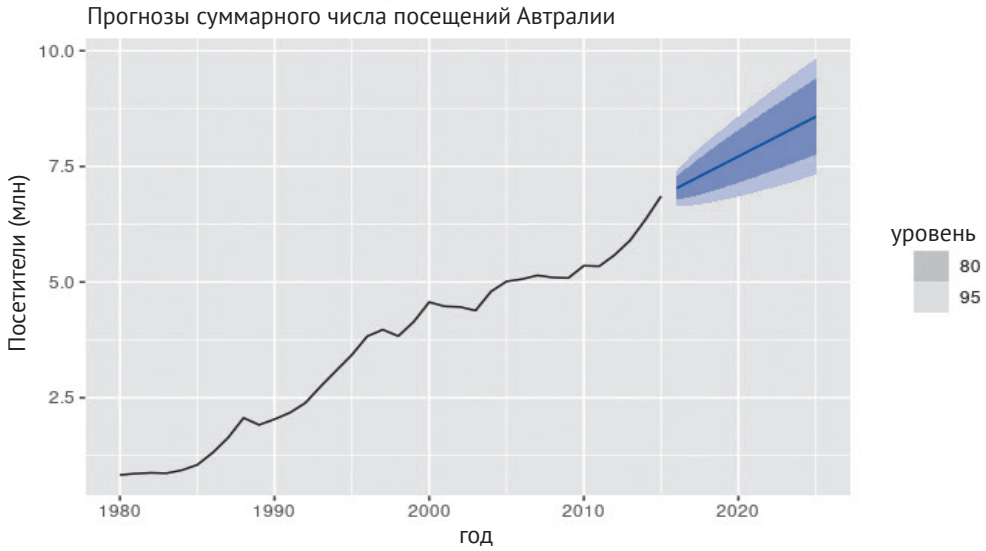


**Рисунок 1.3:** Общее число иностранных посетителей Австралии (1980–2015 гг.) вместе с прогнозами на 10 лет и 80%-ным и 95%-ным предсказательными интервалами

Мы будем использовать индекс $t$ для времени. Например, $y_t$ будет обозначать наблюдение в момент времени $t$. Предположим, мы обозначим всю информацию, которую мы наблюдали, как $I$, и хотим спрогнозировать $y_t$. Тогда мы записываем $y_t|I$, что означает «случайную величину $y_t$ с учетом того, что мы знаем в $I$». Набор значений, которые может принимать эта случайная величина, наряду с их относительными вероятностями называется «распределением вероятностей» случайной величины $y_t|I$. В прогнозировании мы называем его **прогнозным распределением**.

Когда мы говорим о «прогнозе», мы обычно имеем в виду среднее значение прогнозного распределения, и мы ставим «шляпку» над $y$, чтобы это показать. Таким образом, мы записываем прогноз $y_t$ как $\hat{y}_{t|t-1}$, что означает среднее из возможных значений, которые $y_t$ может принимать, учитывая все, что мы знаем.

Нередко бывает полезно точно указывать, какую информацию мы использовали при расчете прогноза. Тогда мы запишем, например, $\hat{y}_{t|t-1}$, чтобы обозначить прогноз $y_t$, принимая во внимание все предыдущие наблюдения $(y_1, \dots, y_{t-1})$. Аналогичным образом $\hat{y}_{T+h|T}$ означает прогноз $y_{T+h}$ с учетом $y_1, \dots, y_T$ (т. е. прогноз на $h$ шагов вперед с учетом всех наблюдений вплоть до времени $T$).

## 1.8 Упражнения

1. Для случаев 3 и 4 в разделе 1.5 перечислите возможные предсказательные переменные, которые могут быть полезны, при условии наличия соответствующих данных.
2. Для случая 3 в разделе 1.5 опишите пять шагов прогнозирования в контексте этого проекта.

## 1.9 Дальнейшее чтение

Армстронг (2001, *https://otexts.com/fpp3/intro-reading.html#ref-Armstrong01*) охватывает всю область прогнозирования, причем каждая глава написана разными экспертами. Временами он очень самоуверен (и мы не со всем с ним согласны), но он полон превосходных общих советов по решению задач прогнозирования.

Орд и соавт. (2017, *https://otexts.com/fpp3/intro-reading.html#ref-Ord2017*) – это учебник по прогнозированию, охватывающий несколько тем, что и в этой книге, но с другим акцентом и не ориентированный на какую-либо конкретную программную среду. Она написана тремя весьма уважаемыми прогнозистами, имеющими многолетний опыт работы.

## Библиография

*Армстронг, Дж. С.* (ред.). (2001). Принципы прогнозирования: руководство для исследователей и практиков. Kluwer Academic Publishers. [Amazon, *http://buy.geni.us/Proxy.ashx?TSID=140570&GR_URL=http%3A%2F%2Fwww.amazon.com%2Fdp%2F0792379306*].

*Орд, Дж. К., Филдес, Р. и Курентзес, Н.* (2017). Принципы бизнес-прогнозирования. 2-е изд. Wessex Press Publishing Co. [Amazon, *http://buy.geni.us/Proxy.ashx?TSID=140570&GR_URL=http%3A%2F%2Fwww.amazon.com%2Fdp%2F0999064916*].

# Глава 2

# Графика временных рядов

В любой задаче анализа данных первым делом нужно построить график данных. Графики позволяют визуализировать многие признаки данных, включая закономерности, необычные наблюдения, изменения с течением времени и взаимосвязи между переменными. Признаки, которые видны на графиках данных, затем должны быть максимально включены в используемые методы прогнозирования. Тип данных определяет метод прогнозирования, который необходимо использовать, равно как и то, какие графики подходят. Но прежде чем строить графики, необходимо настроить временные ряды в R.

## 2.1 Объекты twibble

Временной ряд можно рассматривать как список чисел (измерений), а также некоторую информацию о том, в какое время эти числа были зарегистрированы (внесены в индекс). В языке R указанная информация может храниться в виде объекта `twiddle`.

### Переменная-индекс

Предположим, у вас есть ежегодные наблюдения за последние несколько лет:

| Год | Наблюдения |
|---|---|
| 2015 | 123 |
| 2016 | 39 |
| 2017 | 78 |
| 2018 | 52 |
| 2019 | 110 |

Эти данные можно превратить в объект `twibble` с помощью функции `twiddle()`:

```
y <- tsibble(
  Year = 2015:2019,
  Observation = c(123, 39, 78, 52, 110),
  index = Year
)
```

Объекты `tsibble` расширяют чистые кадры данных (объекты `tibble`), вводя темпоральную структуру. Мы установили индекс временного ряда в качестве столбца года, который ассоциирует наблюдения (`Observation`) со временем регистрации (`Year`).

Для наблюдений, которые происходят чаще, чем один раз в год, необходимо использовать определенную на индексе функцию класса времени. Например, предположим, что у нас есть ежемесячный набор данных `z`:

```
y
#> # A tibble: 5 × 2
#>   Month    Observation
#>   <chr>          <dbl>
#> 1 2019 Jan          50
#> 2 2019 Feb          23
#> 3 2019 Mar          34
#> 4 2019 Apr          30
#> 5 2019 May          25
```

Его можно конвертировать в объект `twibble` с помощью следующего ниже исходного кода:

```
y %>%
  mutate(Month = yearmonth(Month)) %>%
  as_tsibble(index = Month)
#> # A tsibble: 5 x 2 [1M]
#>      Month Observation
#>      <mth>       <dbl>
#> 1 2019 Jan          50
#> 2 2019 Feb          23
#> 3 2019 Mar          34
#> 4 2019 Apr          30
#> 5 2019 May          25
```

Сначала столбец месяца конвертируется из текста в объект месячного времени с помощью функции `yearmonth()`. Затем мы конвертируем кадр данных в `twibble`, задавая переменную-индекс с помощью `as_twiddle()`. Обратите внимание на добавление «`[1M]`» в первой строке, указывающее на то, что это месячные данные.

В зависимости от частоты наблюдений можно использовать другие функции классов времени.

| Частота | Функция |
|---|---|
| Годичная | `start:end` |
| Квартальная | `yearquarter()` |
| Кварталная | `yearmonth()` |
| Недельная | `yearweek()` |
| Дневная | `as_date(), ymd()` |
| Субдневная | `as_datetime(), ymd_hms()` |

## Переменные-ключи

Объект `twibble` также позволяет хранить несколько временных рядов в одном объекте. Предположим, вас интересует набор данных, содержащий самое быстрое финишное время в женских и мужских забегах на Олимпийских играх, от 100 м до 10 000 м:

```
olympic_running
#> # A tsibble: 312 x 4 [4Y]
#> # Key:       Length, Sex [14]
#>     Year Length Sex    Time
#>    <int>  <int> <chr> <dbl>
#>  1  1896    100 men    12
#>  2  1900    100 men    11
#>  3  1904    100 men    11
#>  4  1908    100 men    10.8
#>  5  1912    100 men    10.8
#>  6  1916    100 men    NA
#>  7  1920    100 men    10.8
#>  8  1924    100 men    10.6
#>  9  1928    100 men    10.8
#> 10  1932    100 men    10.3
#> # … и еще 302 строки
```

Приведенная выше сводка показывает, что это объект `twibble`, который содержит 312 строк и 4 столбца. Наряду с этим «`[4Y]`» сообщает о том, что интервал этих наблюдений составляет каждые четыре года. Ниже приведена структура ключа, которая информирует нас о том, что в `tsibble` имеется 14 отдельных временных рядов. Также показан предварительный обзор первых 10 наблюдений, в котором мы видим, что пропущенное значение относится к 1916 году. Это связано с тем, что Олимпийские игры во время Первой мировой войны не проводились.

14 временных рядов в этом объекте однозначно идентифицируются ключами: переменными `Length` (Длина) и `Sex` (Пол). Функцию `distinct()` можно использовать для вывода на экран категорий каждой переменной или даже комбинаций переменных:

```
olympic_running %>% distinct(Sex)
#> # A tibble: 2 × 1
#>   Sex
#>   <chr>
#> 1 men
#> 2 women
```

## Работа с объектами twibble

Для работы с объектами `twibble` можно использовать функции `dplyr`, такие как `mutate()`, `filter()`, `select()` и `summarise()`. В качестве иллюстрации мы будем использовать `tiddle`-объект `PBS`, содержащий данные о продажах фармацевтической продукции в Австралии.

```
PBS
#> # A tsibble: 67,596 x 9 [1M]
#> # Key:       Concession, Type, ATC1, ATC2 [336]
#>       Month Concession   Type    ATC1  ATC1_desc ATC2  ATC2_desc Scripts  Cost
#>       <mth> <chr>        <chr>   <chr> <chr>     <chr> <chr>       <dbl> <dbl>
#>  1 1991 Jul Concessional Co-pay… A     Alimenta… A01   STOMATOL…   18228 67877
#>  2 1991 Aug Concessional Co-pay… A     Alimenta… A01   STOMATOL…   15327 57011
#>  3 1991 Sep Concessional Co-pay… A     Alimenta… A01   STOMATOL…   14775 55020
#>  4 1991 Oct Concessional Co-pay… A     Alimenta… A01   STOMATOL…   15380 57222
#>  5 1991 Nov Concessional Co-pay… A     Alimenta… A01   STOMATOL…   14371 52120
#>  6 1991 Dec Concessional Co-pay… A     Alimenta… A01   STOMATOL…   15028 54299
#>  7 1992 Jan Concessional Co-pay… A     Alimenta… A01   STOMATOL…   11040 39753
#>  8 1992 Feb Concessional Co-pay… A     Alimenta… A01   STOMATOL…   15165 54405
#>  9 1992 Mar Concessional Co-pay… A     Alimenta… A01   STOMATOL…   16898 61108
#> 10 1992 Apr Concessional Co-pay… A     Alimenta… A01   STOMATOL…   18141 65356
#> # … и еще 67586 строк
```

Здесь содержатся ежемесячные рецептурные данные Medicare Australia за период с июля 1991 года по июнь 2008 года. Они классифицируются в соответствии с различными типами концессий и анатомо-терапевтическими химическими индексами (Anatomical Therapeutic Chemical, аббр. ATC). В этом примере нас интересует временной ряд `Cost` (суммарная стоимость рецептов в австралийских долларах).

С целью извлечения рецептов A10 можно использовать функцию `filter()`:

```
PBS %>%
  filter(ATC2 == "A10")
#> # A tsibble: 816 x 9 [1M]
#> # Key:       Concession, Type, ATC1, ATC2 [4]
#>       Month Concession   Type   ATC1  ATC1_desc ATC2  ATC2_desc Scripts   Cost
#>       <mth> <chr>        <chr>  <chr> <chr>     <chr> <chr>       <dbl>  <dbl>
```

```
#>  1 1991 Jul Concessional Co-pa… A     Alimenta… A10   ANTIDIAB…   89733 2.09e6
#>  2 1991 Aug Concessional Co-pa… A     Alimenta… A10   ANTIDIAB…   77101 1.80e6
#>  3 1991 Sep Concessional Co-pa… A     Alimenta… A10   ANTIDIAB…   76255 1.78e6
#>  4 1991 Oct Concessional Co-pa… A     Alimenta… A10   ANTIDIAB…   78681 1.85e6
#>  5 1991 Nov Concessional Co-pa… A     Alimenta… A10   ANTIDIAB…   70554 1.69e6
#>  6 1991 Dec Concessional Co-pa… A     Alimenta… A10   ANTIDIAB…   75814 1.84e6
#>  7 1992 Jan Concessional Co-pa… A     Alimenta… A10   ANTIDIAB…   64186 1.56e6
#>  8 1992 Feb Concessional Co-pa… A     Alimenta… A10   ANTIDIAB…   75899 1.73e6
#>  9 1992 Mar Concessional Co-pa… A     Alimenta… A10   ANTIDIAB…   89445 2.05e6
#> 10 1992 Apr Concessional Co-pa… A     Alimenta… A10   ANTIDIAB…   97315 2.23e6

#> # … и еще 806 строк
```

Это позволяет выбирать строки объекта `twibble`. Далее результирующий объект можно упростить, отобрав столбцы, которые нам понадобятся при последующем анализе.

```
PBS %>%
  filter(ATC2 == "A10") %>%
  select(Month, Concession, Type, Cost)
#> # A tsibble: 816 x 4 [1M]
#> # Key:       Concession, Type [4]
#>       Month Concession   Type           Cost
#>       <mth> <chr>        <chr>         <dbl>
#>  1 1991 Jul Concessional Co-payments 2092878
#>  2 1991 Aug Concessional Co-payments 1795733
#>  3 1991 Sep Concessional Co-payments 1777231
#>  4 1991 Oct Concessional Co-payments 1848507
#>  5 1991 Nov Concessional Co-payments 1686458
#>  6 1991 Dec Concessional Co-payments 1843079
#>  7 1992 Jan Concessional Co-payments 1564702
#>  8 1992 Feb Concessional Co-payments 1732508
#>  9 1992 Mar Concessional Co-payments 2046102
#> 10 1992 Apr Concessional Co-payments 2225977

#> # … и еще 806 строк
```

Функция `select()` позволяет отбирать те или иные столбцы, в то время как `filter()` позволяет оставлять те или иные строки.

Обратите внимание, что переменная-индекс `Month`, а также ключи `Concession` и `Type` будут возвращены, даже если они не были выбраны в явной форме, поскольку они требуются для `tsibble` (с целью обеспечения того, что каждая строка содержала уникальную комбинацию ключей и индекса).

Еще одна полезная функция – это `summarise()`. Она позволяет комбинировать данные по ключам. Например, у нас может возникнуть потребность рассчитать суммарную стоимость за месяц независимо от ключей `Concession` или `Type`.

```
PBS %>%
  filter(ATC2 == "A10") %>%
  select(Month, Concession, Type, Cost) %>%
  summarise(TotalC = sum(Cost))
#> # A tsibble: 204 x 2 [1M]
#>       Month  TotalC
#>       <mth>   <dbl>
#>  1 1991 Jul 3526591
#>  2 1991 Aug 3180891
#>  3 1991 Sep 3252221
#>  4 1991 Oct 3611003
#>  5 1991 Nov 3565869
#>  6 1991 Dec 4306371
#>  7 1992 Jan 5088335
#>  8 1992 Feb 2814520
#>  9 1992 Mar 2985811
#> 10 1992 Apr 3204780
#> # … и еще 194 строки
```

Новая переменная `TotalC` представляет собой сумму всех значений `Cost` за каждый месяц.

С помощью функции `mutate()` можно создавать новые переменные. Здесь мы меняем единицы измерения с долларов на миллионы долларов:

```
PBS %>%
  filter(ATC2 == "A10") %>%
  select(Month, Concession, Type, Cost) %>%
  summarise(TotalC = sum(Cost)) %>%
  mutate(Cost = TotalC/1e6)
#> # A tsibble: 204 x 3 [1M]
#>       Month  TotalC  Cost
#>       <mth>   <dbl> <dbl>
#>  1 1991 Jul 3526591  3.53
#>  2 1991 Aug 3180891  3.18
#>  3 1991 Sep 3252221  3.25
#>  4 1991 Oct 3611003  3.61
#>  5 1991 Nov 3565869  3.57
#>  6 1991 Dec 4306371  4.31
#>  7 1992 Jan 5088335  5.09
#>  8 1992 Feb 2814520  2.81
#>  9 1992 Mar 2985811  2.99
#> 10 1992 Apr 3204780  3.20
#> # … и еще 194 строки
```

Наконец, мы сохраним результирующий twibble для примеров, приводимых позже в этой главе.

```
PBS %>%
  filter(ATC2 == "A10") %>%
  select(Month, Concession, Type, Cost) %>%
  summarise(TotalC = sum(Cost)) %>%
  mutate(Cost = TotalC / 1e6) -> a10
```

В конце этой серии конвейерных функций мы использовали правое присваивание (->), которое встречается в исходном коде на R нечасто, но которое удобно в конце длинной серии команд, поскольку оно продолжает поток исходного кода.

## Прочитать csv-файл и конвертировать его в twibble

Почти все данные, используемые в этой книге, уже хранятся в виде объектов twibble. Но бóльшая часть данных, до того, как они будут импортированы в R, хранится в базах данных, файлах MS-Excel или csv-файлах. Поэтому нередко первым шагом в создании tsibble является чтение данных, а затем определение индекса и переменных-ключей.

Например, предположим, что у нас есть следующие ниже квартальные данные, хранящиеся в csv-файле (показаны только первые 10 строк). Этот набор данных содержит информацию о численности заключенных в Австралии в разбивке по штатам, полу, правовому статусу и статусу принадлежности к коренному населению. (Здесь ATSI – это аббревиатура от Aboriginal or Torres Strait Islander, т. е. абориген или житель островов Торресова пролива.)

| Дата | Штат | Пол | Правовой статус | Коренное население | Количество |
|---|---|---|---|---|---|
| 2005-03-01 | ACT | Женщина | Заключена под стражу | ATSI | 0 |
| 2005-03-01 | ACT | Женщина | Заключена под стражу | не-ATSI | 2 |
| 2005-03-01 | ACT | Женщина | Приговорена | ATSI | 0 |
| 2005-03-01 | ACT | Женщина | Приговорена | не-ATSI | 5 |
| 2005-03-01 | ACT | Мужчина | Заключен под стражу | ATSI | 7 |
| 2005-03-01 | ACT | Мужчина | Заключен под стражу | не-ATSI | 58 |
| 2005-03-01 | ACT | Мужчина | Приговорен | ATSI | 5 |
| 2005-03-01 | ACT | Мужчина | Приговорен | не-ATSI | 101 |
| 2005-03-01 | NSW | Женщина | Заключена под стражу | ATSI | 51 |
| 2005-03-01 | NSW | Женщина | Заключена под стражу | не-ATSI | 131 |

Указанные данные можно прочитать в R и создать объект `tiddle`, просто указав столбец, который содержит индекс времени, и столбцы, которые являются ключами. Остальные столбцы являются значениями – столбцов-значений бывает много, хотя в данном случае есть только один (`Count`). В изначальном csv-файле даты хранились как отдельные дни, хотя на самом деле данные являются квартальными, поэтому необходимо конвертировать переменную `Date` в кварталы.

```
prison <- readr::read_csv("https://OTexts.com/fpp3/extrafiles/prison_population.csv")
prison <- prison %>%
  mutate(Quarter = yearquarter(Date)) %>%
  select(-Date) %>%
  as_tsibble(key = c(State, Gender, Legal, Indigenous),
             index = Quarter)
```

```
prison
#> # A tsibble: 3,072 x 6 [1Q]
#> # Key:       State, Gender, Legal, Indigenous [64]
#>    State Gender Legal    Indigenous Count Quarter
#>    <chr> <chr>  <chr>    <chr>      <dbl>   <qtr>
#>  1 ACT   Female Remanded ATSI           0 2005 Q1
#>  2 ACT   Female Remanded ATSI           1 2005 Q2
#>  3 ACT   Female Remanded ATSI           0 2005 Q3
#>  4 ACT   Female Remanded ATSI           0 2005 Q4
#>  5 ACT   Female Remanded ATSI           1 2006 Q1
#>  6 ACT   Female Remanded ATSI           1 2006 Q2
#>  7 ACT   Female Remanded ATSI           1 2006 Q3
#>  8 ACT   Female Remanded ATSI           0 2006 Q4
#>  9 ACT   Female Remanded ATSI           0 2007 Q1
#> 10 ACT   Female Remanded ATSI           1 2007 Q2
#> # … и еще 3062 строк
```

Распечатанный выше список содержит 64 отдельных временных ряда, соответствующих комбинациям 8 штатов, 2 полов, 2 правовых статусов и 2 статусов коренных народов. Каждый ряд состоит из 48 наблюдений за период с 2005Q1 по 2016Q4.

С целью обеспечения валидности объекта `tsibble` для каждой комбинации ключей требуется уникальный индекс. Функция `twiddle()` или `as_twibble()` будет возвращать ошибку, если это неверно.

## Сезонный период

В некоторых графиках и некоторых моделях будет использоваться сезонный период данных. Сезонный период – это число наблюдений до наступления по-

вторения сезонной закономерности. В большинстве случаев это будет обнаружено автоматически с помощью переменной-индекса времени.

Несколько распространенных периодов для разных временных интервалов показаны в приведенной ниже таблице:

| Даные | Минута | Час | День | Неделя | Год |
|---|---|---|---|---|---|
| Кварталы | | | | | 4 |
| Месяцы | | | | | 12 |
| Недели | | | | | 52 |
| Дни | | | | 7 | 365.25 |
| Часы | | | 24 | 168 | 8766 |
| Минуты | | 60 | 1440 | 10 080 | 525 960 |
| Секунды | 60 | 3600 | 86 400 | 604 800 | 31 557 600 |

В квартальных, ежемесячных и еженедельных данных существует только один сезонный период – число наблюдений в течение каждого года. На самом деле в году не 52 недели, а в среднем 365.25 / 7 = 52.18, с учетом високосного года каждый четвертый год. Аппроксимация сезонных периодов целыми числами бывает полезной, поскольку многие сезонные члены в моделях поддерживают только целочисленные сезонные периоды.

Если данные наблюдаются более одного раза в неделю, то в данных часто присутствует более одной сезонной закономерности. Например, данные с ежедневными наблюдениями могут иметь еженедельную (период = 7) или годовую (период = 365.25) сезонную закономерность. И аналогичным образом данные, которые наблюдаются каждую минуту, могут иметь почасовую (период = 60), ежедневную (период = 24 × 60 = 1440), еженедельную (период = 24 × 60 × 7 = 10 080 ) и годовую (период = 24 × 60 × 365.25 = 525 960) сезонности.

Более сложные (и необычные) сезонные закономерности можно задать с помощью функции `period()` пакета `lubridate`.

## 2.2 Графики времени

Очевидно, что первым графиком при работе с данными временных рядов должен быть график времени. То есть наблюдения наносятся на график в сопоставлении со временем наблюдения, при этом поочередные наблюдения соединяются прямыми линиями. На рис. 2.1 показан еженедельный пассажиропоток эконом-класса авиакомпании Ansett между двумя крупнейшими городами Австралии.

```
melsyd_economy <- ansett %>%
  filter(Airports == "MEL-SYD", Class == "Economy") %>%
  mutate(Passengers = Passengers/1000)
autoplot(melsyd_economy, Passengers) +
  labs(title = "Эконом-класс авиакомпании Ansett",
       subtitle = "Мельбурн-Сидней",
       y = "Пассажиры (тыс.)")
          x = "Неделя [1W]")
```

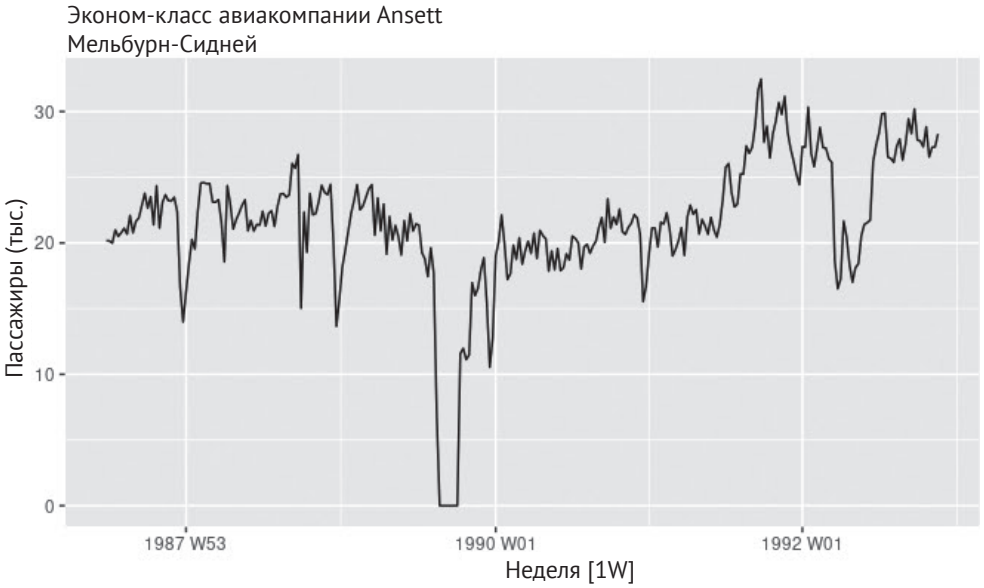


**Рисунок 2.1:** Еженедельный пассажиропоток эконом-класса авиакомпании Ansett Airlines

Мы будем использовать команду `autoplot()` довольно часто. Она автоматически генерирует подходящий график того, что вы передаете ей в первом аргументе. В данном случае она распознает `melsyd_economy` как временной ряд и строит график времени.

График времени сразу же выявляет несколько интересных признаков.

- В 1989 году был период, когда пассажиров не возили, – это было связано с трудовым спором.
- В 1992 году был период снижения нагрузки. Это было связано с испытанием, в ходе которого некоторые места эконом-класса были заменены местами бизнес-класса.
- Значительное увеличение пассажиропотока произошло во второй половине 1991 года.
- Примерно в начале каждого года происходит несколько больших падений нагрузки. Это связано с праздничными эффектами.
- Имеется долгосрочное колебание в уровне ряда, которое увеличивается в течение 1987 года, уменьшается в 1989 году и снова увеличивается в течение 1990 и 1991 годов.

Любая модель должна учитывать все эти признаки, чтобы эффективно прогнозировать пассажиропоток в будущем.

Более простой временной ряд показан на рис. 2.2 с использованием данных `a10`, которые были сохранены ранее.

```
autoplot(a10, Cost) +
  labs(y = "$ (млн)",
       title = "Продажи противодиабетических препаратов в Австралии")
```

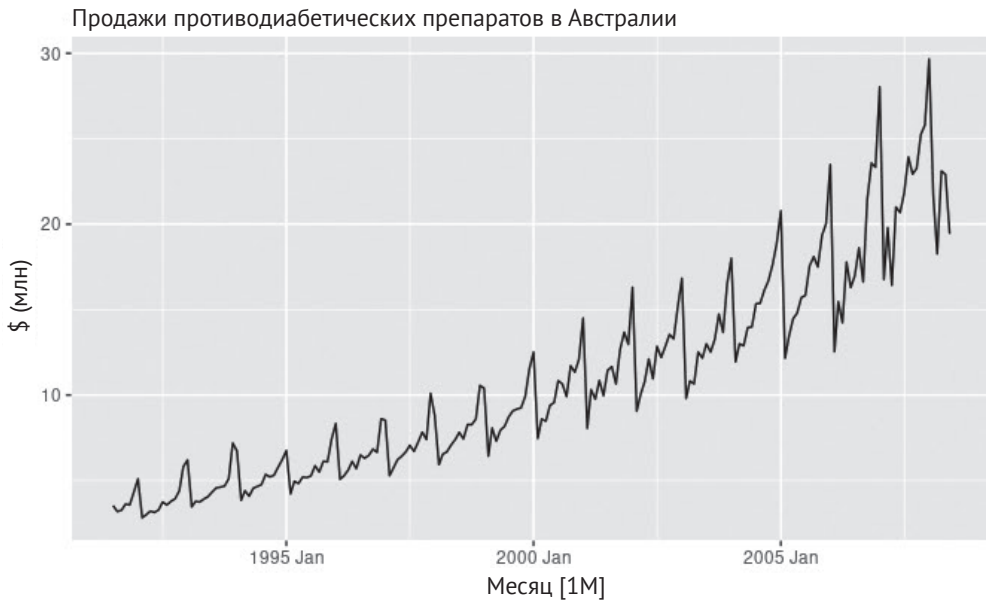


**Рисунок 2.2:** Ежемесячные продажи противодиабетических препаратов в Австралии

Здесь прослеживается четкий и растущий тренд. Кроме того, имеется сильная сезонная закономерность, которая увеличивается в размерах по мере увеличения уровня ряда. Внезапное снижение в начале каждого года обусловлено правительственной схемой субсидирования, которая позволяет пациентам экономично накапливать лекарства в конце календарного года. Любые прогнозы из этого ряда должны учитывать сезонную закономерность и тот факт, что тренд меняется медленно.

## 2.3 Закономерности временных рядов

При описании упомянутых выше временных рядов мы использовали такие слова, как «тренд» и «сезонный», которые нуждаются в более тщательном определении.

### Тренд

Тренд существует, когда данные увеличиваются или уменьшаются в долгосрочной перспективе. Это не обязательно должно происходить линейно. Иногда мы будем называть тренд «изменением в направлении», когда он может переходить от восходящего тренда к нисходящему тренду. На рис. 2.2 показан тренд в данных продаж противодиабетических препаратов.

### Сезонный

Сезонная закономерность возникает, когда на временной ряд влияют сезонные факторы, такие как время года или день недели. Сезонность всегда имеет фиксированный и известный период. Ежемесячные продажи противодиабетических препаратов (рис. 2.2) показывают сезонность, которая частично обусловлена изменением стоимости лекарств в конце календарного года.

## Циклический

Цикл возникает, когда данные демонстрируют подъемы и спады, которые не имеют фиксированной частоты. Эти колебания обычно обусловлены экономически и часто связаны с «деловым циклом». Продолжительность указанных колебаний обычно составляет не менее 2 лет.

Многие люди путают циклическое поведение с сезонным поведением, но на самом деле поведение совершенно разное. Если колебания не имеют фиксированной частоты, то они цикличны; если частота неизменна и связана с каким-либо аспектом календаря, то закономерность носит сезонный характер. В целом средняя продолжительность циклов больше, чем продолжительность сезонной закономерности, и величины циклов, как правило, более изменчивы, чем величины сезонных закономерностей.

Многие временные ряды включают тренд, циклы и сезонность. При выборе метода прогнозирования сначала необходимо выявить закономерности временных рядов в данных, а затем выбрать метод, который способен улавливать закономерности надлежащим образом.

Примеры на рис. 2.3 показывают разные комбинации этих компонент.

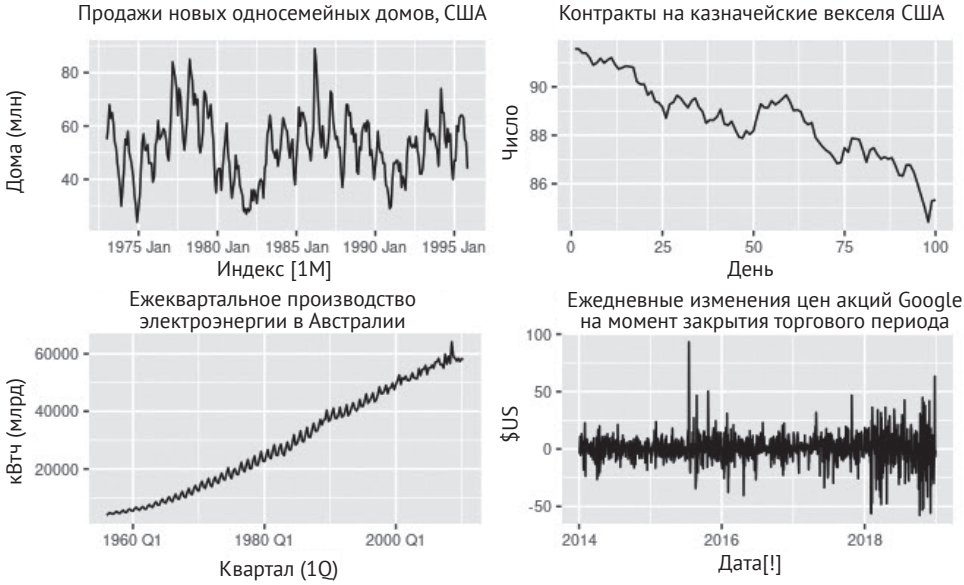


**Рисунок 2.3:** Четыре примера временных рядов, демонстрирующих различные закономерности

1. Ежемесячные продажи жилья (вверху слева) демонстрируют сильную сезонность в течение каждого года, а также некоторую сильную цикличность с периодом около 6–10 лет. В данных за этот период нет явного тренда.
2. Контракты на казначейские векселя США (вверху справа) показывают результаты чикагского рынка за 100 торговых дней подряд в 1981 году. Здесь нет сезонности, но очевиден понижательный тренд. Возможно, если бы у нас был гораздо более длинный ряд, то мы бы увидели, что

этот понижательный тренд на самом деле является частью длительного цикла, но при просмотре всего за 100 дней он выглядит как тренд.

3. Квартальный отчет по производству электроэнергии в Австралии (внизу слева) демонстрирует сильный повышательный тренд с сильной сезонностью. Здесь нет никаких подтверждающих данных о каком-либо циклическом поведении.
4. Ежедневное изменение цены акций Google на момент закрытия торгового периода (внизу справа) не имеет ни тренда, ни сезонности, ни цикличности. Имеются случайные колебания, которые выглядят не очень предсказуемыми, и нет сильных закономерностей, которые помогли бы при разработке модели прогнозирования.

## 2.4 Сезонные графики

Сезонный график аналогичен графику времени, за исключением того, что данные изображаются в сопоставлении с отдельными «сезонами», в которые они наблюдались. Пример приведен на рис. 2.4, показывающем продажи противодиабетических препаратов.

```
a10 %>%
  gg_season(Cost, labels = "both") +
  labs(y = "$ (млн)",
       title = "Сезонный график: продажи противодиабетических препаратов")
```

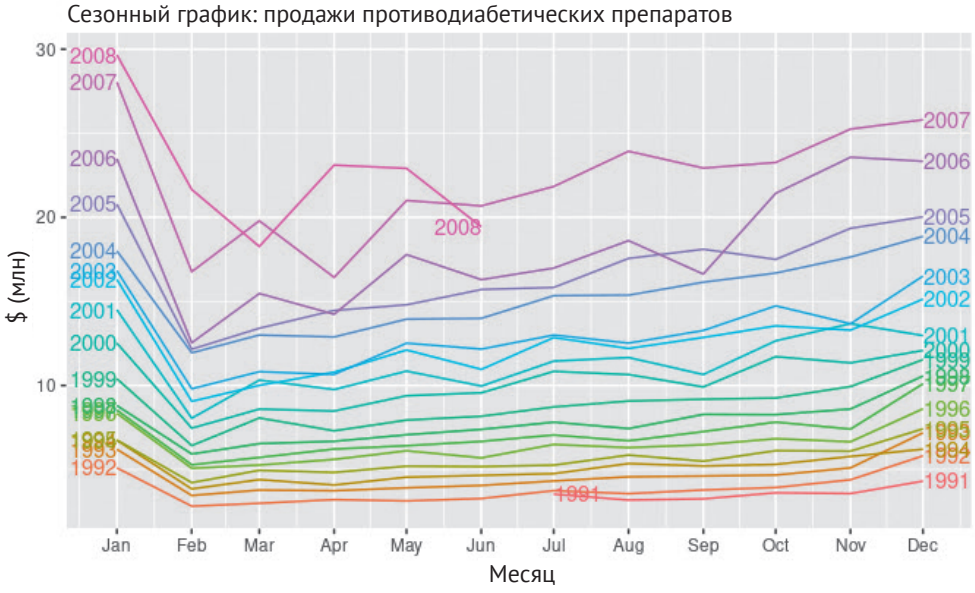


**Рисунок 2.4:** Сезонный график ежемесячных продаж противодиабетических препаратов в Австралии

Это точно те же данные, которые были показаны ранее, но теперь данные за каждый сезон накладываются друг на друга. Сезонный график позволяет четче

видеть опорную сезонную закономерность и особенно полезен для выявления лет, в течение которых эта закономерность меняется.

В данном случае ясно, что в январе каждого года наблюдается большой скачок продаж. На самом деле это, вероятно, распродажи в конце декабря, поскольку покупатели делают запасы до конца календарного года, но продажи регистрируются правительством только через неделю или две. График также показывает, что в марте 2008 года было необычно мало продаж (в большинстве других лет в период с февраля по март наблюдается рост). Небольшое количество продаж в июне 2008 года, вероятно, связано с неполным подсчетом продаж на момент сбора данных.

## Несколько сезонных периодов

Если данные содержат более одной сезонной закономерности, то аргумент `period` можно использовать для выбора требуемого сезонного графика. Данные `vic_elec` содержат получасовой спрос на электроэнергию в штате Виктория, Австралия. На график можно нанести дневную закономерность, недельную закономерность либо годовую закономерность, указав аргумент `period`, как показано на рис. 2.5–2.7.

На первом графике три дня с 25 часами относятся к тому времени, когда в каждом году заканчивался переход на летнее время, и поэтому в указанные дни имелся дополнительный час. Также имелось три дня всего по 23 часа в каждом (когда начинался переход на летнее время), но они скрыты под всеми другими линиями на графике.

```
vic_elec %>% gg_season(Demand, period = "day") +
  theme(legend.position = "none") +
  labs(y="МВтч", title="Спрос на электроэнергию: Виктория")
```

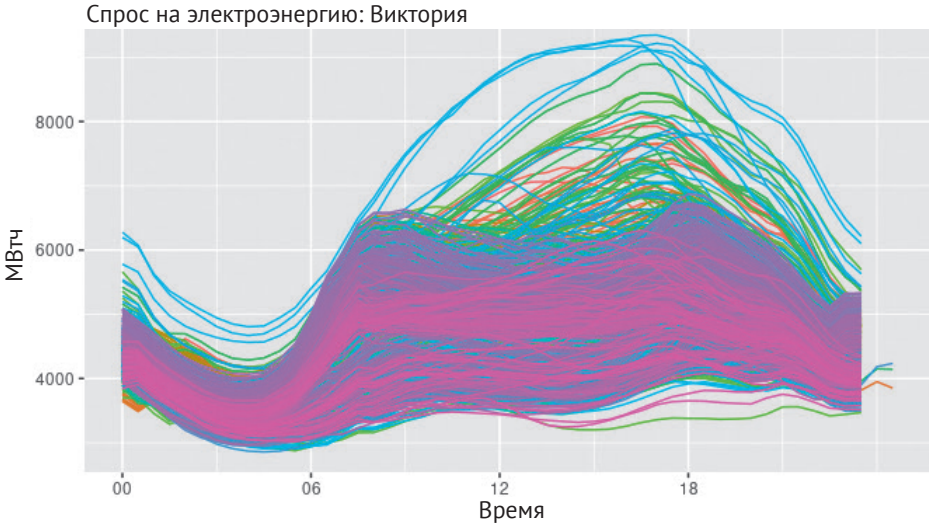


**Рисунок 2.5:** Сезонный график, показывающий ежедневные сезонные изменения спроса на электроэнергию в шт. Виктория

```
vic_elec %>% gg_season(Demand, period = "week") +
  theme(legend.position = "none") +
  labs(y="МВтч", title="Спрос на электроэнергию: Виктория")
```

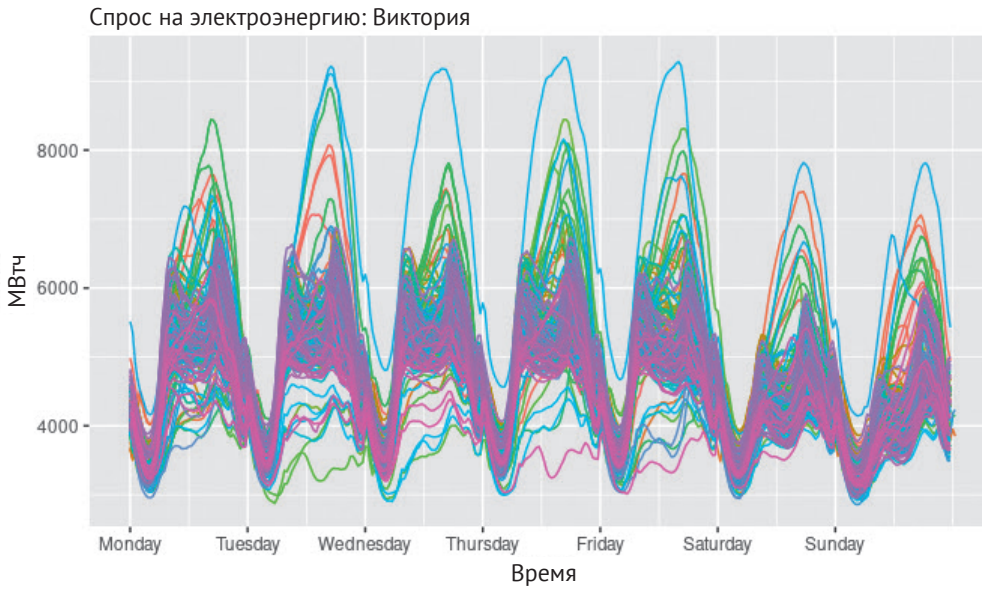


**Рисунок 2.6:** Сезонный график, показывающий еженедельные сезонные изменения спроса на электроэнергию в шт. Виктория

```
vic_elec %>% gg_season(Demand, period = "year") +
  labs(y="МВтч", title="Спрос на электроэнергию: Виктория")
```

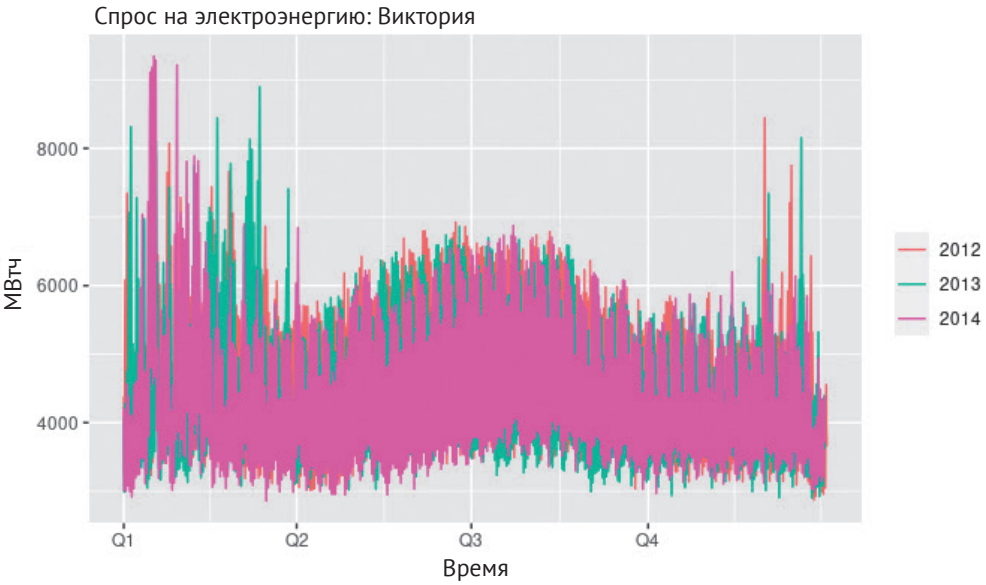


**Рисунок 2.7:** Сезонный график, показывающий ежегодные сезонные изменения спроса на электроэнергию в шт. Виктория

## 2.5 Графики сезонных подрядов

Альтернативный график, который подчеркивает сезонные закономерности, строится, когда данные каждого сезона собираются вместе в отдельные мини-графики времени.

```
a10 %>%
  gg_subseries(Cost) +
  labs(
    y = "$ (млн)",
    title = "Продажи противодиабетических препаратов в Австралии"
  )
```

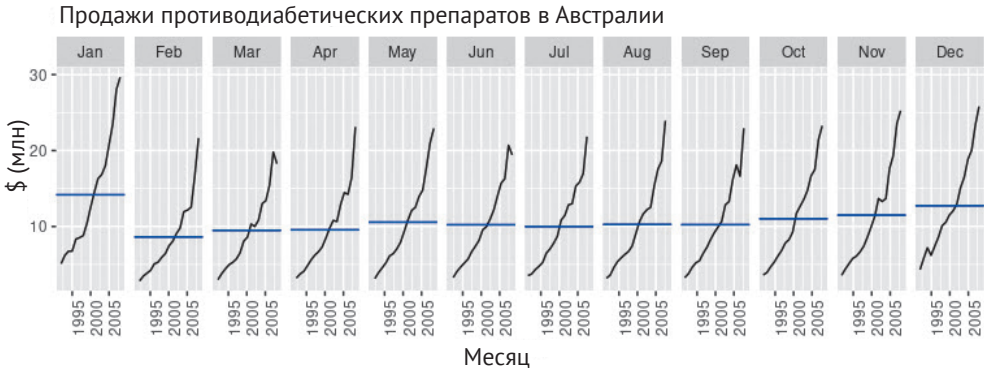


**Рисунок 2.8:** График сезонных подрядов ежемесячных продаж противодиабетических препаратов в Австралии

Синие горизонтальные линии указывают средние значения за каждый месяц. Такая форма графика позволяет четко видеть опорную сезонную закономерность, а также показывает изменения сезонности с течением времени. Это особенно полезно при выявлении изменений в течение тех или иных сезонов. В данном примере график не особенно показателен; но в некоторых случаях он представляет собой наиболее полезный способ просмотра сезонных изменений с течением времени.

### Пример: туристический отдых в Австралии

Ежеквартальные данные о праздничных днях в Австралии представляют собой интересный пример того, как эти графики могут раскрывать информацию. Сначала необходимо извлечь релевантные данные из `twibble`-объекта `tourism`. Применимы все обычные глаголы tidyverse, используемые для упорядочивания данных. В целях получения суммарного числа ночей, проведенных посетителями в праздничные дни по штатам за каждый квартал (т. е. без учета регионов), можно использовать следующий ниже исходный код. Обратите внимание, что группировать по индексу времени в явной форме, как это требуется в `twiddle`, не нужно.

```
holidays <- tourism %>%
  filter(Purpose == "Holiday") %>%
  group_by(State) %>%
```

```
  summarise(Trips = sum(Trips))
holidays
#> # A tsibble: 640 x 3 [1Q]
#> # Key:       State [8]
#>    State Quarter Trips
#>    <chr>   <qtr> <dbl>
#>  1 ACT   1998 Q1  196.
#>  2 ACT   1998 Q2  127.
#>  3 ACT   1998 Q3  111.
#>  4 ACT   1998 Q4  170.
#>  5 ACT   1999 Q1  108.
#>  6 ACT   1999 Q2  125.
#>  7 ACT   1999 Q3  178.
#>  8 ACT   1999 Q4  218.
#>  9 ACT   2000 Q1  158.
#> 10 ACT   2000 Q2  155.
#> # … и еще 630 строк
```

Графики времени по каждому ряду показывают, что в большинстве штатов существует сильная сезонность, но сезонные пики не совпадают.

```
autoplot(holidays, Trips) +
  labs(y = "Поездки с ночевкой (тыс.)",
       title = "Внутренние праздничные дни в Австралии")
```

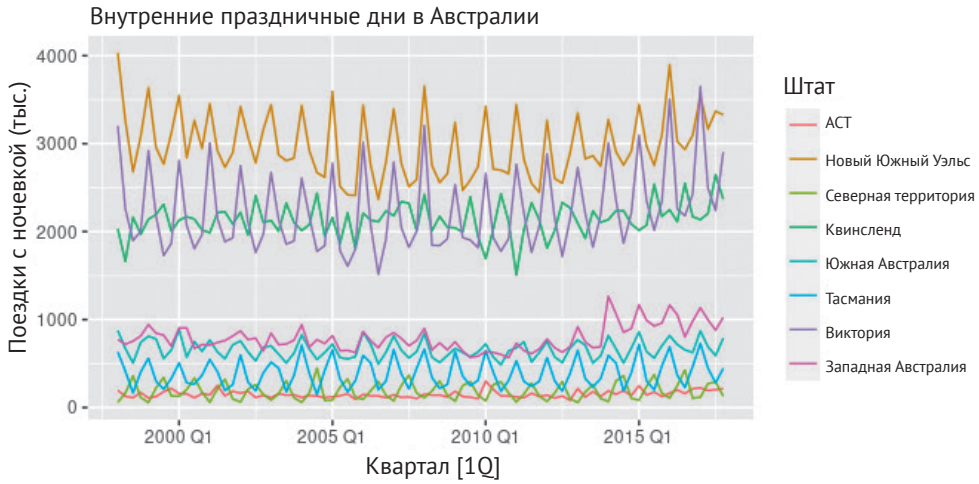


**Рисунок 2.9:** Графики времени по внутренним праздничным дням в Австралии в разбивке по штатам

Для того чтобы увидеть время сезонных пиков в каждом штате, можно использовать график сезона. По рис. 2.10 видно, что в южных штатах Австралии (Тасмания, Виктория и Южная Австралия) наблюдается самый высокий

уровень туризма в первом квартале (лето), в то время как в северных штатах (Квинсленд и Северная территория) самый высокий уровень туризма наблюдается в третьем квартале (сухой сезон).

```
gg_season(holidays, Trips) +
  labs(y = "Поездки с ночевкой (тыс.)",
       title = "Внутренние праздничные дни в Австралии")
```

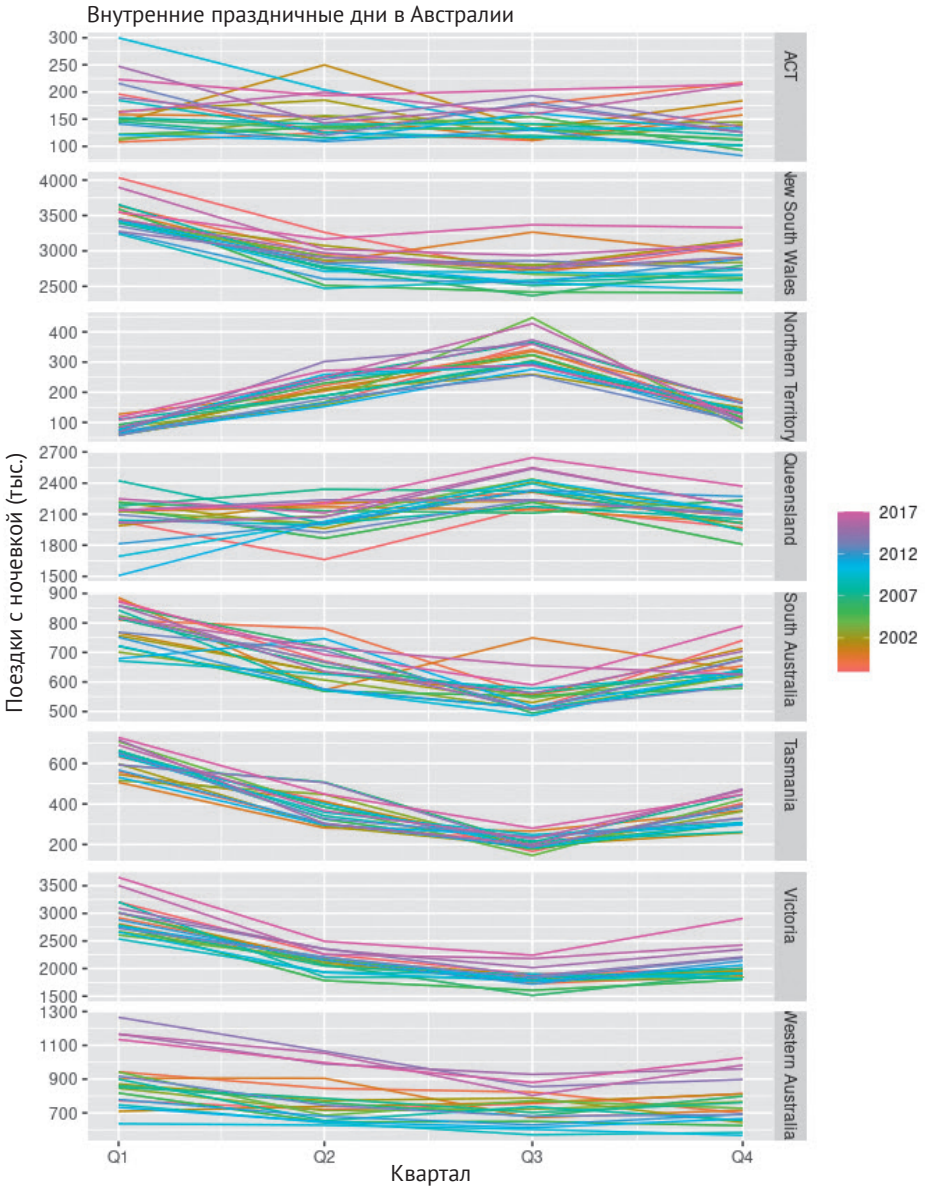


**Рисунок 2.10:** Сезонные графики внутренних праздничных дней Австралии в разбивке по штатам

Соответствующие графики подрядов показаны на рис. 2.11.

```
holidays %>%
  gg_subseries(Trips) +
  labs(y = "Поездки с ночевкой (тыс.)",
       title = "Внутренние праздничные дни в Австралии")
```

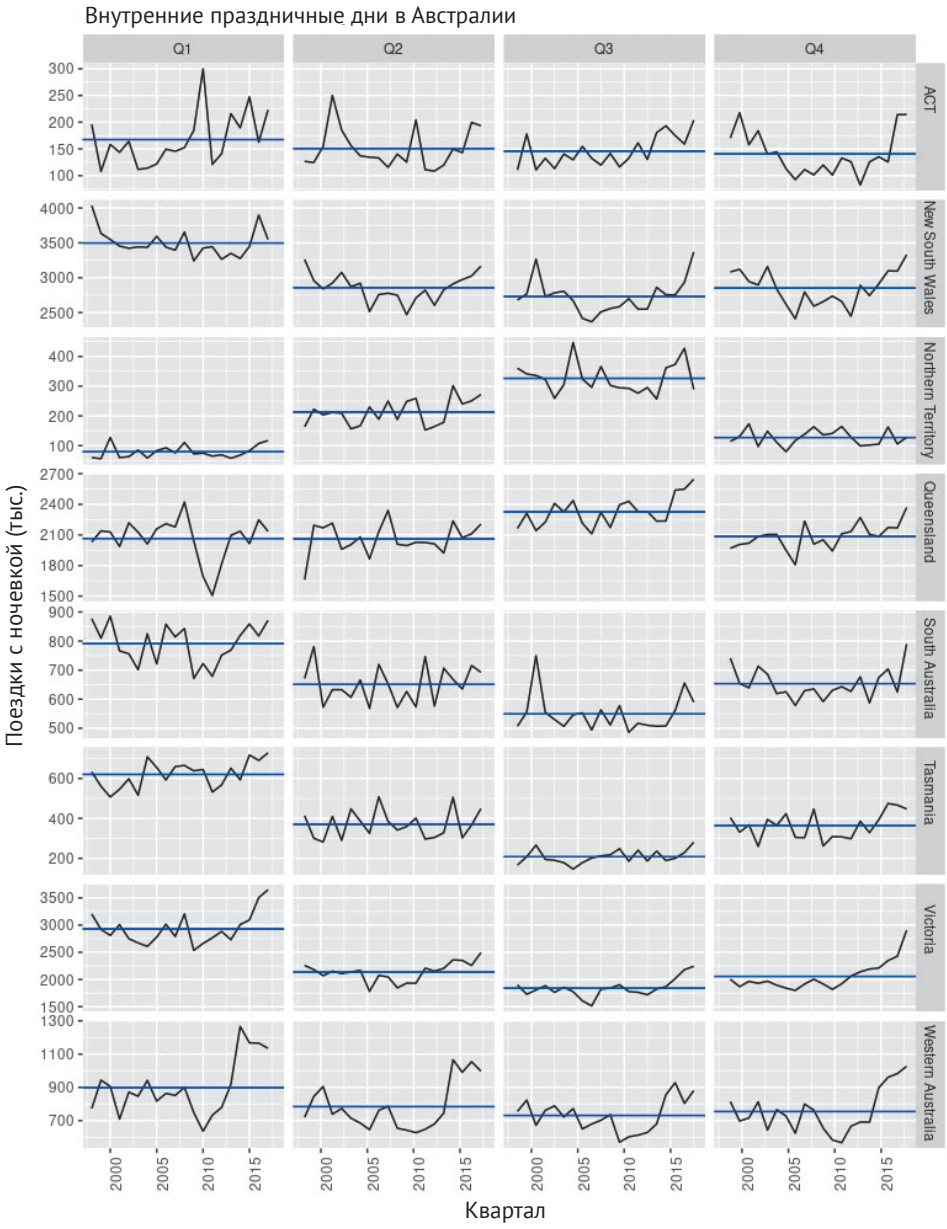


**Рисунок 2.11:** Графики подрядов внутренних праздничных дней в Австралии в разбивке по штатам

Приведенный выше рисунок показывает, что в последние годы туризм в Западной Австралии заметно вырос, в то время как туризм в шт. Виктория увеличивался в 1-м и 4-м кварталах, но не в середине года.

## 2.6 Диаграммы рассеяния

Рассмотренные до этого графики широко применяются для визуализирования индивидуальных временных рядов. Также бывает полезно исследовать взаимосвязи между временными рядами.

На рис. 2.12 и 2.13 показаны два временных ряда: получасовой спрос на электроэнергию (в гигаваттах) и температура (в градусах Цельсия) за 2014 год в шт. Виктория, Австралия. Температуры указаны для Мельбурна, крупнейшего города штата Виктория, в то время как значения спроса указаны для всего штата.

```
vic_elec %>%
  filter(year(Time) == 2014) %>%
  autoplot(Demand) +
  labs(y = "ГВт",
       title = "Получасовой спрос на электроэнергию: Виктория")
```

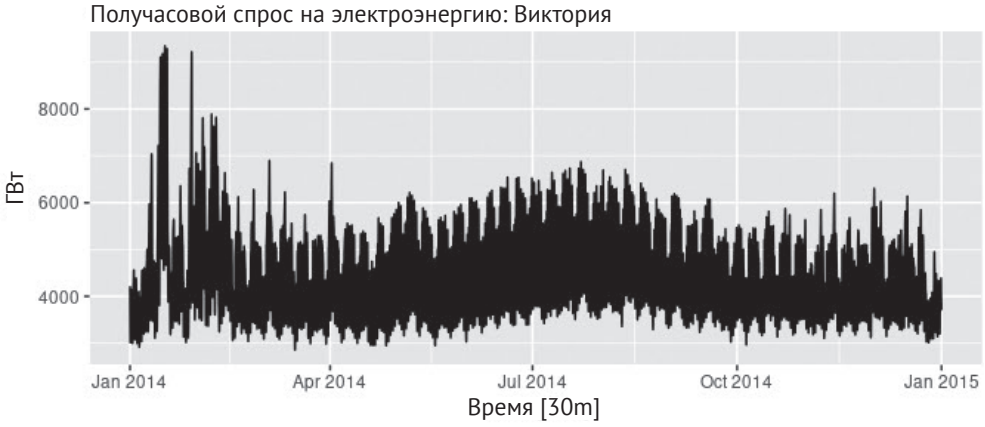


**Рисунок 2.12:** Получасовой спрос на электроэнергию в шт. Виктория, Австралия, в 2014 году

```
vic_elec %>%
  filter(year(Time) == 2014) %>%
  autoplot(Temperature) +
  labs(
    y = "Градусы Цельсия",
    title = "Получасовые температуры: Мельбурн, Австралия"
  )
```

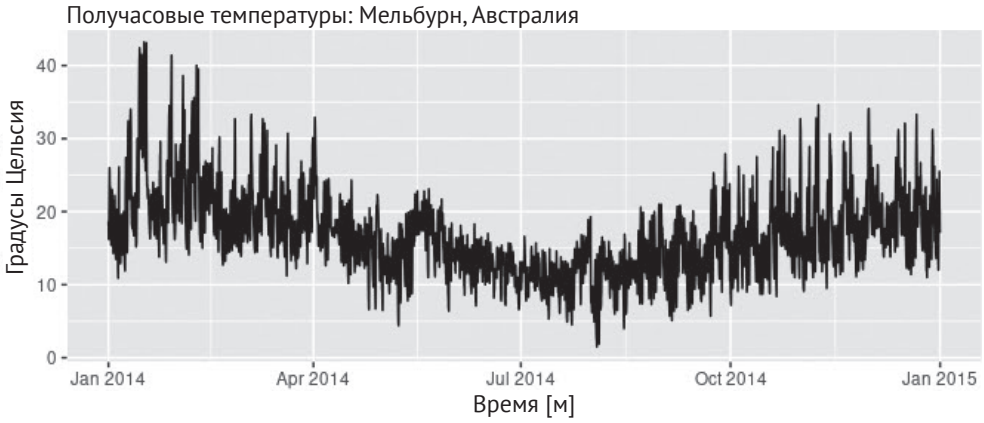


**Рисунок 2.13:** Получасовая температура в Мельбурне, Австралия, за 2014 год

Взаимосвязь между спросом и температурой можно изучить, сопоставив один ряд с другим.

```
vic_elec %>%
  filter(year(Time) == 2014) %>%
  ggplot(aes(x = Temperature, y = Demand)) +
  geom_point() +
  labs(x = "Температура (градусы Цельсия)",
       y = "Спрос на электроэнергию (ГВт)")
```

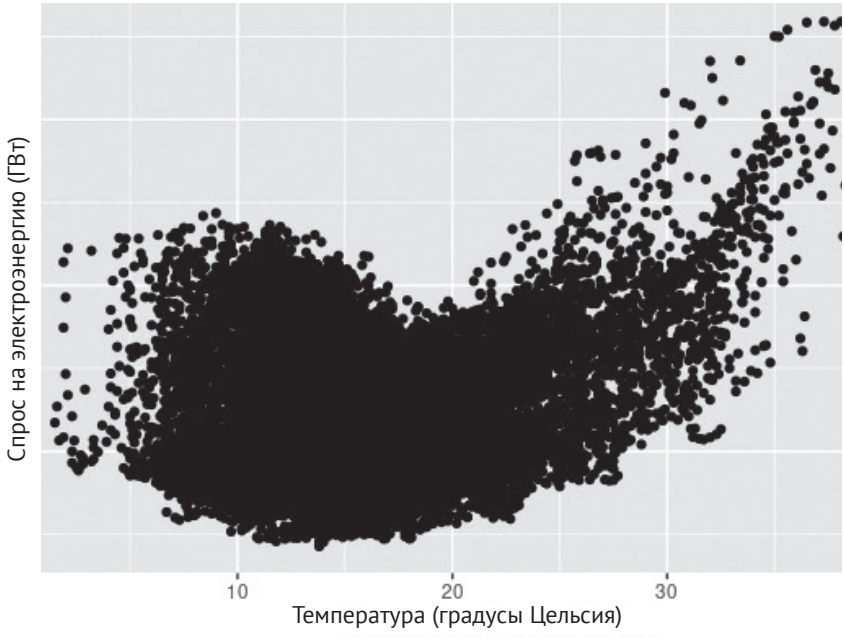


**Рисунок 2.14:** График получасового спроса на электроэнергию в сопоставлении с температурой в 2014 году в шт. Виктория, Австралия

Эта диаграмма рассеяния помогает нам визуализировать взаимосвязь между переменными. Понятно, что высокий спрос возникает при высоких температурах из-за эффекта кондиционирования воздуха. Но существует также эффект отопления, когда спрос возрастает при очень низких температурах.

## Корреляция

Для измерения силы линейной взаимосвязи между двумя переменными обычно вычисляются *коэффициенты корреляции*. Корреляция между переменными x и y задается формулой

$$r = \frac{\sum\left(x_t - \bar{x}\right)\left(y_t - \bar{y}\right)}{\sqrt{\sum(x_t - \bar{x})^2}\sqrt{\sum(y_t - \bar{y})^2}}.$$

Значение $r$ всегда находится между −1 и 1, при этом отрицательные значения указывают на отрицательную взаимосвязь, а положительные – на положительную взаимосвязь. Графики на рис. 2.15 показывают примеры наборов данных с разными уровнями корреляции.

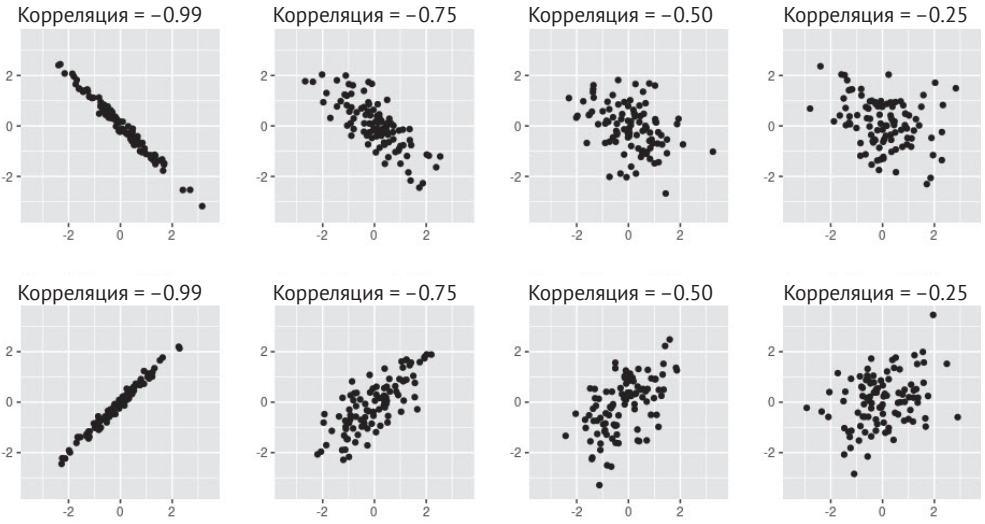


**Рисунок 2.15:** Примеры наборов данных с разными уровнями корреляции

Коэффициент корреляции измеряет силу только линейной взаимосвязи между двумя переменными и иногда может дезориентировать. Например, корреляция для данных потребления электроэнергии и температуры, показанных на рис. 2.14, составляет 0.28, но нелинейная взаимосвязь сильнее, чем эта.

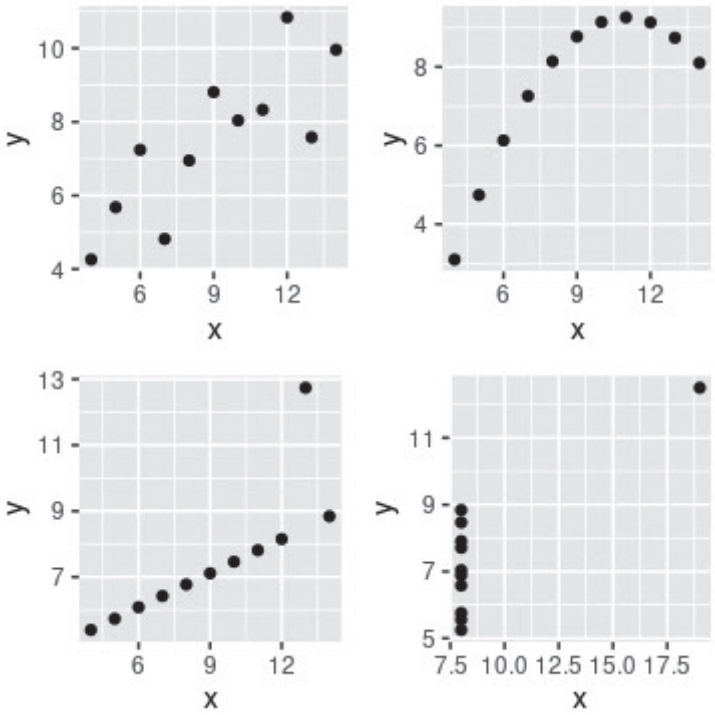


**Рисунок 2.16:** Все приведенные выше графики имеют коэффициент корреляции 0.82. Данные Anscombe (1973)

Все графики на рис. 2.16 имеют коэффициенты корреляции 0.82, но у них очень разные взаимосвязи. Это показывает, насколько важно смотреть на графики данных, а не просто полагаться на значения корреляции.

## Матрицы диаграмм рассеяния

Когда имеется несколько потенциальных предсказательных переменных, полезно сопоставить каждую переменную с каждой другой переменной. Возьмем восемь временных рядов, показанных на рис. 2.17, демонстрирующих квартальное число посетителей по штатам и территориям Австралии.

```
visitors <- tourism %>%
  group_by(State) %>%
  summarise(Trips = sum(Trips))
visitors %>%
  ggplot(aes(x = Quarter, y = Trips)) +
  geom_line() +
  facet_grid(vars(State), scales = "free_y") +
  labs(title = "Австралийский внутренний туризм",
       y= "Поездки с ночевкой (тыс.)")
```

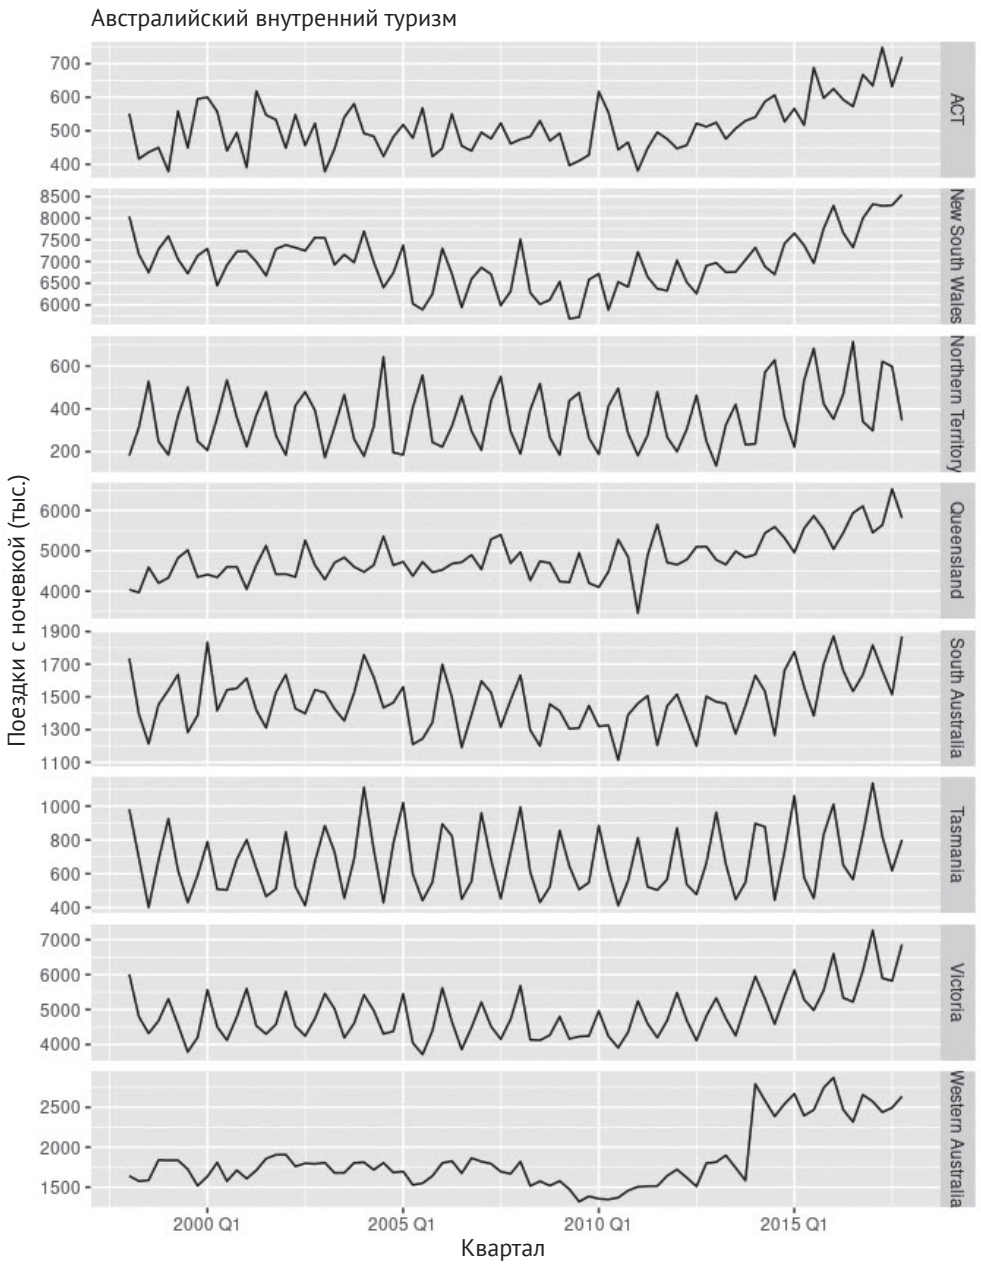


**Рисунок 2.17:** Ежеквартальные гостевые ночи по штатам и территориям Австралии

Для того чтобы увидеть взаимосвязи между приведенными выше восемью временными рядами, можно сопоставить каждый временной ряд с другими. Эти графики можно организовать в матрицу диаграмм рассеяния, как показано на рис. 2.18. (Для получения этого графика требуется установить пакет `GGally`.)

```
visitors %>%
  pivot_wider(values_from=Trips, names_from=State) %>%
  GGally::ggpairs(columns = 2:9)
```

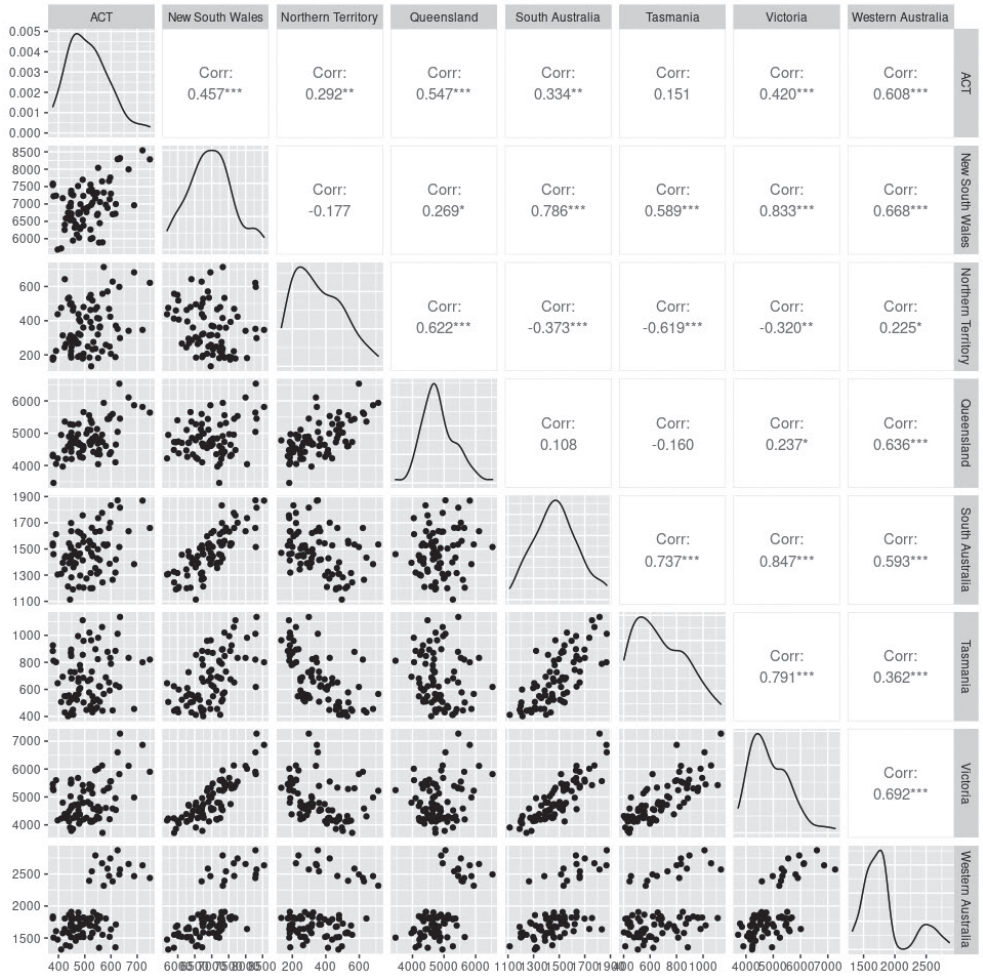


**Рисунок 2.18:** Матрица диаграмм рассеяния для ежеквартальных посещений в штатах и территориях Австралии

По каждой панели переменная на вертикальной оси задается именем переменной в этой строке, а переменная на горизонтальной оси задается именем переменной в этом столбце. Есть несколько опций построения разных графиков внутри каждой панели. В используемой по умолчанию версии корреляции показаны в верхней правой половине графика, в то время как диаграммы рассеяния показаны в нижней половине. По диагонали показаны графики плотности.

Ценность матрицы диаграмм рассеяния заключается в том, что она позволяет быстро просматривать взаимосвязи между всеми парами переменных. В данном примере выявляются в основном положительные взаимосвязи, причем самые сильные взаимосвязи существуют между соседними штатами, расположенными на южном и юго-восточном побережье Австралии, а именно Новым Южным Уэльсом, Викторией и Южной Австралией. Также выявлены некоторые отрицательные взаимосвязи между Северной территорией и другими регионами. Северная территория расположена на севере Австралии и славится своими пустынными пейзажами, посещаемыми в основном зимой. Следовательно, пик посещаемости Северной территории приходится на июльский (зимний) квартал, в отличие от январского (летнего) квартала у остальных регионов.

## Библиография

*Энскомб, Ф. Дж.* (1973). Графики в статистическом анализе. The American Statistician, 27 (1), 17–21. [DOI: https://doi.org/10.1080/00031305.1973.10478966].

# 2.7 Графики лагов

На рис. 2.19 показаны диаграммы рассеяния для квартального производства пива в Австралии (представлены на рис. 1.1), где горизонтальная ось показывает сдвинутые во времени значения (или *лаги*) временных рядов. Каждый график показывает $y_t$, нанесенный на график относительно $y_{t-k}$ для разных значений $k$.

```
recent_production <- aus_production %>%
  filter(year(Quarter) >= 2000)
recent_production %>%
  gg_lag(Beer, geom = "point") +
  labs(x = "lag(Beer, k)")
```

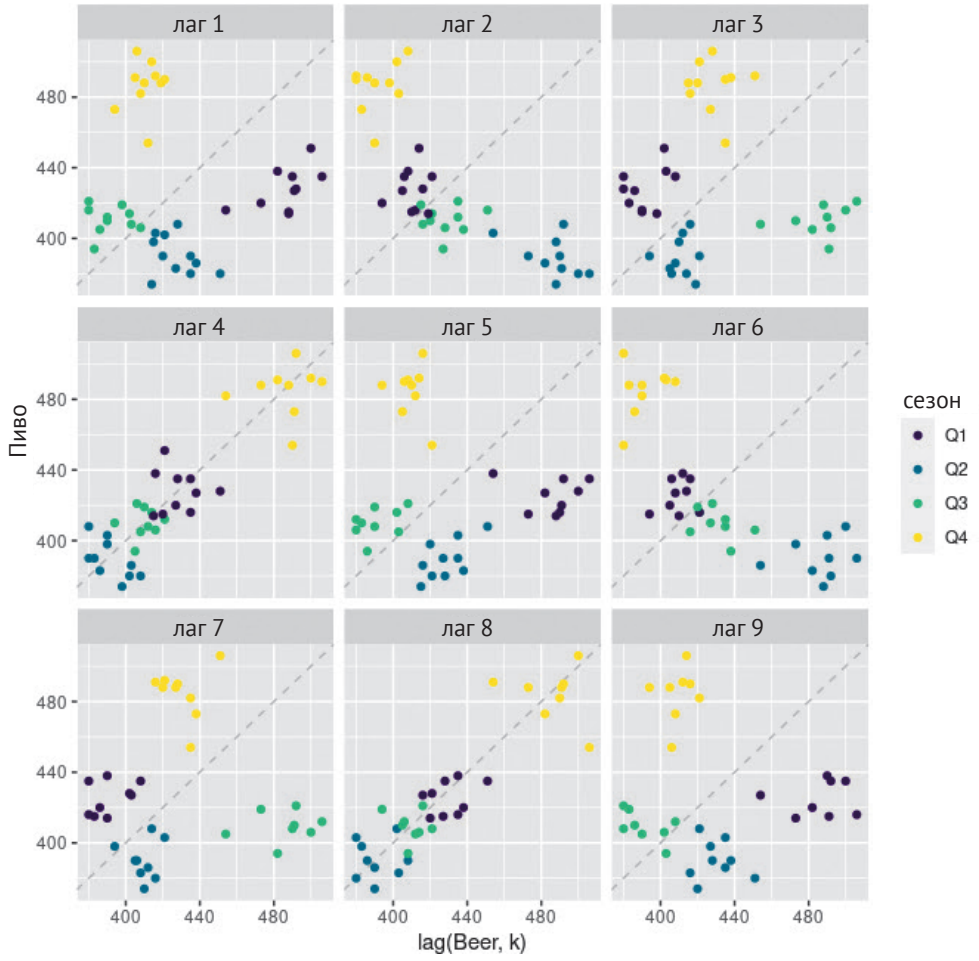


**Рисунок 2.19:** Диаграммы рассеяния с лагом (со сдвигом времени) для квартального производства пива

Здесь цвета указывают четверть переменной на вертикальной оси. Взаимосвязь сильно положительна в лагах 4 и 8, что отражает сильную сезонность в данных. Отрицательная взаимосвязь, наблюдаемая для (лагов) 2 и 6, возникает из-за того, что пики (в 4-м квартале) выводятся на графике в сопоставлении с впадинами (во 2-м квартале).

## 2.8 Автокорреляция

Как уже упоминалось, корреляция измеряет степень линейной взаимосвязи между двумя переменными. В отличие от нее, автокорреляция измеряет линейную взаимосвязь между *лагами* временного ряда.

Каждой панели на графике лагов соответствует несколько коэффициентов автокорреляции. Например, $r_1$ измеряет взаимосвязь между $y_t$ и $y_{t-1}$, $r_2$ измеряет взаимосвязь между $y_t$ и $y_{t-2}$ и т. д.

Значение $r_k$ можно записать как

$$r_k = \frac{\sum_{t=k+1}^{T}(y_t - \bar{y})(y_{t-k} - \bar{y})}{\sum_{t=1}^{T}(y_t - \bar{y})^2},$$

где $T$ – это длина временного ряда. Коэффициенты автокорреляции составляют функцию автокорреляции, или ACF, от англ. autocorrelation function.

Коэффициенты автокорреляции для данных о производстве пива можно вычислить с помощью функции `ACF()`.

```
recent_production %>% ACF(Beer, lag_max = 9)
#> # A tsibble: 9 x 2 [1Q]
#>     lag      acf
#>   <lag>    <dbl>
#> 1    1Q -0.0530
#> 2    2Q -0.758
#> 3    3Q -0.0262
#> 4    4Q  0.802
#> 5    5Q -0.0775
#> 6    6Q -0.657
#> 7    7Q  0.00119
#> 8    8Q  0.707
#> 9    9Q -0.0888
```

Значениями в столбце `acf` являются $r_1$, ... $r_9$, которые соответствуют девяти диаграммам рассеяния на рис. 2.19. График ACF обычно строят, чтобы увидеть то, как корреляции меняются вместе с изменением лага $k$. Указанный график иногда называют *коррелограммой*.

```
recent_production %>%
  ACF(Beer) %>%
  autoplot() + labs(title="Производство пива в Австралии")
```

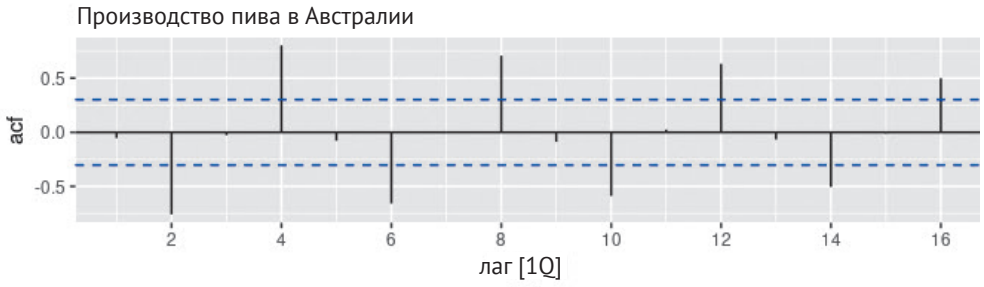


**Рисунок 2.20:** Функция автокорреляции для квартального производства пива

На этом графике:

- $r_4$ – выше, чем другие лаги. Это обусловлено сезонной закономерностью данных: пики, как правило, отстоят на расстоянии четырех кварталов друг от друга, и впадины тоже, как правило, отстоят на расстоянии четырех кварталов друг от друга;
- $r_2$ – более отрицателен, чем другие лаги, потому что впадины, как правило, отстают от пиков на две четверти;
- пунктирные синие линии указывают на то, отличаются ли корреляции значимо от нуля (как описано в разделе 2.9).

## Тренды и сезонность на ACF-графиках

Когда данные имеют тренд, автокорреляции для малых лагов, как правило, большие и положительные, потому что близкие по времени наблюдения также близки по значению. Таким образом, ACF трендового временного ряда тяготеет к тому, чтобы иметь положительные значения, которые медленно уменьшаются по мере увеличения лагов.

Когда данные являются сезонными, автокорреляции будут больше для сезонных лагов (кратных сезонному периоду), чем для других лагов.

Когда данные являются как трендовыми, так и сезонными, можно увидеть комбинацию этих эффектов. Представленные на рис. 2.2 данные `a10` показывают и тренд, и сезонность. Его ACF показан на рис. 2.21. Медленное снижение ACF по мере увеличения лагов обусловлено трендом, в то время как «зубчатая» форма обусловлена сезонностью.

```
a10 %>%
  ACF(Cost, lag_max = 48) %>%
  autoplot() +
  labs(title="Продажи противодиабетических препаратов в Австралии")
```

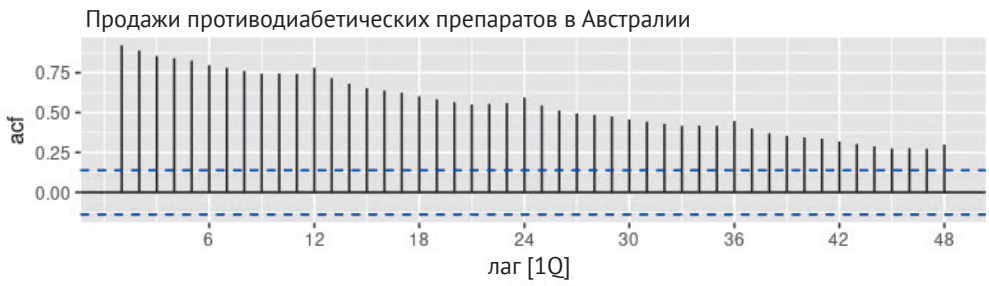


**Рисунок 2.21:** ACF ежемесячных продаж противодиабетических препаратов в Австралии

# 2.9 Белый шум

Временные ряды, которые не показывают автокорреляции, называются **белым шумом**. На рис. 2.22 приведен пример ряда белого шума.

```
set.seed(30)
y <- tsibble(sample = 1:50, wn = rnorm(50), index = sample)
y %>% autoplot(wn) + labs(title = "Белый шум", y = "")
```

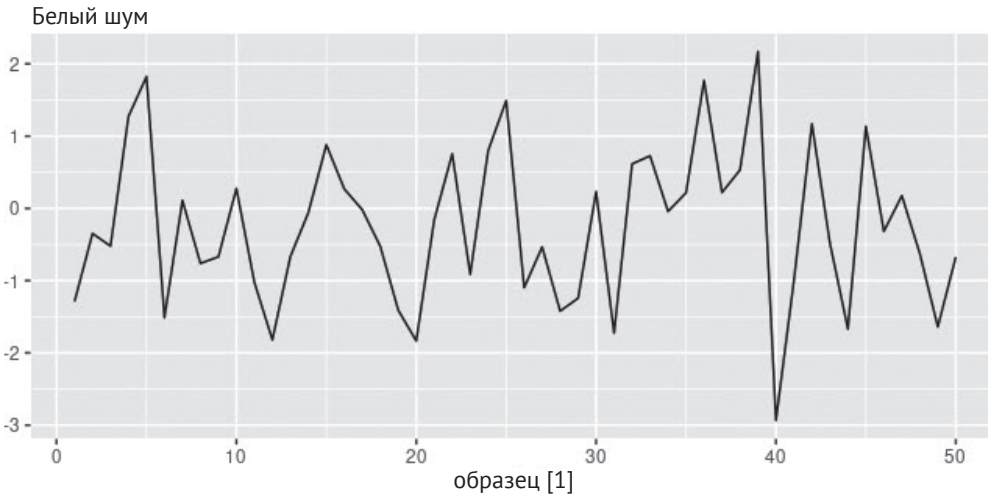


**Рисунок 2.22:** Временной ряд белого шума

```
y %>%
  ACF(wn) %>%
  autoplot() + labs(title = "Белый шум")
```

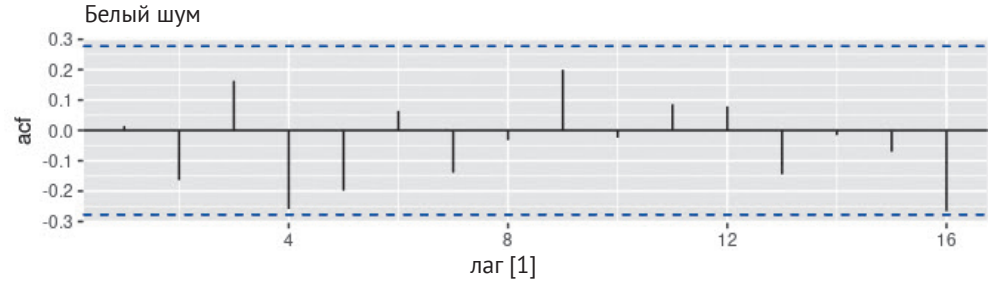


**Рисунок 2.23:** Функция автокорреляции для ряда белого шума

От рядов белого шума ожидается, что каждая автокорреляция будет близка к нулю. Разумеется, они не будут в точности равны нулю, поскольку существует некоторая случайная вариация. От ряда белого шума ожидается, что 95 % пиков в ACF будут находиться в пределах $\pm 2/\sqrt{T}$, где $T$ – это длина временного ряда. Обычно эти границы наносятся на график ACF (приведенные выше синие пунктирные линии). Если один или несколько больших всплесков находятся за пределами этих границ, или если существенно более 5 % всплесков находятся за пределами этих границ, то ряд, вероятно, не является белым шумом.

В данном примере `T = 50`, и поэтому границы находятся в $\pm 2/\sqrt{50} = \pm 0.28$. Все коэффициенты автокорреляции находятся в этих пределах, подтверждая, что данные представляют собой белый шум.

## 2.10 Упражнения

1. Используйте функцию справки, чтобы узнать, что представляют собой ряды `gafa_stock`, `PBS`, `vic_elec` и `pelt`.
   a) Используйте `autopilot()`, чтобы нанести на графики некоторые ряды в этих наборах данных.
   b) Каков временной интервал каждого ряда?
2. Используйте `filter()`, чтобы найти дни, которые соответствовали максимальной цене закрытия торгового периода для каждой из четырех акций в `gafa_stock`.
3. Скачайте файл `tute1.csv` с веб-сайта книги (*https://bit.ly/fpptute1*), откройте его в Excel (или каком-либо другом приложении для работы с электронными таблицами) и просмотрите его содержимое. Вы должны найти четыре столбца информации. Столбцы B–D содержат квартальные ряды с пометками «Sales», «AdBudget» и «GDP». Столбец Sales (Продажи) содержит квартальные продажи небольшой компании за период 1981–2005 годов. Столбец AdBudget – это рекламный бюджет, а GDP – это валовой внутренний продукт. Все ряды были скорректированы с учетом инфляции.
   a) Эти данные можно прочитать в R с помощью следующего ниже скрипта:

```
tute1 <- readr::read_csv("tute1.csv")

View(tute1)
```

   b) Конвертируйте данные во временной ряд:

```
mytimeseries <- tute1 %>%
  mutate(Quarter = yearmonth(Quarter)) %>%

  as_tsibble(index = Quarter)
```

   c) Постройте графики временных рядов для каждого из трех рядов:

```
mytimeseries %>%
  pivot_longer(-Quarter) %>%
  ggplot(aes(x = Quarter, y = value, colour = name)) +
  geom_line() +

  facet_grid(name ~ ., scales = "free_y")
```

   Проверьте, что происходит, когда вы не включаете `facet_grid()`.
4. Пакет `USgas` содержит данные о спросе на природный газ в США.
   a) Проинсталлируйте пакет `USgas`.
   b) Создайте `tsibble` из `us_total` с годом в качестве индекса и штатом в качестве ключа.
   c) Постройте график годового потребления природного газа в разбивке по штатам для территории Новой Англии (включая штаты Мэн, Вермонт, Нью-Гэмпшир, Массачусетс, Коннектикут и Род-Айленд).
5. Скачайте `tourism.xlsx` с веб-сайта книги и прочитайте его в R, используя `readxl::read_excel()`.
   a) Создайте `tsibble`, идентичный tsibble-объекту `tourism` из пакета `tsibble`.

b) Найдите сочетание `Region` и `Purpose`, которое имело в среднем максимальное число поездок с ночевкой.
c) Создайте новый `tsibble`, который комбинирует `Region` и `Purpose` и содержит только суммарное число поездок по штатам.

6. Создайте графики времени для следующих ниже четырех временных рядов: `Bricks` из `aus_production`, `Lynx` (Рысь) из `pelt`, `Close` (Закрытие) из `gafa_stock`, `Demand` (Спрос) из `vic_elec`.
   a) Используйте `?` (или `help()`), чтобы узнать о данных в каждом ряду.
   b) Для последнего графика измените метки осей и заголовок.
7. Набор данных `aus_arrivals` включает ежеквартальные международные прибытия в Австралию из Японии, Новой Зеландии, Великобритании и США.
   a) Примените `autoplot()`, `gg_season()` и `gg_subseries()`, чтобы сравнить различия между прибытиями из этих четырех стран.
   b) Сможете ли вы выделить какие-либо необычные наблюдения?
8. Ежемесячные данные по розничным продажам в Австралии представлены в `aus_retail`. Выберите один из временных рядов следующим образом (но выберите свое собственное затравочное значение):

```
set.seed(12345678)
myseries <- aus_retail %>%
  filter(`Series ID` == sample(aus_retail$`Series ID`,1))
```

   a) Разведайте выбранные вами временные ряды розничной торговли, используя следующие ниже функции:

```
autoplot(), gg_season(), gg_subseries(), gg_lag(),
ACF() %>% autoplot()
```

   b) Сможете ли вы вычленить какую-либо сезонность, цикличность и тренд? Что вы узнали об этом ряде?
9. Используйте следующие ниже графические функции: `autoplot()`, `gg_season()`, `gg_subseries()`, `gg_lag()`, `ACF()` – и разведайте признаки из следующих ниже временных рядов: «Total Private» `Employed` (Всего занятых в частном секторе) из `us_employment`, `Bricks` из `aus_production`, `Hare` (Заяц) из `pelt`, Cost (Стоимость «H02») из `PBS` и `us_gasoline`.
   a) Сможете ли вы вычленить какую-либо сезонность, цикличность и тренд?
   b) Что вы узнали об этом ряде?
   c) Что вы можете сказать о сезонных закономерностях?
   d) Сможете ли вы назвать какие-нибудь необычные годы?
10. Следующие ниже графики времени и графики ACF соответствуют четырем разным временным рядам. Ваша задача состоит в том, чтобы сопоставить каждый график времени в первой строке с одним из графиков ACF во второй строке.

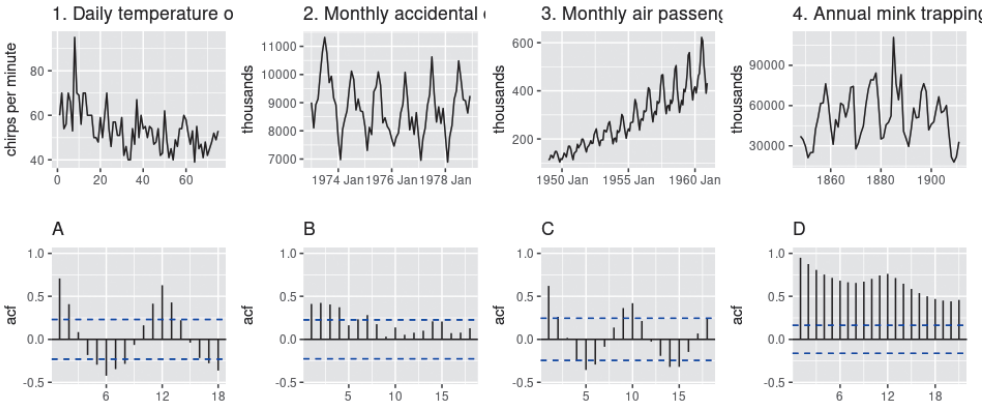


11. Данные `aus_livestock` содержат ежемесячное суммарное поголовье свиней, забитых в шт. Виктория, Австралия, с июля 1972 года по декабрь 2018 года. Примените `filter()`, чтобы извлечь данные о забое свиней в шт. Виктория в период с 1990 по 1995 год. Примените `autopilot()` и `ACF()` на этих данных. Чем они отличаются от белого шума? Если бы использовался более длительный период данных, то какое это имело бы значение для ACF?
12. 
    a) Используйте следующий ниже исходный код, чтобы вычислить ежедневные изменения цен акций Google на момент закрытия торгов.

```
dgoog <- gafa_stock %>%
  filter(Symbol == "GOOG", year(Date) >= 2018) %>%
  mutate(trading_day = row_number()) %>%
  update_tsibble(index = trading_day, regular = TRUE) %>%
  mutate(diff = difference(Close))
```

    b) Почему необходимо было переиндексировать `twibble`?
    c) Нанесите на график эти разницы и их ACF.
    d) Выглядят ли изменения цен на акции как белый шум?

## 2.11 Дальнейшее чтение

У. С. Кливленд (1993, *https://otexts.com/fpp3/graphics-reading.html#ref-Cleveland1993*) – это классическая книга о принципах визуализации для анализа данных. Хотя ей уже более 20 лет, ее идеи неподвластны времени.

Анвин (2015, *https://otexts.com/fpp3/graphics-reading.html#ref-Unwin2015*) – это современное введение в графический анализ данных с использованием R. В нем не так много информации о графике временных рядов, но много отличных общих рекомендаций по использованию графики для анализа данных.

## Библиография

*Кливленд, У. С.* (1993). Визуализация данных. Hobart Press. [Amazon, *http://buy.geni.us/Proxy.ashx?TSID=140570&GR_URL=http%3A%2F%2Fwww.amazon.com%2Fdp%2F0963488406*].

*Анвин, А.* (2015). Графический анализ данных с K. Chapman; Hall/CRC. [Amazon, *http://buy.geni.us/Proxy.ashx?TSID=140570&GR_URL=http%3A%2F%2Fwww.amazon.com%2Fdp%2F1498715230*].

# Глава 3

# Разложение временных рядов

Данные временных рядов могут демонстрировать разнообразие закономерностей, и часто бывает полезно разделить временной ряд на несколько компонент, каждая из которых представляет базовую категорию закономерностей.

В разделе 2.3 мы обсудили три типа моделей временных рядов: тренд, сезонность и циклы. Когда мы разлагаем временной ряд на компоненты, мы обычно объединяем тренд и цикл в одну **трендово-циклическую** компоненту (для простоты часто именуемую просто **трендом**). Таким образом, временной ряд можно рассматривать как состоящий из трех компонент: трендово-циклической компоненты, сезонной компоненты и компоненты остатка (содержащей что-либо еще во временном ряду). В некоторых временных рядах (например, тех, которые наблюдаются по меньшей мере ежедневно) может быть более одной сезонной компоненты, соответствующей разным сезонным периодам.

В данной главе мы рассмотрим наиболее распространенные методы извлечения указанных компонент из временного ряда. Нередко это делается для улучшения понимания временных рядов, но также используется для повышения прогнозной точности.

При разложении временного ряда иногда полезно сначала преобразовывать или корректировать ряд, чтобы делать процесс разложения (и последующего анализа) максимально простым. Итак, мы начнем с обсуждения темы преобразований и корректировок.

## 3.1 Преобразования и корректировки

Корректировка исторических данных нередко может приводить к упрощению временных рядов. Здесь мы имеем дело с четырьмя видами корректировок: календарная корректировка, корректировка по численности населения, корректировка на инфляцию и математические преобразования. Цель этих корректировок и преобразований состоит в том, чтобы упростить закономерности в исторических данных, удалив известные источники вариации или сделав закономерность более согласованной во всем наборе данных. Более простые закономерности обычно легче моделировать, и приводят они к более точным прогнозам.

### Календарные корректировки

Некоторая вариация, наблюдаемая в сезонных данных, может быть вызвана простыми календарными эффектами. В таких случаях обычно гораздо проще вариацию удалять, прежде чем проводить какой-либо дальнейший анализ.

Например, если вы изучаете суммарный объем месячных продаж в розничном магазине, то будет иметься вариация между месяцами просто из-за разного числа торговых дней в каждом месяце, в дополнение к сезонной вариации в течение года. Указанная вариация легко устраняется путем вычисления средних продаж за торговый день в каждом месяце, а не суммарных продаж за месяц. Тогда мы эффективно удаляем календарную вариацию.

## Корректировки по численности населения

Любые данные, на которые влияют изменения численности населения, могут быть скорректированы для получения данных на душу населения. То есть следует учитывать не суммарное число, а данные на душу человека (или на тысячу человек, или на миллион человек). Например, если вы изучаете число больничных коек в конкретном регионе с течением времени, то результаты гораздо легче интерпретировать, если исключить эффекты изменений численности населения, рассматривая число коек на тысячу человек. И тогда можно будет увидеть, произошло ли реальное увеличение числа коек или это увеличение полностью связано с увеличением численности населения. Возможно, суммарное число коек увеличится, но число коек на тысячу человек уменьшится. Это происходит, когда численность населения увеличивается быстрее, чем число больничных коек. Для большинства данных, на которые влияют изменения численности населения, лучше всего использовать данные на душу населения, а не суммарные данные.

Это можно увидеть в наборе данных `global_economy`, где общепринятым преобразованием ВВП является ВВП на душу населения.

```
global_economy %>%
  filter(Country == "Australia") %>%
  autoplot(GDP/Population) +
  labs(title= "ВВП на душу населения", y = "Доллары США")
```

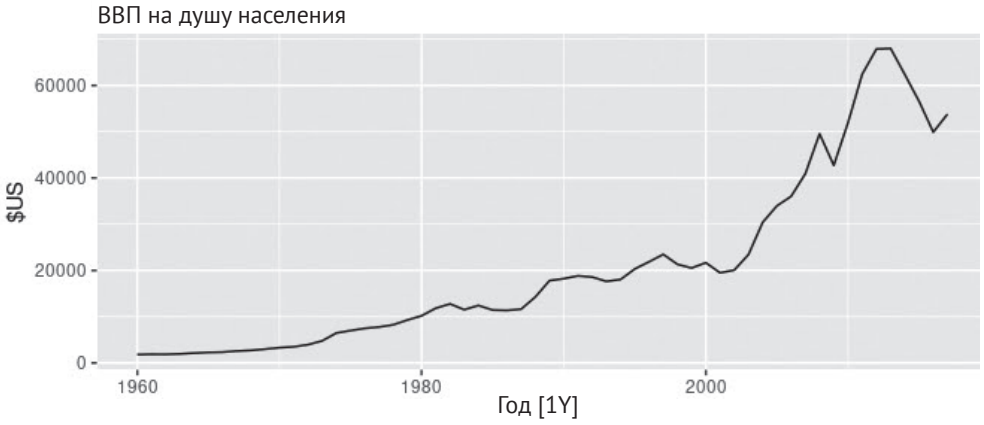


**Рисунок 3.1:** ВВП Австралии на душу населения

## Корректировки на инфляцию

Данные, на которые влияет стоимость денег, лучше всего корректировать перед моделированием. Например, средняя стоимость нового дома за последние несколько десятилетий выросла из-за инфляции. Дом стоимостью 200 000 долларов в этом году – это не то же самое, что дом стоимостью 200 000 долларов двадцать лет назад. По этой причине финансовые временные ряды обычно корректируются таким образом, чтобы все значения указывались в долларах за определенный год. Например, данные о ценах на жилье могут быть указаны в долларах за 2000 год.

Для внесения этих корректировок используется индекс цен. Если $z_t$ обозначает индекс цен, а $y_t$ обозначает первоначальную цену дома в год $t$, тогда $x_t = y_t / z_t * z_{2000}$ дает скорректированную цену дома в долларовом эквиваленте 2000 года. Индексы цен часто составляются правительственными учреждениями. Для потребительских товаров общим индексом цен является Индекс потребительских цен (или ИПЦ).

Это позволяет сравнивать рост или спад отраслей по отношению к общему ценовому значению. Например, анализ совокупного годового оборота розничной торговли «газетами и книгами» из `aus_retail` и корректировка данных с учетом инфляции с использованием индекса потребительских цен из `global_economy` позволяет понимать изменения с течением времени.

```
print_retail <- aus_retail %>%
  filter(Industry == "Newspaper and book retailing") %>%
  group_by(Industry) %>%
  index_by(Year = year(Month)) %>%
  summarise(Turnover = sum(Turnover))
aus_economy <- global_economy %>%
  filter(Code == "AUS")
print_retail %>%
  left_join(aus_economy, by = "Year") %>%
  mutate(Adjusted_turnover = Turnover / CPI * 100) %>%
  pivot_longer(c(Turnover, Adjusted_turnover),
               values_to = "Turnover") %>%
  mutate(name = factor(name,
         levels=c("Turnover","Adjusted_turnover"))) %>%
  ggplot(aes(x = Year, y = Turnover)) +
  geom_line() +
  facet_grid(name ~ ., scales = "free_y") +
  labs(title = "Оборот: австралийская индустрия печатных СМИ",
       y = "Австралийский доллар")
```

**Рисунок 3.2:** Оборот австралийской индустрии печатных СМИ в австралийских долларах. «Скорректированный» оборот был скорректирован на инфляцию с использованием индекса потребительских цен

Сделав поправку на инфляцию с использованием индекса потребительских цен, можном увидеть, что австралийская индустрия розничной торговли газетами и книгами находится в состоянии спада гораздо дольше, чем предполагают первоначальные данные. Скорректированный оборот указан в австралийских долларах 2010 года, поскольку индекс потребительских цен в 2010 году в этом наборе данных равен 100.

## Математические преобразования

Если данные показывают вариации, которые увеличиваются или уменьшаются с уровнем ряда, то преобразование бывает полезным. Например, часто бывает полезно логарифмическое преобразование. Если обозначить изначальные наблюдения как $y_1, \ldots y_T$ и преобразованные наблюдения как $w_1, \ldots w_T$, то $w_1 = \log(y_t)$. Логарифмы полезны тем, что они поддаются интерпретации: изменения в логарифмическом значении представляют собой относительные (или процентные) изменения в изначальной шкале. Так, если используется логарифмическое основание 10, то увеличение на 1 в логарифмической шкале соответствует умножению на 10 в изначальной шкале. Если какое-либо значение изначального ряда равно нулю либо отрицательно, то логарифмирование невозможно.

Иногда используются и другие преобразования (хотя они не так интерпретируемы). Например, можно использовать квадратные и кубические корни. Они называются **степенными преобразованиями**, потому что их можно записать в форме $w_t = y_t^p$.

Полезным семейством преобразований, включающим как логарифмические, так и степенные преобразования, является семейство преобразований Бокса–

Кокса (Бокс и Кокс, 1964, *https://otexts.com/fpp3/transformations.html#ref-BC64*), которые зависят от параметра $\lambda$ и определяются следующим образом:

$$w_t = \begin{cases} \log(y_t) & \text{если } \lambda = 0; \\ (\text{sign}(y_t)\,|y_t|^{\lambda} - 1)/\lambda & \text{в противном случае.} \end{cases} \tag{3.1}$$

На самом деле это модифицированное преобразование Бокса–Кокса, обсуждаемое в Бикель и Доксум (1981), которое допускает отрицательные значения $y_t$ при условии $\lambda > 0$.

Логарифм в преобразовании Бокса–Кокса всегда является натуральным логарифмом (т. е. по основанию *e*). Так что если $\lambda = 0$, то используются натуральные логарифмы, но если $\lambda \neq 0$, то используется степенное преобразование, за которым следует некоторое простое шкалирование.

Если $\lambda > 1$, тогда $w_t = y_t - 1$, таким образом, преобразованные данные смещаются вниз, но форма временного ряда не изменяется. Для всех остальных значений $\lambda$ временной ряд будет изменять форму.

Используйте расположенный ниже ползунок[1], чтобы увидеть эффект варьирования $\lambda$ на преобразовывание квартальной добычи газа в Австралии:

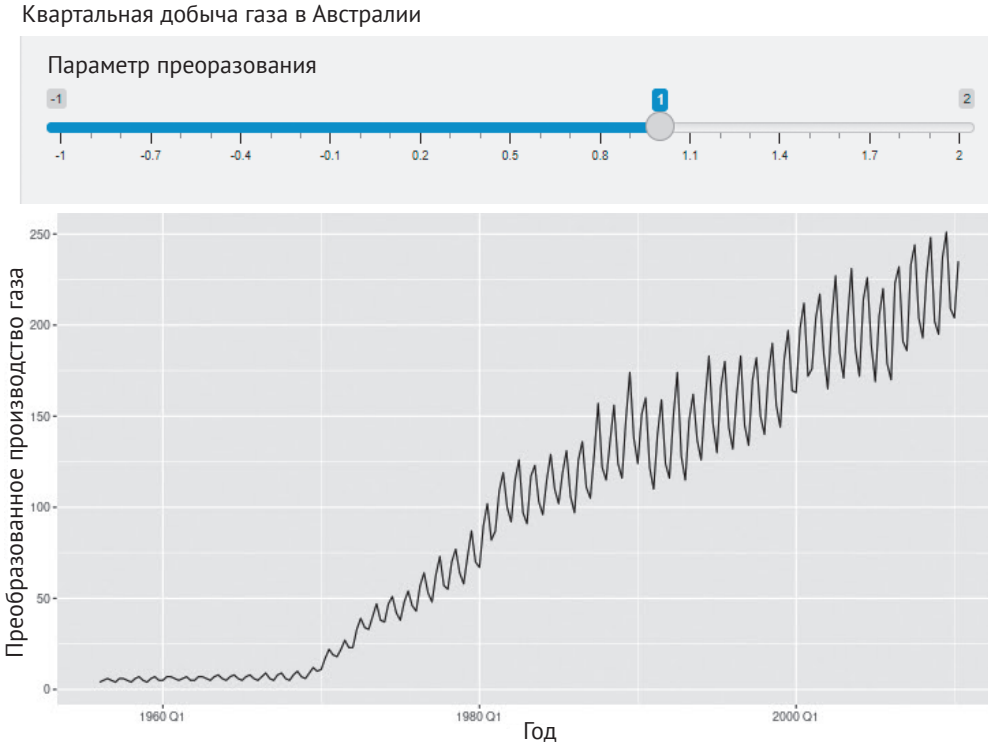


**Рисунок 3.3:** Преобразования Бокса–Кокса применительно к квартальной добыче газа в Австралии

[1] В онлайновой версии данной книги величину можно задавать динамически. – *Прим. перев.*

Хорошее значение $\lambda$ – это то, которое делает размер сезонной вариации примерно одинаковым для всего ряда, поскольку это упрощает модель прогнозирования. В данном случае $\lambda = 0.10$ работает довольно хорошо, хотя любое значение $\lambda$ в диапазоне от 0.0 до 0.2 будет давать аналогичные результаты.

Для автоматического выбора значения лямбды можно воспользоваться функцией `guerrero` (Герреро, 1993, *https://otexts.com/fpp3/transformations.html#ref-Guerrero93*). В этом случае она выбирает `λ=0.12`. (См. следующую далее главу, где обсуждается применение функции `features()`.)

```
lambda <- aus_production %>%
  features(Gas, features = guerrero) %>%
  pull(lambda_guerrero)
aus_production %>%
  autoplot(box_cox(Gas, lambda)) +
  labs(y = "",
       title = latex2exp::TeX(paste0(
         "Преобразованное производство газа с $\\lambda$ = ",
         round(lambda,2))))
```

**Рисунок 3.4:** Преобразованная квартальная добыча газа в Австралии: параметр $\lambda$ был выбран с использованием метода Герреро ($\lambda = 0.11$)

## Библиография

*Бикель, П. Дж., и Доксам, К. А.* (1981). Ревизия анализа преобразований. Journal of the American Statistical Association, 76 (374), 296–311. [DOI: https://doi.org/10.1080/01621459.1981.10477649].

*Бокс, Дж. Е. П. и Кокс, Д. Р.* (1964). Анализ преобразований. Journal of the Royal Statistical Society. Series B, Statistical Methodology, 26 (2), 211–252. [DOI: https://doi.org/10.1111/j.2517-6161.1964.tb00553.x].

*Герреро, В. М.* (1993). Анализ временных рядов, поддерживаемый степенными преобразованиями. Journal of Forecasting, 12 (1), 37–48. [DOI: https://doi.org/10.1002/for.3980120104].

## 3.2 Компоненты временных рядов

Если исходить из аддитивного разложения, то можно записать

$$y_t = S_t + T_t + R_t,$$

где $y_t$ – это данные, $S_t$ – сезонная компонента, $T_t$ – трендово-циклическая компонента и $R_t$ — компонента остатка, все в период $t$. В качестве альтернативы мультипликативное разложение можно было бы записать как

$$y_t = S_t \times T_t \times R_t.$$

Аддитивное разложение подходит больше всего, если магнитуда сезонных колебаний или вариаций вокруг тренда-цикла не варьируется вместе с уровнем временного ряда. Когда вариация сезонной закономерности или вариация вокруг тренда-цикла, по-видимому, пропорциональна уровню временного ряда, тогда больше всего подходит мультипликативное разложение. Мультипликативные разложения широко применяются для экономических временных рядов.

Альтернативой использованию мультипликативного разложения является сначала преобразовывание данных до тех пор, пока вариация в ряду не станет стабильной с течением времени, а затем использование аддитивного разложения. Когда используется логарифмическое преобразование, это эквивалентно применению мультипликативного разложения, поскольку

$$y_t = S_t \times T_t \times R_t \text{ эквивалентно } \log y_t = \log S_t + \log T_t + \log R_t.$$

### Пример: занятость в секторе розничной торговли США

Мы рассмотрим несколько методов получения компонентов $S_t$, $T_t$ и $R_t$ позже в данной главе, но сначала полезно посмотреть пример. Мы разложим число лиц, занятых в розничной торговле, как показано на рис. 3.5. Данные показывают суммарную ежемесячную численность человек в тысячах, занятых в секторе розничной торговли по всей территории США с 1990 года.

```
us_retail_employment <- us_employment %>%
  filter(year(Month) >= 1990, Title == "Retail Trade") %>%
  select(-Series_ID)
autoplot(us_retail_employment, Employed) +
  labs(y = "Люди (тысячи)",
       title = "Суммарная занятость в розничной торговле США")
```

**Рисунок 3.5:** Суммарная численность лиц, занятых в розничной торговле США

Для того чтобы проиллюстрировать идеи, мы будем использовать метод STL-разложения, который обсуждается в разделе 3.6.

```
dcmp <- us_retail_employment %>%
  model(stl = STL(Employed))
components(dcmp)
#> # A dable: 357 x 7 [1M]
#> # Key:     .model [1]
#> # :        Employed = trend + season_year + remainder
#>    .model    Month Employed  trend season_year remainder season_adjust
#>    <chr>     <mth>    <dbl>  <dbl>       <dbl>     <dbl>         <dbl>
#>  1 stl    1990 Jan   13256. 13288.      -33.0      0.836        13289.
#>  2 stl    1990 Feb   12966. 13269.     -258.      -44.6          13224.
#>  3 stl    1990 Mar   12938. 13250.     -290.      -22.1          13228.
#>  4 stl    1990 Apr   13012. 13231.     -220.       1.05          13232.
#>  5 stl    1990 May   13108. 13211.     -114.      11.3           13223.
#>  6 stl    1990 Jun   13183. 13192.      -24.3     15.5           13207.
#>  7 stl    1990 Jul   13170. 13172.      -23.2     21.6           13193.
#>  8 stl    1990 Aug   13160. 13151.       -9.52    17.8           13169.
#>  9 stl    1990 Sep   13113. 13131.      -39.5     22.0           13153.
#> 10 stl    1990 Oct   13185. 13110.       61.6     13.2           13124.
#> # … и еще 347 строк
```

В приведенной выше распечатке показаны компоненты STL-разложения. Приведены изначальные данные (в том виде, в каком они использовались), за которыми следуют оцененные компоненты. Этот результат формирует «dable», или таблицу разложения. Заголовок таблицы показывает, что используемый ряд был разложен аддитивно.

Столбец `trend` (содержащий тренд-цикл $T_t$) следует за совокупным движением ряда, игнорируя любую сезонность и случайные колебания, как показано на рис. 3.6.

```
components(dcmp) %>%
  as_tsibble() %>%
  autoplot(Employed, colour="gray") +
  geom_line(aes(y=trend), colour = "#D55E00") +
  labs(
    y = "Люди (тыс.)",
    title = "Суммарная занятость в розничной торговле США"
  )
```

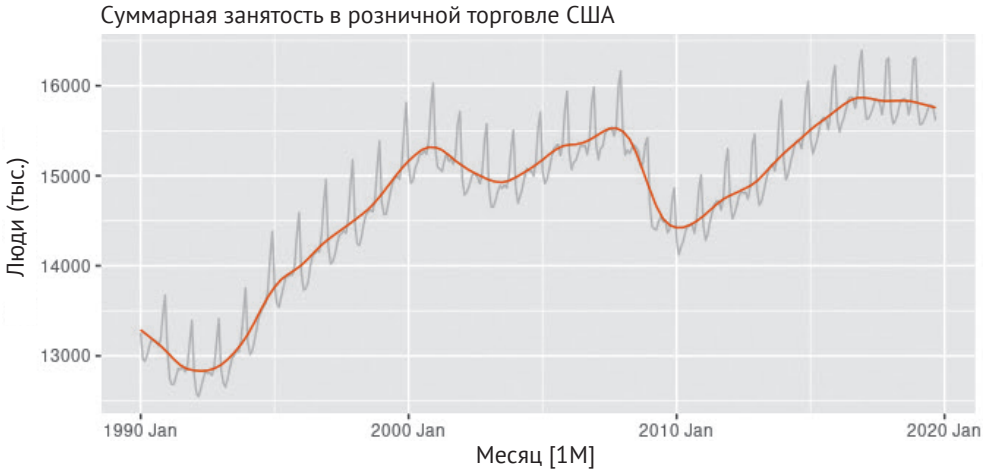


**Рисунок 3.6:** Суммарная численность занятых в розничной торговле США: трендово-циклическая компонента (оранжевый) и изначальные данные (серый)

Все компоненты можно показать на одном графике с помощью функции `autoplot()`, как видно на рис. 3.7.

```
components(dcmp) %>% autoplot()
```

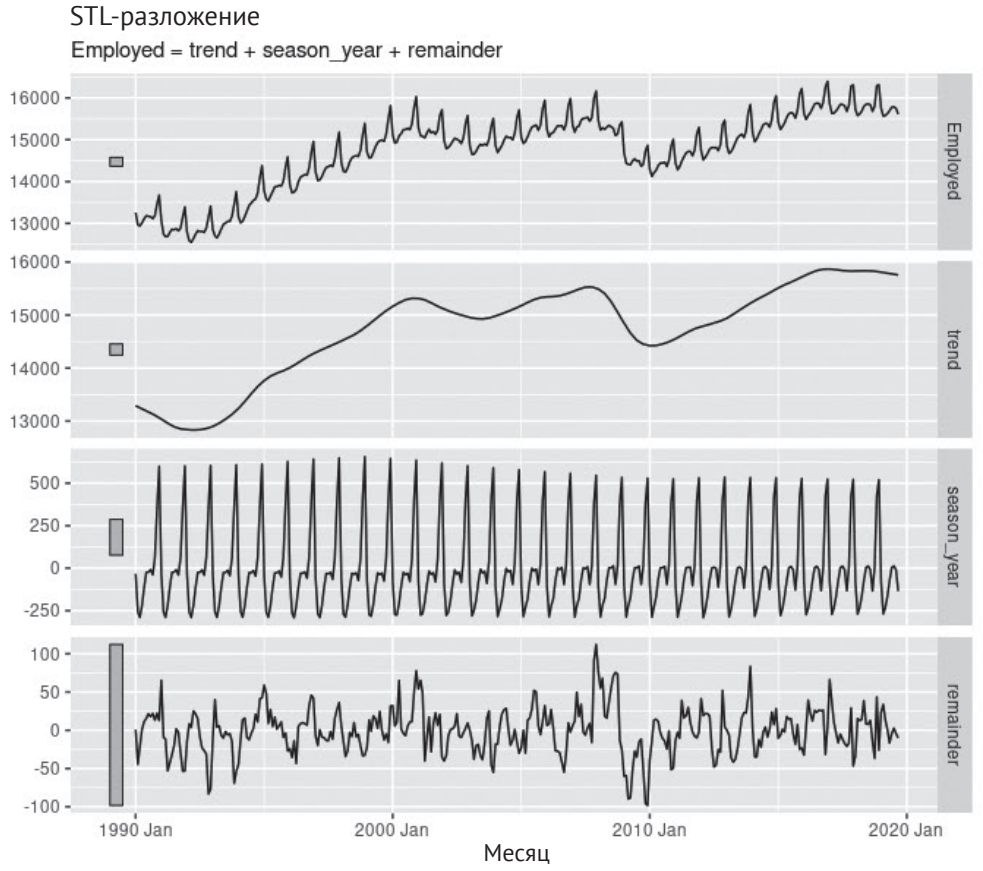


**Рисунок 3.7:** Суммарная численность занятых в розничной торговле США (верх) и ее три дополнительные компоненты

Три компоненты показаны отдельно на трех нижних панелях. Эти компоненты можно сложить, чтобы восстановить данные, показанные на верхней панели. Обратите внимание, что сезонная компонента меняется с течением времени, так что любые два поочередных года имеют схожие закономерности, но годы, расположенные далеко друг от друга, могут иметь разные сезонные закономерности. Компонента остатка, показанная на нижней панели, – это то, что осталось после вычитания из данных компонентов сезонности и тренда-цикла.

Серые полосы слева от каждой панели показывают относительные шкалы компонент. Каждая серая полоса имеет одинаковую длину, но поскольку графики выполнены в разных шкалах, полосы различаются по размеру. Большая серая полоса на нижней панели показывает, что вариация в компоненте остатка является наименьшей по сравнению с вариацией в данных. Если бы мы сжимали три нижние панели до тех пор, пока их столбики не стали одинакового размера, что и на панели данных, то все панели имели бы одинаковую шкалу.

## Сезонно скорректированные данные

Если удалить сезонную компоненту из изначальных данных, то результирующие значения становятся сезонно скорректированными данными. Для аддитивного разложения сезонно скорректированные данные задаются через $y_t - S_t$, а для мультипликативных данных сезонно скорректированные значения получаются с использованием $y_t/S_t$. На рис. 3.8 показана сезонно скорректированная численность занятых.

```
components(dcmp) %>%
  as_tsibble() %>%
  autoplot(Employed, colour = "gray") +
  geom_line(aes(y=season_adjust), colour = "#0072B2") +
  labs(y = "Люди (тыс.)",
       title = "Суммарная занятость в розничной торговле США")
```

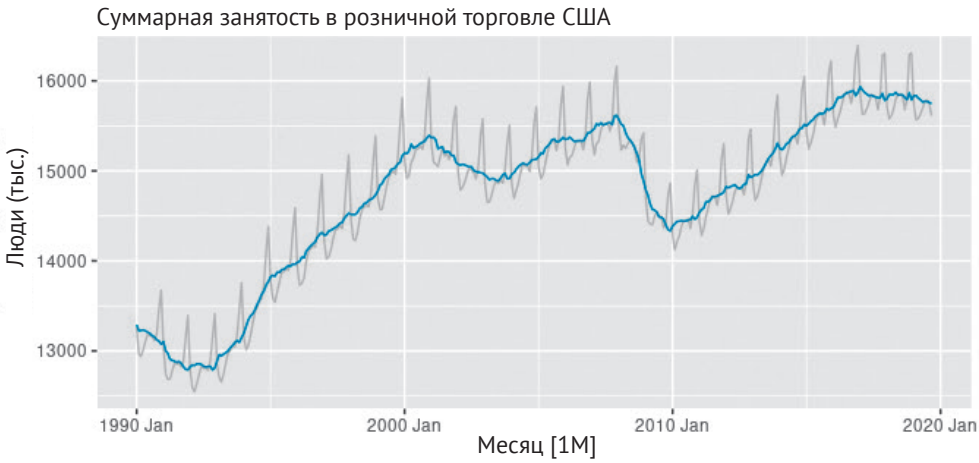


**Рисунок 3.8:** Сезонно скорректированные данные занятости в розничной торговле (синий) и изначальные данные (серый)

Если обусловленная сезонностью вариация не представляет первостепенного интереса, то бывает полезен сезонно скорректированный ряд. Например, ежемесячные данные по безработице обычно сезонно корректируются, чтобы подчеркнуть вариацию, обусловленную опорным состоянием экономики, а не сезонной вариацией. Рост безработицы из-за ищущих работу выпускников школ является сезонной вариацией, в то время как рост безработицы из-за экономического спада имеет внесезонный характер. Большинство экономических аналитиков, которые изучают данные по безработице, больше интересуются внесезонной вариацией. Следовательно, данные о занятости (и многие другие экономические ряды) обычно сезонно корректируются.

Сезонно скорректированные ряды содержат компоненту остатка, а также тренд-цикл. Следовательно, они не являются «плавными», и «спады» или «подъемы» могут дезориентировать. Если целевая задача состоит в том, чтобы искать в ряду поворотные точки и интерпретировать любые изменения в направлении, тогда лучше использовать трендово-циклическую компоненту, а не сезонно скорректированные данные.

# 3.3 Скользящие средние

Классический метод разложения временных рядов возник в 1920-х годах и широко использовался вплоть до 1950-х годов. Он по-прежнему лежит в основе многих методов разложения временных рядов, поэтому важно понимать, как он работает. Первым шагом в классическом разложении является использование метода скользящей средней для оценивания тренда-цикла, поэтому мы начнем с обсуждения скользящих средних.

## Сглаживание скользящей средней

Скользящую среднюю порядка $m$ можно записать как

$$\widehat{T}_t = \frac{1}{m}\sum_{j=-k}^{k} y_{t+j},$$

где $m = 2k + 1$. То есть оценка тренда-цикла во времени $t$ получается путем усреднения значений временного ряда в пределах $k$ периодов $t$. Наблюдения, близкие по времени, также, вероятно, будут близки по значению. И поэтому среднее значение устраняет некоторую случайность в данных, оставляя плавную трендово-циклическую компоненту. Мы называем эту оценку $m$-**MA**, что означает скользящую среднюю порядка $m$ (от англ. Moving Average).

Например, рассмотрим рис. 3.9, на котором показан экспорт товаров и услуг из Австралии в процентах от ВВП с 1960 по 2017 год. Эти данные также приведены в табл. 3.1.

```
global_economy %>%
  filter(Country == "Australia") %>%
  autoplot(Exports) +
  labs(y = "% от ВВП", title = "Суммарный австралийский экспорт")
```

**Рисунок 3.9:** Австралийский экспорт товаров и услуг: 1960–2017 годы

**Таблица 3.1:** Годовой австралийский экспорт товаров и услуг: 1960–2017 гг.

| Год | Экспорт | 5-MA |
|---|---|---|
| 1960 | 12.99 | |
| 1961 | 12.40 | |
| 1962 | 13.94 | 13.46 |
| 1963 | 13.01 | 13.50 |
| 1964 | 14.94 | 13.61 |
| 1965 | 13.22 | 13.40 |
| 1966 | 12.93 | 13.25 |
| 1967 | 12.88 | 12.66 |
| … | … | … |
| 2010 | 19.84 | 21.21 |
| 2011 | 21.47 | 21.17 |
| 2012 | 21.52 | 20.78 |
| 2013 | 19.99 | 20.81 |
| 2014 | 21.08 | 20.37 |
| 2015 | 20.01 | 20.32 |
| 2016 | 19.25 | |
| 2017 | 21.27 | |

В последнем столбце этой таблицы показано скользящее среднее порядка 5, обеспечивающее оценку тренда-цикла. Первое значение в этом столбце – среднее значение первых пяти наблюдений за 1960–1964 годы; второе значение в столбце 5-MA – среднее значение наблюдений за 1961–1965 годы и т. д. Каждое значение в столбце 5-MA представляет собой среднее значение наблюдений за пятилетний период, центрированное на соответствующем году. В нотации уравнения (3.2) столбец 5-MA содержит значения $\widehat{T}_t$ с $k = 2$ и $m = 2k + 1 = 5$. Значений нет ни за первые два года, ни за последние два года, потому что у нас нет двух наблюдений с обеих сторон. Позже мы будем использовать более сложные методы оценивания тренда-цикла, которые позволяют проводить оценивание вблизи конечных точек.

Оно легко вычисляется с помощью функции `slide_dbl()` из пакета `slider`, который применяет функцию к «скользящим» окнам времени. В данном случае мы используем функцию `mean()` с окном размером 5.

```
aus_exports <- global_economy %>%
  filter(Country == "Australia") %>%
  mutate(
    `5-MA` = slider::slide_dbl(Exports, mean,
                .before = 2, .after = 2, .complete = TRUE)
  )
```

Для того чтобы увидеть, как выглядит оценка тренда-цикла, мы нанесем ее на график вместе с изначальными данными на рис. 3.10.

```
aus_exports %>%
  autoplot(Exports) +
  geom_line(aes(y = `5-MA`), colour = "#D55E00") +
  labs(y = "% от ВВП",
       title = "Суммарный австралийский экспорт") +
  guides(colour = guide_legend(title = "series"))
```

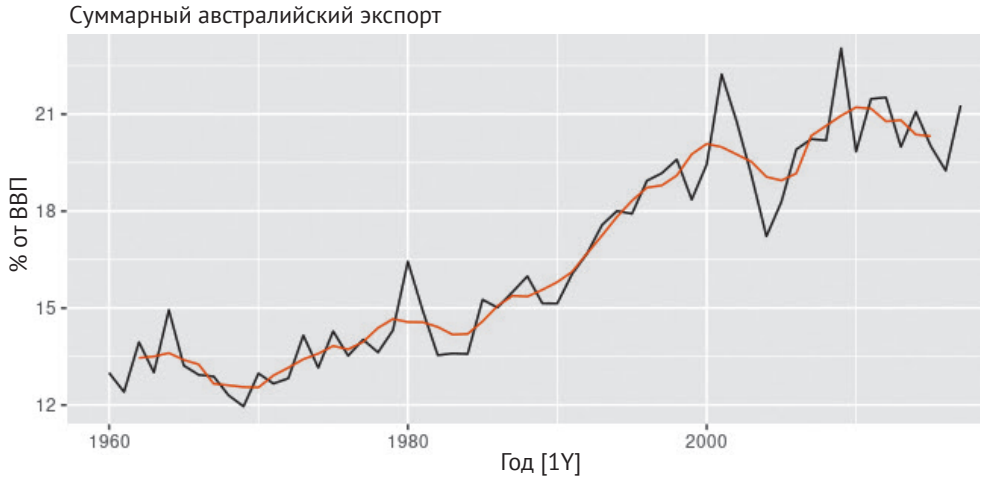


**Рисунок 3.10:** Австралийский экспорт (черный) вместе с 5-месячной оценкой тренда-цикла (оранжевый)

Обратите внимание, что тренд-цикл (выделен оранжевым цветом) имеет более плавный вид, чем изначальные данные, и улавливает главное движение временного ряда без всех незначительных колебаний. Порядок скользящей средней определяет плавность оценки тренда-цикла. В общем случае больший порядок означает более плавную кривую. На рис. 3.11 показан эффект изменения порядка скользящей средней для данных экспорта из Австралии.

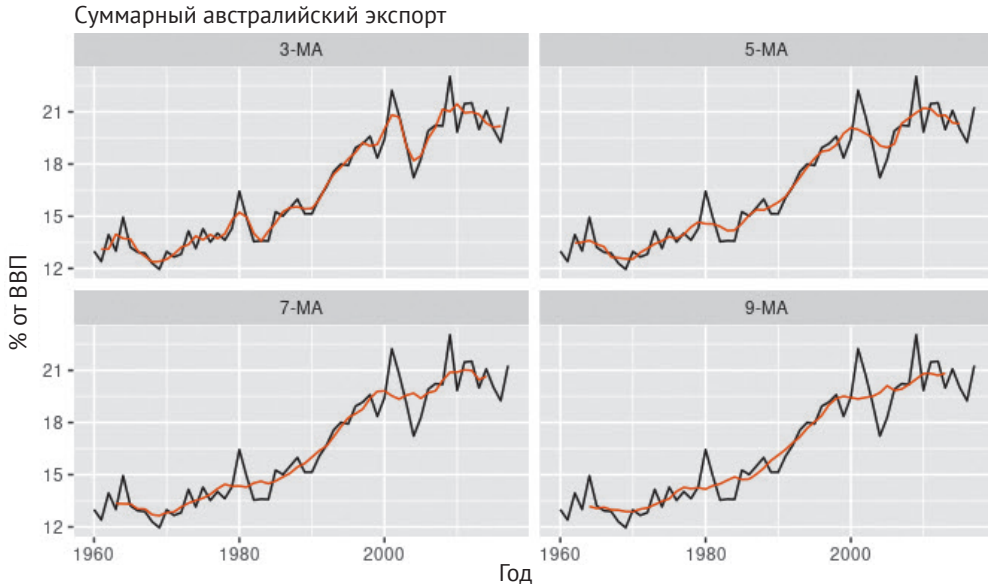


**Рисунок 3.11:** Различные скользящие средние применительно к данным экспорта из Австралии

Простые скользящие средние, подобные этим, обычно имеют нечетный порядок (например, 3, 5, 7 и т. д.). Это делается для того, чтобы они были симметричными: в скользящей средней порядка $m = 2k + 1$, срединное наблюдение, и $k$ наблюдений с обеих сторон усредняются. Но если бы $m$ было четным, то оно больше не было бы симметричным.

## Скользящие средние скользящих средних

Скользящую среднюю можно применять к скользящей средней. Одна из причин тому заключается в том, чтобы сделать скользящую среднюю четного порядка симметричной.

Например, можно было бы взять скользящую среднюю порядка 4, а затем применить к результатам еще одну скользящую среднюю порядка 2. В следующей ниже таблице это сделано для первых нескольких лет ежеквартальных данных по производству пива в Австралии.

```
beer <- aus_production %>%
  filter(year(Quarter) >= 1992) %>%
  select(Quarter, Beer)
beer_ma <- beer %>%
  mutate(
    `4-MA` = slider::slide_dbl(Beer, mean,
                .before = 1, .after = 2, .complete = TRUE),
    `2x4-MA` = slider::slide_dbl(`4-MA`, mean,
                .before = 1, .after = 0, .complete = TRUE)
  )
```

**Таблица 3.2:** Скользящее среднее порядка 4 применительно к квартальным данным о пиве, за которым следует скользящее среднее порядка 2

| Квартал | Пиво | 4-MA | 2×4-MA |
|---|---|---|---|
| 1992 Q1 | 443.00 | | |
| 1992 Q2 | 410.00 | 451.25 | |
| 1992 Q3 | 420.00 | 448.75 | 450.00 |
| 1992 Q4 | 532.00 | 451.50 | 450.12 |
| 1993 Q1 | 433.00 | 449.00 | 450.25 |
| 1993 Q2 | 421.00 | 444.00 | 446.50 |
| ... | ... | ... | ... |
| 2009 Q1 | 415.00 | 430.00 | 428.88 |
| 2009 Q2 | 398.00 | 430.00 | 430.00 |
| 2009 Q3 | 419.00 | 429.75 | 429.88 |
| 2009 Q4 | 488.00 | 423.75 | 426.75 |
| 2010 Q1 | 414.00 | | |
| 2010 Q2 | 374.00 | | |

Нотация «2×4-MA» в последнем столбце означает 4-MA, за которой следует 2-MA. Значения в последнем столбце получены путем вычисления скользящей средней порядка 2 для значений в предыдущем столбце. Например, первые два значения в столбце 4-MA равны 451.25 = (443 + 410 + 420 + 532)/4 и 448 .75 = (410 + 420 + 532 + 433)/4. Первое значение в столбце 2×4-MA – это среднее значение указанных двух: 450.00 = (451.25 + 448.75)/2.

Когда 2-MA следует за скользящей средней четного порядка (к примеру, 4), это называется «центрированной скользящей средней порядка 4». Это происходит потому, что результаты теперь симметричны. Для того чтобы убедиться, что это так, 2×4-MA можно записать следующим образом:

$$\begin{aligned}\widehat{T}_t &= \frac{1}{2}\left[\frac{1}{4}\left(y_{t-2}+y_{t-1}+y_t+y_{t+1}\right)+\frac{1}{4}\left(y_{t-1}+y_t+y_{t+1}+y_{t+2}\right)\right] \\ &= \frac{1}{8}y_{t-2}+\frac{1}{4}y_{t-1}+\frac{1}{4}y_t+\frac{1}{4}y_{t+1}+\frac{1}{8}y_{t+2}.\end{aligned}$$

Теперь это средневзвешенное значение наблюдений, которое является симметричным.

Возможны и другие комбинации скользящих средних. Например, нередко используется 3×3-MA, состоящая из скользящей средней порядка 3, за которой следует еще одна скользящая средняя порядка 3. В общем случае за MA четного порядка должна следовать MA четного порядка, которая делает ее симметричной. Аналогичным образом за MA нечетного порядка должна следовать MA нечетного порядка.

## Оценивание тренда-цикла с сезонными данными

Наиболее часто центрированные скользящие средние используются для оценивания тренда-цикла из сезонных данных. Рассмотрим 2×4-MA:

$$\widehat{T}_t = \frac{1}{8}y_{t-2} + \frac{1}{4}y_{t-1} + \frac{1}{4}y_t + \frac{1}{4}y_{t+1} + \frac{1}{8}y_{t+2}.$$

При применении к квартальным данным каждому кварталу года придается одинаковый вес, поскольку первый и последний члены применяются к одному и тому же кварталу в последующие годы. Следовательно, сезонная вариация будет усреднена, и результирующие значения $\widehat{T}_t$ будут иметь незначительную сезонную вариацию либо ее вообще не останется. Аналогичный эффект был бы получен при использовании 2×8-MA или 2 × 12-MA к квартальным данным.

В общем случае 2×m-MA эквивалентно взвешенной скользящей средней порядка $m + 1$, где все наблюдения принимают вес $1/m$, за исключением первого и последнего членов, которые принимают веса $1/(2m)$. Так, если сезонный период является четным и порядка $m$, то для оценивания тренда-цикла используется $2\times m$-MA. Если сезонный период является нечетным и порядка $m$, то для оценивания тренда-цикла применяется $m$-MA. Например, 2×12-MA можно использовать для оценивания тренда-цикла месячных данных с годовой сезонностью, а 7-MA можно использовать для оценивания тренда-цикла ежедневных данных с еженедельной сезонностью.

Другие варианты порядка MA обычно приводят к тому, что оценки тренда-цикла искажаются сезонностью данных.

## Пример: занятость в секторе розничной торговли США

```
us_retail_employment_ma <- us_retail_employment %>%
  mutate(
    `12-MA` = slider::slide_dbl(Employed, mean,
                .before = 5, .after = 6, .complete = TRUE),
    `2x12-MA` = slider::slide_dbl(`12-MA`, mean,
                .before = 1, .after = 0, .complete = TRUE)
  )
us_retail_employment_ma %>%
  autoplot(Employed, colour = "gray") +
  geom_line(aes(y = `2x12-MA`), colour = "#D55E00") +
  labs(y = "Люди (тыс.)",
       title = "Суммарная занятость в розничной торговле США")
```

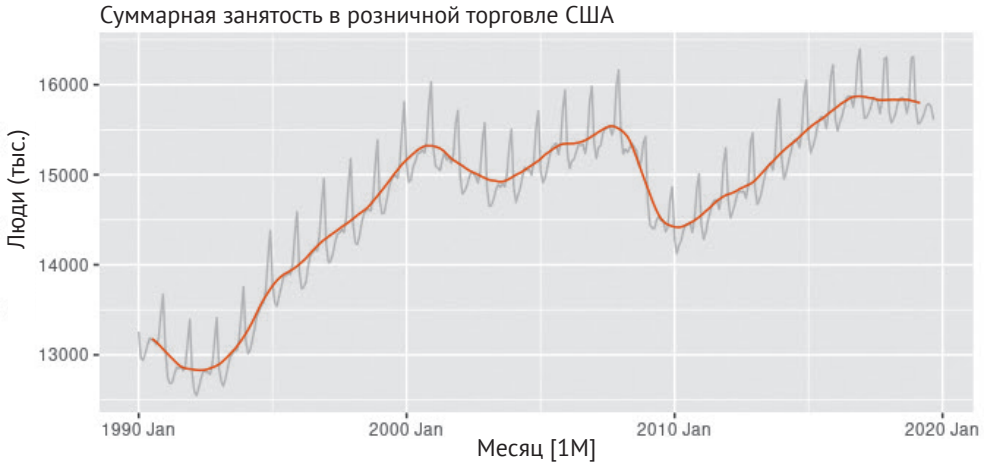


**Рисунок 3.12:** 2×12-MA применительно к ряду данных занятости в розничной торговле США

На рис. 3.12 показана 2×12-MA применительно к суммарной численности лиц, занятых в секторе розничной торговли США. Обратите внимание, что плавная линия не показывает сезонности; она почти такая же, как тренд-цикл, показанный на рис. 3.6, который был оценен с использованием гораздо более сложного метода, чем скользящая средняя. Любой другой выбор порядка скользящей средней (за исключением 24, 36 и т. д.) привел бы к плавной линии, которая показывала бы некоторые сезонные колебания.

## Взвешенные скользящие средние

Комбинации скользящих средних приводят к получению взвешенных скользящих средних. Например, рассмотренная выше 2×4-MA эквивалентна взвешенной 5-MA с весами, заданными через $\left[\frac{1}{8},\frac{1}{4},\frac{1}{4},\frac{1}{4},\frac{1}{8}\right]$. В общем случае взвешенную $m$-MA можно записать как

$$\widehat{T}_t = \sum_{j=-k}^{k} a_j y_{t+j},$$

где $k = (m-1)/2$, а веса задаются через $[a_{-k}, \dots, a_k]$. Важно, чтобы все веса в сумме составляли единицу и чтобы они были симметричными, так чтобы $a_j = a_{-j}$. Простая $m$-MA – это особый случай, когда все веса равны $1/m$.

Главным преимуществом взвешенных скользящих средних является то, что они дают более плавную оценку тренда-цикла. Вместо того чтобы наблюдения входили и выходили из расчета с полным весом, их веса медленно увеличиваются, а затем медленно уменьшаются, что приводит к более плавной кривой.

# 3.4 Классическое разложение

Метод классического разложения возник в 1920-х годах. Это относительно простая процедура, которая служит отправной точкой для большинства других методов разложения временных рядов. Существует две формы классического разложения: аддитивное разложение и мультипликативное разложение. Они описаны ниже для временного ряда с сезонным периодом $m$ (например, $m = 4$ для квартальных данных, $m = 12$ для ежемесячных данных, $m = 7$ для ежедневных данных с еженедельной закономерностью).

В классическом разложении мы исходим из допущения о том, что сезонная компонента постоянна из года в год. В мультипликативной сезонности значения $m$, которые формируют сезонную компоненту, иногда называются «сезонными индексами».

## Аддитивное разложение

***Шаг 1***

Если $m$ – это четное число, то вычислить трендово-циклическую компоненту $\widehat{T}_t$, используя $2\times m$-MA. Если $m$ – это нечетное число, то вычислить трендово-циклическую компоненту $\widehat{T}_t$, используя $m$-MA.

***Шаг 2***

Вычислить детрендированный ряд: $y_t - \widehat{T}_t$.

***Шаг 3***

Для того чтобы оценить сезонную компоненту каждого сезона, следует просто усреднить детрендированные значения этого сезона. Например, при использовании месячных данных сезонная компонента за март представляет собой среднее значение всех детрендированных мартовских значений в данных. Затем эти значения сезонных компонент корректируются таким образом, чтобы они в сумме равнялись нулю. Сезонная компонента получается путем сведения указанных месячных значений, а затем повторения последовательности для каждого года данных. В результате получается $\widehat{S}_t$.

***Шаг 4***

Компонента остатка рассчитывается путем вычитания оцененных сезонной компоненты и трендово-циклической компоненты: $\widehat{R}_t = y_t - \widehat{T}_t - \widehat{S}_t$.

На рис. 3.13 показано классическое разложение суммарной занятости в розничной торговле в США.

```
us_retail_employment %>%
  model(
    classical_decomposition(Employed, type = "additive")
  ) %>%
  components() %>%
  autoplot() +
  labs(title = "Классическое аддитивное разложение занятости в рознице в США")
```

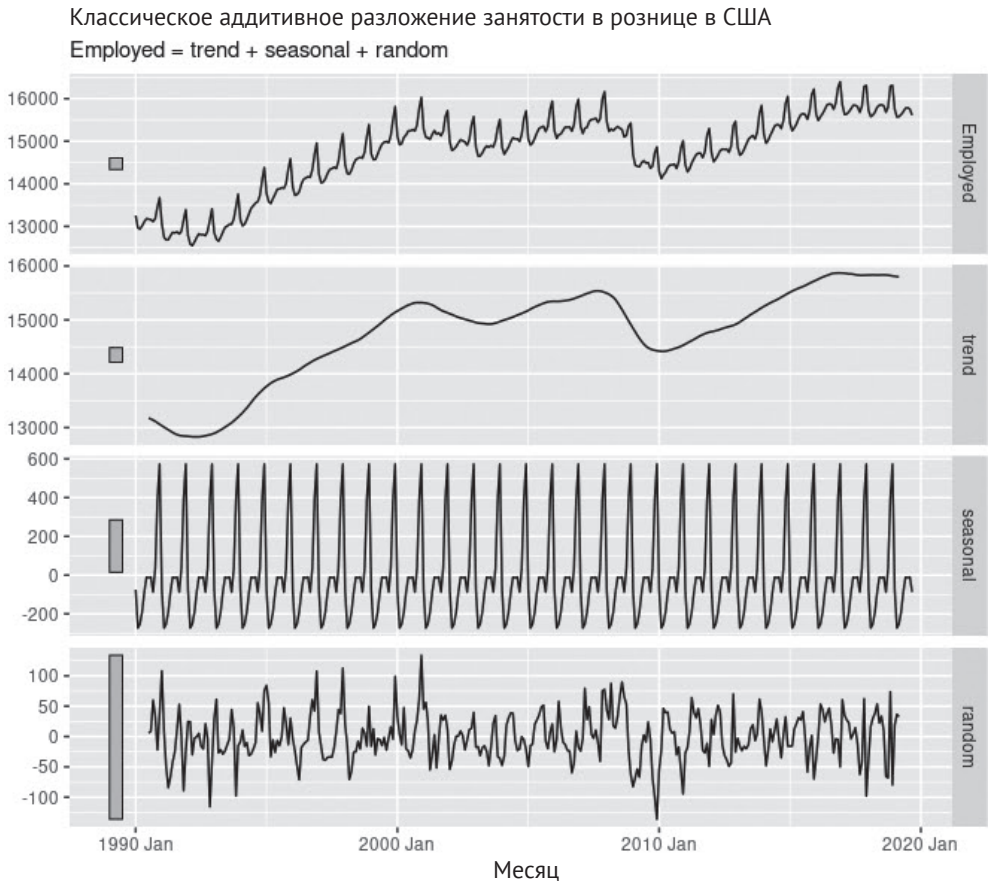


**Рисунок 3.13:** Классическое аддитивное разложение занятости в розничной торговле США

## Мультипликативное разложение

Классическое мультипликативное разложение проводится аналогичным образом, за исключением того, что вычитания заменяются делениями.

***Шаг 1***

Если $m$ – это четное число, то вычислить трендово-циклическую компоненту $\widehat{T}_t$, используя $2\times m$-MA. Если $m$ – это нечетное число, то вычислить трендово-циклическую компоненту $\widehat{T}_t$, используя $m$-MA.

***Шаг 2***

Вычислить детрендированный ряд: $y_t / \widehat{T}_t$.

***Шаг 3***

Для того чтобы оценить сезонную компоненту каждого сезона, следует просто усреднить детрендированные значения этого сезона. Например, при использовании месячных данных сезонная компонента за март представляет собой среднее значение всех детрендированных мартовских значений в данных. Затем эти значения сезонных компонент корректируются таким образом,

чтобы они в сумме составляли $m$. Сезонная компонента получается путем сведения указанных месячных значений, а затем повторения последовательности для каждого года данных. В результате получается $\widehat{S}_t$.

***Шаг 4***

Компонента остатка рассчитывается путем деления оцененных сезонной компоненты и трендово-циклической компоненты: $\widehat{R}_t = y_t / \left(\widehat{T}_t \widehat{S}_t\right)$.

## Комментарии к классическому разложению

Хотя классическое разложение по-прежнему широко используется, оно не рекомендуется, поскольку в настоящее время существует несколько гораздо более совершенных методов. Несколько проблем, связанных с классическим разложением, кратко изложены ниже.

- Оценивание тренда-цикла недоступно для первых нескольких и последних нескольких наблюдений. Например, если $m = 12$, то отсутствует оценка тренда-цикла для первых шести или последних шести наблюдений. Следовательно, также отсутствует оценка компонента остатка за те же периоды времени.
- Оценка тренда-цикла тяготеет к чрезмерному сглаживанию быстрых подъемов и падений в данных.
- Методы классического разложения основаны на допущении о том, что сезонная компонента повторяется из года в год. Для многих рядов это будет разумным допущением, но для некоторых более длинных рядов это не так. Например, закономерности спроса на электроэнергию со временем изменялись по мере того, как кондиционирование воздуха стало более распространенным явлением. Во многих местах сезонная закономерность используемости, существовавшая несколько десятилетий назад, имела максимальный спрос зимой (из-за отопления), в то время как текущая сезонная закономерность имеет максимальный спрос летом (из-за кондиционирования воздуха). Методы классического разложения не в состоянии улавливать эти сезонные изменения с течением времени.
- Иногда значения временных рядов за небольшое число периодов могут быть особенно необычными. Например, на ежемесячный пассажиропоток может влиять производственный спор, в результате чего движение во время спора будет отличаться от обычного. Классический метод не является устойчивым к такого рода необычным значениям.

# 3.5 Методы, используемые официальными статистическими агентствами

Официальные статистические агентства (такие как Бюро переписи населения США и Австралийское бюро статистики) отвечают за большое число официальных экономических и социальных временных рядов. Эти агентства разработали свои собственные процедуры разложения, которые используются для сезонной корректировки. В большинстве из них применяются варианты метода X-11, либо метод SEATS, либо их комбинация. Указанные методы разработа-

ны специально для работы с квартальными и ежемесячными данными, то есть наиболее распространенными рядами, обрабатываемыми официальными статистическими агентствами. Они не будут обрабатывать сезонность других видов, таких как ежедневные данные, почасовые данные или еженедельные данные. Мы будем использовать последнюю имплементацию этой группы методов, именуемую «X-13ARIMA-SEATS». Для методов, описанных в этом разделе, необходимо установить пакет `seasonal` в R.

## Метод X-11

Метод X-11 был разработан Бюро переписи населения США и получил дальнейшее развитие в Статистическом управлении Канады. Он основан на классическом разложении, но включает в себя целый ряд дополнительных шагов и функциональных средств, обеспечивающих преодоление недостатков классического разложения, которые обсуждались в предыдущем разделе. В частности, оценки тренда-цикла доступны для всех наблюдений, включая конечные точки, а сезонная компонента может медленно варьироваться с течением времени. X-11 также обрабатывает вариацию торгового дня, праздничные эффекты и эффекты известных предсказателей. Существуют методы как для аддитивного, так и для мультипликативного разложения. Процесс полностью автоматизирован и, как правило, обладает высокой устойчивостью к выбросам и сдвигам уровней во временных рядах. Подробности метода X-11 описаны в работе Дагум и Бьянкончини (2016, *https://otexts.com/fpp3/methods-used-by-official-statistics-agencies.html#ref-Dagum2016*).

```
x11_dcmp <- us_retail_employment %>%
  model(x11 = X_13ARIMA_SEATS(Employed ~ x11())) %>%
  components()
autoplot(x11_dcmp) +
  labs(title =
    "Разложение суммарной занятости в розничной торговле с помощью X-11.")
```

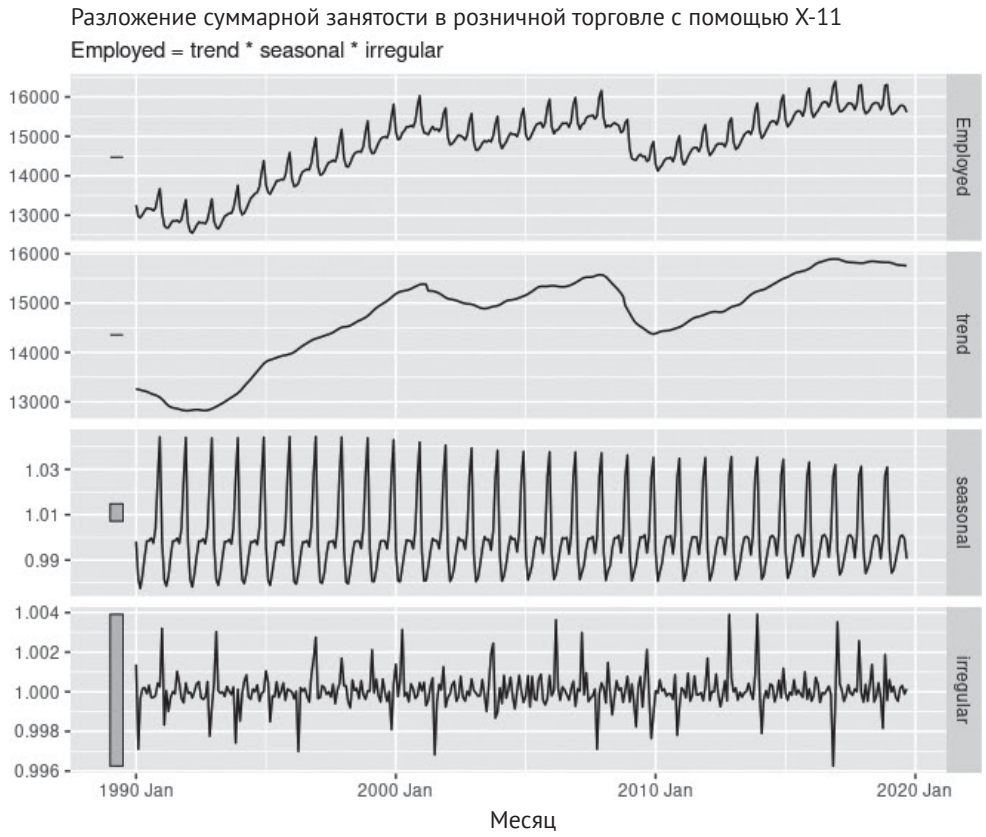


**Рисунок 3.14:** Мультипликативное разложение занятости в розничной торговле США с использованием X-11

Сравните это разложение с STL-разложением, показанным на рис. 3.7, и классическим разложением, показанным на рис. 3.13. Показанный здесь дефолтный для X_13ARIMA_SEATS подход является мультипликативным разложением, тогда как показанные ранее STL- и классическое разложения были аддитивными; но в данном случае это не имеет большого значения. Тренд-цикл метода X-11 уловил внезапное падение в данных из-за глобального финансового кризиса 2007–2008 годов лучше, чем любой из двух других методов (где влияние кризиса просочилось в компонент остатка). Кроме того, необычное наблюдение в 1996 году теперь видно четче в компоненте остатка метода X-11.

На рис. 3.15 показана трендово-циклическая компонента и сезонно скорректированные данные, а также изначальные данные. В этом примере сезонно скорректированные данные очень похожи на трендово-циклическую компоненту, поэтому их трудно различить на графике.

```
x11_dcmp %>%
  ggplot(aes(x = Month)) +
  geom_line(aes(y = Employed, colour = "Data")) +
  geom_line(aes(y = season_adjust,
```

```
              colour = "Seasonally Adjusted")) +
  geom_line(aes(y = trend, colour = "Trend")) +
  labs(y = "Люди (тыс.)",
       title = "Суммарная занятость в розничной торговле США") +
  scale_colour_manual(
    values = c("gray", "#0072B2", "#D55E00"),
    breaks = c("Data", "Seasonally Adjusted", "Trend")
  )
```

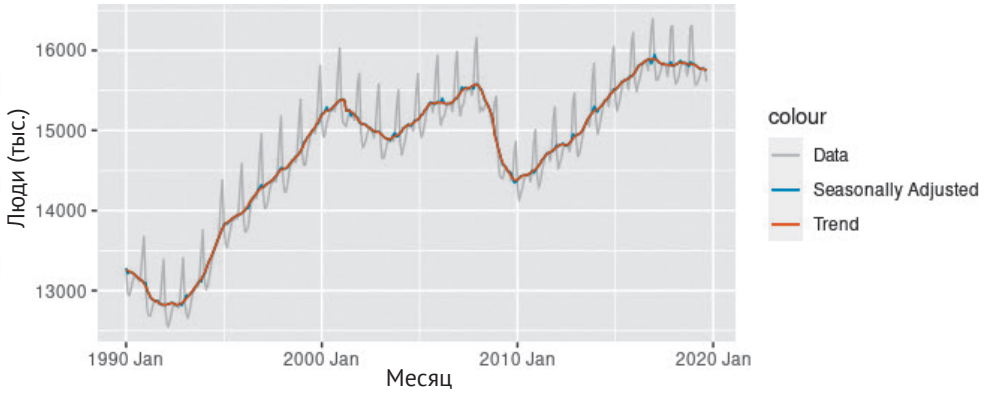


**Рисунок 3.15:** Занятость в розничной торговле США: изначальные данные (серый), трендово-циклическая компонента (оранжевый) и сезонно скорректированные данные (едва видны синим цветом)

Бывает полезно использовать сезонные графики и графики сезонных подрядов сезонной компоненты. Это делается с целью оказания помощи в визуализировании вариации сезонной компоненты с течением времени. На рис. 3.16 показан график сезонных подрядов сезонной компоненты из рис. 3.14. В данном случае со временем происходят лишь небольшие изменения.

```
x11_dcmp %>%
  gg_subseries(seasonal)
```

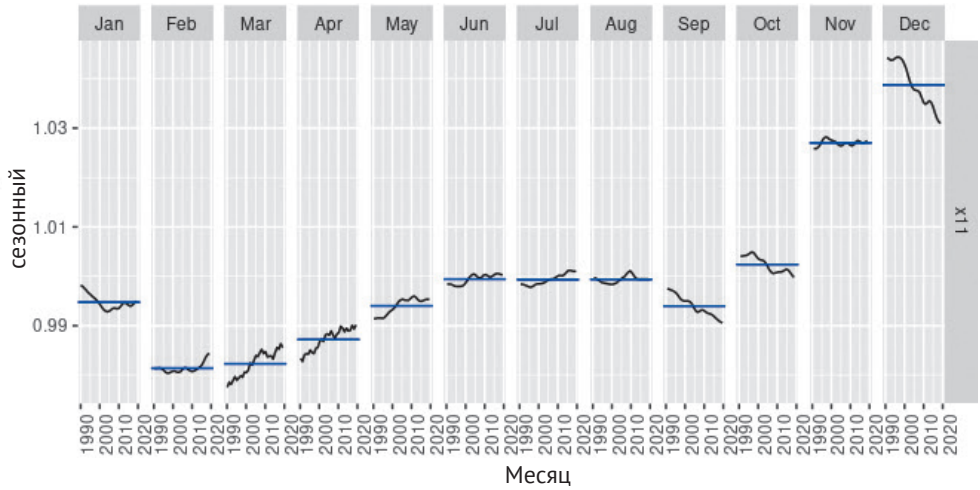


**Рисунок 3.16:** График сезонных подсерий сезонной компоненты из метода X-11 применительно к суммарной занятости в розничной торговле США

## Метод SEATS

«SEATS» означает «Извлечение сезонности во временных рядах ARIMA», от англ. Seasonal Extraction in ARIMA Time Series (модели ARIMA обсуждаются в главе 9). Указанная процедура была разработана в Банке Испании и в настоящее время широко используется правительственными учреждениями по всему миру. Ее подробности выходят за рамки данной книги. Однако полное обсуждение этого метода доступно в Дагум и Бьянкончини (2016, *https://otexts.com/fpp3/methods-used-by-official-statistics-agencies.html#ref-Dagum2016*).

```
seats_dcmp <- us_retail_employment %>%
  model(seats = X_13ARIMA_SEATS(Employed ~ seats())) %>%
  components()
autoplot(seats_dcmp) +
  labs(title =
    "Разложение общей занятости в США с использованием SEATS")
```

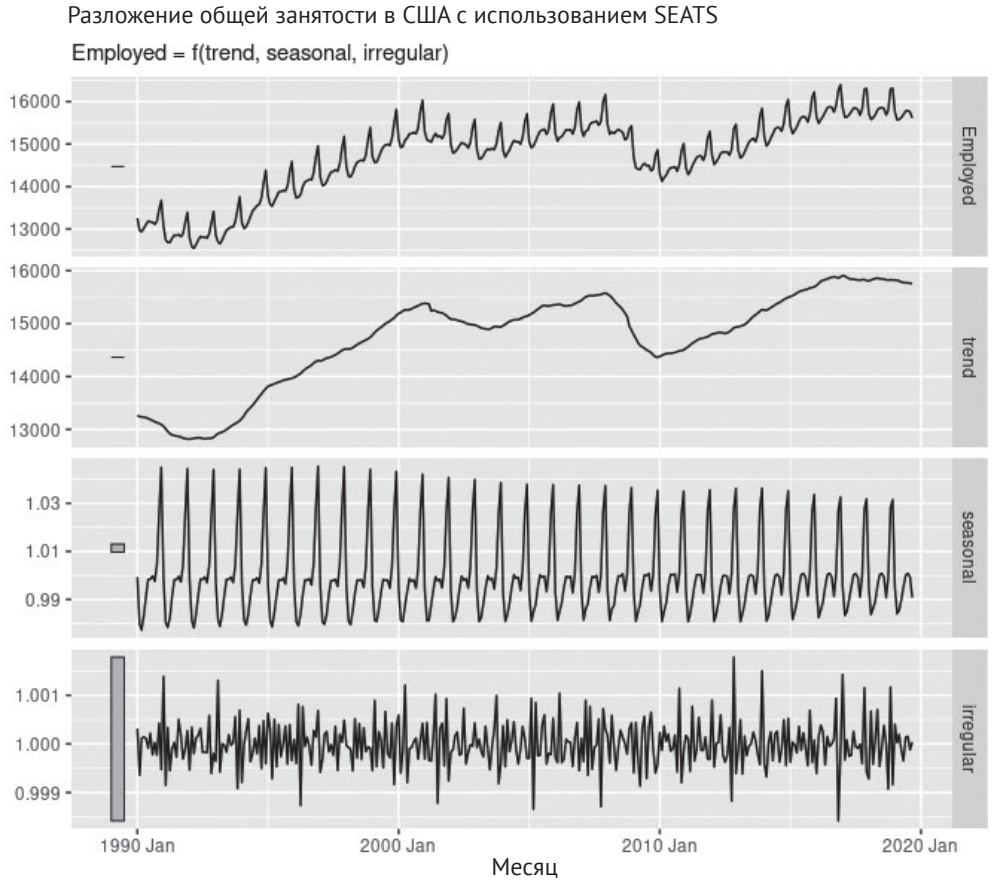


**Рисунок 3.17:** Разложение занятости в розничной торговле США, полученное с использованием SEATS

На рис. 3.17 показан метод SEATS применительно к ряду суммарной занятости в розничной торговле по США. Результат очень похож на результат, полученный с помощью метода X-11, показанного на рис. 3.14.

Функция `X_13ARIMA_SEATS()` вызывает пакет `seasonal`, который имеет много опций для обработки вариантов методов X-11 и SEATS. Подробное описание имеющихся опций и функциональных средств см. на веб-сайте пакета (*https://bit.ly/seaspkg*).

## Библиография

*Дагум, Э. Б. и Бьянкончини, С.* (2016). Методы сезонной корректировки и оценивание тренда-цикла в реальном времени. Springer. [Amazon, *http://buy.geni.us/Proxy.ashx?TSID=140570&GR_URL=http%3A%2F%2Fwww.amazon.com%2Fdp%2F3319318209*].

## 3.6 STL-разложение

STL представляет собой универсальный и надежный метод разложения временных рядов. STL – это аббревиатура от англ. «Seasonal and Trend decomposition using Loess», т. е. сезонно-трендовое разложение с использованием метода Loess, причем Loess – это метод оценивания нелинейных взаимосвязей. Метод STL был разработан Р. Б. Кливлендом и соавт. (1990, *https://otexts.com/fpp3/stl.html#ref-Cleveland1990*).

STL имеет ряд преимуществ перед классическим разложением, а также методами SEATS и X-11:

- в отличие от SEATS и X-11, STL будет обрабатывать любой тип сезонности, а не только ежемесячные и квартальные данные;
- сезонная компонента может изменяться с течением времени, и скорость изменения может контролироваться пользователем;
- плавность тренда-цикла также может контролироваться пользователем;
- он может быть устойчивым к выбросам (т. е. пользователь может указывать устойчивое разложение), вследствие чего случайные необычные наблюдения не повлияют на оценки трендово-циклической и сезонной компонент. Однако они повлияют на компоненту остатка.

С другой стороны, STL имеет несколько недостатков. В частности, он не обрабатывает вариацию торгового дня или календаря автоматически и предоставляет средства только для аддитивного разложения.

Мультипликативное разложение можно получить, сначала взяв логарифмы данных, а затем преобразовав компоненты обратно. Разложения, которые находятся между аддитивным и мультипликативным, могут быть получены с использованием преобразования Бокса–Кокса данных с $0 < \lambda < 1$. Значение $\lambda = 0$ дает мультипликативное разложение, в то время как $\lambda = 1$ дает аддитивное разложение.

Начать освоение STL лучше всего с просмотра нескольких примеров и с экспериментирования с настройками. На рис. 3.7 показан пример STL-разложения применительно к ряду суммарной занятости в розничной торговле США. На рис. 3.18 показано альтернативное STL-разложение, в котором тренд-цикл является более гибким, сезонная закономерность фиксирована и используется устойчивый вариант.

```
us_retail_employment %>%
  model(
    STL(Employed ~ trend(window = 7) +
                   season(window = "periodic"),
    robust = TRUE)) %>%
  components() %>%
  autoplot()
```

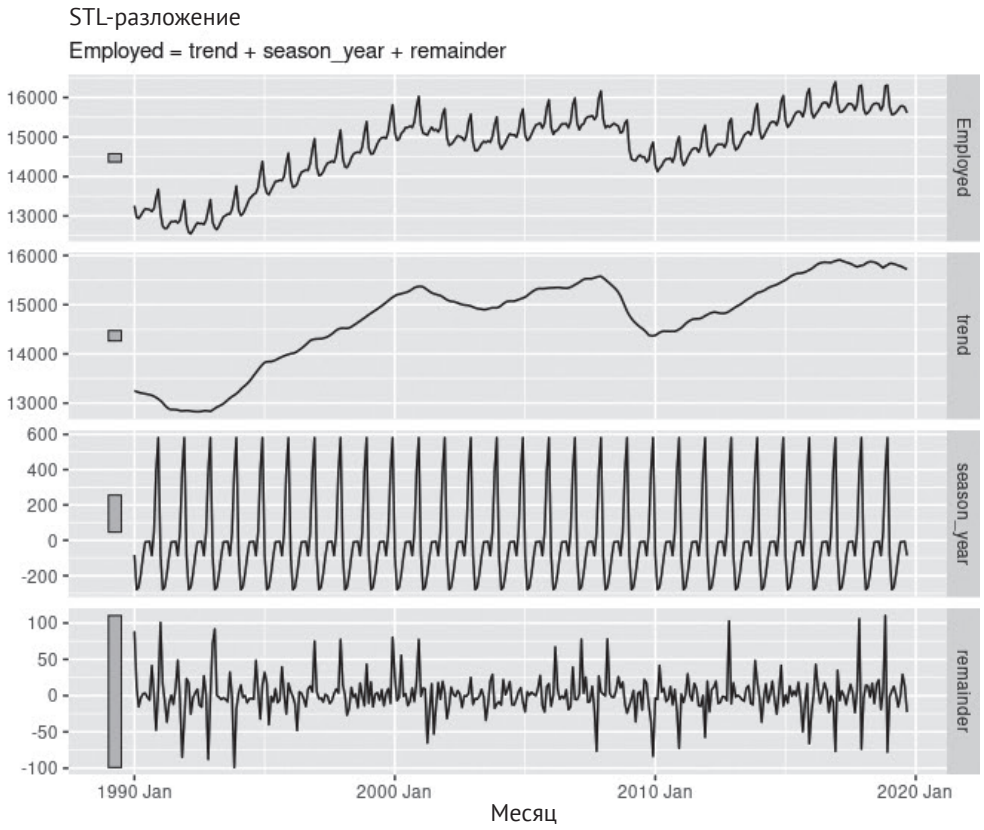


**Рисунок 3.18:** Суммарная занятость в розничной торговле США (вверху) и ее три аддитивные компоненты, полученные в результате устойчивого STL-разложения с гибким трендом-циклом и фиксированной сезонностью

Два главных параметра, которые следует выбирать при использовании STL, – это окно тренда-цикла `trend(window = ?)` и сезонное окно `season(window = ?)`. Они контролируют скорость изменения трендово-циклической и сезонной компонент. Меньшие значения обеспечивают более быстрые изменения. Как трендовое, так и сезонное окна должны быть нечетными числами; трендовое окно – это число поочередных наблюдений, которые будут использоваться при оценивании тренда-цикла; сезонное окно – это число поочередных лет, которые будут использоваться при оценивании каждого значения в сезонной компоненте. Установка сезонного окна, равного бесконечности, эквивалентна тому, чтобы заставить сезонную компоненту быть периодическим сезоном `season(window='periodic')` (т. е. одинаковым по годам). Это было показано на рис. 3.18.

Функция `STL()` по умолчанию обеспечивает удобное автоматическое STL-разложение с использованием сезонного окна `season(window=13)` и трендового окна, выбираемого автоматически из сезонного периода. Дефолтной настройкой для месячных данных является `trend(window=21)`. Обычно за счет этого обеспечивается хороший баланс между переподгонкой сезонности и возможностью ее постепенного изменения с течением времени. Но, как и в случае лю-

бой автоматизированной процедуры, дефолтные настройки будут нуждаться в корректировке для некоторых временных рядов. В данном случае дефолтная настройка трендового окна создает слишком жесткую трендово-циклическую компоненту. В результате сигнал от глобального финансового кризиса 2008 года просочился в компоненту остатка, как видно на нижней панели рис. 3.7. Выбор более короткого трендового окна, как на рис. 3.18, улучшает ситуацию.

## Библиография

*Кливленд, Р. Б., Кливленд, У. С., Макрэй, Дж. Е. и Терпеннинг, И. Дж.* (1990). STL: процедура сезонно-трендового разложения на основе loess. Journal of Official Statistics, 6 (1), 3–33. *http://bit.ly/stl1990*.

# 3.7 Упражнения

1. Рассмотрите информацию о ВВП в `global_economy`. Постройте график ВВП на душу населения для каждой страны с течением времени. В какой стране самый высокий ВВП на душу населения? Как этот показатель изменялся с течением времени?
2. Для каждого из следующих ниже рядов постройте график данных. Если преобразование выглядит целесообразным, то выполните его и опишите эффект.
   - ВВП Соединенных Штатов из `global_economy`;
   - забой «быков, бычков и бычков-кастратов» в шт. Виктория из `aus_livestock`;
   - спрос на электроэнергию в шт. Виктория из `vic_elec`;
   - добыча газа из `aus_production`.
3. Почему преобразование Бокса–Кокса бесполезно для данных `canadian_gas`?
4. Какое преобразование Бокса–Кокса вы бы выбрали для своих розничных данных (из упражнения 8 в разделе 2.10)?
5. Для следующих рядов найдите подходящее преобразование Бокса–Кокса, чтобы стабилизировать дисперсию: табак из `aus_production`, пассажиры эконом-класса между Мельбурном и Сиднеем из `ansett`, а число пешеходов на станции Сазерн Кросс из `pedestrian`.
6. Покажите, что 3×5-MA эквивалентна 7-членной взвешенной скользящей средней с весами 0.067, 0.133, 0.200, 0.200, 0.200, 0.133 и 0.067.
7. Рассмотрите данные по газу за последние пять лет из `aus_production`.

```
gas <- tail(aus_production, 5*4) %>% select(Gas)
```

   a) Нанесите временной ряд на график. Сможете ли вы выявить сезонные колебания и/или тренд-цикл?
   b) Используйте `classical_decomposition` с `type=multiplicative` для вычисления трендово-циклического и сезонного индексов.
   c) Подтверждают ли результаты графическую интерпретацию из части a?
   d) Вычислите и нанесите на график сезонно скорректированные данные.

e) Измените одно наблюдение, сделав его выбросом (например, добавьте 300 к одному наблюдению), и пересчитайте сезонно скорректированные данные. Каков эффект выброса?
f) Имеет ли какое-либо значение, если выброс находится ближе к концу, а не в середине временного ряда?

8. Вспомните свои данные временных рядов розничной торговли (из упражнения 8 в разделе 2.10). Разложите ряд, используя метод X-11. Выявляет ли он какие-либо выбросы или необычные признаки, которые вы ранее не замечали?
9. На рис. 3.19 и 3.20 показан результат разложения численности гражданской рабочей силы в Австралии за каждый месяц с февраля 1978 года по август 1995 года.

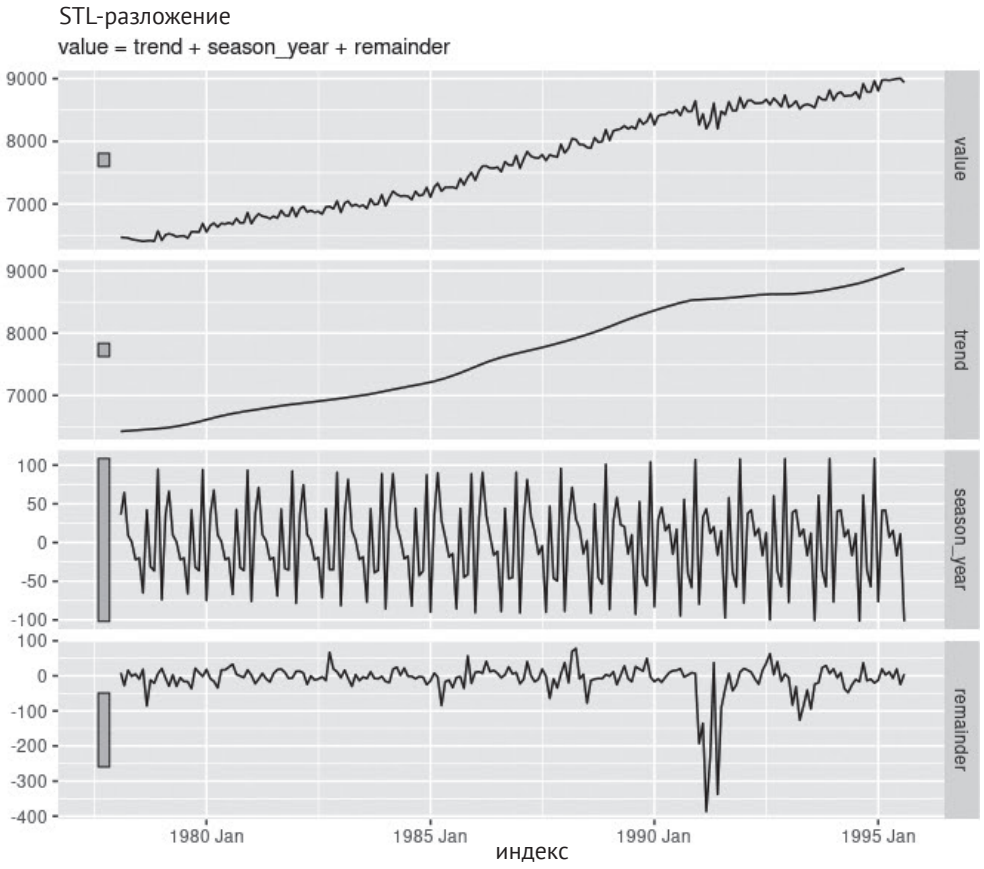


**Рисунок 3.19:** Разложение численности гражданской рабочей силы в Австралии за каждый месяц с февраля 1978 года по август 1995 года

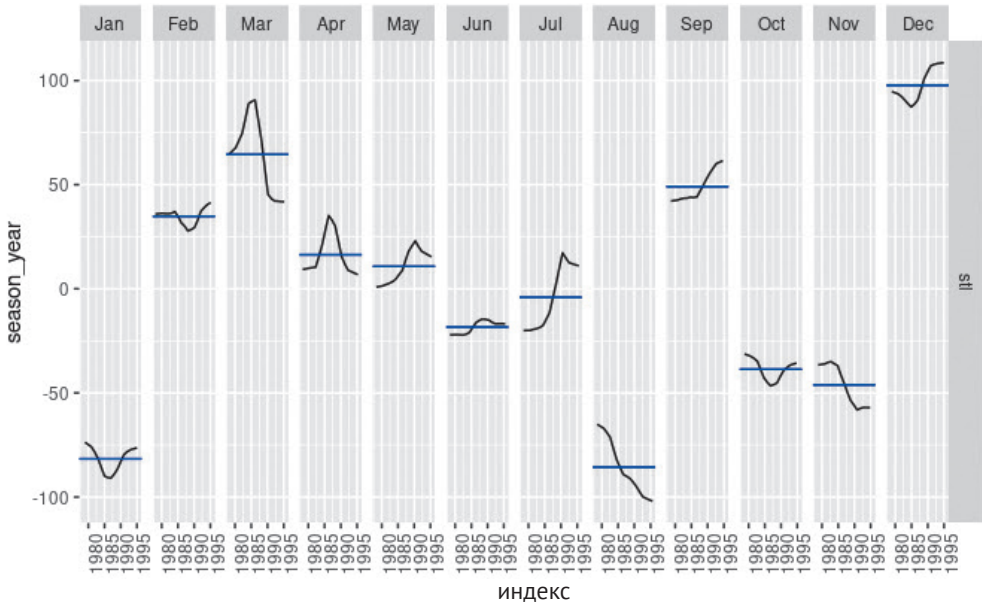


**Рисунок 3.20:** Сезонная компонента из разложения, показанного на предыдущем рисунке

a) Напишите 3–5 предложений, описывающих результаты разложения. При интерпретировании обратите особое внимание на шкалы графиков.
b) Виден ли спад 1991/1992 годов в оцененных компонентах?

10. В этом упражнении используются данные `canadian_gas` (ежемесячная добыча газа в Канаде в миллиардах кубических метров, январь 1960 – февраль 2005).
    a) Нанесите данные на график с помощью `autoplot()`, `gg_subseries()` и `gg_season()`, чтобы посмотреть на влияние изменения сезонности с течением времени[1].
    b) Выполните STL-разложение данных. Вам нужно будет выбрать сезонное окно, чтобы учесть изменение формы сезонной компоненты.
    c) Как меняется сезонная форма с течением времени? [Подсказка: попробуйте нанести сезонную компоненту на график с помощью `gg_season()`.]
    d) Сможете ли вы создать правдоподобный сезонно скорректированный ряд?
    e) Сравните результаты с результатами, полученными с использованием SEATS и X-11. Чем они отличаются друг от друга?

[1] Эволюция сезонной закономерности, возможно, связана с изменениями в регулировании цен на газ – спасибо Льюису Кирвану за указание на это.

## 3.8 Дальнейшее чтение

Подробное современное обсуждение методов SEATS и X-11 представлено в Дагум и Бьянкончини (2016, *https://otexts.com/fpp3/decomposition-reading.html#ref-Dagum2016*).

Р. Б. Кливленд и соавт. (1990, *https://otexts.com/fpp3/decomposition-reading.html#ref-Cleveland1990*) представили STL и до сих пор дают наилучшее описание алгоритма.

## Библиография

*Кливленд, Р. Б., Кливленд, У. С., Макрэй, Дж. Е. и Терпеннинг, И. Дж.* (1990). STL: Процедура сезонно-трендового разложения на основе loess. Journal of Official Statistics, 6 (1), 3–33. *http://bit.ly/stl1990*.

*Дагум, Э. Б. и Бьянкончини, С.* (2016). Методы сезонной корректировки и оценивание тренда-цикла в реальном времени. Springer. [Amazon, *http://buy.geni.us/Proxy.ashx?TSID=140570&GR_URL=http%3A%2F%2Fwww.amazon.com%2Fdp%2F3319318209*].

# Глава 4

# Признаки временных рядов

Пакет feasts содержит функции для вычисления признаков (FEatures) и статистики (Statistics) из временных рядов (Time Series) (отсюда и название). Мы уже увидели несколько признаков временных рядов. Например, автокорреляции, обсуждаемые в разделе 2.8, можно рассматривать как признаки временных рядов – они представляют собой числовые обобщения, вычисленные из ряда. Еще одним признаком, который мы увидели в прошлой главе, была оценка Герреро параметра преобразования Бокса–Кокса – опять же, это число, вычисленное из временного ряда.

Можно вычислять многочисленные и разные признаки для самых разных временных рядов и использовать их для проведения разведывательного анализа свойств рядов. В этой главе мы рассмотрим некоторые признаки, которые были признаны полезными при разведывании временных рядов, и то, как их можно использовать для получения интересной информации о ваших данных. В качестве сквозного примера будем использовать австралийский квартальный туризм (ранее обсуждавшийся в разделе 2.5).

## 4.1 Несколько простых статистик

Любая числовая сводка, вычисленная из временного ряда, является признаком этого временного ряда, например среднее, минимальное или максимальное значение. Они вычисляются с помощью функции `features()`. Например, давайте вычислим средние значения всех рядов данных по туризму в Австралии.

```
tourism %>%
  features(Trips, list(mean = mean)) %>%
  arrange(mean)
#> # A tibble: 304 × 4
#>    Region          State              Purpose   mean
#>    <chr>           <chr>              <chr>    <dbl>
#>  1 Kangaroo Island South Australia    Other    0.340
#>  2 MacDonnell      Northern Territory Other    0.449
#>  3 Wilderness West Tasmania           Other    0.478
#>  4 Barkly          Northern Territory Other    0.632
#>  5 Clare Valley    South Australia    Other    0.898
#>  6 Barossa         South Australia    Other    1.02
```

```
#>  7 Kakadu Arnhem   Northern Territory Other    1.04
#>  8 Lasseter        Northern Territory Other    1.14
#>  9 Wimmera         Victoria           Other    1.15
#> 10 MacDonnell      Northern Territory Visiting 1.18
#> # … и еще 294 строки
```

Здесь мы видим, что наименьшее среднее число посещений имел ряд «Другие» с посещениями острова Кенгуру в Южной Австралии.

Вместо того чтобы вычислять по одному признаку за раз, удобно вычислять сразу несколько признаков. Обычная краткая сводка набора данных заключается в вычислении пяти сводных статистик: минимум, первый квартиль, медиана, третий квартиль и максимум. Они делят данные на четыре раздела одинакового размера, каждый из которых содержит 25 % данных. Для их вычисления можно использовать функцию `quantile()`.

```
tourism %>% features(Trips, quantile)
#> # A tibble: 304 × 8
#>    Region         State           Purpose    `0%`  `25%`  `50%`  `75%`
`100%`
#>    <chr>          <chr>           <chr>     <dbl>  <dbl>  <dbl>  <dbl>
<dbl>
#>  1 Adelaide       South Australia Busine…  68.7   134.   153.    177.   242.
#>  2 Adelaide       South Australia Holiday 108.    135.   154.    172.   224.
#>  3 Adelaide       South Australia Other    25.9    43.9   53.8    62.5  107.
#>  4 Adelaide       South Australia Visiti… 137.    179.   206.    229.   270.
#>  5 Adelaide Hills South Australia Busine…   0       0      1.26    3.92  28.6
#>  6 Adelaide Hills South Australia Holiday   0       5.77   8.52   14.1   35.8
#>  7 Adelaide Hills South Australia Other     0       0      0.908   2.09
8.95
#>  8 Adelaide Hills South Australia Visiti…   0.778   8.91  12.2    16.8   81.1
#>  9 Alice Springs  Northern Terri… Busine…   1.01    9.13  13.3    18.5   34.1
#> 10 Alice Springs  Northern Terri… Holiday   2.81   16.9   31.5    44.8   76.5
#> # … и еще 294 строки
```

Здесь минимальное значение обозначено как 0 %, а максимальное – как 100 %.

## 4.2 Признаки ACF

Автокорреляции обсуждались в разделе 2.8. Все автокорреляции ряда можно рассматривать как признаки этого ряда. Автокорреляции также можно обобщать и получать новые признаки; например, сумма первых десяти квадратов коэффициентов автокорреляции является полезной суммой, указывающей на величину автокорреляция в ряду, независимо от лага.

Кроме того, можно вычислять автокорреляции изменений в рядах между периодами. То есть мы «дифференцируем» данные и создаем новый временной

ряд, состоящий из разниц между поочередными наблюдениями. И тогда появляется возможность вычислять автокорреляции этого нового дифференцированного ряда. Иногда бывает полезно снова применить ту же операцию дифференцирования, поэтому мы вычисляем разницы разниц. Автокорреляции этого дважды дифференцированного ряда могут предоставлять полезную информацию.

Еще один связанный с этим подход заключается в вычислении сезонных разниц ряда. Например, если бы у нас были месячные данные, то мы бы вычислили разницу между поочередными январями, поочередными февралями и т. д. Это позволяет смотреть на то, как меняется ряд между годами, а не между месяцами. Опять же, автокорреляции сезонно дифференцированных рядов могут предоставить полезную информацию.

Мы обсудим дифференцирование временных рядов подробнее в разделе 9.1.

Функция `feat_acf()` вычисляет подборку обсуждаемых здесь автокорреляций. Она будет возвращать шесть или семь признаков:

- первый коэффициент автокорреляции из изначальных данных;
- сумму квадратов первых десяти коэффициентов автокорреляции из изначальных данных;
- первый коэффициент автокорреляции из дифференцированных данных;
- сумму квадратов первых десяти коэффициентов автокорреляции из дифференцированных данных;
- первый коэффициент автокорреляции из дважды дифференцированных данных;
- сумму квадратов первых десяти коэффициентов автокорреляции из дважды дифференцированных данных;
- в случае сезонных данных также возвращается коэффициент автокорреляции в первом сезонном лаге.

При применении к данным по туризму в Австралии мы получаем следующий ниже результат.

```
tourism %>% features(Trips, feat_acf)
#> # A tibble: 304 × 10
#>    Region       State Purpose     acf1 acf10 diff1_acf1 diff1_acf10 diff2_acf1
#>    <chr>        <chr> <chr>      <dbl> <dbl>      <dbl>       <dbl>      <dbl>
#>  1 Adelaide     Sout… Busine…  0.0333  0.131     -0.520       0.463     -0.676
#>  2 Adelaide     Sout… Holiday  0.0456  0.372     -0.343       0.614     -0.487
#>  3 Adelaide     Sout… Other    0.517   1.15      -0.409       0.383     -0.675
#>  4 Adelaide     Sout… Visiti…  0.0684  0.294     -0.394       0.452     -0.518
#>  5 Adelaide Hi… Sout… Busine…  0.0709  0.134     -0.580       0.415     -0.750
#>  6 Adelaide Hi… Sout… Holiday  0.131   0.313     -0.536       0.500     -0.716
#>  7 Adelaide Hi… Sout… Other    0.261   0.330     -0.253       0.317     -0.457
#>  8 Adelaide Hi… Sout… Visiti…  0.139   0.117     -0.472       0.239     -0.626
#>  9 Alice Sprin… Nort… Busine…  0.217   0.367     -0.500       0.381     -0.658
#> 10 Alice Sprin… Nort… Holiday -0.00660 2.11      -0.153       2.11      -0.274
#> # … и еще 294 строки и еще 2 переменные: diff2_acf10 <dbl>,
#> #   season_acf1 <dbl>
```

## 4.3 Признаки STL

STL-разложение, которое обсуждается в главе 3, является базисом для еще нескольких признаков.

Разложение временного ряда используется для измерения силы тренда и сезонности во временном ряду. Напомним, что разложение записывается как

$$y_t = T_t + S_t + R_t,$$

где $T_t$ – это сглаженная трендовая компонента, $S_t$ – сезонная компонента и $R_t$ – компонента остатка. Для данных с сильным трендом сезонно скорректированные данные должны иметь гораздо больше вариаций, чем компонента остатка. Поэтому $\text{Var}(R_t)/\text{Var}(T_t + R_t)$ должно быть относительно малым. Но для данных с малым трендом или без него две дисперсии должны быть примерно одинаковыми. Таким образом, мы определяем силу тренда как

$$F_T = \max\left(0, 1 - \frac{\text{Var}(R_t)}{\text{Var}(T_t + R_t)}\right).$$

В результате будет получена оценка силы тренда между 0 и 1. Поскольку дисперсия остатка иногда может быть даже больше, чем дисперсия сезонно скорректированных данных, мы устанавливаем минимально возможное значение $F_T$ равным нулю.

Сила сезонности определяется аналогичным образом, но в отношении не сезонно скорректированных данных, а детрендированных данных:

$$F_S = \max\left(0, 1 - \frac{\text{Var}(R_t)}{\text{Var}(S_t + R_t)}\right).$$

Ряд с сезонной силой $F_S$, близкой к 0, почти не проявляет сезонности, в то время как ряд с сильной сезонностью будет иметь $F_S$ близко к 1, потому что $\text{Var}(R_t)$ будет намного меньше, чем $\text{Var}(S_t + R_t)$.

Эти меры бывают полезны, например, когда у вас есть большая коллекция временных рядов и вам нужно найти ряды с наибольшим трендом или наибольшей сезонностью. Эти и другие основанные на STL признаки вычисляются с помощью функции `feat_stl()`.

```
tourism %>%
  features(Trips, feat_stl)
#> # A tibble: 304 × 12
#>    Region       State Purpose trend_strength seasonal_streng… seasonal_peak_y…
#>    <chr>        <chr> <chr>            <dbl>            <dbl>            <dbl>
#>  1 Adelaide     Sout… Busine…          0.464            0.407                3
#>  2 Adelaide     Sout… Holiday          0.554            0.619                1
#>  3 Adelaide     Sout… Other            0.746            0.202                2
#>  4 Adelaide     Sout… Visiti…          0.435            0.452                1
```

```
#>  5 Adelaide Hi… Sout… Busine…        0.464        0.179      3
#>  6 Adelaide Hi… Sout… Holiday       0.528        0.296      2
#>  7 Adelaide Hi… Sout… Other         0.593        0.404      2
#>  8 Adelaide Hi… Sout… Visiti…       0.488        0.254      0
#>  9 Alice Sprin… Nort… Busine…       0.534        0.251      0
#> 10 Alice Sprin… Nort… Holiday       0.381        0.832      3
#> # … и еще 294 строки и еще 6 переменных: seasonal_trough_year <dbl>,
#> #   spikiness <dbl>, linearity <dbl>, curvature <dbl>, stl_e_acf1 <dbl>,
#> #   stl_e_acf10 <dbl>
```

Затем эти признаки можно использовать в графиках, чтобы определить, какие ряды имеют сильный тренд, а какие являются наиболее сезонными.

```
tourism %>%
  features(Trips, feat_stl) %>%
  ggplot(aes(x = trend_strength, y = seasonal_strength_year,
             col = Purpose)) +
  geom_point() +
  facet_wrap(vars(State))
```

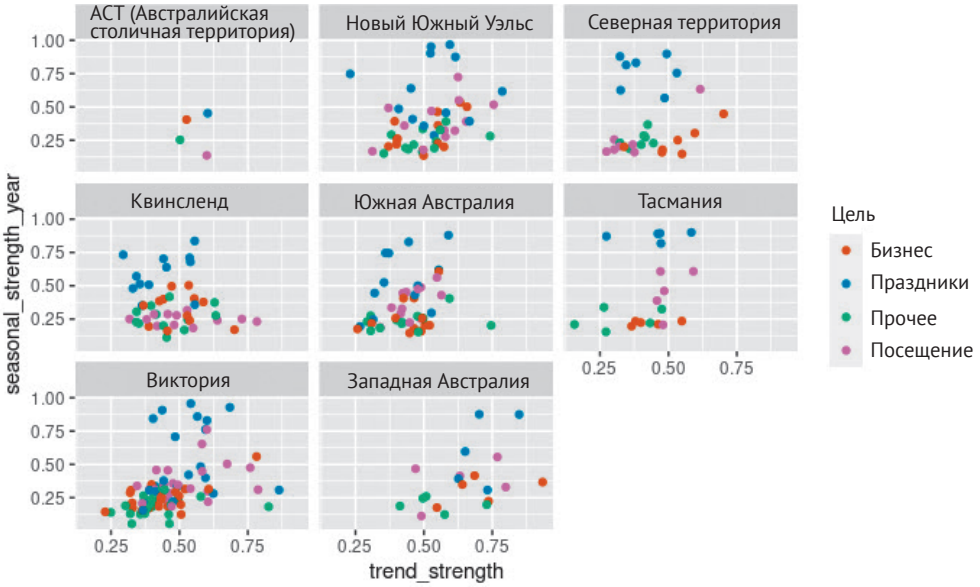


**Рисунок 4.1:** Сезонная сила в сопоставлении с силой тренда по всем туристическим рядам

Очевидно, что праздничные ряды являются в основном сезонными, что неудивительно. Наиболее сильные тренды, как правило, наблюдаются в Западной Австралии и Виктории. Наиболее сезонные ряды также можно легко идентифицировать и нанести на график.

```
tourism %>%
  features(Trips, feat_stl) %>%
  filter(
    seasonal_strength_year == max(seasonal_strength_year)
  ) %>%
  left_join(tourism, by = c("State", "Region", "Purpose")) %>%
  ggplot(aes(x = Quarter, y = Trips)) +
  geom_line() +
  facet_grid(vars(State, Region, Purpose))
```

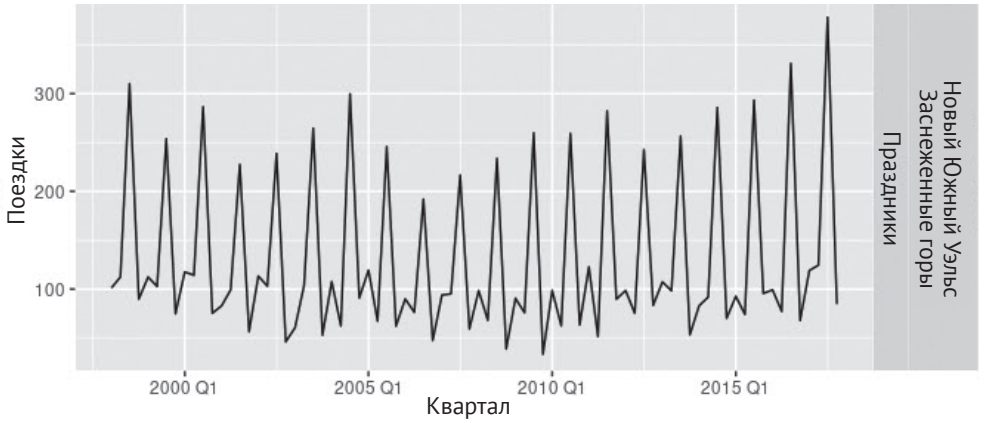


**Рисунок 4.2:** Наиболее сезонные ряды в данных по туризму в Австралии

Приведенный выше рисунок показывает праздничные поездки в самый популярный горнолыжный регион Австралии.

Функция `feat_stl()` возвращает еще несколько признаков, отличных от тех, которые обсуждались выше.

- `seasonal_peak_year` указывает время пиков – в каком месяце или квартале содержится наибольшая сезонная компонента. Этот признак говорит кое-что о природе сезонности. Согласно австралийским туристическим данным, если 3-й квартал является пиковым сезонным периодом, то люди едут в регион зимой, тогда как пик в 1-м квартале говорит о том, что регион более популярен летом.
- `seasonal_trough_year` указывает время спада – в каком месяце или квартале содержится наименьшая сезонная компонента.
- `spikiness` измеряет распространенность всплесков в компоненте остатков $R_t$ STL-разложения. Это дисперсия дисперсий с исключением по одному из $R_t$.
- `linearity` измеряет линейность трендовой компоненты STL-декомпозиции. Этот признак основан на коэффициенте линейной регрессии, применяемом к трендовой компоненте.
- `curvature` измеряет кривизну трендовой компоненты STL-разложения. Этот признак основан на коэффициенте ортогональной квадратичной регрессии, применяемой к трендовой компоненте.

- `stl_e_acf1` – это первый коэффициент автокорреляции ряда остатков.
- `stl_e_acf10` – это сумма квадратов первых десяти коэффициентов автокорреляции ряда остатков.

## 4.4 Другие признаки

Можно получать гораздо больше признаков, и пакет feasts вычисляет всего несколько десятков признаков, которые оказались полезными при анализе временных рядов. Также легко добавлять свои собственные признаки, написав функцию R, которая на входе принимает данные одномерного временного ряда и на выходе возвращает числовой вектор, содержащий значения признаков.

Остальные признаки пакета feasts, которые ранее не обсуждались, перечислены здесь для справки. Подробности некоторых из них обсуждаются далее в книге.

- `coef_hurst` вычисляет коэффициент Херста временного ряда, то есть меру «длинной памяти». Ряд с длинной памятью будет иметь значительные автокорреляции в течение многих лагов.
- `feat_spectral` вычисляет спектральную энтропию (Шеннона) временного ряда, то есть меру того, насколько легко прогнозировать этот ряд. Ряд, который имеет сильный тренд и сезонность (и поэтому легко прогнозируется), будет иметь энтропию, близкую к 0. Ряд, который является очень шумным (и поэтому его трудно предсказывать), будет иметь энтропию, близкую к 1.
- `box_pierce` выдает статистику Бокса–Пирса для выполнения теста на предмет того, является ли временной ряд белым шумом, и соответствующее *p*-значение. Этот тест обсуждается в разделе 5.4.
- `ljung_box` выдает статистику Льюнга–Бокса для выполнения теста на предмет того, является ли временной ряд белым шумом, и соответствующее *p*-значение. Этот тест обсуждается в разделе 5.4.
- *k*-я частичная автокорреляция измеряет взаимосвязь между наблюдениями, отстоящими на *k* периодов друг от друга после устранения последствий наблюдений между ними. Таким образом, первая частичная автокорреляция ($k = 1$) идентична первой автокорреляции, потому что между поочередными наблюдениями нет ничего, что можно было бы удалить. Частичные автокорреляции обсуждаются в разделе 9.5. Функция `feat_pacf` содержит несколько признаков, связанных с частичными автокорреляциями, включая сумму квадратов первых пяти частичных автокорреляций для изначального ряда, первично-дифференцированный ряд и вторично-дифференцированный ряд. В случае сезонных данных он также включает частичную автокорреляцию в первом сезонном лаге.
- `unitroot_kpss` дает статистику Квятковского–Филлипса–Шмидта–Шина (KPSS) для выполнения теста на предмет того, является ли ряд стационарным, и соответствующее *p*-значение. Этот тест обсуждается в разделе 9.1.
- `unitroot_pp` выдает статистику Филлипса–Перрона для выполнения теста на предмет того, является ли ряд нестационарным, и соответствующее *p*-значение.
- `unitroot_ndiffs` выдает число разниц, необходимых для получения стационарного ряда на основе теста KPSS. Этот признак обсуждается в разделе 9.1.

- `unitroot_nsdiffs` выдает число сезонных разниц, необходимых для того, чтобы сделать ряд стационарным. Этот признак обсуждается в разделе 9.1.
- `var_tiled_mean` выдает дисперсии «плиточных средних» (т. е. средних значений поочередных не накладывающихся друг на друга блоков наблюдений). Длина плитки по умолчанию равна либо 10 (для несезонных данных), либо длине сезонного периода. Этот признак иногда называется признаком «стабильности».
- `var_tiled_var` выдает дисперсии «плиточных дисперсий» (т. е. дисперсии поочередных не накладывающихся друг на друга блоков наблюдений). Этот признак иногда называется признаком «комковатости».
- `shift_level_max` находит наибольший сдвиг среднего между двумя поочередными скользящими окнами временного ряда. Этот признак полезен для обнаружения внезапных скачков или падений во временном ряду.
- `shift_level_index` выдает индекс, при котором происходит наибольший сдвиг среднего.
- `shift_var_max` находит наибольший сдвиг дисперсии между двумя поочередными скользящими окнами временного ряда. Этот признак полезен для обнаружения внезапных изменений волатильности временного ряда.
- `shift_var_index` выдает индекс, при котором происходит наибольший сдвиг дисперсии.
- `shift_kl_max` находит наибольший распределительный сдвиг (основанный на расхождении Кульбака–Лейблера) между двумя поочередными скользящими окнами временного ряда. Этот признак полезен для обнаружения внезапных изменений в распределении временного ряда.
- `shift_kl_index` выдает индекс, при котором происходит наибольший сдвиг Кульбака–Лейблера.
- `n_crossing_points` вычисляет число раз, когда временной ряд пересекает медиану.
- `longest_flat_spot` вычисляет число секций данных, в которых ряд относительно неизменен.
- `stat_arch_lm` возвращает статистику, основанную на тесте Энгла (1982) множителя Лагранжа (LM) для авторегрессионной условной гетероскедастичности (ARCH).
- `guerrero` вычисляет оптимальное значение $\lambda$ для преобразования Бокса–Кокса с использованием метода Герреро (обсуждается в разделе 3.1).

## 4.5 Разведывательный анализ данных о туризме в Австралии

Все включенные в пакет feasts признаки можно вычислить в одной строке следующим образом.

```
tourism_features <- tourism %>%
  features(Trips, feature_set(pkgs = "feasts"))
tourism_features
```

```
#> # A tibble: 304 × 51
#>    Region       State Purpose trend_strength seasonal_streng… seasonal_peak_y…
#>    <chr>        <chr> <chr>            <dbl>            <dbl>            <dbl>
#>  1 Adelaide     Sout… Busine…          0.464            0.407                3
#>  2 Adelaide     Sout… Holiday          0.554            0.619                1
#>  3 Adelaide     Sout… Other            0.746            0.202                2
#>  4 Adelaide     Sout… Visiti…          0.435            0.452                1
#>  5 Adelaide Hi… Sout… Busine…          0.464            0.179                3
#>  6 Adelaide Hi… Sout… Holiday          0.528            0.296                2
#>  7 Adelaide Hi… Sout… Other            0.593            0.404                2
#>  8 Adelaide Hi… Sout… Visiti…          0.488            0.254                0
#>  9 Alice Sprin… Nort… Busine…          0.534            0.251                0
#> 10 Alice Sprin… Nort… Holiday          0.381            0.832                3
#> # … и еще 294 строки и еще 45 переменных: seasonal_trough_year <dbl>,
#> #   spikiness <dbl>, linearity <dbl>, curvature <dbl>, stl_e_acf1 <dbl>,
#> #   stl_e_acf10 <dbl>, acf1 <dbl>, acf10 <dbl>, diff1_acf1 <dbl>,
#> #   diff1_acf10 <dbl>, diff2_acf1 <dbl>, diff2_acf10 <dbl>,
#> #   season_acf1 <dbl>, pacf5 <dbl>, diff1_pacf5 <dbl>, diff2_pacf5 <dbl>,
#> #   season_pacf <dbl>, zero_run_mean <dbl>, nonzero_squared_cv <dbl>,
#> #   zero_start_prop <dbl>, zero_end_prop <dbl>, lambda_guerrero <dbl>, …
```

Это вычисление выдает 48 признаков для каждой комбинации трех переменных-ключей (`Region`, `State` и `Purpose`). Данный объект `tiddle` можно трактовать как любой набор данных и проводить его анализ с целью отыскания интересующих наблюдений или групп наблюдений.

Мы уже видели пример того, как можно сопоставлять один признак с другим (раздел 4.3). Можно также создавать попарные графики групп признаков. На рис. 4.3, например, мы показываем все признаки, связанные с сезонностью, вместе с переменной `Purpose`.

```
library(glue)
tourism_features %>%
  select_at(vars(contains("season"), Purpose)) %>%
  mutate(
    seasonal_peak_year = seasonal_peak_year +
      4*(seasonal_peak_year==0),
    seasonal_trough_year = seasonal_trough_year +
      4*(seasonal_trough_year==0),
    seasonal_peak_year = glue("Q{seasonal_peak_year}"),
    seasonal_trough_year = glue("Q{seasonal_trough_year}"),
  ) %>%
  GGally::ggpairs(mapping = aes(colour = Purpose))
```

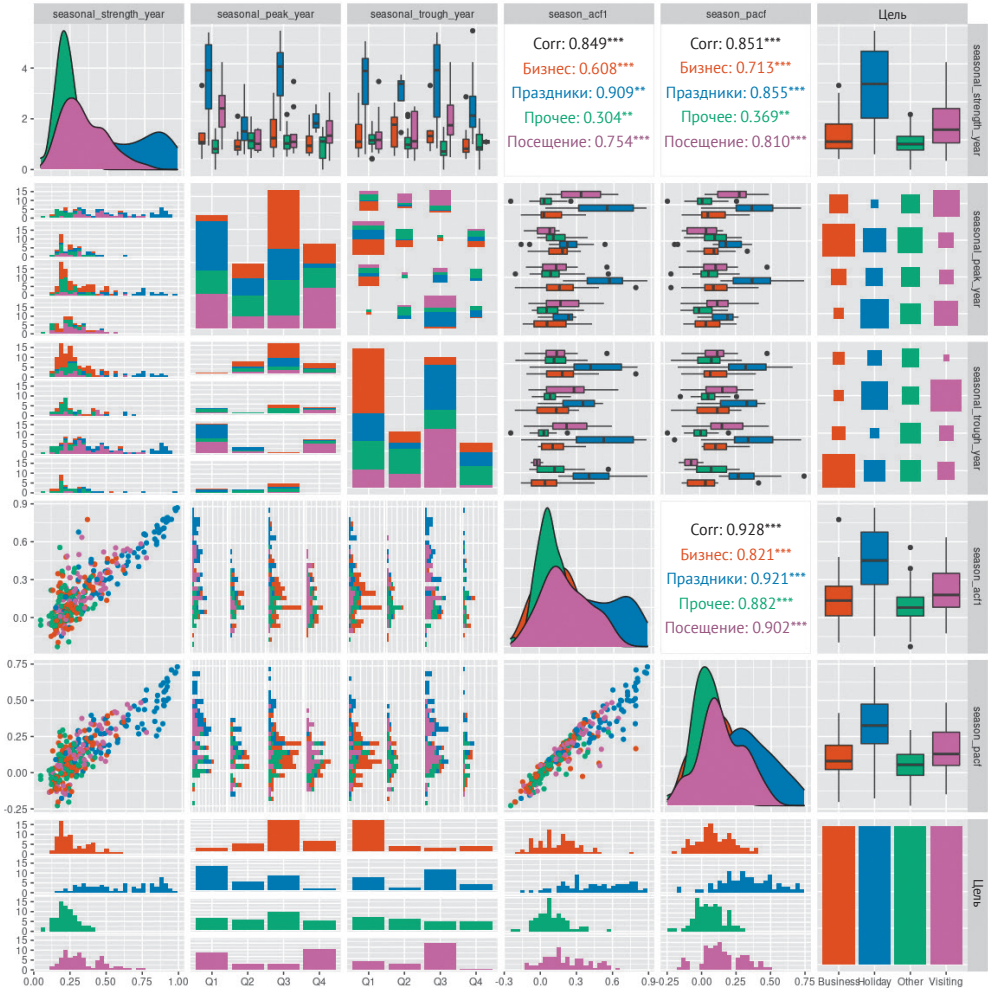


**Рисунок 4.3:** Попарные графики всех сезонных признаков для данных о туризме в Австралии

Здесь переменная `Purpose` сопоставляется с цветом. На этом рисунке содержится много информации, и мы выделим лишь несколько моментов, которые можем усвоить.

- Все три числовые меры, связанные с сезонностью (`seasonal_strength_year`, `season_acf1` и `season_pacf`), имеют положительную корреляцию.
- Нижняя левая панель и верхняя правая панель показывают, что наиболее сильно сезонные ряды связаны с праздниками (как мы видели ранее).
- Столбчатые графики в нижней строке столбцов `seasonal_peak_year` и `seasonal_trough_year` показывают, что сезонные пики деловых поездок чаще всего происходят в 3-м квартале и реже всего в 1-м квартале.

Таким образом, трудно исследовать больше, чем несколько переменных. Полезным способом обработки большего числа переменных является использование методики редукции размерности, такой как главные компоненты. Этот

метод дает линейные комбинации переменных, которые объясняют наибольшую вариацию в изначальных данных. Главные компоненты туристических признаков можно вычислить следующим образом.

```
library(broom)
pcs <- tourism_features %>%
  select(-State, -Region, -Purpose) %>%
  prcomp(scale = TRUE) %>%
  augment(tourism_features)
pcs %>%
  ggplot(aes(x = .fittedPC1, y = .fittedPC2, col = Purpose)) +
  geom_point() +
  theme(aspect.ratio = 1)
```

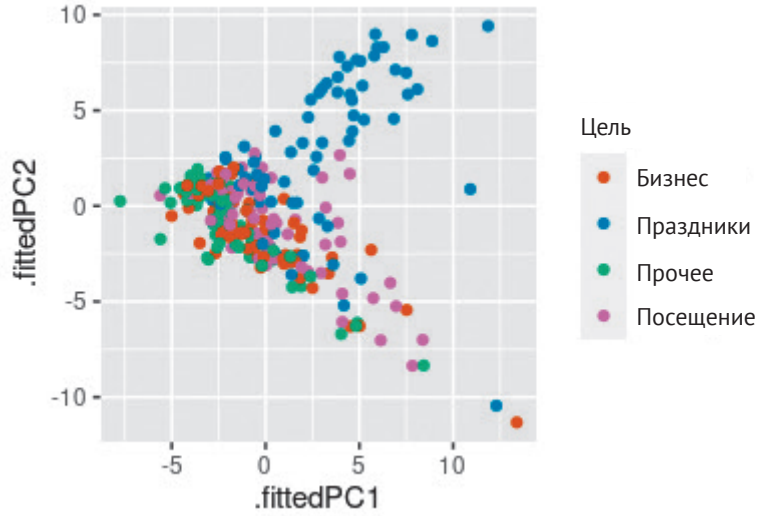


**Рисунок 4.4:** График первых двух главных компонент, рассчитанный на основе 48 признаков квартальных данных по туризму в Астралии

Каждая точка на рис. 4.4 представляет один ряд, и его расположение на графике основано на всех 48 объектах. Первая главная компонента (`.fittedPC1`) – это линейная комбинация признаков, которая объясняет наибольшую вариацию в данных. Вторая главная компонента (`.fittedPC2`) – это линейная комбинация, которая объясняет следующую по величине вариацию в данных, будучи при этом некоррелированной с первой главной компонентой. Для получения дополнительной информации о редукции размерности методом главных компонент см. Изерман (2008, *https://otexts.com/fpp3/exploring-australian-tourism-data.html#ref-izenman2008*).

На рис. 4.4 показаны некоторые данные о туризме. Прежде всего праздничный ряд ведет себя совершенно иначе, чем остальные ряды. Почти все праздничные ряды появляются в верхней половине графика, в то время как почти все остальные ряды появляются в нижней половине графика. Очевидно, что

вторая главная компонента проводит различие между праздничными и другими видами поездок.

График также позволяет идентифицировать аномальные временные ряды – ряды, которые имеют необычные комбинации признаков. Они показаны в виде точек, которые отделены от большинства рядов на рис. 4.4. Выделяются четыре, и мы можем определить их соответствие какому-либо ряду следующим образом.

```
outliers <- pcs %>%
  filter(.fittedPC1 > 10) %>%
  select(Region, State, Purpose, .fittedPC1, .fittedPC2)
outliers
#> # A tibble: 4 × 5
#>   Region                State            Purpose  .fittedPC1 .fittedPC2
#>   <chr>                 <chr>            <chr>         <dbl>      <dbl>
#> 1 Australia's North West Western Australia Business       13.4    -11.3
#> 2 Australia's South West Western Australia Holiday        10.9      0.880
#> 3 Melbourne             Victoria         Holiday        12.3    -10.4
#> 4 South Coast           New South Wales  Holiday        11.9      9.42
outliers %>%
  left_join(tourism, by = c("State", "Region", "Purpose")) %>%
  mutate(
    Series = glue("{State}", "{Region}", "{Purpose}",
                  .sep = "\n\n")
  ) %>%
  ggplot(aes(x = Quarter, y = Trips)) +
  geom_line() +
  facet_grid(Series ~ ., scales = "free") +
  labs(title = "Временные ряды с выбросами в пространстве главных компонент")
```

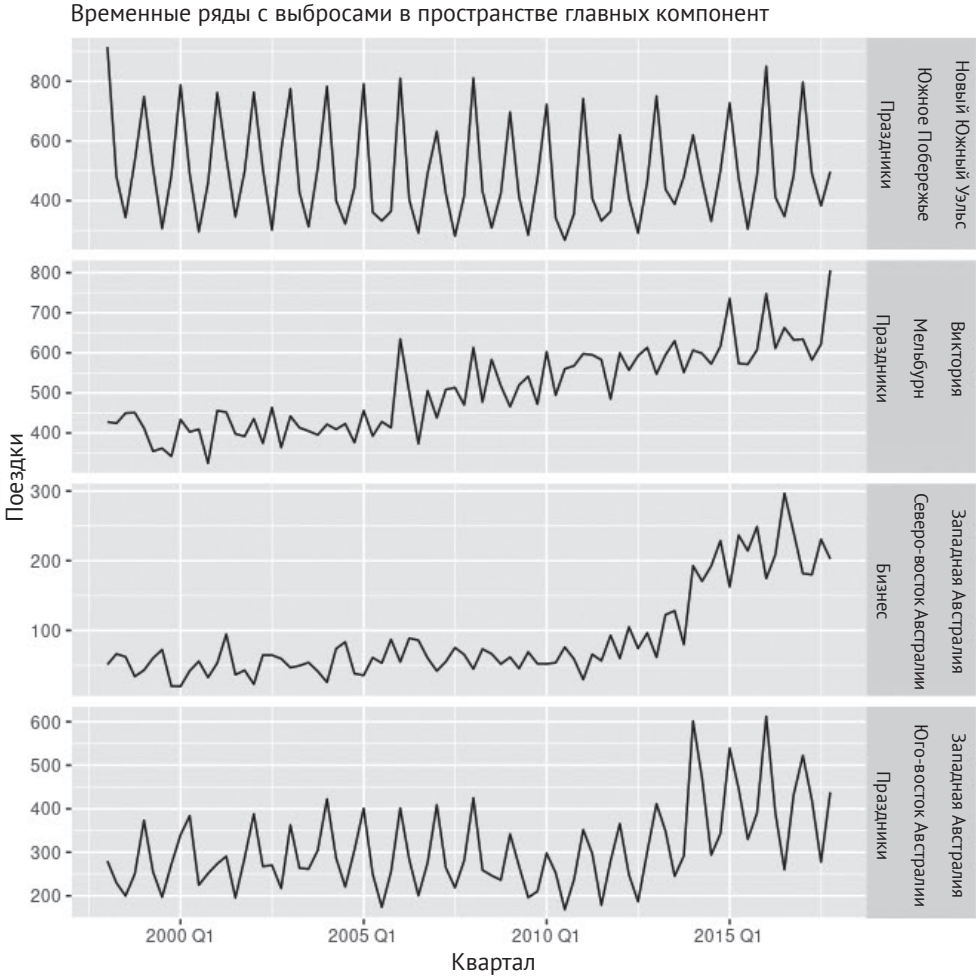


**Рисунок 4.5:** Четыре аномальных временных ряда из данных по туризму в Австралии

Мы можем поразмышлять о том, почему эти ряды идентифицируются как необычные.

- Поездки на отдых на южное побережье Нового Южного Уэльса носят сезонный характер, но почти не имеют тренда, в то время как большинство мест отдыха в Австралии демонстрируют некоторый тренд с течением времени.
- Мельбурн – необычное место для отдыха, потому что в нем почти нет сезонности, в то время как большинство мест отдыха в Австралии отличаются высокой сезонностью туризма.
- Северо-западная часть Западной Австралии необычна тем, что, по имеющимся данным, за последние несколько лет наблюдается рост делового туризма, но практически отсутствует сезонность.
- Юго-западный угол Западной Австралии необычен тем, что он демонстрирует как рост праздничного туризма за последние несколько лет, так и высокий уровень сезонности.

## Библиография

*Айзенман, А. Дж.* (2008). Современные методы многомерной статистики: регрессия, классификация и множественное обучение. Springer. [Amazon, *http://buy.geni.us/Proxy.ashx?TSID=140570&GR_URL=http%3A%2F%2Fwww.amazon.com%2Fdp%2F0387781889*].

## 4.6 Упражнения

1. Напишите функцию для вычисления среднего значения и стандартного отклонения временного ряда и примените ее к данным PBS. Нанесите на график ряд с наибольшим средним значением и ряд с наименьшим стандартным отклонением.
2. Используйте `GGally::ggpairs()`, чтобы просмотреть взаимосвязи между признаками, основанными на STL, для ряда праздников в данных `tourism`. Измените значения `seasonal_peak_year` и `seasonal_trough_year` на коэффициенты, как показано на рис. 4.3. Какой квартал является пиковым для праздников в каждом штате?
3. Используйте признакоориентированный подход для отыскания выбросных рядов в данных PBS. Что необычного в ряду, который вы идентифицируете как «выбросы»?

## 4.7 Дальнейшее чтение

Идея использования STL для признаков возникла у Ванг и соавт. (2006, *https://otexts.com/fpp3/further-reading.html#ref-WangSH06*).

Признаки, предоставляемые пакетом feasts, были мотивированы их использованием в работах Хайндман и соавт. (2015, *https://otexts.com/fpp3/further-reading.html#ref-cikm2015*) и Канг и соавт. (2017, *https://otexts.com/fpp3/further-reading.html#ref-m3pca*).

Разведывательный анализ набора временных рядов с использованием главных компонент на крупной коллекции признаков был предложен Канг и соавт. (2017, *https://otexts.com/fpp3/further-reading.html#ref-m3pca*).

## Библиография

*Хайндман Р. Дж., Ванг Э. и Лаптев Н.* (2015). Крупномасштабное обнаружение необычных временных рядов. Proceedings of the IEEE International Conference on Data Mining, 1616–1619. [DOI: https://doi.org/10.1109/ICDMW.2015.104].

*Кан, Ю., Хайндман, Р. Дж. и Смит-Майлз, К.* (2017). Визуализация результативности алгоритма прогнозирования с использованием пространств экземпляров временных рядов. International Journal of Forecasting, 33 (2), 345–358. [DOI: https://doi.org/10.1016/j.ijforecast.2016.09.004].

*Ван, Х., Смит, К. А. и Хайндман, Р. Дж.* (2006). Характеристикоориентированная кластеризация данных временных рядов. Data Mining and Knowledge Discovery, 13 (3), 335–364. [DOI: https://doi.org/10.1007/s10618-005-0039-x].

# Глава 5

# Инструментарий прогнозиста

В этой главе мы обсудим несколько общих инструментов, которые находят широкое применение во многих различных ситуациях прогнозирования. Мы опишем несколько эталонных методов прогнозирования, процедуры проверки адекватности использования методом прогнозирования имеющейся информации, методы вычисления предсказательных интервалов и методы оценивания прогнозной точности.

Каждый обсуждаемый в этой главе инструмент будет использоваться неоднократно в последующих главах по мере разработки и разведывательного анализа серии методов прогнозирования.

## 5.1 Чистый рабочий поток прогнозирования

Поток генерирования прогнозов для данных временных рядов можно разбить на несколько шагов.

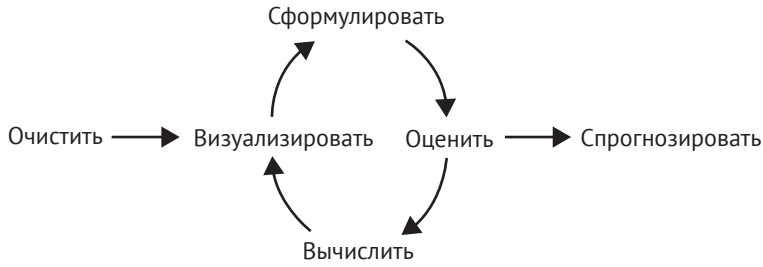


В целях иллюстрации этого потока мы выполним подгонку моделей линейных трендов к данным национального ВВП, хранящимся в `global_economy`.

### Подготовка данных (очистка)

Первым шагом в прогнозировании является подготовка данных в правильном формате. Этот процесс может включать загрузку данных, выявление пропущенных значений, фильтрацию временных рядов и другие задачи предобработки. Функциональность, предоставляемая пакетом twiddle и другими пакетами в tidyverse, существенно упрощает этот шаг.

Многие модели предъявляют разные требования к данным; некоторые требуют, чтобы ряды были упорядочены по времени, другие требуют отсутствия пропущенных значений. Проверка ваших данных является важным шагом к пониманию их признаков, и ее всегда следует проводить до расчета моделей.

Мы будем моделировать ВВП на душу населения с течением времени; поэтому сначала необходимо вычислить релевантную переменную.

```
gdppc <- global_economy %>%
  mutate(GDP_per_capita = GDP / Population)
```

## Построение графика данных (визуализация)

Как мы увидели в главе 2, визуализация является важным шагом в понимании данных. Визуальное изучение ваших данных позволяет выявлять распространенные закономерности и впоследствии формировать подходящую модель.

В нашем примере на рис. 5.1 на график нанесены данные по одной стране.

```
gdppc %>%
  filter(Country == "Sweden") %>%
  autoplot(GdDP_per_capita) +
  labs(y = ""$US", title = "ВВП Швеции на душу населения")
```

**Рисунок 5.1:** Данные ВВП на душу населения в Швеции за период с 1960 по 2017 год

## Определение модели (формулирование)

Для прогнозирования можно использовать целый ряд разных моделей временных рядов, и бóльшая часть этой книги посвящена описанию различных моделей. Формулирование надлежащей модели для данных имеет важное значение для продуцирования надлежащих прогнозов.

Модели в fable задаются с помощью модельных функций, в каждой из которых используется формульный интерфейс (`y ~ x`). Переменная-отклик (переменные-отклики) указывается слева от формулы, а структура модели записывается справа.

Например, модель линейного тренда (которая будет обсуждаться в главе 7) для ВВП на душу населения можно сформулировать следующим образом:

```
TSLM(GDP_per_capita ~ trend()).
```

В данном случае модельной функцией является `TSLM()` (линейная модель временных рядов), переменной-откликом является `GDP_per_capita`, и она моделируется с помощью `trend()` («специальной» функцией, задающей линейный тренд при ее использовании в `TSLM()`). Мы рассмотрим формулирование каждой модели подробнее в соответствующих разделах.

Специальные функции, используемые для формулирования структуры модели, различаются в разных моделях (поскольку каждая модель может поддерживать разные структуры). В разделе «Специальные функции» документации по каждой модельной функции приводится перечень этих специальных функций и перечислены способы их использования.

Левая часть формулы также поддерживает преобразования, рассмотренные в разделе 3.1, которые бывают полезны для упрощения моделей временных рядов или ограничения прогнозов между конкретными значениями (см. раздел 13.3).

## Тренировка модели (вычисление)

После того как подходящая модель была сформулирована, затем мы приступаем к тренировке модели на некоторых данных. С помощью функции `model()` можно оценить одну или несколько формулировок модели.

Для того чтобы рассчитать модель в нашем примере, мы используем

```
fit <- gdppc %>%
  model(trend_model = TSLM(GDP_per_capita ~ trend()))
```

Приведенный выше исходный код выполнит подгонку модели линейного тренда к данным ВВП на душу населения для каждой комбинации переменных-ключей в `twibble`. В этом примере он выполнит подгонку модели для каждой из 263 стран в наборе данных. Результирующий объект представляет собой модельную таблицу, или «mable».

```
fit
#> # A mable: 263 x 2
#> # Key:     Country [263]
#>    Country             trend_model
#>    <fct>                   <model>
#>  1 Afghanistan              <TSLM>
#>  2 Albania                  <TSLM>
#>  3 Algeria                  <TSLM>
#>  4 American Samoa           <TSLM>
#>  5 Andorra                  <TSLM>
#>  6 Angola                   <TSLM>
#>  7 Antigua and Barbuda      <TSLM>
```

```
#>  8 Arab World              <TSLM>
#>  9 Argentina               <TSLM>
#> 10 Armenia                 <TSLM>
#> # … и еще 253 строки
```

Каждая строка соответствует одной комбинации переменных-ключей. Столбец `trend_model` содержит информацию о подходящей модели для каждой страны. В последующих главах мы узнаем о том, какие существуют возможности просматривать дополнительную информацию по каждой модели.

## Проверка результативности модели (оценивание)

После того как модель была подогнана, важно проверить, какую результативность она показывает на данных. Для проверки поведения модели имеется несколько диагностических инструментов, а также меры точности, которые позволяют сравнивать одну модель с другой. Более подробная информация содержится в разделах 5.8 и 5.9.

## Генерирование прогнозов (прогнозирование)

После того как подходящая модель сформулирована, оценена и проверена, пришло время произвести прогнозы с помощью функции `forecast()`. Самый простой способ использования этой функции состоит в указании числа будущих наблюдений, подлежащих прогнозированию. Например, прогнозы для следующих 10 наблюдений можно сгенерировать с использованием `h = 10`. Также можно использовать естественный язык; например, `h = "2 years"` можно использовать для прогнозирования на два года вперед.

В других ситуациях бывает удобнее предоставлять для прогнозирования набор данных о будущих периодах времени. Это обычно требуется, когда в вашей модели используется дополнительная информация из данных, такая как экзогенные регрессоры. Требуемые моделью дополнительные данные можно включить в набор данных наблюдений, подлежащих прогнозированию.

```
fit %>% forecast(h = "3 years")
#> # A fable: 789 x 5 [1Y]
#> # Key:     Country, .model [263]
#>    Country        .model       Year   GDP_per_capita  .mean
#>    <fct>          <chr>       <dbl>           <dist>  <dbl>
#>  1 Afghanistan    trend_model  2018     N(526, 9653)   526.
#>  2 Afghanistan    trend_model  2019     N(534, 9689)   534.
#>  3 Afghanistan    trend_model  2020     N(542, 9727)   542.
#>  4 Albania        trend_model  2018  N(4716, 476419)  4716.
#>  5 Albania        trend_model  2019  N(4867, 481086)  4867.
#>  6 Albania        trend_model  2020  N(5018, 486012)  5018.
#>  7 Algeria        trend_model  2018  N(4410, 643094)  4410.
#>  8 Algeria        trend_model  2019  N(4489, 645311)  4489.
#>  9 Algeria        trend_model  2020  N(4568, 647602)  4568.
```

```
#> 10 American Samoa trend_model  2018 N(12491, 652926) 12491.
#> # … и еще 779 строк
```

Это таблица прогнозов, или «fable». Каждая строка соответствует одному прогнозируемому периоду по каждой стране. Столбец `GDP_per_capita` содержит прогнозное распределение, в то время как столбец `.mean` содержит точечный прогноз. Точечный прогноз – это среднее (или среднеарифметическое) значение прогнозного распределения.

Прогнозы можно наносить на график вместе с историческими данными с помощью `autopilot()` следующим образом.

```
fit %>%
  forecast(h = "3 years") %>%
  filter(Country == "Sweden") %>%
  autoplot(gdppc) +
  labs(y = ""$US", title = "ВВП Швеции на душу населения")
```

**Рисунок 5.2:** Прогнозы ВВП на душу населения для Швеции с использованием простой трендовой модели

## 5.2 Несколько простых методов прогнозирования

Некоторые методы прогнозирования чрезвычайно просты и удивительно эффективны. В этой книге мы будем использовать четыре простых метода прогнозирования в качестве эталонов. В целях их иллюстрации будем использовать ежеквартальное производство глиняного кирпича в Австралии в период с 1970 по 2004 год.

```
bricks <- aus_production %>%
  filter_index("1970 Q1" ~ "2004 Q4") %>%
  select(Bricks)
```

Функция `filter_index()` – это удобная аббревиатура для извлечения части временного ряда.

## Средне-арифметический метод

Здесь прогнозы всех будущих значений равны среднему (или «среднеарифметическому») значению исторических данных. Если обозначить исторические данные через $y_1, \ldots, y_T$, то прогнозы можно будет записывать как

$$\hat{y}_{T+h|T} = \bar{y} = \left(y_1 + \cdots + y_T\right) / T.$$

Нотация $\hat{y}_{T+h|T}$ – это сокращение для оценки $y_{T+h}$, если основываться на данных $y_1, \ldots, y_T$.

```
bricks %>% model(MEAN(Bricks))
```

**Рисунок 5.3:** Средние (или среднеарифметические) прогнозы применительно к производству глиняного кирпича в Австралии

## Наивный метод

В случае наивных прогнозов мы просто устанавливаем для всех прогнозов значение последнего наблюдения. То есть

$$\hat{y}_{T+h|T} = y_T.$$

Этот метод исключительно хорошо работает для многих экономических и финансовых временных рядов.

```
bricks %>% model(NAIVE(Bricks))
```

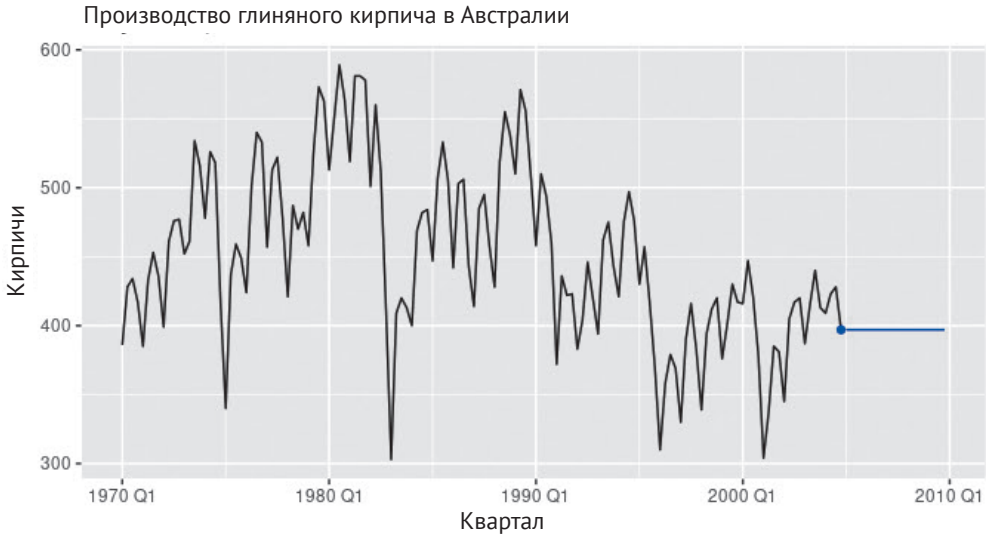


**Рисунок 5.4:** Наивные прогнозы применительно к производству глиняного кирпича в Австралии

Поскольку наивный прогноз является оптимальным, когда данные подчиняются случайному блужданию (см. раздел 9.1), они также называются **прогнозами случайного блуждания**, и вместо функции `NAIVE()` можно использовать функцию `RW()`.

## Сезонный наивный метод

Аналогичный метод полезен для данных с высокой сезонностью. В этом случае мы устанавливаем каждый прогноз равным последнему наблюдаемому значению за тот же сезон (например, за тот же месяц предыдущего года). Формально прогноз на момент времени $T + h$ записывается как

$$\hat{y}_{T+h|T} = y_{T+h-m(k+1)},$$

где $m$ – это сезонный период и $k$ – целочисленная часть $(h - 1)/m$ (т. е. число полных лет в прогнозном периоде до наступления времени $T + h$). Это выглядит сложнее, чем есть на самом деле. Например, при использовании месячных данных прогноз для всех будущих значений за февраль равен последнему наблюдаемому значению за февраль. При использовании квартальных данных прогноз всех будущих значений Q2 равен последнему наблюдаемому значению Q2 (где Q2 означает второй квартал). Аналогичные правила применяются и для других месяцев и кварталов, а также для других сезонных периодов.

```
bricks %>% model(SNAIVE(Bricks ~ lag("year")))
```

Функция `log()` здесь опциональна, поскольку это квартальные данные, и поэтому для сезонного наивного метода потребуется годичная давность. Однако для некоторых временных рядов существует более одного сезонного периода, и тогда необходимо указывать требуемый лаг.

**Рисунок 5.5:** Сезонные наивные прогнозы применительно к производству глиняного кирпича в Австралии

## Дрейфовый метод

Данный вариант наивного метода разрешает прогнозам увеличиваться или уменьшаться с течением времени, где величина изменения с течением времени (именуемая дрейфом) устанавливается как среднее изменение, наблюдаемое в исторических данных. Таким образом, прогноз на момент времени $T + h$ задается формулой

$$\hat{y}_{T+h|T} = y_T + \frac{h}{T-1}\sum_{t=2}^{T}\left(y_t - y_{t-1}\right) = y_T + h\left(\frac{y_T - y_1}{T-1}\right).$$

Это эквивалентно проведению черты между первым и последним наблюдениями и экстраполированию ее на будущее.

```
bricks %>% model(RW(Bricks ~ drift()))
```

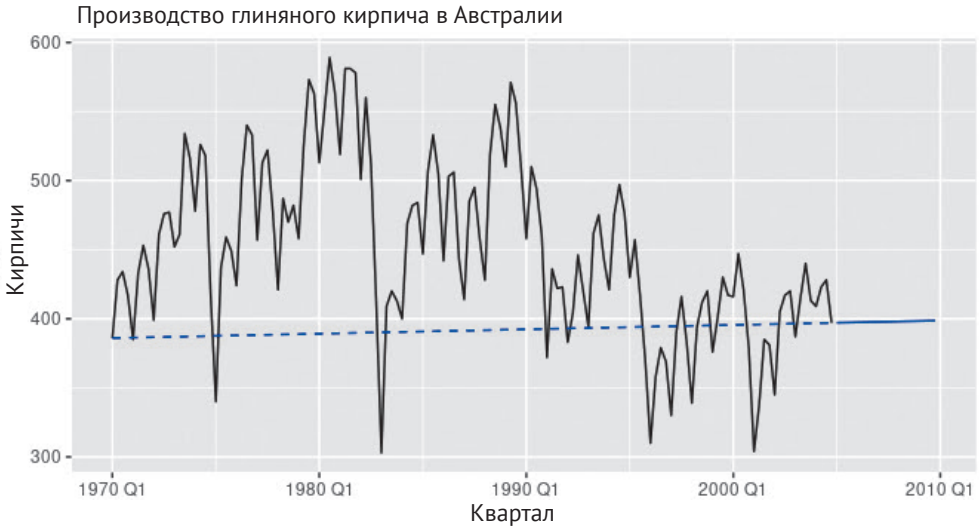


**Рисунок 5.6:** Дрейфовые прогнозы применительно к производству глиняного кирпича в Австралии

## Пример: ежеквартальное производство пива в Австралии

На рис. 5.7 показаны первые три метода применительно к ежеквартальному производству пива в Австралии с 1992 по 2006 год, при этом прогнозы сравниваются с фактическими значениями в следующие 3.5 года.

```
# Задать тренировочные данные с 1992 по 2006 год
train <- aus_production %>%
  filter_index("1992 Q1" ~ "2006 Q4")
# Выполнить подгонку моделей
beer_fit <- train %>%
  model(
    Mean = MEAN(Beer),
    `Naïve` = NAIVE(Beer),
    `Seasonal naïve` = SNAIVE(Beer)
  )
# Сгенерировать прогнозы на 14 кварталов
beer_fc <- beer_fit %>% forecast(h = 14)
# Нанести прогнозы на график в сопоставлении с фактическими значениями
beer_fc %>%
  autoplot(train, level = NULL) +
  autolayer(
    filter_index(aus_production, "2007 Q1" ~ .),
    colour = "black"
  ) +
```

```
  labs(
    y = "Мегалитры",
    title = "Прогнозы ежеквартального производства пива"
  ) +
  guides(colour = guide_legend(title = "Прогноз"))
```

**Рисунок 5.7:** Прогнозы ежеквартального производства пива в Австралии

В данном случае только сезонные наивные прогнозы близки к значениям, наблюдаемым с 2007 года и далее.

## Пример: ежедневная цена акций Google на момент закрытия торгов

На рис. 5.8 несезонные методы применяются к ежедневной цене акций Google на момент закрытия торгового периода в 2015 году и используются для прогнозирования на месяц вперед. Поскольку цены акций наблюдаются не каждый день, мы сначала настраиваем новый индекс времени, основанный не на календарных днях, а на торговых.

```
# Переиндексировать, основываясь на торговых днях
google_stock <- gafa_stock %>%
  filter(Symbol == "GOOG", year(Date) >= 2015) %>%
  mutate(day = row_number()) %>%
  update_tsibble(index = day, regular = TRUE)
# Отфильтровать интересующий год
google_2015 <- google_stock %>% filter(year(Date) == 2015)
# Выполнить подгонку моделей
google_fit <- google_2015 %>%
  model(
    Mean = MEAN(Close),
    `Naïve` = NAIVE(Close),
    Drift = NAIVE(Close ~ drift())
  )
```

```
# Произвести прогнозы на торговые дни в январе 2016
google_jan_2016 <- google_stock %>%
  filter(yearmonth(Date) == yearmonth("2016 Jan"))
google_fc <- google_fit %>%
  forecast(new_data = google_jan_2016)
# Нанести прогнозы на график
google_fc %>%
  autoplot(google_2015, level = NULL) +
  autolayer(google_jan_2016, Close, colour = "black") +
  labs(y = "$US",
       title = "Ежедневная цена акций Google на момент закрытия торгов",
       subtitle = "(Янв. 2015 – Янв. 2016)") +
  guides(colour = guide_legend(title = "Прогноз"))
```

**Рисунок 5.8:** Прогнозы, основанные на ежедневной цене акций Google на момент закрытия торгового периода в 2015 году

Иногда один из этих простых методов будет самым лучшим из имеющихся методов прогнозирования; но во многих случаях эти методы будут служить в качестве эталона, а не предпочтительного метода. То есть любые методы прогнозирования, которые мы разрабатываем, будут сопоставляться с этими простыми методами с целью обеспечения того, чтобы новый метод был лучше, чем эти простые альтернативы. Если это не так, то новый метод рассматривать не стоит.

# 5.3 Подогнанные значения и остатки

## Подогнанные значения

Каждое наблюдение во временном ряду можно прогнозировать с использованием всех предыдущих наблюдений. Мы называем их **подогнанными значениями**, и они обозначаются через $\hat{y}_{t|t-1}$. А такая запись означает прогноз наблюдения $y_t$, основываясь на наблюдениях $y_1, \ldots, y_{t-1}$. Подогнанные значения используются так часто, что иногда часть нижнего индекса отбрасыва-

ется и вместо $\hat{y}_{t|t-1}$ просто пишется $\hat{y}_t$. Подогнанные значения почти всегда предусматривают одношаговые прогнозы, т. е. на один шаг вперед (но см. раздел 13.8).

На деле подогнанные значения зачастую не являются истинными прогнозами, поскольку любые параметры, участвующие в методе прогнозирования, оцениваются с использованием всех доступных наблюдений во временном ряду, включая будущие наблюдения. Например, если мы используем метод среднего, то подогнанные значения задаются формулой

$$\hat{y}_t = \hat{c},$$

где $\hat{c}$ – это среднее значение, вычисленное по всем имеющимся наблюдениям, включая наблюдения в моменты времени после $t$. Для дрейфового метода параметр дрейфа оценивается аналогичным образом с использованием всех имеющихся наблюдений. В этом случае подогнанные значения задаются формулой

$$\hat{y}_t = y_{t-1} + \hat{c},$$

где $\hat{c} = (y_T - y_1)/(T-1)$. В обоих случаях существует параметр, который необходимо оценивать из данных. «Шляпка» над $c$ напоминает о том, что это приближенная оценка. Когда оценка $c$ включает наблюдения после времени $t$, то подогнанные значения не являются истинными прогнозами. С другой стороны, наивные или сезонные наивные прогнозы не предусматривают никаких параметров, и поэтому подогнанные значения в таких случаях являются истинными прогнозами.

## Остатки

«Остатки» в модели временного ряда – это то, что остается после подгонки модели. Остатки равны разнице между наблюдениями и соответствующими подогнанными значениями:

$$e_t = y_t - \widehat{y_t}.$$

Если в модели было использовано преобразование, то нередко бывает полезно посмотреть на остатки в преобразованной шкале. Мы называем их «**остатками инноваций**» (реже инновационными остатками). Например, предположим, что мы смоделировали логарифмы данных, $w_t = \log(y_t)$. Тогда остатки инноваций задаются через $w_t - \widehat{w}_t$, тогда как регулярные остатки задаются через $y_t - \widehat{y_t}$. (См. раздел 5.6, где излагается о том, как в прогнозировании используются преобразования.) Если преобразование не использовалось, то остатки инноваций идентичны обычным остаткам, и в таких случаях мы будем просто называть их «остатками»[1].

[1] Для справки: в зарубежной специализированной литературе по анализу временных рядов под инновацией (новизной, нововведением) нередко подразумевается ошибка одношагового прогноза. См. *https://www.researchgate.net/publication/314079379_Linear_Innovations_State_Space_Models*. – *Прим. перев.*

Подогнанные значения и остатки от модели можно получить с помощью функции `augment()`. В примере производства пива из раздела 5.2 мы сохранили подогнанные модели как `beer_fit`. И поэтому к данному объекту можно беспрепятственно применить функцию `augment()`, чтобы вычислить подогнанные значения и остатки для всех моделей.

```
augment(beer_fit)
#> # A tsibble: 180 x 6 [1Q]
#> # Key:       .model [3]
#>    .model Quarter  Beer .fitted .resid .innov
#>    <chr>    <qtr> <dbl>   <dbl>  <dbl>  <dbl>
#>  1 Mean   1992 Q1   443    436.   6.55   6.55
#>  2 Mean   1992 Q2   410    436. -26.4  -26.4
#>  3 Mean   1992 Q3   420    436. -16.4  -16.4
#>  4 Mean   1992 Q4   532    436.  95.6   95.6
#>  5 Mean   1993 Q1   433    436.  -3.45  -3.45
#>  6 Mean   1993 Q2   421    436. -15.4  -15.4
#>  7 Mean   1993 Q3   410    436. -26.4  -26.4
#>  8 Mean   1993 Q4   512    436.  75.6   75.6
#>  9 Mean   1994 Q1   449    436.  12.6   12.6
#> 10 Mean   1994 Q2   381    436. -55.4  -55.4
#> # … и еще 170 строк
```

К изначальным данным добавлены три новых столбца:

- `.fitted` содержит подогнанные значения;
- `.resid` содержит остатки;
- `.innov` содержит «инновационные остатки», которые в данном случае идентичны обычным остаткам.

Остатки широко применяются для проверки адекватности модели в том, как она отразила информацию, содержащуюся в данных. Для этой цели мы используем остатки инноваций.

Если в остатках инноваций наблюдаются закономерности, то модель, вероятно, может быть усовершенствована. В следующем .далее разделе мы рассмотрим некоторые инструменты, служащие для проведения разведывательного анализа закономерностей в остатках.

## 5.4 Диагностика остатков

Хороший метод прогнозирования будет давать остатки инноваций со следующими ниже свойствами:

1) остатки инноваций некоррелированы. Если между остатками инноваций есть корреляции, то в остатках остается информация, которую следует использовать при расчете прогнозов;
2) остатки инноваций имеют нулевое среднее значение. Если они имеют среднее значение, отличное от нуля, то прогнозы смещены.

Любой метод прогнозирования, который не удовлетворяет этим свойствам, может быть усовершенствован. Однако это не означает, что методы прогнозирования, удовлетворяющие этим свойствам, не могут быть усовершенствованы. Для одного и того же набора данных можно использовать несколько разных методов прогнозирования, все из которых удовлетворяют этим свойствам. Проверка указанных выше свойств важна для того, чтобы увидеть, использует метод всю имеющуюся информацию или нет, но это не очень хороший способ выбора метода прогнозирования.

Если какое-либо из этих свойств не удовлетворяется, то метод прогнозирования может быть модифицирован, чтобы получать более точные прогнозы. Поправка на смещение проста: если остатки имеют среднее значение $m$, тогда из всех прогнозов просто нужно вычесть $m$, и проблема смещения будет решена. Решить проблему корреляции сложнее, и мы не будем рассматривать ее до главы 10.

В дополнение к этим существенным свойствам полезно (но не обязательно), чтобы остатки также обладали следующими ниже двумя свойствами:

1) остатки инноваций имеют постоянную дисперсию. Это свойство называется «гомоскедастичностью»;
2) остатки инноваций нормально распределены.

Приведенные выше два свойства упрощают вычисление предсказательных интервалов (пример см. в разделе 5.5). Однако метод прогнозирования, который не удовлетворяет этим свойствам, не обязательно может быть усовершенствован. Иногда применение преобразования Бокса–Кокса помогает получить эти свойства, но в противном случае обычно мало что можно сделать, чтобы обеспечить постоянную дисперсию и нормальное распределение ваших остатков инноваций. Вместо этого необходим альтернативный подход к получению предсказательных интервалов. В разделе 5.5 мы покажем, как работать с ненормальными остатками инноваций.

## Пример: прогнозирование цен акций Google на момент закрытия торгов

Мы продолжим с примером цены акций Google на момент закрытия торгового периода из раздела 5.2. Для цен и индексов фондового рынка самым лучшим методом прогнозирования часто является наивный метод. То есть каждый прогноз просто равен последнему наблюдаемому значению, или $\hat{y}_t = y_{t-1}$ . Следовательно, остатки просто равны разнице между поочередными наблюдениями:

$$e_t = y_t - \hat{y}_t = y_t - y_{t-1}.$$

На следующем ниже графике показана ежедневная цена акций Google на момент закрытия торгового периода за торговые дни в течение 2015 года. Большой скачок соответствует 17 июля 2015 года, когда цена подскочила на 16 % из-за неожиданно сильных результатов второго квартала. (Объект `google_2015` был создан в разделе 5.2.)

```
autoplot(google_2015, Close) +
  labs(y = "Доллары США",
       title = "Ежедневные цены акций Google на момент закрытия в 2015 г.")
```

**Рисунок 5.9:** Ежедневные цены акций Google в 2015 году

Остатки от прогнозирования этого ряда с использованием наивного метода показаны на рис. 5.10. Большой положительный остаток является результатом неожиданного скачка цен в июле.

```
aug <- google_2015 %>%
  model(NAIVE(Close)) %>%
  augment()
autoplot(aug, .innov) +
  labs(y = "$US",
       title = "Остатки от наивного метода")
```

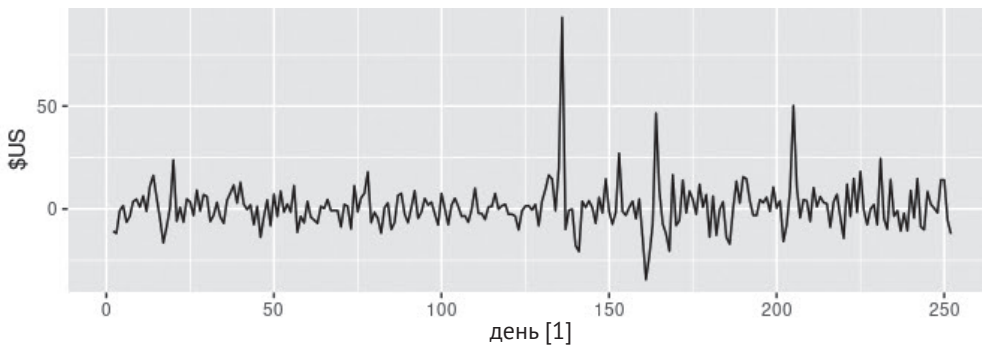


**Рисунок 5.10:** Остатки от прогнозирования цены акций Google с использованием наивного метода

```
aug %>%
  ggplot(aes(x = .innov)) +
  geom_histogram() +
  labs(title = "Гистограмма остатков")
```

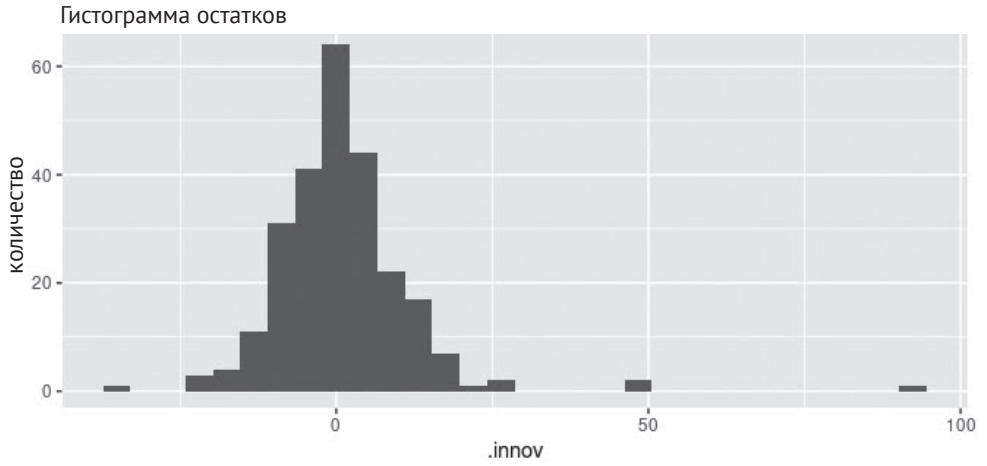


**Рисунок 5.11:** Гистограмма остатков от наивного метода применительно к цене акций Google. Правый хвост выглядит для нормального распределения немного длинноватым

```
aug %>%
  ACF(.innov) %>%
  autoplot() +
  labs(title = "Остатки от наивного метода")
```

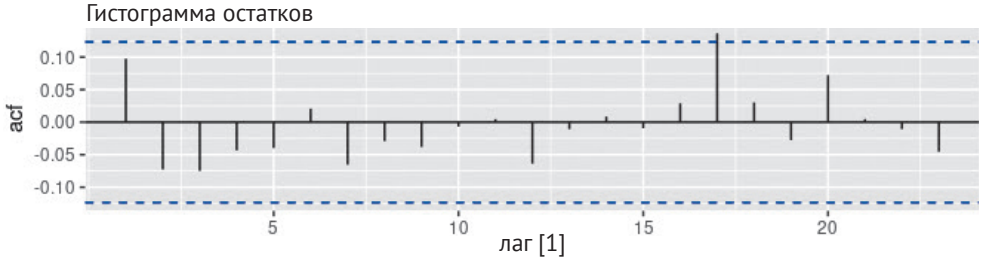


**Рисунок 5.12:** ACF остатков от наивного метода применительно к цене акций Google. Отсутствие корреляции говорит о том, что прогнозы хорошие

Приведенные выше графики показывают, что наивный метод дает прогнозы, которые, по-видимому, учитывают всю имеющуюся информацию. Среднее значение остатков близко к нулю, и в рядах остатков нет значимой корреляции. Временной график остатков показывает, что вариация остатков остается практически одинаковой по всем историческим данным, за исключением одного выброса, и поэтому дисперсия остатков может рассматриваться как константа. Это также можно увидеть на гистограмме остатков. Указанная гисто-

грамма предполагает, что остатки могут быть ненормальными – правый хвост выглядит слишком длинным, даже если игнорировать выброс. Следовательно, прогнозы из этого метода, вероятно, будут довольно хорошими, но предсказательные интервалы, которые вычисляются исходя из допущения о нормальности распределения, могут быть неточными.

Удобной аббревиатурой для продуцирования этих диагностических графиков остатков является функция `gg_tsresiduals()`, которая будет генерировать график времени, график ACF и гистограмму остатков.

```
google_2015 %>%
  model(NAIVE(Close)) %>%
  gg_tsresiduals()
```

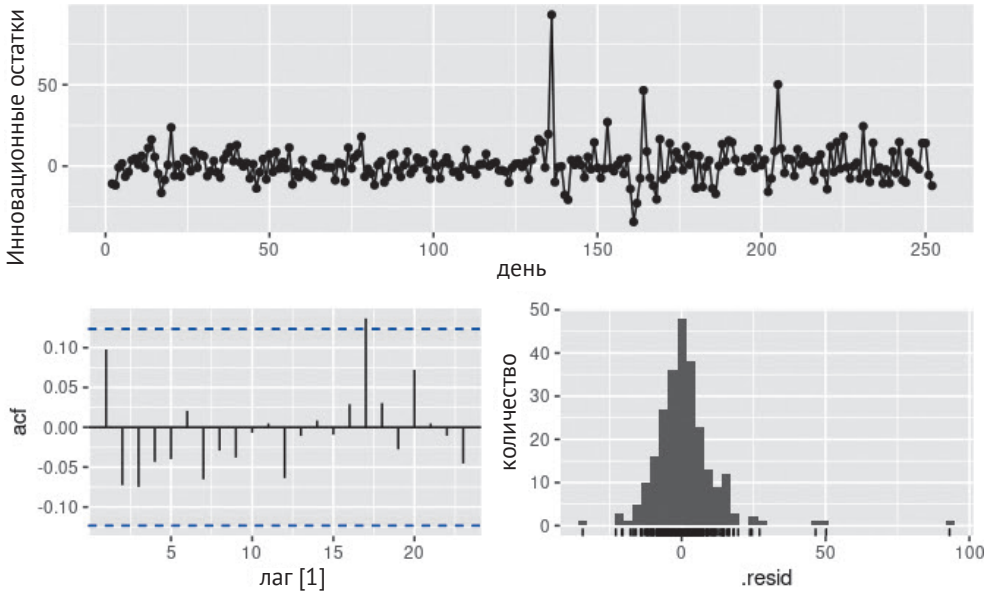


**Рисунок 5.13:** Диагностические графики остатков для наивного метода применительно к цене акций Google

## Тесты портманто на автокорреляцию

В дополнение к просмотру графика ACF мы также можем провести более формальный тест на автокорреляцию, рассматривая весь набор значений $r_k$ как группу, вместо того чтобы разбирать каждое из них отдельно.

Вспомните, что $r_k$ – это автокорреляция для лага $k$. Когда мы смотрим на график ACF, чтобы увидеть, находится ли каждый всплеск в требуемых пределах, мы неявно выполняем несколько проверок гипотез, каждый из которых с небольшой вероятностью дает ложноположительный результат. Когда будет проведено достаточное число таких проверок, вполне вероятно, что по крайней мере один даст ложноположительный результат, и поэтому мы решим сделать вывод о том, что остатки имеют некоторую автокорреляцию остатков, хотя на самом деле это не так.

В целях преодоления этой проблемы мы проводим тестирование на предмет значимого отличия первых $l$ автокорреляций от того, что можно было бы ожидать от процесса белого шума. Тест для группы автокорреляций называется **тестом портманто**, от французского слова, описывающего чемодан или вешалку, на которой висит несколько предметов одежды[1].

Одним из таких тестов является **тест Бокса–Пирса**, основанный на следующей ниже статистике:

$$Q = T\sum_{k=1}^{\ell} r_k^2,$$

где $l$ – это рассматриваемый максимальный лаг, $T$ – число наблюдений. Если каждая $r_k$ близка к нулю, то $Q$ будет малым. Если некоторые значения $r_k$ большие (положительные либо отрицательные), то $Q$ будет большим. Мы предлагаем использовать $l = 10$ для несезонных данных и $l = 2m$ для сезонных данных, где $m$ – это период сезонности. Однако тест не будет хорошим, когда $l$ является большим, поэтому если указанные значения больше $T/5$, то следует использовать $l = T/5$.

Родственным (и более точным) тестом является **тест Льюнга–Бокса**, основанный на

$$Q^* = T(T+2)\sum_{k=1}^{\ell}(T-k)^{-1} r_k^2.$$

Опять же, большие значения $Q^*$ говорят о том, что автокорреляции не поступают из ряда белого шума.

Насколько большой – это слишком большой? Если автокорреляции действительно поступают из ряда белого шума, то и $Q$, и $Q^*$ будут оба иметь распределение $\chi^2$ с $(l – K)$ степенями свободы, где $K$ – это число параметров в модели. Если они рассчитываются на основе сырых данных (а не остатков от модели), то следует установить $K = 0$.

В примере с ценой акций Google наивный метод не имеет параметров, и, значит, в этом случае $K = 0$ тоже. В следующем ниже исходном коде `lag` представляет $l$ и `dof` представляет $K$.

```
aug %>% features(.innov, box_pierce, lag = 10, dof = 0)
#> # A tibble: 1 × 4
#>   Symbol .model       bp_stat bp_pvalue
#>   <chr>  <chr>          <dbl>     <dbl>
#> 1 GOOG   NAIVE(Close)    7.74     0.654
```

[1] Для справки: статистика теста портманто (portmanteau test statistic) применяется для обнаружения нестационарности временного ряда. Указанная статистика выводится из логарифма определителя $m$-й блочной матрицы автокорреляций и перекрестных корреляций. – *Прим. перев.*

```
aug %>% features(.innov, ljung_box, lag = 10, dof = 0)
#> # A tibble: 1 × 4
#>   Symbol .model       lb_stat lb_pvalue
#>   <chr>  <chr>          <dbl>     <dbl>
#> 1 GOOG   NAIVE(Close)    7.91     0.637
```

Для $Q$ и $Q^*$ результаты не являются значимыми (т. е. $p$-значения относительно велики). Отсюда можно сделать вывод о том, что остатки неотличимы от ряда белого шума.

Альтернативным простым подходом, который может подходить для прогнозирования цены акций Google на момент закрытия торгов, является дрейфовый метод. Функция `tidy()` показывает один оцениваемый параметр, коэффициент дрейфа, измеряющий среднедневное изменение, наблюдаемое в исторических данных.

```
fit <- google_2015 %>% model(RW(Close ~ drift()))
tidy(fit)
#> # A tibble: 1 × 7
#>   Symbol .model              term  estimate std.error statistic p.value
#>   <chr>  <chr>               <chr>    <dbl>     <dbl>     <dbl>   <dbl>
#> 1 GOOG   RW(Close ~ drift()) b        0.944     0.705      1.34   0.182
```

Применяя тест Льюнга–Бокса, мы устанавливаем $K$ –1 для учета оцениваемого параметра.

```
augment(fit) %>% features(.innov, ljung_box, lag=10, dof=1)
#> # A tibble: 1 × 4
#>   Symbol .model              lb_stat lb_pvalue
#>   <chr>  <chr>                 <dbl>     <dbl>
#> 1 GOOG   RW(Close ~ drift())    7.91     0.543
```

Как и в случае с наивным методом, остатки от дрейфового метода неотличимы от ряда белого шума.

## 5.5 Распределительные прогнозы и предсказательные интервалы

### Прогнозные распределения

Как обсуждалось в разделе 1.7, мы выражаем неопределенность в прогнозах, используя распределение вероятностей. Оно описывает вероятность наблюдать возможные будущие значения, используя подогнанную модель. Точечный прогноз – это среднее значение такого распределения. Большинство моделей временных рядов дают нормально распределенные прогнозы, то есть мы исходим из допущения о том, что распределение возможных будущих значений подчиняется нормальному распределению. Позже в этом разделе мы рассмотрим несколько альтернатив нормальным распределениям.

## Предсказательные интервалы

Предсказательный интервал дает интервал, в пределах которого мы ожидаем, что $y_t$ будет лежать с заданной вероятностью. Например, допуская, что распределение будущих наблюдений является нормальным, 95%-ный предсказательный интервал для прогноза на $h$ шагов вперед равен

$$\hat{y}_{T+h|T} \pm 1.96\hat{\sigma}_h,$$

где $\hat{\sigma}_h$ – это оценка стандартного отклонения распределения $h$-шаговых прогнозов.

В более общем случае предсказательный интервал можно записать как

$$\hat{y}_{T+h|T} \pm c\hat{\sigma}_h,$$

где множитель $c$ зависит от вероятности покрытия. В этой книге мы обычно рассчитываем 80%-ные и 95%-ные интервалы, хотя можно использовать любой процент. В табл. 5.1 приведено значение $c$ для диапазона вероятностей покрытия, исходя из допущения о нормальности прогнозного распределения.

**Таблица 5.1:** Множители, используемые для предсказательных интервалов

| Процент | Множитель |
|---|---|
| 50 | 0.67 |
| 55 | 0.76 |
| 60 | 0.84 |
| 65 | 0.93 |
| 70 | 1.04 |
| 75 | 1.15 |
| 80 | 1.28 |
| 85 | 1.44 |
| 90 | 1.64 |
| 95 | 1.96 |
| 96 | 2.05 |
| 97 | 2.17 |
| 98 | 2.33 |
| 99 | 2.58 |

Ценность предсказательных интервалов заключается в том, что они выражают неопределенность в прогнозах. Если мы продуцируем только точечные прогнозы, то нет ни единой возможности сказать, насколько точны эти прогнозы. Однако если мы также создадим предсказательные интервалы, то станет ясно, какая степень неопределенности связана с каждым прогнозом. По этой причине точечные прогнозы бывают практически бесполезны без сопутствующих предсказательных интервалов.

## Одношаговые предсказательные интервалы

При прогнозировании на шаг вперед стандартное отклонение прогнозного распределения можно оценить с использованием стандартного отклонения остатков, задаваемого формулой

$$\hat{\sigma} = \sqrt{\frac{1}{T-K}\sum_{t=1}^{T} e_t^2}, \tag{5.1}$$

где $K$ – это число параметров, оцениваемых в методе прогнозирования.

Например, рассмотрим наивный прогноз для данных о ценах акций Google `google_2015` (показан на рис. 5.8). Последнее значение наблюдаемого ряда равно 758.88, поэтому прогноз следующего значения цены составляет 758.88. Стандартное отклонение остатков от наивного метода, как указано в уравнении (5.1), равно 11.19. Следовательно, 95%-ный предсказательный интервал для следующего значения цены акции Google составляет

$$758.88 \pm 1.96(11.19) = [736.9,780.8].$$

Аналогичным образом 80%-ный предсказательный интервал задается через

$$758.88 \pm 1.28(11.19) = [744.5,773.2].$$

Значение множителя (1.96 либо 1.28) взято из табл. 5.1.

## Многошаговые предсказательные интервалы

Общей особенностью предсказательных интервалов является то, что они обычно увеличиваются по мере увеличения прогнозного горизонта. Чем дальше мы прогнозируем, тем больше неопределенности связано с прогнозом и, следовательно, тем шире предсказательные интервалы. То есть $\sigma_h$ обычно увеличивается с увеличением $h$ (хотя существуют некоторые нелинейные методы прогнозирования, которые не обладают этим свойством).

Для генерирования предсказательного интервала необходимо иметь оценку $\sigma_h$. Как уже отмечалось, для одношаговых прогнозов ($h = 1$) уравнение (5.1) дает хорошую оценку прогнозного стандартного отклонения $\sigma_1$. Для многошаговых прогнозов требуется более сложный метод расчета. Указанные расчеты основываются на допущении о том, что остатки некоррелированы.

## Эталонные методы

Для четырех эталонных методов прогнозное стандартное отклонение в рамках допущения о некоррелированных остатках можно вывести математически. Если $\sigma_h$ обозначает стандартное отклонение распределения $h$-шаговых прогнозов и $\hat{\sigma}$ – стандартное отклонение остатков, заданное формулой (5.1), то можно использовать выражения, приведенные в табл. 5.2. Обратите внимание, что при $h = 1$ и крупном $T$ все они дают одинаковое приближенное значение $\hat{\sigma}$.

**Таблица 5.2:** Стандартное отклонение многошагового прогноза для четырех эталонных методов, где $\sigma$ – это стандартное отклонение остатков, $m$ – сезонный период, $k$ – целочисленная часть $(h-1)/m$ (т. е. число полных лет в прогнозном периоде до наступления времени $T+h$)

| Эталонный метод | Стандартное отклонение $h$-шаговых прогнозов |
|---|---|
| Среднего значения | $\hat{\sigma}_h = \hat{\sigma}\sqrt{1+1/T}$ |
| Наивный | $\hat{\sigma}_h = \hat{\sigma}\sqrt{h}$ |
| Сезонный наивный | $\hat{\sigma}_h = \hat{\sigma}\sqrt{k+1}$ |
| Дрейфовый | $\hat{\sigma}_h = \hat{\sigma}\sqrt{h(1+h/T)}$ |

При использовании пакета fable предсказательные интервалы могут легко вычисляться за вас. Например, ниже приведен результат при использовании наивного метода для цены акций Google.

```
google_2015 %>%
  model(NAIVE(Close)) %>%
  forecast(h = 10) %>%
  hilo()
#> # A tsibble: 10 x 7 [1]
#> # Key:       Symbol, .model [1]
#>    Symbol .model      day        Close .mean            `80%`            `95%`
#>    <chr>  <chr>     <dbl>       <dist> <dbl>           <hilo>           <hilo>
#>  1 GOOG   NAIVE(Cl…   253  N(759, 125)  759. [744.5, 773.2]80 [736.9, 780.8]95
#>  2 GOOG   NAIVE(Cl…   254  N(759, 250)  759. [738.6, 779.2]80 [727.9, 789.9]95
#>  3 GOOG   NAIVE(Cl…   255  N(759, 376)  759. [734.0, 783.7]80 [720.9, 796.9]95
#>  4 GOOG   NAIVE(Cl…   256  N(759, 501)  759. [730.2, 787.6]80 [715.0, 802.7]95
#>  5 GOOG   NAIVE(Cl…   257  N(759, 626)  759. [726.8, 790.9]80 [709.8, 807.9]95
#>  6 GOOG   NAIVE(Cl…   258  N(759, 751)  759. [723.8, 794.0]80 [705.2, 812.6]95
#>  7 GOOG   NAIVE(Cl…   259  N(759, 876)  759. [720.9, 796.8]80 [700.9, 816.9]95
#>  8 GOOG   NAIVE(Cl…   260 N(759, 1002)  759. [718.3, 799.4]80 [696.8, 820.9]95
#>  9 GOOG   NAIVE(Cl…   261 N(759, 1127)  759. [715.9, 801.9]80 [693.1, 824.7]95
#> 10 GOOG   NAIVE(Cl…   262 N(759, 1252)  759. [713.5, 804.2]80 [689.5, 828.2]95
```

Функция `hilo()` преобразовывает прогнозные распределения в интервалы. По умолчанию возвращаются 80%-ный и 95%-ный прогнозные интервалы, хотя посредством аргумента `level` возможны и другие варианты.

При построении графика прогнозные интервалы показываются в виде заштрихованных участков, при этом интенсивность цвета указывает на связанную с интервалом вероятность. Опять же, по умолчанию показываются 80%-ный и 95%-ный интервалы, а другие параметры доступны посредством аргумента `level`.

```
google_2015 %>%
  model(NAIVE(Close)) %>%
  forecast(h = 10) %>%
  autoplot(google_2015) +
  labs(title="Ежедневная цена акций Google на момент закрытия торгов",
       y="$US")
```

**Рисунок 5.14:** 80%-ный и 95%-ный предсказательные интервалы для цены акций Google на момент закрытия торгового периода на основе наивного метода

## Предсказательные интервалы из бутстрапированных остатков

Когда допущение о нормальности распределения остатков является необоснованным, одной из альтернатив выступает использование бутстрапирования, которое основано только на допущении о том, что остатки некоррелированы с постоянной дисперсией.

Ошибка одношагового прогноза определяется как $e_t = y_t - \hat{y}_{t|t-1}$. Это можно переписать как

$$y_t = \hat{y}_{t|t-1} + e_t.$$

И поэтому следующее наблюдение временного ряда можно просимулировать, используя

$$y_{T+1} = \hat{y}_{T+1|T} + e_{T+1},$$

где $\hat{y}_{T+1|T}$ – это одношаговый прогноз, а $e_{T+1}$ – неизвестная будущая ошибка. Исходя из допущения о том, что будущие ошибки будут похожи на прошлые ошибки, можно заменить $e_{T+1}$ путем отбора из коллекции ошибок, которые мы

видели в прошлом (т. е. остатков). Добавив новое симулированное наблюдение в набор данных, можно повторить процесс, чтобы получить

$$y_{T+2} = \hat{y}_{T+2|T+1} + e_{T+2},$$

где $e_{T+2}$ – это еще одно извлечение из коллекции остатков. Продолжая в том же ключе, можно просимулировать весь набор будущих значений временного ряда.

Делая это неоднократно, мы получаем множество возможных вариантов будущего. Для того чтобы увидеть некоторые из них, можно применить функцию `generate()`.

```
fit <- google_2015 %>%
  model(NAIVE(Close))
sim <- fit %>% generate(h = 30, times = 5, bootstrap = TRUE)
sim
#> # A tsibble: 150 x 5 [1]
#> # Key:       Symbol, .model, .rep [5]
#>    Symbol .model         day .rep   .sim
#>    <chr>  <chr>        <dbl> <chr> <dbl>
#>  1 GOOG   NAIVE(Close)   253 1      756.
#>  2 GOOG   NAIVE(Close)   254 1      749.
#>  3 GOOG   NAIVE(Close)   255 1      751.
#>  4 GOOG   NAIVE(Close)   256 1      750.
#>  5 GOOG   NAIVE(Close)   257 1      754.
#>  6 GOOG   NAIVE(Close)   258 1      754.
#>  7 GOOG   NAIVE(Close)   259 1      758.
#>  8 GOOG   NAIVE(Close)   260 1      763.
#>  9 GOOG   NAIVE(Close)   261 1      759.
#> 10 GOOG   NAIVE(Close)   262 1      748.
#> # … еще 140 строк
```

Здесь мы сгенерировали пять возможных путей выборки[1] на следующие 30 торговых дней. Переменная `.rep` предоставляет новый ключ для twibble. На приведенном ниже графике показаны пять путей выборки вместе с историческими данными.

```
google_2015 %>%
  ggplot(aes(x = day)) +
  geom_line(aes(y = Close)) +
  geom_line(aes(y = .sim, colour = as.factor(.rep)),
    data = sim) +
```

[1] Путь выборки (sample path) – это многомерная выборка будущих результатов, выводимая из параметрического распределения либо из непараметрической модели. – *Прим. перев.*

```
labs(title="Ежедневная цена акций Google на момент закрытия торгов",
       y="$US") +
  guides(colour = "none")
```

**Рисунок 5.15:** Пять просимулированных будущих путей выборки в отношении цены акций Google на момент закрытия торгового периода на основе наивного метода с бутстрапированными остатками

Обратите внимание, что прогнозное распределение теперь представлено как симуляция с 5000 путей выборки. Поскольку нет допущения о нормальности, предсказательные интервалы не являются симметричными. Столбец `.mean` – это среднее значение бутстраповских выборок, поэтому оно может слегка отличаться от результатов, полученных без бутстрапа.

```
autoplot(fc, google_2015) +
  labs(title="Ежедневная цена акций Google на момент закрытия торгов",
       y="$US")
```

**Рисунок 5.16:** Прогнозы цены акций Google на момент закрытия торгов, основанные на наивном методе с бутстрапированными остатками

Числом выборок можно управлять, используя аргумент `times` в функции `forecast()`. Например, интервалы, основанные на 1000 бутстраповских выборок, можно отобрать с помощью:

```
google_2015 %>%
  model(NAIVE(Close)) %>%
  forecast(h = 10, bootstrap = TRUE, times = 1000) %>%
  hilo()
#> # A tsibble: 10 x 7 [1]
#> # Key:       Symbol, .model [1]
#>    Symbol .model      day        Close .mean            `80%`            `95%`
#>    <chr>  <chr>     <dbl>       <dist> <dbl>           <hilo>           <hilo>
#>  1 GOOG   NAIVE(Cl…   253 sample[1000]  760. [748.2, 770.8]80 [743.9, 777.6]95
#>  2 GOOG   NAIVE(Cl…   254 sample[1000]  760. [743.9, 776.1]80 [734.1, 801.6]95
#>  3 GOOG   NAIVE(Cl…   255 sample[1000]  760. [739.5, 781.7]80 [728.6, 809.0]95
#>  4 GOOG   NAIVE(Cl…   256 sample[1000]  760. [736.7, 784.7]80 [723.4, 813.1]95
#>  5 GOOG   NAIVE(Cl…   257 sample[1000]  760. [734.4, 787.2]80 [719.4, 819.7]95
#>  6 GOOG   NAIVE(Cl…   258 sample[1000]  760. [731.5, 790.2]80 [717.8, 820.3]95
#>  7 GOOG   NAIVE(Cl…   259 sample[1000]  761. [730.4, 793.0]80 [713.0, 826.3]95
#>  8 GOOG   NAIVE(Cl…   260 sample[1000]  761. [726.2, 796.2]80 [706.3, 830.7]95
#>  9 GOOG   NAIVE(Cl…   261 sample[1000]  761. [723.5, 800.2]80 [707.5, 841.0]95
#> 10 GOOG   NAIVE(Cl…   262 sample[1000]  760. [719.2, 801.8]80 [701.9, 841.4]95
```

В данном случае они аналогичны (но не идентичны) предсказательным интервалам, основанным на нормальном распределении.

Используйте ползунок на виджете, чтобы увидеть влияние изменения числа бутстраповских выборок (раз) на распределение прогнозов[1]:

[1] В онлайновой версии данной книги величину выборки можно задавать динамически. – *Прим. перев.*

## 5.6 Прогнозирование с использованием преобразований

Некоторые часто встречающиеся преобразования, которые можно использовать при моделировании, обсуждались в разделе 3.1. При прогнозировании из модели с преобразованиями мы сначала производим прогнозы преобразованных данных. Затем необходимо обратить преобразование вспять (или выполнить обратное преобразование), чтобы получить прогнозы в исходной шкале. Для преобразований Бокса–Кокса, заданных формулой (3.1), обратное преобразование задается формулой

$$y_t = \begin{cases} \exp(w_t) & \text{если } \lambda = 0; \\ \text{sign}(\lambda w_t + 1)\,|\lambda w_t + 1|^{1/\lambda} & \text{в противном случае.} \end{cases} \tag{5.2}$$

Пакет fable преобразовывает прогнозы в обратном направлении автоматически всякий раз, когда в определении модели используется преобразование. В этом случае обратно преобразованное прогнозное распределение является «преобразованным нормальным» распределением.

### Предсказательные интервалы с преобразованиями

Если было использовано преобразование, то сначала вычисляется предсказательный интервал в преобразованной шкале, и конечные точки преобразовываются обратно, чтобы получить предсказательный интервал в изначальной шкале. Этот подход сохраняет вероятностный охват предсказательного интервала, хотя он больше не будет симметричным вокруг точечного прогноза.

Обратное преобразование предсказательных интервалов выполняется автоматически при использовании пакета fable, при условии что в модельной формуле вы использовали преобразование.

Преобразования иногда мало влияют на точечные прогнозы, но оказывают большое влияние на предсказательные интервалы.

### Поправки на смещение

Одна из проблем, связанных с использованием математических преобразований, таких как преобразования Бокса–Кокса, заключается в том, что прогноз с обратным преобразованием точки не будет средним значением прогнозного распределения. Фактически обычно это будет медиана прогнозного распределения (при условии что распределение в преобразованном пространстве симметрично). Для многих целей это приемлемо, хотя среднее значение обычно предпочтительнее. Например, вы, возможно, захотите сложить прогнозы продаж из разных регионов, чтобы сформировать прогноз для всей страны. Но медианы не складываются, в то время как средние значения складываются.

Для преобразования Бокса–Кокса среднее значение обратного преобразования (приближенно) задается формулой

$$\hat{y}_{T+h|T} = \begin{cases} \exp\left(\widehat{w}_{T+h|T}\right)\left[1+\dfrac{\sigma_h^2}{2}\right] & \text{если } \lambda = 0; \\ (\lambda\widehat{w}_{T+h|T}+1)^{1/\lambda}\left[1+\dfrac{\sigma_h^2(1-\lambda)}{2(\lambda\widehat{w}_{T+h|T}+1)^2}\right] & \text{в противном случае.} \end{cases} \quad (5.3)$$

где $\widehat{w}_{T+h|T}$ – это среднее $h$-шагового прогноза и $\sigma_h^2$ – дисперсия $h$-шагового прогноза на преобразованной шкале. Чем больше дисперсия прогноза, тем больше разница между средним и медианой.

Разница между простым обратно преобразованным прогнозом, заданным формулой (5.2), и средним значением, заданным формулой (5.3), называется **смещением**. Когда мы используем среднее значение, а не медиану, то говорим, что в точечные прогнозы были внесены **поправки на смещение**.

Для того чтобы понять важность данной поправки на смещение, рассмотрим следующий ниже пример, в котором мы прогнозируем среднегодовую цену яиц, используя дрейфовый метод с логарифмическим преобразованием ($\lambda$ = 0). В данном случае логарифмическое преобразование полезно тем, что оно обеспечивает, чтобы прогнозы и предсказательные интервалы оставались положительными.

```
prices %>%
  filter(!is.na(eggs)) %>%
  model(RW(log(eggs) ~ drift())) %>%
  forecast(h = 50) %>%
  autoplot(prices %>% filter(!is.na(eggs)),
    level = 80, point_forecast = lst(mean, median)
  ) +
  labs(title = "Годовые цены на яйца",
       y = "$US (в центах с поправкой на инфляцию)")
```

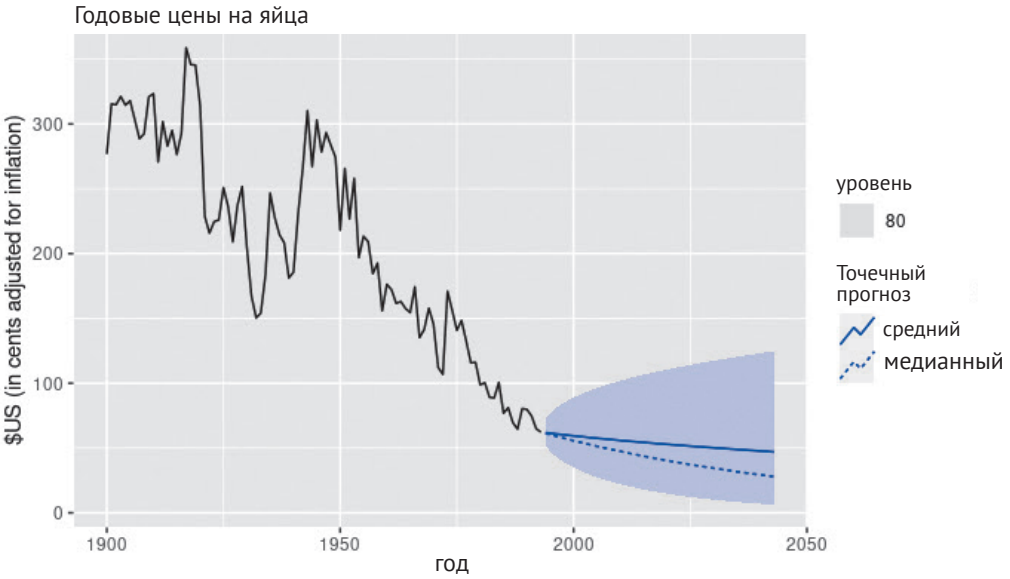


**Рисунок 5.17:** Прогнозы цен на яйца с использованием дрейфового метода применительно к зарегистрированным данным. Средние прогнозы с поправкой на смещение показаны сплошной линией, в то время как медианные прогнозы выделены пунктиром

Пунктирной линией на рис. 5.17 показаны прогнозные медианы, а сплошной линией – прогнозные средние значения. Обратите внимание, как искаженное прогнозное распределение подтягивает среднее значение прогнозного распределения вверх; это результат добавленного члена из поправки на смещение.

Прогнозные средние значения с поправкой на смещение вычисляются в пакете fable автоматически. Прогнозную медиану (точечный прогноз до поправки на смещение) можно получить с помощью функции `median()` на столбце распределения.

## 5.7 Прогнозирование с разложением

Разложение временных рядов (которое обсуждается в главе 3) бывает полезным шагом при генерировании прогнозов.

Исходя из аддитивного разложения, разложенный временной ряд можно записать как

$$y_t = \widehat{S}_t + \widehat{A}_t,$$

где $\widehat{A}_t = \widehat{T}_t + \widehat{R}_t$ – это сезонно скорректированная компонента. Или же, если было использовано мультипликативное разложение, можно записать

$$y_t = \widehat{S}_t \widehat{A}_t,$$

где $\widehat{A}_t = \widehat{T}_t \widehat{R}_t$.

Для того чтобы спрогнозировать разложенный временной ряд, мы прогнозируем сезонную компоненту, $\widehat{S}_t$, а также сезонно скорректированную компоненту, $\widehat{A}_t$, отдельно. Обычно принято исходить из допущения о том, что сезонная компонента неизменна либо меняется крайне медленно, поэтому ее прогнозируют, просто беря последний год оценочной компоненты. Другими словами, для сезонной компоненты используется сезонный наивный метод.

Для прогнозирования сезонно скорректированной компоненты можно использовать любой несезонный метод прогнозирования. Например, можно использовать дрейфовый метод, либо метод Хольта (который обсуждается в главе 8), либо несезонную модель ARIMA (которая обсуждается в главе 9).

## Пример: занятость в секторе розничной торговли США

```
us_retail_employment <- us_employment %>%
  filter(year(Month) >= 1990, Title == "Retail Trade")
dcmp <- us_retail_employment %>%
  model(STL(Employed ~ trend(window = 7), robust = TRUE)) %>%
  components() %>%
  select(-.model)
dcmp %>%
  model(NAIVE(season_adjust)) %>%
  forecast() %>%
  autoplot(dcmp) +
  labs(y = "Численность людей",
       title = "Занятость в секторе розничной торговли США")
```

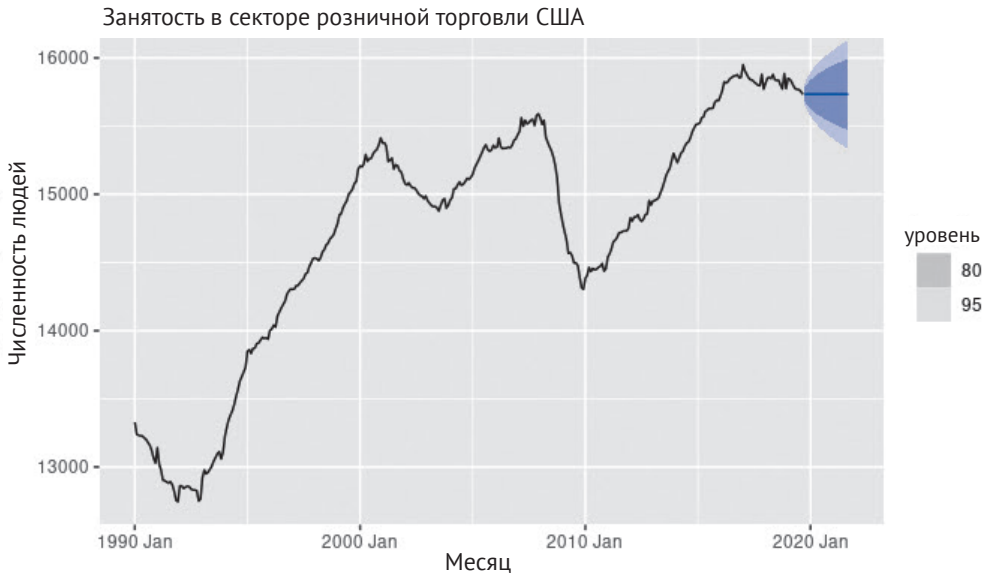


**Рисунок 5.18:** Наивные прогнозы сезонно скорректированных данных, полученных в результате STL-разложения суммарной занятости в розничной торговле США

На рис. 5.18 показаны наивные прогнозы сезонно скорректированных данных занятости в розничной торговле США. Затем они «ресезонализируются» путем добавления сезонных наивных прогнозов сезонной компоненты.

Это упрощается с помощью функции `decomposition_model()`, которая позволяет вычислять прогнозы с помощью любого аддитивного разложения, используя для прогнозирования каждой компоненты разложения другие модельные функции. Сезонные компоненты модели будут автоматически прогнозироваться с помощью `SNAIVE()`, если не указана другая модель. Указанная функция также выполнит за вас десезонализацию, обеспечивая получение результирующих прогнозов изначальных данных. Они показаны на рис. 5.19.

```
it_dcmp <- us_retail_employment %>%
  model(stlf = decomposition_model(
    STL(Employed ~ trend(window = 7), robust = TRUE),
    NAIVE(season_adjust)
  ))
fit_dcmp %>%
  forecast() %>%
  autoplot(us_retail_employment)+
  labs(y = "Численность людей",
       title = "Занятость в секторе розничной торговли США")
```

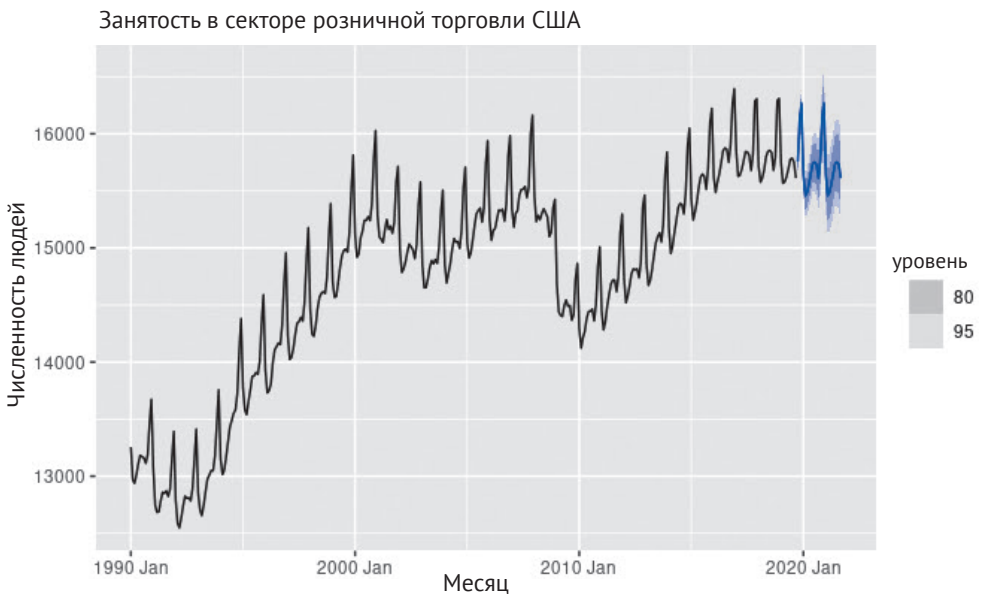


**Рисунок 5.19:** Прогнозы суммарных данных занятости в розничной торговле США, основанные на наивном прогнозе сезонно скорректированных данных, и сезонно-наивный прогноз сезонной компоненты после STL-разложения данных

Предсказательные интервалы, показанные на этом графике, построены таким же образом, как и точечные прогнозы. То есть верхняя и нижняя границы

предсказательных интервалов для сезонно скорректированных данных «ресезонализируются» путем добавления в прогнозы сезонной компоненты.

ACF остатков, показанный на рис. 5.20, демонстрирует значительные автокорреляции. Это обусловлено тем, что наивный метод не отражает меняющийся тренд в сезонно скорректированных рядах.

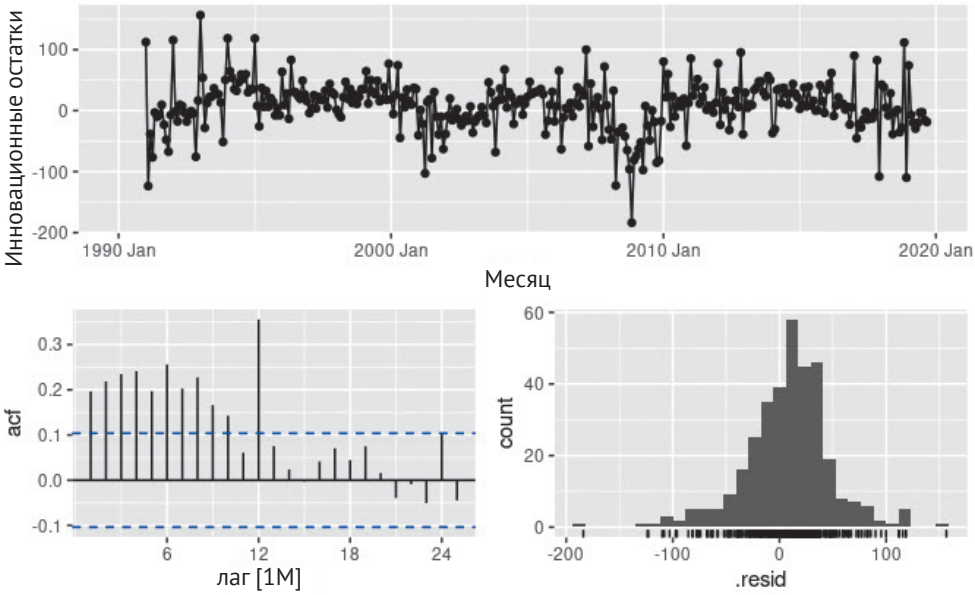


**Рисунок 5.20:** Проверка остатков

В последующих главах мы изучим более подходящие методы, которые можно использовать для прогнозирования сезонно скорректированной компоненты вместо наивного метода.

# 5.8 Оценивание точности точечного прогноза

## Тренировочный и тестовый наборы

Важно оценивать точность прогноза, используя подлинные прогнозы. Следовательно, размер остатков не является надежным индикатором того, насколько велики могут быть ошибки истинного прогноза. Точность прогнозов можно определить только путем рассмотрения того, насколько хорошую результативность модель демонстрирует с новыми данными, которые не использовались при подгонке модели.

На практике при выборе моделей обычно принято делить имеющиеся данные на две части, **тренировочные** и **тестовые** данные, где тренировочные данные используются для оценивания любых параметров метода прогнозирования, а тестовые данные – для оценивания ее точности. Поскольку тестовые данные не используются при определении прогнозов, они должны обеспечивать надежное представление о том, насколько хорошо модель, вероятно, будет прогнозировать на новых данных.

Размер тестового набора обычно составляет около 20 % от общей выборки, хотя это значение зависит от длины выборки и от того, насколько далеко вперед вы хотите сделать прогноз. В идеале тестовый набор должен быть по крайней мере таким же большим, как максимальный требуемый прогнозный горизонт. Необходимо отметить следующие моменты.

- Модель, которая хорошо вписывается в тренировочные данные, не обязательно будет хорошо прогнозировать.
- Идеальную подгонку всегда можно получить, используя модель с достаточным числом параметров.
- Переподгонка модели к данным так же плоха, как и неспособность выявлять систематическую закономерность в данных.

В некоторых справочных материалах тестовый набор описывается как «отложенный набор», поскольку эти данные «откладываются в сторону» из данных, используемых для подгонки. В других справочных материалах тренировочный набор называется «внутривыборочными данными», а тестовый набор – «вневыборочными данными». В этой книге мы предпочитаем использовать термины «тренировочные данные» и «тестовые данные».

## Функции для взятия подмножеств из временных рядов

Функция `filter()` полезна при извлечении порции временного ряда, например при создании тренировочного и тестового наборов. При делении данных на оценочные наборы особенно полезна фильтрация индекса данных. Например:

```
aus_production %>% filter(year(Quarter) >= 1995)
```

извлекает все данные с 1995 года и далее. Следующее ниже выражение может использоваться эквивалентным образом:

```
aus_production %>% filter_index("1995 Q1" ~ .)
```

Еще одной полезной функцией является `slice()`, которая позволяет использовать индексы для выбора подмножества из каждой группы. Например:

```
aus_production %>%
  slice(n()-19:0)
```

извлекает последние 20 наблюдений (5 лет).

Функция нарезки `slice()` также работает с группами, позволяя брать подмножество наблюдений из каждого ключа. Например:

```
aus_retail %>%
  group_by(State, Industry) %>%
  slice(1:12)
```

извлечет подмножество данных за первый год из каждого временного ряда в данных.

## Ошибки прогнозов

«Ошибка» прогноза, или прогнозная ошибка, – это разница между наблюдаемым значением и его прогнозом. Здесь термин «ошибка» означает не промашку, а непредсказуемую часть наблюдения. Ее можно записать как

$$e_{T+h} = y_{T+h} - \hat{y}_{T+h|T},$$

где тренировочные данные задаются через $\{y_1, \dots, y_T\}$, а тестовые данные – через $\{y_{T+1}, y_{T+1}, \dots\}$.

Обратите внимание, что прогнозные ошибки отличаются от остатков двумя направлениями. Во-первых, остатки вычисляются на *тренировочном наборе*, в то время как прогнозные ошибки вычисляются на *тестовом* наборе. Во-вторых, остатки основаны на *одношаговых* прогнозах, в то время как прогнозные ошибки могут предусматривать *многошаговые* прогнозы.

Точность прогноза можно измерить, беря итог прогнозных ошибок разными способами.

## Ошибки, зависимые от шкалы

Прогнозные ошибки находятся в той же шкале, что и данные. Меры точности, основанные только на $e_t$, как следствие зависят от шкалы и не могут использоваться для сравнения рядов, в которых используются разные единицы измерения.

Две наиболее часто встречающиеся зависимые от шкалы меры основаны на абсолютных ошибках или квадратах ошибок:

$$\text{Средняя абсолютная ошибка: MAE} = \text{mean}(|e_t|),$$

$$\text{Корень из среднего квадрата ошибки: RMSE} = \sqrt{\text{mean}\left(e_t^2\right)}.$$

При сравнении методов прогнозирования, применяемых к одному временному ряду или к нескольким временным рядам с одинаковыми единицами измерения, MAE пользуется популярностью, поскольку ее легко понять и вычислить. Метод прогнозирования, который минимизирует MAE, будет приводить к прогнозам медианы, в то время как минимизирование RMSE будет приводить к прогнозам среднего. Следовательно, RMSE также находит широкое применение на практике, несмотря на то что его труднее интерпретировать.

## Процентные ошибки

Процентная ошибка задается через $p_t = 100e_t/y_t$. Преимущество процентных ошибок состоит в том, что они не зависят от единиц измерения и поэтому нередко используются для сравнения прогнозной результативности между наборами данных. Наиболее часто используемой мерой является:

$$\text{Средняя абсолютная процентная ошибка: MAPE} = \text{mean}(|p_t|).$$

Меры, основанные на процентных ошибках, имеют характерный недостаток – они бесконечны либо неопределенны, если $y_t = 0$ для любого $t$ в интересующий период, и имеют экстремальные значения, если любой $y_t$ близок к нулю.

Еще одна проблема с процентными ошибками, которую часто упускают из виду, заключается в том, что они основаны на допущении о том, что единица измерения имеет содержательный ноль[1]. Например, процентная ошибка не имеет смысла при измерении точности температурных прогнозов по шкале Фаренгейта или Цельсия, поскольку температура имеет произвольную нулевую точку.

У них также есть недостаток, заключающийся в том, что они накладывают более суровый штраф на отрицательные ошибки, чем на положительные ошибки. Это наблюдение привело к использованию так называемой «симметричной» MAPE (sMAPE), предложенной Армстронгом (1978, с. 348, *https://otexts.com/fpp3/accuracy.html#ref-Armstrong85*), которая использовалась в конкурсе прогнозирования M3. Указанная мера определяется как

$$\text{sMAPE} = \text{mean}\left(200\left|y_t - \hat{y}_t\right| / \left(y_t + \hat{y}_t\right)\right).$$

Однако если $y_t$ находится близко к нулю, то $\hat{y}_t$, скорее всего, тоже будет находиться близко к нулю. Отсюда следует, что эта мера по-прежнему предусматривает деление на число, близкое к нулю, что делает вычисление нестабильным. Кроме того, значение sMAPE может быть отрицательным, так что на самом деле это вообще не мера «абсолютных процентных ошибок».

Хайндман и Келер (2006, *https://otexts.com/fpp3/accuracy.html#ref-HK06*) рекомендуют не использовать sMAPE. Указанная мера включена сюда только потому, что широко используется, хотя мы не будем использовать ее в этой книге.

## Шкалированные ошибки

Шкалированные ошибки были предложены Хайндманом и Келером (2006, *https://otexts.com/fpp3/accuracy.html#ref-HK06*) в качестве альтернативы использованию процентных ошибок при сравнении прогнозной точности по рядам с разными единицами измерения. Они предложили шкалировать ошибки, основываясь на тренировочной MAE из простого метода прогнозирования.

Для несезонных временных рядов полезным способом определения шкалированной ошибки является использование наивных прогнозов:

$$q_j = \frac{e_j}{\frac{1}{T-1}\sum_{t=2}^{T}|y_t - y_{t-1}|}.$$

Поскольку и числитель, и знаменатель содержат значения в шкале изначальных данных, $q_j$ не зависит от шкалы данных. Шкалированная ошибка меньше единицы, если она возникает из более качественного прогноза, чем средний одношаговый наивный прогноз, вычисленный на тренировочных данных. И наоборот, она больше единицы, если прогноз хуже среднего одношагового наивного прогноза, вычисленного на тренировочных данных.

Для сезонных временных рядов шкалированную ошибку можно определить с использованием сезонных наивных прогнозов:

[1] То есть процент валиден в шкале отношения, но не в интервальной шкале. Только шкальные переменные отношения имеют содержательные нули.

$$q_j = \frac{e_j}{\frac{1}{T-m}\sum_{t=m+1}^{T} |y_t - y_{t-m}|}.$$

Средняя абсолютная шкалированная ошибка – это просто

$$\text{MAE} = \text{mean}(|q_i|).$$

Аналогичным образом корень из среднего квадрата (или корень из среднеквадратической) шкалированной ошибки определяется как

$$\text{RMSSE} = \sqrt{\text{mean}\left(q_j^2\right)},$$

где $q_j^2 = \frac{e_j^2}{\frac{1}{T-m}\sum_{t=m+1}^{T}(y_t - y_{t-m})^2}$,

и мы устанавливаем $m = 1$ для несезонных данных.

## Примеры

```
recent_production <- aus_production %>%
  filter(year(Quarter) >= 1992)
beer_train <- recent_production %>%
  filter(year(Quarter) <= 2007)

beer_fit <- beer_train %>%
  model(
    Mean = MEAN(Beer),
    `Naïve` = NAIVE(Beer),
    `Seasonal naïve` = SNAIVE(Beer),
    Drift = RW(Beer ~ drift())
  )

beer_fc <- beer_fit %>%
  forecast(h = 10)

beer_fc %>%
  autoplot(
    aus_production %>% filter(year(Quarter) >= 1992),
    level = NULL
  ) +
  labs(
    y = "Мегалитры",
    title = "Прогнозы ежеквартального производства пива"
  ) +
  guides(colour = guide_legend(title = "прогноз"))
```

**Рисунок 5.21:** Прогнозы ежеквартального производства пива в Австралии с использованием данных вплоть до конца 2007 года

На рис. 5.21 показаны четыре метода прогнозирования применительно к ежеквартальному производству пива в Австралии, с использованием данных только на конец 2007 года. Также показаны фактические значения за период 2008–2010 годов. Мы вычисляем меры точности прогноза на этот период.

```
accuracy(beer_fc, recent_production)
```

| Метод | RMSE | MAE | MAPE | MASE |
|---|---|---|---|---|
| Дрейфовый метод | 64.90 | 58.88 | 14.58 | 4.12 |
| Метод среднего | 38.45 | 34.83 | 8.28 | 2.44 |
| Наивный метод | 62.69 | 57.40 | 14.18 | 4.01 |
| Сезонный наивный метод | 14.31 | 13.40 | 3.17 | 0.94 |

Функция `accuracy()`извлекает релевантные периоды из данных автоматически (в данном примере это `recent_production`), чтобы сочетать прогнозы при вычислении различных мер точности.

Из графика очевидно, что сезонный наивный метод подходит для этих данных лучше всего, хотя он все еще может быть улучшен, как мы узнаем позже. Иногда разные меры точности приводят к разным результатам в отношении того, какой метод прогнозирования является наилучшим. Однако в данном случае все результаты указывают на сезонный наивный метод как на наилучший из этих четырех методов для этого набора данных.

В качестве несезонного примера возьмем цену акций Google. На следующем ниже графике показаны цены акций на момент закрытия торгового периода в 2015 году, а также прогнозы на январь 2016 года, полученные из трех разных методов.

```
google_fit <- google_2015 %>%
  model(
    Mean = MEAN(Close),
    `Naïve` = NAIVE(Close),
    Drift = RW(Close ~ drift())
  )

google_fc <- google_fit %>%
  forecast(google_jan_2016)
google_fc %>%
  autoplot(bind_rows(google_2015, google_jan_2016),
    level = NULL) +
  labs(y = "$US",
       title = "Цена акций Google на момент закрытия торгового периода в январе 2015") +
  guides(colour = guide_legend(title = "Прогноз"))
```

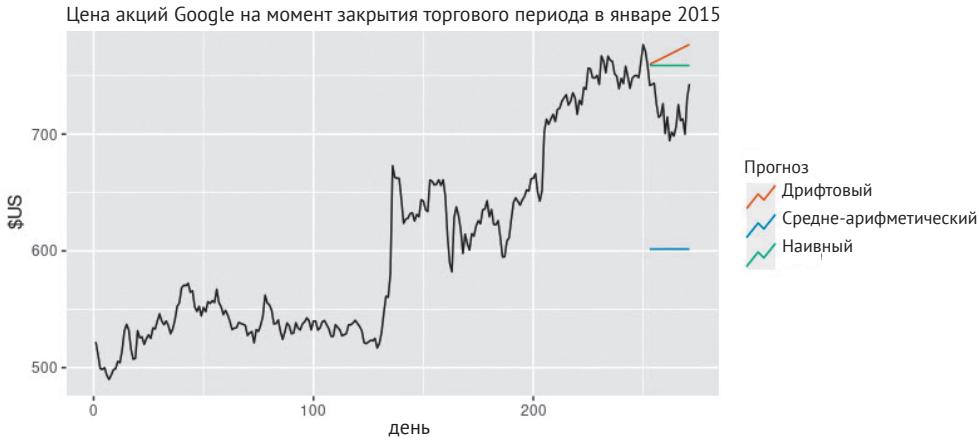


**Рисунок 5.22:** Прогнозы цены акций Google на январь 2016 года

| Метод | RMSE | MAE | MAPE | MASE |
|---|---|---|---|---|
| Дрейфовый метод | 53.07 | 49.82 | 6.99 | 6.99 |
| Метод среднего | 118.03 | 116.95 | 16.24 | 16.41 |
| Наивный метод | 43.43 | 40.38 | 5.67 | 5.67 |

Здесь наилучшим методом является наивный метод (независимо от того, какая мера точности используется).

## Библиография

*Армстронг, Дж. С.* (1978). Долгосрочное прогнозирование: От хрустального шара до компьютера. John Wiley & Sons. [Amazon, *http://buy.geni.us/Proxy.ashx?TSID=140570&GR_URL=http%3A%2F%2Fwww.amazon.com%2Fdp%2F0471030023*].

*Хайндман, Р. Дж., и Келер, А. Б.* (2006). Еще один взгляд на меры точности прогноза. International Journal of Forecasting, 22 (4), 679–688. [DOI: https://doi.org/10.1016/j.ijforecast.2006.03.001].

# 5.9 Оценивание точности распределительного прогноза

Все предыдущие меры измеряют точность точечного прогноза. При оценивании распределительных прогнозов необходимо использовать некоторые другие меры.

## Квантильные баллы

Рассмотрим пример цены акций Google из предыдущего раздела. На рис. 5.23 показан 80%-ный предсказательный интервал для прогноза из наивного метода.

```
google_fc %>%
  filter(.model == "Naïve") %>%
  autoplot(bind_rows(google_2015, google_jan_2016), level=80)+
  labs(y = " $US",
       title = "Цены акций Google на момент закрытия торгов")
```

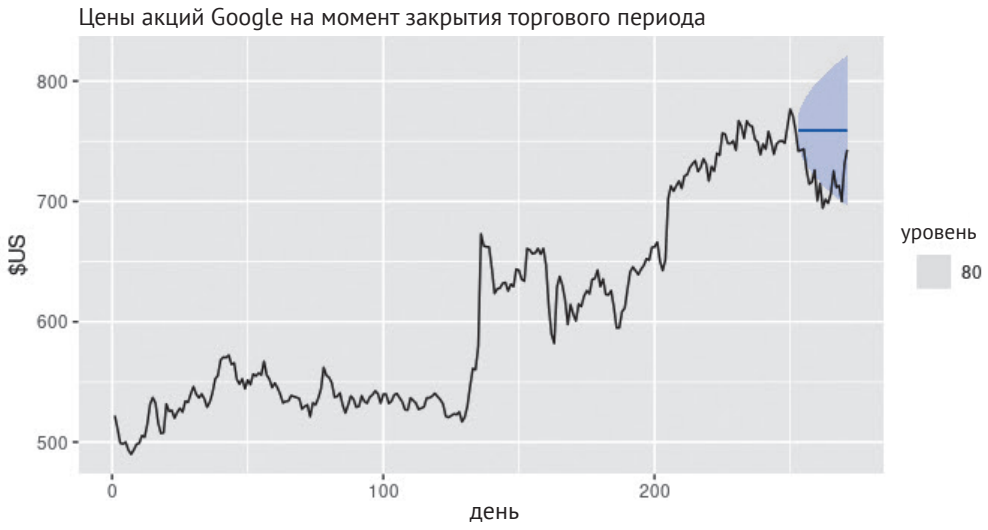


**Рисунок 5.23:** Наивные прогнозы цены акций Google на январь 2016 года, а также 80%-ные предсказательные интервалы

Нижний предел этого предсказательного интервала дает 10-й процентиль (или 0.1 квантиль) прогнозного распределения, поэтому мы ожидаем, что фактическое значение будет находиться ниже нижнего предела примерно в 10 %

случаев и находиться выше нижнего предела примерно в 90 % случаев. Когда мы сравниваем фактическое значение с этим процентилем, мы должны учитывать тот факт, что оно, скорее всего, будет выше, чем ниже.

В более общем случае предположим, что нас интересует квантильный прогноз с вероятностью $p$ в будущее время $t$, и пусть он обозначается через $f_{p,t}$. То есть мы ожидаем, что наблюдение $y_t$ должно быть меньше $f_{p,t}$ с вероятностью $p$. Например, 10-й процентиль будет равен $f_{0.10,t}$. Если $y_t$ обозначает наблюдение в момент времени $t$, то **квантильный балл** равен

$$Q_{p,t} = \begin{cases} 2(1-p)(f_{p,t} - y_t), & \text{если } y_t < f_{p,t} \\ 2p(y_t - f_{p,t}), & \text{если } y_t \geq f_{p,t} \end{cases}.$$

Эту функцию иногда называют «функцией пинбольной потери», потому что ее график напоминает траекторию мяча на столе для игры в пинбол. Множитель, равный 2, часто опускается, но его включение немного облегчает интерпретацию. Низкое значение $Q_{p,t}$ указывает на более качественный квантильный балл.

Квантильный балл можно интерпретировать как абсолютную ошибку. На самом деле при $p = 0.5$ квантильный балл $Q_{0.5,t}$ совпадает с абсолютной ошибкой. Для других значений $p$ «ошибка» $(y_t - f_{p,t})$ взвешивается с учетом того, насколько вероятно, что оно будет положительным либо отрицательным. Если $p > 0.5$, то $Q_{p,t}$ накладывает более суровый штраф, когда наблюдение больше оценочного квантиля, чем когда наблюдение меньше оценочного квантиля. Обратное верно для $p < 0.5$.

На рис. 5.23 10%-квантильный прогноз на один шаг вперед (на 4 января 2016 года) равен $f_{0.1,t} = 744.54$, и наблюдаемое значение равно $y_t = 741.84$. Тогда

$$Q_{0.1,t} = 2(1 - 0.1)(744.54 - 741.84) = 4.86.$$

Это легко вычисляется с помощью функции `accuracy()` с функцией `quantile_score()`:

```
google_fc %>%
  filter(.model == "Naïve", Date == "2016-01-04") %>%
  accuracy(google_stock, list(qs=quantile_score), probs=0.10)
#> # A tibble: 1 × 4
#>   .model Symbol .type    qs
#>   <chr>  <chr>  <chr> <dbl>
#> 1 Naïve  GOOG   Test   4.86
```

## Балл Винклера

Нередко представляет интерес оценка предсказательного интервала, а не нескольких квантилей, и предложенный Винклером (1972, *https://otexts.com/fpp3/distaccuracy.html#ref-Winkler1972*) балл Винклера предназначен для этой цели. Если $100(1 - \alpha)$%-ный предсказательный интервал в момент времени $t$ задается через $[l_{\alpha,t}, u_{\alpha,t})]$, то балл Винклера определяется как длина интервала плюс штраф, если наблюдение находится за пределами интервала:

$$W_{\alpha,t} = \begin{cases} \left(u_{\alpha,t} - \ell_{\alpha,t}\right) + \frac{2}{\alpha}\left(\ell_{\alpha,t} - y_t\right), & \text{если } y_t < \ell_{\alpha,t} \\ \left(u_{\alpha,t} - \ell_{\alpha,t}\right), & \text{если } \ell_{\alpha,t} \le y_t \le u_{\alpha,t}. \\ \left(u_{\alpha,t} - \ell_{\alpha,t}\right) + \frac{2}{\alpha}\left(y_t - u_{\beta,t}\right), & \text{если } y_t > u_{\alpha,t} \end{cases}$$

Для наблюдений, которые попадают в интервал, баллом Винклера является просто длина интервала. И поэтому низкие баллы связаны с узкими интервалами. Однако если наблюдение выходит за пределы интервала, то применяется штраф, причем штраф пропорционален тому, насколько далеко наблюдение находится за пределами интервала.

Предсказательные интервалы обычно строятся из квантилей путем установки $\ell_{\alpha,t} = f_{\alpha/2,t}$ и $u_{\alpha,t} = f_{1-\alpha/2,t}$. Если сложить соответствующие квантильные баллы и разделить на $\alpha$, то мы получим балл Винклера:

$$W_{\alpha,t} = \left(Q_{\alpha/2,t} + Q_{1-\alpha/2,t}\right)/\alpha.$$

80%-ный интервал на один шаг вперед, показанный на рис. 5.23 для 4 января 2016 года, равен [744.54, 773.22], а фактическое значение составило 741.84, поэтому балл Винклера равен

$$W_{\alpha,t} = \left(773.22 - 744.54\right) + \frac{2}{0.2}\left(744.54 - 741.84\right) = 55.68.$$

Он легко вычисляется с помощью функции `accuracy()` с функцией `winkler_score()`:

```
google_fc %>%
  filter(.model == "Naïve", Date == "2016-01-04") %>%
  accuracy(google_stock,
    list(winkler = winkler_score), level = 80)
#> # A tibble: 1 × 4
#>   .model Symbol .type winkler
#>   <chr>  <chr>  <chr>   <dbl>
#> 1 Naïve  GOOG   Test     55.7
```

## Непрерывный рангово-вероятностный балл

Нередко нас интересует распределение прогноза в целом, а не конкретные квантили или предсказательные интервалы. В этом случае можно усреднить квантильные баллы по всем значениям $p$ и получить Непрерывный рангово-вероятностный балл, или CRPS, от англ. Continuous Ranked Probability Score (Гнейтинг и Кацфусс, 2014).

В примере с ценой акций Google можно вычислить среднее значение CRPS за все дни в тестовом наборе. Значение CRPS немного похоже на взвешенную абсолютную ошибку, вычисленную по всему прогнозному распределению, где при взвешивании учитываются вероятности.

```
google_fc %>%
  accuracy(google_stock, list(crps = CRPS))
#> # A tibble: 3 × 4
#>   .model Symbol .type  crps
#>   <chr>  <chr>  <chr> <dbl>
#> 1 Drift  GOOG   Test   33.5
#> 2 Mean   GOOG   Test   76.7
#> 3 Naïve  GOOG   Test   26.5
```

Здесь наивный метод дает наилучшие распределительные прогнозы, чем дрейфовый метод или метод среднего.

## Бесшкальные сравнения с использованием баллов навыков

Как и в случае точечных прогнозов, полезно иметь возможность сравнивать точность распределительного прогноза нескольких методов по рядам в разных шкалах. В случае точечных прогнозов для этой цели мы использовали шкалированные ошибки. Еще один подход заключается в использовании баллов навыков. Их можно использовать как для точности точечного прогноза, так и для точности распределительного прогноза.

С помощью баллов навыков мы вычисляем меру точности прогноза относительно некоторого эталонного метода. Например, если в качестве эталона мы используем наивный метод, а также вычисляем прогнозы с использованием дрейфового метода, то балл навыков CRPS дрейфового метода относительно наивного метода можно вычислить как

$$\frac{\text{CRPS}_{\text{Наивный}} - \text{CRPS}_{\text{Дрейфовый}}}{\text{CRPS}_{\text{Наивный}}}.$$

Данная формула дает долю, на которую дрейфовый метод улучшается по сравнению с наивным методом, основанным на CRPS. Это легко вычислить с помощью функции `accuracy()`.

```
google_fc %>%
  accuracy(google_stock, list(skill = skill_score(CRPS)))
#> # A tibble: 3 × 4
#>   .model Symbol .type  skill
#>   <chr>  <chr>  <chr>  <dbl>
#> 1 Drift  GOOG   Test  -0.266
#> 2 Mean   GOOG   Test  -1.90
#> 3 Naïve  GOOG   Test   0
```

Разумеется, балл навыков для наивного метода равен 0, потому что он не может улучшить сам себя. Два других метода имеют более высокие значения CRPS, чем наивный, поэтому баллы навыков – отрицательные; дрейфовый метод на 26.6 % хуже наивного метода.

Функция `skill_score()` всегда будет вычислять CRPS для надлежащих эталонных прогнозов, даже если они не включены в объект fable. Когда данные являются сезонными, в качестве эталона используется сезонный наивный метод, а не наивный метод. С целью обеспечения того, чтобы для эталонных прогнозов использовались одни и те же тренировочные данные, важно, чтобы предоставляемые в функцию `accuracy()` данные начинались одновременно с тренировочными данными.

Функцию `skill_score()` можно использовать с любой мерой точности. Например, `skill_score(MSE)` предоставляет способ сравнения значений MSE в различных рядах. Однако важно, чтобы тестовый набор был достаточно крупным, дабы обеспечить надежное вычисление меры ошибки, в особенности в знаменателе. По этой причине MASE или RMSSE часто являются предпочтительными бесшкальными мерами точности точечного прогноза.

## Библиография

*Гнейтинг, Т. и Кацфусс, М.* (2014). Вероятностное прогнозирование. Annual Review of Statistics and Its Application, 1 (1), 125–151. [DOI: https://doi.org/10.1146/annurev-statistics-062713-085831].

*Винклер, Р. Л.* (1972). Теоретико-решающий подход к оцениванию интервалов. Journal of the American Statistical Association, 67 (337), 187–191. [DOI: https://doi.org/10.1080/01621459.1972.10481224].

# 5.10 Перекрестная валидация временных рядов

Более сложной версией тренировочного/тестового наборов является перекрестная валидация временного ряда. В этой процедуре используется серия тестовых наборов, каждый из которых состоит из одного наблюдения. Соответствующий тренировочный набор состоит только из тех наблюдений, которые произошли *до* наблюдения, формирующего тестовый набор. Таким образом, при построении прогноза никакие будущие наблюдения не могут использоваться. Поскольку невозможно получить надежный прогноз на основе малого тренировочного набора, самые ранние наблюдения не рассматриваются как тестовые наборы.

Следующая ниже диаграмма иллюстрирует серию тренировочных и тестовых наборов, где синие наблюдения образуют тренировочные наборы, а оранжевые наблюдения образуют тестовые наборы.

Точность прогноза вычисляется путем усреднения по всем тестовым наборам. Эта процедура иногда называется «оцениванием на скользящем источнике прогнозирования», поскольку «источник», на котором основан прогноз, перемещается вперед во времени.

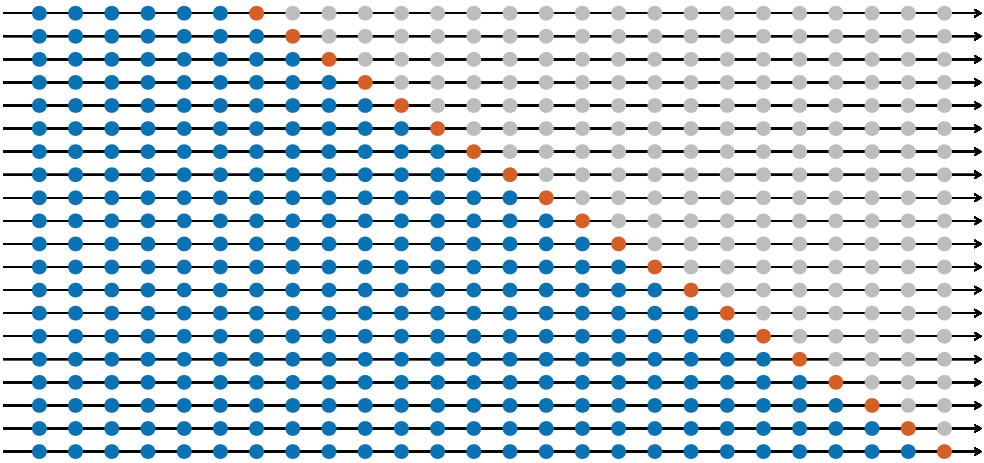


При прогнозировании временных рядов одношаговые прогнозы бывают не столь актуальны, как многошаговые прогнозы. В этом случае процедуру перекрестной валидации, основанную на скользящем источнике прогнозирования, можно изменить так, чтобы разрешить использование многошаговых ошибок. Предположим, что нас интересуют модели, которые дают хорошие прогнозы на 4 шага вперед. Тогда соответствующая диаграмма показана ниже.

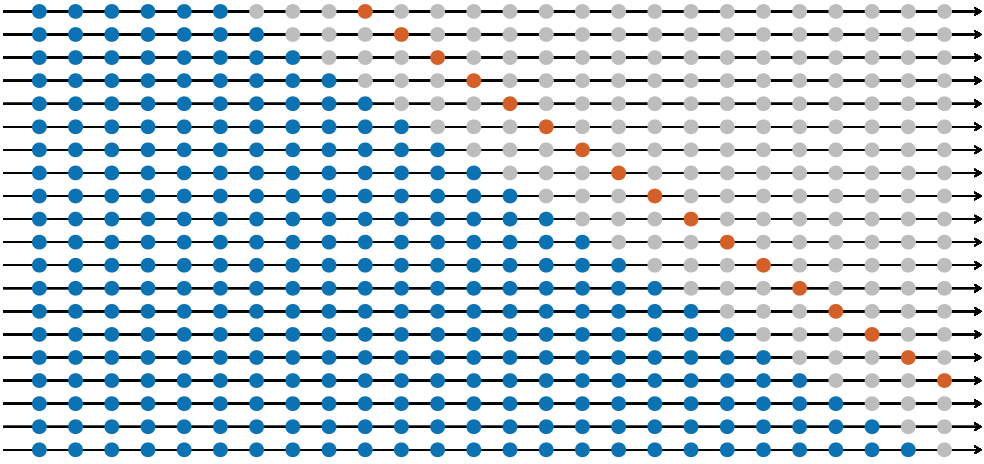


В следующем ниже примере мы сравниваем точность, полученную с помощью перекрестной валидации временного ряда, с точностью остатков. Функция `stretch_twibble()` используется для создания многочисленных тренировочных наборов. В данном примере мы начинаем с тренировочного набора длиной `.init=3` и увеличиваем размер поочередных тренировочных наборов на `.step=1`.

```
# Перекрестно-валидационная точность временного ряда
google_2015_tr <- google_2015 %>%
  stretch_tsibble(.init = 3, .step = 1) %>%
  relocate(Date, Symbol, .id)
google_2015_tr
#> # A tsibble: 31,875 x 10 [1]
#> # Key:       Symbol, .id [250]
#>    Date       Symbol   .id  Open  High   Low Close Adj_Close  Volume   day
#>    <date>     <chr>  <int> <dbl> <dbl> <dbl> <dbl>     <dbl>   <dbl> <int>
#>  1 2015-01-02 GOOG       1  526.  528.  521.  522.      522. 1447600     1
#>  2 2015-01-05 GOOG       1  520.  521.  510.  511.      511. 2059800     2
#>  3 2015-01-06 GOOG       1  512.  513.  498.  499.      499. 2899900     3
#>  4 2015-01-02 GOOG       2  526.  528.  521.  522.      522. 1447600     1
#>  5 2015-01-05 GOOG       2  520.  521.  510.  511.      511. 2059800     2
#>  6 2015-01-06 GOOG       2  512.  513.  498.  499.      499. 2899900     3
#>  7 2015-01-07 GOOG       2  504.  504.  497.  498.      498. 2065100     4
#>  8 2015-01-02 GOOG       3  526.  528.  521.  522.      522. 1447600     1
#>  9 2015-01-05 GOOG       3  520.  521.  510.  511.      511. 2059800     2
#> 10 2015-01-06 GOOG       3  512.  513.  498.  499.      499. 2899900     3
#> # … и еще 31 865 строк
```

Столбец `.id` содержит новый ключ, указывающий на различные тренировочные наборы. Функцию `accuracy()` можно использовать для оценивания точности прогнозов по всем тренировочным наборам.

```
# TSCV-точность
google_2015_tr %>%
  model(RW(Close ~ drift())) %>%
  forecast(h = 1) %>%
  accuracy(google_2015)
# Точность на тренировочном наборе
google_2015 %>%
  model(RW(Close ~ drift())) %>%
  accuracy()
```

| Метод оценивания | RMSE | MAE | MAPE | MASE |
|---|---|---|---|---|
| Перекрестная валидация | 11.27 | 7.26 | 1.19 | 1.02 |
| Тренировка | 11.15 | 7.16 | 1.18 | 1.00 |

Как и ожидалось, меры точности из остатков меньше, поскольку соответствующие «прогнозы» основаны на модели, подогнанной ко всему набору данных, а не являются истинными прогнозами.

Хороший способ выбрать наилучшую модель прогнозирования – найти модель с наименьшей RMSE, вычисленной с помощью перекрестной валидации временных рядов.

## Пример: точность прогнозного горизонта с помощью перекрестной валидации

Показанное на рис. 5.9 подмножество данных `gafa_stock google_2015` включает в себя дневную цену акций Google Inc на момент закрытия на бирже NASDAQ за все торговые дни 2015 года.

Приведенный ниже исходный код оценивает результативность прогнозирования дрейфовых прогнозов на 1–8 шагов вперед. График показывает, что прогнозная ошибка увеличивается по мере увеличения прогнозного горизонта, как и следовало ожидать.

```
google_2015_tr <- google_2015 %>%
  stretch_tsibble(.init = 3, .step = 1)
fc <- google_2015_tr %>%
  model(RW(Close ~ drift())) %>%
  forecast(h = 8) %>%
  group_by(.id) %>%
  mutate(h = row_number()) %>%
  ungroup() %>%
  as_fable(response = "Close", distribution = Close)
fc %>%
  accuracy(google_2015, by = c("h", ".model")) %>%
  ggplot(aes(x = h, y = RMSE)) +
  geom_point()
```

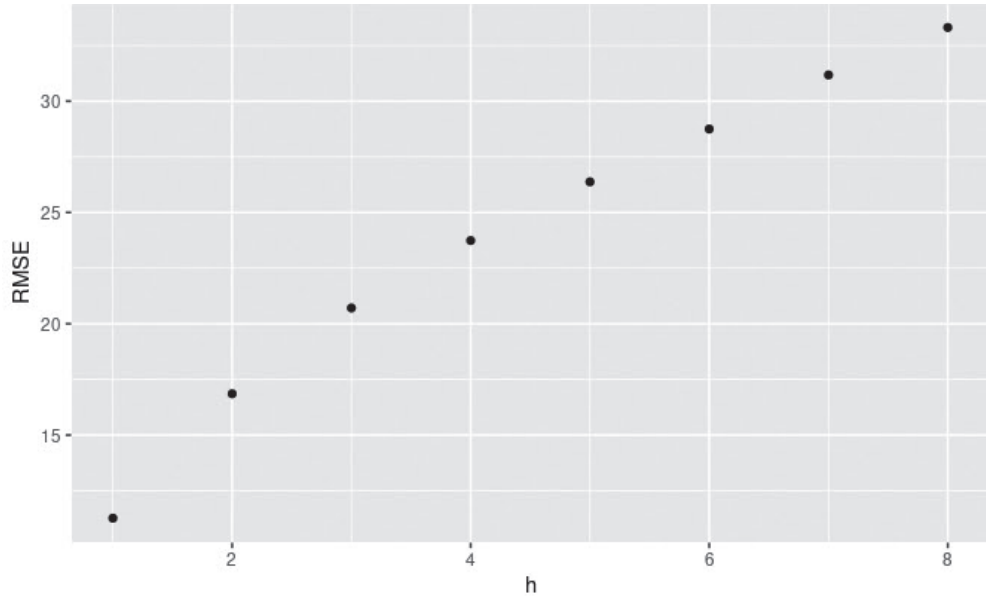


**Рисунок 5.24:** RMSE как функция прогнозного горизонта для дрейфового метода применительно к ценам акций Google на момент закрытия торгового периода

## 5.11 Упражнения

1. Сгенерируйте прогнозы для следующих рядов, используя любой из трех методов – `NAIVE(y)`, `SNAIVE(y)` или `RW(y ~ drift())`, – который более подходит в каждом конкретном случае:
   - население Австралии (`global_economy`);
   - кирпичи (`aus_production`);
   - ягнята Нового Южного Уэльса (`aus_livestock`);
   - благосостояние домохозяйств (`hh_budget`);
   - оборот австралийских продуктов питания навынос (`aus_retail`).
2. Используйте цену акций Facebook (набор данных `gafa_stock`), чтобы выполнить следующее:
   a) постройте временной график ряда;
   b) сгенерируйте прогнозы с использованием дрейфового метода и нанесите их на график;
   c) покажите, что прогнозы идентичны отрезку линии, проведенному между первым и последним наблюдениями;
   d) попробуйте использовать некоторые другие эталонные функции для прогнозирования того же набора данных. Какой, по вашему мнению, лучше? Почему?
3. Примените сезонный наивный метод к ежеквартальным данным производства пива в Австралии за 1992 год. Проверьте, выглядят ли остатки как белый шум, и сгенерируйте прогнозы. Следующий ниже исходный код вам в этом поможет.

```
# Извлечь интересущие данные
recent_production <- aus_production %>%
  filter(year(Quarter) >= 1992)
# Определить и оценить модель
fit <- recent_production %>% model(SNAIVE(Beer))
# Посмотреть на остатки
fit %>% gg_tsresiduals()
# Посмотреть на некоторые прогнозы
fit %>% forecast() %>% autoplot(recent_production)
```

   К какому выводу вы пришли?
4. Повторите предыдущее упражнение, используя ряд с данными экспорта из Австралии из `global_economy` и ряд с данными о производстве кирпичей из `aus_production`. Используйте любой из двух методов – `NAIVE()` или `SNAIVE()`, – который более подходит в каждом конкретном случае.
5. Сгенерируйте прогнозы для 7 рядов в `aus_livestock` по штату Виктория с помощью `SNAIVE()`. Постройте результирующие прогнозы, включая исторические данные. Является ли он разумным эталоном для указанных рядов?
6. Являются ли следующие ниже утверждения истинными или ложными? Объясните свой ответ.

a) Хорошие методы прогнозирования должны иметь нормально распределенные остатки.
b) Модель с малыми остатками даст хорошие прогнозы.
c) Самой лучшей мерой прогнозной точности является MAPE.
d) Если ваша модель плохо прогнозирует, то вам следует ее усложнить.
e) Всегда выбирайте модель с наилучшей прогнозной точностью, измеренной на тестовом наборе.

7. Для вашего временного ряда розничной торговли (из упражнения 8 в разделе 2.10):
   a) создайте тренировочный набор данных, состоящий из наблюдений до наступления 2011 года, используя

```
myseries_train <- myseries %>%
  filter(year(Month) < 2011)
```

   b) убедитесь, что ваши данные были разделены надлежащим образом, создав следующий ниже график:

```
autoplot(myseries, Turnover) +
  autolayer(myseries_train, Turnover, colour = "red")
```

   c) выполните подгонку сезонной наивной модели, используя `SNAIVE()` применительно к вашим тренировочным данным (`myseries_train`):

```
fit <- myseries_train %>%
  model(SNAIVE())
```

   d) проверьте остатки.

```
fit %>% gg_tsresiduals()
```

   Выглядят ли остатки некоррелированными и нормально распределенными?
   e) сгенерируйте прогнозы для тестовых данных:

```
fc <- fit %>%
  forecast(new_data = anti_join(myseries, myseries_train))

fc %>% autoplot(myseries)
```

   f) сравните точность ваших прогнозов с фактическими значениями:

```
fit %>% accuracy()

fc %>% accuracy(myseries)
```

   g) насколько чувствительны меры точности к объему используемых тренировочных данных?
8. Рассмотрите поголовье свиней, забитых в Новом Южном Уэльсе (набор данных `aus_livestock`).
   a) Постройте несколько графиков данных, чтобы ознакомиться с ними.
   b) Создайте тренировочный набор из 486 наблюдений, отложив тестовый набор из 72 наблюдений (6 лет).
   c) Попробуйте использовать различные эталонные методы для прогнозирования тренировочного набора и сравнения результатов на тестовом наборе. Какой метод сработал лучше всего?
   d) Проверьте остатки вашего предпочтительного метода. Похожи ли они на белый шум?

9.
   a) Создайте тренировочный набор для определения благосостояния домашних хозяйств (`hh_budget`), отложив последние четыре года в качестве тестового набора.
   b) Выполните подгонку всех подходящих эталонных методов к тренировочному набору и спрогнозируйте периоды, охватываемые тестовым набором.
   c) Рассчитайте точность ваших прогнозов. Какой метод работает лучше всего?
   d) Напоминают ли остатки от наилучшего метода белый шум?

10.
   a) Создайте тренировочный набор для австралийского оборота продуктов питания навынос (`aus_retail`), отложив последние четыре года в качестве тестового набора.
   b) Выполните подгонку всех подходящих эталонных методов к тренировочному набору и спрогнозируйте периоды, охватываемые тестовым набором.
   c) Рассчитайте точность ваших прогнозов. Какой метод работает лучше всего?
   d) Напоминают ли остатки из наилучшего метода белый шум?

11. В этом упражнении мы будем использовать данные по кирпичам из `aus_production` (австралийское ежеквартальное производство глиняного кирпича за 1956–2005 годы).
   a) Примените STL-разложение для вычисления индексов трендового цикла и сезонных индексов. (Поэкспериментируйте с фиксированной либо изменяющейся сезонностью.)
   b) Вычислите и нанесите на график сезонно скорректированные данные.
   c) Используйте наивный метод для генерирования прогнозов сезонно скорректированных данных.
   d) Используйте `decomposition_model()` для повторного анализа результатов, давая прогнозы для изначальных данных.
   e) Выглядят ли остатки некоррелированными?
   f) Повторите с использованием устойчивого STL-разложения. Насколько они отличаются?
   g) Сравните прогнозы из `decomposition_model()` с прогнозами из `SNAIVE()`, используя тестовый набор, содержащий данные за последние 2 года. Что лучше?

12. Набор данных `tourism` содержит ежеквартальные гостевые ночи (в тысячах) с 1998 по 2017 год по 76 регионам Австралии.
   a) Извлеките данные из региона Голд-Кост с помощью `filter()` и агрегируйте суммарное число поездок с ночевкой (суммируйте по `Purpose`) с помощью `summarise()`. Назовите этот новый набор данных `gc_tourism`.
   b) Используя `slice()` либо `filter()`, создайте три тренировочных набора для этих данных, исключив последние 1, 2 и 3 года. Например, `gc_train_1 <- gc_tourism %>% slice(1:(n()-4))`.

c) Вычислите прогнозы на один год для каждого тренировочного набора, используя сезонный наивный метод (`SNAIVE()`). Назовите их соответственно `gc_fc_1`, `gc_fc_2` и `gc_fc_3`.
d) Используйте `accuracy()` для сравнения прогнозной точности тестового набора с помощью MAPE. Прокомментируйте это.

## 5.12 Дальнейшее чтение

Орд и соавт. (2017, *https://otexts.com/fpp3/basics-reading.html#ref-Ord2017*) предлагают дальнейшее обсуждение простых методов эталонного прогнозирования.

Обзор методов оценивания прогнозов приведен в работе Хайндман и Келер (2006, *https://otexts.com/fpp3/basics-reading.html#ref-HK06*), в которой рассматриваются сильные и слабые стороны различных подходов. В данной статье была представлена мера MASE как мера прогнозной точности общего назначения.

Обсуждение прогнозирования с использованием STL см. в Феодосиу (2011, *https://otexts.com/fpp3/basics-reading.html#ref-Theodosiou2011*).

Отличное обсуждение оценивания точности распределительного прогноза представлено в Гнейтинг и Кацфусс (2014, *https://otexts.com/fpp3/basics-reading.html#ref-Gneiting2014*).

## Библиография

*Гнейтинг, Т. и Кацфусс, М. (2014).* Вероятностное прогнозирование. Annual Review of Statistics and Its Application, 1 (1), 125–151. [DOI: https://doi.org/10.1146/annurev-statistics-062713-085831].

*Хайндман, Р. Дж. и Келер, А. Б.* (2006). Еще один взгляд на меры точности прогноза. International Journal of Forecasting, 22 (4), 679–688. [DOI: https://doi.org/10.1016/j.ijforecast.2006.03.001].

*Орд, Дж. К., Филдес, Р. и Курентзес, Н.* (2017). Принципы бизнес-прогнозирования (2-е изд.). Wessex Press Publishing Co. [Amazon, *http://buy.geni.us/Proxy.ashx?TSID=140570&GR_URL=http%3A%2F%2Fwww.amazon.com%2Fdp%2F0999064916*].

*Феодосиу, М.* (2011). Прогнозирование месячных и квартальных временных рядов с использованием декомпозиции STL. International Journal of Forecasting, 27 (4), 1178–1195. [DOI: https://doi.org/10.1016/j.ijforecast.2010.11.002].

# Глава 6

# Прогнозы на основе суждений

Прогнозирование с использованием суждения является распространенным явлением на практике. Во многих случаях сужденческое (или рассудочное) прогнозирование является единственным вариантом, допустим при полном отсутствии исторических данных, или при запуске нового продукта, или при выходе на рынок нового конкурента, или в совершенно новых и уникальных рыночных условиях. Например, в декабре 2012 года правительство Австралии первым в мире приняло закон, запрещающий использование логотипов компаний на пачках сигарет и требующий, чтобы все пачки сигарет были темно-зеленого цвета. Для прогнозирования последствий такой политики необходимо применять суждение, поскольку исторических прецедентов нет.

Существуют также ситуации, когда данные являются неполными или становятся доступными только после некоторого опоздания. Например, центральные банки учитывают суждения при прогнозировании текущего уровня экономической активности, применяя процедуру, именуемую сверхкраткосрочным прогнозированием (nowcasting), поскольку ВВП доступен только на ежеквартальной основе.

Исследования в этой области[1] показали, что точность сужденческого прогнозирования повышается, когда прогнозист обладает (i) важными знаниями в предметной области и (ii) более своевременной и актуальной информацией. Сужденческий подход может быстро приспосабливаться к таким изменениям, информации или событиям.

С годами признание сужденческого прогнозирования как науки возросло, равно как и признание его необходимости. Что еще важнее, качество сужденческих прогнозов также улучшилось, что является прямым результатом признания того, что улучшения в сужденческом прогнозировании могут достигаться путем внедрения хорошо структурированных и систематических подходов. Важно признать, что сужденческое прогнозирование имеет субъективный характер и сопряжено с ограничениями. Однако внедрение систематических и хорошо структурированных подходов может ограничивать эти ограничения и заметно повышать точность прогноза.

Существует три общих условия, в которых используется сужденческое прогнозирование: (i) нет данных, поэтому статистические методы неприменимы и сужденческое прогнозирование является единственно возможным подходом; (ii) данные есть, формируются статистические прогнозы, которые затем

[1] См. *Лоуренс* и соавт. (2006, *https://otexts.com/fpp3/judgmental.html#ref-Lawrence2006*).

корректируются с использованием суждения; и (iii) данные есть, и статистические, и оценочные прогнозы формируются независимо, а затем комбинируются. Необходимо уточнить, что при наличии данных применение статистических методов (таких как те, которые обсуждаются в других главах этой книги) является предпочтительным, и они всегда должны использоваться в качестве отправной точки. Статистические прогнозы, как правило, превосходят генерирование прогнозов с использованием только суждений. Бóльшую часть главы мы сосредоточим внимание на первом случае, когда данных нет, а в последнем разделе обсудим сужденческую корректировку статистических прогнозов. Мы обсуждаем комбинирование прогнозов в разделе 13.4.

## Библиография

*Лоуренс, М., Гудвин, П., О'Коннор, М. и Онкал, Д.* (2006). Сужденческое прогнозирование: обзор прогресса за последние 25 лет. International Journal of Forecasting, 22 (3), 493–518. [DOI: https://doi.org/10.1016/j.ijforecast.2006.03.007].

# 6.1 Остерегайтесь ограничений

Сужденческие прогнозы субъективны и, следовательно, не свободны от систематического смещения или ограничений.

Сужденческие прогнозы бывают противоречивыми. В отличие от статистических прогнозов, которые всякий раз могут быть получены с помощью одних и тех же математических формул, сужденческие прогнозы в значительной степени зависят от человеческого познания и уязвимы перед его ограниченностью. Например, ограниченность памяти может делать недавние события более важными, чем они есть на самом деле, и может игнорировать важные события из более отдаленного прошлого; либо ограниченность концентрации внимания может приводить к пропуску важной информации; либо неправильное понимание причинно-следственных связей может приводить к ошибочным выводам. Кроме того, человеческое суждение может меняться из-за влияния психологических факторов. Можно представить себе менеджера, который в один прекрасный день находится в положительном настроении и делает прогнозы, которые могут быть несколько оптимистичными, а в другой день находится в отрицательном настроении и делает несколько менее оптимистичные прогнозы.

Суждения бывают омрачены личными или политическими целями, когда цели и прогнозы (как определено в главе 1) не сегрегированы. Например, если менеджер по продажам знает, что прогнозы, которые он генерирует, будут использоваться для установления ожиданий продаж (целевых показателей), то он, возможно, будет стремиться установить их на низком уровне, чтобы показать хорошую результативность (т. е. превысить ожидаемые целевые показатели). Даже в тех случаях, когда цели и прогнозы четко сегрегированы, суждения бывают искажены оптимизмом или принятием желаемого за действительное. Например, было бы крайне маловероятно, что коллектив, работающий над запуском нового продукта, будет прогнозировать его провал. Как мы обсудим позже, этот оптимизм может быть усилен в обстановке группового совещания. «Остерегайтесь энтузиазма ваших коллег по маркетингу и продажам»[1].

[1] См. *Филдс* и *Гудвин* (2007b, *https://otexts.com/fpp3/judgmental-limitations.html#ref-Fildes2007a*).

Еще одним нежелательным свойством, которое обычно наблюдается при сусденческом прогнозировании, является эффект заякоревания. В этом случае последующие прогнозы имеют тенденцию сходиться или быть близкими к исходной знакомой контрольной точке. Например, обычно в качестве контрольной точки берется последнее наблюдаемое значение. На прогнозиста чрезмерно влияет предварительная информация, и поэтому в процессе прогнозирования он придает ей больший вес. Заякоривание может приводить к консерватизму и недооценке новой и более актуальной информации и тем самым создавать систематическое смещение.

### Библиография

*Филдес, Р. и Гудвин, П.* (2007b). Правильное и неправильное суждения в прогнозировании: уроки четырех компаний. Foresight: The International Journal of Applied Forecasting, 8, 5–10.

## 6.2 Ключевые принципы

Использование систематического и хорошо структурированного подхода к сусденческому прогнозированию помогает уменьшать негативные последствия ограничений сусденческого прогнозирования, некоторые из которых мы перечислили в предыдущем разделе. Независимо от того, касается ли этот подход одного человека или многих, следует придерживаться следующих ниже принципов.

### Четко и кратко формулировать задачу прогнозирования

Необходимо проявлять осторожность при постановке задач прогнозирования и формулировании задач прогнозирования. Важно, чтобы все четко понимали, в чем заключается задача. Все определения должны быть четкими и всеобъемлющими, избегая двусмысленных и расплывчатых выражений. Кроме того, важно избегать включения эмоциональных терминов и нерелевантной информации, которая может отвлечь прогнозиста. В приведенном ниже дельфийском методе (см. раздел 6.3) перед постановкой задачи прогнозирования иногда бывает полезно провести предварительный раунд сбора информации.

### Внедрять систематический подход

Точность и консистентость прогноза можно повысить, используя систематический подход к сусденческому прогнозированию, включающий контрольные списки категорий информации, которые имеют отношение к задаче прогнозирования. Например, полезно выявить информацию, которая является важной, и то, как эта информация должна быть взвешена. При прогнозировании спроса на новый продукт следует выявить факторы, которые необходимо учитывать, и то, каким образом их необходимо учитывать. Должна ли это быть цена, качество и/или число конкурентов, текущая экономическая обстановка, целевая аудитория продукта? Стоит потратить значительные усилия и ресурсы на разработку правил принятия решений, которые приведут к наилучшему возможному систематическому подходу.

## Документировать и обосновывать

Формализация и документирование правил принятия решений и допущений, принимаемых в рамках систематического подхода, могут способствовать согласованности, поскольку одни и те же правила могут применяться неоднократно. Кроме того, обращение к прогнозисту с просьбой документировать и обосновывать свои прогнозы ведет к подотчетности, что может приводить к уменьшению систематического смещения. Кроме того, официальная документация значительно помогает в процессе систематической оценки, который предлагается далее.

## Систематически оценивать прогнозы

Систематический мониторинг процесса прогнозирования может выявлять непредвиденные нарушения. В частности, следует вести учет прогнозов и использовать их для получения обратной связи, когда станут доступны соответствующие наблюдения. Хотя вы можете делать все возможное в качестве прогнозиста, обстановка, в которой вы работаете, динамична. Постоянно происходят изменения, и вам необходимо их отслеживать, чтобы оценивать правила принятия решений и допущения. Обратная связь и оценивание помогают прогнозистам учиться и повышать точность своих прогнозов.

## Сегрегировать прогнозистов и пользователей

На пути достижения точности прогноза могут возникать препятствия, если задача прогнозирования выполняется пользователями прогнозов, например теми, кто отвечает за внедрение планов действий, о которых идет речь в прогнозе. Здесь мы должны еще раз уточнить (как и в разделе 1.2), что прогнозирование заключается в максимально точном прогнозировании будущего, учитывая всю доступную информацию, включая исторические данные и знания о любых будущих событиях, которые могут повлиять на прогнозы. Прогнозисты и пользователи должны быть четко сегрегированы. Классический случай – это запуск нового продукта. Прогноз должен представлять собой разумную оценку объема продаж нового продукта, который может значительно отличаться от ожиданий или надежд руководства о том, что объем продаж будет соответствовать финансовым целям компании. В этом случае прогнозист может предоставлять пользователю проверку реальности.

Важно, чтобы прогнозисты тщательно доводили прогнозы до сведения потенциальных пользователей. Как мы увидим в разделе 6.7, пользователи могут чувствовать себя далекими и оторванными от прогнозов и могут не испытывать к ним полного доверия. Объяснение и разъяснение процесса и обоснование базовых допущений, которые привели к прогнозам, обеспечат некоторую уверенность пользователям.

То, каким образом прогнозы затем могут быть использованы и внедрены, явно будет зависеть от принятия управленческих решений. Например, руководство может принять решение скорректировать прогноз в сторону повышения (быть чрезмерно оптимистичным), поскольку прогноз может использоваться для определения уровней закупок и хранения запасов. Такое решение может быть принято после того, как анализ затрат и выгод покажет, что

затраты на хранение избыточных запасов намного ниже, чем потери от продаж. Этот тип корректировки должен быть частью постановки целей или планирования поставок, а не частью процесса прогнозирования. Напротив, если прогнозы используются в качестве целевых показателей, то они могут быть установлены на низком уровне, чтобы их было легче превысить. Опять же, постановка целевых показателей отличается от продуцирования прогнозов, и их не следует путать.

Приведенный ниже пример взят из нашего опыта работы в промышленности. Он иллюстрирует два противоположных стиля сусденческого прогнозирования – тот, который придерживается принципов, которые мы только что представили, и тот, который этого не делает.

## Пример: схема фармацевтических льгот (PBS)

Австралийское правительство субсидирует стоимость широкого спектра отпускаемых по рецепту лекарств в рамках программы PBS. Каждое субсидируемое лекарство попадает в одну из четырех категорий: концессионные доплаты, концессионная страховка, общие доплаты и общая страховка. Каждый человек, имеющий льготную карту, вносит доплату за льготное лекарство PBS (5.80 доллара)[1] до тех пор, пока не достигнет установленной пороговой суммы, обозначенной как концессионная страховка (348 долларов). До конца финансового года все лекарства, включенные в список PBS, предоставляются бесплатно. Каждый пациент общего профиля вносит общую доплату за лекарство PBS (35.40 доллара) до тех пор, пока не будет достигнута общая сумма страховки (1363.30 доллара). До конца финансового года они вносят небольшую сумму за каждое лекарство, включенное в список PBS (5.80 доллара). Процесс прогнозирования PBS предусматривает использование 84 групп лекарств, включенных в список PBS, и продуцирование прогнозов объема лекарств и общих расходов для каждой группы и для каждой из четырех категорий PBS, в общей сложности 672 ряда. Указанный процесс прогнозирования помогает определять правительственный бюджет, выделяемый на PBS, который составляет более 7 млрд долларов в год, или примерно 1 % ВВП.

На рис. 6.1 кратко представлен процесс прогнозирования. Сусденческие прогнозы производятся для новых списков лекарств и для оценивания воздействия новой политики. Они показаны зелеными прямоугольниками. Розовые прямоугольники указывают на используемые данные, которые были получены из различных правительственных ведомств и ассоциированных с ними органов власти. Синие прямоугольники показывают значения, рассчитанные на основе предоставленных данных. Сусденческие корректировки были внесены в данные с учетом новых списков и новой политики, а также в прогнозы. Из-за изменения численности как концессионного населения, так и суммарной численности населения прогнозы производятся на основе показателя на душу населения, а затем умножаются на прогнозируемую численность населения с целью получения прогнозов общего объема и расходов за месяц.

[1] Это суммы в австралийских долларах, опубликованные правительством Австралии на 2012 год.

**Рисунок 6.1:** Процесс продуцирования прогнозов PBS

Несколько лет назад одного из нас (Хайндмана) попросили оценить процесс прогнозирования. Мы обнаружили, что использование суждений для новых списков и воздействий новых политик дает более качественные прогнозы, чем использование только статистической модели. Однако мы также обнаружили, что точность и систематичность прогнозирования могут быть улучшены за счет более структурированного и систематического процесса, в особенности в отношении воздействия политики.

*Прогнозирование новых списков*: компаниям, которые подают заявки на добавление своего лекарства в PBS, предлагается представить подробные прогнозы по различным аспектам лекарства, таким как проецируемое число пациентов, доля нового лекарства на рынке, эффекты замещения и т. д. Консультативный комитет по фармацевтическим преимуществам предоставляет руководящие принципы, описывающие высокоструктурированный и систематический подход к составлению этих прогнозов, и требует тщательной документации для каждого этапа процесса. Указанный структурированный процесс помогает снижать вероятность и последствия преднамеренных корыстных систематических смещений. Подкомитет проводит два раунда детального оценивания прогнозов компании: один до добавления лекарства в PBS и один после его добавле-

ния. Наконец, проводится сравнение наблюдений с прогнозами для некоторых выбранных новых списков, через 12 месяцев и 24 месяца после размещения, и результаты отправляются обратно компаниям для комментариев.

*Прогнозы воздействия политики*: в отличие от строго структурированного процесса, используемого для новых списков, систематических процедур прогнозирования воздействия политики не существовало. Во многих случаях прогнозы воздействия политики рассчитывались небольшой группой и нередко в значительной степени зависели от работы одного человека. Прогнозы обычно не подвергались официальному процессу пересмотра. Не существовало руководящих принципов относительно того, как строить сусденческие прогнозы воздействия политики, и часто отсутствовала адекватная документация о том, как эти прогнозы, лежащие в их основе допущения, были получены, и т. д.

Следовательно, мы рекомендовали внести несколько изменений:

- следует разработать руководящие принципы прогнозирования последствий новой политики с целью поощрения более систематического и структурированного подхода к прогнозированию;
- следует документировать методологию прогнозирования в каждом конкретном случае, включая все допущения, принятые при формировании прогнозов;
- прогнозы в отношении новых политик должны делаться по меньшей мере двумя людьми из разных областей организации;
- пересмотр прогнозов должен проводиться комитетом по пересмотру через год после внедрения каждой новой политики, в особенности в отношении новых стратегий, которые предполагают значительные ежегодные затраты или экономию. В состав комитета по пересмотру должны входить не только те, кто участвует в продуцировании прогнозов, но и другие лица.

Указанные рекомендации отражают принципы, изложенные в этом разделе.

## 6.3 Дельфийский метод

Дельфийский метод был изобретен Олафом Хелмером и Норманом Далки из корпорации Rand в 1950-х годах с целью решения конкретной военной задачи. Указанный метод основан на ключевом допущении о том, что прогнозы, сделанные группой, как правило, более точны, чем прогнозы отдельных лиц. Целью дельфийского метода является построение консенсусных прогнозов группой экспертов структурированным итеративным способом. Для осуществления процесса и управления им назначается куратор (или фасилитатор). Дельфийский метод обычно включает в себя следующие ниже стадии:

1. Собирается группа экспертов.
2. Работы/задачи прогнозирования ставятся и распределяются среди экспертов.
3. Эксперты возвращают первоначальные прогнозы и обоснования. Они компонуются и обобщаются, для того чтобы обеспечить обратную связь.
4. Обратная связь предоставляется экспертам, которые теперь пересматривают свои прогнозы в свете обратной связи. Этот шаг может повторяться до тех пор, пока не будет достигнут удовлетворительный уровень консенсуса.

5. Окончательные прогнозы строятся путем агрегирования прогнозов экспертов.

Каждая стадия применения дельфийского метода сопряжена со своими собственными задачами. В дальнейшем мы приводим некоторые предложения и обсуждения по каждому из них[1].

## Эксперты и анонимность

Первая задача куратора состоит в том, чтобы определить группу экспертов, которые могут внести свой вклад в задачу прогнозирования. Обычно предлагается от 5 до 20 экспертов с разнообразным опытом. Эксперты представляют прогнозы, а также предоставляют подробные качественные обоснования для них.

Ключевой особенностью дельфийского метода является то, что участвующие эксперты всегда остаются анонимными. Это означает, что эксперты не могут зависеть от политического и социального давления в своих прогнозах. Кроме того, всем экспертам предоставляется равное право голоса, и все они несут ответственность за свои прогнозы. Это позволяет избегать ситуации, когда проводится групповое собрание и некоторые участники не вносят свой вклад, в то время как другие доминируют. Это также не позволяет членам оказывать ненадлежащее влияние, основанное на старшинстве или личности. Высказывались предположения, что даже такая простая вещь, как расположение сидячих мест в групповой обстановке, может повлиять на динамику группы. Кроме того, существует множество свидетельств того, что обстановка группового собрания способствует энтузиазму и влияет на индивидуальные суждения, что приводит к оптимизму и чрезмерной уверенности[2].

Побочным продуктом анонимности является то, что экспертам не нужно встречаться как группе в физическом месте. Важным преимуществом этого является повышение вероятности привлечения экспертов с разнооборазными навыками и опытом из разных мест. Кроме того, это делает процесс экономически эффективным, устраняя расходы и неудобства, связанные с поездками, и гибким, поскольку эксперты должны только соблюдать общий крайний срок представления прогнозов, а не устанавливать общее время совещания.

## Постановка задачи прогнозирования в дельфийском методе

В дельфийской обстановке бывает полезно провести предварительный раунд сбора информации от экспертов, прежде чем ставить задачи прогнозирования. В качестве альтернативы, когда эксперты представляют свои первоначальные прогнозы и обоснования, куратор может выявить ценную информацию, которая не является общей для всех экспертов, при компоновании обратной связи.

---

[1] Для дальнейшего ознакомления обратитесь к: *Роуи* (2007, *https://otexts.com/fpp3/delphimethod.html#ref-Rowe2007*); *Роуи и Райт* (1999, *https://otexts.com/fpp3/delphimethod.html#ref-RW99*).

[2] См. *Бюлер и соавт.* (2005, *https://otexts.com/fpp3/delphimethod.html#ref-Buehler2005*).

## Обратная связь

Обратная связь с экспертами должна включать сводную статистику прогнозов и краткое описание качественных обоснований. Для обобщения прогнозов экспертов могут использоваться сводные числовые данные и графические представления.

Поскольку обратная связь контролируется куратором, существует возможность направлять внимание и информацию экспертов в те области, где это наиболее необходимо. Например, куратор может обратить внимание экспертов на ответы, которые выходят за пределы межквартильного размаха, и на качественное обоснование таких прогнозов.

## Итерация

Процесс представления экспертами прогнозов, получения обратной связи и пересмотра своих прогнозов в свете обратной связи повторяется до тех пор, пока не будет достигнут удовлетворительный уровень консенсуса между экспертами. Удовлетворительный консенсус не означает полного совпадения прогнозных значений; это просто означает, что вариабельность ответов снизилась до удовлетворительного уровня. Обычно достаточно двух или трех раундов. Эксперты с большей вероятностью будут отсеиваться по мере увеличения числа итераций, поэтому следует избегать слишком большого числа раундов.

## Окончательные прогнозы

Окончательные прогнозы обычно строятся путем придания равного веса всем экспертным прогнозам. Однако куратор должен иметь в виду возможность экстремальных значений, которые могут искажать окончательный прогноз.

## Ограничения и вариации

Применение дельфийского метода может занимать много времени. На групповом совещании окончательные прогнозы могут быть получены за несколько часов или даже минут, что практически невозможно сделать в дельфийской обстановке. Если для достижения консенсуса в дельфийской обстановке требуется много времени, то группа может потерять интерес и сплоченность.

В групповой обстановке личное взаимодействие может приводить к более быстрому и качественному разъяснению качественных обоснований. Разновидностью дельфийского метода, который находит широкое применение, является метод «оценить–обсудить–оценить», при котором эксперты могут взаимодействовать между итерациями, хотя представленные прогнозы попрежнему могут оставаться анонимными. Недостатком этого варианта является возможность чрезмерного влияния со стороны самого громкого человека.

## Куратор

Роль куратора имеет первостепенное значение. Куратор в значительной степени отвечает за разработку и администрирование дельфийского процесса. Куратор также отвечает за предоставление обратной связи экспертам и генери-

рование окончательных прогнозов. В этой роли куратор должен обладать достаточным опытом, чтобы распознавать области, которые могут потребовать большего внимания, и направлять на них внимание экспертов. Кроме того, поскольку между экспертами нет личного взаимодействия, куратор отвечает за распространение важной информации. Эффективность и результативность куратора могут значительно повышать вероятность успешного применения дельфийского метода в условиях сурденческого прогнозирования.

## Библиография

*Бюлер Р., Мессервей Д. и Гриффин Д.* (2005). Совместное планирование и прогнозирование: влияет ли групповое обсуждение на оптимистические отклонения в оценивании времени? Organizational Behavior and Human Decision Processes, 97 (1), 47–63. [DOI: https://doi.org/10.1016/j.obhdp.2005.02.004].

*Роу, Г.* (2007). Путеводитель по дельфийскому методу. Foresight: The International Journal of Applied Forecasting, 8, 11–16.

*Роу, Г. и Райт, Г.* (1999). Дельфийский метод как инструмент прогнозирования: проблемы и анализ. International Journal of Forecasting, 15 (4), 353–375. [DOI: https://doi.org/10.1016/S0169-2070(99)00018-7].

# 6.4 Прогнозирование по аналогии

Полезным сурденческим подходом, который часто применяется на практике, является прогнозирование по аналогии. Распространенным примером выступает определение цены дома в процессе оценивания. Оценщик оценивает рыночную стоимость дома, сравнивая его с аналогичными объектами недвижимости, которые были проданы в этом районе. Степень сходства зависит от рассматриваемых атрибутов. При оценивании дома обычно учитываются такие характеристики, как размер земельного участка, площадь жилья, число спален и ванных комнат, а также площадь гаража.

Генерировать полезную (а иногда и важную) информацию могут даже обдумывание и обсуждение аналогичных продуктов или ситуаций. Мы проиллюстрируем этот момент следующим ниже примером[1].

## Пример: разработка учебной программы средней школы

Небольшой группе ученых и преподавателей была поставлена задача разработать учебную программу для обучения суждению и принятию решений в условиях неопределенности для средних школ Израиля. Каждого члена группы попросили спрогнозировать количество времени, которое потребуется для завершения учебной программы. Ответы варьировались от 18 до 30 месяцев. Одного из членов группы, который был экспертом в разработке учебных программ, попросили рассмотреть аналогичные разработки учебных программ по всему миру. Он пришел к выводу, что 40 % аналогичных групп, которые он рассматривал, так и не выполнили эту задачу. Остальное заняло от 7 до 10 лет. Израильский проект был завершен за 8 лет.

[1] Этот пример взят из *Канеман и Ловалло* (1993, *https://otexts.com/fpp3/analogies.html#ref-Kahneman1993*).

Очевидно, что прогнозирование по аналогии сопряжено с трудностями. Мы должны стремиться основывать прогнозы на многочисленных аналогиях, а не на одной аналогии, которая может приводить к систематическому смещению. Однако их бывает сложно идентифицировать. Точно так же мы должны стремиться учитывать многочисленные атрибуты. Их идентификация или даже сравнение не всегда бывает простым делом. Как всегда, мы предлагаем проводить эти сравнения и процесс прогнозирования с использованием систематического подхода. Разработка подробного механизма оценивания с целью ранжирования атрибутов и регистрирования процесса ранжирования всегда будет полезна.

## Структурированная аналогия

В качестве альтернативы может быть внедрен структурированный подход, включающий группу экспертов, как это было предложено в Грин и Армстронг (2007, *https://otexts.com/fpp3/analogies.html#ref-Green2007*). Данная концепция аналогична дельфийской концепции; однако задача прогнозирования завершается рассмотрением аналогий. Сначала назначается куратор. Затем структурированный подход включает в себя следующие ниже шаги.

1. Собирается группа экспертов, которые, вероятно, имеют опыт работы с аналогичными ситуациями.
2. Работы/задачи ставятся и распределяются среди экспертов.
3. Эксперты выявляют и описывают как можно больше аналогий и формируют прогнозы на основе каждой аналогии.
4. Эксперты перечисляют сходства и различия каждой аналогии с целевой ситуацией, затем оценивают сходство каждой аналогии с целевой ситуацией по шкале.
5. Прогнозы выводятся куратором с использованием установленного правила. Это может быть средневзвешенное значение, где веса могут определяться ранговыми баллами каждой аналогии экспертами.

Как и в случае с дельфийским подходом, анонимность экспертов может быть преимуществом, поскольку она не подавляет творческий потенциал, но может препятствовать сотрудничеству. В своих результатах Грин и Армстронг не нашли никакой выгоды в сотрудничестве между экспертами. Их ключевым выводом было то, что эксперты, проводившие несколько аналогий (более двух) и имевшие непосредственный опыт работы с аналогиями, давали наиболее точные прогнозы.

## Библиография

*Грин, К. К. и Армстронг, Дж. С.* (2007). Структурированные аналогии для прогнозирования. International Journal of Forecasting, 23 (3), 365–376. [DOI: https://doi.org/10.1016/j.ijforecast.2007.05.005].

*Канеман Д. и Ловалло Д.* (1993). Робкий выбор и смелые прогнозы: когнитивный взгляд на принятие риска. Management Science, 39 (1), 17–31. [DOI: https://doi.org/10.1287/mnsc.39.1.17].

## 6.5 Сценарное прогнозирование

Принципиально иной подход к сурденческому прогнозированию состоит в сценарно ориентированном прогнозировании. Целью этого подхода является генерирование прогнозов на основе вероятных сценариев. В отличие от двух предыдущих подходов (дельфийского и прогнозирования по аналогии), где предполагается, что результирующий прогноз является вероятным результатом, каждый сценарно ориентированный прогноз может иметь низкую вероятность наступления. Сценарии разрабатываются с учетом всех возможных факторов или движущих сил, их относительного воздействия, взаимодействия между ними и прогнозируемых целей.

Строительство сценарно ориентированных прогнозов позволяет генерировать широкий спектр возможных прогнозов и выявлять некоторые экстремальные ситуации. Например, обычно представляются сценарии «наилучшего», «среднего» и «наихудшего» развития событий, хотя будет сгенерировано множество других сценариев. Обдумывание и документирование этих противоположных крайностей может приводить к раннему планированию на случай непредвиденных обстоятельств.

При сценарном прогнозировании принимающие решения лица нередко участвуют в генерировании сценариев. Хотя такое участие может приводить к некоторым систематическим смещениям, оно может облегчать доведение сценарных прогнозов и приводить к более глубокому пониманию результатов.

## 6.6 Прогнозирование новых продуктов

Определение понятия нового продукта может варьироваться. Это может быть совершенно новый продукт, который был запущен, вариация существующего продукта («новый и улучшенный»), изменение схемы ценообразования существующего продукта или даже выход существующего продукта на новый рынок.

Сурденческое прогнозирование обычно является единственным доступным методом прогнозирования новых продуктов, поскольку нет исторических данных. При прогнозировании спроса на новый продукт применимы подходы, которые мы уже описали (дельфийский, прогнозирование по аналогии и сценарное прогнозирование).

Также есть другие методы, которые более специфичны для конкретной ситуации. Мы кратко опишем три таких метода, которые обычно применяются на практике. Эти методы менее структурированы, чем те, которые уже обсуждались, и в результате, вероятно, приведут к более смещенным прогнозам.

### Композитный прогноз торгового отдела

При таком подходе прогнозы по каждой торговой точке/филиалу/магазину компании формируются продавцами, а затем агрегируются. Обычно это связано с тем, что менеджеры по продажам прогнозируют спрос на торговую точку, которой они управляют. Продавцы, как правило, находятся ко взаимодействию между клиентами и продуктами ближе всего и часто развивают интуицию относительно покупательских намерений клиентов. Они привносят в прогноз этот ценный опыт и знания.

Однако генерирование прогнозов продавцами нарушает ключевой принцип сегрегирования прогнозистов и пользователей, что может приводить к систематическому смещению во многих направлениях. Обычно результативность работы продавца оценивается в соответствии с заранее установленными прогнозами или ожиданиями продаж. В этом случае продавец, выступающий в роли прогнозиста, может вносить некоторое корыстное смещение, создавая заниженные прогнозы. С другой стороны, можно представить себе восторженного продавца, полного оптимизма, делающего высокие прогнозы.

Более того, успешный продавец не обязательно является успешным или хорошо информированным прогнозистом. Значительная часть продавцов не будет иметь никакого или ограниченного формального обучения прогнозированию. Наконец, продавцы на собственном опыте почувствуют недовольство покупателей, если, например, товар закончится или его не будет в их магазине. Такое взаимодействие затуманит их суждения.

## Мнение руководства

В отличие от композитного прогноза отдела продаж, этот подход предусматривает, что агрегатные прогнозы формируются сотрудниками на самом верху управленческой структуры. Такие прогнозы обычно формируются на групповом совещании, на котором руководители предоставляют информацию из своего подразделения компании. Наличие руководителей из разных функциональных областей компании способствует большому разнообразию навыков и знаний в группе.

Этот процесс несет в себе все преимущества и недостатки группового совещания, которые мы обсуждали ранее. В этой ситуации важно обосновывать и документировать процесс прогнозирования. То есть руководители должны привлекаться к ответственности, чтобы уменьшать систематические смещения, порождаемые обстановкой группового совещания. В этом случае также могут быть возможности для применения вариаций дельфийского подхода, например описанный ранее процесс оценить–обсудить–оценить.

## Намерения клиентов

Намерения клиентов могут использоваться для прогнозирования спроса на новый продукт или на изменение существующего продукта. Покупатели заполняют анкеты относительно их намерений приобрести товар. Используется структурированная анкета, в которой клиентам предлагается оценить по определенной шкале вероятность того, что они купят продукт; например, «весьма вероятно», «вероятно», «возможно», «маловероятно», «крайне маловероятно».

При этом необходимо решить проблемы, связанные с разработкой выборочного обследования, такие как сбор репрезентативной выборки, применение эффективного по времени и затратам метода и улаживание неполученных ответов[1].

Кроме того, при проведении данного опроса мы должны иметь в виду взаимосвязь между намерением совершить покупку и покупательским поведением. Клиенты не всегда делают то, что обещают. Многие исследования выявили положительную корреляцию между намерениями совершить покупку и по-

[1] См. *Гроувс и соавт.* (2009, *https://otexts.com/fpp3/new-products.html#ref-Groves2009*).

купательским поведением; однако сила этих корреляций существенно различается. Факторы, определяющие это различие, включают сроки сбора данных и запуска продукта, определение термина «новый» для продукта и тип отрасли. Бихевиористская теория говорит о том, что намерения предсказывают поведение, если намерения измеряются непосредственно перед поведением[1]. Время между намерением и поведением будет варьироваться в зависимости от того, является ли это совершенно новым продуктом или вариацией существующего продукта. Кроме того, корреляция между намерением и поведением оказывается сильнее для вариаций существующих и знакомых продуктов, чем для совершенно новых продуктов.

Какой бы метод прогнозирования новых продуктов ни использовался, важно тщательно документировать сделанные прогнозы и лежащие в их основе обоснования, чтобы иметь возможность их оценить, когда данные станут доступны.

## Библиография

*Гроувз, Р. М., Фаулер, Ф. Дж., Купер, М. П., Лепковски, Дж. М., Сингер, Э. и Туранго, Р.* (2009). Методология опроса (2-е изд.). John Wiley & Sons. [Amazon, http://buy.geni.us/Proxy.ashx?TSID=140570&GR_URL=http%3A%2F%2Fwww.amazon.com%2Fdp%2F0470465468].

*Рэндалл, Д. М. и Вольф, Дж. А.* (1994). Временной интервал во взаимосвязи намерение–поведение: метаанализ. British Journal of Social Psychology, 33 (4), 405-418. [DOI: https://doi.org/10.1111/j.2044-8309.1994.tb01037.x].

# 6.7 Сужденческие корректировки

В этом заключительном разделе мы рассмотрим ситуацию, когда исторические данные доступны и используются для генерирования статистических прогнозов. Практикующие специалисты обычно затем применяют к этим прогнозам сужденческие корректировки. Указанные корректировки потенциально могут обеспечивать все преимущества сужденческого прогнозирования, которые обсуждались ранее в этой главе. Например, они предоставляют возможность для включения факторов, которые могут не учитываться в статистической модели, такие как рекламные акции, крупные спортивные мероприятия, праздники или недавние события, которые еще не отражены в данных. Однако эти преимущества проявляются только при наличии надлежащих условий. Сужденческие корректировки, как и сужденческие прогнозы, сопряжены с систематическими смещениями и ограничениями, и необходимо применять методические стратегии, чтобы сводить их к минимуму.

## Использовать корректировки экономно

Практикующие специалисты вносят корректировки гораздо чаще, чем следовало бы, и нередко по неправильным причинам. Корректируя статистические прогнозы, пользователи прогнозов создают чувство сопричастности и доверия. Пользователи часто не понимают или не ценят механизмы, которые генерируют статистические прогнозы (поскольку они, как правило, не имеют

[1] См. *Рэндалл и Вольф* (1994, *https://otexts.com/fpp3/new-products.html#ref-RW94*).

подготовки в этой области). Внося сусденческие корректировки, пользователи чувствуют, что они внесли свой вклад в прогнозы и завершили их и теперь могут соотносить с ними свою собственную интуицию и интерпретации. Прогнозы стали их собственными.

Сусденческие корректировки не должны нацеливаться на исправление систематической закономерности в данных, которая, как считается, была упущена статистической моделью. Было доказано, что это неэффективно, поскольку прогнозисты склонны читать несуществующие закономерности в зашумленных рядах. Статистические модели гораздо лучше учитывают закономерности данных, а сусденческие корректировки только снижают точность.

Сусденческие корректировки наиболее эффективны, когда имеется значительная дополнительная информация или убедительные доказательства необходимости корректировки. Следует вносить корректировки только тогда, когда имеется важная дополнительная информация, которая не включена в статистическую модель. Следовательно, корректировки, по-видимому, наиболее точны, когда они имеют большой размер. Было обнаружено, что малые корректировки (в особенности в положительном направлении, способствующие иллюзии оптимизма) препятствуют точности, и их следует избегать.

## Применять структурированный подход

Использование структурированного и систематического подхода будет повышать точность сусденческих корректировок. Жизненно важно следовать ключевым принципам, изложенным в разделе 6.2. В частности, необходимость документирования и обоснования корректировок усложнит переопределение статистических прогнозов и защитит от ненужных корректировок.

Обычно корректировки выполняются группой (см. следующий ниже пример). Использование дельфийской обстановки имеет большие преимущества. Однако если корректировки вносятся на групповом совещании, разумно сначала рассмотреть прогнозы по ключевым рынкам или продуктам, поскольку члены группы во время этого процесса устанут. Как правило, по мере того как совещание продолжается в течение дня, вносится все меньше корректировок.

## Пример: комитет по прогнозированию туризма (TFC)

Корпорация Tourism Australia публикует прогнозы по всем аспектам австралийского туризма два раза в год. Опубликованные прогнозы составляются TFC, независимым органом, в состав которого входят эксперты из различных национальных и промышленных секторов, например Казначейство Австралийского Содружества, авиакомпании, консалтинговые фирмы, компании банковского сектора и туристические организации.

Применяемая методология прогнозирования представляет собой итеративный процесс. Сначала статистические модельно ориентированные прогнозы формируются отделом прогнозирования в Tourism Australia, затем в них в два этапа вносятся сусденческие корректировки. В первом раунде Технический комитет TFC[1] (в состав которого входят старшие исследователи, экономисты

[1] В течение нескольких лет Атанасопулос был наблюдателем в этом техническом комитете.

и независимые консультанты) корректирует модельно ориентированные прогнозы. Во втором и заключительном раунде TFC (в состав которого входят отраслевые и правительственные эксперты) вносит окончательные корректировки. В обоих раундах корректировки вносятся консенсусно.

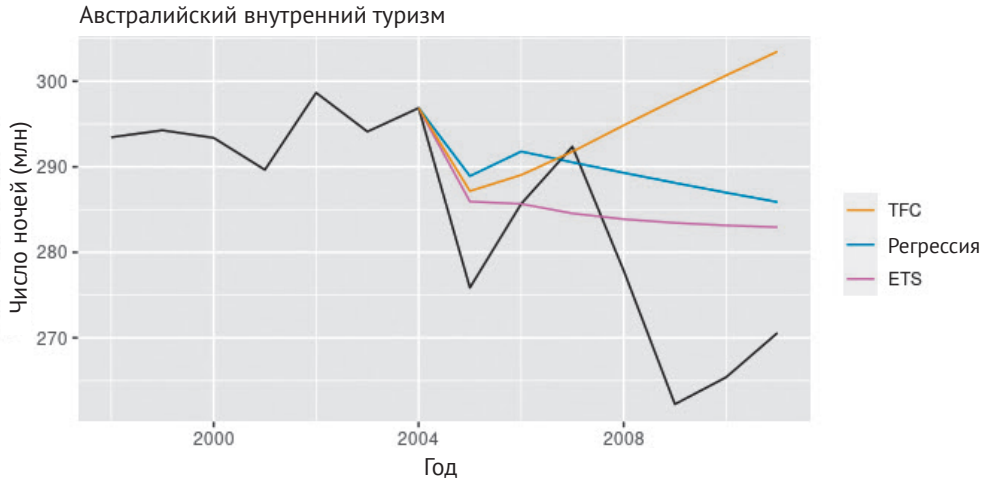


**Рисунок 6.2:** Долгосрочные годовые прогнозы числа поездок с ночевкой для внутренних туристов в Австралии. Мы изучаем регрессионные модели в главе 7, а модели ETS (экспоненциального сглаживания) – в главе 8

В 2008 году мы[1] проанализировали прогнозы внутреннего туризма Австралии. Мы пришли к выводу, что опубликованные прогнозы TFC были оптимистичными, в особенности в долгосрочной перспективе, и предложили альтернативные модельно ориентированные прогнозы. Теперь у нас есть доступ к наблюдаемым данным за период до 2011 года включительно. На рис. 6.2 мы сопоставляем опубликованные прогнозы с фактическими данными. Мы видим, что опубликованные прогнозы TFC продолжают оставаться оптимистичными.

Чему можно научиться на этом примере? Хотя в методологии TFC четко указано, что он производит «прогнозы», а не «целевые показатели», может ли это быть случаем, когда они были перепутаны? Достаточно ли хорошо в этом процессе сегрегированы прогнозисты и пользователи? Можно ли улучшить сам итеративный процесс? Можно ли улучшить процесс корректировки на совещаниях? Может быть, групповые совещания способствовали росту оптимизма? Может быть, о внутреннем туризме следовало подумать заблаговременно?

## Библиография

*Атанасопулос, Г. и Хайндман, Р. Дж.* (2008). Моделирование и прогнозирование внутреннего туризма Австралии. Tourism Management, 29 (1), 19–31. [DOI: https://doi.org/10.1016/j.tourman.2007.04.009].

[1] См. *Дж. Атанасопулос и Хайндман* (2008, *https://otexts.com/fpp3/judgmental-adjustments.html#ref-austourism*).

## 6.8 Дальнейшее чтение

Многие учебники по прогнозированию вообще игнорируют сужденческое прогнозирование. Ниже приведено три учебника, в которых оно описывается довольно подробно.

- Глава 11 Орд и соавт. (2017, *https://otexts.com/fpp3/judgmental-reading.html#ref-Ord2017*) содержит отличный обзор некоторых тем, что и в этой главе, но также включает использование суждений для оценивания неопределенности прогноза и прогнозирования с использованием предсказательных рынков.
- Гудвин и Райт (2009, *https://otexts.com/fpp3/judgmental-reading.html#ref-GW04*) посвящена использованию суждений при принятии решений и написана двумя ведущими исследователями в этой области.
- Кан (2006, *https://otexts.com/fpp3/judgmental-reading.html#ref-Kahn2006*) описывает методы прогнозирования новых продуктов, где важную роль играют сужденческие методы.

За последние 20 лет было опубликовано несколько полезных обзорных работ по сужденческому прогнозированию. Три из них мы нашли особенно полезными:

- Филдс и Гудвин (2007b, *https://otexts.com/fpp3/judgmental-reading.html#ref-Fildes2007a*);
- Филдс и Гудвин (2007a, *https://otexts.com/fpp3/judgmental-reading.html#ref-Fildes2007*);
- Харви (2001, *https://otexts.com/fpp3/judgmental-reading.html#ref-Harvey2001*).

Ниже приведена таблица, в которой перечислены некоторые полезные документы, посвященные индивидуальным методам сужденческого прогнозирования.

| Метод прогнозирования | Рекомендуемые статьи |
|---|---|
| Дельфийский метод | Роуи и Райт (1999) |
| | Роуи (2007) |
| Корректировки | Сандерс и соавт. (2005) |
| | Эроглу и Крокстон (2010) |
| | Франсес и Леже (2013) |
| Аналогия | Грин и Армстронг (2007) |
| Сценарии | Онкал и соавт. (2013) |
| Намерения клиентов | Морвитц и соавт. (2007) |

## Библиография

*Эроглу, К. и Крокстон, К. Л.* (2010). Систематическое смещение в сужденческих корректировках статистических прогнозов: роль индивидуальных различий. International Journal of Forecasting, 26 (1), 116–133. [DOI: https://doi.org/10.1016/j.ijforecast.2009.02.005].

*Филдес, Р. и Гудвин, П.* (2007a). Вопреки твоему здравому смыслу? Как организации могут улучшить использование управленческих суждений при прогнозировании. Interfaces, 37 (6), 570–576. [DOI: https://doi.org/10.1287/inte.1070.0309].

*Филдес, Р. и Гудвин, П.* (2007b). Правильное и неправильное суждение в прогнозировании: уроки четырех компаний. Foresight: The International Journal of Applied Forecasting, 8, 5–10.

*Франсес, П. Х. и Легерсти, Р.* (2013). Выигрывают ли статистические модели прогнозирования для данных на уровне SKU от включения прошлых экспертных знаний? International Journal of Forecasting, 29 (1), 80–87. [DOI: https://doi.org/10.1016/j.ijforecast.2012.05.008].

*Гудвин П. и Райт Г.* (2009). Анализ решений для принятия управленческих решений (4-е изд.). John Wiley & Sons. [Amazon, *http://buy.geni.us/Proxy.ashx?TSID=140570&GR_URL=http%3A%2F%2Fwww.amazon.com%2Fdp%2F0470714395*].

*Грин, К. К. и Армстронг, Дж. С.* (2007). Структурированные аналогии для прогнозирования. International Journal of Forecasting, 23 (3), 365–376. [DOI: https://doi.org/10.1016/j.ijforecast.2007.05.005].

*Харви, Н.* (2001). Улучшение суждений при прогнозировании. В кн.: *Дж. С. Армстронг* (ред.). Принципы прогнозирования: руководство для исследователей и практиков (стр. 59–80). Изд-во Kluwer Academic Publishers. [DOI: https://doi.org/10.1007/978-0-306-47630-3_4].

*Кан, К. Б.* (2006). Прогнозирование новых продуктов: прикладной подход / М. Э. Шарп. [Amazon, *http://buy.geni.us/Proxy.ashx?TSID=140570&GR_URL=http%3A%2F%2Fwww.amazon.com%2Fdp%2F0765616092*].

*Морвиц, В. Г., Штекель, Дж. Х. и Гупта, А.* (2007). Когда намерения о покупке предсказывают продажи? International Journal of Forecasting, 23 (3), 347–364. [DOI: https://doi.org/10.1016/j.ijforecast.2007.05.015].

*Онкал, Д., Сайим, К. З. и Генюль, М. С.* (2013). Сценарии как каналы получения рекомендаций по прогнозированию. Technological Forecasting and Social Change, 80 (4), 772–788. [DOI: https://doi.org/10.1016/j.techfore.2012.08.015].

*Орд, Дж. К., Филдес, Р. и Курентзес, Н.* (2017). Принципы бизнес-прогнозирования (2-е изд.). Wessex Press Publishing Co. [Amazon, *http://buy.geni.us/Proxy.ashx?TSID=140570&GR_URL=http%3A%2F%2Fwww.amazon.com%2Fdp%2F0999064916*].

*Роу, Г.* (2007). Путеводитель по дельфийскому методу. Foresight: The International Journal of Applied Forecasting, 8, 11–16.

*Роу, Г. и Райт, Г.* (1999). Дельфийский метод как инструмент прогнозирования: проблемы и анализ. International Journal of Forecasting, 15 (4), 353–375. [DOI: https://doi.org/10.1016/S0169-2070(99)00018-7].

*Сандерс, Н., Гудвин, П., Онкал, Д., Генюль, М. С., Харви, Н., Ли, А. и Кьолсо, Л.* (2005). Когда и как следует корректировать статистические прогнозы на основе суждений? Foresight: The International Journal of Applied Forecasting, 1 (1), 5–23.

# Глава 7

# Модели регрессии временных рядов

В этой главе мы обсудим регрессионные модели. Базовая концепция заключается в том, что мы прогнозируем интересующий нас временной ряд *y*, исходя из допущения о том, что он имеет линейную взаимосвязь с другими временными рядами *x*.

Например, мы могли бы захотеть спрогнозировать ежемесячные продажи *y*, используя в качестве предсказателя суммарные расходы на рекламу *x*. Или же мы могли бы спрогнозировать ежедневный спрос на электроэнергию *y*, используя в качестве предсказателей температуру $x_1$ и день недели $x_2$.

**Прогнозная переменная** *y* иногда также называется регрессандом, зависимой или объясняемой переменной. **Предсказательные переменные** *x* иногда также называются регрессорами, предикторами, независимыми или объясняющими переменными. В этой книге мы всегда будем называть их «прогнозной» и «предсказательными» переменными.

## 7.1 Линейная модель

### Простая линейная регрессия

В простейшем случае регрессионная модель допускает линейную взаимосвязь между прогнозной переменной *y* и единственной предсказательной переменной *x*:

$$y_t = \beta_0 + \beta_1 x_t + \varepsilon_t.$$

Искусственный пример данных из такой модели показан на рис. 7.1. Коэффициенты $\beta_0$ и $\beta_1$ обозначают соответственно пересечение и наклон линии. Пересечение $\beta_0$ представляет предсказанное значение *y* при $x = 0$. Наклон $\beta_1$ представляет среднее предсказанное изменение в *y* в результате единичного увеличения в *x*:

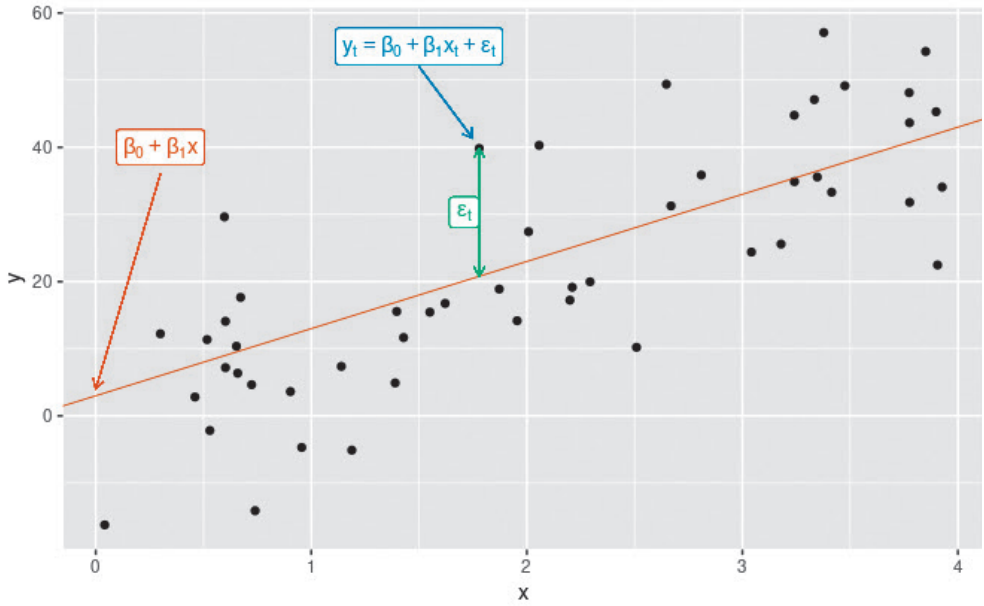


**Рисунок 7.1:** Пример данных из модели простой линейной регрессии

Обратите внимание, что наблюдения не лежат на прямой линии, а разбросаны вокруг нее. О каждом наблюдении $y_t$ можно думать как состоящем из систематической или объясненной части модели, $\beta_0 + \beta_1 x_t$, и случайной «ошибки», $\varepsilon_t$. Термин «ошибка» подразумевает не промашку, а отклонение от опорной прямолинейной модели. Он улавливает все, что может повлиять на $y_t$, отличное от $x_t$.

## Пример: потребительские расходы в США

На рис. 7.2 показаны временные ряды квартальных процентных изменений (темпов роста) реальных расходов на личное потребление, $y$, и реального личного располагаемого дохода, $x$, для США с 1970Q1 по 2019Q2.

```
us_change %>%
  pivot_longer(c(Consumption, Income), names_to="Series") %>%
  autoplot(value) +
  labs(y = "Процентное изменение")
```

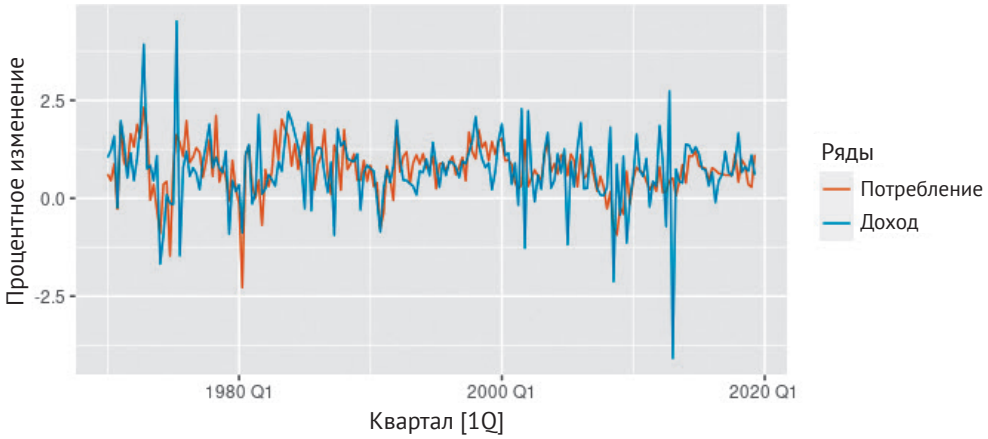


**Рисунок 7.2:** Процентные изменения в расходах на личное потребление и личных доходах в США

Точечный график изменений потребления в зависимости от изменений доходов показан на рис. 7.3 вместе с оценочной линией регрессии:

$$\hat{y}_t = 0.54 + 0.27x_t.$$

(Мы ставим «шляпку» (циркумфлекс) над $y$, чтобы обозначить, что это значение $y$, которое было предсказано моделью.)

```
us_change %>%
  ggplot(aes(x = Income, y = Consumption)) +
  labs(y = "Потребление (ежеквартальное процентное изменение)",
       x = "Доход (ежеквартальное процентное изменение)") +
  geom_point() +
  geom_smooth(method = "lm", se = FALSE)
```

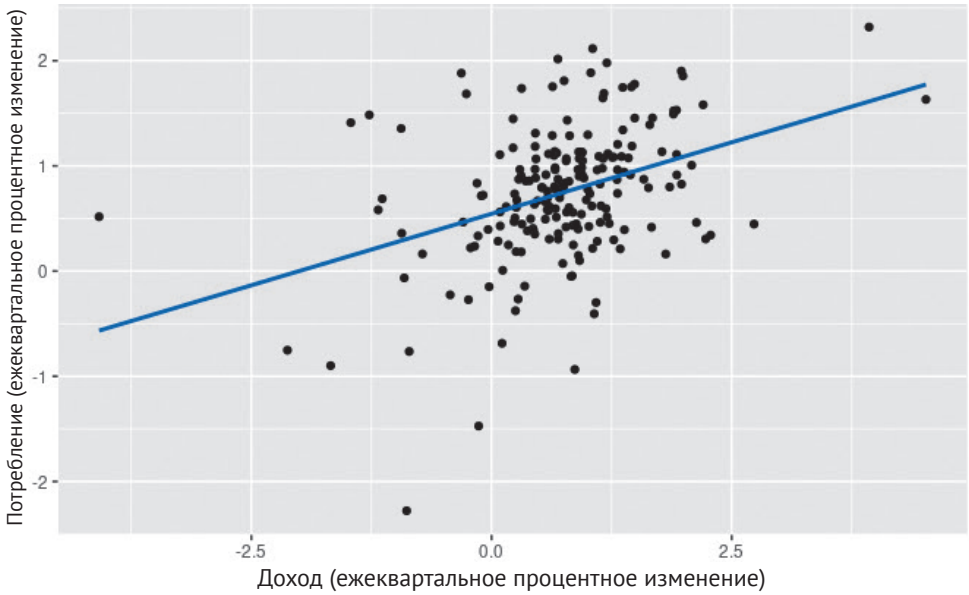


**Рисунок 7.3:** Точечный график ежеквартальных изменений в потребительских расходах в сравнении с ежеквартальными изменениями в личных доходах и подогнанная линия регрессии

Уравнение оценивается с помощью функции `TSM()`:

```
us_change %>%
  model(TSLM(Consumption ~ Income)) %>%
  report()
#> Series: Consumption
#> Model: TSLM
#>
#> Residuals:
#>     Min      1Q  Median      3Q     Max
#> -2.5824 -0.2778  0.0186  0.3233  1.4223
#>
#> Coefficients:
#>             Estimate Std. Error t value Pr(>|t|)
#> (Intercept)   0.5445     0.0540   10.08  < 2e-16 ***
#> Income        0.2718     0.0467    5.82  2.4e-08 ***
#> ---
#> Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
#>
#> Residual standard error: 0.591 on 196 degrees of freedom
#> Multiple R-squared: 0.147,   Adjusted R-squared: 0.143
#> F-statistic: 33.8 on 1 and 196 DF, p-value: 2.4e-08
```

Мы обсудим процедуру, с помощью которой функция `TSLM()` вычисляет коэффициенты, в разделе 7.2.

Подогнанная линия имеет положительный наклон, отражающий положительную взаимосвязь между доходом и потреблением. Коэффициент наклона показывает, что единичное увеличение *x* (увеличение личного располагаемого дохода на 1 процентный пункт) приводит в среднем к увеличению на 0.27 единицы в *y* (средний рост расходов на личное потребление составил 0.27 процентных пункта). В качестве альтернативы расчетное уравнение показывает, что значение 1 для *x* (процентное увеличение личного располагаемого дохода) будет приводить к прогнозному значению 0.54 + 0.27 × 1 = 0.82 для *y* (процентное увеличение расходов на личное потребление).

Интерпретация пересечения требует, чтобы значение $x = 0$ имело смысл. В данном случае, когда $x = 0$ (т. е. когда нет изменений в личном располагаемом доходе с последнего квартала), прогнозное значение *y* составляет 0.54 (т. е. среднее увеличение расходов на личное потребление на 0.54 %). Пересечение является важной частью модели, даже когда $x = 0$ не имеет смысла. Без этого коэффициент наклона может быть искажен без необходимости. Пересечение всегда должно быть включено, если только не требуется принудительно провести линию регрессии «через начало координат». В дальнейшем мы исходим из допущения о том, что пересечение всегда включено в модель.

## Множественная линейная регрессия

Когда имеются две или более предсказательные переменные, модель называется **моделью множественной регрессии**. Общая форма модели множественной регрессии такова:

$$y_t = \beta_0 + \beta_1 x_{1,t} + \beta_2 x_{2,t} + \cdots + \beta_k x_{k,t} + \varepsilon_t, \tag{7.1}$$

где *y* – это переменная, подлежащая прогнозированию, и $x_1, \ldots, x_k$ – это *k* предсказательных переменных. Каждая предсказательная переменная должна быть числовой. Коэффициенты $\beta_1, \ldots, \beta_k$ измеряют влияние каждого предсказателя после учета влияния всех других предсказателей в модели. Отсюда следует, что коэффициенты измеряют *предельные эффекты* предсказательных переменных.

## Пример: потребительские расходы в США

На рис. 7.4 показаны дополнительные предсказатели, которые могут быть полезны для прогнозирования потребительских расходов в США. Это ежеквартальные процентные изменения в промышленном производстве и личных сбережениях, а также ежеквартальные изменения в уровне безработицы (поскольку это уже процент). Модель множественной линейной регрессии потенциально может генерировать более точные прогнозы, поскольку мы ожидаем, что потребительские расходы будут зависеть не только от личного дохода, но и от других факторов.

```
us_change %>%
  select(-Consumption, -Income) %>%
  pivot_longer(-Quarter) %>%
  ggplot(aes(Quarter, value, colour = name)) +
  geom_line() +
  facet_grid(name ~ ., scales = "free_y") +
  guides(colour = "none") +
  labs(y="% изменения")
```

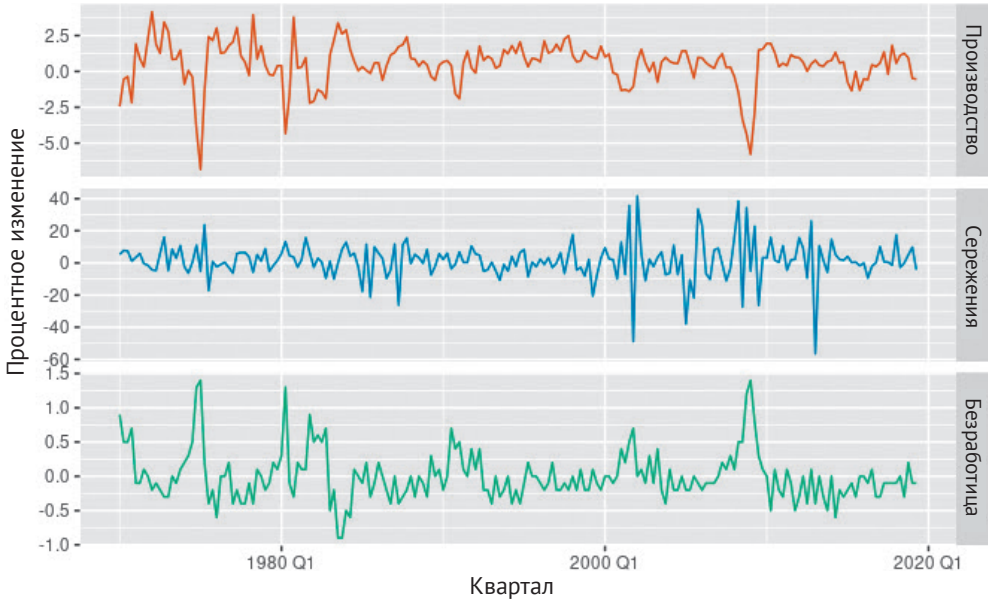


**Рисунок 7.4:** Ежеквартальные процентные изменения в промышленном производстве и личных сбережениях и ежеквартальные изменения в уровне безработицы в США за период 1970Q1–2019Q2

На рис. 7.5 представлена матрица диаграмм рассеяния из пяти переменных. В первом столбце показаны взаимосвязи между прогнозной переменной (потреблением) и каждым предсказателем. Точечные диаграммы показывают положительную взаимосвязь с доходами и промышленным производством и отрицательную взаимосвязь со сбережениями и безработицей. Сила этих взаимосвязей показана коэффициентами корреляции в первой строке. Остальные диаграммы рассеяния и коэффициенты корреляции показывают взаимосвязи между предсказателями.

```
us_change %>%
  GGally::ggpairs(columns = 2:6)
```

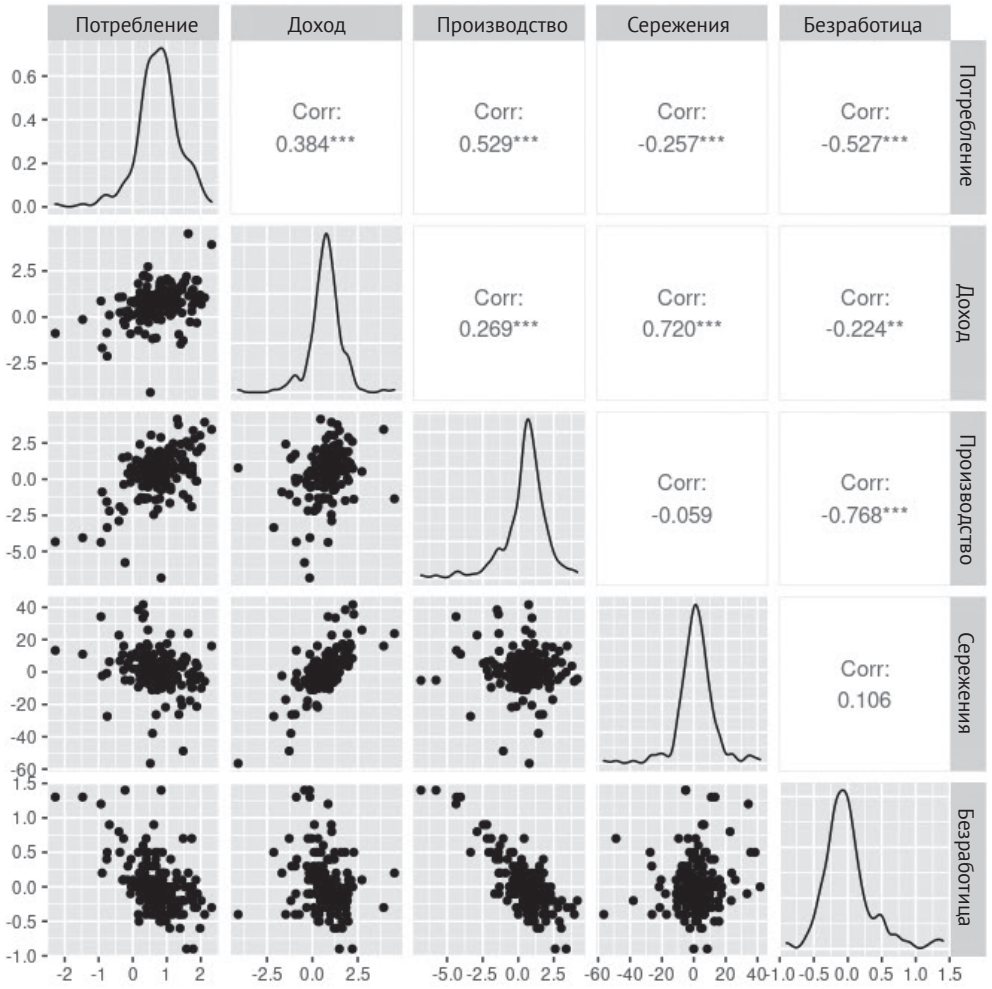


**Рисунок 7.5:** Точечная матрица потребительских расходов в США и четыре предсказателя

## Допущения

Когда мы используем модель линейной регрессии, то неявно принимаем несколько допущений относительно переменных в уравнении (7.1).

Во-первых, мы исходим из допущения о том, что модель является разумной аппроксимацией реальности; то есть взаимосвязь между прогнозной переменной и предсказательными переменными удовлетворяет этому линейному уравнению.

Во-вторых, мы принимаем следующие ниже допущения об ошибках $\varepsilon_1, \ldots, \varepsilon_T$:

- их среднее значение равно нулю; в противном случае прогнозы будут систематически смещенными;
- они не имеют автокорреляции; в противном случае прогнозы будут неэффективными, поскольку в данных содержится больше информации, которую можно использовать;

- они не связаны с предсказательными переменными; в противном случае имелось бы больше информации, которую необходимо было бы включить в систематическую часть модели.

Также полезно, чтобы ошибки были нормально распределены с постоянной дисперсией $\sigma^2$. Это нужно для того, чтобы было легко создавать предсказательные интервалы.

Еще одним важным допущением в модели линейной регрессии является то, что каждый предсказатель $x$ не является случайной величиной. Если бы мы проводили контролируемый эксперимент в лаборатории, то могли бы контролировать значения каждого $x$ (чтобы они не были случайными) и наблюдать результирующие значения $y$. Работая с данными наблюдений (включая большинство данных в бизнесе и экономике), контролировать значение $x$ невозможно, мы просто его наблюдаем. Следовательно, мы принимаем это допущение.

## 7.2 Оценивание методом наименьших квадратов

На практике, конечно, у нас есть набор наблюдений, но мы не знаем значений коэффициентов $\beta_0, \beta_1, \ldots, \beta_k$. Они должны быть оценены из данных.

Принцип наименьших квадратов обеспечивает эффективный выбор коэффициентов путем минимизирования суммы квадратов ошибок. То есть мы выбираем значения $\beta_0, \beta_1, \ldots, \beta_k$, которые минимизируют

$$\sum_{t=1}^{T} \varepsilon_t^2 = \sum_{t=1}^{T} (y_t - \beta_0 - \beta_1 x_{1,t} - \beta_2 x_{2,t} - \cdots - \beta_k x_{k,t})^2.$$

Эта формула называется оцениванием методом **наименьших квадратов**, потому что она дает наименьшее значение суммы квадратов ошибок. Отыскание наилучших оценок коэффициентов часто называют «подгонкой» модели к данным, а иногда «усвоением» значений коэффициентов моделью или «тренировкой» модели. Линия, показанная на рис. 7.3, была получена таким образом.

Когда мы будем ссылаться на *оцениваемые* коэффициенты, мы будем использовать нотацию $\hat{\beta}_0, \ldots, \hat{\beta}_k$. Уравнения для них будут приведены в разделе 7.9.

Функция `TSLM()` выполняет подгонку модели линейной регрессии к данным временного ряда. Она похожа на функцию `lm()`, которая широко используется для линейных моделей, но `TSLM()` предоставляет дополнительные возможности по обработке временных рядов.

### Пример: потребительские расходы в США

Модель множественной линейной регрессии для потребления в США такова:

$$y_t = \beta_0 + \beta_1 x_{1,t} + \beta_2 x_{2,t} + \beta_3 x_{3,t} + \beta_4 x_{4,t} + \varepsilon_t,$$

где $y$ – это процентное изменение в реальных расходах на личное потребление, $x_1$ – процентное изменение в реальном личном располагаемом доходе, $x_2$ – процентное изменение в промышленном производстве, $x_3$ – процентное изменение в личных сбережениях и $x_4$ – изменение в уровне безработицы.

Следующий ниже результат содержит информацию о подогнанной модели. Первый столбец коэффициентов дает оценку каждого коэффициента $\beta$, а во втором столбце указана его стандартная ошибка (т. е. стандартное отклонение, которое было бы получено в результате неоднократного оценивания коэффициентов $\beta$ на аналогичных наборах данных). Стандартная ошибка дает меру неопределенности в оцениваемом коэффициенте $\beta$.

```
fit_consMR <- us_change %>%
  model(tslm = TSLM(Consumption ~ Income + Production +
                                    Unemployment + Savings))
report(fit_consMR)
#> Series: Consumption
#> Model: TSLM
#>
#> Residuals:
#>     Min      1Q  Median      3Q     Max
#> -0.9055 -0.1582 -0.0361  0.1362  1.1547
#>
#> Coefficients:
#>              Estimate Std. Error t value Pr(>|t|)
#> (Intercept)   0.25311    0.03447    7.34  5.7e-12 ***
#> Income        0.74058    0.04012   18.46  < 2e-16 ***
#> Production    0.04717    0.02314    2.04    0.043 *
#> Unemployment -0.17469    0.09551   -1.83    0.069 .
#> Savings      -0.05289    0.00292  -18.09  < 2e-16 ***
#> ---
#> Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
#>
#> Residual standard error: 0.31 on 193 degrees of freedom
#> Multiple R-squared: 0.768,   Adjusted R-squared: 0.763
#> F-statistic:  160 on 4 and 193 DF, p-value: <2e-16
```

Для целей прогнозирования последние два столбца представляют ограниченный интерес. «Значение t» – это отношение оцениваемого коэффициента $\beta$ к его стандартной ошибке, а в последнем столбце указано $p$-значение: вероятность оцениваемого коэффициента $\beta$ быть таким же большим, как если бы не было реальной взаимосвязи между потреблением и соответствующим предсказателем. Оно полезно при изучении влияния каждого предсказателя, но не особенно полезно для прогнозирования.

## Подогнанные значения

Предсказания в отношении y можно получить путем использования оцениваемых в регрессионном уравнении коэффициентов и установки члена ошибки равным нулю. В общем случае мы пишем:

$$\hat{y}_t = \hat{\beta}_0 + \hat{\beta}_1 x_{1,t} + \hat{\beta}_2 x_{2,t} + \cdots + \hat{\beta}_k x_{k,t}. \tag{7.2}$$

Включение значений $x_{1,t}, \ldots, x_{k,t}$ для $t = 1, \ldots, T$ возвращает предсказания переменной $y_t$ внутри тренировочного набора, именуемые *подогнанными значениями*. Обратите внимание, что это *предсказания* данных, используемых для оценивания модели, а не подлинные *прогнозы* будущих значений $y$.

На следующих ниже графиках показаны фактические значения в сопоставлении с подогнанными значениями для процентного изменения в ряду потребительских расходов США. График времени на рис. 7.6 показывает, что подогнанные значения довольно точно соответствуют фактическим данным. Это подтверждается сильной положительной взаимосвязью, показанной диаграммой рассеяния на рис. 7.7.

```
augment(fit_consMR) %>%
  ggplot(aes(x = Quarter)) +
  geom_line(aes(y = Consumption, colour = "Данные")) +
  geom_line(aes(y = .fitted, colour = "Подогнано")) +
  labs(y = NULL,
    title = "Процентное изменение в потребительских расходах в США"
  ) +
  scale_colour_manual(values=c(Data="black",Fitted="#D55E00")) +
  guides(colour = guide_legend(title = NULL))
```

**Рисунок 7.6:** График времени в отношении фактических потребительских расходов в США и предсказанных потребительских расходов в США

```
augment(fit_consMR) %>%
  ggplot(aes(x = Consumption, y = .fitted)) +
  geom_point() +
  labs(
    y = "Подогнанные (предсказанные значения)",
    x = "Данные (фактические значения)",
    title = "Процентное изменение в потребительских расходах в США"
  ) +
  geom_abline(intercept = 0, slope = 1)
```

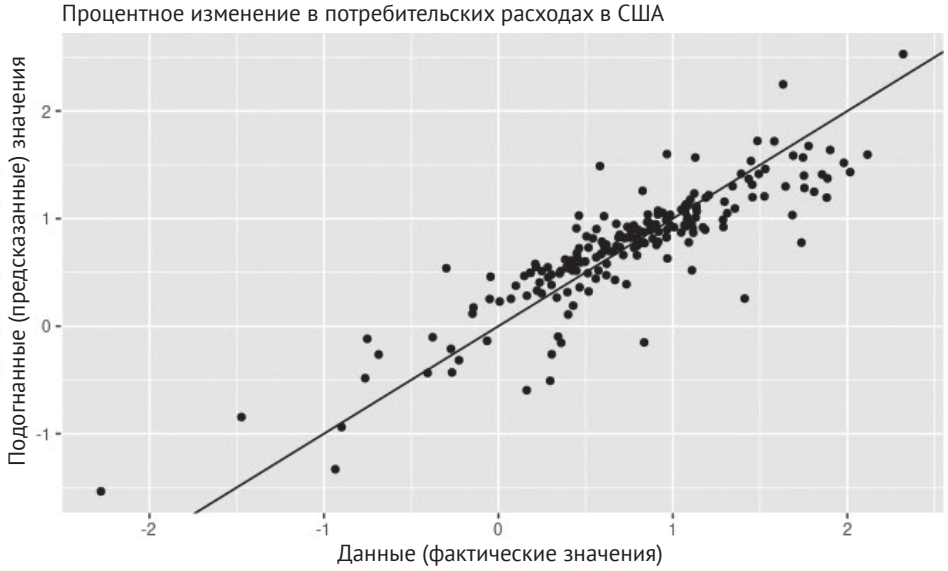


**Рисунок 7.7:** Фактические потребительские расходы в США в сопоставлении с предсказанными потребительскими расходами в США

## Качество подгонки

Распространенным способом обобщения того, насколько хорошо модель линейной регрессии подогнана под данные, является использование коэффициента детерминации, или $R^2$. Его можно рассчитать как квадрат корреляции между наблюдаемыми значениями $y$ и предсказанными значениями $\hat{y}$. В качестве альтернативы его также можно рассчитать как

$$R^2 = \frac{\sum(\hat{y}_t - \bar{y})^2}{\sum(y_t - \bar{y})^2},$$

где суммирование производится по всем наблюдениям. Таким образом, он отражает долю вариации в прогнозной переменной, которая учитывается (или объясняется) регрессионной моделью.

В простой линейной регрессии значение $R^2$ также равно квадрату корреляции между $y$ и $x$ (при условии что было включено пересечение).

Если прогнозы близки к фактическим значениям, то можно было бы ожидать, что $R^2$ будет близок к 1. С другой стороны, если предсказания не связаны с фактическими значениями, то $R2 = 0$ (опять же, при допущении о том, что имеется пересечение). Во всех случаях $R^2$ лежит между 0 и 1.

Значение $R^2$ используется в прогнозировании часто, хотя и нередко неправильно. Значение $R^2$ никогда не будет уменьшаться при добавлении дополнительного предсказателя в модель, и это может приводить к переподгонке. Нет никаких установленных правил в отношении того, каким должно быть хорошее значение $R^2$, и типичные значения $R^2$ зависят от типа используемых данных. Валидирование результативности прогнозирования модели на тестовых данных работает намного лучше, чем измерение значения $R^2$ на тренировочных данных.

## Пример: потребительские расходы в США

На рис. 7.7 показаны фактические значения расходов на потребление в сравнении с подогнанными значениями. Корреляция между этими переменными составляет $r = 0.877$ и, следовательно, $R^2 = 0.768$ (показано в приведенных выше результатах). В данном случае модель справляется отлично, поскольку объясняет 76.8 % вариации в данных потребления. Сравните это со значением $R^2$, равным 0.15 и полученным в результате простой регрессии из того же набора данных, что и в разделе 7.1. Добавление трех дополнительных предсказателей позволило объяснить гораздо больше вариаций в данных потребления.

## Стандартная ошибка регрессии

Еще одной мерой того, насколько хорошо модель подогнана под данные, является стандартное отклонение остатков, которое часто называют «стандартной ошибкой остатков». Она показана в приведенном выше результате со значением 0.31.

Указанная мера рассчитывается с использованием следующей ниже формулы:

$$\hat{\sigma}_e = \sqrt{\frac{1}{T-k-1}\sum_{t=1}^{T} e_t^2}, \tag{7.3}$$

где $k$ – это число предсказателей в модели. Обратите внимание, что мы делим на $T - k - 1$, потому что при вычислении остатков мы оценили $k + 1$ параметров (пересечение и коэффициент для каждой предсказательной переменной).

Стандартная ошибка связана с размером средней ошибки, продуцируемой моделью. Эту ошибку можно сравнить с выборочным средним значением относительно $y$ или со стандартным отклонением от $y$, чтобы получить некоторое представление о точности модели.

Стандартная ошибка будет использоваться при формировании предсказательных интервалов, обсуждаемых в разделе 7.6.

# 7.3 Оценивание регрессионной модели

Разницы между наблюдаемыми значениями $y$ и соответствующими подогнанными значениями $\hat{y}$ – это ошибки тренировочного набора, или «остатки», определяемые как

$$e_t = y_t - \hat{y}_t = y_t - \hat{\beta}_0 - \hat{\beta}_1 x_{1,t} - \hat{\beta}_2 x_{2,t} - \cdots - \hat{\beta}_k x_{k,t}$$

для $t = 1, \ldots, T$. Каждый остаток является непредсказуемой компонентой ассоциированного наблюдения.

Остатки обладают несколькими полезными свойствами, включая следующие два:

$$\sum_{t=1}^{T} e_t = 0 \quad \text{и} \quad \sum_{t=1}^{T} x_{k,t} e_t = 0 \quad \textit{для всех } k.$$

Как следствие, вытекающее из этих свойств, ясно, что среднее значение остатков равно нулю и что корреляция между остатками и наблюдениями для предсказательной переменной тоже равна нулю. (Это не обязательно верно, когда пересечение из модели исключено.)

После отбора регрессионных переменных и подгонки регрессионной модели необходимо построить график остатков, чтобы проверить, что допущения модели были удовлетворены. Существует ряд графиков, которые должны быть построены для проверки разных аспектов подогнанной модели и опорных допущений. Теперь мы обсудим каждый из них по очереди.

## График ACF остатков

При работе с данными временного ряда весьма вероятно, что значение переменной, наблюдаемой в текущем периоде времени, будет аналогично ее значению в предыдущем периоде или даже в период до этого и т. д. Поэтому при подгонке регрессионной модели к данным временного ряда обычно обнаруживается автокорреляция в остатках. В этом случае оцениваемая модель нарушает допущение об отсутствии автокорреляции в ошибках, и наши прогнозы могут оказаться неэффективными – остается некоторая информация, которая должна быть учтена в модели с целью получения более точных прогнозов. Прогнозы из модели с автокоррелированными ошибками по-прежнему являются несмещенными и поэтому не являются «неправильными», но обычно они имеют более крупные предсказательные интервалы, чем необходимо. Поэтому мы всегда должны смотреть на график ACF остатков.

## Гистограмма остатков

Всегда полезно выполнить проверку на предмет нормальности распределения остатков. Как мы объясняли ранее, это не имеет существенного значения для прогнозирования, но значительно упрощает вычисление предсказательных интервалов.

### Пример

Используя функцию `gg_tsresiduals()`, представленную в разделе 5.3, можно получить всю полезную упомянутую выше диагностику остатков.

```
fit_consMR %>% gg_tsresiduals()
```

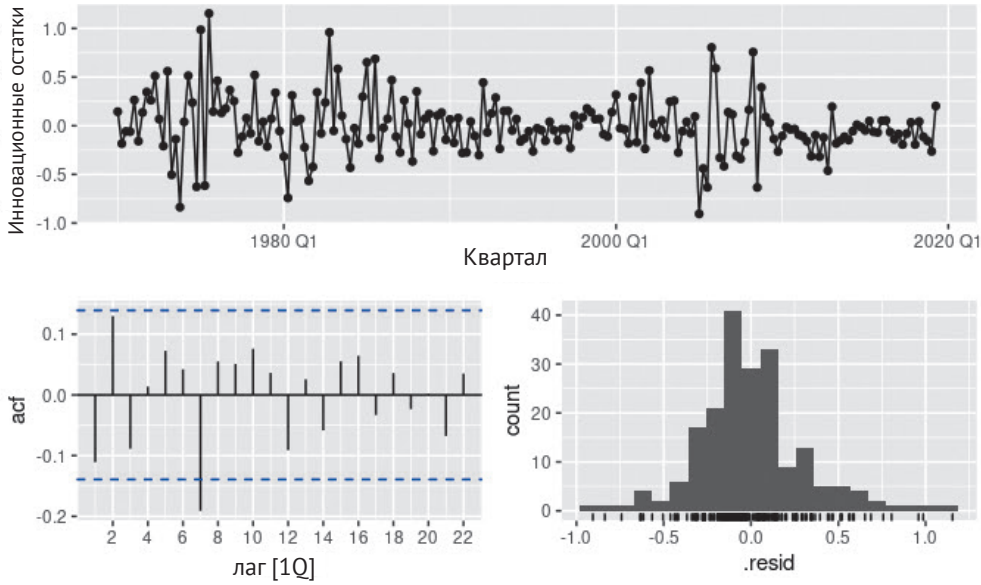


**Рисунок 7.8:** Анализ остатков регрессионной модели для квартального потребления в США

```
augment(fit_consMR) %>%
  features(.innov, ljung_box, lag = 10, dof = 5)
#> # A tibble: 1 × 3
#>   .model lb_stat lb_pvalue
#>   <chr>    <dbl>     <dbl>
#> 1 tslm      18.9   0.00204
```

График времени показывает некоторую изменяющуюся вариацию с течением времени, но в остальном он относительно ничем не примечателен. Эта гетероскедастичность потенциально может сделать покрытие предсказательного интервала неточным.

Гистограмма показывает, что остатки выглядят слегка искаженными, что также может повлиять на вероятность покрытия предсказательных интервалов.

График автокорреляции показывает значительный всплеск в лаге 7 и значимый тест Льюнга–Бокса на уровне 5 %. Однако автокорреляция не особенно велика, и в лаге 7 она вряд ли окажет какое-либо заметное влияние на прогнозы или предсказательные интервалы. В главе 10 мы обсуждаем модели динамической регрессии, используемые для более качественного улавливания информации, оставшейся в остатках.

## Графики остатков в сопоставлении с предсказателями

Мы ожидаем, что остатки будут разбросаны случайным образом без каких-либо систематических закономерностей. Простой и быстрый способ проверить это состоит в инспектировании диаграммы рассеяния остатков по каждой предсказательной переменной. Если эти диаграммы рассеяния показывают закономерность, то взаимосвязь может быть нелинейной, и модель необходи-

мо будет соответствующим образом модифицировать. См. раздел 7.7, в котором обсуждается нелинейная регрессия.

Также необходимо построить график остатков по отношению к любым предсказателям, которых в модели нет. Если какой-либо из них показывает закономерность, то соответствующий предсказатель, возможно, потребуется добавить в модель (возможно, в нелинейной форме).

### Пример

Остатки из модели множественной регрессии для прогнозирования потребления в США, построенные по каждому предсказателю на рис. 7.9, выглядят случайно разбросанными. Следовательно, в данном случае мы этим удовлетворены.

```
us_change %>%
  left_join(residuals(fit_consMR), by = "Quarter") %>%
  pivot_longer(Income:Unemployment,
               names_to = "regressor", values_to = "x") %>%
  ggplot(aes(x = x, y = .resid)) +
  geom_point() +
  facet_wrap(. ~ regressor, scales = "free_x") +
  labs(y = "Остатки", x = "")
```

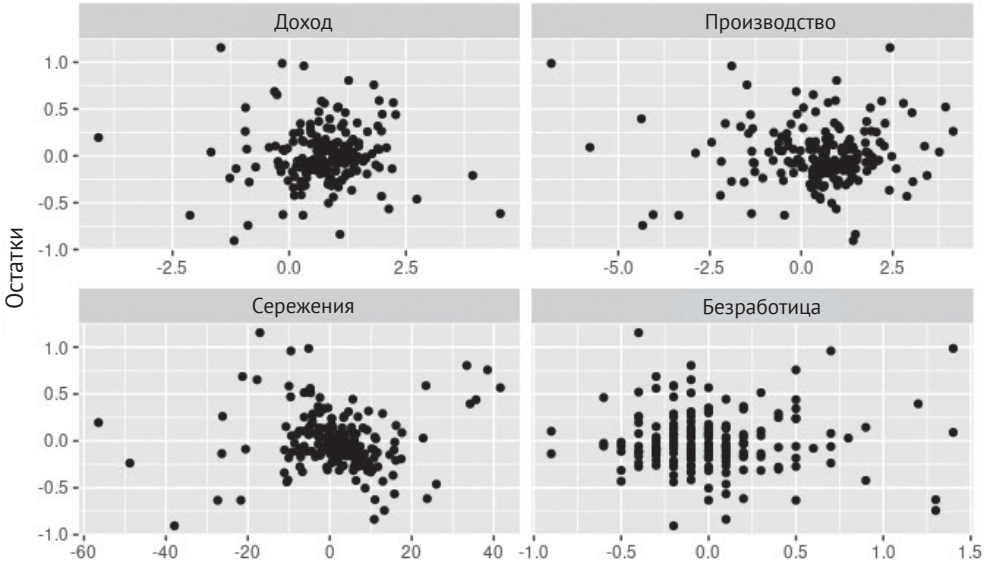


**Рисунок 7.9:** Диаграммы рассеяния остатков в сопоставлении с каждым предсказателем

## Графики остатков в сопоставлении с подогнанными значениями

График остатков в сопоставлении с подогнанными значениями также не должен показывать никакой закономерности. Если наблюдается закономерность,

то в ошибках может наблюдаться «гетероскедастичность», из чего вытекает, что дисперсия остатков может быть непостоянной. Если возникает эта проблема, то может потребоваться преобразование прогнозной переменной, такое как логарифмическое или на основе квадратного корня (см. раздел 3.1).

### Пример

Продолжая предыдущий пример, на рис. 7.10 показаны остатки, нанесенные на график в сопоставлении с подогнанными значениями. Случайный разброс говорит о том, что ошибки являются гомоскедастичными.

```
augment(fit_consMR) %>%
  ggplot(aes(x = .fitted, y = .resid)) +
  geom_point() + labs(x = "Подогнанные значения", y = "Остатки")
```

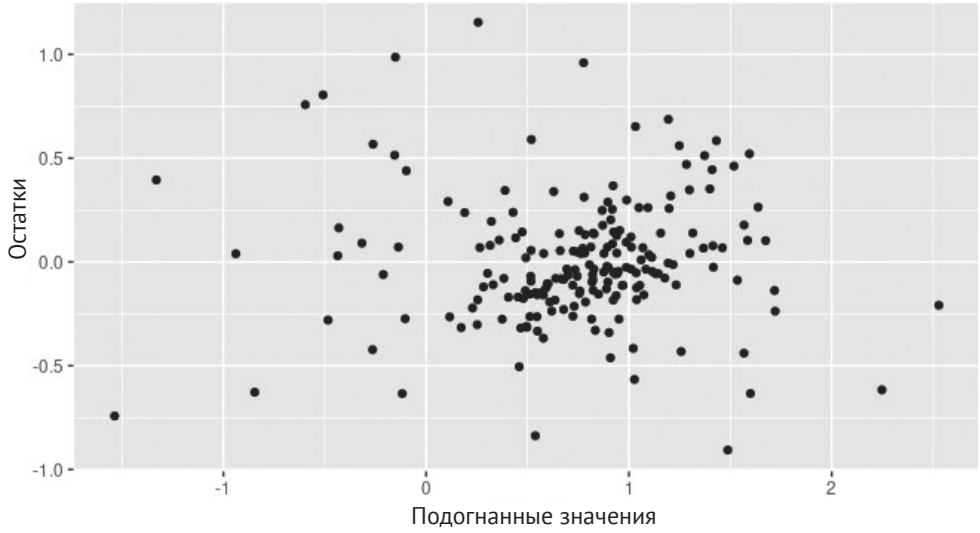


**Рисунок 7.10:** Диаграммы рассеяния остатков в сопоставлении с подогнанными значениями

## Выбросы и влиятельные наблюдения

Наблюдения, которые принимают экстремальные значения по сравнению с большинством данных, называются **выбросами**. Наблюдения, которые оказывают большое влияние на оцениваемые коэффициенты регрессионной модели, называются **влиятельными наблюдениями**. Обычно влиятельные наблюдения также являются выбросами, которые являются экстремальными в направлении *x*.

Существуют формальные методы обнаружения выбросов и влиятельных наблюдений, которые выходят за рамки данного учебника. Как мы предлагали в начале главы 2, ознакомление с вашими данными перед выполнением любого анализа имеет жизненно важное значение. Точечный график *y* в сопоставлении с каждым *x* всегда является полезной отправной точкой в регрессионном анализе и часто помогает выявлять необычные наблюдения.

Одним из источников выбросов является неправильный ввод данных. Простая описательная статистика ваших данных поможет выявить минимумы и максимумы, которые не являются разумными. Если такое наблюдение обнаружено, и оно было зарегистрировано неправильно, то его следует немедленно исправить или удалить из выборки.

Выбросы также возникают, когда некоторые наблюдения просто отличаются. В этом случае, возможно, было бы неразумно эти наблюдения удалять. Если наблюдение было идентифицировано как вероятный выброс, то важно его изучить и проанализировать возможные причины, стоящие за ним. Решение об удалении или оставлении наблюдения бывает непростым (в особенности когда выбросы являются влиятельными наблюдениями). Целесообразно сообщать о результатах как с удалением таких наблюдений, так и без них.

### Пример

На рис. 7.11 показано влияние единичного выброса при регрессировании потребления в США на доход (пример представлен в разделе 7.1). На левой панели выброс является экстремальным только в направлении *y*, поскольку процентное изменение в потреблении было неправильно зарегистрировано как –4 %. Оранжевая линия – это линия регрессии, подогнанная под данные, включающие выбросы, в сопоставлении с черной линией, подогнанной под данные без выбросов. На правой панели выброс теперь также является экстремальным в направлении *x* со снижением в потреблении на 4 %, соответствующем увеличению дохода на 6 %. В этом случае выброс чрезвычайно влиятелен, поскольку оранжевая линия теперь существенно отклоняется от черной линии.

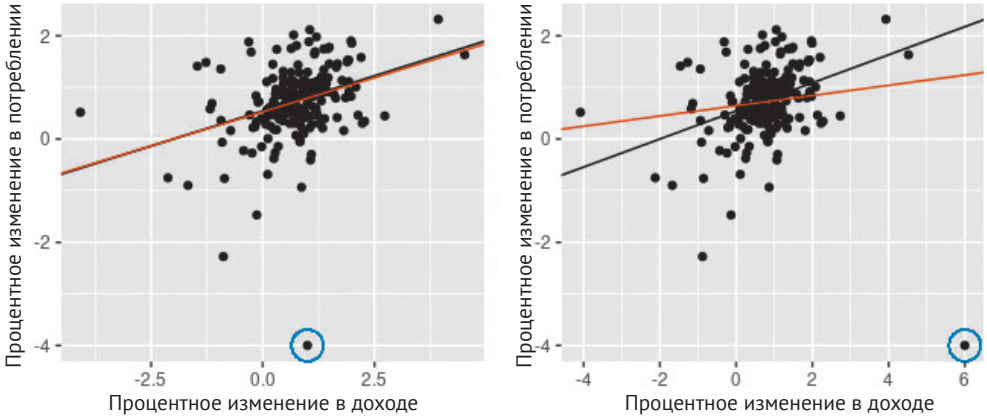


**Рисунок 7.11:** Влияние выбросов и влиятельных наблюдений на регрессию

## Мнимая регрессия

Чаще всего данные временных рядов являются «нестационарными», то есть значения временных рядов не колеблются вокруг постоянного среднего или с постоянной дисперсией. Мы рассмотрим стационарность временных рядов более подробно в главе 9, но здесь нам нужно рассмотреть влияние, которое нестационарные данные могут оказывать на регрессионные модели.

Например, возьмем две переменные, изображенные на рис. 7.12. Они выглядят взаимосвязанными просто потому, что обе имеют одинаковый повышательный тренд. Однако авиапассажирские перевозки в Австралии не имеют никакого отношения к производству риса в Гвинее.

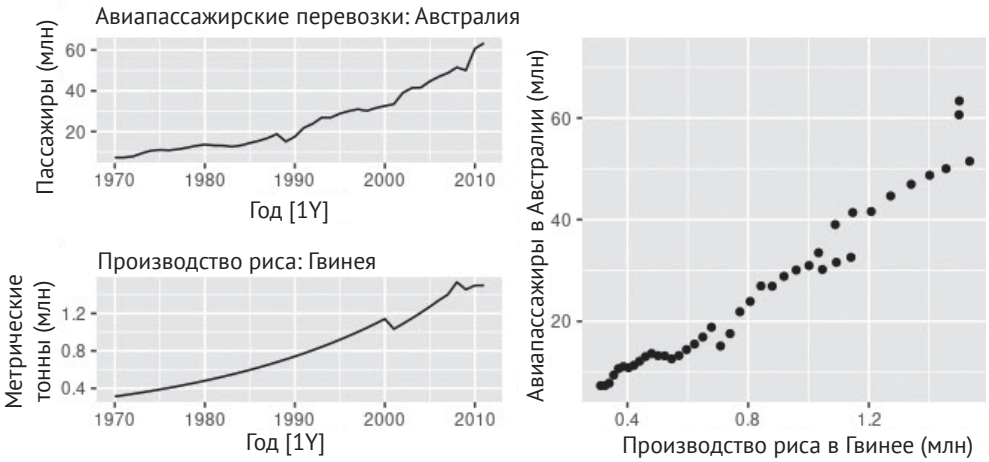


**Рисунок 7.12:** Данные трендовых временных рядов могут оказаться взаимосвязанными, как показано в данном примере, где авиапассажиры в Австралии регрессированы в сопоставлении с производством риса в Гвинее

Регрессирование нестационарных временных рядов может приводить к мнимым регрессиям. Результат регрессирования австралийских авиапассажиров на производство риса в Гвинее показан на рис. 7.13. Высокий $R^2$ и высокая автокорреляция остатков могут быть признаками мнимой регрессии. Обратите внимание на эти признаки в приведенных ниже результатах. Мы обсудим проблемы, связанные с нестационарными данными и мнимыми регрессиями, более подробно в главе 10.

Может показаться, что случаи мнимой регрессии дают разумные краткосрочные прогнозы, но они, как правило, не будут продолжать работать в будущем.

```
fit <- aus_airpassengers %>%
  filter(Year <= 2011) %>%
  left_join(guinea_rice, by = "Year") %>%
  model(TSLM(Passengers ~ Production))
report(fit)
#> Series: Passengers
#> Model: TSLM
#>
#> Residuals:
#>     Min      1Q  Median      3Q     Max
#> -5.945 -1.892 -0.327  1.862 10.421
#>
```

```
#> Coefficients:
#>             Estimate Std. Error t value Pr(>|t|)
#> (Intercept)    -7.49       1.20   -6.23  2.3e-07 ***
#> Production     40.29       1.34   30.13  < 2e-16 ***
#> ---
#> Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
#>
#> Residual standard error: 3.24 on 40 degrees of freedom
#> Multiple R-squared: 0.958,   Adjusted R-squared: 0.957
#> F-statistic:  908 on 1 and 40 DF, p-value: <2e-16
fit %>% gg_tsresiduals()
```

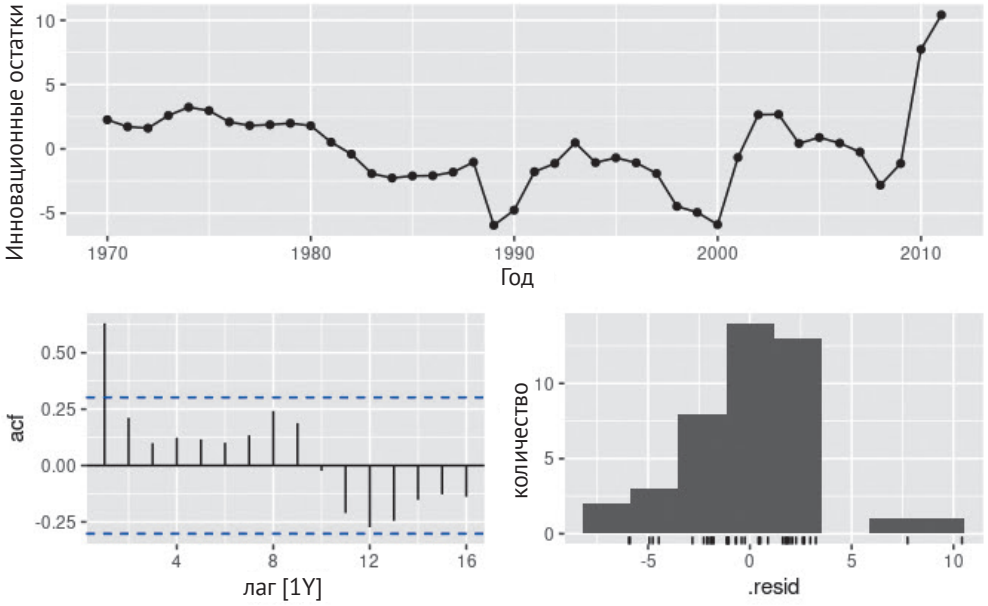


**Рисунок 7.13:** Остатки от мнимой регрессии

## 7.4 Несколько полезных предсказателей

Существует несколько полезных предсказателей, которые часто встречаются при использовании регрессии для данных временных рядов.

### Тренд

Обычно данные временных рядов находятся в тренде. Линейный тренд можно смоделировать, просто используя $x_{1,t} = t$ как предсказатель:

$$y_t = \beta_0 + \beta_1 t + \varepsilon_t,$$

где $t = 1, \ldots, T$. Переменная тренда может быть задана в функции `TSLM()` с помощью специальной функции `trend()`. В разделе 7.7 мы также обсудим вопрос о том, как можно моделировать нелинейные тренды.

## Фиктивные переменные

До сих пор мы исходили из допущения о том, что каждый предсказатель принимает числовые значения. Но как быть, когда предсказатель представляет собой категориальную переменную, принимающую только два значения (например, «да» и «нет»)? Такая переменная может возникать, например, при прогнозировании ежедневных продаж, и вы хотите учесть, является этот день национальным праздником или нет. Таким образом, предсказатель принимает значение «да» в праздничные дни и «нет» в противном случае.

Подобную ситуацию все еще можно обработать в пределах каркаса моделей множественной регрессии путем создания «фиктивной переменной», которая принимает значение 1, соответствующее «да», и 0, соответствующее «нет». Фиктивная переменная еще называется «индикаторной переменной».

Фиктивная переменная также может использоваться для учета выбросов в данных. Вместо того чтобы опускать выброс, фиктивная переменная удаляет его эффект. В этом случае фиктивная переменная принимает значение 1 для этого наблюдения и 0 в остальных случаях. Примером может служить случай, когда произошло особое событие. Например, при прогнозировании туристического потока в Бразилию необходимо будет учитывать влияние летних Олимпийских игр в Рио-де-Жанейро в 2016 году.

Если существует более двух категорий, то переменная может быть закодирована с использованием нескольких фиктивных переменных (на одну меньше, чем суммарное число категорий). Функция `TSLM()` будет обрабатывать этот случай автоматически, если в качестве предсказателя указывать факторную переменную. Создавать соответствующие фиктивные переменные вручную обычно нет необходимости.

## Сезонные фиктивные переменные

Предположим, что мы прогнозируем ежедневные данные и хотим учитывать день недели в качестве предсказателя. Тогда можно создать следующие ниже фиктивные переменные.

| | $d_{1,t}$ | $d_{2,t}$ | $d_{3,t}$ | $d_{4,t}$ | $d_{5,t}$ | $d_{6,t}$ |
|---|---|---|---|---|---|---|
| Понедельник | 1 | 0 | 0 | 0 | 0 | 0 |
| Вторник | 0 | 1 | 0 | 0 | 0 | 0 |
| Среда | 0 | 0 | 1 | 0 | 0 | 0 |
| Четверг | 0 | 0 | 0 | 1 | 0 | 0 |
| Пятница | 0 | 0 | 0 | 0 | 1 | 0 |
| Суббота | 0 | 0 | 0 | 0 | 0 | 1 |
| Воскресенье | 0 | 0 | 0 | 0 | 0 | 0 |
| Понедельник | 1 | 0 | 0 | 0 | 0 | 0 |
| ⋮ | ⋮ | ⋮ | ⋮ | ⋮ | ⋮ | ⋮ |

Обратите внимание, что для кодирования семи категорий требуется всего шесть фиктивных переменных. Это обусловлено тем, что седьмая категория (в данном случае воскресенье) улавливается пересечением и указывается, когда все фиктивные переменные равны нулю.

Многие новички попытаются добавить седьмую фиктивную переменную для седьмой категории. Такая ситуация называется «ловушкой фиктивной переменной», потому что это приведет к сбою регрессии. Когда также будет включено пересечение, окажется слишком много оцениваемых параметров. Общее правило состоит в том, чтобы использовать на одну фиктивную переменную меньше, чем категорий. Таким образом, для квартальных данных следует использовать три фиктивные переменные; для ежемесячных данных надо использовать 11 фиктивных переменных; а для ежедневных данных – шесть фиктивных переменных и т. д.

Интерпретация каждого коэффициента, связанного с фиктивными переменными, заключается в том, что он является *мерой влияния этой категории по отношению к опущенной категории*. В приведенном выше примере коэффициент $d_{1,t}$, ассоциированный с понедельником, будет измерять влияние понедельника на прогнозную переменную по сравнению с влиянием воскресенья. Ниже приведен пример интерпретации оценочных коэффициентов фиктивных переменных, отражающих ежеквартальную сезонность производства пива в Австралии.

Функция `TSLM()` будет обрабатывать эту ситуацию автоматически, если указывать специальную функцию `season()`.

## Пример: ежеквартальное производство пива в Австралии

Вспомните квартальные данные по производству пива в Австралии, которые снова показаны на рис. 7.14.

```
recent_production <- aus_production %>%
  filter(year(Quarter) >= 1992)
recent_production %>%
  autoplot(Beer) +
  labs(y = "Мегалитры",
       title = "Квартальное производство пива в Австралии")
```

**Рисунок 7.14:** Ежеквартальное производство пива в Австралии

Мы хотим спрогнозировать стоимость будущего производства пива. Мы можем смоделировать эти данные, используя регрессионную модель с линейным трендом и поквартальными фиктивными переменными:

$$y_t = \beta_0 + \beta_1 t + \beta_2 d_{2,t} + \beta_3 d_{3,t} + \beta_4 d_{4,t} + \varepsilon_t,$$

где $d_{i,t} = 1$, если $t$ находится в квартале $i$, и 0 в противном случае. Переменная первого квартала была опущена, поэтому коэффициенты, ассоциированные с другими кварталами, являются мерами разницы между этими кварталами и первым кварталом.

```
fit_beer <- recent_production %>%
  model(TSLM(Beer ~ trend() + season()))
report(fit_beer)
#> Series: Beer
#> Model: TSLM
#>
#> Residuals:
#>    Min     1Q Median     3Q    Max
#> -42.90  -7.60  -0.46   7.99  21.79
#>
#> Coefficients:
#>               Estimate Std. Error t value Pr(>|t|)
#> (Intercept)   441.8004     3.7335  118.33  < 2e-16 ***
#> trend()        -0.3403     0.0666   -5.11  2.7e-06 ***
#> season()year2 -34.6597     3.9683   -8.73  9.1e-13 ***
#> season()year3 -17.8216     4.0225   -4.43  3.4e-05 ***
#> season()year4  72.7964     4.0230   18.09  < 2e-16 ***
#> ---
#> Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
#>
#> Residual standard error: 12.2 on 69 degrees of freedom
#> Multiple R-squared: 0.924,   Adjusted R-squared: 0.92
#> F-statistic:  211 on 4 and 69 DF, p-value: <2e-16
```

Обратите внимание, что `trend()` и `season()` не являются стандартными функциями; это «специальные» функции, которые работают в формулах модели `TSLM()`.

Средний понижательный тренд составляет –0.34 мегалитра в квартал. В среднем во втором квартале объем производства на 34.7 мегалитра ниже, чем в первом квартале, в третьем квартале объем производства на 17.8 мегалитра ниже, чем в первом квартале, и в четвертом квартале объем производства на 72.8 мегалитра выше, чем в первом квартале.

```
augment(fit_beer) %>%
  ggplot(aes(x = Quarter)) +
  geom_line(aes(y = Beer, colour = "Данные")) +
  geom_line(aes(y = .fitted, colour = "Подогнано")) +
  scale_colour_manual(
    values = c(Data = "black", Fitted = "#D55E00")
  ) +
  labs(y = "Мегалитры",
       title = "Квартальное производство пива в Австралии") +
  guides(colour = guide_legend(title = "Ряды"))
```

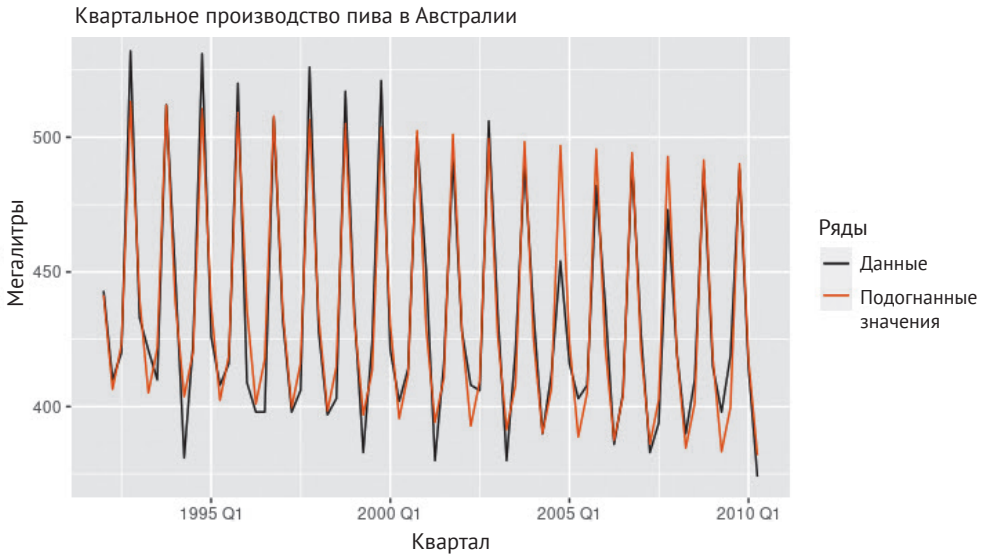


**Рисунок 7.15:** График времени в отношении производства пива и предсказанного производства пива

```
augment(fit_beer) %>%
  ggplot(aes(x = Beer, y = .fitted,
             colour = factor(quarter(Quarter)))) +
  geom_point() +
  labs(y = "Подогнанные значения", x = "Фактические значения",
       title = "Квартальное производство пива в Австралии") +
  geom_abline(intercept = 0, slope = 1) +
  guides(colour = guide_legend(title = "Квартал"))
```

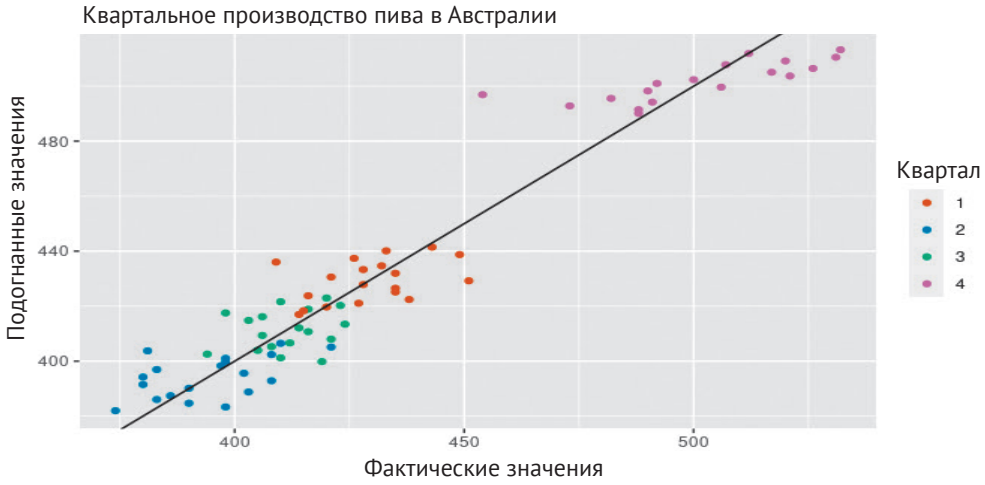


**Рисунок 7.16:** График фактического производства пива в сопоставлении с предсказанным производством пива

## Переменные вмешательства

Нередко бывает необходимо смоделировать вмешательства, которые могли повлиять на подлежащую прогнозированию переменную. Например, активность конкурентов, расходы на рекламу, забастовки и т. д. – все это может оказать влияние.

Когда эффект длится только один период, мы используем переменную «всплеска». Это фиктивная переменная, которая принимает значение 1 в период вмешательства и 0 в остальных случаях. Переменная всплеска эквивалентна фиктивной переменной для обработки выбросов.

Другие вмешательства дают немедленный и перманентный эффект. Если вмешательство вызывает сдвиг уровня (т. е. значение ряда изменяется внезапно и перманентно с момента вмешательства), то мы используем переменную «шага». Переменная шага принимает значение 0 до вмешательства и 1 с момента вмешательства и далее.

Еще одной формой перманентного эффекта является изменение наклона. Здесь вмешательство обрабатывается с использованием кусочно-линейного тренда; тренда, который изгибается во время вмешательства и, следовательно, является нелинейным. Мы обсудим это в разделе 7.7.

## Торговые дни

Число торговых дней в месяце может значительно варьироваться и оказывать существенное влияние на данные продаж. С целью учета такой ситуации число торговых дней в каждом месяце может включаться в качестве предсказателя.

Альтернатива, учитывающая влияние разных дней недели, имеет следующие ниже предсказатели:

$$x_1 = \text{число понедельников в месяце;}$$
$$x_2 = \text{число вторников в месяце;}$$
$$\vdots$$
$$x_7 = \text{число воскресений в месяце.}$$

## Распределенные лаги

Нередко бывает полезно включить расходы на рекламу в качестве предсказателя. Однако поскольку эффект от рекламирования может длиться и после фактической кампании, нам необходимо включить лаги расходов на рекламу. Отсюда следует, что могут быть использованы следующие ниже предсказатели:

$x_1$ = рекламирование за предыдущий месяц;

$x_2$ = рекламирование за два предыдущих месяца;

⋮

$x_m$ = рекламирование за $m$ предыдущих месяцев.

Обычно требуется, чтобы коэффициенты уменьшались по мере увеличения лага, хотя этот вопрос выходит за рамки данной книги.

## Пасха

Пасха отличается от большинства праздников тем, что она не проводится в один и тот же день каждый год и ее действие может длиться несколько дней. В данном случае можно использовать фиктивную переменную со значением 1, если праздник приходится на определенный период времени, и 0 в противном случае.

В случае ежемесячных данных, если Пасха выпадает на март, то фиктивная переменная принимает значение 1 в марте, а если она выпадает на апрель, то фиктивная переменная принимает значение 1 в апреле. Когда Пасха начинается в марте и заканчивается в апреле, фиктивная переменная распределяется между месяцами пропорционально.

## Ряд Фурье

Альтернативой использованию сезонных фиктивных переменных, в особенности для длительных сезонных периодов, является применение членов Фурье. Жан-Батист Фурье был французским математиком, родившимся в 1700-х годах, который показал, что ряд синусных и косинусных членов правильных частот может аппроксимировать любую периодическую функцию. Мы можем использовать их для сезонных закономерностей.

Если $m$ – это сезонный период, то первые несколько членов Фурье задаются формулами

$$x_{1,t} = \sin\left(\frac{2\pi t}{m}\right), x_{2,t} = \cos\left(\frac{2\pi t}{m}\right), x_{3,t} = \sin\left(\frac{4\pi t}{m}\right),$$
$$x_{4,t} = \cos\left(\frac{4\pi t}{m}\right), x_{5,t} = \sin\left(\frac{6\pi t}{m}\right), x_{6,t} = \cos\left(\frac{6\pi t}{m}\right)$$

и т. д. Если мы имеем месячную сезонность и используем первые 11 предсказательных переменных, то получим точно такие же прогнозы, как при использовании 11 фиктивных переменных.

С членами Фурье нам часто требуется меньше предсказателей, чем с фиктивными переменными, в особенности когда $m$ является крупным. Это делает их пригодными для еженедельных данных, например там, где $m \approx 52$. Для ко-

ротких сезонных периодов (например, для квартальных данных) использование членов Фурье имеет мало преимуществ по сравнению с сезонными фиктивными переменными.

Указанные члены Фурье генерируются с помощью функции `fourier()`. Например, данные по австралийскому пиву можно смоделировать следующим образом:

```
fourier_beer <- recent_production %>%
  model(TSLM(Beer ~ trend() + fourier(K = 2)))
report(fourier_beer)
#> Series: Beer
#> Model: TSLM
#>
#> Residuals:
#>    Min     1Q Median     3Q    Max
#> -42.90  -7.60  -0.46   7.99  21.79
#>
#> Coefficients:
#>                    Estimate Std. Error t value Pr(>|t|)
#> (Intercept)        446.8792     2.8732  155.53  < 2e-16 ***
#> trend()             -0.3403     0.0666   -5.11  2.7e-06 ***
#> fourier(K = 2)C1_4   8.9108     2.0112    4.43  3.4e-05 ***
#> fourier(K = 2)S1_4 -53.7281     2.0112  -26.71  < 2e-16 ***
#> fourier(K = 2)C2_4 -13.9896     1.4226   -9.83  9.3e-15 ***
#> ---
#> Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
#>
#> Residual standard error: 12.2 on 69 degrees of freedom
#> Multiple R-squared: 0.924,   Adjusted R-squared: 0.92
#> F-statistic:  211 on 4 and 69 DF, p-value: <2e-16
```

Аргумент `K` в функции `fourier()` указывает, сколько пар синусных и косинусных членов следует включить. Максимально допустимое значение составляет $K = m/2$, где $m$ – это сезонный период. Поскольку здесь мы использовали максимум, результаты идентичны результатам, полученным при использовании сезонных фиктивных переменных.

Если используются только первые два члена Фурье ($x_{1,t}$ и $x_{2,t}$), то сезонная закономерность будет подчиняться простой синусной волне. Регрессионную модель, содержащую члены Фурье, часто называют **гармонической регрессией**, потому что поочередные члены Фурье представляют гармоники первых двух членов Фурье.

## 7.5 Отбор предсказателей

Когда существует много возможных предсказателей, нам нужна некоторая стратегия отбора наилучших предсказателей для использования в регрессионной модели.

Распространенный подход, который не рекомендуется, заключается в построении графика прогнозной переменной в сопоставлении с определенным предсказателем, и если нет заметной взаимосвязи, то удалении указанного предсказателя из модели. Это неверно, поскольку увидеть взаимосвязь на диаграмме рассеяния не всегда возможно, в особенности когда не были учтены эффекты других предсказателей.

Еще один распространенный подход, который также невалиден, заключается в выполнении множественной линейной регрессии по всем предсказателям и игнорировании всех переменных, чьи $p$-значения больше 0.05. Начнем с того, что статистическая значимость не всегда указывает на предсказательную ценность. Даже если прогнозирование не является целью, это не очень хорошая стратегия, потому что $p$-значения могут дезориентировать, когда два или более предсказателей коррелируют друг с другом (см. раздел 7.8).

Вместо этого мы будем использовать меру предсказательной точности. В этом разделе представлены пять таких мер. Их можно показать с помощью функции `glance()`, применяемой здесь к модели потребления в США:

```
glance(fit_consMR) %>%
  select(adj_r_squared, CV, AIC, AICc, BIC)
#> # A tibble: 1 × 5
#>   adj_r_squared    CV   AIC  AICc   BIC
#>           <dbl> <dbl> <dbl> <dbl> <dbl>
#> 1         0.763 0.104 -457. -456. -437.
```

Мы сравниваем эти значения с соответствующими значениями из других моделей. Для мер CV, AIC, AICc и BIC мы хотим найти модель с наименьшим значением; для скорректированного $R^2$ мы ищем модель с наибольшим значением.

## Скорректированный $R^2$

Компьютерный вывод для регрессии всегда будет давать значение $R^2$, обсуждаемое в разделе 7.2. Однако оно не является хорошим показателем предсказательной способности модели. Оно служит мерой того, насколько хорошо модель вписывается в исторические данные, но не того, насколько хорошо модель будет прогнозировать будущие данные.

В дополнение к этому $R^2$ не допускает «степеней свободы». Добавление любой переменной приводит к увеличению значения $R^2$, даже если эта переменная нерелевантна. По этим причинам прогнозисты не должны использовать $R^2$, чтобы определять способность модели давать хорошие предсказания, так как это приведет к переподгонке.

Эквивалентная идея состоит в отборе модели, которая дает минимальную сумму квадратов ошибок (SSE), задаваемую формулой

$$\text{SSE} = \sum_{t=1}^{T} e_t^2.$$

Минимизирование SSE эквивалентно максимизированию $R^2$ и всегда будет выбирать модель с наибольшим числом переменных, поэтому такой способ отбора предсказателей невалиден.

Альтернативой, призванной преодолевать указанные проблемы, является скорректированный $R^2$ (также именуемый «R-квадрат с крышкой»):

$$\bar{R}^2 = 1 - \left(1 - R^2\right)\frac{T-1}{T-k-1},$$

где $T$ – это число наблюдений и $k$ – число предсказателей. Это улучшение по сравнению с $R^2$, так как он больше не будет увеличиваться с каждым добавленным предсказателем. Используя эту меру, лучшей моделью будет та, у которой будет наибольшее значение $\bar{R}^2$. Максимизирование $\bar{R}^2$ эквивалентно минимизированию стандартной ошибки $\hat{\sigma}_e$, заданной в уравнении (7.3).

Максимизирование $\bar{R}^2$ работает довольно хорошо как метод отбора предсказателей, хотя он все-таки имеет тенденцию ошибаться в сторону отбора слишком большого числа предсказателей.

## Перекрестная валидация

Перекрестная валидация временных рядов была введена в разделе 5.8 как общий инструмент определения предсказательной способности модели. В целях отбора предсказателей для регрессионных моделей также можно использовать классическую перекрестную валидацию с исключением по одному (Бергмейер и соавт., 2018, *https://otexts.com/fpp3/selecting-predictors.html#ref-BHK15*). Она работает быстрее и позволяет эффективнее использовать данные. В процедуре перекрестной валидации используются следующие ниже шаги:

1. Удалить наблюдение $t$ из набора данных и выполнить подгонку модели, используя оставшиеся данные. Затем вычислить ошибку ($e_t^* = y_t - \hat{y}_t$) для опущенного наблюдения. (Это не то же самое, что и остаток, потому что $t$-е наблюдение не использовалось при оценивании значения $\hat{y}_t$.)
2. Повторить шаг 1 для $t = 1, \ldots, T$.
3. Вычислить MSE из $e_1^*, \ldots, e_T^*$. Мы будем называть эту процедуру **CV**, от англ. cross-validation.

Хотя указанная процедура выглядит трудоемкой, существуют быстрые методы расчета CV, так что ее выполнение занимает не больше времени, чем подгонка одной модели к полному набору данных. Уравнение эффективного расчета CV приведено в разделе 7.9. В рамках этого критерия наилучшей моделью является модель с наименьшим значением CV.

## Информационный критерий Акаике

Близкородственным методом является информационный критерий Акаике, который мы определяем как

$$\text{AIC} = T\log\left(\frac{\text{SSE}}{T}\right) + 2\left(k+2\right),$$

где $T$ – это число наблюдений, использованных для оценивания, и $k$ – число предсказателей в модели. В разных компьютерных пакетах используются слегка разные определения AIC, хотя все они должны приводить к отбору одной и той же модели. Часть $k + 2$ уравнения происходит потому, что в модели имеется $k + 2$ параметров: $k$ коэффициентов для предсказателей, пересечения и дисперсии остатков. Идея здесь состоит в том, чтобы штрафовать подгонку модели (SSE) числом параметров, которые необходимо оценить.

Модель с минимальным значением AIC часто является наилучшей прогнозируемой моделью. Для крупных значений $T$ минимизирование AIC эквивалентно минимизированию значения CV.

## Исправленный информационный критерий Акаике

Для малых значений $T$ AIC имеет тенденцию отбирать слишком много предсказателей, и поэтому была разработана версия AIC с поправкой на смещение:

$$\text{AIC}_\text{c} = \text{AIC} + \frac{2(k+2)(k+3)}{T-k-3}.$$

Как и в случае с AIC, AICc следует минимизировать.

## Байесов информационный критерий Шварца

Близкородственной мерой является байесов информационный критерий Шварца (обычно именуемый сокращенно как BIC, SBIC или SC):

$$\text{BIC} = T\log\left(\frac{\text{SSE}}{T}\right) + (k+2)\log(T).$$

Как и в случае с AIC, минимизирование BIC предназначено для получения наилучшей модели. Выбранная критерием BIC модель либо совпадает с моделью, выбранной критерием AIC, либо содержит меньшее число членов. Это обусловлено тем, что BIC штрафует число параметров строже, чем AIC. Для крупных значений $T$ минимизирование BIC аналогично перекрестной валидации с исключением по одному при $v = T\left[1 - 1/\left(\log(T) - 1\right)\right]$.

## Какую меру мы должны использовать?

Хотя $\bar{R}^2$ широко используется и существует дольше, чем другие меры, его тенденция отбирать слишком много предсказательных переменных делает его менее подходящим для прогнозирования.

Многим специалистам в области статистики нравится использовать BIC, потому что у него есть одна важная функциональная особенность: если существует истинная опорная модель, то BIC будет отбирать эту модель при наличии достаточного количества данных. Однако на самом деле истинная опорная модель существует редко, если вообще существует, и даже если бы существовала истинная опорная модель, то выбор этой модели не обязательно будет давать наилучшие прогнозы (поскольку оценки параметров могут не быть точными).

Следовательно, мы рекомендуем использовать одну из статистик AICc, AIC либо CV, каждая из которых имеет целью прогнозирование. Если значение $T$ достаточно велико, то все они приведут к одной и той же модели. В большинстве примеров в этой книге для отбора модели прогнозирования мы используем значение AICc.

## Пример: потребление в США

В примере множественной регрессии для прогнозирования потребления в США мы рассмотрели четыре предсказателя. С четырьмя предсказателями существует $2^4 = 16$ возможных моделей. Теперь мы можем проверить, действительно ли все четыре предсказателя полезны или же можно отказаться от одного или нескольких из них. Все 16 моделей были подогнаны, и результаты обобщены в табл. 7.1. Символ ● указывает на то, что предсказатель был включен в модель, следовательно, в первой строке показаны меры точности прогнозирования для модели, включающей все четыре предсказателя.

Результаты были отсортированы в соответствии с AICc. Поэтому наилучшие модели приведены в верхней части таблицы, а наихудшие – в нижней части таблицы.

**Таблица 7.1:** Все 16 возможных моделей для прогнозирования потребления в США 4 предсказателями

| Income | Production | Savings | Unemployment | AdjR2 | CV | AIC | AICc | BIC |
|---|---|---|---|---|---|---|---|---|
| ● | ● | ● | ● | 0.763 | 0.104 | −456.6 | −456.1 | −436.9 |
| ● | ● | ● | | 0.761 | 0.105 | −455.2 | −454.9 | −438.7 |
| ● | | ● | ● | 0.760 | 0.104 | −454.4 | −454.1 | −437.9 |
| ● | | ● | | 0.735 | 0.114 | −435.7 | −435.5 | −422.6 |
| ● | ● | | ● | 0.366 | 0.271 | −262.3 | −262.0 | −245.8 |
| ● | ● | ● | | 0.349 | 0.279 | −257.1 | −256.8 | −240.7 |
| ● | | | ● | 0.345 | 0.276 | −256.9 | −256.6 | −243.7 |
| ● | ● | | | 0.336 | 0.282 | −254.2 | −254.0 | −241.0 |
| ● | ● | | | 0.324 | 0.287 | −250.7 | −250.5 | −237.5 |
| ● | ● | | | 0.311 | 0.291 | −246.9 | −246.7 | −233.7 |
| ● | | ● | | 0.308 | 0.293 | −246.1 | −245.9 | −232.9 |
| ● | | | | 0.276 | 0.304 | −238.1 | −238.0 | −228.2 |
| ● | | | | 0.274 | 0.303 | −237.4 | −237.3 | −227.5 |
| ● | | | | 0.143 | 0.356 | −204.6 | −204.5 | −194.7 |
| ● | | | | 0.061 | 0.388 | −186.5 | −186.4 | −176.7 |
| | | | | 0.000 | 0.409 | −175.1 | −175.0 | −168.5 |

Наилучшая модель содержит все четыре предсказателя. Однако более пристальный взгляд на результаты выявляет некоторые интересные особенности. Между моделями в первых четырех рядах и моделями ниже существует четкое

разделение. Это указывает на то, что доход (`Income`) и сбережения (`Savings`) являются более важными переменными, чем производство (`Production`) и безработица (`Unemployment`). Кроме того, первые три строки имеют почти идентичные значения CV, AIC и AICc. Поэтому мы могли бы, пожалуй, отказаться либо от переменной `Production`, либо от переменной `Unemployment` и получить аналогичные прогнозы. Обратите внимание, что `Production` и `Unemployment` сильно (отрицательно) коррелируют, как показано на рис. 7.5, и поэтому бóльшая часть предсказательной информации в переменной `Production` также содержится в переменной `Unemployment`.

## Регрессия наилучшего подмножества

Там, где это возможно, должны быть подогнаны все потенциальные регрессионные модели (как это было сделано в приведенном выше примере), и наилучшая модель должна быть отобрана на основе одной из рассмотренных мер. Эта процедура называется регрессией «наилучших подмножеств», или регрессией «всех возможных подмножеств».

## Пошаговая регрессия

При наличии большого числа предсказателей невозможно выполнить подгонку всех возможных моделей. Например, 40 предсказателей приводят к $2^{40} > 1$ трлн возможных моделей! Следовательно, требуется стратегия лимитирования числа моделей, которое необходимо разведать.

Довольно хорошо работает подход, который называется *обратной пошаговой регрессией*:

- начать с модели, содержащей все потенциальные предсказатели;
- удалять по одному предсказателю за раз. Сохранять модель, если она улучшает меру предсказательной точности;
- повторять до тех пор, пока дальнейшее улучшение станет невозможным.

Если число потенциальных предсказателей слишком велико, то обратная пошаговая регрессия не будет работать и вместо нее можно использовать *прямую пошаговую регрессию*. Эта процедура начинается с модели, которая включает в себя только пересечение. Предсказатели добавляются по одному за раз, и тот, который в наибольшей степени улучшает меру предсказательной точности, сохраняется в модели. Указанная процедура повторяется до тех пор, пока дальнейшее улучшение станет невозможным.

В качестве альтернативы обратному либо прямому направлению исходной моделью может быть модель, включающая подмножество потенциальных предсказателей. В этом случае необходимо включить дополнительный шаг. В обратной процедуре мы также должны рассмотреть возможность добавления предсказателя с каждым шагом, а в прямой процедуре мы должны рассмотреть еще возможность удаления предсказателя с каждым шагом. Такие процедуры называются *гибридными*.

Важно понимать, что любой пошаговый подход не гарантирует, что приведет к наилучшей возможной модели, но он почти всегда приводит к хорошей модели. Более подробную информацию см. в Джеймс и соавт. (2014, *https://otexts.com/fpp3/selecting-predictors.html#ref-ISLR*).

## Остерегайтесь статистического вывода после отбора предсказателей

В этой книге мы не обсуждаем статистический вывод предсказателей (например, рассматривая *p*-значения, ассоциированные с каждым предсказателем). Если вы действительно хотите посмотреть на статистическую значимость предсказателей, то имейте в виду, что любая процедура, предусматривающая предварительный отбор предсказателей, приведет к аннулированию допущений, лежащих в основе *p*-значения. Процедуры, которые мы рекомендуем для отбора предсказателей, полезны, когда модель используется для прогнозирования; они бесполезны, если вы хотите изучить эффект любого предсказателя на прогнозную переменную.

## Библиография

*Бергмейр, К., Хайндман, Р. Дж. и Ку, Б.* (2018). Примечание о валидности перекрестной валидации для оценивания авторегрессионных предсказаний для временных рядов. Computational Statistics and Data Analysis, 120, 70–83. [DOI: https://doi.org/10.1016/j.csda.2017.11.003].

*Джеймс, Г., Виттен, Д., Хасти, Т. и Тибширани, Р.* (2014). Введение в статистическое обучение: с приложениями на R. Springer. [Amazon, http://buy.geni.us/Proxy.ashx?TSID=140570&GR_URL=http%3A%2F%2Fwww.amazon.com%2Fdp%2F1461471370].

# 7.6 Прогнозирование с помощью регрессии

Вспомните, что предсказания в отношении $y$ можно получить с помощью уравнения

$$\widehat{y_t} = \widehat{\beta}_0 + \widehat{\beta}_1 x_{1,t} + \widehat{\beta}_2 x_{2,t} + \cdots + \widehat{\beta}_k x_{k,t},$$

которое содержит оцениваемые коэффициенты и игнорирует ошибку в уравнении регрессии. Подключение значений предсказательных переменных $x_{1,t}, \ldots, x_{k,t}$ для $t = 1, \ldots, T$ возвращает подогнанные (на тренировочном наборе) значения $y$. Однако здесь нас интересует прогнозирование именно будущих значений $y$.

## Антефактумные прогнозы в сопоставлении с постфактумными прогнозами

При использовании регрессионных моделей для данных временных рядов необходимо различать разные типы прогнозов, которые могут производиться, в зависимости от того, что считается известным при вычислении прогнозов.

**Антефактумные прогнозы** (от лат. *ex-ante*, т. е. *до* факта) – это такие прогнозы, которые делаются с использованием только той информации, которая доступна заранее. Например, антефактумные прогнозы процентного изменения в потреблении в США для кварталов, следующих за окончанием выборки, должны использовать только ту информацию, которая была доступна до 2-го

квартала 2019 года включительно. Это настоящие прогнозы, делаемые заранее с использованием любой доступной на тот момент информации. Поэтому, для того чтобы генерировать антефактумные прогнозы, модель требует прогнозов предсказателей. В целях их получения можно использовать один из простых методов, представленных в разделе 5.2, либо более изощренные подходы на основе чистых временных рядов, которые описаны в главах 8 и 9. В качестве альтернативы могут быть доступны и использоваться прогнозы из какого-либо другого источника, такого как правительственное учреждение.

**Постфактумные прогнозы** (от лат. *ex-post*, т. е. *после* факта) – это такие прогнозы, которые делаются с использованием более поздней информации на предсказателях. Например, в постфактумных прогнозах потребления могут использоваться фактические наблюдения предсказателей, как только они поступили. Это не настоящие прогнозы, но они полезны для изучения поведения моделей прогнозирования.

Модель, на основе которой продуцируются постфактумные прогнозы, не должна оцениваться с использованием данных за прогнозный период. То есть постфактумные прогнозы могут допускать знание о предсказательных переменных (переменных $x$), но не должны допускать знание о данных, которые должны быть спрогнозированы (переменной $y$).

Сравнительное оценивание антефактумных прогнозов и постфактумных прогнозов помогает вычленять источники прогнозной неопределенности. Оно покажет, возникли ли прогнозные ошибки из-за слабых прогнозов предсказателя либо из-за слабой модели прогнозирования.

## Пример: ежеквартальное производство пива в Австралии

Обычно мы не можем использовать фактические будущие значения предсказательных переменных при продуцировании антефактумных прогнозов, поскольку их значения не будут известны заранее. Однако все специальные предсказатели, представленные в разделе 7.4, известны заранее, поскольку они основаны на календарных переменных (например, сезонных фиктивных переменных или индикаторах национальных праздников) либо детерминированных функциях от времени (например, временной тренд). В таких случаях между антефактумными и постфактумными прогнозами нет никакой разницы.

```
recent_production <- aus_production %>%
  filter(year(Quarter) >= 1992)
fit_beer <- recent_production %>%
  model(TSLM(Beer ~ trend() + season()))
fc_beer <- forecast(fit_beer)
fc_beer %>%
  autoplot(recent_production) +
  labs(
    title = "Прогнозы производства пива с использованием регрессии",
    y = "Мегалитры"
  )
```

**Рисунок 7.17:** Прогнозы из регрессионной модели в отношении производства пива. Темный заштрихованный участок показывает 80%-ный предсказательный интервал, а светлый заштрихованный участок показывает 95%-ный предсказательный интервал

## Прогнозирование на основе сценариев

В данном параметре прогнозист допускает возможные сценарии для интересующих его предсказательных переменных. Например, политический деятель из США может быть заинтересован в сравнении предсказанного изменения в потреблении, когда имеется постоянный рост доходов и сбережений соответственно на 1 % и 0.5 % при отсутствии изменений в уровне занятости, с соответствующим снижением на 1 % и 0.5 % для каждого из четырех кварталов, следующих за концом выборки. Результирующие прогнозы рассчитаны ниже и показаны на рис. 7.18. Следует отметить, что предсказательные интервалы для сценарных прогнозов не включают неопределенность, связанную с будущими значениями предсказательных переменных. При их расчете исходят из того, что значения предсказателей известны заранее.

```
fit_consBest <- us_change %>%
  model(
    lm = TSLM(Consumption ~ Income + Savings + Unemployment)
  )
future_scenarios <- scenarios(
  Increase = new_data(us_change, 4) %>%
    mutate(Income=1, Savings=0.5, Unemployment=0),
  Decrease = new_data(us_change, 4) %>%
    mutate(Income=-1, Savings=-0.5, Unemployment=0),
  names_to = "Scenario")
```

```
fc <- forecast(fit_consBest, new_data = future_scenarios)
us_change %>%
  autoplot(Consumption) +
  autolayer(fc) +
  labs(title = "Потребление в США", y = "Процентное изменение")
```

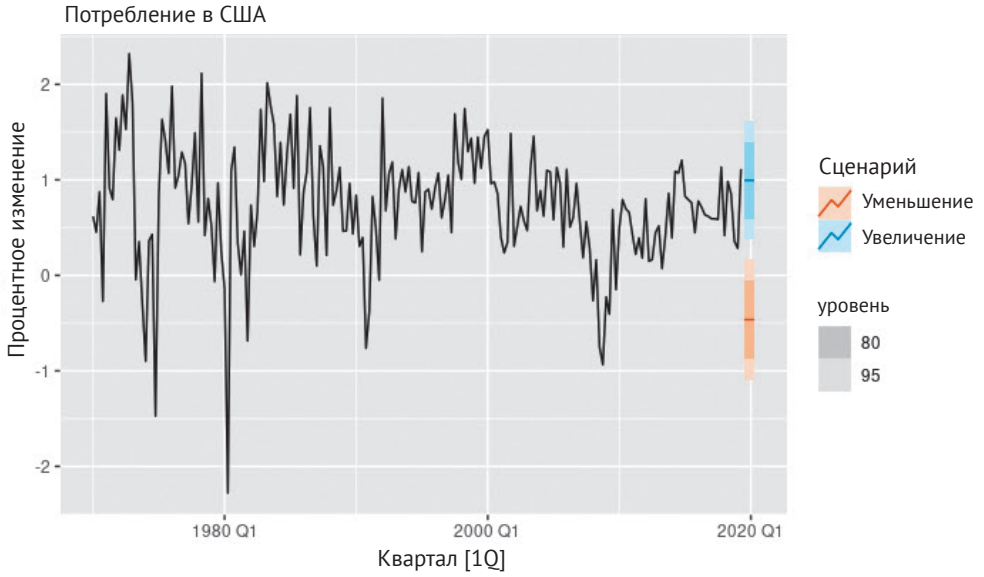


**Рисунок 7.18:** Прогнозирование процентных изменений расходов на личное потребление для США в рамках сценарного прогнозирования

## Строительство предсказательной регрессионной модели

Огромным преимуществом регрессионных моделей является то, что их можно использовать для определения важных взаимосвязей между интересующей прогнозной переменной и предсказательными переменными. Однако в случае антефактумных прогнозов эти модели требуют будущих значений каждого предсказателя, которые бывает непросто получить. Если прогнозирование каждого предсказателя слишком затруднено, то вместо этого можно использовать сценарное прогнозирование, где мы допускаем существование будущих значений всех предсказателей.

Альтернативная формулировка заключается в использовании в качестве предсказателей их лагов. Исходя из того, что мы заинтересованы в генерировании прогноза на $h$ шагов вперед, мы пишем

$$y_{t+h} = \beta_0 + \beta_1 x_{1,t} + \cdots + \beta_k x_{k,t} + \varepsilon_{t+h}$$

для $h = 1, 2 \ldots$. Набор предсказателей формируется значениями $x$, которые наблюдаются за $h$ периодов времени до наблюдения $y$. Поэтому, когда оцененная модель проецируется в будущее, т. е. за пределы конца выборки $T$, доступны все значения предсказателей.

Включение лагированных значений предсказателей не только делает модель работоспособной для беспрепятственного генерирования прогнозов, но и делает ее интуитивно привлекательной. Например, эффект от изменения в политике с целью увеличения производства может не оказать мгновенного влияния на потребительские расходы. Скорее всего, оно произойдет с лаговым эффектом. Мы коснулись этого в разделе 7.4, когда кратко представили распределенные лаги в качестве предсказателей. Несколько направлений обобщения регрессионных моделей с целью лучшего учета богатой динамики, наблюдаемой во временных рядах, обсуждаются в разделе 10.

## Предсказательные интервалы

Для каждого прогноза изменения в потреблении на рис. 7.18 также включены 95%-ный и 80%-ный предсказательные интервалы. Общая формулировка того, как вычислять предсказательные интервалы для моделей множественной регрессии, представлена в разделе 7.9. Поскольку она требует некоторой продвинутой матричной алгебры, ниже мы представляем пример вычисления предсказательных интервалов для простой регрессии, где прогноз может генерироваться с использованием уравнения

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x.$$

Исходя из допущения о том, что регрессионные ошибки распределены нормально, приближенный 95%-ный предсказательный интервал, ассоциированный с этим прогнозом, задается формулой

$$\hat{y} \pm 1.96\hat{\sigma}_e \sqrt{1 + \frac{1}{T} + \frac{(x-\bar{x})^2}{(T-1)s_x^2}}, \tag{7.4}$$

где $T$ – это суммарное число наблюдений, $\bar{x}$ – среднее значение наблюдаемых значений $x$, $s_x$ – стандартное отклонение наблюдаемых значений $x$ и $\hat{\sigma}_e$ – стандартная регрессионная ошибка, заданная уравнением (7.3). 80%-ный предсказательный интервал может быть получен аналогичным образом путем замены 1.96 на 1.28. Другие предсказательные интервалы можно получить путем замены значения 1.96 надлежащим значением, приведенным в табл. 5.1. Если для получения предсказательных интервалов используется пакет fable, то получаются более точные вычисления (в особенности для малых значений $T$), чем то, что задается уравнением (7.4).

Уравнение (7.4) показывает, что предсказательный интервал шире, когда $x$ находится далеко от $\bar{x}$. То есть мы более уверены в наших прогнозах, когда рассматриваем значения предсказательной переменной, близкие к ее выборочному среднему значению.

### Пример

Оценочная линия простой регрессии в примере потребления в США равна

$$\hat{y}_t = 0.54 + 0.27x_t.$$

Исходя из допущения о том, что в течение следующих четырех кварталов личный доход увеличится на свое историческое среднее значение, равное $\bar{x} = 0.73$ %, прогнозируется увеличение потребления на 0.74 %, и соответствующие 80%-ный и 95%-ный предсказательные интервалы равны соответственно [−0.02, 1.5] и [−0.42, 1.9] (рассчитано с использованием R). Если допустить экстремальный рост дохода на 12 %, то предсказательные интервалы будут значительно шире, как показано на рис. 7.19.

```
fit_cons <- us_change %>%
  model(TSLM(Consumption ~ Income))
new_cons <- scenarios(
  "Average increase" = new_data(us_change, 4) %>%
    mutate(Income = mean(us_change$Income)),
  "Extreme increase" = new_data(us_change, 4) %>%
    mutate(Income = 12),
  names_to = "Scenario"
)
fcast <- forecast(fit_cons, new_cons)

us_change %>%
  autoplot(Consumption) +
  autolayer(fcast) +
  labs(title = "Потребление в США", y = "Процентное изменение")
```

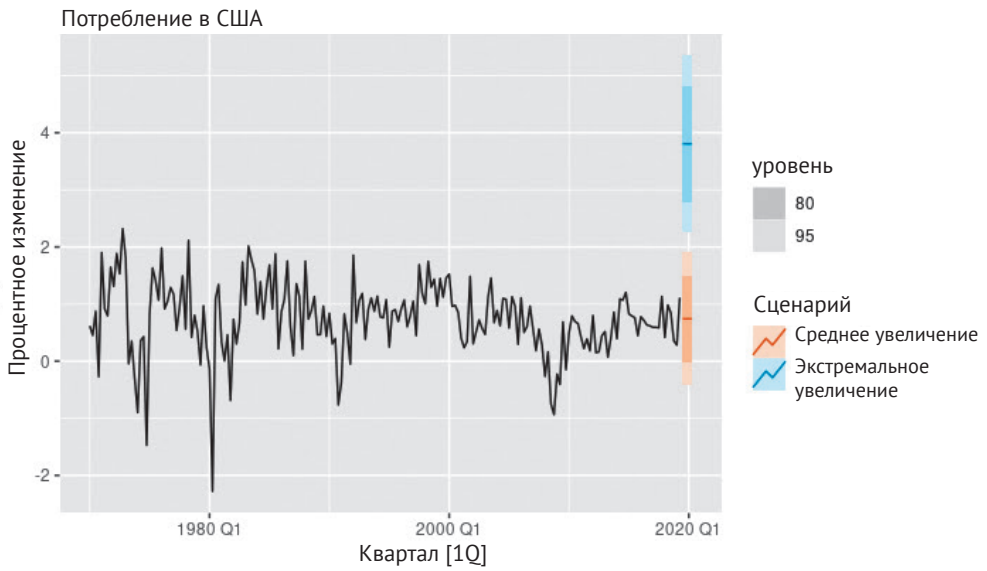


**Рисунок 7.19:** Предсказательные интервалы, если доход увеличивается на его историческое среднее значение, равное 0.73 %, по сравнению с экстремальным увеличением на 12 %

## 7.7 Нелинейная регрессия

Хотя линейная взаимосвязь, принятая до сих пор в этой главе, часто является адекватной, существует много случаев, когда нелинейная функциональная форма является более подходящей. В целях упрощения задачи в этом разделе мы исходим из допущения о том, что у нас есть только один предсказатель *x*.

Простейшим способом моделирования нелинейной взаимосвязи является преобразование прогнозной переменной *y* и/или предсказательной переменной *x* перед оцениванием регрессионной модели. Хотя оно обеспечивает нелинейную функциональную форму, модель по-прежнему линейна по параметрам. Наиболее часто используемым преобразованием является (натуральный) логарифм (см. раздел 3.1).

Двойная логарифмическая функциональная форма описывается как

$$\log y = \beta_0 + \beta_1 \log x + \beta.$$

В этой модели наклон $\beta_1$ можно интерпретировать как эластичность: $\beta_1$ – это среднее процентное изменение в *y* в результате увеличения в *x* на 1 %. Также могут быть указаны другие полезные формы. Логарифмическо-линейная форма задается преобразованием только прогнозной переменной, а линейно-логарифмическая форма получается путем преобразования предсказателя.

Вспомните, что для выполнения логарифмического преобразования переменной все ее наблюдаемые значения должны быть больше нуля. В случае если переменная *x* содержит нули, мы используем преобразование $\log(x + 1)$; т. е. мы добавляем единицу к значению переменной, а затем берем логарифмы. Это имеет тот же эффект, что и при вычислении логарифмов, но позволяет избегать проблемы нулей. Оно также имеет приятный побочный эффект, заключающийся в том, что нули в исходной шкале остаются нулями в преобразованной шкале.

Существуют случаи, для которых простого преобразования данных будет недостаточно и может потребоваться более общая формулировка. Тогда модель, которую мы используем, будет такой:

$$y = f(x) + \varepsilon,$$

где *f* – это нелинейная функция. В стандартной (линейной) регрессии $f(x) = \beta_0 + \beta_1 x$. В приведенной ниже формулировке нелинейной регрессии мы допускаем, что *f* является более гибкой нелинейной функцией от *x* по сравнению с простым логарифмическим или другим преобразованием.

Одна из самых простых формулировок заключается в том, чтобы сделать *f* **кусочно-линейной**. То есть мы вводим точки, в которых наклон *f* может изменяться. Такие точки называются **узловыми точками**. Это достигается путем уравнивания $x_1 = x$ и введения переменной $x_2$ такой, что

$$x_2 = (x - c)_+ = \begin{cases} 0, & \text{если } x < c. \\ x - c, & \text{если } x \geq c \end{cases}$$

Нотация $(x - c)_+$ означает значение $x - c$, если оно положительное, и 0 в противном случае. Это заставляет наклон изгибаться в точке *c*. Дополнительные

изгибы могут быть включены во взаимосвязь путем добавления дополнительных переменных вышеуказанной формы.

Построенные таким образом кусочно-линейные взаимосвязи являются частным случаем регрессионных сплайнов. В общем случае сплайн линейной регрессии получается с использованием

$$x_1 = xx_2 = (x - c_1)_+ \ldots x_k = (x - c_{k-1})_+,$$

где $c_1, \ldots, c_{k-1}$ – это узловые точки (точки, в которых линия может изгибаться). Выбор числа узловых точек ($k - 1$) и мест, где они должны быть расположены, бывает затруднен и несколько произвольным. Имеется несколько алгоритмов автоматического отбора узловых точек, но они широко не используются.

## Прогнозирование с нелинейным трендом

В разделе 7.4 была введена подгонка линейного тренда к временному ряду путем установки $x = t$. Простейшим способом подгонки нелинейного тренда является использование квадратичных трендов или трендов более высокого порядка, получаемых в результате формулировки

$$x_{1,t} = t, x_{2,t} = t^2, \ldots.$$

Однако не рекомендуется использовать квадратичные тренды или тренды более высокого порядка при прогнозировании. Когда они экстраполируются, результирующие прогнозы часто оказываются нереалистичными.

Более совершенный подход заключается в использовании представленной выше кусочной формулировки и подгонке кусочно-линейного тренда, который изгибается в некоторый момент времени. Это можно представить как нелинейный тренд, построенный из линейных частей. Если тренд отклоняется во времени $\tau$, то его можно задать, просто заменив $x = t$ и $c = \tau$ в вышеприведенной формуле так, чтобы включить предсказатели

$$\begin{aligned} x_{1,t} &= t \\ x_{2,t} &= (t - \tau)_+ = \begin{cases} 0, & \text{если } t < \tau \\ t - \tau, & \text{если } t \geq \tau \end{cases} \end{aligned}$$

в модели. Если ассоциированными коэффициентами переменных $x_{1,t}$ и $x_{2,t}$ являются $\beta_1$ и $\beta_2$, то $\beta_1$ показывает наклон тренда до наступления времени $\tau$, тогда как наклон линии после наступления времени $\tau$ задается через $\beta_1 + \beta_2$. Дополнительные изгибы могут быть включены во взаимосвязь путем добавления дополнительных переменных вида $(t - \tau)_+$, где $\tau$ – это «узловая точка», или момент времени, в котором линия должна изгибаться.

## Пример: времена побед в Бостонском марафоне

Мы подберем несколько трендовых моделей для мужчин, победивших в Бостонском марафоне. Сначала мы извлекаем данные о мужчинах и конвертируем времена побед в числовое значение. В 1924 году трасса была удлинена

(с 24.5 мили до 26.2 мили), что привело к скачку времен побед, поэтому мы рассматриваем данные только с этой даты и далее.

```
boston_men <- boston_marathon %>%
  filter(Year >= 1924) %>%
  filter(Event == "Men's open division") %>%
  mutate(Minutes = as.numeric(Time)/60)
```

На верхней панели рис. 7.20 показаны времена побед с 1924 года. Временной ряд показывает общий понижательный тренд, поскольку времена побед с годами улучшаются. На нижней панели показаны остатки от подгонки линейного тренда к данным. График показывает очевидную нелинейную взаимосвязь, которая не была захвачена линейным трендом.

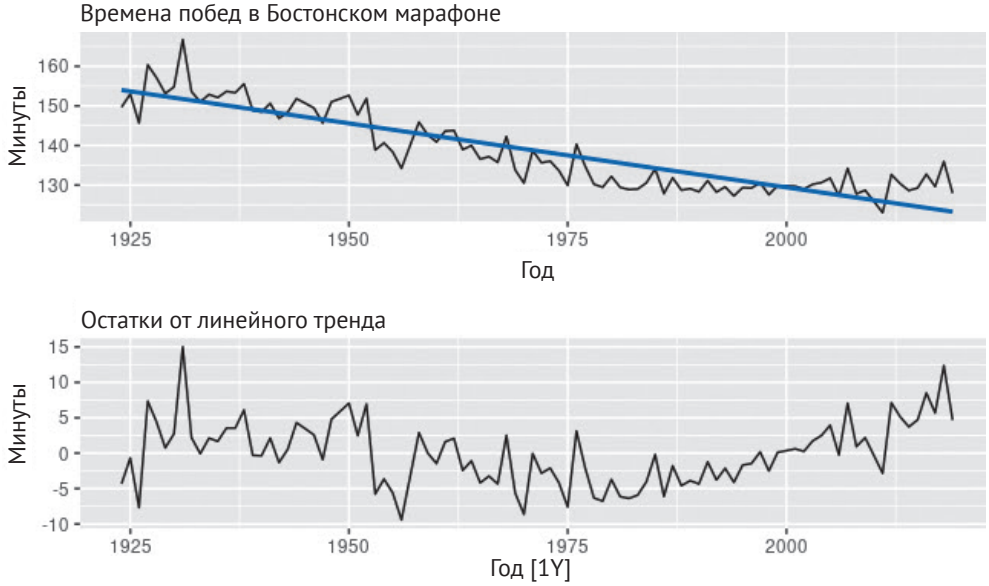


**Рисунок 7.20:** Неадекватность подгонки линейного тренда к временам побед в Бостонском марафоне

Подгонки экспоненциального тренда (эквивалентного логарифмическо-линейной регрессии) к данным можно достичь путем преобразования переменной $y$ так, чтобы подгоняемая модель стала

$$\log y_t = \beta_0 + \beta_1 t + \varepsilon_t.$$

Подогнанный экспоненциальный тренд и прогнозы показаны на рис. 7.21. Хотя экспоненциальный тренд, по-видимому, не вписывается в данные намного лучше, чем линейный тренд, он, возможно, дает более разумную проекцию в том смысле, что времена побед в будущем будут уменьшаться, но с убывающей скоростью, а не с фиксированной линейной скоростью.

График времен побед раскрывает три разных периода. Примерно до 1950 года имеется большая волатильность времен побед, при этом времена побед прак-

тически не уменьшались. После 1950 года наблюдается явное сокращение времен, за которым идет выравнивание после 1980-х годов, с предположением о повороте вверх к концу выборки. Для того чтобы учесть эти изменения, мы указываем 1950 и 1980 годы в качестве узловых точек. Здесь мы должны предупредить, что субъективная идентификация узловых точек может приводить к переподгонке, что может нанести ущерб прогнозной результативности модели, и должна выполняться с осторожностью.

```
fit_trends <- boston_men %>%
  model(
    linear = TSLM(Minutes ~ trend()),
    exponential = TSLM(log(Minutes) ~ trend()),
    piecewise = TSLM(Minutes ~ trend(knots = c(1950, 1980)))
  )
fc_trends <- fit_trends %>% forecast(h = 10)

boston_men %>%
  autoplot(Minutes) +
  geom_line(data = fitted(fit_trends),
            aes(y = .fitted, colour = .model)) +
  autolayer(fc_trends, alpha = 0.5, level = 95) +
  labs(y = "Минуты",
       title = "Времена побед в Бостонском марафоне")
```

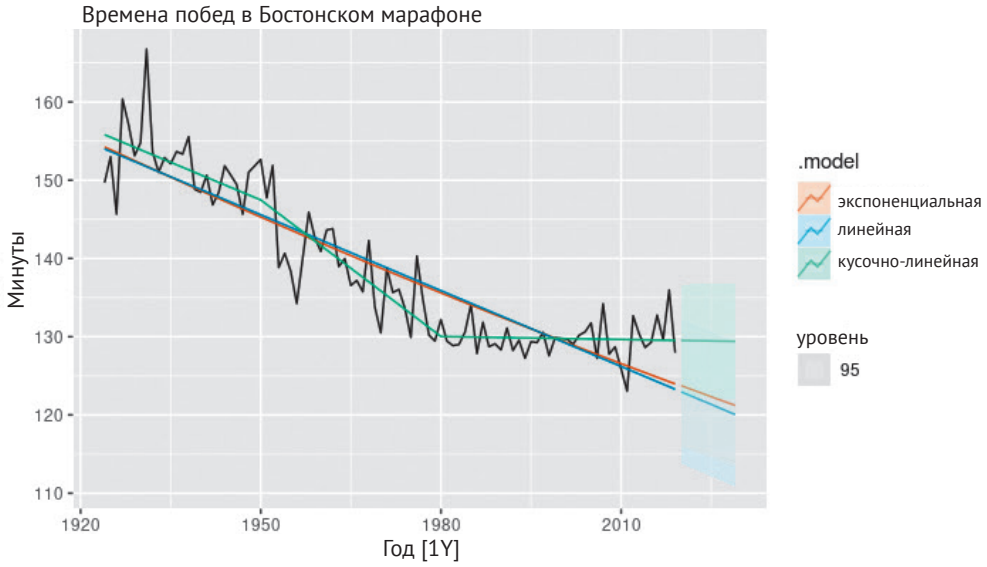


**Рисунок 7.21:** Проецирование прогнозов из линейного, экспоненциального и кусочно-линейного трендов для времен побед в Бостонском марафоне

На рис. 7.21 показаны подогнанные линии и прогнозы из линейного, экспоненциального и кусочно-линейного трендов. Наилучшие прогнозы, по-видимому, поступают из кусочно-линейного тренда.

## 7.8 Корреляция, каузация и прогнозирование

### Корреляция – это не каузация

Важно не путать корреляцию с каузацией, т. е. причинно-следственной связью, или каузацию с прогнозированием. Переменная *x* может быть полезна для прогнозирования переменной *y*, но это не означает, что из *x* следует *y*. Возможно, что из *x* следует y, но может случиться так, что из *y* следует *x* или что взаимосвязь между ними более сложна, чем простая причинно-следственная связь.

Например, можно смоделировать число утонувших на пляжном курорте каждый месяц с количеством мороженого, проданного за тот же период. Модель может давать разумные прогнозы не потому, что из мороженого следует несчастный случай на воде, а потому, что люди едят больше мороженого в жаркие дни, когда они также с большей вероятностью пойдут купаться. Таким образом, две переменные (продажи мороженого и несчастные случаи на воде) коррелируют, но одно не вызывает другое. Оба они обусловлены третьей переменной (температурой). Это пример «спутывания», когда опущенная переменная вызывает изменения как в переменной-отклике, так и, по меньшей мере, в одной переменной-предсказателе.

Мы описываем переменную, которая не включена в нашу модель прогнозирования, как **спутывающую переменную**, когда она влияет как на переменную-отклик, так и, по меньшей мере, на одну переменную-предсказатель. Спутывание затрудняет определение того, какие переменные *вызывают* изменения в других переменных, но это не обязательно усложняет прогнозирование.

Аналогичным образом можно спрогнозировать, будет ли дождь во второй половине дня, наблюдая за числом велосипедистов на дороге утром. Когда велосипедистов меньше, чем обычно, более вероятно, что позже в тот же день пойдет дождь. Модель может давать разумные прогнозы не потому, что велосипедисты предотвращают дождь, а потому, что люди с большей вероятностью будут ездить на велосипеде, когда опубликованный прогноз погоды показывает сухой день. В этом данном существует причинно-следственная связь, но в направлении, противоположном нашей модели прогнозирования. Число велосипедистов падает, потому что прогнозируется дождь. То есть *y* (осадки) влияют на *x* (велосипедистов).

Важно понимать, что корреляции полезны для прогнозирования, даже когда между двумя переменными нет причинно-следственной связи, или когда причинно-следственная связь работает в направлении, противоположном модели, или когда есть спутывание.

Однако нередко возможна более совершенная модель, если можно определить причинно-следственный механизм. Более совершенная модель для несчастных случаев на воде, вероятно, будет включать температуру и число посетителей и исключать продажи мороженого. Хорошая модель прогнозирования осадков не будет включать велосипедистов, но она будет включать атмосферные наблюдения за предыдущие несколько дней.

## Прогнозирование с использованием коррелированных предсказателей

Когда два или более предсказателей сильно коррелируют, всегда сложно точно вычленить их индивидуальные эффекты. Предположим, мы прогнозируем ежемесячные продажи компании на 2012 год, используя данные за 2000–2011 годы. В январе 2008 года на рынок вышел новый конкурент и начал занимать некоторую долю рынка. В то же время начался спад экономики. В свою модель прогнозирования вы включаете как активность конкурентов (измеряемую с помощью рекламного времени на местной телевизионной станции), так и состояние экономики (измеряемое с помощью ВВП). Вычленить эффекты этих двух предсказателей будет невозможно, поскольку они сильно коррелируют.

Наличие коррелированных предсказателей на самом деле не является проблемой для прогнозирования, поскольку мы все еще можем вычислять прогнозы без необходимости вычленять эффекты предсказателей. Однако это становится проблемой при сценарном прогнозировании, поскольку сценарии должны учитывать взаимосвязи между предсказателями. Это также является проблемой, если требуется некоторый исторический анализ вклада различных предсказателей.

## Мультиколлинеарность и прогнозирование

Близкородственной проблемой является мультиколлинеарность, которая возникает, когда аналогичная информация предоставляется двумя или более предсказательными переменными в множественной регрессии.

Это может происходить, когда два предсказателя сильно коррелируют друг с другом (то есть они имеют коэффициент корреляции, близкий к +1 либо –1). В этом случае знание значения одной из переменных многое говорит о значении другой переменной. Следовательно, они предоставляют аналогичную информацию. Например, размер стопы можно использовать для предсказания роста, но включение размера левой и правой стоп в одну и ту же модель не улучшит прогнозы, хотя и не ухудшит их.

Мультиколлинеарность может также возникать, когда линейная комбинация предсказателей сильно коррелирует с другой линейной комбинацией предсказателей. В этом случае знание значения первой группы предсказателей многое говорит о значении второй группы предсказателей. Следовательно, они предоставляют аналогичную информацию.

Примером этой проблемы является ловушка фиктивных переменных, рассмотренная в разделе 7.4. Предположим, у вас есть квартальные данные, и вы используете четыре фиктивные переменные: $d_1$, $d_2$, $d_3$, и $d_4$. Тогда $d_4 = 1 - d_1 - d_2 - d_3$, так что существует идеальная корреляция между $d_4$ и $d_1 + d_2 + d_3$.

В случае идеальной корреляции (т. е. корреляции +1 или –1, например в ловушке фиктивных переменных) оценить регрессионную модель невозможно.

Если существует высокая корреляция (близкая, но не равная +1 или –1), то оценить коэффициенты регрессии вычислительно трудно. На самом деле некоторые программы (в частности, Microsoft Excel) могут давать очень неточные оценки коэффициентов. Большинство авторитетных статистических программ будут использовать алгоритмы лимитирования влияния мульти-

коллинеарности на оценки коэффициентов, но вам нужно быть осторожным. Основные программные пакеты, такие как R, SPSS, SAS и Stata, используют алгоритмы оценивания, чтобы максимально избежать этой проблемы.

При наличии мультиколлинеарности неопределенность, связанная с отдельными коэффициентами регрессии, будет большой. Это происходит потому, что их трудно оценить. Следовательно, статистические тесты (например, *t*-тесты) коэффициентов регрессии ненадежны. (В прогнозировании мы редко интересуемся такими тестами.) Кроме того, невозможно будет сделать точные утверждения о вкладе каждого отдельного предсказателя в прогноз.

Прогнозы будут ненадежными, если значения будущих предсказателей находятся за пределами диапазона исторических значений предсказателей. Например, предположим, что вы снабдили регрессионную модель предсказателями $x_1$ и $x_2$, которые сильно коррелируют друг с другом, и предположим, что значения $x_1$ в тренировочных данных варьировались от 0 до 100. Тогда прогнозы, основанные на $x_1 > 100$ или $x_1 < 0$, будут ненадежными. Всегда немного опасно, когда будущие значения предсказателей лежат далеко за пределами исторического диапазона, но это особенно проблематично, когда присутствует мультиколлинеарность.

Обратите внимание, что если вы используете хорошее статистическое программное обеспечение, и если вас не интересует конкретный вклад каждого предсказателя, и если будущие значения ваших предсказательных переменных находятся в пределах их исторических диапазонов, то беспокоиться не о чем – мультиколлинеарность не является проблемой, за исключением случаев, когда существует идеальная корреляция.

## 7.9 Матричная формулировка

Внимание: это более продвинутый факультативный раздел, предполагающий знание матричной алгебры.

Напомним, что модель множественной регрессии можно записать как

$$y_t = \beta_0 + \beta_1 x_{1,t} + \beta_2 x_{2,t} + \cdots + \beta_k x_{k,t} + \varepsilon_t,$$

где $\varepsilon_t$ имеет среднее значение, равное нулю, и дисперсию $\sigma^2$. Эта формула выражает взаимосвязь между одним значением прогнозной переменной и предсказателями.

Бывает удобно записать ее в матричной форме, в которой все значения прогнозной переменной формулируются в одном уравнении. Пусть $\boldsymbol{y} = (y_1, \ldots, y_T)', \boldsymbol{\varepsilon} = (\varepsilon_1, \ldots, \varepsilon_T)', \boldsymbol{\beta} = (\varepsilon_0, \ldots, \varepsilon_k)'$ и

$$\boldsymbol{X} = \begin{bmatrix} 1 & x_{1,1} & x_{2,1} & \cdots & x_{k,1} \\ 1 & x_{1,2} & x_{2,2} & \cdots & x_{k,2} \\ \vdots & \vdots & \vdots & & \vdots \\ 1 & x_{1,T} & x_{2,T} & \cdots & x_{k,T} \end{bmatrix}.$$

Тогда

$$\boldsymbol{y} = \boldsymbol{X}\beta + \varepsilon,$$

где $\boldsymbol{\varepsilon}$ имеет среднее значение 0 и дисперсию $\sigma^2$. Обратите внимание, что матрица $\boldsymbol{X}$ имеет $T$ строк, отражающих число наблюдений, и $k + 1$ столбцов, отражающих пересечение, которое представлено столбцом единиц плюс числом предсказателей.

## Оценивание методом наименьших квадратов

Оценивание методом наименьших квадратов выполняется путем минимизирования выражения $\boldsymbol{\varepsilon}'\boldsymbol{\varepsilon} = (\boldsymbol{y} - \boldsymbol{X}\boldsymbol{\beta})'\left(\boldsymbol{y} - \boldsymbol{X}\boldsymbol{\beta}\right)$. Можно показать, что оно минимизируется, когда $\boldsymbol{\beta}$ принимает значение

$$\widehat{\boldsymbol{\beta}} = (\boldsymbol{X}'\boldsymbol{X})^{-1}\boldsymbol{X}'\boldsymbol{y}.$$

Это уравнение иногда называют «нормальным уравнением». Оцениваемые коэффициенты требуют инверсии матрицы $\boldsymbol{X}'\boldsymbol{X}$. Если $\boldsymbol{X}$ не имеет полного столбцового ранга, то матрица $\boldsymbol{X}'\boldsymbol{X}$ является сингулярной, и оценить модель невозможно. Это произойдет, например, если вы попадете в «ловушку фиктивных переменных», то есть будете иметь такое же число фиктивных переменных, как и категорий категориального предсказателя, как обсуждалось в разделе 7.4.

Дисперсия остатков оценивается с использованием

$$\widehat{\sigma_e^2} = \frac{1}{T-k-1}(\boldsymbol{y} - \boldsymbol{X}\widehat{\boldsymbol{\beta}})'\left(\boldsymbol{y} - \boldsymbol{X}\widehat{\boldsymbol{\beta}}\right).$$

## Подогнанные значения и перекрестная валидация

Нормальное уравнение показывает, что подогнанные значения можно рассчитать с использованием

$$\hat{\boldsymbol{y}} = \boldsymbol{X}\widehat{\boldsymbol{\beta}} = \boldsymbol{X}(\boldsymbol{X}'\boldsymbol{X})^{-1}\boldsymbol{X}'\boldsymbol{y} = \boldsymbol{H}\boldsymbol{y},$$

где $\boldsymbol{H} = \boldsymbol{X}(\boldsymbol{X}'\boldsymbol{X})^{-1}\boldsymbol{X}'$ называется проекционной матрицей, или «шляпной матрицей» (hat-matrix), поскольку она используется для вычисления $\hat{\boldsymbol{y}}$ ($y$ с циркумфлексом).

Если диагональные значения матрицы $\boldsymbol{H}$ обозначаются через $h_1, \ldots, h_T$, тогда статистику перекрестной валидации (CV) можно вычислить с использованием

$$\text{CV} = \frac{1}{T}\sum_{t=1}^{T}[e_t / (1 - h_t)]^2,$$

где $e_t$ – это остаток, полученный в результате подгонки модели ко всем $T$ наблюдения. Таким образом, на самом деле нет необходимости выполнять подгонку $T$ отдельных моделей при вычислении статистики CV.

### Прогнозы и предсказательные интервалы

Пусть $\boldsymbol{x}^*$ есть вектор-строка, содержащий значения предсказателей (в том же формате, что и $\boldsymbol{X}$), для которого мы хотим сгенерировать прогноз. Тогда прогноз задается формулой

$$\hat{y} = \boldsymbol{x}^* \hat{\boldsymbol{\beta}} = \boldsymbol{x}^* (\boldsymbol{X}'\boldsymbol{X})^{-1} \boldsymbol{X}'\boldsymbol{y},$$

а оценочная прогнозная дисперсия задается формулой

$$\widehat{\sigma_e^2}[1 + \boldsymbol{x}^* (\boldsymbol{X}'\boldsymbol{X})^{-1} (\boldsymbol{x}^*)'].$$

95%-ный предсказательный интервал можно рассчитать (приняв допущение о нормальности распределения ошибок) как

$$\hat{y} \pm 1.96\widehat{\sigma_e}\sqrt{1 + \boldsymbol{x}^* (\boldsymbol{X}'\boldsymbol{X})^{-1} (\boldsymbol{x}^*)'}.$$

При этом учитывается неопределенность, обусловленная членом ошибки $\varepsilon$, и неопределенность в оценках коэффициентов. Однако это выражение игнорирует любые ошибки в $\boldsymbol{x}^*$. Таким образом, если будущие значения предсказателей неопределенны, то предсказательный интервал, рассчитанный с использованием указанного выражения, будет слишком узким.

## 7.10 Упражнения

1. Получасовой спрос на электроэнергию для шт. Виктория, Австралия, содержится в `vic_elec`. Извлеките данные спроса на электроэнергию за январь 2014 года и агрегируйте эти данные, сведя их к ежедневным с учетом ежедневных суммарных спросов и максимальных температур.

```
an14_vic_elec <- vic_elec %>%
  filter(yearmonth(Time) == yearmonth("2014 Jan")) %>%
  index_by(Date = as_date(Time)) %>%
  summarise(
    Demand = sum(Demand),
    Temperature = max(Temperature)
  )
```

   a) Нанесите данные на график и найдите регрессионную модель для спроса с температурой в качестве предсказательной переменной. Почему существует положительная взаимосвязь?
   b) Сгенерируйте график остатков. Является ли модель адекватной? Есть ли какие-либо выбросы или влиятельные наблюдения?
   c) Используйте модель для прогнозирования спроса на электроэнергию, который можно было бы ожидать на следующий день, если бы максимальная температура была 15 °C, и сравните ее прогноз с прогнозом, если максимальная температура была 35 °C. Верите ли вы

этим прогнозам? Следующий ниже исходный код на R поможет вам начать работу:

```
jan14_vic_elec %>%
  model(TSLM(Demand ~ Temperature)) %>%
  forecast(
    new_data(jan14_vic_elec, 1) %>%
      mutate(Temperature = 15)
  ) %>%
  autoplot(jan14_vic_elec)
```

a) Укажите предсказательные интервалы для ваших прогнозов.
b) Постройте график взаимосвязи между спросом и температурой для всех имеющихся в `vic_elec` данных, агрегированных со сведением к суммарному суточному спросу и максимальной температуре. Что это говорит о вашей модели?

2. Набор данных `olympic_running` содержит времена побед (в секундах) на всех Олимпийских играх в спринте, беге на средние и длинные дистанции с 1896 по 2016 год.
   a) Нанесите на график время победы в сопоставлении с годом для каждого события. Опишите главные признаки графика.
   b) Выполните подгонку линии регрессии к данным каждого события. Очевидно, что времена побед сокращаются, но с какой средней скоростью в год?
   c) Постройте график остатков в сопоставлении с годом. Что он говорит о пригодности подогнанных линий?
   d) Предскажите время победы в каждом забеге на Олимпийских играх 2020 года. Укажите предсказательный интервал для ваших прогнозов. Какие допущения вы приняли в этих расчетах?
3. Коэффициент эластичности – это отношение процентного изменения в прогнозной переменной ($y$) к процентному изменению в предсказательной переменной ($x$). Математически эластичность определяется как $(dy/dx) \times (x/y)$. Рассмотрим двойную логарифмическую модель:

$$\log y = \beta_0 + \beta_1 \log x + \varepsilon.$$

   Выразите $y$ как функцию от $x$ и покажите, что коэффициент $\beta_1$ – это коэффициент эластичности.
4. Набор данных `souvenirs` касается ежемесячных показателей продаж магазина, который открылся в январе 1987 года и продает подарки, сувениры и новинки. Магазин расположен на пристани в пляжном курортном городке в Квинсленде, Австралия. Объем продаж варьируется в зависимости от сезонного числа туристов. На Рождество и на местный фестиваль серфинга, который проводится каждый март с 1988 года, в город приезжает большой поток посетителей. Со временем магазин расширил свои помещения, ассортимент продукции и штат сотрудников.

a) Постройте график времени в сопоставлении с данными и опишите закономерности на графике. Определите любые необычные или неожиданные колебания во временном ряду.
b) Объясните, почему перед подгонкой модели необходимо брать логарифмы этих данных.
c) Выполните подгонку регрессионной модели к логарифмам этих данных продаж с помощью линейного тренда, сезонных фиктивных переменных и фиктивной переменной «фестиваль серфинга».
d) Постройте график остатков в сопоставлении со временем и в сопоставлении с подогнанными значениями. Выявляют ли эти графики какие-либо проблемы с моделью?
e) Постройте коробчатые диаграммы остатков за каждый месяц. Выявит ли это какие-либо проблемы с моделью?
f) Что говорят значения коэффициентов о каждой переменной?
g) Что говорит тест Льюнга–Бокса о вашей модели?
h) Независимо от ваших ответов на вышеприведенные вопросы используйте свою регрессионную модель для прогнозирования ежемесячных продаж за 1994, 1995 и 1996 годы. Сгенерируйте предсказательные интервалы для каждого из ваших прогнозов.
i) Какие существуют пути улучшения этих прогнозов путем модифицирования модели?

5. Ряд `us_gasoline` состоит из еженедельных данных поставок готового автомобильного бензина в США за период со 2 февраля 1991 года по 20 января 2017 года. Единицы измерения указаны в «миллионах баррелей в день». Рассмотрите данные только на конец 2004 года.
   a) Выполните подгонку гармонической регрессии с трендом к данным. Поэкспериментируйте с изменением числа членов Фурье. Нанесите на график наблюдаемые значения бензина и подогнанные значения и прокомментируйте то, что вы видите.
   b) Выберите подходящее число членов Фурье для включения в модель, минимизируя значение AICc или CV.
   c) Постройте график остатков окончательной модели с помощью функции `gg_tsresiduals()` и прокомментируйте их. Используйте тест Льюнга–Бокса для проверки автокорреляции остатков.
   d) Создайте прогнозы на следующий год из данных и нанесите их на график вместе с фактическими данными за 2005 год. Прокомментируйте прогнозы.
6. Годовая численность населения Афганистана имеется в наборе данных `global_economy`.
   a) Постройте график данных и прокомментируйте их особенности. Можно ли наблюдать последствия советско-афганской войны?
   b) Выполните подгонку модели линейного тренда и сравните ее с кусочно-линейной моделью тренда с узловыми точками в 1980 и 1989 годах.
   c) Сгенерируйте прогнозы на основе этих двух моделей на пять лет после окончания сбора данных и прокомментируйте результаты.

7. (Для продвинутых читателей, последовавших из раздела 7.9.)

   Используя матричную нотацию, было показано, что если $\boldsymbol{y} = \boldsymbol{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$, где $\boldsymbol{\varepsilon}$ имеет среднее значение 0 и матрицу дисперсий $\sigma^2\boldsymbol{I}$, оцениваемые коэффициенты задаются формулой $\widehat{\boldsymbol{\beta}} = (\boldsymbol{X}'\boldsymbol{X})^{-1}\boldsymbol{X}'\boldsymbol{y}$ и прогноз задается формулой $\hat{y} = \boldsymbol{x}^*\widehat{\boldsymbol{\beta}} = \boldsymbol{x}^*(\boldsymbol{X}'\boldsymbol{X})^{-1}\boldsymbol{X}'\boldsymbol{y}$, где $\boldsymbol{x}^*$ – это вектор-строка, содержащий значения предсказателей для прогноза (в том же формате, что и $\boldsymbol{X}$), и прогнозная дисперсия задается формулой $\mathrm{Var}\left(\hat{y}\right) = \sigma^2[1 + \boldsymbol{x}^*(\boldsymbol{X}'\boldsymbol{X})^{-1}\left(\boldsymbol{x}^*\right)']$.

   Рассмотрите простую модель временного тренда, где $y_t = \beta_0 + \beta_1 t$. Используя следующие ниже результаты:

$$\sum_{t=1}^{T} t = \frac{1}{2}T(T+1), \quad \sum_{t=1}^{T} t^2 = \frac{1}{6}T(T+1)(2T+1),$$

   математически выведите следующие ниже выражения:

   a) $\boldsymbol{X}'\boldsymbol{X} = \frac{1}{6}\begin{bmatrix} 6T & 3T(T+1) \\ 3T(T+1) & T(T+1)(2T+1) \end{bmatrix}$;

   b) $(\boldsymbol{X}'\boldsymbol{X})^{-1} = \frac{2}{T(T^2-1)}\begin{bmatrix} (T+1)(2T+1) & -3(T+1) \\ -3(T+1) & 6 \end{bmatrix}$;

   c) $\hat{\beta}_0 = \frac{2}{T(T-1)}\left[(2T+1)\sum_{t=1}^{T} y_t - 3\sum_{t=1}^{T} t y_t\right]$;
   $\hat{\beta}_1 = \frac{6}{T(T^2-1)}\left[2\sum_{t=1}^{T} t y_t - (T+1)\sum_{t=1}^{T} y_t\right]$

   d) $\mathrm{Var}\left(\hat{y}_t\right) = \hat{\sigma}^2\left[1 + \frac{2}{T(T-1)}\left(1 - 4T - 6h + 6\frac{(T+h)^2}{T+1}\right)\right]$.

## 7.11 Дальнейшее чтение

Существует бесчисленное множество книг по регрессионному анализу, но лишь немногие из них посвящены регрессии в отношении временных рядов и прогнозированию.

- Хорошей общей и современной книгой по регрессии является Хизер (2009, *https://otexts.com/fpp3/regression-reading.html#ref-Sheather09*).
- Еще один общий регрессионный текст, полный превосходных практических советов, представлен книгой Харрелл (2015, *https://otexts.com/fpp3/regression-reading.html#ref-RMS15*).
- Орд и соавт. (2017, *https://otexts.com/fpp3/regression-reading.html#ref-Ord2017*) предоставляет практическое описание регрессионных моделей для временных рядов в главах 7–9 с сильным уклоном на прогнозирование.

# Библиография

*Харрелл, Ф. Э.* (2015). Стратегии регрессионного моделирования: с приложениями к линейным моделям, логистической и порядковой регрессии и анализом выживаемости (2-е изд.). Springer. [Amazon, *http://buy.geni.us/Proxy.ashx?TSID=140570&GR_URL=http%3A%2F%2Fwww.amazon.com%2Fdp%2F3319194240*].

*Орд, Дж. К., Филдес, Р. и Курентзес, Н.* (2017). Принципы бизнес-прогнозирования (2-е изд.). Wessex Press Publishing Co. [Amazon, *http://buy.geni.us/Proxy.ashx?TSID=140570&GR_URL=http%3A%2F%2Fwww.amazon.com%2Fdp%2F0999064916*].

*Хизер, С. Дж.* (2009). Современный подход к регрессии на R. Springer. [Amazon, *http://buy.geni.us/Proxy.ashx?TSID=140570&GR_URL=http%3A%2F%2Fwww.amazon.com%2Fdp%2F0387096078*].

# Глава 8

# Экспоненциальное сглаживание

Экспоненциальное сглаживание было предложено в конце 1950-х годов (Браун, 1959; Хольт, 1957; Винтерс, 1960) и послужило основой для нескольких наиболее успешных методов прогнозирования. Прогнозы, произведенные с использованием методов экспоненциального сглаживания, представляют собой средневзвешенные значения прошлых наблюдений, причем веса экспоненциально убывают по мере старения наблюдений. Другими словами, чем наблюдение является более недавним, тем выше соответствующий вес. Этот каркас быстро генерирует надежные прогнозы для широкого диапазона временных рядов, что является большим преимуществом и имеет большое значение для применения в промышленности.

Настоящая глава разделена на две части. В первой части (разделы 8.1–8.4) мы представляем механику наиболее важных методов экспоненциального сглаживания и их применение для прогнозирования временных рядов с различными характеристиками. Она помогает нам развить интуицию относительно того, как работают описываемые методы. В этой ситуации выбор и использование метода прогнозирования могут показаться несколько случайными. Выбор метода, как правило, основан на распознавании ключевых компонент (трендовой и сезонной) временного ряда и способа, которым они входят в метод сглаживания (например, аддитивным, демпфирующим или мультипликативным способом).

Во второй части главы (разделы 8.5–8.7) мы представляем статистические модели, лежащие в основе методов экспоненциального сглаживания. Указанные модели генерируют точечные прогнозы, идентичные методам, рассмотренным в первой части главы, но также генерируют предсказательные интервалы. Кроме того, указанный статистический каркас позволяет осуществлять подлинный отбор модели между конкурирующими моделями.

## Библиография

*Браун, Р. Г.* (1959). Статистическое прогнозирование для управления запасами. McGraw/Hill.

*Хольт, К. С.* (1957). Прогнозирование сезонных колебаний и трендов с помощью экспоненциально взвешенных средних (ONR Memorandum No. 52). Технологический институт Карнеги, Питтсбург, США. Перепечатано

в International Journal of Forecasting, 2004 год. [DOI: https://doi.org/10.1016/j.ijforecast.2003.09.015].

*Винтерс, П. Р.* (1960). Прогнозирование продаж с помощью экспоненциально взвешенных скользящих средних. Management Science, 6 (3), 324–342. [DOI: https://doi.org/10.1287/mnsc.6.3.324].

## 8.1 Простое экспоненциальное сглаживание

Простейший метод экспоненциального сглаживания, естественно, называется **простым экспоненциальным сглаживанием** (simple exponential smoothing, аббр. SES)[1]. Этот метод подходит для прогнозирования данных без четкой трендовой или сезонной закономерности. Например, данные на рис. 8.1 не показывают каких-либо четких трендов или какой-либо сезонности. (В последние несколько лет наблюдается спад, что может свидетельствовать о тренде. Позже в этой главе мы рассмотрим, будет ли трендовый метод работать лучше для этого ряда.) Мы уже рассматривали наивный метод и метод среднего как возможные методы прогнозирования таких данных (раздел 5.2).

```
algeria_economy <- global_economy %>%
  filter(Country == "Algeria")
algeria_economy %>%
  autoplot(Exports) +
  labs(y = "Процент ВВП", title = "Экспорт: Алжир")
```

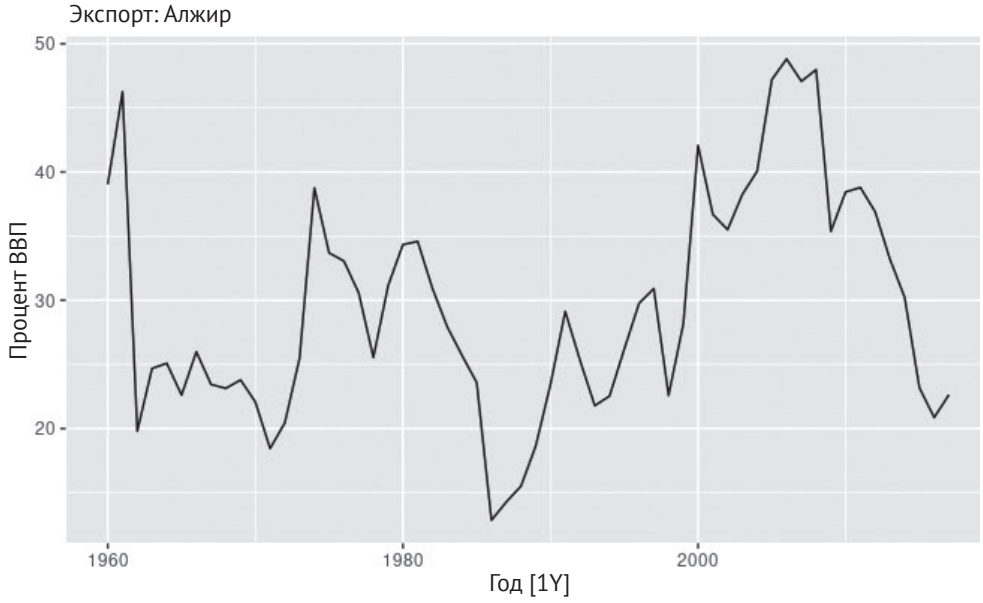


**Рисунок 8.1:** Экспорт товаров и услуг из Алжира с 1960 по 2017 год

[1] В некоторых книгах оно называется «одиночным экспоненциальным сглаживанием» (single exponential smoothing).

Используя наивный метод, все прогнозы на будущее равны последнему наблюдаемому значению ряда

$$\hat{y}_{T+h|T} = y_T$$

для $h = 1, 2, \ldots$. Следовательно, наивный метод основан на допущении о том, что самое последнее наблюдение является единственным важным, а все предыдущие наблюдения не дают никакой информации на будущее. Его можно рассматривать как средневзвешенное значение, в котором весь вес придается последнему наблюдению.

Используя метод усреднения, все будущие прогнозы равны простому среднему значению наблюдаемых данных

$$\hat{y}_{T+h|T} = \frac{1}{T}\sum_{t=1}^{T} y_t$$

для $h = 1, 2, \ldots$. Следовательно, метод среднего основан на допущении о том, что все наблюдения имеют одинаковую важность, и придает им равные веса при генерировании прогнозов.

Мы нередко хотим чего-то между этими двумя крайностями. Например, бывает разумно придавать больший вес более недавним наблюдениям, чем наблюдениям из далекого прошлого. Именно эта концепция лежит в основе простого экспоненциального сглаживания. Прогнозы рассчитываются с использованием средневзвешенных значений, в которых веса уменьшаются экспоненциально, по мере того как наблюдения поступают из более отдаленного прошлого – наименьшие веса связаны с самыми старыми наблюдениями:

$$\hat{y}_{T+1|T} = \alpha y_T + \alpha(1-\alpha) y_{T-1} + \alpha(1-\alpha)^2 y_{T-2} + \cdots, \tag{8.1}$$

где $0 \le \alpha \le 1$ – это параметр сглаживания. Прогноз на один шаг вперед на момент времени $T + 1$ – это средневзвешенное значение всех наблюдений в ряду $y_1, \ldots y_T$. Скорость, с которой веса уменьшаются, регулируется параметром $\alpha$.

В приведенной ниже таблице показаны веса, приданные наблюдениям для четырех различных значений $\alpha$ при прогнозировании с использованием простого экспоненциального сглаживания. Обратите внимание, что сумма весов даже при небольшом значении $\alpha$ будет приближенно равна единице для любого разумного размера выборки.

| | $\alpha = 0.2$ | $\alpha = 0.4$ | $\alpha = 0.6$ | $\alpha = 0.8$ |
|---|---|---|---|---|
| $y_T$ | 0.2000 | 0.4000 | 0.6000 | 0.8000 |
| $y_{T-1}$ | 0.1600 | 0.2400 | 0.2400 | 0.1600 |
| $y_{T-2}$ | 0.1280 | 0.1440 | 0.0960 | 0.0320 |
| $y_{T-3}$ | 0.1024 | 0.0864 | 0.0384 | 0.0064 |
| $y_{T-4}$ | 0.0819 | 0.0518 | 0.0154 | 0.0013 |
| $y_{T-5}$ | 0.0655 | 0.0311 | 0.0061 | 0.0003 |

Для любого $\alpha$ между 0 и 1 привязанные к наблюдениям веса экспоненциально уменьшаются, по мере того как мы возвращаемся назад во времени, отсюда и название «экспоненциальное сглаживание». Если $\alpha$ мал (т. е. близок к 0), то больший вес придается наблюдениям из более отдаленного прошлого. Если $\alpha$ – большой (т. е. близок к 1), то больший вес придается более поздним наблюдениям. Для крайнего случая, когда $\alpha = 1$, $\hat{y}_{T+h|T} = y_T$, и прогнозы равны наивным прогнозам.

Мы представляем две эквивалентные формы простого экспоненциального сглаживания, каждая из которых приводит к уравнению прогноза (8.1).

## Средневзвешенная форма

Прогноз на момент времени $T + 1$ равен средневзвешенному значению между самыми последними наблюдениями $\hat{y}$ и предыдущим прогнозом $\hat{y}_{T|T-1}$:

$$\hat{y}_{T+1|T} = \alpha y_T + (1-\alpha)\hat{y}_{T|T-1},$$

где $0 \le \alpha \le 1$ – это параметр сглаживания. Подогнанные значения можно записать аналогичным образом как

$$\hat{y}_{t+1|t} = \alpha y_t + (1-\alpha)\hat{y}_{t|t-1}$$

для $t = 1, \ldots T$. (Напомним, что подогнанные значения – это просто прогнозы на данных одношаговой тренировки.)

Процесс должен где-то начинаться, поэтому мы даем первому подогнанному значению на момент времени 1 обозначение $l_0$ (которое мы должны будем оценить). Тогда

$$\begin{aligned}
\hat{y}_{2|1} &= \alpha y_1 + (1-\alpha)\ell_0 \\
\hat{y}_{3|2} &= \alpha y_2 + (1-\alpha)\hat{y}_{2|1} \\
\hat{y}_{4|3} &= \alpha y_3 + (1-\alpha)\hat{y}_{3|2} \\
&\vdots \\
\hat{y}_{T|T-1} &= \alpha y_{T-1} + (1-\alpha)\hat{y}_{T-1|T-2} \\
\hat{y}_{T+1|T} &= \alpha y_T + (1-\alpha)\hat{y}_{T|T-1}.
\end{aligned}$$

Подставив каждое уравнение в следующее уравнение, мы получаем:

$$\begin{aligned}
\hat{y}_{3|2} &= \alpha y_2 + (1-\alpha)\left[\alpha y_1 + (1-\alpha)\ell_0\right] \\
&= \alpha y_2 + \alpha(1-\alpha)y_1 + (1-\alpha)^2\ell_0 \\
\hat{y}_{4|3} &= \alpha y_3 + (1-\alpha)\left[\alpha y_2 + \alpha(1-\alpha)y_1 + (1-\alpha)^2\ell_0\right] \\
&= \alpha y_3 + \alpha(1-\alpha)y_2 + \alpha(1-\alpha)^2 y_1 + (1-\alpha)^3\ell_0 \\
&\vdots \\
\hat{y}_{T+1|T} &= \sum_{j=0}^{T-1}\alpha(1-\alpha)^j y_{T-j} + (1-\alpha)^T\ell_0.
\end{aligned}$$

Последний член становится крошечным для крупных $T$. Таким образом, средневзвешенная форма приводит к тому же самому уравнению прогноза (8.1).

## Компонентная форма

Альтернативным представлением является компонентная форма. В случае простого экспоненциального сглаживания единственной включенной компонентой является уровень, $l_t$. (Другие методы, которые рассматриваются далее в этой главе, могут также включать трендовую $b_t$ и сезонную $s_t$ компоненты.) Представления компонентной формы методов экспоненциального сглаживания содержат уравнение прогноза и уравнение сглаживания для каждой из компонент, включенных в метод. Компонентная форма простого экспоненциального сглаживания задается формулами:

$$\text{уравнение прогноза} \quad \hat{y}_{t+h|t} = \ell_t,$$
$$\text{уравнение сглаживания} \quad \ell_t = \alpha y_t + (1-\alpha)\ell_{t-1},$$

где $l_t$ – это уровень (или сглаженное значение) ряда на момент времени $t$. Установление $h = 1$ дает подогнанные значения, в то время как установление $t = T$ дает истинные прогнозы, выходящие за рамки тренировочных данных.

Уравнение прогноза показывает, что прогнозное значение на момент времени $t + 1$ – это оценочный уровень на момент времени $t$. Уравнение сглаживания для уровня (обычно именуемое уравнением уровня) дает оценочный уровень ряда в каждый период $t$.

Если в уравнении сглаживания заменить $l_t$ на $\hat{y}_{t+1|t}$, а $l_{t-1}$ на $\hat{y}_{t|t-1}$, то мы восстановим средневзвешенную форму простого экспоненциального сглаживания.

Компонентная форма простого экспоненциального сглаживания сама по себе не особенно полезна, но это будет самая простая в использовании форма, когда мы начнем добавлять другие компоненты.

## Плоские прогнозы

Простое экспоненциальное сглаживание имеет функцию «плоского» прогноза:

$$\hat{y}_{T+h|T} = \hat{y}_{T+1|T} = \ell_T, \qquad h = 2,\ 3,\ \ldots.$$

То есть все прогнозы принимают одинаковое значение, равное компоненте последнего уровня. Помните, что эти прогнозы будут пригодны только в том случае, если временной ряд не имеет трендовой либо сезонной компоненты.

## Оптимизация

Применение каждого метода экспоненциального сглаживания требует выбора параметров сглаживания и начальных значений. В частности, для простого экспоненциального сглаживания необходимо выбрать значения $\alpha$ и $l_0$. Все прогнозы могут быть вычислены из данных, как только мы узнаем эти значения. Для следующих ниже методов обычно требуется выбрать более одного параметра сглаживания и более одной начальной компоненты.

В некоторых случаях параметры сглаживания могут выбираться в субъективной манере – прогнозист формулирует значение параметров сглаживания на основе предыдущего опыта. Однако более надежным и объективным способом получения значений неизвестных параметров является их оценивание из наблюдаемых данных.

В разделе 7.2 мы оценили коэффициенты регрессионной модели путем минимизирования суммы квадратов остатков (обычно именуемых SSE, от англ. sum of squared errors, т. е. «сумма квадратов ошибок»). Аналогичным образом неизвестные параметры и начальные значения для любого метода экспоненциального сглаживания могут быть оценены путем минимизирования SSE.

Остатки формулируются как $e_t = y_t - \hat{y}_{t|t-1}$ для $t = 1, \dots, T$. Следовательно, мы находим значения неизвестных параметров и начальные значения, которые минимизируют

$$\text{SSE} = \sum_{t=1}^{T}(y_t - \hat{y}_{t|t-1})^2 = \sum_{t=1}^{T} e_t^2. \tag{8.2}$$

В отличие от регрессионного случая (где у нас есть формулы, которые возвращают значения регрессионных коэффициентов, которые минимизируют SSE), это предусматривает нелинейную задачу минимизации, и для ее решения необходимо использовать инструмент оптимизации.

## Пример: экспорт из Алжира

В данном примере простое экспоненциальное сглаживание применяется для прогнозирования экспорта товаров и услуг из Алжира.

```
# Оценить параметры
fit <- algeria_economy %>%
  model(ETS(Exports ~ error("A") + trend("N") + season("N")))
fc <- fit %>%
  forecast(h = 5)
```

Оно дает оценки параметров $\hat{\alpha} = 0.84$ и $\hat{l}_0 = 39.5$, полученные путем минимизирования SSE за периоды $t = 1, 2, \dots, 58$ с учетом ограничения $0 \leqslant \alpha \leqslant 1$.

В табл. 8.1 мы демонстрируем расчет с использованием указанных выше параметров. Предпоследний столбец показывает оценочный уровень для периодов с $t = 0$ по $t = 58$; последние несколько строк последнего столбца показывают прогнозы на $h = 1$ до 5 шагов вперед.

**Таблица 8.1:** Прогнозирование экспорта товаров и услуг из Алжира с использованием простого экспоненциального сглаживания

| Год | Время | Наблюдение | Уровень | Прогноз |
|---|---|---|---|---|
| | $t$ | $y_t$ | $l_t$ | $\hat{y}_{t\|t-1}$ |
| 1959 | 0 | | 39.54 | |
| 1960 | 1 | 39.04 | 39.12 | 39.54 |
| 1961 | 2 | 46.24 | 45.10 | 39.12 |
| 1962 | 3 | 19.79 | 23.84 | 45.10 |
| 1963 | 4 | 24.68 | 24.55 | 23.84 |
| 1964 | 5 | 25.08 | 25.00 | 24.55 |
| 1965 | 6 | 22.60 | 22.99 | 25.00 |
| 1966 | 7 | 25.99 | 25.51 | 22.99 |
| 1967 | 8 | 23.43 | 23.77 | 25.51 |
| | ⋮ | ⋮ | ⋮ | ⋮ |
| 2014 | 55 | 30.22 | 30.80 | 33.85 |
| 2015 | 56 | 23.17 | 24.39 | 30.80 |
| 2016 | 57 | 20.86 | 21.43 | 24.39 |
| 2017 | 58 | 22.64 | 22.44 | 21.43 |
| | $h$ | | | $\hat{y}_{T+h\|T}$ |
| 2018 | 1 | | | 22.44 |
| 2019 | 2 | | | 22.44 |
| 2020 | 3 | | | 22.44 |
| 2021 | 4 | | | 22.44 |
| 2022 | 5 | | | 22.44 |

Черная линия на рис. 8.2 показывает данные, уровень которых меняется с течением времени.

```
fc %>%
  autoplot(algeria_economy) +
  geom_line(aes(y = .fitted), col="#D55E00",
            data = augment(fit)) +
  labs(y="% ВВП", title="Экспорт: Алжир") +
  guides(colour = "none")
```

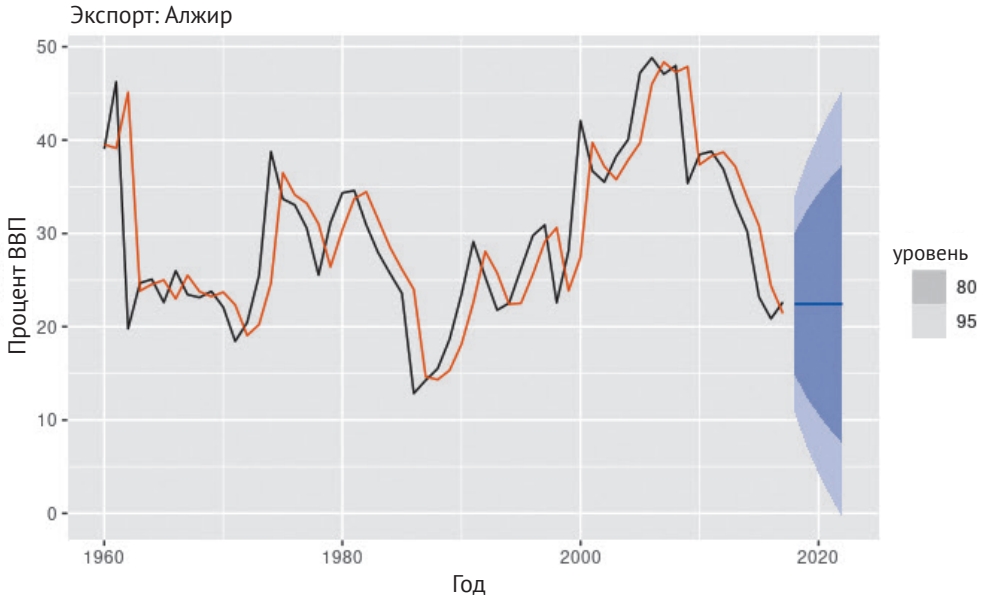


**Рисунок 8.2:** Простое экспоненциальное сглаживание применительно к экспорту из Алжира (1960–2017 гг.). Оранжевая кривая показывает значения, подогнанные с опережением на один шаг

Прогнозы на период 2018–2022 годов представлены на рис. 8.2. Также на графике представлены одношаговые подогнанные значения наряду с данными за период 1960–2017 годов. Крупное значение $\alpha$ в этом примере отражается в крупной корректировке, которая происходит на оценочном уровне $l_t$ в каждый момент времени. Меньшее значение $\alpha$ будет приводить к меньшим изменениям с течением времени, и поэтому ряд подогнанных значений будет более плавным.

Показанные здесь предсказательные интервалы рассчитаны с использованием методов, описанных в разделе 8.7. Предсказательные интервалы показывают, что существует значительная неопределенность в отношении будущего экспорта в течение пятилетнего прогнозного периода. Поэтому интерпретация точечных прогнозов без учета большой неопределенности может дезориентировать.

# 8.2 Методы с трендом

## Метод линейного тренда Хольта

Хольт (1957, *https://otexts.com/fpp3/holt.html#ref-Holt57*) расширил простое экспоненциальное сглаживание, чтобы дать возможность прогнозировать данные с трендом. Этот метод предусматривает уравнение прогноза и два уравнения сглаживания (одно для уровня и одно для тренда):

$$\text{уравнение прогноза} \quad \hat{y}_{t+h|t} = \ell_t + hb_t,$$
$$\text{уравнение уровня} \quad \ell_t = \alpha y_t + (1-\alpha)(\ell_{t-1} + b_{t-1}),$$
$$\text{уравнение тренда} \quad b_t = \beta^*(\ell_t - \ell_{t-1}) + (1-\beta^*)b_{t-1},$$

где $l_t$ обозначает оценку уровня ряда на момент времени $t$, $b_t$ обозначает оценку тренда (наклона) ряда на момент времени $t$, $\alpha$ – параметр сглаживания для уровня, $0 \le \alpha \le 1$, и $\beta^*$ – параметр сглаживания для тренда, $0 \le \beta^* \le 1$. (Мы обозначаем его как $\beta^*$ вместо $\beta$ по причинам, которые будут объяснены в разделе 8.5.)

Как и в случае простого экспоненциального сглаживания, уравнение уровня здесь показывает, что $l_t$ – это средневзвешенное значение наблюдения $y_t$ и прогноз с тренировкой на один шаг вперед для момента времени $t$, здесь заданный выражением $l_{t-1} + b_{t-1}$. Уравнение тренда показывает, что $b_t$ – это средневзвешенное значение оценочного тренда на момент времени $t$ на основе $l_t - l_{t-1}$ и $b_{t-1}$, предыдущей оценки тренда.

Прогнозная функция больше не является плоской, а имеет тренд. Прогноз на $h$ шагов вперед равен последнему оценочному уровню плюс $h$, умноженное на последнее оценочное значение тренда. Следовательно, прогнозы являются линейной функцией от $h$.

## Пример: население Австралии

```
aus_economy <- global_economy %>%
  filter(Code == "AUS") %>%
  mutate(Pop = Population / 1e6)
autoplot(aus_economy, Pop) +
  labs(y = "Млн", title = "Численность населения Австралии")
```

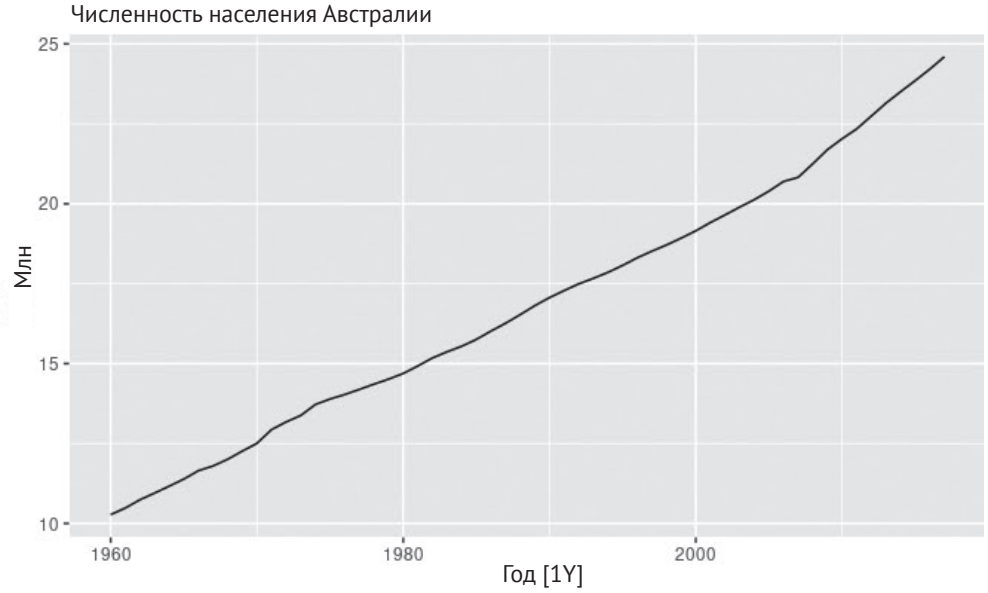


**Рисунок 8.3:** Численность населения Австралии, 1960–2017 годы

На рис. 8.3 показана ежегодная численность населения Австралии с 1960 по 2017 год. Мы применим метод Хольта к этому ряду. Параметры сглаживания, $\alpha$ и $\beta^*$, и начальные значения $l_0$ и $b_0$ оцениваются путем минимизирования SSE для одношаговых ошибок тренировки, как в разделе 8.1.

```
fit <- aus_economy %>%
  model(
    AAN = ETS(Pop ~ error("A") + trend("A") + season("N"))
  )
fc <- fit %>% forecast(h = 10)
```

Оценочный коэффициент сглаживания для уровня равен $\hat{\alpha} = 0.9999$. Очень высокое значение показывает, что уровень быстро меняется, чтобы уловить ряд с сильным трендом. Оценочный коэффициент сглаживания для наклона равен $\hat{\beta}^* = 0.3267$. Это относительно крупное значение, и оно свидетельствует о том, что тренд, кроме того, часто меняется (даже если изменения незначительны).

В табл. 8.2 мы используем эти значения, чтобы продемонстрировать применение метода Хольта.

**Таблица 8.2:** Прогнозирование годовой численности населения Австралии с использованием метода линейного тренда Хольта

| Год | Время | Наблюдение | Уровень | Наклон | Прогноз |
|---|---|---|---|---|---|
| | $t$ | $y_t$ | $l_t$ | | $\hat{y}_{t+1\|t}$ |
| 1959 | 0 | | 10.05 | 0.22 | |
| 1960 | 1 | 10.28 | 10.28 | 0.22 | 10.28 |
| 1961 | 2 | 10.48 | 10.48 | 0.22 | 10.50 |
| 1962 | 3 | 10.74 | 10.74 | 0.23 | 10.70 |
| 1963 | 4 | 10.95 | 10.95 | 0.22 | 10.97 |
| 1964 | 5 | 11.17 | 11.17 | 0.22 | 11.17 |
| 1965 | 6 | 11.39 | 11.39 | 0.22 | 11.39 |
| 1966 | 7 | 11.65 | 11.65 | 0.23 | 11.61 |
| | ⋮ | ⋮ | ⋮ | ⋮ | ⋮ |
| 2014 | 55 | 23.50 | 23.50 | 0.37 | 23.52 |
| 2015 | 56 | 23.85 | 23.85 | 0.36 | 23.87 |
| 2016 | 57 | 24.21 | 24.21 | 0.36 | 24.21 |
| 2017 | 58 | 24.60 | 24.60 | 0.37 | 24.57 |

| Год | Время | Наблюдение | Уровень | Наклон | Прогноз |
|---|---|---|---|---|---|
| | $h$ | | | | $\hat{y}_{T+h\|T}$ |
| 2018 | 1 | | | | 24.97 |
| 2019 | 2 | | | | 25.34 |
| 2020 | 3 | | | | 25.71 |
| 2021 | 4 | | | | 26.07 |
| 2022 | 5 | | | | 26.44 |
| 2023 | 6 | | | | 26.81 |
| 2024 | 7 | | | | 27.18 |
| 2025 | 8 | | | | 27.55 |
| 2026 | 9 | | | | 27.92 |
| 2027 | 10 | | | | 28.29 |

## Методы демпфируемого тренда

Прогнозы, сгенерированные линейным методом Хольта, отображают постоянный тренд (увеличивающийся либо уменьшающийся) без ограничения в будущем. Эмпирические данные указывают на то, что эти методы имеют тенденцию к завышению прогноза, в особенности для более длительных прогнозных горизонтов. Руководствуясь этим наблюдением, Гарднер и Маккензи (1985, *https://otexts.com/fpp3/holt.html#ref-GarMacK1985*) ввели параметр, который «гасит» тренд до плоской линии в некоторое время в будущем. Методы, включающие демпфируемый тренд, оказались очень успешными и, возможно, являются самыми популярными индивидуальными методами, когда требуются автоматические прогнозы для многочисленных рядов.

В сочетании с параметрами сглаживания $\alpha$ и $\beta^*$ (со значениями от 0 до 1, как в методе Хольта) указанный метод также включает параметр демпфирования $0 < \phi < 1$:

$$\begin{aligned}
\hat{y}_{t+h|t} &= \ell_t + \left(\phi + \phi^2 + \cdots + \phi^h\right) b_t, \\
\ell_t &= \alpha y_t + \left(1-\alpha\right)\left(\ell_{t-1} + \phi b_{t-1}\right), \\
b_t &= \beta^* \left(\ell_t - \ell_{t-1}\right) + \left(1-\beta^*\right)\phi b_{t-1}.
\end{aligned}$$

Если $\phi = 1$, то этот метод идентичен линейному методу Хольта. Для значений между 0 и 1 $\phi$ демпфирует тренд так, что он приближается к постоянному значению в будущем. На самом деле прогнозы сходятся к $l_t + \phi b_t/(1 - \phi)$, по мере того как $h \to \infty$, для любого значения $0 < \phi < 1$. Это означает, что краткосрочные прогнозы имеют тренд, в то время как долгосрочные прогнозы остаются постоянными.

На практике $\phi$ редко бывает меньше 0.8, поскольку демпфирование оказывает очень сильное влияние при меньших значениях. Значение $\phi$, близкое к 1, будет означать, что демпфирующую модель невозможно отличить от недемпфирующей модели. По этим причинам мы обычно ограничиваем $\phi$ минимальным значением 0.8 и максимальным значением 0.98.

## Пример: численность населения Австралии (продолжение)

На рис. 8.4 показаны прогнозы на 2018–2032 годы, сгенерированные с помощью метода линейного тренда Хольта и метода демпфируемого тренда.

```
aus_economy %>%
  model(
    `Holt's method` = ETS(Pop ~ error("A") +
                          trend("A") + season("N")),
    `Damped Holt's method` = ETS(Pop ~ error("A") +
                          trend("Ad", phi = 0.9) + season("N"))
  ) %>%
  forecast(h = 15) %>%
  autoplot(aus_economy, level = NULL) +
  labs(title = "Численность населения Австралии",
       y = "Млн") +
  guides(colour = guide_legend(title = "Прогноз"))
```

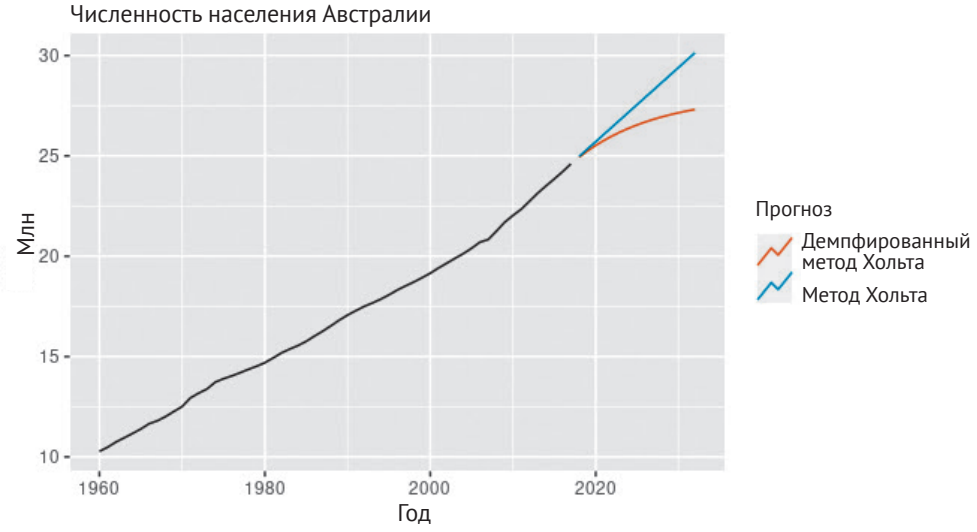


**Рисунок 8.4:** Прогноз ежегодного населения Австралии (в миллионах) на 2018–2032 годы. Для метода демпфируемого тренда, $\phi$ = 0.90

Мы установили параметр демпфирования равным относительно низкому значению ($\phi$ = 0.90), чтобы преувеличить эффект демпфирования для сравнения. Обычно мы оцениваем $\phi$ вместе с другими параметрами. Мы также использовали довольно большой прогнозный горизонт ($h$ = 15), чтобы подчеркнуть разницу между демпфируемым трендом и линейным трендом.

## Пример: используемость интернета

В этом примере мы сравниваем результативность трех методов экспоненциального сглаживания, которые рассмотрели до сих пор при прогнозировании числа пользователей, подключенных к интернету через сервер. Данные наблюдались в течение 100 минут и показаны на рис. 8.5.

```
www_usage <- as_tsibble(WWWusage)
www_usage %>% autoplot(value) +
  labs(x="Минута", y="Число пользователей",
       title = "Используемость интернета в минуту")
```

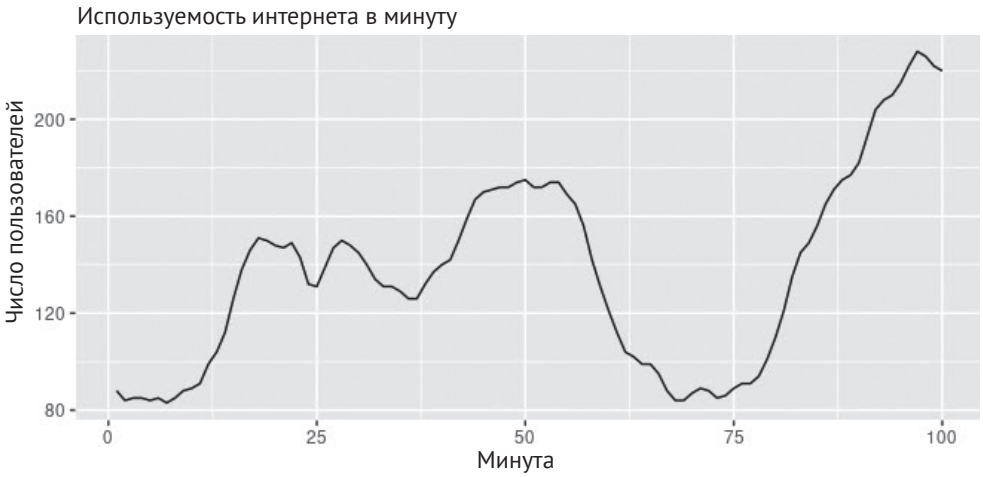


**Рисунок 8.5:** Пользователи, подключенные к интернету через сервер

Мы будем использовать перекрестную валидацию временного ряда для сравнения точности одношагового прогноза трех методов.

```
www_usage %>%
  stretch_tsibble(.init = 10) %>%
  model(
    SES = ETS(value ~ error("A") + trend("N") + season("N")),
    Holt = ETS(value ~ error("A") + trend("A") + season("N")),
    Damped = ETS(value ~ error("A") + trend("Ad") +
                   season("N"))
  ) %>%
  forecast(h = 1) %>%
  accuracy(www_usage)
#> # A tibble: 3 × 10
#>   .model .type     ME  RMSE   MAE   MPE  MAPE  MASE RMSSE  ACF1
#>   <chr>  <chr>  <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl>
#> 1 Damped Test  0.288   3.69  3.00 0.347  2.26 0.663 0.636 0.336
```

```
#> 2 Holt   Test  0.0610  3.87  3.17 0.244  2.38 0.701 0.668 0.296
#> 3 SES    Test  1.46    6.05  4.81 0.904  3.55 1.06  1.04  0.803
```

Демпфирующий метод Хольта проявляет себя лучше всего при сравнении значений MAE либо RMSE. И поэтому мы продолжим использовать демпфирующий метод Хольта и применим его ко всему набору данных, чтобы получить прогнозы на будущие минуты.

```
fit <- www_usage %>%
  model(
    Damped = ETS(value ~ error("A") + trend("Ad") +
                   season("N"))
  )
# Оцениваемые параметры:
tidy(fit)
#> # A tibble: 5 × 3
#>   .model term  estimate
#>   <chr>  <chr>    <dbl>
#> 1 Damped alpha   1.00
#> 2 Damped beta    0.997
#> 3 Damped phi     0.815
#> 4 Damped l[0]   90.4
#> 5 Damped b[0]   -0.0173
```

Параметр сглаживания для наклона оценивается равным почти единице, указывая на то, что тренд изменяется, чтобы в основном отражать наклон между последними двумя минутами используемости интернета. Значение $x$ находится очень близко к единице, показывая, что уровень сильно реагирует на каждое новое наблюдение.

```
fit %>%
  forecast(h = 10) %>%
  autoplot(www_usage) +
  labs(x="Минута", y="Число пользователей",
       title = "Используемость интернета в минуту")
```

**Рисунок 8.6:** Прогнозирование используемости интернета: сравнение результативности несезонных методов прогнозирования

Результирующие прогнозы выглядят разумными с уменьшающимся трендом, который сглаживается из-за низкого значения параметра демпфирования (0.815), и относительно широкими предсказательными интервалами, отражающими изменение исторических данных. Предсказательные интервалы рассчитываются с использованием методов, описанных в разделе 8.7.

В этом примере процесс выбора метода был относительно простым, поскольку сравнения с MSE и MAE предполагали один и тот же метод (демпфирующий метод Хольта). Однако иногда разные показатели точности предполагают разные методы прогнозирования, и тогда требуется решение о том, какой метод прогнозирования мы предпочитаем использовать. Поскольку задачи прогнозирования могут различаться по многим параметрам (длине прогнозного горизонта, размеру тестового набора, мерам прогнозных ошибок, частоте данных и т. д.), маловероятно, что один метод будет лучше всех других для всех сценариев прогнозирования. Что нам требуется от метода прогнозирования, так это стабильно разумные прогнозы, и их следует часто оценивать в соответствии с поставленной задачей.

## Библиография

*Гарднер, Э. С. и Маккензи, Э.* (1985). Прогнозирование трендов во временных рядах. Management Science, 31 (10), 1237–1246. [DOI: https://doi.org/10.1287/mnsc.31.10.1237].

*Хольт, К. С.* (1957). Прогнозирование сезонных колебаний и трендов с помощью экспоненциально взвешенных средних (ONR Memorandum No. 52). Технологический институт Карнеги, Питтсбург, США. Перепечатано в International Journal of Forecasting, 2004 год. [DOI: https://doi.org/10.1016/j.ijforecast.2003.09.015].

## 8.3 Методы с сезонностью

Хольт (1957, *https://otexts.com/fpp3/holt-winters.html#ref-Holt57*) и Винтерс (1960, *https://otexts.com/fpp3/holt-winters.html#ref-Winters60*) расширили метод Хольта с целью улавливания сезонности. Сезонный метод Хольта–Винтерса включает уравнение прогноза и три уравнения сглаживания: одно для уровня $l_t$, одно для тренда $b_t$ и одно для сезонной компоненты $s_t$ с соответствующими параметрами сглаживания $\alpha$, $\beta^*$ и $\gamma$. Мы используем $m$ для обозначения периода сезонности, т. е. числа сезонов в году. Например, для квартальных данных $m = 4$, а для месячных данных $m = 12$.

Существует два варианта этого метода, которые различаются по характеру сезонной компоненты. Аддитивный метод предпочтителен, когда сезонные вариации примерно постоянны на протяжении ряда, в то время как мультипликативный метод предпочтителен, когда сезонные вариации изменяются пропорционально уровню ряда. В случае аддитивного метода сезонная компонента выражается в абсолютных величинах в шкале наблюдаемого ряда, а в уравнении уровня ряд корректируется с учетом сезонных вариаций путем вычитания сезонной компоненты. В течение каждого года сезонная компонента будет в сумме приближенно равняться нулю. В случае мультипликативного метода сезонная компонента выражается в относительных терминах (процентах), а ряд сезонно корректируется путем деления на сезонную компоненту. В течение каждого года сезонная компонента будет составлять примерно $m$.

### Аддитивный метод Хольта–Винтерса

Компонентная форма для аддитивного метода такова:

$$\begin{aligned}
\hat{y}_{t+h|t} &== \ell_t + hb_t + s_{t+h-m(k+1)},\\
\ell_t &= \alpha\left(y_t - s_{t-m}\right) + \left(1-\alpha\right)\left(\ell_{t-1} + b_{t-1}\right),\\
b_t &= \beta^*\left(\ell_t - \ell_{t-1}\right) + \left(1-\beta^*\right)b_{t-1},\\
s_t &== \gamma\left(y_t - \ell_{t-1} - b_{t-1}\right) + \left(1-\gamma\right)s_{t-m},
\end{aligned}$$

где $k$ – это целочисленная часть $(h-1)/m$, которая обеспечивает, чтобы оценки сезонных индексов, используемых для прогнозирования, брались из последнего года выборки. Уравнение уровня показывает средневзвешенное значение между сезонно скорректированным наблюдением $(y_t - s_{t-m})$ и несезонным прогнозом $(l_{t-1} - b_{t-1})$ для момента времени $t$. Уравнение тренда идентично линейному методу Хольта. Сезонное уравнение показывает средневзвешенное значение между текущим сезонным индексом, $(y_t - l_{k-1} - b_{t-1})$ и сезонным индексом того же сезона прошлого года (т. е. $m$ периодов времени назад).

Уравнение для сезонной компоненты часто выражается как

$$s_t = \gamma^*\left(y_t - \ell_t\right) + \left(1-\gamma^*\right)s_{t-m}.$$

Если вместо $l_t$ из уравнения сглаживания подставить приведенный выше уровень компонентной формы, то мы получим

$$s_t = \gamma^*(1-\alpha)(y_t - \ell_{t-1} - b_{t-1}) + \left[1 - \gamma^*(1-\alpha)\right] s_{t-m},$$

которое идентично уравнению сглаживания для сезонной компоненты, которую мы формулируем здесь, $\gamma = \gamma^*(1 - \alpha)$. Обычным параметрическим ограничением является $0 \le \gamma^* \le 1$, которое транслируется в $0 \le \gamma \le 1 - \alpha$.

## Мультипликативный метод Хольта–Винтерса

Компонентная форма для мультипликативного метода такова:

$$\hat{y}_{t+h|t} = (\ell_t + hb_t) s_{t+h-m(k+1)},$$

$$\ell_t = \alpha \frac{y_t}{s_{t-m}} + (1-\alpha)(\ell_{t-1} + b_{t-1}),$$

$$b_t = \beta^*(\ell_t - \ell_{t-1}) + (1-\beta^*) b_{t-1},$$

$$s_t = \gamma \frac{y_t}{(\ell_{t-1} + b_{t-1})} + (1-\gamma) s_{t-m}.$$

## Пример: внутренние поездки с ночевкой в Австралии

Мы применяем метод Хольта–Винтерса как с аддитивной, так и с мультипликативной сезонностью[1] для прогнозирования ежеквартальных гостевых ночей внутренних туристов в Австралии. На рис. 8.7 показаны данные за 1998–2017 годы и прогнозы на 2018–2020 годы. Данные показывают очевидную сезонную закономерность: пики наблюдаются в мартовском квартале каждого года, что соответствует австралийскому лету.

```
aus_holidays <- tourism %>%
  filter(Purpose == "Holiday") %>%
  summarise(Trips = sum(Trips)/1e3)
fit <- aus_holidays %>%
  model(
    additive = ETS(Trips ~ error("A") + trend("A") +
                                                season("A")),
    multiplicative = ETS(Trips ~ error("M") + trend("A") +
                                                season("M"))
  )
fc <- fit %>% forecast(h = "3 years")
fc %>%
  autoplot(aus_holidays, level = NULL) +
```

[1] В нашей имплементации используется оценивание максимального правдоподобия, как описано в разделе 8.6, в то время как Хольт и Винтерс изначально минимизировали сумму квадратов ошибок. В случае мультипликативной сезонности это будет приводить к несколько иным оценкам параметров. Оптимизацию суммы квадратов ошибок можно получить, задав аргумент `opt_crit="mse"` в функции `ETS()`.

```
labs(title="Внутренний туризм в Австралии",
     y="Поездки с ночевкой (млн)") +
guides(colour = guide_legend(title = "Прогноз"))
```

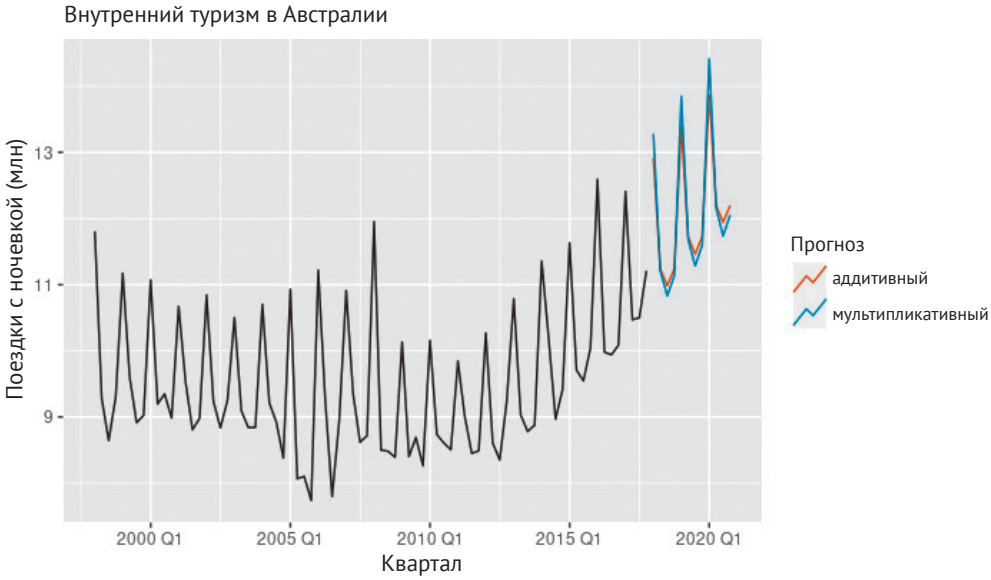


**Рисунок 8.7:** Прогнозирование внутренних поездок с ночевкой в Австралии с помощью метода Хольта–Винтерса как с аддитивной, так и с мультипликативной сезонностью

**Таблица 8.3:** Применение метода Хольта–Винтерса с добавлением сезонности с целью прогнозирования внутреннего туризма в Австралии. Обратите внимание, что аддитивная сезонная компонента в сумме приближенно равна нулю. Параметры сглаживания таковы: $\alpha = 0.2620$, $\beta^* = 0.1646$, $\gamma = 0.0001$, а $RMSE = 0.4169$

| Квартал | Время | Наблюдение | Уровень | Наклон | Сезон | Прогноз |
|---|---|---|---|---|---|---|
| | $t$ | $y_t$ | $l_t$ | $b_t$ | $s_t$ | $\hat{y}_{t+1\|t}$ |
| 1997 Q1 | 0 | | | | 1.5 | |
| 1997 Q2 | 1 | | | | −0.3 | |
| 1997 Q3 | 2 | | | | −0.7 | |
| 1997 Q4 | 3 | | 9.8 | 0.0 | −0.5 | |
| 1998 Q1 | 4 | 11.8 | 9.9 | 0.0 | 1.5 | 11.3 |
| 1998 Q2 | 5 | 9.3 | 9.9 | 0.0 | −0.3 | 9.7 |
| 1998 Q3 | 6 | 8.6 | 9.7 | -0.0 | −0.7 | 9.2 |
| 1998 Q4 | 7 | 9.3 | 9.8 | 0.0 | −0.5 | 9.2 |
| | ⋮ | ⋮ | ⋮ | ⋮ | ⋮ | ⋮ |

| Квартал | Время | Наблюдение | Уровень | Наклон | Сезон | Прогноз |
|---|---|---|---|---|---|---|
| 2017 Q1 | 80 | 12.4 | 10.9 | 0.1 | 1.5 | 12.3 |
| 2017 Q2 | 81 | 10.5 | 10.9 | 0.1 | −0.3 | 10.7 |
| 2017 Q3 | 82 | 10.5 | 11.0 | 0.1 | −0.7 | 10.3 |
| 2017 Q4 | 83 | 11.2 | 11.3 | 0.1 | −0.5 | 10.6 |
| | $h$ | | | | | $\hat{y}_{T+h\|T}$ |
| 2018 Q1 | 1 | | | | | 12.9 |
| 2018 Q2 | 2 | | | | | 11.2 |
| 2018 Q3 | 3 | | | | | 11.0 |
| 2018 Q4 | 4 | | | | | 11.2 |
| 2019 Q1 | 5 | | | | | 13.4 |
| 2019 Q2 | 6 | | | | | 11.7 |
| 2019 Q3 | 7 | | | | | 11.5 |
| 2019 Q4 | 8 | | | | | 11.7 |
| 2020 Q1 | 9 | | | | | 13.9 |
| 2020 Q2 | 10 | | | | | 12.2 |
| 2020 Q3 | 11 | | | | | 11.9 |
| 2020 Q4 | 12 | | | | | 12.2 |

**Таблица 8.4:** Применение метода Хольта–Винтерса с мультипликативной сезонностью с целью прогнозирования внутреннего туризма в Австралии. Обратите внимание, что мультипликативная сезонная составляющая равна приблизительно $m = 4$. Параметры сглаживания таковы: $\alpha = 0.2237$, $\beta^* = 0.1360$, $\gamma = 0.0001$, а $RMSE = 0.4122$

| Квартал | Время | Наблюдение | Уровень | Наклон | Сезон | Прогноз |
|---|---|---|---|---|---|---|
| | $t$ | $y_t$ | $l_t$ | $b_t$ | $s_t$ | $\hat{y}_{t+1\|t}$ |
| 1997 Q1 | 0 | | | | 1.2 | |
| 1997 Q2 | 1 | | | | 1.0 | |
| 1997 Q3 | 2 | | | | 0.9 | |
| 1997 Q4 | 3 | | 10.0 | −0.0 | 0.9 | |
| 1998 Q1 | 4 | 11.8 | 10.0 | −0.0 | 1.2 | 11.6 |
| 1998 Q2 | 5 | 9.3 | 9.9 | −0.0 | 1.0 | 9.7 |

| Квартал | Время | Наблюдение | Уровень | Наклон | Сезон | Прогноз |
|---|---|---|---|---|---|---|
| 1998 Q3 | 6 | 8.6 | 9.8 | −0.0 | 0.9 | 9.2 |
| 1998 Q4 | 7 | 9.3 | 9.8 | −0.0 | 0.9 | 9.2 |
| | ⋮ | ⋮ | ⋮ | ⋮ | ⋮ | ⋮ |
| 2017 Q1 | 80 | 12.4 | 10.8 | 0.1 | 1.2 | 12.6 |
| 2017 Q2 | 81 | 10.5 | 10.9 | 0.1 | 1.0 | 10.6 |
| 2017 Q3 | 82 | 10.5 | 11.1 | 0.1 | 0.9 | 10.2 |
| 2017 Q4 | 83 | 11.2 | 11.3 | 0.1 | 0.9 | 10.5 |
| | $h$ | | | | | $\hat{y}_{T+h\|T}$ |
| 2018 Q1 | 1 | | | | | 13.3 |
| 2018 Q2 | 2 | | | | | 11.2 |
| 2018 Q3 | 3 | | | | | 10.8 |
| 2018 Q4 | 4 | | | | | 11.1 |
| 2019 Q1 | 5 | | | | | 13.8 |
| 2019 Q2 | 6 | | | | | 11.7 |
| 2019 Q3 | 7 | | | | | 11.3 |
| 2019 Q4 | 8 | | | | | 11.6 |
| 2020 Q1 | 9 | | | | | 14.4 |
| 2020 Q2 | 10 | | | | | 12.2 |
| 2020 Q3 | 11 | | | | | 11.7 |
| 2020 Q4 | 12 | | | | | 12.1 |

Применение обоих методов (с аддитивной и мультипликативной сезонностями) представлено соответственно в табл. 8.3 и 8.4. Поскольку оба метода имеют точно такое же число оцениваемых параметров, мы можем сравнить тренировочную меру RMSE из обеих моделей. В этом случае метод с мультипликативной сезонностью вписывается в данные немного лучше.

Оценочные компоненты обеих моделей показаны на рис. 8.8. Небольшое значение $\gamma$ для мультипликативной модели означает, что сезонная компонента практически не меняется с течением времени. Малое значение $\beta^*$ означает, что компонента наклона практически не меняется с течением времени (сравните вертикальные шкалы компонентов наклона и уровня).

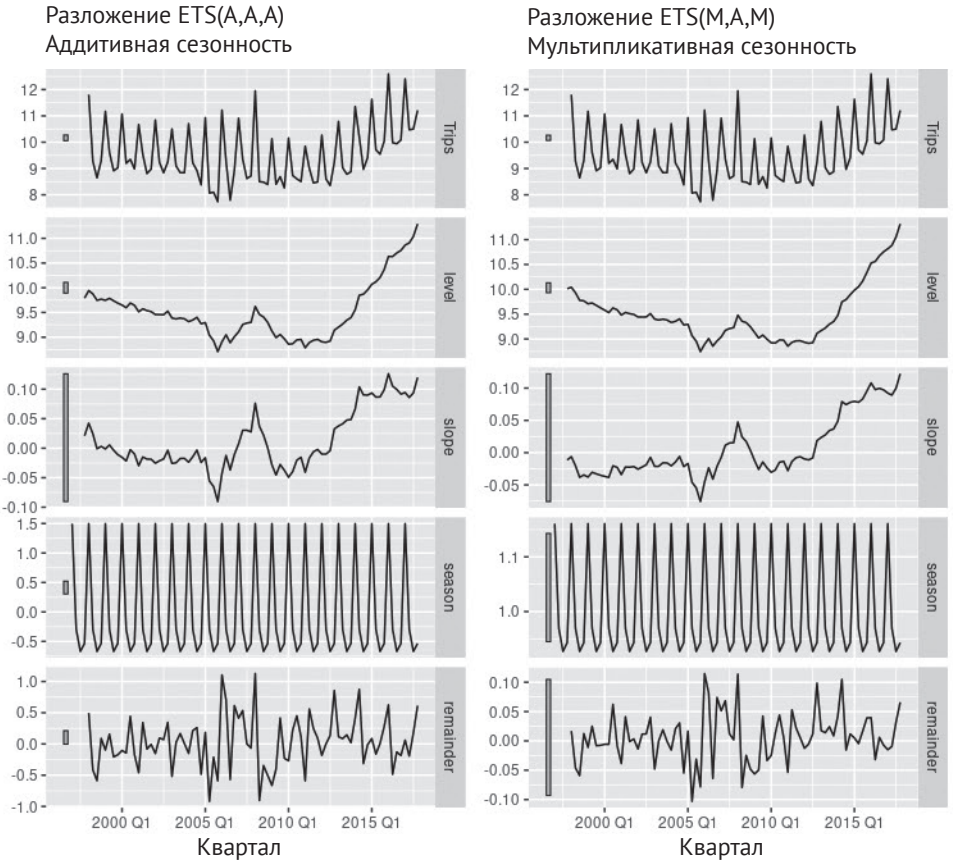


**Рисунок 8.8:** Оценочные компоненты метода Хольта–Винтерса с аддитивными и мультипликативными сезонными компонентами

## Демпфирующий метод Хольта–Винтерса

Демпфирование может использоваться как с аддитивным, так и мультипликативным методами Хольта–Винтерса. Методом, который часто обеспечивает точные и надежные прогнозы для сезонных данных, является метод Хольта–Винтерса с демпфируемым трендом и мультипликативной сезонностью:

$$\hat{y}_{t+h|t} = \left[\ell_t + \left(\phi + \phi^2 + \cdots + \phi^h\right) b_t\right] s_{t+h-m(k+1)},$$

$$\ell_t == \alpha\left(y_t / s_{t-m}\right) + \left(1-\alpha\right)\left(\ell_{t-1} + \phi b_{t-1}\right),$$

$$b_t = \beta^*\left(\ell_t - \ell_{t-1}\right) + \left(1-\beta^*\right)\phi b_{t-1},$$

$$s_t = \gamma \frac{y_t}{\left(\ell_{t-1} + \phi b_{t-1}\right)} + \left(1-\gamma\right) s_{t-m}.$$

## Пример: метод Хольта–Винтерса с ежедневными данными

Метод Хольта–Винтерса также может использоваться для данных ежедневного типа, где сезонный период равен $m = 7$, а соответствующая единица времени для $h$ измеряется в днях. Ниже мы прогнозируем пешеходное движение на оживленном железнодорожном вокзале Мельбурна в июле 2016 года.

```
sth_cross_ped <- pedestrian %>%
  filter(Date >= "2016-07-01",
         Sensor == "Southern Cross Station") %>%
  index_by(Date) %>%
  summarise(Count = sum(Count)/1000)
sth_cross_ped %>%
  filter(Date <= "2016-07-31") %>%
  model(
    hw = ETS(Count ~ error("M") + trend("Ad") + season("M"))
  ) %>%
  forecast(h = "2 weeks") %>%
  autoplot(sth_cross_ped %>% filter(Date <= "2016-08-14")) +
  labs(title = "Ежедневная проходимость: Сазерн Кросс",
       y="Пешеходы (тыс.)")
```

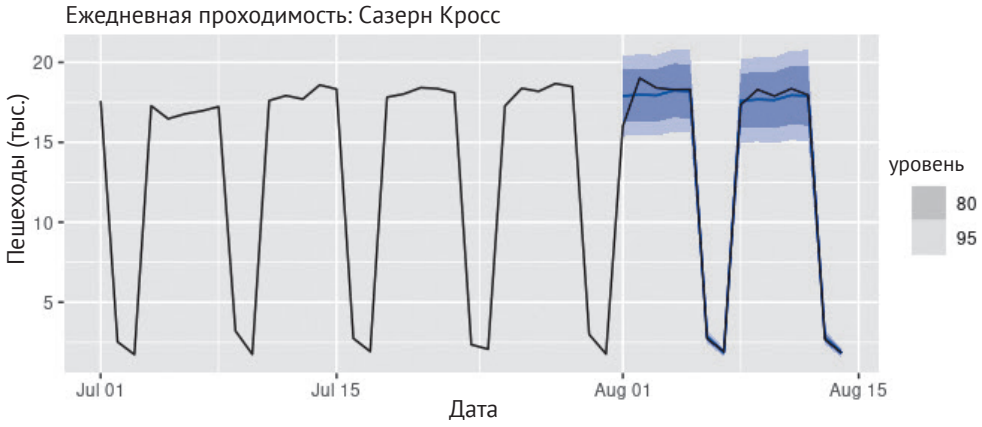


**Рисунок 8.9:** Прогнозы ежедневного пешеходного движения на железнодорожной станции Сазерн Кросс, Мельбурн

Очевидно, что модель определила недельную сезонную закономерность и тренд к увеличению в конце данных, и прогнозы близко соответствуют тестовым данным.

## Библиография

*Хольт, К. С.* (1957). Прогнозирование сезонных колебаний и трендов с помощью экспоненциально взвешенных средних (ONR Memorandum No. 52). Технологический институт Карнеги, Питтсбург, США. Перепечатано в International Journal of Forecasting, 2004 год. [DOI: https://doi.org/10.1016/j.ijforecast.2003.09.015].

*Винтерс, П. Р.* (1960). Прогнозирование продаж с помощью экспоненциально взвешенных скользящих средних. Management Science, 6 (3), 324–342. [DOI: https://doi.org/10.1287/mnsc.6.3.324].

## 8.4 Таксономия методов экспоненциального сглаживания

Методы экспоненциального сглаживания не ограничиваются теми, которые мы представили до сих пор. С учетом вариаций в комбинациях трендовой и сезонной компонент возможны девять методов экспоненциального сглаживания, перечисленных в табл. 8.5. Каждый метод обозначен парой букв (T, S), определяющих тип компонент: «трендовая» и «сезонная». Например, (A,M) – это метод с аддитивным трендом и мультипликативной сезонностью, ($A_d$,N) – это метод с демпфируемым трендом и отсутствием сезонности и т. д.

**Таблица 8.5:** Двухпутная классификация методов экспоненциального сглаживания

| Трендовая компонента | Сезонная компонента | | |
|---|---|---|---|
| | N | A | M |
| | (Ничего) | (Аддитивная) | (Мультипликативная) |
| **N (Ничего)** | (N,N) | (N,A) | (N,M) |
| **A (Аддитивная)** | (A,N) | (A,A) | (A,M) |
| **$A_d$ (Аддитивная демпфируемая)** | ($A_d$,N) | ($A_d$,A) | ($A_d$,M) |

Для некоторых из этих методов, которые мы уже встречали, используются другие названия:

| Сокращение | Метод |
|---|---|
| (N,N) | Простое экспоненциальное сглаживание |
| (A, N) | Линейный метод Хольта |
| ($A_d$,N) | Аддитивный демпфирующий метод тренда |
| (A, A) | Аддитивный метод Хольта–Винтерса |
| (A, M) | Мультипликативный метод Хольта–Винтерса |
| ($A_d$,M) | Демпфирующий метод Хольта–Винтерса |

Этот тип классификации был впервые предложен Пегелсом (1969, *https://otexts.com/fpp3/taxonomy.html#ref-Pegels1969*), который также включил метод с мультипликативным трендом. Позже указанная классификация была расширена Гарднером (1985, *https://otexts.com/fpp3/taxonomy.html#ref-Gar1985*), чтобы включить методы с аддитивным демпфируемым трендом, и Дж. У. Тейлором (2003, *https://otexts.com/fpp3/taxonomy.html#ref-Taylor2003*), чтобы включить методы с мультипликативным демпфируемым трендом. В этой книге мы не рассматриваем методы мультипликативного тренда, поскольку они, как прави-

ло, дают плохие прогнозы. См. Хайндман и соавт. (2008, *https://otexts.com/fpp3/taxonomy.html#ref-expsmooth08*), где приводится более подробное изложение всех методов экспоненциального сглаживания.

В табл. 8.6 приведены рекурсивные формулы для применения девяти методов экспоненциального сглаживания из табл. 8.5. Каждая ячейка содержит прогнозное уравнение для генерирования прогнозов на $h$ шагов вперед и уравнения сглаживания для применения метода.

**Таблица 8.6:** Формулы для рекурсивных вычислений и точечных прогнозов. В каждом случае $l_t$ обозначает уровень ряда на момент времени $t$, $b_t$ обозначает наклон на момент времени $t$, $s_t$ обозначает сезонную компоненту ряда на момент времени $t$, и $m$ обозначает число сезонов в году; $\alpha$, $\beta^*$, $\gamma$ и $\phi$ – это параметры сглаживания, $\phi_h = \phi + \phi^2 + \ldots + \phi^h$, и $k$ – целочисленная часть $(h-1)/m$.

| Тренд | Сезонная компонента | | |
|---|---|---|---|
| | **N** | **A** | **M** |
| **N** | $\hat{y}_{t+h\|t} = \ell_t$<br>$\ell_t = \alpha y_t + (1-\alpha)\ell_{t-1}$ | $\hat{y}_{t+h\|t} = \ell_t + s_{t+h-m(k+1)}$<br>$\ell_t = \alpha(y_t - s_{t-m}) + (1-\alpha)\ell_{t-1}$<br>$s_t = \gamma(y_t - \ell_{t-1}) + (1-\gamma)s_{t-m}$ | $\hat{y}_{t+h\|t} = \ell_t s_{t+h-m(k+1)}$<br>$\ell_t = \alpha(y_t/s_{t-m}) + (1-\alpha)\ell_{t-1}$<br>$s_t = \gamma(y_t/\ell_{t-1}) + (1-\gamma)s_{t-m}$ |
| **A** | $\hat{y}_{t+h\|t} = \ell_t + hb_t$<br>$\ell_t = \alpha y_t + (1-\alpha)(\ell_{t-1} + b_{t-1})$<br>$b_t = \beta^*(\ell_t - \ell_{t-1}) + (1-\beta^*)b_{t-1}$ | $\hat{y}_{t+h\|t} = \ell_t + hb_t + s_{t+h-m(k+1)}$<br>$\ell_t = \alpha(y_t - s_{t-m}) + (1-\alpha)(\ell_{t-1} + b_{t-1})$<br>$b_t = \beta^*(\ell_t - \ell_{t-1}) + (1-\beta^*)b_{t-1}$<br>$s_t = \gamma(y_t - \ell_{t-1} - b_{t-1}) + (1-\gamma)s_{t-m}$ | $\hat{y}_{t+h\|t} = (\ell_t + hb_t)s_{t+h-m(k+1)}$<br>$\ell_t = \alpha(y_t/s_{t-m}) + (1-\alpha)(\ell_{t-1} + b_{t-1})$<br>$b_t = \beta^*(\ell_t - \ell_{t-1}) + (1-\beta^*)b_{t-1}$<br>$s_t = \gamma(y_t/(\ell_{t-1} + b_{t-1})) + (1-\gamma)s_{t-m}$ |
| $\mathbf{A_d}$ | $\hat{y}_{t+h\|t} = \ell_t + \phi_h b_t$<br>$\ell_t = \alpha y_t + (1-\alpha)(\ell_{t-1} + \phi b_{t-1})$<br>$b_t = \beta^*(\ell_t - \ell_{t-1}) + (1-\beta^*)\phi b_{t-1}$ | $\hat{y}_{t+h\|t} = \ell_t + \phi_h b_t + s_{t+h-m(k+1)}$<br>$\ell_t = \alpha(y_t - s_{t-m}) + (1-\alpha)(\ell_{t-1} + \phi b_{t-1})$<br>$b_t = \beta^*(\ell_t - \ell_{t-1}) + (1-\beta^*)\phi b_{t-1}$<br>$s_t = \gamma(y_t - \ell_{t-1} - \phi b_{t-1}) + (1-\gamma)s_{t-m}$ | $\hat{y}_{t+h\|t} = (\ell_t + \phi_h b_t)s_{t+h-m(k+1)}$<br>$\ell_t = \alpha(y_t/s_{t-m}) + (1-\alpha)(\ell_{t-1} + \phi b_{t-1})$<br>$b_t = \beta^*(\ell_t - \ell_{t-1}) + (1-\beta^*)\phi b_{t-1}$<br>$s_t = \gamma(y_t/(\ell_{t-1} + \phi b_{t-1})) + (1-\gamma)s_{t-m}$ |

## Библиография

*Гарднер, Э. С.* (1985). Экспоненциальное сглаживание: Современное состояние. Journal of Forecasting, 4 (1), 1–28. [DOI: https://doi.org/10.1002/for.3980040103].

*Хайндман, Р. Дж., Келер, А. Б., Орд, Дж. К. и Снайдер, Р. Д.* (2008). Прогнозирование с экспоненциальным сглаживанием: подход на основе пространства состояний. Springer-Verlag. *http://www.exponentialsmoothing.net*.

*Пегельс, К. С.* (1969). Экспоненциальное прогнозирование: несколько новых вариаций. Management Science, 15 (5), 311–315. [DOI: https://doi.org/10.1287/mnsc.15.5.311]

*Тейлор, Дж. У.* (2003). Экспоненциальное сглаживание с демпфируемым мультипликативным трендом. International Journal of Forecasting, 19 (4), 715–725. [DOI: https://doi.org/10.1016/S0169-2070(03)00003-7].

## 8.5. Модели пространства состояний инноваций для экспоненциального сглаживания

В остальной части этой главы мы изучаем статистические модели, лежащие в основе рассмотренных нами выше методов экспоненциального сглаживания. Приведенные в табл. 8.6 методы экспоненциального сглаживания представля-

ют собой алгоритмы, которые генерируют точечные прогнозы. Статистические модели в этом разделе генерируют те же точечные прогнозы, но могут также генерировать предсказательные (или прогнозные) интервалы. Статистическая модель – это стохастический (или случайный) процесс генерирования данных, который может продуцировать полное прогнозное распределение. Мы также опишем, как использовать представленные в главе 7 критерии отбора модели с целью объективного выбора модели.

Каждая модель состоит из уравнения измерения, которое описывает наблюдаемые данные, и некоторых уравнений состояния, которые описывают, как ненаблюдаемые компоненты или состояния (уровень, тренд, сезонность) изменяются с течением времени. Следовательно, они называются **моделями пространства состояний**.

Для каждого метода существуют две модели: одна с аддитивными ошибками и одна с мультипликативными ошибками. Производимые моделями точечные прогнозы идентичны, если в них используются одни и те же значения параметров сглаживания. Однако они будут генерировать разные предсказательные интервалы.

Для того чтобы отличить модель с аддитивными ошибками от модели с мультипликативными ошибками (а также отличить модели от методов), мы добавляем в классификацию из табл. 8.5 третью букву. Мы обозначаем каждую модель пространства состояний как ETS(.,.,.) для трех комбинационных составляющих (Ошибка, Тренд, Сезонность). Эту метку также можно рассматривать как экспоненциальное сглаживание. Используя ту же нотацию, что и в табл. 8.5, возможности для каждого компонента (или состояния) таковы: Ошибка = {A,M}, Тренд = {N,A,$A_d$} и Сезонность = {N,A,M}.

## ETS(A,N,N): простое экспоненциальное сглаживание с аддитивными ошибками

Вспомним компонентную форму простого экспоненциального сглаживания:

$$\text{уравнение прогноза} \quad y_{t+1|t} = \ell_t,$$
$$\text{уравнение сглаживания} \quad \ell_t = \alpha y_t + (1-\alpha)\ell_{t-1}.$$

Если перестроить уравнение сглаживания для уровня, то мы получим форму «исправления ошибок»:

$$\begin{aligned}\ell_t &= \ell_{t-1} + \alpha\left(y_t - \ell_{t-1}\right)\\ &= \ell_{t-1} + \alpha e_t,\end{aligned}$$

где $e_t = y_t - \ell_{t-1} = y_t - \hat{y}_{t|t-1}$ – это остаток на момент времени $t$.

Ошибки данных тренировки приводят к корректировке оцениваемого уровня на протяжении всего процесса сглаживания для $t = 1, \ldots T$. Например, если ошибка на момент времени $t$ является отрицательной, то $y_t < \hat{y}_{t|t-1}$ и, значит, уровень во время $t - 1$ был переоценен. Тогда новый уровень $l_t$ – это предыдущий уровень $l_{t-1}$, скорректированный вниз. Чем ближе $\alpha$ к единице, тем «гру-

бее» оценка уровня (происходят большие корректировки). Чем меньше $\alpha$, тем «плавнее» уровень (происходят малые корректировки).

Также можно записать $y_t = l_{t-1} + e_t$, чтобы каждое наблюдение можно было представить предыдущим уровнем плюс ошибка. Для того чтобы превратить эту формулу в модель пространства состояний инноваций, необходимо лишь сформулировать распределение вероятностей для $e_t$. В случае модели с аддитивными ошибками мы исходим из допущения о том, что остатки (ошибки одношаговой тренировки) $e_t$ представляют собой нормально распределенный белый шум со средним значением 0 и дисперсией $\sigma^2$. Сокращенное обозначение для этого – $e_t = \varepsilon_t \sim \text{NID}(0, \sigma^2)$; NID означает normally and independently distributed, т. е. «нормально и независимо распределенный».

Тогда уравнения модели можно записать как

$$y_t = \ell_{t-1} + \varepsilon_t, \tag{8.3}$$

$$\ell_t = \ell_{t-1} + \alpha\varepsilon_t. \tag{8.4}$$

Мы ссылаемся на (8.3) как на уравнение *измерения* (или наблюдения) и (8.4) как на уравнение *состояния* (или перехода). Эти два уравнения вместе со статистическим распределением ошибок образуют полностью сформулированную статистическую модель. В частности, они представляют собой модель пространства состояний инноваций, лежащую в основе простого экспоненциального сглаживания.

Термин «инновации» происходит из того факта, что во всех уравнениях используется один и тот же процесс случайной ошибки, $\varepsilon_t$. По той же причине данная формулировка также упоминается как модель «единого источника ошибок». Существуют альтернативные формулировки множественных источников ошибок, которые мы здесь не приводим.

Уравнение измерения показывает взаимосвязь между наблюдениями и ненаблюдаемыми состояниями. В этом случае наблюдение $y_t$ – это линейная функция от уровня $l_{t-1}$, предсказуемой части $y_t$, и ошибка $\varepsilon_t$ – непредсказуемая часть $y_t$. Для других моделей пространства состояний инноваций эта взаимосвязь может быть нелинейной.

Уравнение состояния показывает эволюцию состояния во времени. Влияние параметра сглаживания $\alpha$ является таким же, как и для методов, рассмотренных ранее. Например, $\alpha$ руководит величиной изменения в поочередных уровнях: высокие значения $\alpha$ позволяют быстро изменять уровень; низкие значения $\alpha$ приводят к плавным изменениям. Если $\alpha = 0$, то уровень ряда не меняется во времени; если $\alpha = 1$, то модель сводится к модели случайного блуждания, $y_t = y_{t-1} + \varepsilon_t$. (Обсуждение этой модели см. в разделе 9.1.)

## ETS(M,N,N): простое экспоненциальное сглаживание с мультипликативными ошибками

Мы можем формулировать модели с мультипликативными ошибками аналогичным образом, записывая ошибки тренировки на один шаг вперед как относительные ошибки

$$\varepsilon_t = \frac{y_t - \hat{y}_{t|t-1}}{\hat{y}_{t|t-1}},$$

где $\varepsilon_t \sim \text{NID}\left(0, \sigma^2\right)$. Подстановка $\hat{y}_{t|t-1} = \ell_{t-1}$ дает $y_t = \ell_{t-1} + \ell_{t-1}\varepsilon_t$ и $e_t = y_t - \hat{y}_{t|t-1} = \ell_{t-1}\varepsilon_t$.

Тогда мультипликативную форму модели пространства состояний можно записать как

$$\begin{aligned} y_t &= \ell_{t-1}\left(1+\varepsilon_t\right), \\ \ell_t &= \ell_{t-1}\left(1+\alpha\varepsilon_t\right). \end{aligned}$$

## ETS(A,A, N): линейный метод Хольта с аддитивными ошибками

Для этой модели мы исходим из допущения о том, что ошибки тренировки на один шаг вперед задаются формулой $\varepsilon_t = y_t - \ell_{t-1} - b_{t-1} \sim \text{NID}\left(0, \sigma^2\right)$. Подставив ее в уравнения исправления ошибок для линейного метода Хольта, мы получаем

$$\begin{aligned} y_t &= \ell_{t-1} + b_{t-1} + \varepsilon_t \\ \ell_t &= \ell_{t-1} + b_{t-1} + \alpha\varepsilon_t \\ b_t &= b_{t-1} + \beta\varepsilon_t, \end{aligned}$$

где для простоты мы задали $\beta = \alpha\beta^*$.

## ETS(M,A, N): линейный метод Хольта с мультипликативными ошибками

Формулируя ошибки тренировки на один шаг вперед как относительные ошибки, таким образом, что

$$\varepsilon_t = \frac{y_t - \left(\ell_{t-1} + b_{t-1}\right)}{\left(\ell_{t-1} + b_{t-1}\right)},$$

и следуя подходу, аналогичному использованному выше, модель пространства состояний инноваций, лежащая в основе линейного метода Хольта с мультипликативными ошибками, формулируется как

$$\begin{aligned} y_t &= \left(\ell_{t-1} + b_{t-1}\right)\left(1+\varepsilon_t\right) \\ \ell_t &= \left(\ell_{t-1} + b_{t-1}\right)\left(1+\alpha\varepsilon_t\right) \\ b_t &= b_{t-1} + \beta\left(\ell_{t-1} + b_{t-1}\right)\varepsilon_t, \end{aligned}$$

где опять-таки $\beta = \alpha\beta^*$ и $\varepsilon_t \sim \text{NID}\left(0, \sigma^2\right)$.

## Другие модели ETS

Модель пространства состояний инноваций можно написать аналогичным образом для каждого метода экспоненциального сглаживания, приведенного в табл. 8.6. В табл. 8.7 представлены уравнения всех моделей в каркасе ETS.

**Таблица 8.7:** Уравнения пространства состояний для каждой модели в каркасе ETS

*АДДИТИВНЫЕ МОДЕЛИ ОШИБОК*

| Тренд | Сезонная компонента | | |
|---|---|---|---|
| | **N** | **A** | **M** |
| **N** | $y_t = \ell_{t-1} + \varepsilon_t$<br>$\ell_t = \ell_{t-1} + \alpha\varepsilon_t$ | $y_t = \ell_{t-1} + s_{t-m} + \varepsilon_t$<br>$\ell_t = \ell_{t-1} + \alpha\varepsilon_t$<br>$s_t = s_{t-m} + \gamma\varepsilon_t$ | $y_t = \ell_{t-1}s_{t-m} + \varepsilon_t$<br>$\ell_t = \ell_{t-1} + \alpha\varepsilon_t/s_{t-m}$<br>$s_t = s_{t-m} + \gamma\varepsilon_t/\ell_{t-1}$ |
| **A** | $y_t = \ell_{t-1} + b_{t-1} + \varepsilon_t$<br>$\ell_t = \ell_{t-1} + b_{t-1} + \alpha\varepsilon_t$<br>$b_t = b_{t-1} + \beta\varepsilon_t$ | $y_t = \ell_{t-1} + b_{t-1} + s_{t-m} + \varepsilon_t$<br>$\ell_t = \ell_{t-1} + b_{t-1} + \alpha\varepsilon_t$<br>$b_t = b_{t-1} + \beta\varepsilon_t$<br>$s_t = s_{t-m} + \gamma\varepsilon_t$ | $y_t = (\ell_{t-1} + b_{t-1})s_{t-m} + \varepsilon_t$<br>$\ell_t = \ell_{t-1} + b_{t-1} + \alpha\varepsilon_t/s_{t-m}$<br>$b_t = b_{t-1} + \beta\varepsilon_t/s_{t-m}$<br>$s_t = s_{t-m} + \gamma\varepsilon_t/(\ell_{t-1} + b_{t-1})$ |
| $\mathbf{A_d}$ | $y_t = \ell_{t-1} + \phi b_{t-1} + \varepsilon_t$<br>$\ell_t = \ell_{t-1} + \phi b_{t-1} + \alpha\varepsilon_t$<br>$b_t = \phi b_{t-1} + \beta\varepsilon_t$ | $y_t = \ell_{t-1} + \phi b_{t-1} + s_{t-m} + \varepsilon_t$<br>$\ell_t = \ell_{t-1} + \phi b_{t-1} + \alpha\varepsilon_t$<br>$b_t = \phi b_{t-1} + \beta\varepsilon_t$<br>$s_t = s_{t-m} + \gamma\varepsilon_t$ | $y_t = (\ell_{t-1} + \phi b_{t-1})s_{t-m} + \varepsilon_t$<br>$\ell_t = \ell_{t-1} + \phi b_{t-1} + \alpha\varepsilon_t/s_{t-m}$<br>$b_t = \phi b_{t-1} + \beta\varepsilon_t/s_{t-m}$<br>$s_t = s_{t-m} + \gamma\varepsilon_t/(\ell_{t-1} + \phi b_{t-1})$ |

*МУЛЬТИПЛИКАТИВНЫЕ МОДЕЛИ ОШИБОК*

| Тренд | Сезонная компонента | | |
|---|---|---|---|
| | **N** | **A** | **M** |
| **N** | $y_t = \ell_{t-1}(1 + \varepsilon_t)$<br>$\ell_t = \ell_{t-1}(1 + \alpha\varepsilon_t)$ | $y_t = (\ell_{t-1} + s_{t-m})(1 + \varepsilon_t)$<br>$\ell_t = \ell_{t-1} + \alpha(\ell_{t-1} + s_{t-m})\varepsilon_t$<br>$s_t = s_{t-m} + \gamma(\ell_{t-1} + s_{t-m})\varepsilon_t$ | $y_t = \ell_{t-1}s_{t-m}(1 + \varepsilon_t)$<br>$\ell_t = \ell_{t-1}(1 + \alpha\varepsilon_t)$<br>$s_t = s_{t-m}(1 + \gamma\varepsilon_t)$ |
| **A** | $y_t = (\ell_{t-1} + b_{t-1})(1 + \varepsilon_t)$<br>$\ell_t = (\ell_{t-1} + b_{t-1})(1 + \alpha\varepsilon_t)$<br>$b_t = b_{t-1} + \beta(\ell_{t-1} + b_{t-1})\varepsilon_t$ | $y_t = (\ell_{t-1} + b_{t-1} + s_{t-m})(1 + \varepsilon_t)$<br>$\ell_t = \ell_{t-1} + b_{t-1} + \alpha(\ell_{t-1} + b_{t-1} + s_{t-m})\varepsilon_t$<br>$b_t = b_{t-1} + \beta(\ell_{t-1} + b_{t-1} + s_{t-m})\varepsilon_t$<br>$s_t = s_{t-m} + \gamma(\ell_{t-1} + b_{t-1} + s_{t-m})\varepsilon_t$ | $y_t = (\ell_{t-1} + b_{t-1})s_{t-m}(1 + \varepsilon_t)$<br>$\ell_t = (\ell_{t-1} + b_{t-1})(1 + \alpha\varepsilon_t)$<br>$b_t = b_{t-1} + \beta(\ell_{t-1} + b_{t-1})\varepsilon_t$<br>$s_t = s_{t-m}(1 + \gamma\varepsilon_t)$ |
| $\mathbf{A_d}$ | $y_t = (\ell_{t-1} + \phi b_{t-1})(1 + \varepsilon_t)$<br>$\ell_t = (\ell_{t-1} + \phi b_{t-1})(1 + \alpha\varepsilon_t)$<br>$b_t = \phi b_{t-1} + \beta(\ell_{t-1} + \phi b_{t-1})\varepsilon_t$ | $y_t = (\ell_{t-1} + \phi b_{t-1} + s_{t-m})(1 + \varepsilon_t)$<br>$\ell_t = \ell_{t-1} + \phi b_{t-1} + \alpha(\ell_{t-1} + \phi b_{t-1} + s_{t-m})\varepsilon_t$<br>$b_t = \phi b_{t-1} + \beta(\ell_{t-1} + \phi b_{t-1} + s_{t-m})\varepsilon_t$<br>$s_t = s_{t-m} + \gamma(\ell_{t-1} + \phi b_{t-1} + s_{t-m})\varepsilon_t$ | $y_t = (\ell_{t-1} + \phi b_{t-1})s_{t-m}(1 + \varepsilon_t)$<br>$\ell_t = (\ell_{t-1} + \phi b_{t-1})(1 + \alpha\varepsilon_t)$<br>$b_t = \phi b_{t-1} + \beta(\ell_{t-1} + \phi b_{t-1})\varepsilon_t$<br>$s_t = s_{t-m}(1 + \gamma\varepsilon_t)$ |

# 8.6 Оценивание и отбор модели

## Оценивание моделей ETS

Альтернативой оцениванию параметров путем минимизирования суммы квадратов ошибок является максимизирование «правдоподобия». Правдоподобие – это вероятность того, что данные возникнут из указанной модели[1]. Таким образом, большое правдоподобие ассоциировано с хорошей моделью. Для аддитивной модели ошибок максимизирование правдоподобия (при условии нормально распределенных ошибок) дает те же результаты, что и минимизи-

[1] В зарубежной литературе правдоподобие (likelihood) часто понимается как возможность возникновения данных. – *Прим. перев.*

рование суммы квадратов ошибок. Однако для моделей с мультипликативными ошибками будут получены другие результаты. В этом разделе мы оценим параметры сглаживания $\alpha$, $\beta$, $\gamma$ и $\phi$ и начальные состояния $l_0$, $b_0$, $s_0$, $s_{-1}$, … ,$s_{-m+1}$ путем максимизирования правдоподобия (понимаемого как возможность возникновения данных. – *Прим. перев.*).

Возможные значения, которые могут принимать параметры сглаживания, ограничиваются. Традиционно параметры были ограничены в пределах от 0 до 1, чтобы уравнения можно было интерпретировать как средневзвешенные значения. То есть $0 < \alpha, \beta^*, \gamma^*, \phi < 1$. Для моделей пространства состояний мы установили $\beta = \alpha\beta^*$ и  $= (1 - \alpha)\gamma^*$. Следовательно, традиционные ограничения транслируются в $0 < \alpha < 1$, $0 < \beta < \alpha$ и $0 < \gamma < 1 - \alpha$. На практике параметр демпфирования $\phi$ обычно ограничивается дальше, чтобы предотвратить численные трудности в оценивании модели. В пакете fable он ограничен таким образом, что $0.8 < \phi < 0.98$.

Еще одна точка зрения на параметры состоит в рассмотрении математических свойств моделей пространства состояний. Параметры ограничиваются для того, чтобы наблюдения в далеком прошлом не оказывали продолжающегося влияния на текущие прогнозы. Это приводит к некоторым накладываемым на параметры ограничениям *допустимости*, которые обычно (но не всегда) являются менее строгими, чем участок традиционных ограничений (*Хайндман и соавт.*, 2008, глава 10, *https://otexts.com/fpp3/ets-estimation.html#ref-expsmooth08*). Например, для модели ETS(A,N,N) традиционный параметрический участок равен $0 < \alpha < 1$, но допустимый участок равен $0 < \alpha < 2$. Для модели ETS(A,A,N) традиционный параметрический участок – $0 < \alpha <$  и $0 < \beta < \alpha$, но допустимый участок равен $0 < \alpha < 2$ и $0 < \beta < 4 - 2\alpha$.

## Отбор модели

Огромным преимуществом статистического каркаса ETS является то, что для отбора модели можно использовать информационные критерии. AIC, AICc и BIC, представленные в разделе 7.5, могут использоваться здесь для определения того, какая из моделей ETS наиболее подходит для данного временного ряда.

Для моделей ETS информационный критерий Акаике (AIC) определяется как

$$\text{AIC} = -2\log(L) + 2k,$$

где $L$ – это правдоподобие модели и $k$ – суммарное число параметров и начальных состояний, которые были оценены (включая дисперсию остатков).

AIC, скорректированный на небольшое смещение выборки (AICc), определяется как

$$\text{AIC}_\text{c} = \text{AIC} + \frac{2k(k+1)}{T-k-1},$$

и байесов информационный критерий (BIC) равен

$$\text{BIC} = \text{AIC} + k\left[\log(T) - 2\right].$$

Три комбинации (Ошибка, Тренд, Сезонность) могут приводить к числовым трудностям. В частности, моделями, которые могут вызывать такие нестабильности, являются ETS(A, N, M), ETS(A,A, M) и ETS(A, $A_d$, M) из-за деления на значения, потенциально близкие к нулю в уравнениях состояния. Обычно мы не учитываем эти конкретные комбинации при отборе модели.

Модели с мультипликативными ошибками полезны, когда данные строго положительны, но не являются численно стабильными, когда данные содержат нули или отрицательные значения. Следовательно, модели с мультипликативными ошибками рассматриваться не будут, если временной ряд не является строго положительным. В этом случае будут применяться только шесть полностью аддитивных моделей.

## Пример: гостевые ночи праздничных туристов в Австралии

Теперь мы задействуем статистический каркас ETS для прогнозирования праздничного туризма в Австралии на период 2016–2019 годов. Мы позволяем функции `ETS()` отбирать модель, минимизируя AICc.

```
aus_holidays <- tourism %>%
  filter(Purpose == "Holiday") %>%
  summarise(Trips = sum(Trips)/1e3)
fit <- aus_holidays %>%
  model(ETS(Trips))
report(fit)
#> Series: Trips
#> Model: ETS(M,N,A)
#>   Smoothing parameters:
#>     alpha = 0.3484
#>     gamma = 1e-04
#>
#>   Initial states:
#>   l[0]    s[0]   s[-1]   s[-2] s[-3]
#>  9.727 -0.5376 -0.6884 -0.2934 1.519
#>
#>   sigma^2:  0.0022
#>
#>   AIC  AICc   BIC
#> 226.2 227.8 242.9
```

Была отобрана модель ETS(M,N,A).

$$\begin{aligned} y_t &= \left(\ell_{t-1} + s_{t-m}\right)\left(1+\varepsilon_t\right) \\ \ell_t &= \ell_{t-1} + \alpha\left(\ell_{t-1} + s_{t-m}\right)\varepsilon_t \\ s_t &= s_{t-m} + \gamma\left(\ell_{t-1} + s_{t-m}\right)\varepsilon_t. \end{aligned}$$

Оценки параметров таковы: $\hat{\alpha} = 0.3484$ и $\hat{\gamma} = 0.0001$. Результат также возвращает оценки начальных состояний $l_0$, $s_0$, $s_{-1}$, $s_{-2}$ и $s_{-3}$. Сравните их со значениями, полученными для метода Хольта–Винтерса с аддитивной сезонностью, представленной в табл. 8.3.

На рис. 8.10 показаны состояния с течением времени, а на рис. 8.12 – точечные прогнозы и предсказательные интервалы, сгенерированные из модели. Малые значения $\gamma$ указывают на то, что сезонные состояния изменяются очень мало с течением времени.

```
components(fit) %>%
  autoplot() +
  labs(title = "Компоненты ETS(M,N,A)")
```

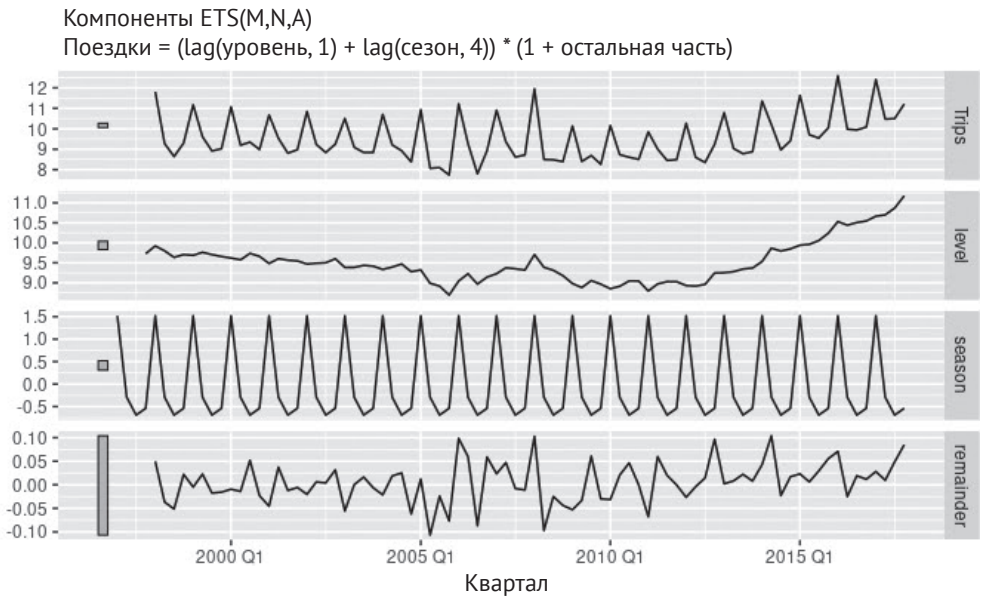


**Рисунок 8.10:** Графическое представление оценочных состояний с течением времени

Поскольку эта модель имеет мультипликативные ошибки, остатки инноваций не эквивалентны обычным остаткам (т. е. ошибкам одношаговой тренировки). Остатки инноваций определяются как $\hat{\varepsilon}_t$, в то время как регулярные остатки определяются как $y_t - \hat{y}_{t|t-1}$. Получить и то, и другое можно, используя функцию `augment()`. Они показаны на рис. 8.11.

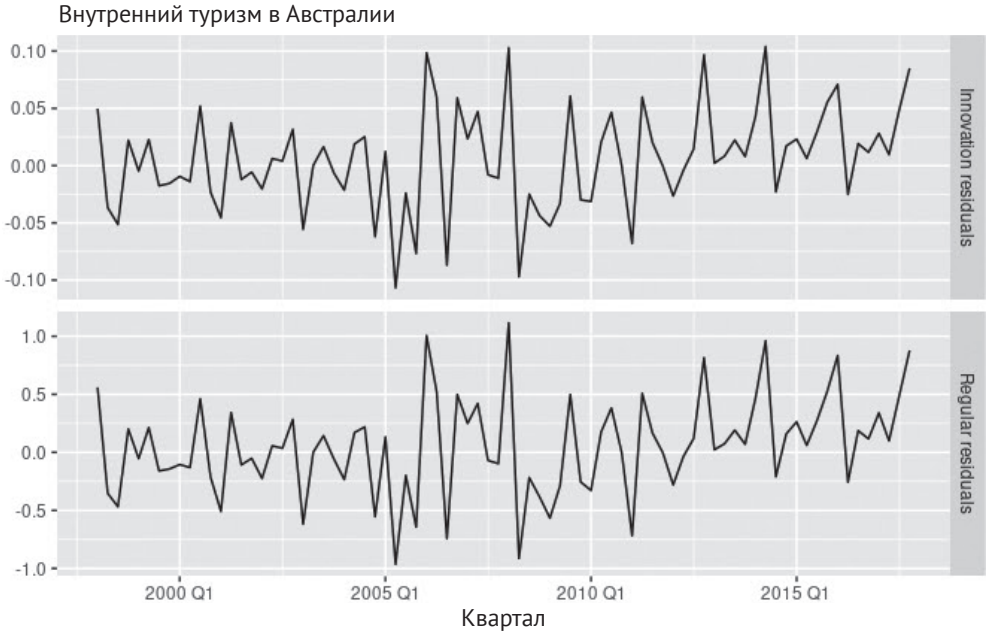


**Рисунок 8.11:** Остатки и ошибки одношагового прогноза из модели ETS(M,N,A)

## Библиография

*Хайндман, Р. Дж., Келер, А. Б., Орд, Дж. К. и Снайдер, Р. Д.* (2008). Прогнозирование с экспоненциальным сглаживанием: подход на основе пространства состояний. Springer-Verlag. *http://www.exponentialsmoothing.net*.

# 8.7 Прогнозирование с использованием моделей ETS

Точечные прогнозы могут быть получены из моделей путем итерирования уравнений для $t = T + 1, \ldots, T + h$ и установки всех $\varepsilon_t = 0$ для $t > T$.

Например, для модели ETS(M,A,N) $y_{T+1} = (\ell_T + b_T)(1 + \varepsilon_{T+1})$. Следовательно, $\hat{y}_{T+1|T} = \ell_T + b_T$. Аналогичным образом

$$y_{T+2} = (\ell_{T+1} + b_{T+1})(1 + \varepsilon_{T+2}) =$$
$$\left[(\ell_T + b_T)(1 + \alpha\varepsilon_{T+1}) + b_T + \beta(\ell_T + b_T)\varepsilon_{T+1}\right](1 + \varepsilon_{T+2}).$$

Следовательно, $\hat{y}_{T+2|T} = \ell_T + 2b_T$ и т. д. Эти прогнозы идентичны прогнозам линейного метода Хольта, а также прогнозам модели ETS(A,A,N). Таким образом, точечные прогнозы, полученные из метода и двух моделей, лежащих в основе метода, идентичны (при условии что используются одни и те же значения параметров). Точечные прогнозы ETS, построенные в таком ключе, равны среднему значению прогнозных распределений, за исключением моделей с мультипликативной сезонностью (Хайндман и соавт., 2008).

В целях получения прогнозов из модели ETS мы используем функцию `forecast()` из пакета fable. Указанная функция всегда будет возвращать сред-

ние значения прогнозного распределения, даже если они отличаются от этих традиционных точечных прогнозов.

```
fit %>%
  forecast(h = 8) %>%
  autoplot(aus_holidays)+
  labs(title="Внутренний туризм в Австралии",
       y="Поездки с ночевкой (млн)")
```

**Рисунок 8.12:** Прогнозирование внутренних поездок с ночевкой в Австралии с использованием модели ETS(M,N,A)

## Предсказательные интервалы

Большим преимуществом статистических моделей является то, что предсказательные интервалы также могут генерироваться – то, что невозможно сделать, используя только методы точечного прогнозирования. Предсказательные интервалы будут различаться между моделями с аддитивными и мультипликативными методами.

Для большинства моделей ETS предсказательный интервал можно записать как

$$\hat{y}_{T+h|T} \pm c\sigma_h,$$

где $c$ зависит от вероятности покрытия и $\sigma_h^2$ – это прогнозная дисперсия. Значения $c$ приведены в табл. 5.1. Для моделей ETS формулы для $\sigma_h^2$ могут быть сложными; подробности приведены в главе 6 Хайндман и соавт. (2008, *https://otexts.com/fpp3/ets-forecasting.html#ref-expsmooth08*). В табл. 8.8 мы приводим формулы для аддитивных моделей ETS, которые являются самыми простыми.

**Таблица 8.8:** Выражения прогнозной дисперсии для каждой аддитивной модели пространства состояний, где $\sigma^2$ – это дисперсия остатков, $m$ – сезонный период, $k$ – целочисленная часть $(h-1)/m$ (т. е. число полных лет в прогнозном периоде до момента времени $T+h$)

| Модель | Прогнозная дисперсия $\sigma_h^2$ |
|---|---|
| (A,N,N) | $\sigma_h^2 = \sigma^2\left[1+\alpha^2(h-1)\right]$ |
| (A,A,N) | $\sigma_h^2 = \sigma^2\left[1+(h-1)\left\{\alpha^2+\alpha\beta h+\frac{1}{6}\beta^2 h(2h-1)\right\}\right]$ |
| (A,$A_d$,N) | $\sigma_h^2 = \sigma^2[1+\alpha^2(h-1)+\frac{\beta\phi h}{(1-\phi)^2}\{2\alpha(1-\phi)+\beta\phi\} -\frac{\beta\phi(1-\phi^h)}{(1-\phi)^2(1-\phi^2)}\{2\alpha(1-\phi^2)+\beta\phi(1+2\phi-\phi^h)\}]$ |
| (A,N,A) | $\sigma_h^2 = \sigma^2\left[1+\alpha^2(h-1)+\gamma k(2\alpha+\gamma)\right]$ |
| (A,A,A) | $\sigma_h^2 = \sigma^2[1+(h-1)\left\{\alpha^2+\alpha\beta h+\frac{1}{6}\beta^2 h(2h-1)\right\} +\gamma k\{2\alpha+\gamma+\beta m(k+1)\}]$ |
| (A, $A_d$,A) | $\sigma_h^2 = \sigma^2[1+\alpha^2(h-1)+\gamma k(2\alpha+\gamma) +\frac{\beta\phi h}{(1-\phi)^2}\{2\alpha(1-\phi)+\beta\phi\} -\frac{\beta\phi(1-\phi^h)}{(1-\phi)^2(1-\phi^2)}\{2\alpha(1-\phi^2)+\beta\phi(1+2\phi-\phi^h)\} +\frac{2\beta\gamma\phi}{(1-\phi)(1-\phi^m)}\{k(1-\phi^m)-\phi^m(1-\phi^{mk})\}]$ |

Для нескольких моделей ETS не существует известных формул для предсказательных интервалов. В этих случаях в функции `forecast()` используются симулированные будущие пути выборки, и предсказательные интервалы вычисляются из процентилей этих симулированных будущих путей.

## Библиография

*Хайндман, Р. Дж., Келер, А. Б., Орд, Дж. К. и Снайдер, Р. Д.* (2008). Прогнозирование с экспоненциальным сглаживанием: подход на основе пространства состояний. Springer-Verlag. *http://www.exponentialsmoothing.net*.

## 8.8 Упражнения

1. Рассмотрите данные о поголовье свиней, забитых в шт. Виктория, доступных в наборе данных `aus_livestock`.
   a) Используйте функцию `ETS()`, чтобы оценить эквивалентную модель для простого экспоненциального сглаживания. Найдите оптимальные значения $\alpha$ и $l_0$ и сгенерируйте прогнозы на следующие четыре месяца.
   b) Вычислите 95%-ный предсказательный интервал для первого прогноза, используя $\hat{y} \pm 1.96s$, где $s$ – это стандартная дисперсия остатков. Сравните ваш интервал с интервалом, полученным R.
2. Напишите свою собственную функцию, чтобы имплементировать простое экспоненциальное сглаживание. Функция должна принимать аргументы `y` (временной ряд), `alpha` (параметр сглаживания $\alpha$) и `level` (начальный уровень $l_0$). Он должен возвращать прогноз следующего наблюдения в ряду. Дает ли он тот же прогноз, что и `ETS()`?
3. Модифицируйте свою функцию из предыдущего упражнения, чтобы возвращать сумму квадратов ошибок, а не прогноз следующего наблюдения. Затем примените функцию `optim()`, чтобы найти оптимальные значения $\alpha$ и $l_0$. Получаете ли вы те же значения, что и функция `ETS()`?
4. Скомбинируйте ваши предыдущие две функции, чтобы создать функцию, которая одновременно находит оптимальные значения $\alpha$ и $l_0$ и выдает прогноз следующего наблюдения в ряду.
5. Набор данных `global_economy` содержит данные о годовом экспорте из многих стран. Выберите одну страну для анализа.
   a) Постройте график экспорта и обсудите главные характеристики данных.
   b) Используйте модель ETS(A,N,N) для прогнозирования ряда и построения прогнозов.
   c) Вычислите значения RMSE для тренировочных данных.
   d) Сравните результаты с результатами модели ETS(A,A,N). (Помните, что в трендовой модели используется на один параметр больше, чем в более простой модели.) Обсудите достоинства двух методов прогнозирования для этого набора данных.
   e) Сравните прогнозы, полученные с помощью обоих методов. Какой из них, по вашему мнению, лучше?
   f) Рассчитайте 95%-ный предсказательный интервал для первого прогноза для каждой модели, используя значения RMSE и исходя из допущения о нормальности ошибок. Сравните ваши интервалы с интервалами, полученными с помощью R.
6. Спрогнозируйте ВВП Китая из набора данных `global_economy` с использованием модели ETS. Поэкспериментируйте с различными опциями функции `ETS()`, чтобы увидеть, насколько сильно прогнозы изменяются при демпфировании тренда или при преобразовании Бокса–Кокса. Постарайтесь развить интуицию относительно того, что каждый из них делает с прогнозами.

[Подсказка: при прогнозировании используйте относительно большое значение *h*, чтобы при построении прогнозов вы могли четко видеть различия между разными вариантами.]

7. Найдите модель ETS для данных о газе из `aus_production` и сделайте прогноз на ближайшие несколько лет. Почему здесь необходима мультипликативная сезонность? Поэкспериментируйте с демпфированием тренда. Улучшает ли оно прогнозы?
8. Вспомните свои данные временного ряда о розничной торговле (из упражнения 8 в разделе 2.10).
   a) Почему для этого ряда необходима мультипликативная сезонность?
   b) Примените к данным мультипликативный метод Хольта–Винтерса. Поэкспериментируйте с демпфированием тренда.
   c) Сравните RMSE одношаговых прогнозов, полученных с помощью двух методов. Какой из них вы предпочитаете?
   d) Убедитесь, что остатки от наилучшего метода выглядят как белый шум.
   e) Теперь найдите RMSE тестового набора, одновременно натренировав модель до конца 2010 года. Сможете ли вы победить сезонный наивный подход из упражнения 7 раздела 5.11?
9. Для тех же розничных данных попробуйте STL-разложение применительно к ряду, трансформированному на основе преобразования Бокса–Кокса, с последующим использованием ETS для сезонно скорректированных данных. Как это соотносится с вашими лучшими предыдущими прогнозами на тестовом наборе?
10. Вычислите суммарное число внутренних поездок с ночевкой в Австралии из набора данных `tourism`.
    a) Постройте график данных и опишите главные характеристики ряда.
    b) Разложите ряд с использованием STL и получите сезонно скорректированные данные.
    c) Спрогнозируйте следующие два года ряда с использованием аддитивного метода с демпфированием тренда применительно к сезонно скорректированным данным. (Это можно указать с помощью функции `decomposition_model()`.)
    d) Спрогнозируйте следующие два года ряда, используя соответствующую модель для линейного метода Хольта, применительно к сезонно скорректированным данным (как и раньше, но без демпфирования тренда).
    e) Теперь примените `ETS()`, чтобы выбрать сезонную модель для данных.
    f) Сравните RMSE модели ETS с RMSE моделей, полученных с помощью STL-разложений. Какой из подходов дает более оптимальную внутривыборочную подгонку?
    g) Сравните прогнозы, полученные с помощью трех подходов. Какой из них выглядит наиболее разумным?
    h) Проверьте остатки вашей предпочтительной модели.

11. В этом упражнении используйте ежеквартальное число прибытий в Австралию из Новой Зеландии, 1981Q1–2012Q3, из набора данных `aus_arrivals`.
    a) Составьте график времени на основе ваших данных и опишите главные характеристики ряда.
    b) Создайте тренировочный набор, который откладывает доступные данные за последние два года. Спрогнозируйте тестовый набор, используя соответствующую модель для мультипликативного метода Хольта–Винтерса.
    c) Почему здесь необходима мультипликативная сезонность?
    d) Спрогнозируйте двухлетний тестовый набор, используя каждый из следующих ниже методов:
       - модель ETS;
       - аддитивная модель ETS применительно к логарифмически преобразованному ряду;
       - сезонный наивный метод;
       - STL-разложение применительно к логарифмически преобразованным данным, за которым следует модель ETS, применительно к сезонно скорректированным (преобразованным) данным.
    e) Какой метод дает наилучшие прогнозы? Проходит ли он тесты остатков?
    f) Сравните те же четыре метода, используя перекрестную валидацию временных рядов вместо тренировочного и тестового наборов. Вы пришли к тем же выводам?
12.
    a) Примените методы перекрестной валидации для получения ETS и сезонных наивных прогнозов на 1 год вперед производства портландцемента (из `aus_production`). Используйте растягивающееся окно данных с начальным размером 5 лет и увеличивайте окно на одно наблюдение.
    b) Вычислите MSE результирующих ошибок на 4 шага вперед. Прокомментируйте в отношении того, какие прогнозы оказались точнее. Это то, чего вы ожидали?
13. Сравните `ETS()`, `SNAIVE()` и `decomposition_model(STL, ???)` на следующих ниже пяти временных рядах. Возможно, вам потребуется использовать преобразование Бокса–Кокса для прогнозов на основе STL-разложения. Используйте тестовый набор за три года, чтобы решить, какой из методов дает наилучшие прогнозы.
    - Производство пива и кирпичей из `aus_production`.
    - Стоимость субсидий на препараты от диабета (`ATC2 == "A10"`) и кортикостероиды (`ATC2 == "H02"`) из `PBS`.
    - Суммарный оборот розничной торговли продуктами питания в Австралии из `aus_retail`.
14.
    a) Используйте функцию `ETS()`, чтобы отобрать подходящую модель для следующих рядов: суммарное число поездок по Австралии с ис-

пользованием набора данных `tourism`, цены закрытия для четырех акций из `gafa_stock` и ряда lynx из `pelt`. Всегда ли она дает хорошие прогнозы?

b) Найдите пример, где она работает плохо. Сможете ли вы понять причину?

15. Покажите, что точечные прогнозы из модели ETS (M,A,M) совпадают с прогнозами, полученными с использованием мультипликативного метода Хольта–Винтерса.
16. Покажите, что прогнозная дисперсия для модели ETS(A,N,N) формулируется как

$$\sigma^2\left[1+\alpha^2\left(h-1\right)\right].$$

17. Запишите 95%-ные предсказательные интервалы для модели ETS(A,N,N) как функции от $l_T$, $\alpha$, $h$ и $\sigma$, исходя из допущения о нормальности распределения ошибок.

## 8.9 Дальнейшее чтение

Две статьи Эва Гарднера (Гарднер, 1985, *https://otexts.com/fpp3/expsmooth-reading.html#ref-Gar1985*, 2006, *https://otexts.com/fpp3/expsmooth-reading.html#ref-Gar2006*) дают отличный обзор истории экспоненциального сглаживания и его многочисленных вариаций.

Полная трактовка предмета в книге с математическими подробностями приведена Хайндманом и соавт. (2008, *https://otexts.com/fpp3/expsmooth-reading.html#ref-expsmooth08*).

## Библиография

*Гарднер, Э. С.* (1985). Экспоненциальное сглаживание: Современное состояние. Journal of Forecasting, 4 (1), 1–28. [DOI: https://doi.org/10.1002/for.3980040103].

*Гарднер, Э. С.* (2006). Экспоненциальное сглаживание: Современное состояние. Часть II. International Journal of Forecasting, 22, 637–666. [DOI: https://doi.org/10.1016/j.ijforecast.2006.03.005].

*Хайндман, Р. Дж., Келер, А. Б., Орд, Дж. К. и Снайдер, Р. Д.* (2008). Прогнозирование с экспоненциальным сглаживанием: подход на основе пространства состояний. Springer-Verlag. *http://www.exponentialsmoothing.net*.

# Глава 9

# Модели ARIMA

Модели ARIMA обеспечивают еще один подход к прогнозированию временных рядов. Экспоненциальное сглаживание и модели ARIMA являются двумя наиболее широко используемыми подходами к прогнозированию временных рядов и обеспечивают дополнительные подходы к решению задачи. В то время как модели экспоненциального сглаживания основаны на описании тренда и сезонности в данных, модели ARIMA ориентированы на описание автокорреляций в данных.

Прежде чем мы представим модели ARIMA, сначала необходимо обсудить концепцию стационарности и технику дифференцирования временных рядов.

## 9.1 Стационарность и дифференцирование

Стационарный временной ряд – это такой временной ряд, статистические свойства которого не зависят от времени, в которое наблюдается ряд[1]. Таким образом, временные ряды с трендами или с сезонностью не являются стационарными – тренд и сезонность будут влиять на значение временного ряда в разное время. С другой стороны, ряд белого шума является стационарным – не имеет значения, когда вы его наблюдаете, он должен выглядеть практически одинаково в любой момент времени.

Некоторые случаи могут дезориентировать – временной ряд с циклическим поведением (но без тренда или сезонности) является стационарным. Это обусловлено тем, что циклы не имеют фиксированной длины, поэтому мы не можем быть уверены в том, где будут находиться пики и впадины циклов до того, как мы будем наблюдать ряд.

В целом стационарный временной ряд не будет иметь предсказуемых закономерностей в долгосрочной перспективе. Графики времени будут показывать, что ряды примерно горизонтальны (хотя некоторое циклическое поведение вполне возможно) с постоянной дисперсией.

---

[1] Точнее, если $\{y_t\}$ – это **стационарный** временной ряд, то для всех $s$ распределение $(y_t, \ldots, y_{t+s})$ не зависит от $t$.

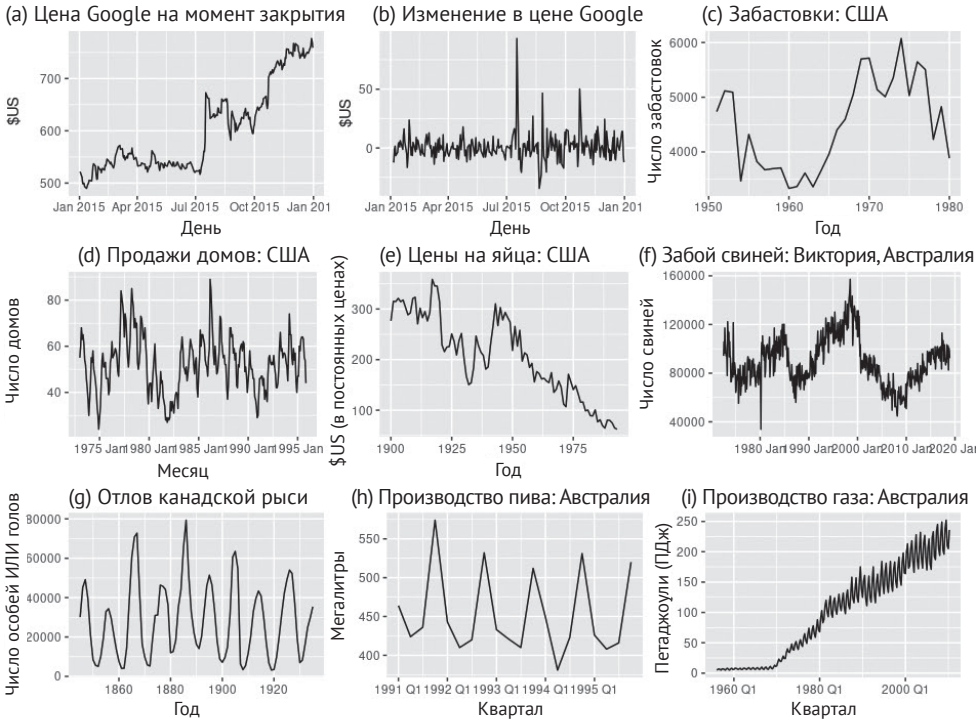


**Рисунок 9.1:** Какие из этих рядов являются стационарными? (a) Цена акций Google на момент закрытия торгового периода в 2015 году; (b) ежедневное изменение в цене акций Google в 2015 году; (c) годовое число забастовок в США; (d) ежемесячные продажи новых односемейных домов, проданных в США; (e) годовая цена дюжины яиц в США (постоянные доллары); (f) ежемесячное общее поголовье свиней, забитых в шт. Виктория, Австралия; (g) годовое общее количество мехов канадской рыси, проданных компанией Hudson Bay; (h) ежеквартальное производство пива в Австралии; (i) ежемесячная добыча газа в Австралии

Рассмотрим девять рядов, изображенных на рис. 9.1. Какие из них, по вашему мнению, являются стационарными?

Очевидная сезонность исключает ряды (d), (h) и (i). Тренды и изменяющиеся уровни исключают ряды (a), (c), (e), (f) и (i). Увеличивающаяся дисперсия также исключает (i). В результате в качестве стационарных рядов остаются только (b) и (g).

На первый взгляд может показаться, что сильные циклы в ряде (g) делают его нестационарным. Но эти циклы являются апериодическими – они возникают, когда популяция рысей становится слишком большой для располагаемого корма, вследствие чего они перестают размножаться и численность популяции падает до низкой, затем восстановление источников их пищи позволяет популяции снова расти, и т. д. В долгосрочной перспективе сроки этих циклов непредсказуемы. Следовательно, указанный ряд является стационарным.

## Дифференцирование

На рис. 9.1 обратите внимание на то, что цена акций Google была нестационарной на панели (a), но ежедневные изменения были стационарными на панели (b). Это показывает один из способов сделать нестационарный временной ряд стационарным – вычислить разницы между поочередными наблюдениями. Указанная процедура называется **дифференцированием**[1].

Преобразования, такие как логарифмы, помогают стабилизировать дисперсию временного ряда. Дифференцирование помогает стабилизировать среднее значение временного ряда, устраняя изменения в уровне временного ряда и, следовательно, устраняя (или редуцируя) тренд и сезонность.

Помимо графика времени, график ACF также полезен для идентифицирования нестационарных временных рядов. Для стационарных временных рядов ACF относительно быстро упадет до нуля, в то время как ACF нестационарных данных уменьшается медленно. Кроме того, для нестационарных данных значение $r_1$ часто является большим и положительным.

```
google_2015 <- gafa_stock %>%
  filter(Symbol == "GOOG", year(Date) == 2015)
google_2015 %>% ACF(Close) %>%
  autoplot() + labs(subtitle = "Цена акций Google на момент закрытия")
google_2015 %>% ACF(difference(Close)) %>%
  autoplot() + labs(subtitle = "Изменения в цене акций Google на момент закрытия")
```

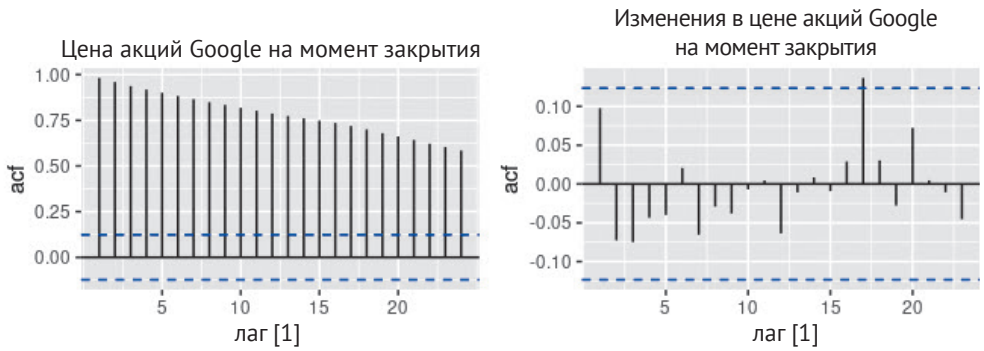


**Рисунок 9.2:** ACF цены акций Google на момент закрытия торгового периода в 2015 году (слева) и ежедневных изменений в цене акций Google на момент закрытия в 2015 году (справа)

```
google_2015 %>%
  mutate(diff_close = difference(Close)) %>%
  features(diff_close, ljung_box, lag = 10)
#> # A tibble: 1 × 3
```

[1] Дифференцирование (differencing) временного ряда в дискретном времени – это преобразование ряда в новый временной ряд, где значения представляют собой разницы между поочередными значениями. Например, дифференцирование первого порядка выполняется путем вычитания предыдущего наблюдения из текущего наблюдения. – *Прим. перев.*

```
#>   Symbol lb_stat lb_pvalue
#>   <chr>    <dbl>     <dbl>
#> 1 GOOG      7.91     0.637
```

ACF дифференцированной цены акций Google выглядит точно так же, как в ряде белого шума. Только одна автокорреляция выходит за пределы 95 %, а статистика $Q^*$ Льюнга–Бокса имеет $p$-значение 0.637 (для $h = 10$). Это говорит о том, что *ежедневное изменение* цены акций Google, по сути, является случайной величиной, которая не коррелирует с изменениями за предыдущие дни.

## Модель случайного блуждания

Дифференцированный ряд представляет собой *изменение* между поочередными наблюдениями в изначальном ряду, и его можно записать как

$$y'_t = y_t - y_{t-1}.$$

Дифференцированные ряды будут иметь только $T - 1$ значений, так как невозможно вычислить разницу $y'_1$ для первого наблюдения.

Когда дифференцированный ряд представляет собой белый шум, модель для изначального ряда можно записать как

$$y_t - y_{t-1} = \varepsilon_t,$$

где $\varepsilon_t$ обозначает белый шум. Перестановка этой формулы путем вынесения второго члена в правую часть приводит к модели «случайного блуждания»

$$y_t = y_{t-1} + \varepsilon_t.$$

Модели случайного блуждания широко используются для нестационарных данных, в особенности финансовых и экономических. Случайные блуждания обычно имеют:

- длительные периоды очевидных восходящих и нисходящих трендов;
- внезапные и непредсказуемые изменения в направлении.

Прогнозы из модели случайного блуждания равны последнему наблюдению, поскольку будущие движения непредсказуемы и с равной вероятностью будут как восходящими, так и нисходящими. Таким образом, модель случайного блуждания лежит в основе наивных прогнозов, впервые представленных в разделе 5.2.

Близкородственная модель основана на допущении, что разницы имеют ненулевое среднее значение. Тогда

$$y_t - y_{t-1} = c + \varepsilon_t, \text{ или } y_t = c + y_{t-1} + \varepsilon_t.$$

Значение $c$ – это среднее значение изменений между поочередными наблюдениями. Если $c$ положительно, то среднее изменение представляет собой увеличение значения $y_t$. Отсюда $y_t$ будет иметь тенденцию дрейфовать вверх. Однако если $c$ отрицательно, то $y_t$ будет иметь тенденцию дрейфовать вниз.

Указанная модель лежит в основе метода дрейфа, также обсуждаемого в разделе 5.2.

## Дифференцирование второго порядка

От случая к случаю дифференцированные данные не будут казаться стационарными, и может потребоваться дифференцировать данные по второму разу, чтобы получить стационарный ряд:

$$y_t'' = y_t' - y_{t-1}' = (y_t - y_{t-1}) - (y_{t-1} - y_{t-2}) = y_t - 2y_{t-1} + y_{t-2}.$$

В этом случае $y_t''$ будет иметь $T - 2$ значений. И тогда мы будем моделировать «изменение в изменениях» изначальных данных. На практике почти никогда нет необходимости выходить за рамки разниц второго порядка.

## Сезонное дифференцирование

Сезонная разница – это разница между наблюдением и предыдущим наблюдением из того же сезона. И поэтому

$$y_t' = y_t - y_{t-m},$$

где $m$ – это число сезонов. Такие разницы также называются «разницами лаг – $m$», поскольку мы вычитаем наблюдение после лага в $m$ периодов времени.

Если сезонно дифференцированные данные выглядят как белый шум, то соответствующей моделью для изначальных данных является

$$y_t = y_{t-m} + \varepsilon_t.$$

Прогнозы из этой модели равны последним наблюдениям за соответствующий сезон. То есть указанная модель дает сезонные наивные прогнозы, представленные в разделе 5.2.

Нижняя панель на рис. 9.3 показывает сезонные разницы логарифма ежемесячных рецептов на (противодиабетические) препараты A10, продаваемые в Австралии. Преобразование и дифференцирование сделали ряд относительно неподвижным.

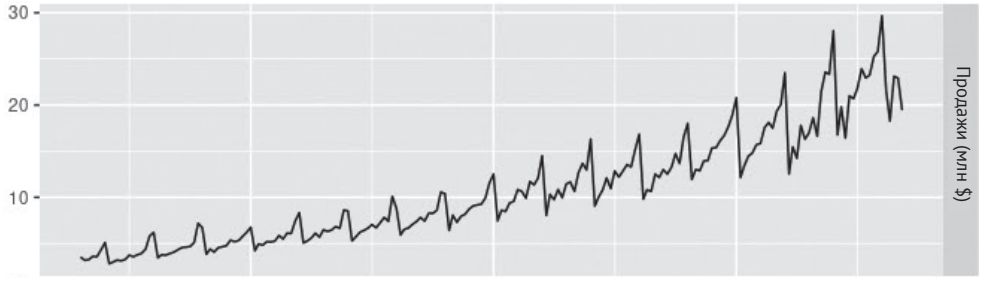


**Рисунок 9.3:** Логарифмы и сезонные разницы данных продаж A10 (противодиабетических средств). Логарифмы стабилизируют дисперсию, в то время как сезонные разницы устраняют сезонность и тренд

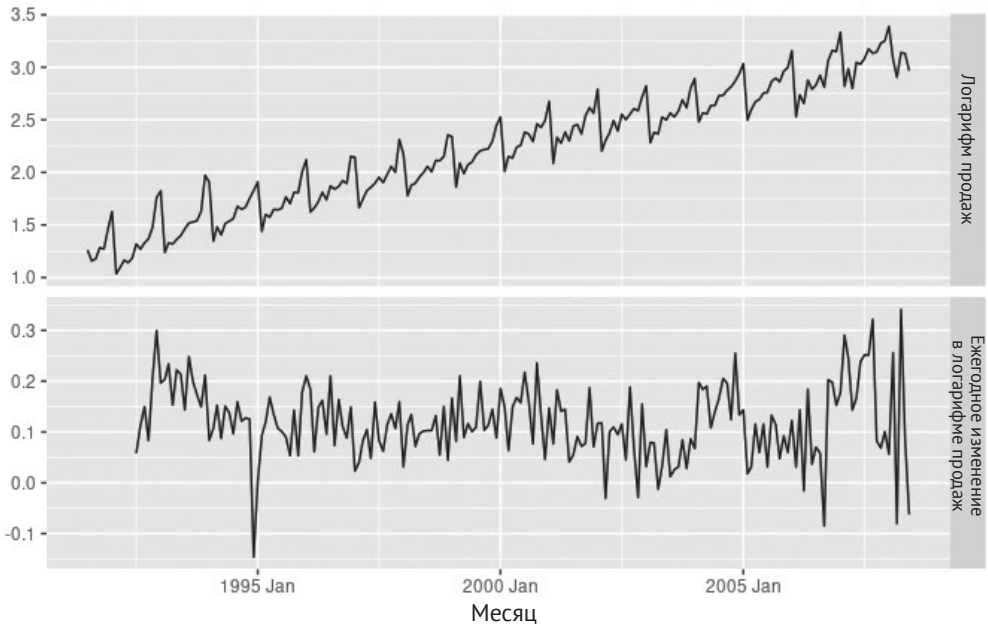


**Рисунок 9.3:** *Окончание*

В целях различения сезонных разниц от обычных разниц мы иногда называем обычные разницы «первыми разницами», что означает разницы с лагом 1.

Иногда для получения стационарных данных необходимо брать как сезонную разницу, так и первую разницу. На рис. 9.4 показаны продажи кортикостероидных препаратов в Австралии (австралийский доллар) (верхняя панель). Здесь данные сначала преобразовываются с использованием логарифмов (вторая панель), затем вычисляются сезонные разницы (третья панель). Данные по-прежнему выглядят несколько нестационарными, и поэтому вычисляется еще много первых разниц (нижняя панель).

```
PBS %>%
  filter(ATC2 == "H02") %>%
  summarise(Cost = sum(Cost)/1e6) %>%
  transmute(
    `Продажи (млн $)` = Cost,
    `Логарифм продаж` = log(Cost),
    `Ежегодное изменение в логарифме продаж` = difference(log(Cost), 12),
    `Дважды дифференцированный логарифм продаж` =
                    difference(difference(log(Cost), 12), 1)
  ) %>%
  pivot_longer(-Month, names_to="Type", values_to="Sales") %>%
  mutate(
    Type = factor(Type, levels = c(
      "Продажи (млн $)",
```

```
    "Логарифм продаж",
    "Ежегодное изменение в логарифме продаж",
    "Дважды дифференцированный логарифм продаж"))
) %>%
ggplot(aes(x = Month, y = Sales)) +
geom_line() +
facet_grid(vars(Type), scales = "free_y") +
labs(title = "Продажи кортикостероидных препаратов", y = NULL)
```

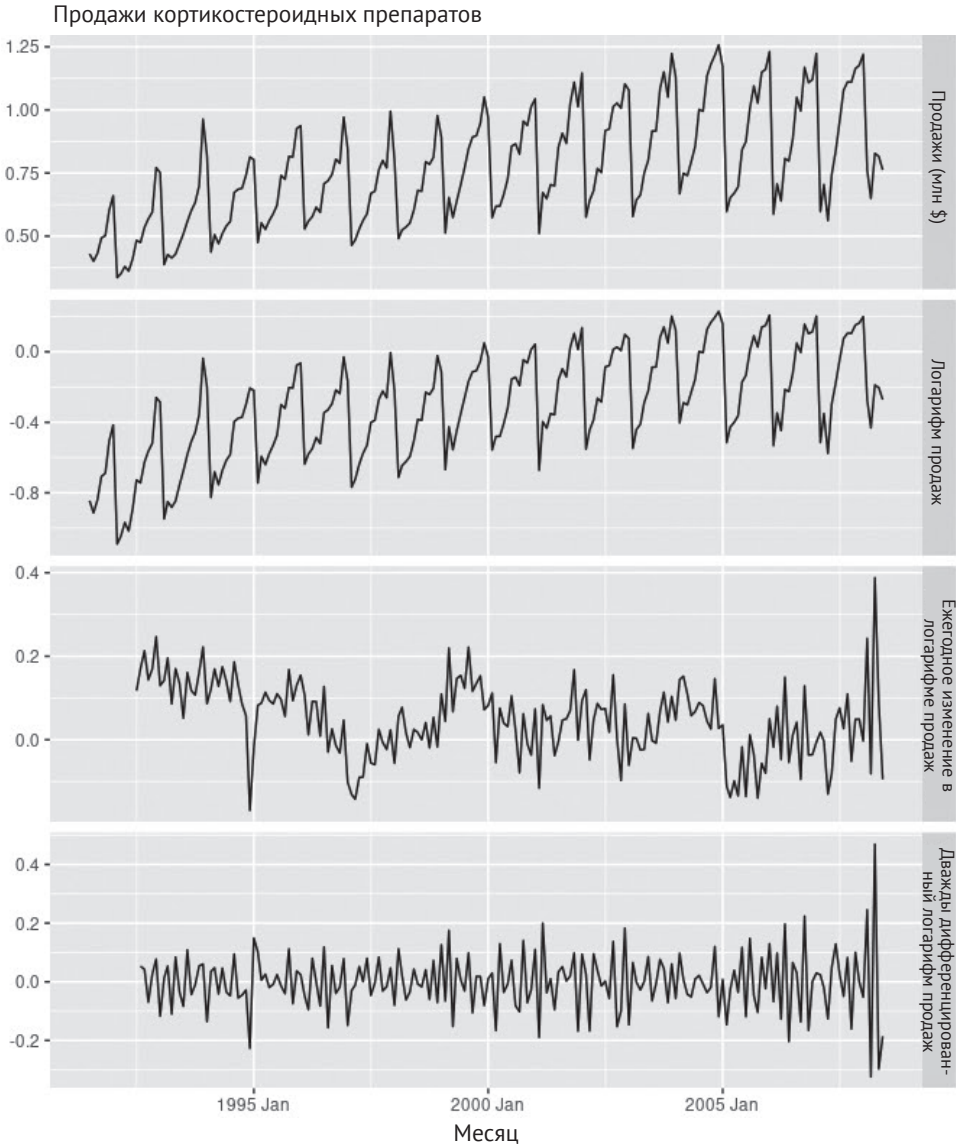


**Рисунок 9.4:** Верхняя панель: продажи кортикостероидных препаратов (австралийский доллар). Другие панели показывают те же данные после преобразования и дифференцирования

При отборе того, какие разницы следует применять, существует определенная степень субъективности. Сезонно дифференцированные данные на рис. 9.3 не демонстрируют поведение, существенно отличающееся от сезонно дифференцированных данных на рис. 9.4. В последнем случае мы могли бы решить остановиться на сезонно дифференцированных данных и не проводить дополнительный раунд дифференцирования. В первом случае мы могли бы решить, что данные недостаточно стационарны, и провести дополнительный раунд дифференцирования. Некоторые формальные тесты на дифференцирование обсуждаются ниже, но в процессе моделирования всегда необходимо делать какой-то выбор, и разные аналитики могут выбирать разные варианты.

Если $y'_t = y_t - y_{t-m}$ обозначает сезонно дифференцированный ряд, тогда дважды дифференцированный ряд равен

$$\begin{aligned} y''_t &= y'_t - y'_{t-1} = (y_t - y_{t-m}) - (y_{t-1} - y_{t-m-1}) \\ &= y_t - y_{t-1} - y_{t-m} + y_{t-m-1}. \end{aligned}$$

Когда применяются как сезонные, так и первые разницы, не имеет значения, что делается первым – результат будет одинаковым. Однако если данные имеют сильную сезонную закономерность, то мы рекомендуем сначала провести сезонное дифференцирование, поскольку результирующий ряд иногда будет стационарным и в дальнейшем первом дифференцировании не будет необходимости. Если сначала будет произведено первое дифференцирование, то сезонность все равно будет присутствовать.

Имейте в виду, что применение большего числа разниц, чем требуется, приведет к ложной динамике или автокорреляциям, которых на самом деле во временном ряде не существует. Поэтому, для того чтобы получить стационарный ряд, берите как можно меньше разниц.

Важно, чтобы при использовании дифференцирования разницы были интерпретируемыми. Первые разницы – это изменение между одним наблюдением и следующим. Сезонные разницы – это изменение от одного года к другому. Другие лаги вряд ли будут иметь много интерпретируемого смысла, и их следует избегать.

## Тесты на единичные корни

Один из способов более объективно определить необходимость в дифференцировании состоит в применении *теста на единичный корень*. Это статистические проверки гипотез в отношении стационарности, которые предназначены для определения необходимости в дифференцировании.

Имеется несколько тестов на единичный корень, которые основаны на разных допущениях и могут приводить к конфликтующим ответам. В нашем анализе мы используем тест Квятковского–Филлипса–Шмидта–Шина (KPSS) (Квятковский и соавт., 1992, *https://otexts.com/fpp3/stationarity.html#ref-KPSS92*). В этом тесте нулевая гипотеза заключается в том, что данные являются стационарными, и мы ищем доказательства того, что нулевая гипотеза ложна. Следовательно, малые $p$-значения (например, менее 0.05) предполагают, что требуется дифференцирование. Указанный тест можно вычислить с помощью функции `unitroot_kpss()`.

Например, давайте применим его к данным о ценах акций Google.

```
google_2015 %>%
  features(Close, unitroot_kpss)
#> # A tibble: 1 × 3
#>   Symbol kpss_stat kpss_pvalue
#>   <chr>      <dbl>       <dbl>
#> 1 GOOG        3.56        0.01
```

*p*-значение указывается как 0.01, если оно меньше 0.01, и как 0.1, если оно больше 0.1. В данном случае статистика (3.56) теста больше критического значения на 1 %, поэтому *p*-значение меньше 0.01, указывая на то, что нулевая гипотеза отклонена. То есть данные не являются стационарными. Можно дифференцировать данные и снова применить тест.

```
google_2015 %>%
  mutate(diff_close = difference(Close)) %>%
  features(diff_close, unitroot_kpss)
#> # A tibble: 1 × 3
#>   Symbol kpss_stat kpss_pvalue
#>   <chr>      <dbl>       <dbl>
#> 1 GOOG      0.0989         0.1
```

На этот раз статистика теста невелика и находится в пределах диапазона, который мы ожидали бы для стационарных данных, поэтому *p*-значение больше 0.1, и можно сделать вывод о том, что дифференцированные данные выглядят стационарными.

Указанный процесс использования последовательности тестов KPSS для определения подходящего числа первых разниц выполняется с помощью функции `unitroot_ndiffs()`.

```
google_2015 %>%
  features(Close, unitroot_ndiffs)
#> # A tibble: 1 × 2
#>   Symbol ndiffs
#>   <chr>   <int>
#> 1 GOOG        1
```

Как мы увидели из приведенных выше тестов KPSS, для того чтобы сделать данные `google_2015` стационарными, требуется одна разница.

Аналогичным средством определения необходимости сезонного дифференцирования является функция `unitroot_nsdiffs()`, которая использует меру сезонной силы, введенную в разделе 4.3, для определения подходящего числа требуемых сезонных разниц. Никаких сезонных разниц не предполагается, если $F_S < 0.64$, в противном случае предполагается одна сезонная разница.

Функцию `unitroot_nsdiffs()` можно применить к суммарному месячному розничному обороту в Австралии.

```
aus_total_retail <- aus_retail %>%
  summarise(Turnover = sum(Turnover))
aus_total_retail %>%
  mutate(log_turnover = log(Turnover)) %>%
  features(log_turnover, unitroot_nsdiffs)
#> # A tibble: 1 × 1
#>   nsdiffs
#>     <int>
#> 1       1

aus_total_retail %>%
  mutate(log_turnover = difference(log(Turnover), 12)) %>%
  features(log_turnover, unitroot_ndiffs)
#> # A tibble: 1 × 1
#>   ndiffs
#>    <int>
#> 1      1
```

Поскольку функция `unitroot_nsdiffs()` возвращает 1 (указывая на то, что требуется одна сезонная разница), мы применяем функцию `unitroot_diffs()` к сезонно дифференцированным данным. Указанные функции предполагают, что мы должны использовать как сезонную разницу, так и первую разницу.

## Библиография

*Квятковский Д., Филлипс П. К. Б., Шмидт П. и Шин Ю.* (1992). Проверка нулевой гипотезы стационарности в сопоставлении с альтернативой в виде единичного корня: насколько мы уверены, что экономические временные ряды имеют единичный корень? Journal of Econometrics, 54 (1–3), 159–178. [DOI: https://doi.org/10.1016/0304-4076(92)90104-Y].

# 9.2 Нотация обратного сдвига

Оператор обратного сдвига ***B*** является полезным средством обозначения при работе с лагами временных рядов:

$$By_t = y_{t-1}.$$

(В некоторых справочных материалах используется символ ***L***, от англ. «lag», т. е. «отставание, запаздывание», вместо ***B***, от англ. «backshift», т. е. обратный сдвиг, сдвиг назад.) Другими словами, ***B***, оперируя на $y_t$, приводит к сдвигу данных на один период назад. Два применения ***B*** к $y_t$ сдвигают данные на два периода назад:

$$B(By_t) = B^2y_t = y_{t-2}.$$

Если мы хотим рассмотреть «тот же месяц в прошлом году» для ежемесячных данных, то нотация будет такова:

$$B^{12}y_t = y_{t-12}.$$

Оператор обратного сдвига удобен для описания процесса дифференцирования. Первую разницу можно записать как

$$y_t' = y_t - y_{t-1} = y_t - By_t = (1-B)y_t.$$

Таким образом, первую разницу можно представить с помощью $(1 - B)$. Аналогичным образом, если необходимо вычислить разницы второго порядка, то

$$y_t'' = y_t - 2y_{t-1} + y_{t-2} = (1-2B+B^2)y_t = (1-B)^2 y_t.$$

В общем случае разницу $d$-го порядка можно записать как

$$(1 - B)^d y_t.$$

Нотация обратного сдвига особенно полезна при комбинировании разниц, поскольку указанный оператор может обрабатываться с использованием обычных алгебраических правил. В частности, члены, включающие $\boldsymbol{B}$, можно перемножать.

Например, сезонную разницу, за которой следует первая разница, можно записать как

$$(1-B)(1-B^m)y_t == (1-B-B^m+B^{m+1})y_t = y_t - y_{t-1} - y_{t-m} + y_{t-m-1}$$

и получить тот же результат, который мы получили ранее.

## 9.3 Авторегрессионные модели

В модели множественной регрессии, представленной в главе 7, мы прогнозируем интересующую нас переменную, используя линейную комбинацию предсказателей. В модели авторегрессии мы прогнозируем интересующую нас переменную, используя линейную комбинацию прошлых значений переменной. Термин «авторегрессия» указывает на то, что это регрессия переменной в сопоставлении с самой собой.

Таким образом, авторегрессионную модель порядка $p$ можно записать как

$$y_t = c + \phi_1 y_{t-1} + \phi_2 y_{t-2} + \cdots + \phi_p y_{t-p} + \varepsilon_t,$$

где $\varepsilon_t$ – это белый шум. Она похожа на множественную регрессию, но с лагированными значениями переменной $y_t$ в качестве предсказателей. Мы называем ее **моделью AR($p$)**, авторегрессионной моделью порядка $p$.

Авторегрессионные модели обладают поразительной гибкостью при обработке широкого спектра разных закономерностей временных рядов. Два ряда на рис. 9.5 показывают ряды из модели AR(1) и модели AR(2). Изменение параметров $\phi_1$, ... $\phi_2$ приводит к разным закономерностям временных рядов. Дисперсия члена ошибки $\varepsilon_t$ будет изменять только шкалу ряда, а не закономерности.

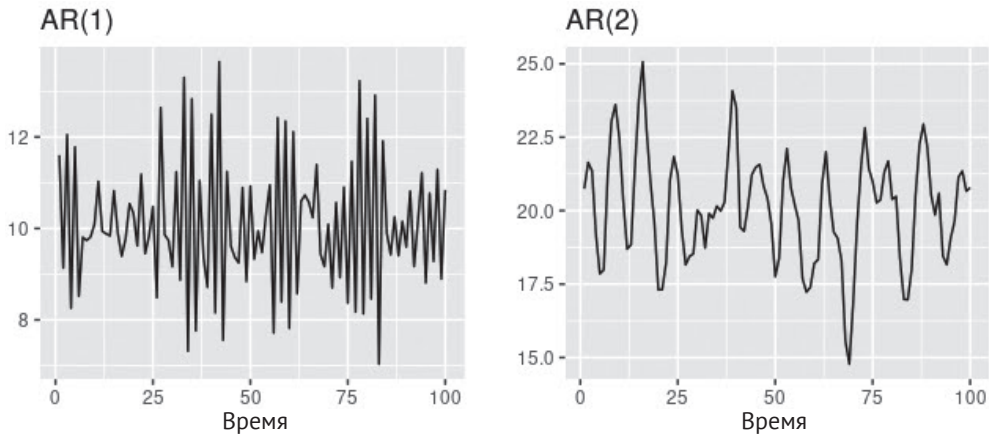


**Рисунок 9.5:** Два примера данных из авторегрессионных моделей с разными параметрами. Слева: AR(1) с $y_t = 18 - 0.8y_{t-1} + \varepsilon_t$. Справа: AR(2) с $y_t = 8 + 1.3y_{t-1} - 0.7y_{t-2} + \varepsilon_t$. В обоих случаях $\varepsilon_t$ – это нормально распределенный белый шум со средним значением, равным нулю, и дисперсией, равной единице

Для модели AR(1):

- когда $\phi_1 = 0$ и $c = 0$, $y_t$ эквивалентна белому шуму;
- когда $\phi_1 = 1$ и $c = 0$, $y_t$ эквивалентна случайному блужданию;
- когда $\phi_1 = 1$и $c \neq 0$, $y_t$ эквивалентна случайному блужданию с дрейфом;
- когда $\phi_1 < 0$, $y_t$ тяготеет к осциллированию вокруг среднего значения.

Обычно мы ограничиваем авторегрессионные модели стационарными данными, и в этом случае требуются некоторые ограничения на значения параметров.

- Для модели AR(1): $-0 < \phi_1 < 1$.
- Для модели AR(2): $-1 < \phi_2 < 1$, $\phi_1 + \phi_2 < 1$, $\phi_2 - \phi_1 < 1$.

При p ⩾ 3 ограничения намного сложнее. Пакет fable позаботится об этих ограничениях при оценивании модели.

## 9.4 Модели скользящих средних

Вместо того чтобы использовать прошлые значения прогнозной переменной в регрессии, модель скользящего среднего применяет прошлые прогнозные ошибки в регрессионно-подобной модели:

$$y_t = c + \varepsilon_t + \varepsilon_1\varepsilon_{t-1} + \theta_2\varepsilon_{t-2} + \cdots + \theta_q\varepsilon_{t-q},$$

где $\varepsilon_t$ – это белый шум. Такая модель называется моделью **MA(*q*)**, моделью скользящего среднего порядка $q$. Разумеется, мы не наблюдаем значения $\varepsilon_t$, так что на самом деле это не регрессия в обычном смысле.

Обратите внимание, что каждое значение $y_t$ можно рассматривать как взвешенное скользящее среднее за последние несколько прогнозных ошибок (хотя коэффициенты в сумме обычно не составляют единицу). Однако модели

скользящих средних не следует путать со сглаживанием скользящих средних, которое мы обсуждали в главе 3. Модель скользящего среднего используется для прогнозирования будущих значений, в то время как сглаживание скользящего среднего используется для оценивания трендового цикла прошлых значений.

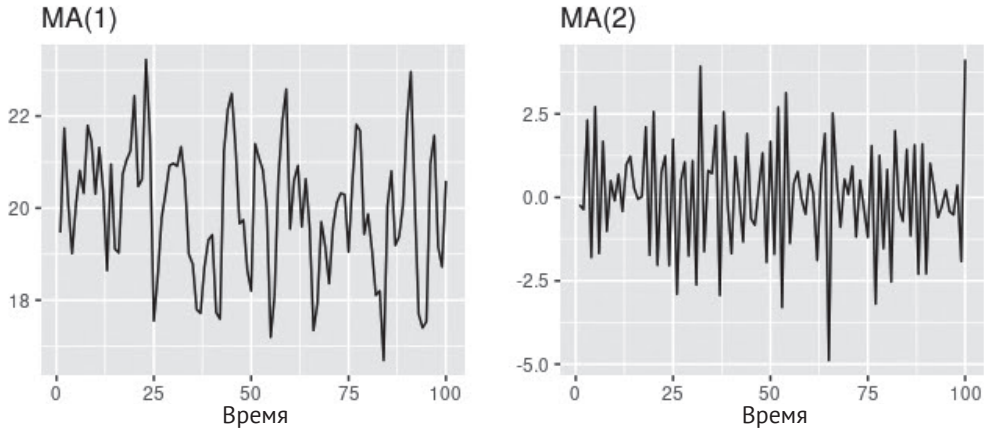


**Рисунок 9.6:** Два примера данных из моделей скользящих средних с разными параметрами. Слева: MA(1) с $y_t = 20 + \varepsilon_t + 0.8\varepsilon_{t-1}$. Справа: MA(2) с $y_t = \varepsilon_t - \varepsilon_{t-1} + 0.8\varepsilon_{t-2}$. В обоих случаях $\varepsilon_t$ – это нормально распределенный белый шум со средним значением, равным нулю, и дисперсией, равной единице

На рис. 9.6 показано немного данных из модели MA(1) и модели MA(2). Изменение параметров $\theta_1, \ldots, \theta_q$ приводит к разным закономерностям временных рядов. Как и в случае с авторегрессионными моделями, дисперсия члена ошибки $\varepsilon_t$ будет изменять только шкалу ряда, а не закономерности.

Любую стационарную модель AR($p$) можно записать в качестве модели MA($\infty$). Например, используя повторную подстановку, можно продемонстрировать это для модели AR(1):

$$y_t == \phi_1 y_{t-1} + \varepsilon_t = \phi_1\left(\phi_1 y_{t-2} + \varepsilon_{t-1}\right) + \varepsilon_t = \phi_1^2 y_{t-2} + \phi_1\varepsilon_{t-1} + \varepsilon_t = \phi_1^3 y_{t-3} + \phi_1^2\varepsilon_{t-2} + \phi_1\varepsilon_{t-1} + \varepsilon_t.$$

При условии что $-1 < \phi_1 < 1$, значение $\phi_1^k$ будет уменьшаться по мере увеличения $k$. Таким образом, в конечном итоге мы получаем

$$y_t = \varepsilon_t + \phi_1\varepsilon_{t-1} + \phi_1^2\varepsilon_{t-2} + \phi_1^3\varepsilon_{t-3} + \cdots,$$

процесс MA($\infty$).

Обратный результат соблюдается, если мы наложим некоторые ограничения на параметры MA. Тогда модель MA называется **обратимой**. То есть любой обратимый процесс MA($q$) можно записать как процесс AR($\infty$). Обратимые модели вводятся не просто для того, чтобы иметь возможность перейти от моделей MA к моделям AR. Они также обладают некоторыми желательными математическими свойствами.

Например, рассмотрим процесс MA(1), $y_t = \varepsilon_t + \theta_1 \varepsilon_{t-1}$. В его AP(∞)-представлении самую последнюю ошибку можно записать как линейную функцию текущих и прошлых наблюдений:

$$\varepsilon_t = \sum_{j=0}^{\infty} (-\theta_1)^j y_{t-j}.$$

При $|\theta_1| > 1$ веса увеличиваются по мере увеличения лагов, поэтому чем дальше наблюдения, тем больше их влияние на текущую ошибку. При $|\theta_1| = 1$ веса постоянны по размеру, и отдаленные наблюдения оказывают такое же влияние, как и недавние наблюдения. Поскольку ни одна из этих ситуаций не имеет особого смысла, нам требуется $|\theta_1| < 1$, поэтому самые последние наблюдения имеют больший вес, чем наблюдения из более отдаленного прошлого. Таким образом, процесс обратим при $|\theta_1| < 1$.

Ограничения обратимости для других моделей аналогичны ограничениям стационарности.

- Для модели MA(1): $-1 < |\theta_1| < 1$.
- Для модели MA(2): $-1 < |\theta_2| < 1$, $\theta_2 + \theta_1 > -1$, $\theta_1 - \theta_2 < 1$.

Более сложные условия соблюдаются для $q \geqslant 3$. Опять же, пакет fable позаботится об этих ограничениях при оценивании моделей.

## 9.5 Несезонные модели ARIMA

Если скомбинировать дифференцирование с авторегрессией и моделью скользящего среднего, то мы получим несезонную модель ARIMA. ARIMA – это аббревиатура от англ. AutoRegressive Integrated Moving Averagea, т. е. авторегрессионного интегрированного скользящего среднего (в данном контексте «интеграция» – это обратное дифференцирование). Полную модель можно записать как

$$y_t' = c + \phi_1 y_{t-1}' + \cdots + \phi_p y_{t-p}' + \theta_1 \varepsilon_{t-1} + \cdots + \theta_q \varepsilon_{t-q} + \varepsilon_t, \tag{9.1}$$

где $y_t'$ – это дифференцированный ряд (возможно, он был дифференцирован более одного раза). «Предсказатели» в правой части включают как лагированные значения $y_t$, так и лагированные ошибки. Мы называем это моделью ARIMA($p$,$d$,$q$), где

$p$ = порядок авторегрессионной части;
$d$ = порядок участвующего первого дифференцирования;
$q$ = порядок части со скользящим средним.

Те же условия стационарности и обратимости, которые используются для моделей авторегрессии и скользящего среднего, применимы и к модели ARIMA.

Многие обсуждавшиеся нами модели являются частными случаями модели ARIMA, как показано в табл. 9.1.

**Таблица 9.1:** Частные случаи моделей ARIMA

| | |
|---|---|
| Белый шум | ARIMA(0,0,0) без константы |
| Случайное блуждание | ARIMA(0,1,0) без константы |
| Случайное блуждание с дрейфом | ARIMA(0,1,0) с константой |
| Авторегрессия | ARIMA(p,0,0) |
| Скользящее среднее | ARIMA(0,0,q) |

Как только мы начнем комбинировать компоненты в таком ключе с целью формирования более сложных моделей, работать с нотацией обратного сдвига станет намного проще. Например, уравнение (9.1) можно записать в нотации обратного сдвига как

$$\underset{\uparrow}{\left(1-\phi_1 B-\cdots-\phi_p B^p\right)}\ \underset{\uparrow}{(1-B)^d y_t}\ =\ c+\underset{\uparrow}{\left(1+\theta_1 B+\cdots+\theta_q B^q\right)}\varepsilon_t, \tag{9.2}$$

$$\text{AR}(p) \qquad d \text{ разниц} \qquad \text{MA}(q)$$

Выбор подходящих значений для $p$, $d$ и $q$ бывает затруднен. Однако функция `ARIMA()` из пакета fable сделает это за вас автоматически. В разделе 9.7 мы узнаем, как эта функция работает, а также о некоторых методах самостоятельного выбора этих значений.

## Пример: экспорт из Египта

На рис. 9.7 показан экспорт из Египта в процентах от ВВП с 1960 по 2017 год.

```
global_economy %>%
  filter(Code == "EGY") %>%
  autoplot(Exports) +
  labs(y = "% от ВВП", title = "Экспорт из Египта")
```

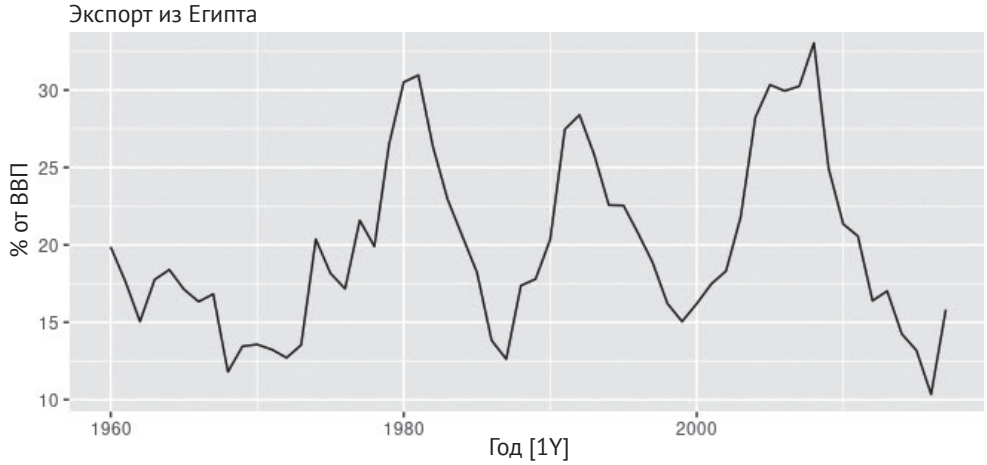


**Рисунок 9.7:** Ежегодный экспорт из Египта в процентах от ВВП с 1960 года

Следующий ниже исходный код R отбирает несезонную модель ARIMA автоматически.

```
fit <- global_economy %>%
  filter(Code == "EGY") %>%
  model(ARIMA(Exports))
report(fit)
#> Series: Exports
#> Model: ARIMA(2,0,1) w/ mean
#>
#> Coefficients:
#>          ar1      ar2      ma1  constant
#>       1.6764  -0.8034  -0.6896    2.5623
#> s.e.  0.1111   0.0928   0.1492    0.1161
#>
#> sigma^2 estimated as 8.046:  log likelihood=-141.6
#> AIC=293.1   AICc=294.3   BIC=303.4
```

Это модель ARIMA(2, 0, 1):

$$y_t = 2.56 + 1.68y_{t-1} - 0.80y_{t-2} - 0.69\varepsilon_{t-1} + \varepsilon_t,$$

где $\varepsilon_t$ – это белый шум со стандартным отклонением, равным $2.837 = \sqrt{8.046}$. Основанные на модели прогнозы показаны на рис. 9.8. Обратите внимание, как они отражают циклы, очевидные в египетской экономике за последние несколько десятилетий.

```
fit %>% forecast(h=10) %>%
  autoplot(global_economy) +
  labs(y = "% от ВВП", title = "Экспорт из Египта")
```

**Рисунок 9.8:** Прогнозы экспорта из Египта

## Понимание моделей ARIMA

Функция `ARIMA()` имеет широкое применение на практике, но все автоматизированное бывает чуточку опасным, и стоит немного разобраться в поведении моделей, даже если вы полагаетесь на автоматическую процедуру выбора модели за вас.

Константа $c$ оказывает важное влияние на долгосрочные прогнозы, получаемые из этих моделей.

- Если $c = 0$ и $d = 0$, то долгосрочные прогнозы будут равны нулю.
- Если $c = 0$ и $d = 1$, то долгосрочные прогнозы перейдут к ненулевой константе.
- Если $c = 0$ и $d = 2$, то долгосрочные прогнозы будут следовать прямой линии.
- Если $c \approx 0$ и $d = 0$, то долгосрочные прогнозы будут соответствовать среднему значению данных.
- Если $c \neq 0$ и $d = 1$, то долгосрочные прогнозы будут следовать прямой линии.
- Если $c \neq 0$ и $d = 2$, то долгосрочные прогнозы будут следовать квадратичному тренду. (Это не рекомендуется, и fable этого не допустит.)

Значение $d$ также влияет на предсказательные интервалы: чем выше значение $d$, тем быстрее увеличиваются предсказательные интервалы. Для $d = 0$ стандартное отклонение долгосрочного прогноза будет равно стандартному отклонению исторических данных, поэтому все предсказательные интервалы будут по существу одинаковыми.

Такое поведение показано на рис. 9.8, где $d = 0$ и $c \neq 0$. На этом рисунке предсказательные интервалы имеют почти одинаковую ширину для последних нескольких прогнозных горизонтов, а прогнозы конечных точек близки к среднему значению данных.

Значение $p$ имеет важность, если данные показывают циклы. Для получения циклических прогнозов необходимо иметь $p \geqslant 2$ наряду с некоторыми дополнительными условиями в отношении параметров. Для модели AR(2) циклическое поведение возникает, если $\phi_1^2 + 4\phi_2 < 0$ (как и в случае с моделью экспорта из Египта). В данном случае средний период циклов составляет[1]

$$\frac{2\pi}{\arccos\left(-\phi_1\left(1-\phi_2\right)/\left(4\phi_2\right)\right)}.$$

## Графики ACF и PACF

Обычно просто по графику времени невозможно определить, какие значения $p$ и $q$ подходят для данных. Однако для определения подходящих значений для $p$ и $q$ иногда можно использовать график ACF и тесно связанный график PACF.

Напомним, что график ACF показывает автокорреляции, которые измеряют взаимосвязь между $y_t$ и $y_{t-k}$ для разных значений $k$. Теперь если $y_t$ и $y_{t-1}$ коррелируются, тогда $y_{t-1}$ и $y_{t-2}$ тоже должны коррелироваться. Однако тогда $y_t$ и $y_{t-2}$ могут коррелироваться просто потому, что они обе связаны с $y_{t-1}$, а не из-за

[1] *arccos* – это обратная косинусная функция. Он должна быть у вас на вашем калькуляторе. Она может быть помечена как *acos* или $cos^{-1}$.

какой-либо новой информации, содержащейся в $y_{t-2}$, которую можно было бы использовать при прогнозировании $y_t$.

В целях преодоления этой проблемы можно использовать **частичные автокорреляции**. Они измеряют взаимосвязь между $y_t$ и $y_{t-k}$ после устранения последствий лагов 1, 2, 3, … , $k$ – 1. Таким образом, первая частичная автокорреляция идентична первой автокорреляции, потому что между ними нет ничего, что можно было бы удалить. Каждую частичную автокорреляцию можно оценить, как последний коэффициент в авторегрессионной модели. В частности, $\alpha_k$, $k$-й частичный коэффициент автокорреляции, равен оценке $\phi_k$ в модели AR($k$). На практике существуют более эффективные алгоритмы вычисления $\alpha_k$, чем подгонка всех этих авторегрессий, но они дают те же результаты.

На рис. 9.9 и 9.10 показаны графики ACF и PACF для данных экспорта из Египта, представленных на рис. 9.7. Частичные автокорреляции имеют те же критические значения $\pm 1.96/\sqrt{T}$, как для обычных автокорреляций, и они обычно показываются на графике, как на рис. 9.10.

```
global_economy %>%
  filter(Code == "EGY") %>%
  ACF(Exports) %>%
  autoplot()
```

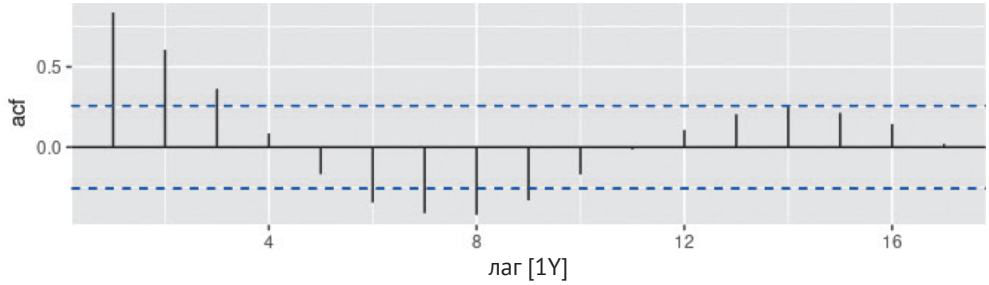


**Рисунок 9.9:** ACF экспорта из Египта

```
global_economy %>%
  filter(Code == "EGY") %>%
  PACF(Exports) %>%
  autoplot()
```

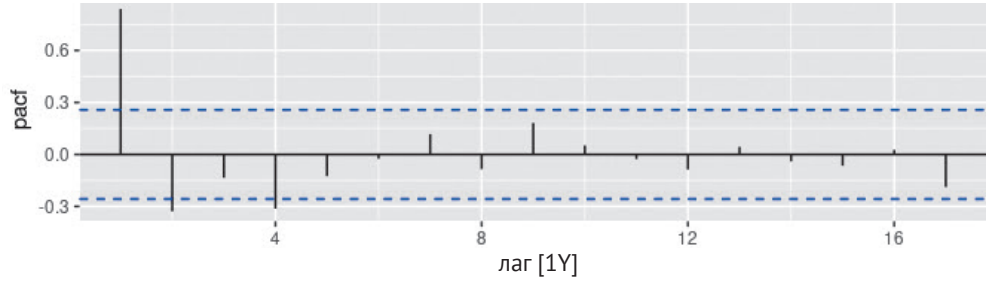


**Рисунок 9.10:** PACF экспорта из Египта

Удобным способом создания графика времени, графика ACF и графика PACF в одной команде является использование функции `gg_tsdisplay()` с аргументом `plot_type = "partial"`.

Если данные получены из модели ARIMA($p$, $d$, 0) или ARIMA(0, $d$, $q$), то графики ACF и PACF могут быть полезны при определении значения $p$ или $q$. Если и $p$, и $q$ оба положительны, то в отыскании подходящих значений $p$ и $q$ эти графики не помогают.

Данные могут следовать модели ARIMA($p$, $d$, 0), если графики ACF и PACF дифференцированных данных показывают следующие ниже закономерности:

- ACF является экспоненциально затухающим или синусоидальным;
- наблюдается значительный всплеск в лаге $p$ на PACF, но ни один из них не выходит за пределы лага $p$.

Данные могут следовать модели ARIMA(0, $d$, $q$), если графики ACF и PACF дифференцированных данных показывают следующие ниже закономерности:

- PACF является экспоненциально затухающим или синусоидальным;
- наблюдается значительный всплеск в лаге $q$ на ACF, но ни один из них не выходит за пределы лага $q$.

На рис. 9.9 мы видим, что на ACF наблюдается затухающая синусоидальная закономерность, а на рис. 9.10 PACF показывает последний значительный всплеск в лаге 4. Это то, что можно было бы ожидать от модели ARIMA(4, 0, 0).

```
fit2 <- global_economy %>%
  filter(Code == "EGY") %>%
  model(ARIMA(Exports ~ pdq(4,0,0)))
report(fit2)
#> Series: Exports
#> Model: ARIMA(4,0,0) w/ mean
#>
#> Coefficients:
#>          ar1      ar2     ar3      ar4  constant
#>       0.9861  -0.1715  0.1807  -0.3283    6.6922
#> s.e.  0.1247   0.1865  0.1865   0.1273    0.3562
#>
#> sigma^2 estimated as 7.885:  log likelihood=-140.5
#> AIC=293.1   AICc=294.7   BIC=305.4
```

Эта модель лишь немного хуже, чем модель ARIMA(2, 0, 1), определенная функцией `ARIMA()` (со значением AICc 294.70 по сравнению с 294.29).

Мы также можем указать конкретные значения `pdq()`, которые `ARIMA()` может искать. Например, для отыскания наилучшей модели ARIMA с $p \in \{1, 2, 3\}$, $q \in \{0, 1, 2\}$ и $d = 1$ вы могли бы применить *ARIMA*($y$ ~ *pdq*($p$ = 1:3, $d$ = 1, $q$ = 0:2)).

# 9.6 Оценивание и выбор порядка

## Оценивание максимального правдоподобия

После того как будет определен порядок модели (т. е. значения $p$, $d$ и $q$), необходимо оценить параметры $c$, $\phi_1, \ldots, \phi_p$ и $\theta_1, \ldots, \theta_q$. Когда fable оценивает модель ARIMA, он использует метод оценивания максимального правдоподобия (maximum likelihood estimation, аббр. MLE). Указанный метод находит значения параметров, которые максимизируют вероятность получения наблюдавшихся нами данных. Для моделей ARIMA оценки MLE аналогичны оценкам по методу наименьших квадратов, которые были бы получены путем минимизирования

$$\sum_{t=1}^{T} \varepsilon_t^2 .$$

(Для регрессионных моделей, рассмотренных в главе 7, MLE дает точно такие же оценки параметров, что и оценивание методом наименьших квадратов.) Обратите внимание, что оценивать модели ARIMA намного сложнее, чем регрессионные модели, и разные программы будут давать несколько отличающиеся ответы, поскольку в них используются разные методы оценивания и разные алгоритмы оптимизации.

На практике пакет fable будет сообщать значение *логарифмического правдоподобия* данных; то есть логарифм вероятности будет наблюдать данные, поступающие из оцененной модели. Для заданных значений $p$, $d$ и $q$ функция `ARIMA()` попытается максимизировать логарифмическое правдоподобие при отыскании оценок параметров.

## Информационные критерии

Информационный критерий Акаике (AIC), который был полезен при отборе предсказателей для регрессии (см. раздел 7.5), также полезен для определения порядка модели ARIMA. Его можно записать как

$$\text{AIC} = -2\log(L) + 2(p + q + k + 1),$$

где $L$ – это правдоподобие данных, $k = 1$, если $c \neq 0$, и $k = 0$, если $c = 0$. Обратите внимание, что последний член в круглых скобках – это число параметров в модели (включая $\sigma^2$, дисперсию остатков).

Для моделей ARIMA скорректированный AIC можно записать как

$$\text{AICc} = \text{AIC} + \frac{2(p+q+k+1)(p+q+k+2)}{T-p-q-k-2},$$

и байесов информационный критерий можно записать как

$$\text{BIC} = \text{AIC} + \left[\log(T) - 2\right](p+q+k+1).$$

Хорошие модели получаются путем минимизирования критериев AIC, AICc или BIC. Мы предпочитаем использовать критерий AICc.

Важно отметить, что указанные информационные критерии, как правило, не являются хорошими ориентирами для отбора подходящего порядка дифференцирования ($d$) модели, а только для отбора значений $p$ и $q$. Это обусловлено тем, что дифференцирование изменяет данные, на которых вычисляется правдоподобие, делая значения AIC между моделями с разными порядками дифференцирования несопоставимыми. Поэтому для выбора $d$ необходимо использовать какой-то другой подход, а затем можно использовать AICc для отбора $p$ и $q$.

# 9.7 Моделирование ARIMA в fable

## Как работает функция ARIMA()?

В функции `ARIMA()` пакета fable используется вариация алгоритма Хайндмана–Хандакара (Хайндман и Хандакар, 2008, *https://otexts.com/fpp3/arima-r.html#ref-HK08*), который для получения модели ARIMA комбинирует тесты на единичный корень, минимизацию AICc и MLE-оценивание. Аргументы функции `ARIMA()` предусматривают многочисленные варианты алгоритма. То, что описано ниже, является поведением, принятым по умолчанию.

Алгоритм Хайндмана–Хандакара для автоматического моделирования ARIMA:

1. Число разниц $0 \le d \le 2$ определяется с использованием повторных тестов KPSS.
2. Значения $p$ и $q$ затем выбираются путем минимизирования AICc после дифференцирования данных $d$ раз. Вместо того чтобы рассматривать все возможные комбинации $p$ и $q$, алгоритм использует пошаговый поиск с целью обхода модельного пространства.
   a) Выполняется подгонка четырех начальных моделей:
      - ARIMA(0, $d$, 0),
      - ARIMA(0, $d$, 0),
      - ARIMA(2, $d$, 2),
      - ARIMA(1, $d$, 0),
      - ARIMA(0, $d$, 1).

      Константа включается, только если $d \neq 2$. Если $d \le 1$, то также выполняется подгонка дополнительной модели:
      - ARIMA(0, $d$, 0) без константы.

   b) Наилучшая модель (с наименьшим значением AICc), подогнанная на шаге (a), устанавливается как «текущая модель».
   c) Рассматриваются вариации текущей модели:
      - варьировать $p$ и/или $q$ из текущей модели на $\pm 1$;
      - включить/исключить $c$ из текущей модели.

      Рассмотренная на данный момент наилучшая модель (либо текущая модель, либо одна из этих вариаций) становится новой текущей моделью.
   d) Повторять шаг 2(c) до тех пор, пока не будет найден более низкий AICc.

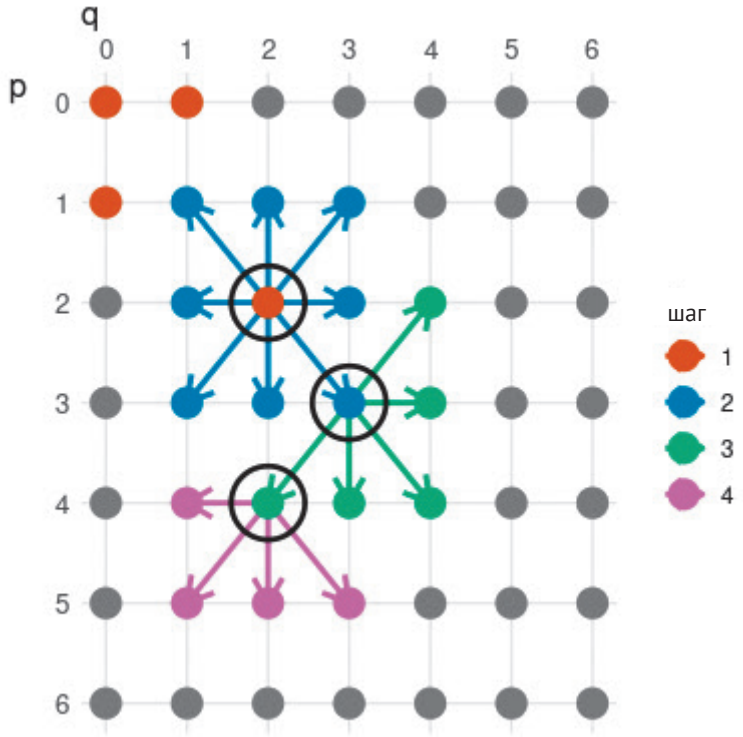


**Рисунок 9.11:** Наглядный пример пошагового процесса поиска Хайндмана–Хандакара

На рис. 9.11 схематически показано, как алгоритм Хайндмана–Хандакара выполняет обход пространства порядков ARMA, на примере. Решетка охватывает комбинации порядков ARMA($p$, $q$), начинающиеся с верхнего левого угла с ARMA(0, 0), при этом порядок AR увеличивается вниз по вертикальной оси, а порядок MA увеличивается поперек по горизонтальной оси.

Оранжевые ячейки показывают начальный набор рассмотренных алгоритмом моделей. В данном примере модель ARMA(2, 2) имеет самое низкое значение AICc среди этих моделей. Она называется «текущей моделью» и показана черным кружком. Затем алгоритм выполняет поиск по соседним моделям, как показано синими стрелками. Если найдена более оптимальная модель, то она становится новой «текущей моделью». В данном примере новой «текущей моделью» является модель ARMA(3, 3). Алгоритм продолжается в таком ключе до тех пор, пока не будет найдена более оптимальная модель. В данном примере возвращаемая модель представлена моделью ARMA(4, 2).

Дефолтная процедура переключится на новую «текущую модель», как только будет идентифицирована более оптимальная модель, без просмотра всех соседних моделей. Полный поиск по окрестностям выполняется, когда задан аргумент `greedy=FALSE`.

В дефолтной процедуре также используется несколько аппроксимаций для ускорения поиска. Этих аппроксимаций можно избежать с помощью аргумента `approximation=FALSE`. Возможно, что из-за этих аппроксимаций или по причине использования пошаговой процедуры модель с минимальным AICc не будет найдена. При использовании аргумента `stepwise=FALSE` будет выполнен поиск по гораздо большему набору моделей. Полное описание аргументов см. в файле справки.

## Процедура моделирования

При подгонке модели ARIMA к набору (несезонных) данных временного ряда следующая ниже процедура обеспечивает полезный общий подход.

1. Нанести данные на график и определить любые необычные наблюдения.
2. При необходимости преобразовать данные (используя преобразование Бокса–Кокса), чтобы стабилизировать дисперсию.
3. Если данные нестационарны, то брать первые разницы данных до тех пор, пока данные не станут стационарными.
4. Проинспектировать ACF/PACF: подходит ли модель ARIMA($p$, $d$, 0) либо модель ARIMA(0, $d$, $q$)?
5. Попробовать выбранные вами модели и использовать AICc для отыскания более оптимальной модели.
6. Проверить остатки от выбранной вами модели, построив график ACF остатков и выполнив тест остатков на основе статистики портманто. Если они не похожи на белый шум, то попробовать модифицированную модель.
7. Как только остатки будут выглядеть как белый шум, рассчитать прогнозы.

Алгоритм Хайндмана–Хандакара берет на себя только шаги 3–5. И поэтому даже при его использовании вам все равно нужно будет позаботиться о других шагах самостоятельно.

Указанный процесс кратко описан на рис. 9.12.

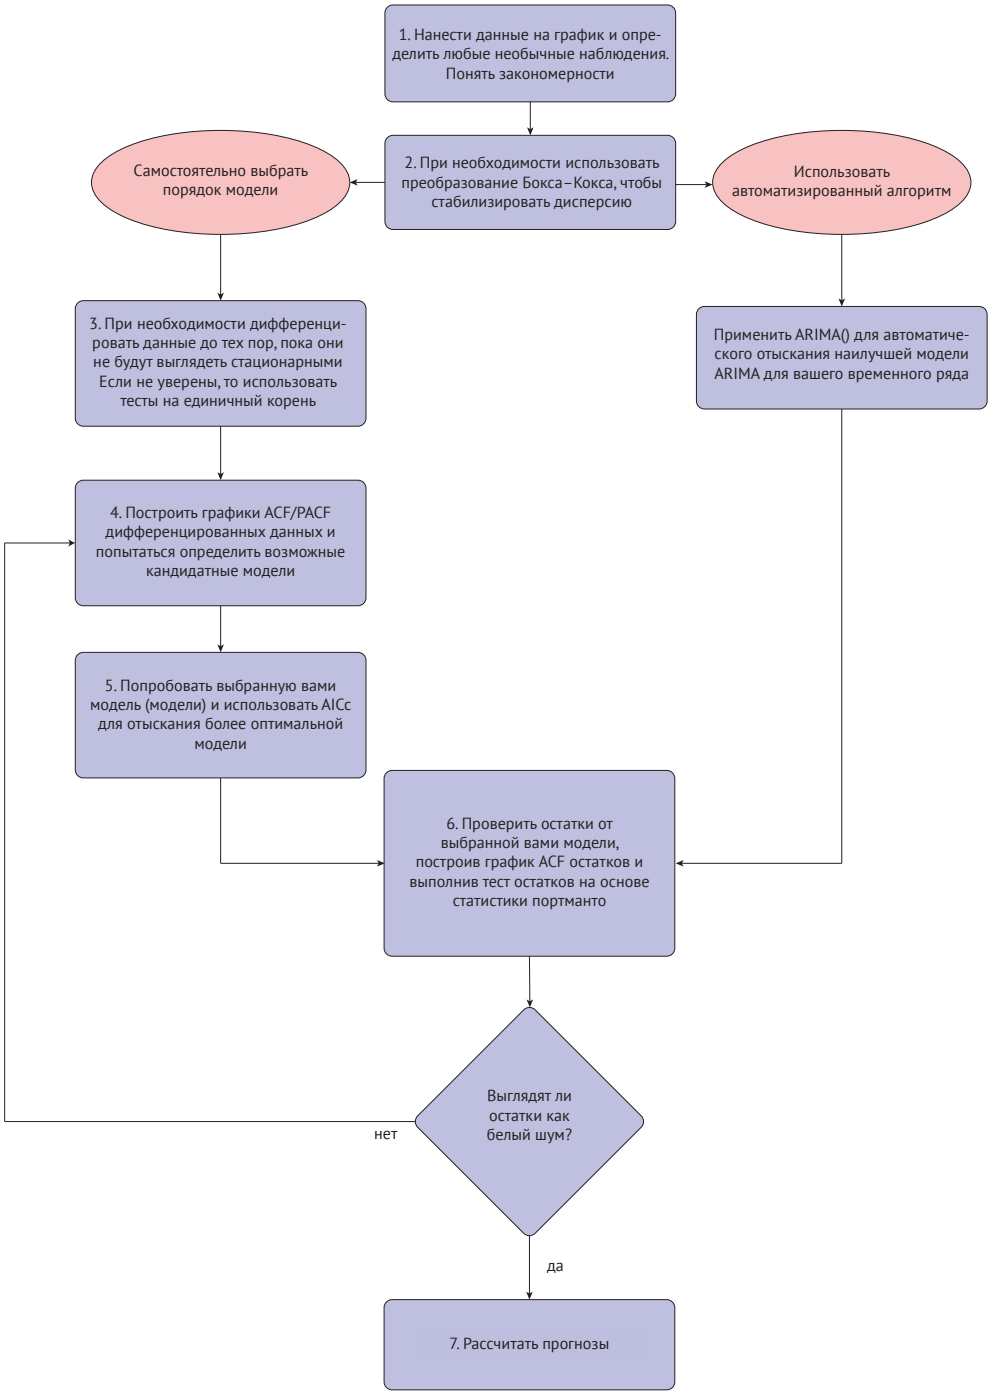


**Рисунок 9.12:** Общий процесс прогнозирования с использованием модели ARIMA

## Пример: экспорт из Центральноафриканской Республики

Мы применим эту процедуру к экспорту из Центральноафриканской Республики, показанному на рис. 9.13.

```
global_economy %>%
  filter(Code == "CAF") %>%
  autoplot(Exports) +
  labs(title="Экспорт из Центральноафриканской Республики",
       y="% от ВВП")
```

**Рисунок 9.13:** Экспорт из Центральноафриканской Республики в процентах от ВВП

1. График времени показывает некоторую нестационарность с совокупным снижением. Улучшение ситуации в 1994 году произошло благодаря новому правительству, которое свергло военную хунту и добилось некоторого начального успеха, прежде чем беспорядки вызвали дальнейший экономический спад.
2. Нет никаких свидетельств об изменяющейся дисперсии, поэтому выполнять преобразование Бокса–Кокса мы не будем.
3. В целях устранения нестационарности мы возьмем первую разницу данных. Дифференцированные данные показаны на рис. 9.14.

```
global_economy %>%
  filter(Code == "CAF") %>%
  gg_tsdisplay(difference(Exports), plot_type='partial')
```

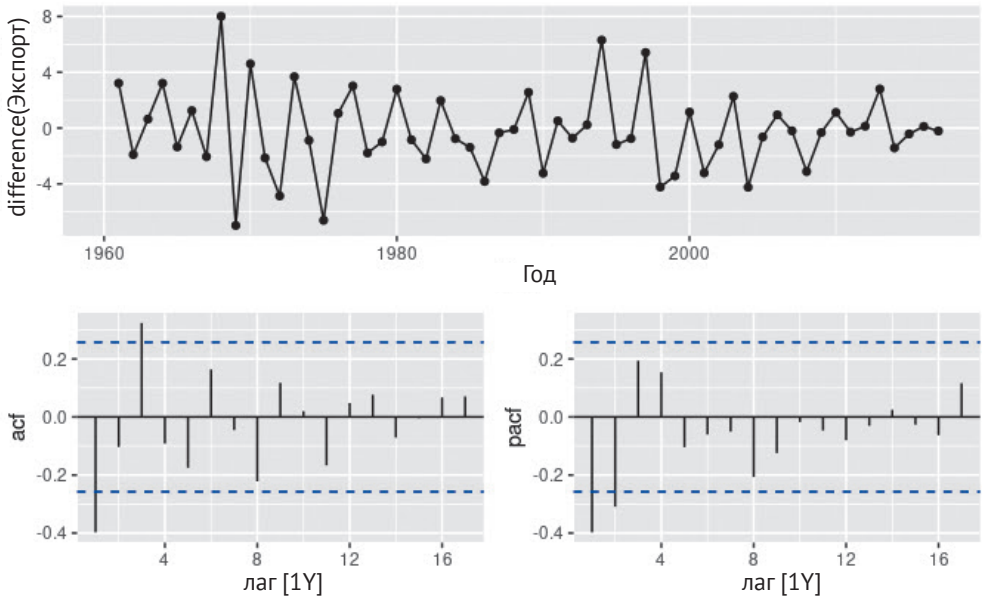


**Рисунок 9.14:** График времени и графики ACF и PACF для дифференцированного экспорта из Центральноафриканской Республики

Теперь они выглядят стационарными.

4. PACF, показанный на рис. 9.14, наводит на мысль о модели AR(2); поэтому начальной кандидатной моделью является ARIMA(2,1,0). ACF предлагает модель MA(3); поэтому альтернативным кандидатом является ARIMA(0,1,3).
5. Мы выполняем подгонку моделей ARIMA(2,1,0) и ARIMA(0,1,3) вместе с двумя автоматическими отборами моделей, в одном из которых используется дефолтная пошаговая процедура, а в другой прилагается больше усилий для того, чтобы выполнить поиск в более крупном модельном пространстве.

```
caf_fit <- global_economy %>%
  filter(Code == "CAF") %>%
  model(arima210 = ARIMA(Exports ~ pdq(2,1,0)),
        arima013 = ARIMA(Exports ~ pdq(0,1,3)),
        stepwise = ARIMA(Exports),
        search = ARIMA(Exports, stepwise=FALSE))

caf_fit %>% pivot_longer(!Country, names_to = "Model name",
                         values_to = "Orders")
#> # A mable: 4 x 3
#> # Key:     Country, Model name [4]
#>   Country                  `Model name`         Orders
#>   <fct>                    <chr>              <model>
#> 1 Central African Republic arima210     <ARIMA(2,1,0)>
```

```
#> 2 Central African Republic arima013     <ARIMA(0,1,3)>
#> 3 Central African Republic stepwise     <ARIMA(2,1,2)>
#> 4 Central African Republic search       <ARIMA(3,1,0)>
glance(caf_fit) %>% arrange(AICc) %>% select(.model:BIC)
#> # A tibble: 4 × 6
#>   .model   sigma2 log_lik   AIC  AICc   BIC
#>   <chr>     <dbl>   <dbl> <dbl> <dbl> <dbl>
#> 1 search     6.52   -133.  274.  275.  282.
#> 2 arima210   6.71   -134.  275.  275.  281.
#> 3 arima013   6.54   -133.  274.  275.  282.
#> 4 stepwise   6.42   -132.  274.  275.  284.
```

Все четыре модели имеют почти идентичные значения AICc. Из подогнанных моделей полный поиск показал, что ARIMA(3,1,0) дает наименьшее значение AICc, за которой следуют ARIMA(2,1,0) и ARIMA(0,1,3) – последние две модели – это те модели, которые мы угадали из графиков ACF и PACF. Автоматический пошаговый отбор выявил модель ARIMA(2,1,2), которая имеет самое высокое значение AICc из четырех моделей.

6. График ACF остатков от модели ARIMA (3,1,0) показывает, что все автокорреляции находятся в пределах пороговых значений, что указывает на то, что остатки ведут себя как белый шум.

```
caf_fit %>%
  select(search) %>%
  gg_tsresiduals()
```

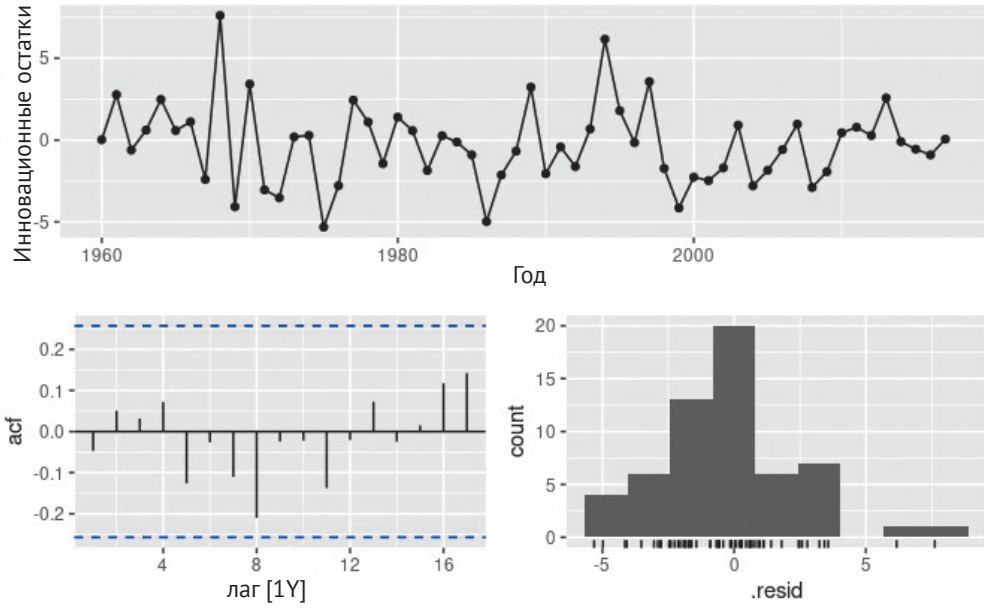


**Рисунок 9.15:** Графики остатков для модели ARIMA(3,1,0)

Тест портманто возвращает крупное *p*-значение, также предполагая, что остатки являются белым шумом.

```
augment(caf_fit) %>%
  filter(.model=='search') %>%
  features(.innov, ljung_box, lag = 10, dof = 3)
#> # A tibble: 1 × 4
#>   Country                  .model lb_stat lb_pvalue
#>   <fct>                    <chr>    <dbl>     <dbl>
#> 1 Central African Republic search    5.75     0.569
```

7. Прогнозы, основанные на выбранной модели, показаны на рис. 9.16.

```
caf_fit %>%
  forecast(h=5) %>%
  filter(.model=='search') %>%
  autoplot(global_economy)
```

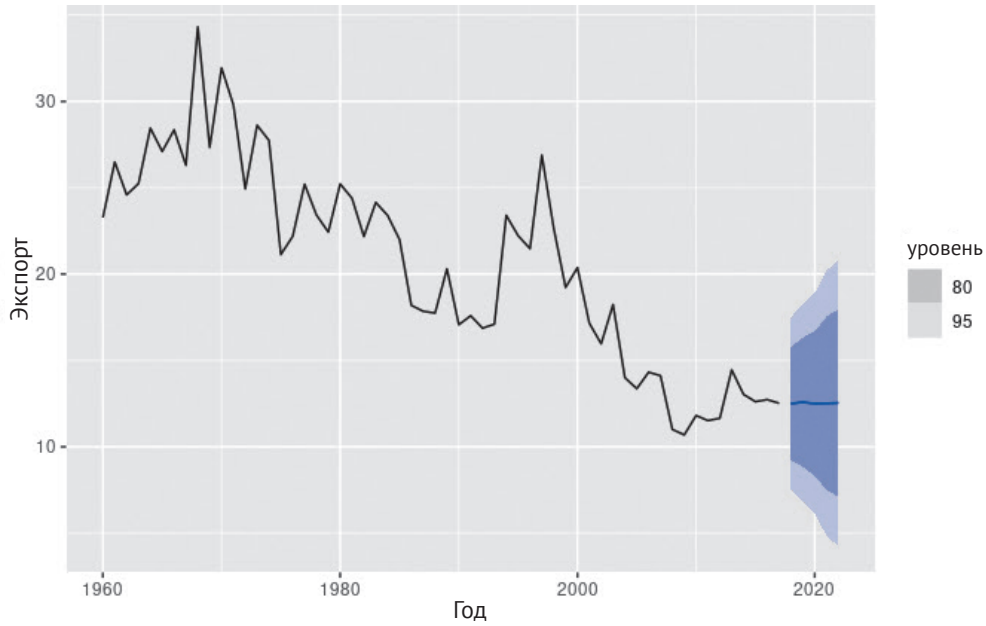


**Рисунок 9.16:** Прогнозы экспорта из Центральноафриканской Республики

Обратите внимание, что средние прогнозы выглядят очень похожими на то, что мы получили бы при случайном блуждании (эквивалентном ARIMA(0, 1, 0)). В этом примере дополнительная работа по включению членов AR и MA мало повлияла на точечные прогнозы, хотя предсказательные интервалы намного уже, чем для модели случайного блуждания.

## Понимание констант в R

Несезонную модель ARIMA можно записать как

$$\left(1-\phi_1 B-\cdots-\phi_p B^p\right)(1-B)^d y_t = c+\left(1+\theta_1 B+\cdots+\theta_q B^q\right)\varepsilon_t \tag{9.3}$$

либо эквивалентно как

$$\left(1-\phi_1 B-\cdots-\phi_p B^p\right)(1-B)^d \left(y_t-\mu t^d/d!\right)=\left(1+\theta_1 B+\cdots+\theta_q B^q\right)\varepsilon_t, \tag{9.4}$$

где $c=\mu\left(1-\phi_1-\cdots-\phi_p\right)$ и $\mu$ – это среднее значение $(1-B)^d y_t$. В пакете fable используется параметризация уравнения (9.3), в то время как в большинстве других имплементаций на R используется уравнение (9.4).

Таким образом, включение константы в нестационарную модель ARIMA эквивалентно индуцированию полиномиального тренда порядка $d$ в прогнозах. (Если константа опущена, то прогнозы включают полиномиальный тренд порядка $d-1$.) При $d=0$ мы имеем частный случай, когда $\mu$ – это среднее значение $y_t$.

По умолчанию функция `ARIMA()` автоматически определяет необходимость включения константы. Для $d=0$ или $d=1$ константа будет включена, если она улучшает значение AICc. Если $d>1$, то константа всегда опускается, поскольку квадратичный тренд или тренд более высокого порядка особенно опасен при прогнозировании.

Константу можно указать, включив в модельную формулу 0 или 1 (подобно пересечению в `lm()`). Например, для того чтобы выбрать модель ARIMA с константой автоматически, можно использовать `ARIMA(y ~ 1 + ...)`. Схожим образом константа может быть исключена посредством `ARIMA(y ~ 0 + ...)`.

## Построение графика характеристических корней

(Это более продвинутый раздел, и при желании его можно пропустить.)

Уравнение (9.3) можно переписать как

$$\phi(B)(1-B)^d y_t = c+\theta(B)\varepsilon_t,$$

где $\phi(B)=\left(1-\phi_1 B-\cdots-\phi_p B^p\right)$ – это многочлен $p$-го порядка в $B$ и $\theta(B)=\left(1+\theta_1 B+\cdots+\theta_q B^q\right)$ – многочлен $q$-го порядка в $B$.

Условия стационарности для модели заключаются в том, что $p$ комплексных корней из $\phi(B)$ лежат за пределами единичной окружности, а условия обратимости заключаются в том, что $q$ комплексных корней из $\theta(B)$ лежат за пределами единичной окружности. Таким образом, близость модели к обратимости либо стационарности можно увидеть по графику корней относительно комплексной единичной окружности.

Вместо этого проще построить обратные корни, так как все они должны лежать *в пределах* единичной окружности. На языке R это легко делается. Для модели ARIMA(3, 1, 0), подогнанной к экспорту из Центральноафриканской Республики, мы получаем рис. 9.17.

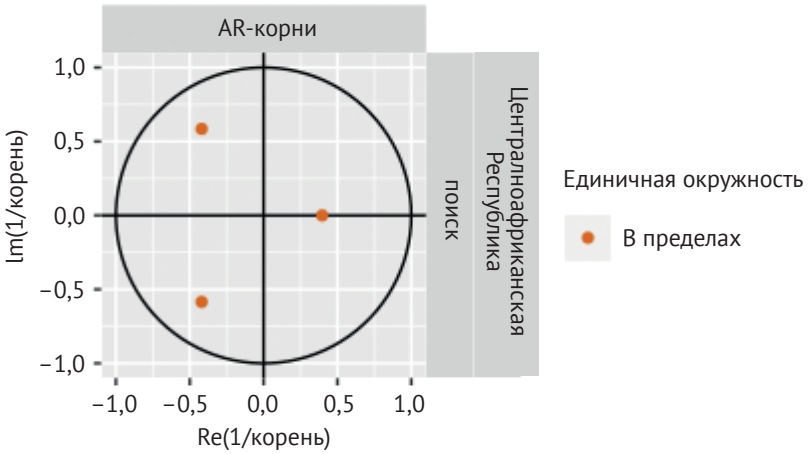


**Рисунок 9.17:** Обратные характеристические корни для модели ARIMA(3,1,0), подогнанной к экспорту из Центральноафриканской Республики

Три оранжевые точки на графике соответствуют корням многочленов $\phi(B)$. Как и следовало ожидать, все они находятся в пределах единичной окружности, поскольку fable гарантирует, что подогнанная модель является одновременно стационарной и обратимой. Любые корни, близкие к единичной окружности, могут быть численно нестабильными, и соответствующая модель не будет пригодна для прогнозирования.

Функция `ARIMA()` никогда не вернет модель с обратными корнями за пределами единичной окружности. Модели, автоматически отобранные функцией `ARIMA()`, также не будут содержать корней, близких к единичной окружности. Следовательно, иногда можно отыскать модель с более оптимальным значением AICc, чем вернет `ARIMA()`, но такие модели будут потенциально проблематичными.

## Библиография

*Хайндман, Р. Дж. и Хандакар, Ю.* (2008). Автоматическое прогнозирование временных рядов: Пакет прогнозирования для R. Journal of Statistical Software, 27 (1), 1–22. [DOI: https://doi.org/10.18637/jss.v027.i03].

# 9.8 Прогнозирование

## Точечные прогнозы

Хотя в наших примерах мы рассчитывали прогнозы из моделей ARIMA, мы еще не объяснили, как они получаются. Точечные прогнозы можно рассчитать, используя следующие три шага.

1. Разложить уравнение ARIMA так, чтобы $y_t$ было в левой части, а все остальные члены – справа.
2. Переписать уравнение, заменив $t$ на $T + h$.

3. В правой части уравнения заменить будущие наблюдения их прогнозами, будущие ошибки – нулем, а прошлые ошибки – соответствующими остатками.

Затем, начиная с $h = 1$, эти шаги повторяются для $h = 2, 3, \ldots$ до тех пор, пока не будут рассчитаны все прогнозы.

Эту процедуру легче всего понять на примере. Мы проиллюстрируем ее с помощью модели ARIMA(3, 1, 1), которую можно записать следующим образом:

$$\left(1-\widehat{\phi}_1 B-\widehat{\phi}_2 B^2-\widehat{\phi}_3 B^3\right)(1-B)y_t=\left(1+\widehat{\theta}_1 B\right)\varepsilon_t.$$

Затем мы раскладываем левую часть и получаем

$$\left[1-\left(1+\widehat{\phi}_1\right)B+\left(\widehat{\phi}_1-\widehat{\phi}_2\right)B^2+\left(\widehat{\phi}_2-\widehat{\phi}_3\right)B^3+\widehat{\phi}_3 B^4\right]y_t=\left(1+\widehat{\theta}_1 B\right)\varepsilon_t,$$

и применение оператора обратного сдвига дает

$$y_t-\left(1+\widehat{\phi}_1\right)y_{t-1}+\left(\widehat{\phi}_1-\widehat{\phi}_2\right)y_{t-2}+\left(\widehat{\phi}_2-\widehat{\phi}_3\right)y_{t-3}+\widehat{\phi}_3 y_{t-4}=\varepsilon_t+\widehat{\theta}_1\varepsilon_{t-1}.$$

Наконец, мы перемещаем все члены, отличные от $y_t$, в правую часть:

$$y_t=\left(1+\widehat{\phi}_1\right)y_{t-1}-\left(\widehat{\phi}_1-\widehat{\phi}_2\right)y_{t-2}-\left(\widehat{\phi}_2-\widehat{\phi}_3\right)y_{t-3}-\widehat{\phi}_3 y_{t-4}+\varepsilon_t+\widehat{\theta}_1\varepsilon_{t-1}. \tag{9.5}$$

На этом первый шаг завершен. Хотя уравнение теперь выглядит как ARIMA(4, 0, 1), это все та же модель ARIMA (3, 1, 1), с которой мы начали. Ее нельзя считать ARIMA(4, 0, 1), поскольку коэффициенты не удовлетворяют условиям стационарности.

В качестве второго шага мы заменим $t$ на $T + 1$ в (9.5):

$$y_{T+1}=\left(1+\widehat{\phi}_1\right)y_T-\left(\widehat{\phi}_1-\widehat{\phi}_2\right)y_{T-1}-\left(\widehat{\phi}_2-\widehat{\phi}_3\right)y_{T-2}-\widehat{\phi}_3 y_{T-3}+\varepsilon_{T+1}+\widehat{\theta}_1\varepsilon_T.$$

Исходя из допущения о том, что у нас есть наблюдения вплоть до времени $T$, все значения в правой части известны, за исключением $\varepsilon_{T+1}$, который мы заменяем на ноль, и $\varepsilon_T$, который мы заменяем последним наблюдаемым остатком $e_T$:

$$\hat{y}_{T+1|T}=\left(1+\widehat{\phi}_1\right)y_T-\left(\widehat{\phi}_1-\widehat{\phi}_2\right)y_{T-1}-\left(\widehat{\phi}_2-\widehat{\phi}_3\right)y_{T-2}-\widehat{\phi}_3 y_{T-3}+\widehat{\theta}_1 e_T.$$

Прогноз $y_{T+2}$ получается путем замены $t$ на $T + 2$ в (9.5) . Все значения в правой части будут известны во время $T$, кроме $y_{T+1}$, который мы заменяем на $\hat{y}_{T+1|T}$, а $\varepsilon_{T+2}$ и $\varepsilon_{T+1}$ оба заменяются на ноль:

$$\hat{y}_{T+2|T}=\left(1+\widehat{\phi}_1\right)\hat{y}_{T+1|T}-\left(\widehat{\phi}_1-\widehat{\phi}_2\right)y_T-\left(\widehat{\phi}_2-\widehat{\phi}_3\right)y_{T-1}-\widehat{\phi}_3 y_{T-2}.$$

Процесс продолжается в таком ключе для всех будущих периодов времени. Благодаря этому можно получить любое число точечных прогнозов.

## Предсказательные интервалы

Вычисление предсказательных интервалов ARIMA выполняется сложнее, и детали в значительной степени выходят за рамки этой книги. Мы приведем лишь несколько простых примеров.

Первый предсказательный интервал рассчитать легко. Если $\hat{\sigma}$ – это стандартное отклонение остатков, тогда 95%-ный предсказательный интервал задается в виде $\hat{y}_{T+1|T} \pm 1.96\hat{\sigma}$. Этот результат справедлив для всех моделей ARIMA, независимо от их параметров и порядков.

Многошаговые предсказательные интервалы для моделей ARIMA (0, 0, $q$) вычисляются относительно легко. Указанную модель можно записать как

$$y_t = \varepsilon_t + \sum_{i=1}^{q} \theta_i \varepsilon_{t-i}.$$

Тогда оценочную прогнозную дисперсию можно записать как

$$\hat{\sigma}_h^2 = \hat{\sigma}^2 \left[1 + \sum_{i=1}^{h-1} \hat{\theta}_i^2\right], \qquad \text{для } h = 2, 3, \ldots,$$

и 95%-ный предсказательный интервал задается выражением $\hat{y}_{T+1|T} \pm 1.96\hat{\sigma}_h$.

В разделе 9.4 мы показали, что модель AR(1) можно записать как модель MA(∞). Используя эту эквивалентность, приведенный выше результат для модели MA($q$) также может использоваться с целью получения предсказательных интервалов для моделей AR(1).

Более общие результаты и другие частные случаи многошаговых предсказательных интервалов для модели ARIMA($p$, $d$, $q$) приведены в более продвинутых учебниках, таких как Броквелл и Дэвис (2016, *https://otexts.com/fpp3/arima-forecasting.html#ref-BDbook16*).

Предсказательные интервалы для моделей ARIMA основаны на допущениях о том, что остатки некоррелированы и распределены нормально. Если какое-либо из этих допущений не соблюдается, то предсказательные интервалы могут быть неверными. По этой причине, прежде чем создавать предсказательные интервалы, необходимо всегда строить график ACF и гистограмму остатков, чтобы проверить эти допущения.

Если остатки некоррелированы, но не распределены нормально, то вместо этого можно получить бутстрапированные интервалы, как описано в разделе 5.5. Этого легко достичь, просто добавив аргумент `bootstrap=TRUE` в функцию `forecast()`.

В общем случае предсказательные интервалы в моделях ARIMA увеличиваются по мере увеличения прогнозного горизонта. Для стационарных моделей (т. е. с $d = 0$) они будут сходиться, так что предсказательные интервалы для длинных горизонтов будут по существу одинаковыми. Для $d \geqslant 1$ предсказательные интервалы будут продолжать расти в будущем.

Как и при большинстве вычислений предсказательных интервалов, интервалы на основе ARIMA, как правило, слишком узкие. Это обусловлено тем, что были учтены только вариации в ошибках. Существует также вариация в оценках параметров и в модельном порядке, которые не были включены в расчет.

В дополнение к этому расчет основан на допущении о том, что исторические закономерности, которые были смоделированы, будут продолжаться в течение прогнозного периода.

## Библиография

*Броквелл, П. Дж. и Дэвис, Р. А.* (2016). Введение во временные ряды и прогнозирование (3-е изд.). Springer. [Amazon, *http://buy.geni.us/Proxy.ashx?TSID=140570&GR_URL=http%3A%2F%2Fwww.amazon.com%2Fdp%2F3319298526*].

# 9.9 Сезонные модели ARIMA

До сих пор мы ограничивали наше внимание несезонными данными и несезонными моделями ARIMA. Однако модели ARIMA также способны моделировать широкий спектр сезонных данных.

Сезонная модель ARIMA формируется путем включения дополнительных сезонных членов в модели ARIMA, которые мы встречали до сих пор. Это записывается следующим образом:

$$ARIMA \quad \underbrace{(p,d,q)}_{\text{Несезонная часть модели}} \quad \underbrace{(P,D,Q)_m}_{\text{Сезонная часть модели}}$$

где $m$ – это сезонный период (например, число наблюдений в год). Нотация в верхнем регистре используется для сезонных частей модели, нотация в нижнем регистре – для несезонных частей модели.

Сезонная часть модели состоит из членов, которые аналогичны несезонным компонентам модели, но включают обратные сдвиги сезонного периода. Например, модель $ARIMA(1,1,1)(1,1,1)_4$ (без константы) предназначена для квартальных данных ($m = 4$) и может быть записана как

$$\left(1-\phi_1 B\right)\left(1-\Phi_1 B^4\right)\left(1-B\right)\left(1-B^4\right)y_t = \left(1+\theta_1 B\right)\left(1+\Theta_1 B^4\right)\varepsilon_t.$$

Дополнительные сезонные члены просто умножаются на несезонные члены.

## ACF/PACF

Сезонная часть модели AR или MA будет видна в сезонных лагах PACF и ACF. Например, модель $ARIMA(0,0,0)(0,0,1)_{12}$ покажет:

- всплеск в лаге 12 на ACF, но никаких других значительных всплесков;
- экспоненциальный спад в сезонных лагах на PACF (т. е. в лагах 12, 24, 36, ...).

Аналогичным образом модель $ARIMA(0,0,0)(1,0,0)_{12}$ покажет:

- экспоненциальный спад сезонных лагов на ACF;
- единственный значительный всплеск в лаге 12 на PACF.

При рассмотрении подходящих сезонных порядков для сезонной модели ARIMA следует ограничивать внимание сезонными лагами.

Процедура моделирования почти такая же, как и для несезонных данных, за исключением того, что необходимо выбрать сезонные члены AR и MA, а также несезонные компоненты модели. Этот процесс лучше всего проиллюстрировать на примерах.

## Пример: ежемесячная занятость в сфере досуга и гостиничного бизнеса в США

Мы опишем сезонное моделирование ARIMA с использованием ежемесячных данных о занятости в сфере досуга и гостиничного бизнеса в США за период с января 2001 года по сентябрь 2019 года, показанных на рис. 9.18.

```
leisure <- us_employment %>%
  filter(Title == "Досуг и гостиничный бизнес",
         year(Month) > 2000) %>%
  mutate(Employed = Employed/1000) %>%
  select(Month, Employed)
autoplot(leisure, Employed) +
  labs(title = "Занятость в США: сфера досуга и гостиничного бизнеса",
       y="Численность людей (млн)")
```

**Рисунок 9.18:** Ежемесячная занятость в сфере досуга и гостиничного бизнеса в США, 2001–2019 годы

Данные явно нестационарны, с сильной сезонностью и нелинейным трендом, поэтому сначала мы возьмем сезонную разницу. Сезонно дифференцированные данные показаны на рис. 9.19.

```
leisure %>%
  gg_tsdisplay(difference(Employed, 12),
               plot_type='partial', lag=36) +
  labs(title="Сезонно дифференцированные данные", y="")
```

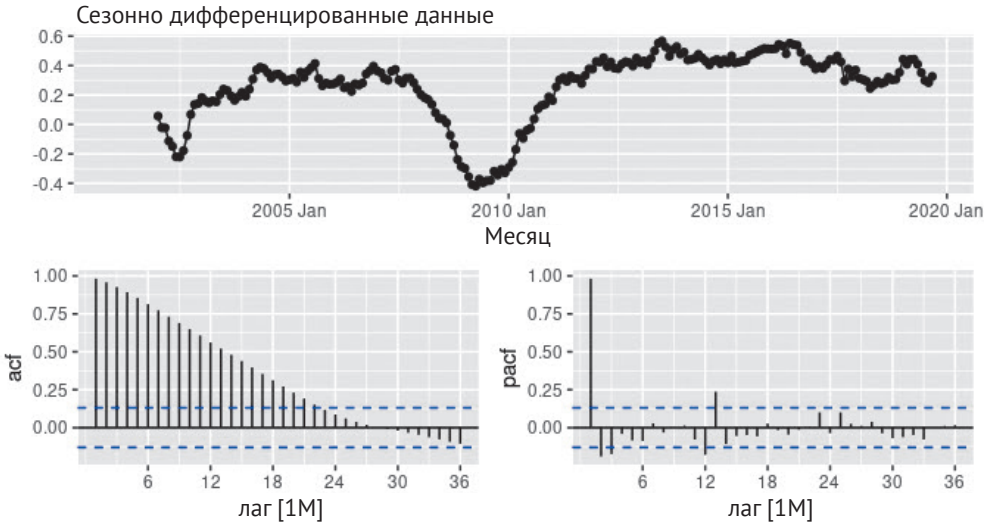


**Рисунок 9.19:** Сезонно дифференцированная ежемесячная занятость в сфере досуга и гостиничного бизнеса в США

Они также явно нестационарны, поэтому мы рассмотрим еще одну первую разницу на рис. 9.20.

```
leisure %>%
  gg_tsdisplay(difference(Employed, 12) %>% difference(),
               plot_type='partial', lag=36) +
  labs(title = "Дважды дифференцированные данные", y="")
```

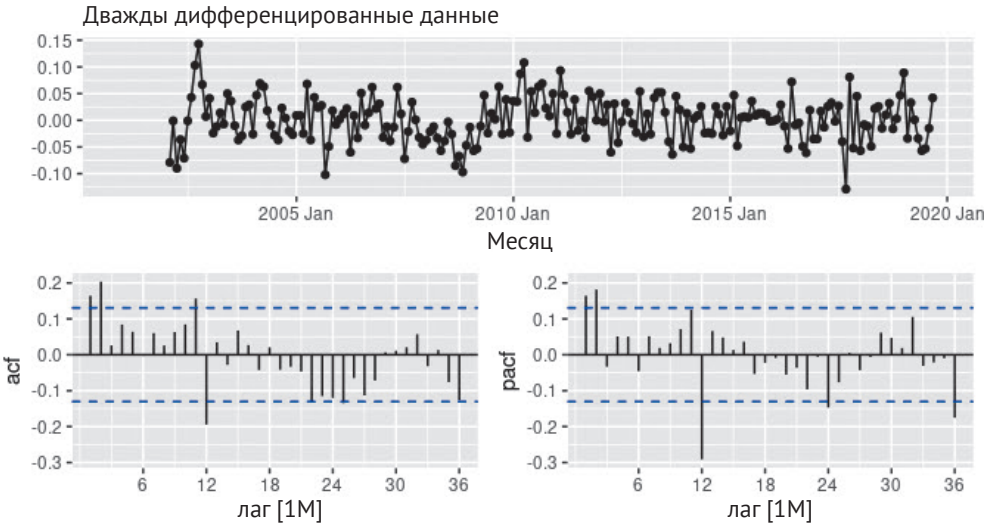


**Рисунок 9.20:** Дважды дифференцированная ежемесячная занятость в сфере досуга и гостиничного бизнеса в США

Теперь наша цель – найти подходящую модель ARIMA на основе ACF и PACF, показанных на рис. 9.20. Значительный всплеск в лаге 2 на ACF указывает на несезонную компоненту MA(2). Значительный всплеск в лаге 12 на ACF предполагает наличие сезонной компоненты MA(1). Следовательно, мы начинаем с модели $ARIMA(0,1,2)(0,1,1)_{12}$, указывающей на первую разницу, сезонную разницу и несезонную компоненту MA(2) и сезонную компоненту MA(1). Если бы мы начали с PACF, то, возможно, мы выбрали бы модель $ARIMA(2,1,0)(0,1,1)_{12}$ – использование PACF для выбора несезонной части модели и ACF для выбора сезонной части модели. Мы также включим автоматически отобранную модель. Установив аргументы `stepwise=FALSE` и `approximation=FALSE`, мы заставляем R усердно поработать, чтобы отыскать хорошую модель. Это занимает гораздо больше времени, но при моделировании только одного ряда дополнительное время не является проблемой.

```
fit <- leisure %>%
  model(
    arima012011 = ARIMA(Employed ~ pdq(0,1,2) + PDQ(0,1,1)),
    arima210011 = ARIMA(Employed ~ pdq(2,1,0) + PDQ(0,1,1)),
    auto = ARIMA(Employed, stepwise = FALSE, approx = FALSE)
  )
fit %>% pivot_longer(everything(), names_to = "Model name",
                     values_to = "Orders")
#> # A mable: 3 x 2
#> # Key:     Model name [3]
#>   `Model name`                  Orders
#>   <chr>                        <model>
#> 1 arima012011  <ARIMA(0,1,2)(0,1,1)[12]>
#> 2 arima210011  <ARIMA(2,1,0)(0,1,1)[12]>
#> 3 auto         <ARIMA(2,1,0)(1,1,1)[12]>
glance(fit) %>% arrange(AICc) %>% select(.model:BIC)
#> # A tibble: 3 × 6
#>   .model       sigma2 log_lik   AIC  AICc   BIC
#>   <chr>         <dbl>   <dbl> <dbl> <dbl> <dbl>
#> 1 auto        0.00142    395. -780. -780. -763.
#> 2 arima210011 0.00145    392. -776. -776. -763.
#> 3 arima012011 0.00146    391. -775. -775. -761.
```

В функции `ARIMA()` используется `unitroot_nsdiffs()` для определения $D$ (числа используемых сезонных разниц) и `unitroot_diffs()` для определения $d$ (числа используемых обычных разниц), если они не указаны. Отбор других модельных параметров ($p$, $q$, $P$ и $Q$) целиком определяется путем минимизирования AICc, как и в несезонных моделях ARIMA.

Три подогнанные модели имеют одинаковые значения AICc, при этом автоматически отобранная модель немного лучше. Наша вторая «догадка» –

*ARIMA*(2,1,0)(0,1,1)$_{12}$ – оказалась очень близка к автоматически отобранной модели *ARIMA*(2,1,0)(1,1,1)$_{12}$.

Остатки для наилучшей модели показаны на рис. 9.21.

```
fit %>% select(auto) %>% gg_tsresiduals(lag=36)
```

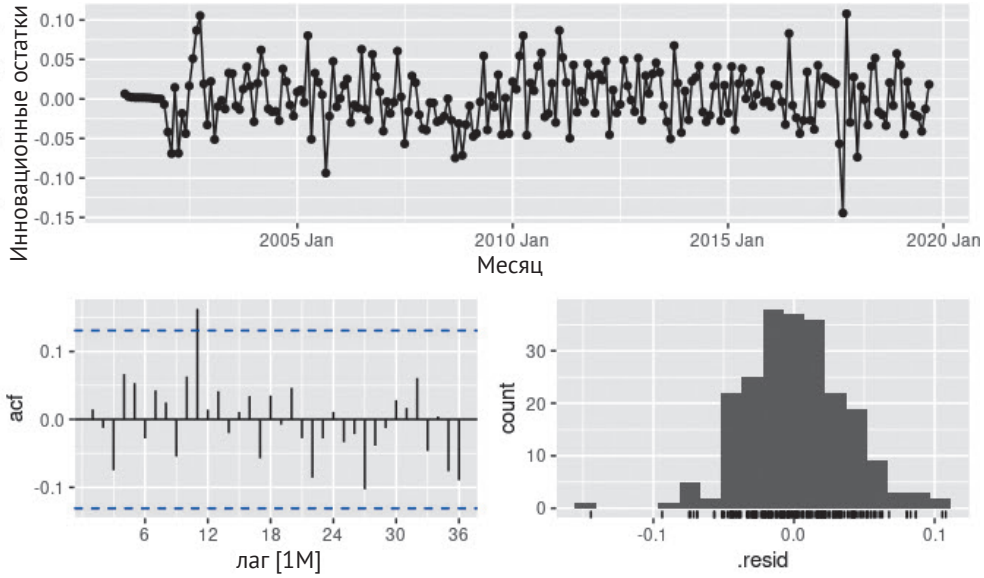


**Рисунок 9.21:** Остатки от подогнанной модели *ARIMA*(2,1,0)(1,1,1)$_{12}$

Один небольшой, но значительный всплеск (в лаге 11) из 36 все еще соответствует белому шуму. Для подстраховки мы используем тест Льюнга–Бокса, тщательно устанавливая степени свободы в соответствии с числом параметров в модели.

```
augment(fit) %>%
  filter(.model == "auto") %>%
  features(.innov, ljung_box, lag=24, dof=4)
#> # A tibble: 1 × 3
#>   .model lb_stat lb_pvalue
#>   <chr>    <dbl>     <dbl>
#> 1 auto      16.6     0.680
```

Большое *p*-значение подтверждает, что остатки похожи на белый шум.

Таким образом, теперь у нас есть сезонная модель ARIMA, которая проходит необходимые проверки и готова к прогнозированию. Прогнозы модели на следующие три года показаны на рис. 9.22. Прогнозы очень хорошо отражают сезонную закономерность, и растущий тренд расширяет недавнюю закономерность. Тренд в прогнозах индуцирован двойным дифференцированием.

```
forecast(fit, h=36) %>%
  filter(.model=='auto') %>%
  autoplot(leisure) +
  labs(title = "Занятость в США: сфера досуга и гостиничного бизнеса",
       y="Численность людей (млн)")
```

**Рисунок 9.22:** Прогнозы ежемесячной занятости в сфере досуга и гостиничного бизнеса в США с использованием модели *ARIMA*(2,1,0)(1,1,1)$_{12}$. Показаны 80%-ный и 95%-ный предсказательные интервалы

## Пример: продажа кортикостероидных препаратов в Австралии

В нашем втором примере мы попытаемся спрогнозировать ежемесячные продажи кортикостероидных препаратов в Австралии. В соответствии со схемой анатомической терапевтической химической классификации указанные препараты называются препаратами H02.

```
h02 <- PBS %>%
  filter(ATC2 == "H02") %>%
  summarise(Cost = sum(Cost)/1e6)
h02 %>%
  mutate(log(Cost)) %>%
  pivot_longer(-Month) %>%
  ggplot(aes(x = Month, y = value)) +
  geom_line() +
  facet_grid(name ~ ., scales = "free_y") +
  labs(y="", title="Рецепты на кортикостероидные препараты (H02)")
```

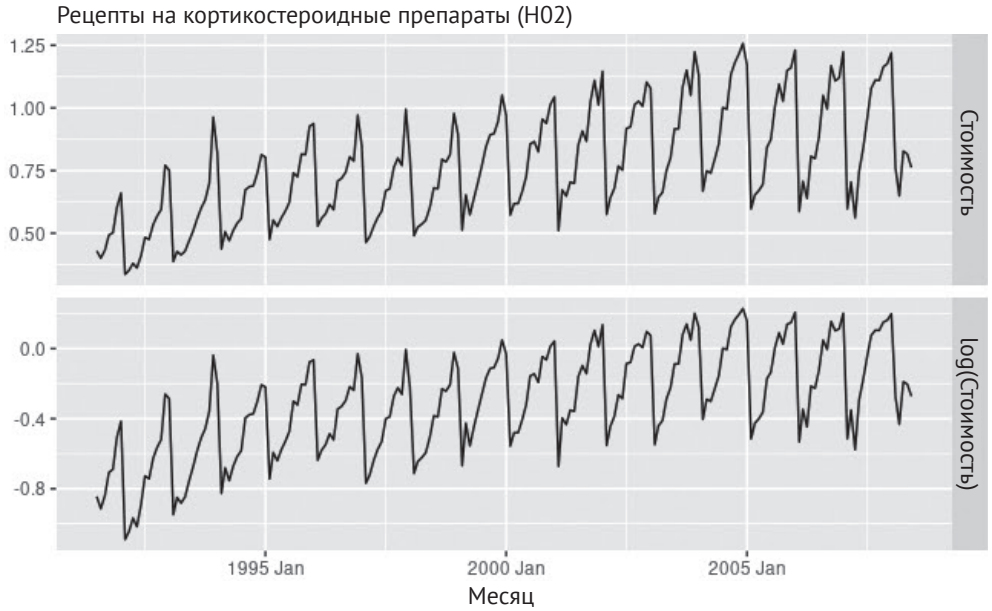


**Рисунок 9.23:** Продажи кортикостероидных препаратов в Австралии (в миллионах рецептов в месяц). Зарегистрированные данные показаны на нижней панели

Данные за период с июля 1991 года по июнь 2008 года представлены на рис. 9.23. Существует небольшое увеличение в дисперсии вместе с уровнем, поэтому мы берем логарифмы, чтобы стабилизировать дисперсию.

Данные характеризуются сильной сезонностью и явно нестационарные, поэтому будет применено сезонное дифференцирование. Сезонно дифференцированные данные показаны на рис. 9.24. На данный момент не ясно, должны ли мы взять еще одну разницу или нет. Мы решаем этого не делать, но выбор неочевиден.

Последние несколько наблюдений, по-видимому, отличаются (более изменчивы) от более ранних данных. Это может быть обусловлено тем фактом, что данные иногда пересматриваются, когда о более ранних продажах сообщается с опозданием.

```
h02 %>% gg_tsdisplay(difference(log(Cost), 12),
                     plot_type='partial', lag_max = 24)
```

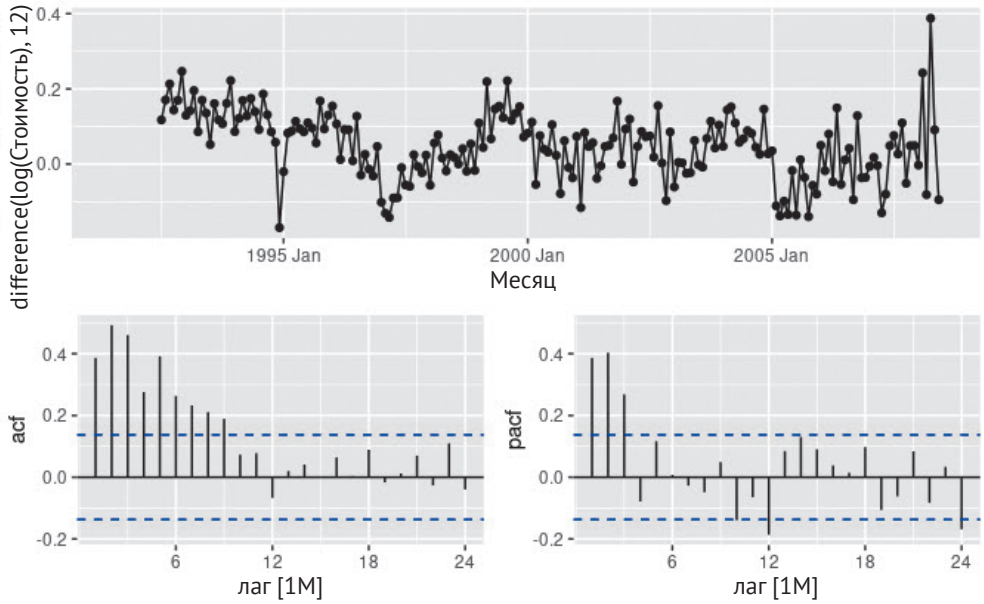


**Рисунок 9.24:** Продажи кортикостероидных препаратов в Австралии с учетом сезонных колебаний (в миллионах рецептов в месяц)

На графиках сезонно дифференцированных данных наблюдается следующая картина: мы наблюдаем всплески на PACF в лагах 12 и 24, но ничего в сезонных лагах на ACF. Это может навести на мысль о сезонном члене AR(2). В несезонных лагах наблюдаются три значительных всплеска на PACF, что указывает на возможный член AR(3). Закономерность на ACF не указывает на какую-либо простую модель.

Следовательно, этот начальный анализ предполагает, что возможной моделью для этих данных является $ARIMA(3,0,0)(2,1,1)_{12}$. Мы выполняем подгонку этой модели вместе с некоторыми ее вариациями и вычисляем значения AICc, приведенные в табл. 9.2.

**Таблица 9.2:** Значения AICc для разных моделей ARIMA, применяемые для ежемесячных данных продаж рецептов H02

| Модель | AICc |
|---|---|
| $ARIMA(3,0,1)(0,1,2)_{12}$ | –485.5 |
| $ARIMA(3,0,1)(1,1,1)_{12}$ | –484.2 |
| $ARIMA(3,0,1)(0,1,1)_{12}$ | –483.7 |
| $ARIMA(3,0,1)(2,1,0)_{12}$ | –476.3 |
| $ARIMA(3,0,0)(2,1,0)_{12}$ | –475.1 |
| $ARIMA(3,0,2)(2,1,0)_{12}$ | –474.9 |
| $ARIMA(3,0,1)(1,1,0)_{12}$ | –463.4 |

Из этих моделей наилучшей является модель *ARIMA*(3,0,1)(0,1,2)$_{12}$ (т. е. она имеет наименьшее значение AICc). Инновационные остатки от этой модели показаны на рис. 9.25.

```
fit <- h02 %>%
  model(ARIMA(log(Cost) ~ 0 + pdq(3,0,1) + PDQ(0,1,2)))
fit %>% gg_tsresiduals(lag_max=36)
```

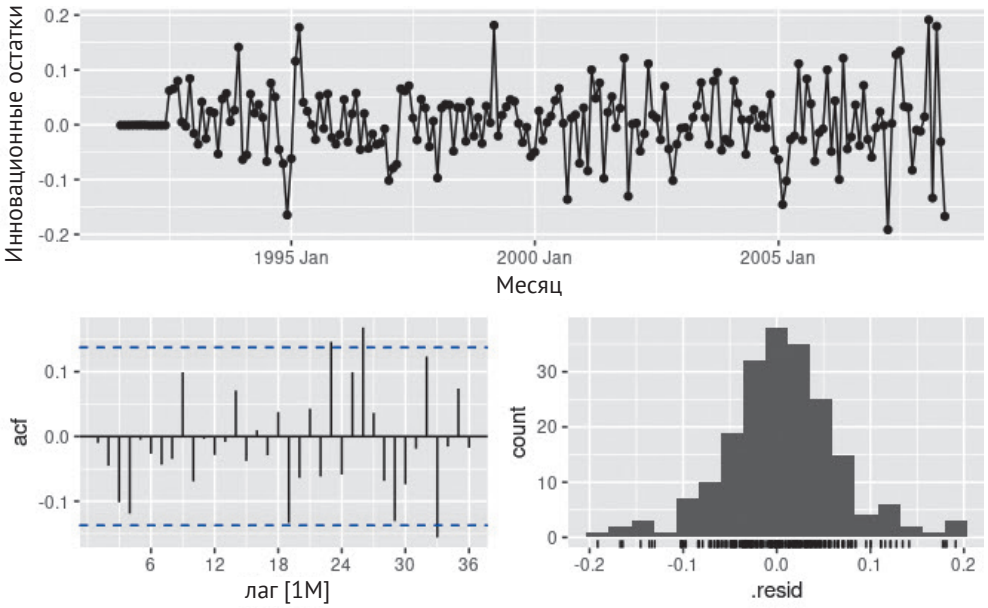


**Рисунок 9.25:** Инновационные остатки от модели *ARIMA*(3,0,1)(0,1,2)$_{12}$ применительно к ежемесячным данным продаж рецептов H02

```
augment(fit) %>%
  features(.innov, ljung_box, lag = 36, dof = 6)
#> # A tibble: 1 × 3
#>   .model                                          lb_stat lb_pvalue
#>   <chr>                                             <dbl>     <dbl>
#> 1 ARIMA(log(Cost) ~ 0 + pdq(3, 0, 1) + PDQ(0, 1, 2))    50.7    0.0104
```

На ACF есть несколько значительных скачков, и модель не проходит тест Льюнга–Бокса. Модель все еще можно использовать для прогнозирования, но предсказательные интервалы могут быть неточными из-за коррелированных остатков.

Далее мы попробуем использовать автоматический алгоритм ARIMA. Выполнение `ARIMA()` со всеми аргументами, оставленными в их дефолтных значениях, привел к модели *ARIMA*(2,1,0)(0,1,1)$_{12}$. Выполнение `ARIMA()` с аргументами `stepwise=FALSE` и `approximation=FALSE` дает модель *ARIMA*(2,1,3)(0,1,1)$_{12}$. Тем не менее обе модели по-прежнему не проходят тест Льюнга–Бокса с 36 лагами. Иногда просто невозможно отыскать модель, которая прошла бы все тесты.

## Оценивание на тестовом наборе

Мы сравним некоторые из подогнанных до сих пор моделей, используя тестовый набор, состоящий из данных за последние два года. Таким образом, мы выполняем подгонку моделей, используя данные с июля 1991 по июнь 2006 года, и прогнозируем продажи рецептов на июль 2006 – июнь 2008 года. Результаты обобщены в табл. 9.3.

**Таблица 9.3:** Значения RMSE для разных моделей ARIMA применительно к ежемесячным данным продаж рецептов H02 за тестовый период с июля 2006 по июнь 2008 года

| Модель | RMSE |
|---|---|
| $ARIMA(3,0,1)(1,1,1)_{12}$ | 0.0619 |
| $ARIMA(3,0,1)(0,1,2)_{12}$ | 0.0621 |
| $ARIMA(2,1,1)(0,1,1)_{12}$ | 0.0622 |
| $ARIMA(2,1,2)(0,1,1)_{12}$ | 0.0623 |
| $ARIMA(2,1,4)(0,1,1)_{12}$ | 0.0627 |
| $ARIMA(2,1,3)(0,1,1)_{12}$ | 0.0628 |
| $ARIMA(3,0,1)(0,1,1)_{12}$ | 0.0630 |
| $ARIMA(3,0,2)(0,1,1)_{12}$ | 0.0630 |
| $ARIMA(2,1,0)(0,1,1)_{12}$ | 0.0630 |
| $ARIMA(3,0,1)(0,1,3)_{12}$ | 0.0630 |
| $ARIMA(3,0,3)(0,1,1)_{12}$ | 0.0631 |
| $ARIMA(3,0,2)(2,1,0)_{12}$ | 0.0651 |
| $ARIMA(3,0,1)(2,1,0)_{12}$ | 0.0653 |
| $ARIMA(2,1,0)(1,1,0)_{12}$ | 0.0666 |
| $ARIMA(3,0,1)(1,1,0)_{12}$ | 0.0666 |
| $ARIMA(3,0,0)(2,1,1)_{12}$ | 0.0668 |

Основываясь на значениях RMSE на этом тестовом наборе, модели, выбираемые вручную, близки к наилучшей модели, в то время как модели, выбираемые автоматически с помощью `ARIMA()`, отстают несильно.

При сопоставлении моделей с использованием значений AICc важно, чтобы все модели имели одинаковые порядки дифференцирования. Однако при сравнении моделей с использованием тестового набора не имеет значения, как прогнозы были произведены – сравнения всегда валидны. Следовательно, в приведенную выше таблицу можно включить некоторые модели только с сезонным дифференцированием и некоторые модели как с первым, так и с сезонным дифференцированием, в то время как в предыдущей таблице, содержащей значения AICc, мы сравнивали модели только с сезонным дифференцированием, но без первого дифференцирования.

Ни одна из рассмотренных здесь моделей не проходит все тесты на остатки. На практике обычно используется наилучшая найденная модель, даже если она не прошла все тесты.

Прогнозы из модели *ARIMA*(3,0,1)(0,1,2)$_{12}$ (которая имеет второе по величине значение RMSE на тестовом наборе и лучшее значение AICc среди моделей только с сезонным дифференцированием) показаны на рис. 9.26.

```
h02 %>%
  model(ARIMA(log(Cost) ~ 0 + pdq(3,0,1) + PDQ(0,1,2))) %>%
  forecast() %>%
  autoplot(h02) +
  labs(y="$AU (млн)",
       title="Продажи рецептов кортикостероидных препаратов (H02)")
```

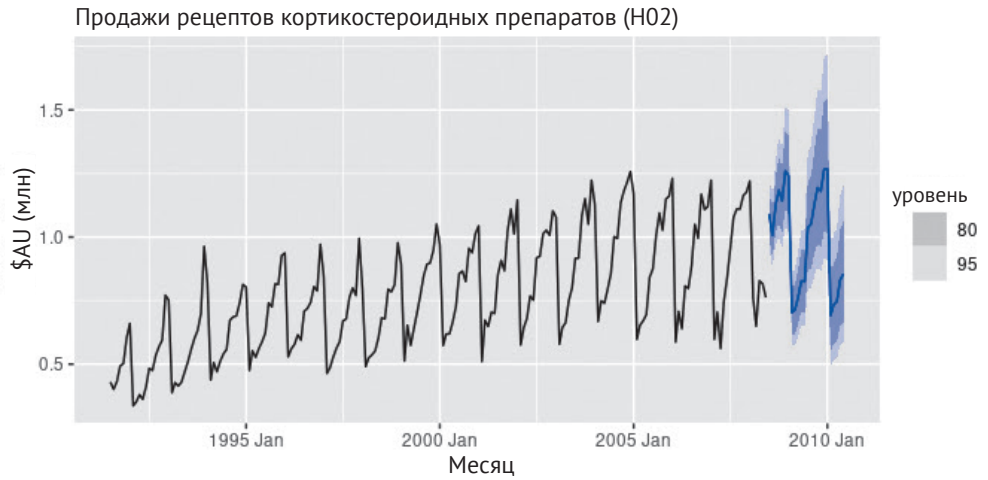


**Рисунок 9.26:** Прогнозы из модели *ARIMA*(3,0,1)(0,1,2)$_{12}$ применительно к ежемесячным данным продаж рецептов H02

# 9.10 ARIMA в сопоставлении с ETS

Распространенный миф гласит, что модели ARIMA являются более общими, чем экспоненциальное сглаживание. В то время как все модели линейного экспоненциального сглаживания являются частными случаями моделей ARIMA, модели нелинейного экспоненциального сглаживания не имеют эквивалентных аналогов ARIMA. С другой стороны, существует также много моделей ARIMA, которые не имеют аналогов экспоненциального сглаживания. В частности, все модели ETS являются нестационарными, в то время как некоторые модели ARIMA являются стационарными. На рис. 9.27 показано наложение между двумя классами моделей.

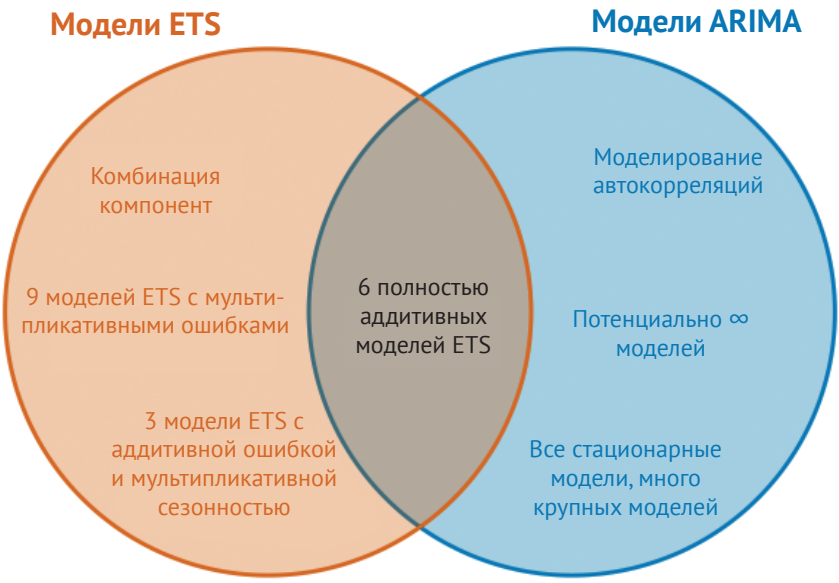


**Рисунок 9.27:** Классы моделей ETS и ARIMA накладываются на аддитивные модели ETS, имеющие эквивалентные формы ARIMA

Модели ETS с сезонностью, либо с недемпфируемым трендом, либо с тем и другим имеют два единичных корня (т. е. им нужны два уровня дифференцирования, чтобы сделать их стационарными). Все остальные модели ETS имеют один единичный корень (им нужен один уровень дифференцирования, чтобы сделать их стационарными).

В табл. 9.4 приведены соотношения эквивалентности для двух классов моделей. Для сезонных моделей параметры ARIMA имеют большое число ограничений.

**Таблица 9.4:** Отношения эквивалентности между моделями ETS и ARIMA

| Модель ETS | Модель ARIMA | Параметры |
|---|---|---|
| ETS($A$,$N$,$N$) | ARIMA(0,1,1) | $\theta_1 = \alpha - 1$ |
| ETS($A$,$A$,$N$) | ARIMA(0,2,2) | $\theta_1 = \alpha + \beta - 2$<br>$\theta_2 = 1 - \alpha$ |
| ETS($A$,$A_d$,$N$) | ARIMA(1,1,2) | $\phi_1 = \phi$<br>$\theta_1 = \alpha + \phi\beta - 1 - \phi$<br>$\theta_2 = (1 - \alpha)\phi$ |
| ETS($A$,$N$,$A$) | ARIMA(0,1,$m$)(0,1,0)$_m$ | |
| ETS($A$,$A$,$A$) | ARIMA(0,1,$m$ + 1)(0,1,0)$_m$ | |
| ETS($A$,$A_d$,$A$) | ARIMA(1,0,$m$ + 1)(0,1,0)$_m$ | |

AICc полезен для выбора между моделями одного и того же класса. Например, его можно использовать для выбора модели ARIMA между кандидатными

моделями ARIMA[1] либо модели ETS между кандидатными моделями ETS. Однако его нельзя использовать для сравнения моделей ETS и ARIMA, поскольку они относятся к разным классам моделей и правдоподобие вычисляется по-разному. Приведенные ниже примеры демонстрируют выбор между этими классами моделей.

## Сравнение ARIMA() и ETS() на несезонных данных

Для сравнения моделей ARIMA и ETS можно использовать перекрестную валидацию временных рядов. Давайте рассмотрим население Австралии из набора данных `global_economy`, представленного в разделе 8.2.

```
aus_economy <- global_economy %>%
  filter(Code == "AUS") %>%
  mutate(Population = Population/1e6)

aus_economy %>%
  slice(-n()) %>%
  stretch_tsibble(.init = 10) %>%
  model(
    ETS(Population),
    ARIMA(Population)
  ) %>%
  forecast(h = 1) %>%
  accuracy(aus_economy) %>%
  select(.model, RMSE:MAPE)
#> # A tibble: 2 × 5
#>   .model              RMSE    MAE   MPE  MAPE
#>   <chr>              <dbl>  <dbl> <dbl> <dbl>
#> 1 ARIMA(Population) 0.194  0.0789 0.277 0.509
#> 2 ETS(Population)   0.0774 0.0543 0.112 0.327
```

В данном случае модель ETS имеет более высокую точность на перекрестно-валидированных мерах результативности. Ниже мы генерируем и строим прогнозы на следующие 5 лет, сгенерированные из модели ETS.

```
aus_economy %>%
  model(ETS(Population)) %>%
  forecast(h = "5 лет") %>%
  autoplot(aus_economy %>% filter(Year >= 2000)) +
  labs(title = "Численность населения Австралии",
       y = "Люди (млн)")
```

[1] Как уже отмечалось, сравнение информационных критериев будет валидным только для моделей ARIMA с одинаковыми порядками дифференцирования.

**Рисунок 9.28:** Прогнозы из модели ETS, подогнанной к населению Австралии

## Сравнение ARIMA() и ETS() на сезонных данных

В данном случае мы хотим сравнить сезонные модели ARIMA и ETS применительно к квартальным данным производства цемента (из `aus_production`). Поскольку этот ряд относительно длинный, можно себе позволить использовать тренировочный и тестовый наборы, а не перекрестную валидацию временных рядов. Преимущество заключается в том, что это происходит намного быстрее. Мы создаем тренировочный набор с начала 1988 года по конец 2007 года и отбираем модель ARIMA и ETS, используя функции `ARIMA()` и `ETS()`.

```
cement <- aus_production %>%
  select(Cement) %>%
  filter_index("1988 Q1" ~ .)
train <- cement %>% filter_index(. ~ "2007 Q4")
```

В приведенной ниже распечатке показана модель, отобранная и оцененная функцией `ARIMA()`. Модель ARIMA хорошо улавливает всю динамику данных, поскольку остатки выглядят белым шумом.

```
fit_arima <- train %>% model(ARIMA(Cement))
report(fit_arima)
#> Series: Cement
#> Model: ARIMA(1,0,1)(2,1,1)[4] w/ drift
#>
#> Coefficients:
#>          ar1      ma1   sar1     sar2     sma1  constant
#>       0.8886  -0.2366  0.081  -0.2345  -0.8979     5.388
```

```
#> s.e.  0.0842   0.1334  0.157   0.1392   0.1780     1.484
#>
#> sigma^2 estimated as 11456:  log likelihood=-463.5
#> AIC=941   AICc=942.7   BIC=957.4
```

```
fit_arima %>% gg_tsresiduals(lag_max = 16)
```

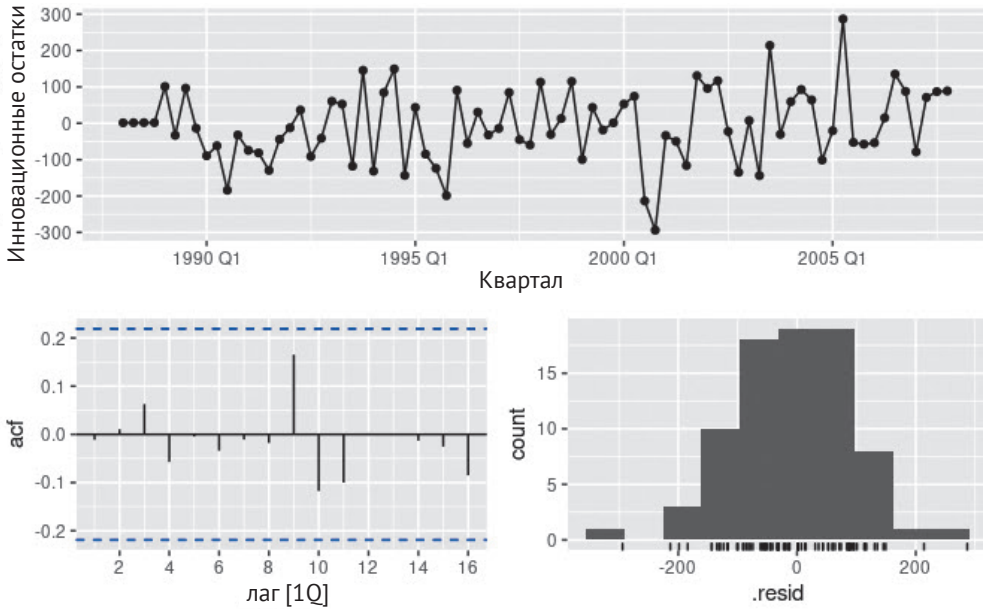


**Рисунок 9.29:** Диагностические графики остатков модели ARIMA, подогнанной к ежеквартальным тренировочным данным производства цемента

```
augment(fit_arima) %>%
  features(.innov, ljung_box, lag = 16, dof = 6)
#> # A tibble: 1 × 3
#>   .model        lb_stat lb_pvalue
#>   <chr>           <dbl>     <dbl>
#> 1 ARIMA(Cement)    6.37     0.783
```

В приведенной ниже распечатке также показана модель ETS, отобранная и оцененная функцией `ETS()`. Эта модель тоже хорошо улавливает всю динамику данных, поскольку остатки выглядят аналогично как белый шум.

```
fit_ets <- train %>% model(ETS(Cement))
report(fit_ets)
#> Series: Cement
#> Model: ETS(M,N,M)
#>   Smoothing parameters:
#>     alpha = 0.7534
#>     gamma = 1e-04
```

```
#>
#>   Initial states:
#>  l[0]  s[0] s[-1] s[-2]  s[-3]
#>  1695 1.031 1.045 1.011 0.9122
#>
#>   sigma^2:  0.0034
#>
#>  AIC AICc  BIC
#> 1104 1106 1121
```

```
fit_ets %>%
  gg_tsresiduals(lag_max = 16)
```

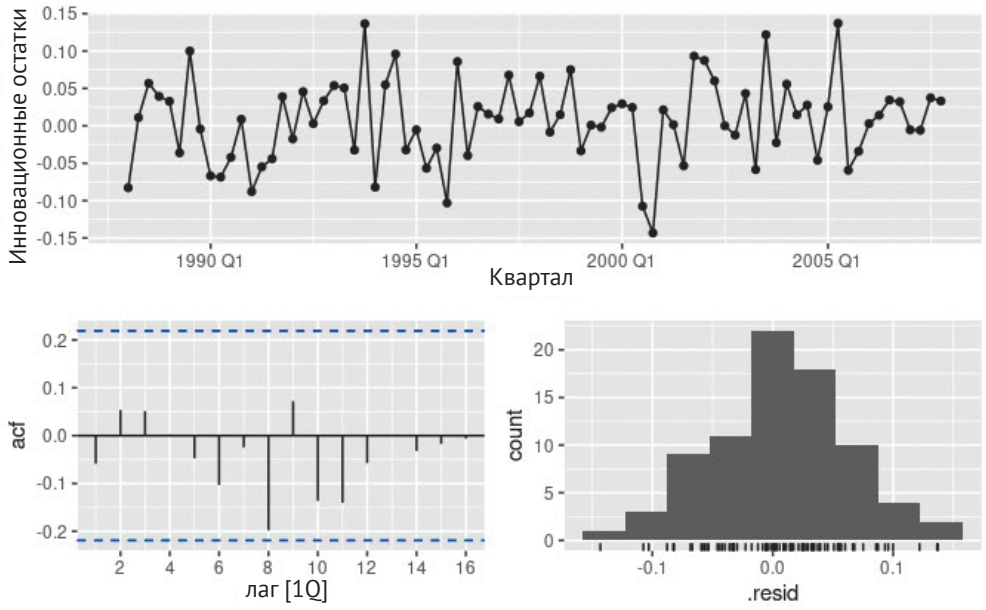


**Рисунок 9.30:** Диагностические графики остатков модели ETS, подогнанной к ежеквартальным тренировочным данным производства цемента

```
augment(fit_ets) %>%
  features(.innov, ljung_box, lag = 16, dof = 6)
#> # A tibble: 1 × 3
#>   .model      lb_stat lb_pvalue
#>   <chr>         <dbl>     <dbl>
#> 1 ETS(Cement)    10.0     0.438
```

В приведенных ниже выходных данных оценивается прогнозная результативность двух конкурирующих моделей на тестовом наборе. В данном случае модель ARIMA представляется немного более точной моделью, если основываться на мерах RMSE, MAPE и MASE, рассчитанных на тестовом наборе.

```
# Сгенерировать прогнозы и сравнить точность на тестовом наборе
bind_rows(
    fit_arima %>% accuracy(),
    fit_ets %>% accuracy(),
    fit_arima %>% forecast(h = 10) %>% accuracy(cement),
    fit_ets %>% forecast(h = 10) %>% accuracy(cement)
  ) %>%
  select(-ME, -MPE, -ACF1)
#> # A tibble: 4 × 7
#>   .model        .type     RMSE   MAE  MAPE  MASE RMSSE
#>   <chr>         <chr>    <dbl> <dbl> <dbl> <dbl> <dbl>
#> 1 ARIMA(Cement) Training  100.  79.9  4.37 0.546 0.582
#> 2 ETS(Cement)   Training  103.  80.0  4.41 0.547 0.596
#> 3 ARIMA(Cement) Test      216. 186.   8.68 1.27  1.26
#> 4 ETS(Cement)   Test      222. 191.   8.85 1.30  1.29
```

Ниже мы генерируем и строим прогнозы из модели ARIMA на следующие 3 года.

```
cement %>%
  model(ARIMA(Cement)) %>%
  forecast(h="3 года") %>%
  autoplot(cement) +
  labs(title = "Производство цемента в Австралии",
       y = "Тонны (тыс.)")
```

**Рисунок 9.31:** Прогнозы из модели ARIMA, подогнанной ко всем имеющимся ежеквартальным данным производства цемента с 1988 года

## 9.11 Упражнения

1. На рис. 9.32 показаны ACF для 36 случайных чисел, 360 случайных чисел и 1000 случайных чисел.
   a) Объясните различия между этими цифрами. Все ли они указывают на то, что данные представляют собой белый шум?

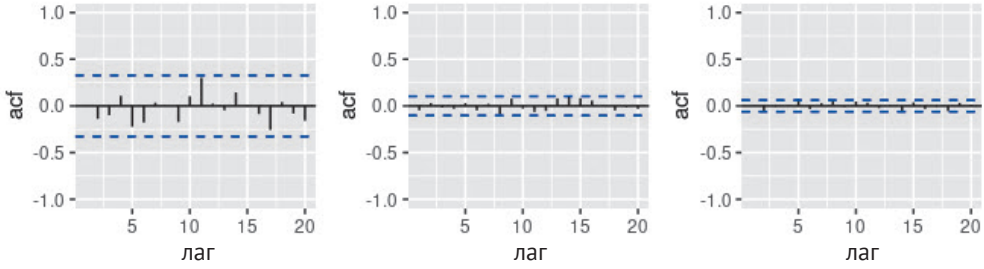


**Рисунок 9.32:** Слева: ACF для ряда белого шума из 36 чисел. Середина: ACF для ряда белого шума из 360 чисел. Справа: ACF для ряда белого шума из 1000 чисел

   b) Почему критические значения находятся на разных расстояниях от нулевого среднего значения? Почему автокорреляции различны на каждом рисунке, когда каждый из них относится к белому шуму?
2. Классическим примером нестационарного ряда являются цены акций. Постройте график ежедневных цен закрытия акций Amazon (содержащихся в `gafa_stock`), а также ACF и PACF. Объясните, как каждый график показывает, что ряд нестационарен и должен быть дифференцирован.
3. Для следующих ниже рядов найдите подходящее преобразование Бокса–Кокса и порядок дифференцирования, чтобы получить стационарные данные.
   a) ВВП Турции из `global_economy`.
   b) Стоимость проживания в штате Тасмания из `aus_accommodation`.
   c) Ежемесячные продажи из `souvenirs`.
4. Для данных `souvenirs` запишите разницы, которые вы выбрали выше, используя нотацию оператора обратного сдвига.
5. Для ваших розничных данных (из упражнения 8 в разделе 2.10) найдите соответствующий порядок дифференцирования (после преобразования, если необходимо), чтобы получить стационарные данные.
6. Просимулируйте и вынесите на график какие-нибудь данные из простых моделей ARIMA.
   a) Используйте следующий ниже исходный код R для генерирования данных из модели AR(1) с $\phi_1 = 0.6$ и $\sigma^2 = 1$. Процесс начинается с $y_1 = 0$.

```
y <- numeric(100)
e <- rnorm(100)
for(i in 2:100)
  y[i] <- 0.6*y[i-1] + e[i]

sim <- tsibble(idx = seq_len(100), y = y, index = idx)
```

b) Постройте график времени для ряда. Как изменяется график, по мере того как вы изменяете $\phi_1$?
c) Напишите свой собственный исходный код для генерирования данных из модели MA(1) с $\phi_1 = 0.6$ и $\sigma^2 = 1$.
d) Постройте график времени для ряда. Как изменяется график, по мере того как вы изменяете $\phi_1$?
e) Сгенерируйте данные из модели ARMA(1, 1) с $\phi_1 = 0.6$, $\theta_1 = 0.6$ и $\sigma^2 = 1$.
f) Сгенерируйте данные из модели AR(2) с $\phi_1 = -0.8$, $\phi_2 = 0.3$ и $\sigma^2 = 1$. (Обратите внимание, что эти параметры дадут нестационарный ряд.)
g) Постройте график последних двух рядов и сравните их.

7. Рассмотрите `aus_airpassengers`, суммарное число пассажиров (в миллионах) от австралийских авиаперевозчиков за период 1970–2011 годов.
   a) Используйте ARIMA(), чтобы найти подходящую модель ARIMA. Какая модель была выбрана? Убедитесь, что остатки выглядят как белый шум. Постройте прогнозы на следующие 10 периодов.
   b) Напишите модель в терминах оператора обратного сдвига.
   c) Постройте прогнозы из модели ARIMA(0,1,0) с дрейфом и сравните их с частью a.
   d) Постройте прогнозы из модели ARIMA (2,1,2) с дрейфом и сравните их с частями a и c. Удалите константу и посмотрите, что произойдет.
   e) Постройте прогнозы из модели ARIMA(0,2,1) с константой. Что происходит?
8. Для ряда ВВП Соединенных Штатов (из `global_economy`):
   a) при необходимости найдите подходящее преобразование Бокса–Кокса для данных;
   b) выполните подгонку подходящей модели ARIMA к преобразованным данным с помощью `ARIMA()`;
   c) попробуйте другие приемлемые модели, поэкспериментировав с выбранными порядками;
   d) выберите ту, которая, по вашему мнению, является наилучшей моделью, и проверьте диагностику остатков;
   e) составьте прогнозы для вашей подогнанной модели. Выглядят ли прогнозы разумными?
   f) сравните результаты с тем, что вы получили бы с помощью `ETS()` (без преобразования).
9. Рассмотрите `aus_arrivals`, ежеквартальное число иностранных посетителей Австралии из нескольких стран за период с 1981 по 3-й квартал 2012 года.
   a) Выберите одну страну и опишите график времени.
   b) Используйте дифференцирование для получения стационарных данных.
   c) Что можно узнать из графика ACF дифференцированных данных?
   d) Что можно узнать из графика PACF дифференцированных данных?
   e) Какую модель предлагают эти графики?
   f) Дает ли `ARIMA()` ту же модель, которую вы выбрали? Если нет, то какая модель, по вашему мнению, лучше?

g) Напишите модель в терминах оператора обратного сдвига, затем без использования оператора обратного сдвига.

10. Выберите ряд из `us_employment`, суммарной занятости в разных отраслях промышленности в Соединенных Штатах.
    a) Создайте STL-разложение данных и опишите тренд и сезонность.
    b) Нуждаются ли данные в преобразовании? Если да, то найдите подходящее преобразование.
    c) Являются ли данные стационарными? Если нет, найдите подходящее дифференцирование, которое дает стационарные данные.
    d) Определите пару моделей ARIMA, которые могут быть полезны при описании временного ряда. Какая из ваших моделей является наилучшей в соответствии с их значениями AICc?
    e) Оцените параметры вашей наилучшей модели и проведите диагностическое тестирование остатков. Напоминают ли остатки белый шум? Если нет, попробуйте найти другую модель ARIMA, которая вписывается лучше.
    f) Спрогнозируйте данные на ближайшие 3 года. Возьмите последние данные из *https://fred.stlouisfed.org/categories/11*, для того чтобы проверить точность ваших прогнозов.
    g) В конце концов, предсказательные интервалы настолько широки, что прогнозы не особенно полезны. На какое число лет, по вашему мнению, прогнозы достаточно точны, чтобы их можно было использовать?
11. Выберите один из следующих сезонных временных рядов: производство электроэнергии, цемента или газа в Австралии (из `aus_production`).
    a) Нуждаются ли данные в преобразовании? Если да, найдите подходящее преобразование.
    b) Являются ли данные стационарными? Если нет, найдите подходящее дифференцирование, которое дает стационарные данные.
    c) Определите пару моделей ARIMA, которые могут быть полезны при описании временных рядов. Какая из ваших моделей является наилучшей в соответствии с их значениями AIC?
    d) Оцените параметры вашей наилучшей модели и проведите диагностическое тестирование остатков. Напоминают ли остатки белый шум? Если нет, попробуйте найти другую модель ARIMA, которая вписывается лучше.
    e) Спрогнозируйте данные на следующие 24 месяца, используя предпочитаемую вами модель.
    f) Сравните прогнозы, полученные с помощью `ETS()`.
12. Для того же временного ряда, который вы применяли в предыдущем упражнении, попробуйте использовать несезонную модель применительно к сезонно скорректированным данным, полученным из STL. Сравните прогнозы с прогнозами, полученными в предыдущем упражнении. Какой подход, по вашему мнению, является наилучшим?
13. Для данных по туризму Австралии (из `tourism`):
    a) выполните подгонку моделей ARIMA для каждого временного ряда;
    b) составьте прогнозы для ваших подогнанных моделей;

c) проверьте прогнозы для регионов «Сноуи Маунтинз» («Снежные горы») и «Мельбурн». Выглядят ли они разумными?

14. Для вашего временного ряда розничной торговли (упражнение 5 выше):
    a) разработайте подходящую сезонную модель ARIMA;
    b) сравните прогнозы с теми, которые вы получили в предыдущих главах;
    c) получите актуальные данные о розничной торговле с веб-сайта ABS (Cat 8501.0, табл. 11, *https://bit.ly/absretail*) и сравните свои прогнозы с фактическими цифрами. Насколько хороши были прогнозы различных моделей?
15. Рассмотрите количество мехов американского зайца-беляка, проданных компанией Hudson Bay в период с 1845 по 1935 год (набор данных `pelt`).
    a) Постройте график времени для временного ряда.
    b) Допустим, вы решили использовать следующую ниже модель:

$$y_t = c + \phi_1 y_{t-1} + \phi_2 y_{t-2} + \phi_3 y_{t-3} + \phi_4 y_{t-4} + \varepsilon_t,$$

    где $\varepsilon_t$ – это ряд белого шума. Что это за модель ARIMA (т. е. какие $p$, $d$ и $q$)?
    c) Изучив ACF и PACF данных, объясните, почему эта модель подходит.
    d) Последние пять значений ряда приведены ниже:

| Год | 1931 | 1932 | 1933 | 1934 | 1935 |
|---|---|---|---|---|---|
| Число заячьих шкурок | 19 520 | 82 110 | 89 760 | 81 660 | 15 760 |

    Оценочные параметры таковы: $c$ = 30 993, $\phi_1$ = 0.82, $\phi_2$ = –0.29, $\phi_3$ = –0.01 и $\phi_4$ = –0.22. Без использования функции `forecast()` рассчитайте прогнозы на следующие три года (1936–1939).
    e) Теперь выполните подгонку модели на R и получите прогнозы с помощью `forecast()`. Чем они отличаются от ваших? Почему?
16. Население Швейцарии с 1960 по 2017 год находится в наборе данных `global_economy`.
    a) Создайте график времени для этих данных.
    b) Вы решили выполнить подгонку следующей ниже модели к этим данным:

$$y_t = c + y_{t-1} + \phi_1 (y_{t-1} - y_{t-2}) + \phi_2 (y_{t-2} - y_{t-3}) + \phi_3 (y_{t-3} - y_{t-4}) + \varepsilon_t,$$

    где $y_t$ – это численность населения в год $t$ и $\varepsilon_t$ – ряд белого шума. Что это за модель ARIMA (т. е. какие $p$, $d$ и $q$)?
    c) Объясните, почему была выбрана эта модель, используя ACF и PACF дифференцированных рядов.
    d) Последние пять значений ряда приведены ниже.

| Год | 2013 | 2014 | 2015 | 2016 | 2017 |
|---|---|---|---|---|---|
| Население (в миллионах) | 8.09 | 8.19 | 8.28 | 8.37 | 8.47 |

Оценочные параметры таковы: $c$ = 0.0053, $\phi_1$ = 1.64, $\phi_2$ = 1.17 и $\phi_3$ = 0.45. Без использования функции `forecast()` рассчитайте прогнозы на следующие три года (2018–2020).

e) Теперь выполните подгонку модели на R и получите прогнозы из той же модели. Чем они отличаются от ваших? Почему?

17. Перед выполнением этого упражнения вам нужно будет установить пакет Quandl в R с помощью команды

```
install.packages("Quandl")
```

a) Выберите временной ряд из Quandl. Затем скопируйте его короткий URL-адрес и импортируйте данные с помощью

```
y <- as_tsibble(Quandl::Quandl("?????"), index = Date)
```

(Замените ????? на соответствующий исходный код.)

b) Постройте графики данных и попытайтесь определить подходящую модель ARIMA.

c) Выполните диагностическую проверку остатков вашей модели ARIMA. Являются ли остатки белым шумом?

d) Примените выбранную вами модель ARIMA для прогнозирования на ближайшие четыре года.

e) Теперь попробуйте определить подходящую модель ETS.

f) Выполните диагностическую проверку остатков вашей модели ETS. Являются ли остатки белым шумом?

g) Примените выбранную вами модель ETS для прогнозирования на следующие четыре года.

h) Какую из двух моделей вы предпочитаете?

## 9.12 Дальнейшее чтение

Классическим текстом, популяризировавшим моделирование ARIMA, была книга Бокс и Дженкинс (1970, *https://otexts.com/fpp3/arima-reading.html#ref-BJ70*). Самое последнее издание – Бокс и соавт. (2015, *https://otexts.com/fpp3/arima-reading.html#ref-BJRL15*), и оно по-прежнему является отличным справочником для всего, что связано с ARIMA.

Броквелл и Дэвис (2016, *https://otexts.com/fpp3/arima-reading.html#ref-BDbook16*) дают хорошее введение в математическую основу моделей.

Алгоритм Хайндмана–Хандакара для автоматического отбора модели ARIMA описан в Хайндман и Хандакар (2008, *https://otexts.com/fpp3/arima-reading.html#ref-HK08*).

Пенья и соавт. (2001, *https://otexts.com/fpp3/arima-reading.html#ref-PTT01*) описывают некоторые альтернативные автоматические алгоритмы тому, который используется в функции `ARIMA()`.

## Библиография

*Бокс, Дж. Е. П. и Дженкинс, Дж. М.* (1970). Анализ временных рядов: прогнозирование и контроль. Holden-Day.

*Бокс, Дж. Е. П., Дженкинс, Дж. М., Райнсел, Дж. С. и Льюнг, Дж. М.* (2015). Анализ временных рядов: прогнозирование и контроль (5-е изд.). John Wiley & Sons. [Amazon, *http://buy.geni.us/Proxy.ashx?TSID=140570&GR_URL=http%3A%2F%2Fwww.amazon.com%2Fdp%2F1118675029*].

*Броквелл, П. Дж. и Дэвис, Р. А.* (2016). Введение во временные ряды и прогнозирование (3-е изд.). Springer. [Amazon, *http://buy.geni.us/Proxy.ashx?TSID=140570&GR_URL=http%3A%2F%2Fwww.amazon.com%2Fdp%2F3319298526*].

*Хайндман, Р. Дж. и Хандакар, Ю.* (2008). Автоматическое прогнозирование временных рядов: Пакет прогнозирования для R. Journal of Statistical Software, 27 (1), 1–22. [DOI: https://doi.org/10.18637/jss.v027.i03].

*Пенья, Д., Тиао, Г. К. и Цай, Р. С.* (ред.). (2001). Курс по анализу временных рядов. John Wiley & Sons. [Amazon, *http://buy.geni.us/Proxy.ashx?TSID=140570&GR_URL=http%3A%2F%2Fwww.amazon.com%2Fdp%2F047136164X*].

# Глава 10

# Модели на основе динамической регрессии

Модели временных рядов, описанные в предыдущих двух главах, допускают включение информации из прошлых наблюдений ряда, но не включают другую информацию, которая также бывает релевантной. Например, влияние праздников, активность конкурентов, изменения в законодательстве, экономика в целом или другие внешние переменные могут объяснять некоторую историческую вариативность и могут приводить к более точным прогнозам. С другой стороны, регрессионные модели главы 7 допускают включение большого количества релевантной информации из предсказательных переменных, но не учитывают тонкую динамику временных рядов, которая может обрабатываться с помощью моделей ARIMA. В этой главе мы рассмотрим вопрос о том, какие существуют возможности расширения модели ARIMA, чтобы включать в модели другую информацию.

В главе 7 мы рассмотрели регрессионные модели вида

$$y_t = \beta_0 + \beta_1 x_{1,t} + \cdots + \beta_k x_{k,t} + \varepsilon_t,$$

где $y_t$ – это линейная функция от $k$ предсказательных переменных ($x_{1,t}, \ldots, x_{k,t}$), и $\varepsilon_t$ обычно считается некоррелированным членом ошибки (т. е. это белый шум). Мы рассматривали такие тесты, как тест Льюнга–Бокса, для оценивания того, были ли результирующие остатки существенно коррелированными.

В этой главе мы допустим, что получившиеся в результате регрессии ошибки содержат автокорреляцию. Для того чтобы подчеркнуть это изменение в перспективе, в уравнении мы заменим $\varepsilon_t$ на $\eta_t$. Мы приняли как допущение то, что ряд ошибок $\eta_t$ подчиняется модели ARIMA. Например, если $\eta_t$ следует модели ARIMA (1,1,1), то можно записать:

$$y_t = \beta_0 + \beta_1 x_{1,t} + \cdots + \beta_k x_{k,t} + \beta_t,$$
$$(1-\phi_1 B)(1-B)\eta_t = (1+\theta_1 B)\varepsilon_t,$$

где $\varepsilon_t$ – это ряд белого шума.

Обратите внимание, что здесь модель имеет два члена ошибки – ошибку из регрессионной модели, которую мы обозначаем через $\eta_t$, и ошибку модели ARIMA, которую мы обозначаем через $\varepsilon_t$. Предполагается, что белым шумом являются только ошибки модели ARIMA.

## 10.1 Оценивание

При оценивании параметров модели необходимо минимизировать сумму квадратов значений $\varepsilon_t$. Если вместо этого мы минимизируем сумму квадратов значений $\eta_t$ (что и произошло бы, если бы мы оценивали регрессионную модель, игнорируя автокорреляции в ошибках), тогда возникает несколько проблем.

1. Оценочные коэффициенты $\hat{\beta}_0,\dots,\hat{\beta}_k$ больше не являются наилучшими оценками, поскольку при расчете была проигнорирована некоторая информация.
2. Любые ассоциированные с моделью статистические тесты (например, *t*-тесты для коэффициентов) будут неверными.
3. Значения AICc подогнанных моделей больше не являются хорошим ориентиром в отношении того, какая модель является для прогнозирования наилучшей.
4. В большинстве случаев ассоциированные с коэффициентами *p*-значения будут слишком малы, и поэтому некоторые предсказательные переменные будут казаться важными, когда они таковыми не являются. Такая ситуация называется «мнимой регрессией».

Минимизирование суммы квадратов значений $\varepsilon_t$ позволяет избежать этих проблем. В качестве альтернативы можно использовать оценивание максимального правдоподобия; оно даст аналогичные оценки коэффициентов.

Важным соображением при оценивании регрессии с ошибками ARMA является то, что все переменные в модели сначала должны быть стационарными. Отсюда следует, что сначала мы должны проверить, что $y_t$ и все предсказатели $(x_{1,t},\dots,x_{k,t})$ выглядят стационарными. Если мы оцениваем модель, когда какой-либо из них нестационарен, то оценочные коэффициенты не будут регулярными (консистентными) оценками (и, следовательно, могут не иметь смысла). Одним из исключений из этого правила является случай, когда нестационарные переменные коинтегрированы. Если существует линейная комбинация нестационарной $y_t$ и предсказателей, которые являются стационарными, тогда оценочные коэффициенты будут регулярными[1].

Поэтому мы сначала дифференцируем нестационарные переменные модели. Зачастую желательно поддерживать форму взаимосвязи между $y_t$ и предсказателями, и, следовательно, в случае если какая-либо из переменных нуждается в дифференцировании, то обычно дифференцируют все переменные. Результирующая модель тогда называется «моделью в разницах», в отличие от «модели в уровнях», которая является тем, что получается, когда изначальные данные используются без дифференцирования.

Если все переменные в модели являются стационарными, то необходимо рассмотреть только процесс ARMA для ошибок. Легко увидеть, что регрессионная модель с ошибками ARIMA эквивалентна регрессионной модели в разницах с ошибками ARMA. Например, если приведенная выше регрессионная модель с ошибками ARIMA(1,1,1) дифференцирована, то мы получаем модель

[1] Прогнозирование с использованием коинтегрированных моделей обсуждается в работе Харрис и Соллис (2003, *https://otexts.com/fpp3/estimation.html#ref-Harris03*).

$$\begin{aligned} y_t' &= \beta_1 x_{1,t}' + \cdots + \beta_k x_{k,t}' + \beta_t', \\ (1-\phi_1 B)\eta_t' &= (1+\theta_1 B)\varepsilon_t, \end{aligned}$$

где $y_t' = y_t - y_{t-1}$, $x_{t,i}' = x_{t,i} - x_{t-1,i}$ и $\eta_t' = \eta_t - \eta_{t-1}$, что является регрессионной моделью в разницах с ошибками ARMA.

## Библиография

*Харрис, Р. и Соллис, Р.* (2003). Прикладное моделирование и прогнозирование временных рядов. John Wiley & Sons. [Amazon, *http://buy.geni.us/Proxy.ashx?TSID=140570&GR_URL=http%3A%2F%2Fwww.amazon.com%2Fdp%2F0470844434*].

# 10.2 Регрессия с ошибками ARIMA с использованием fable

Функция `ARIMA()` будет выполнять подгонку регрессионной модели с ошибками ARIMA, если в формулу включены экзогенные регрессоры. Как описано в разделе 9.5, специальная функция `pdq()` задает порядок модели ошибок ARIMA. Если задано дифференцирование, то дифференцирование применяется ко всем переменным в регрессионной модели до оценивания модели. Например, команда

```
ARIMA(y ~ x + pdq(1,1,0))
```

выполнит подгонку модели $y_t' = \beta_1 x_t' + \eta_t'$, где $\eta_t' = \phi_1 \eta_{t-1}' + \varepsilon_t$ – это ошибка AR(1). Это эквивалентно модели

$$y_t = \beta_0 + \beta_1 x_t + \eta_t,$$

где $\eta_t$ – это ошибка ARIMA(1,1,0). Обратите внимание, что константный член исчезает из-за дифференцирования. Для того чтобы включить константу в дифференцированную модель, мы бы добавили в модельную формулу единицу.

Функция `ARIMA()` также может использоваться для отбора наилучшей модели ARIMA для ошибок. Это делается путем опускания специальной функции `pdq()`. Потребность в дифференцировании определяется путем применения теста KPSS к остаткам от регрессионной модели, оцениваемым с использованием обычных наименьших квадратов. Если требуется дифференцирование, то дифференцируются все переменные, и модель перевычисляется с использованием оценивания максимального правдоподобия. Окончательная модель будет выражена в терминах изначальных переменных, даже если она была оценена с использованием дифференцированных переменных.

AICc рассчитывается для окончательной модели, и это значение может использоваться для определения наилучших предсказателей. То есть процедуру следует повторить для всех рассматриваемых подмножеств предсказателей и отобрать модель с наименьшим значением AICc.

## Пример: личное потребление и доход в США

На рис. 10.1 показаны ежеквартальные изменения в расходах на личное потребление и личном располагаемом доходе с 1970Q1 по 2019Q2. Мы хотели бы спрогнозировать изменения в расходах на основе изменений в доходах. Изменение дохода не обязательно приводит к мгновенному изменению потребления (например, после потери работы может потребоваться несколько месяцев, чтобы расходы были сокращены с учетом новых обстоятельств). Однако в данном примере мы проигнорируем эту сложность и попытаемся измерить мгновенное влияние среднего изменения в доходе на среднее изменение в потребительских расходах.

```
us_change %>%
  pivot_longer(c(Consumption, Income),
               names_to = "var", values_to = "value") %>%
  ggplot(aes(x = Quarter, y = value)) +
  geom_line() +
  facet_grid(vars(var), scales = "free_y") +
  labs(title = "Личное потребление и доход в США",
       y = "Ежеквартальное процентное изменение")
```

**Рисунок 10.1:** Процентные изменения в ежеквартальных расходах на личное потребление и личном располагаемом доходе в США, с 1970Q1 по 2019Q2

```
fit <- us_change %>%
  model(ARIMA(Consumption ~ Income))
report(fit)
#> Series: Consumption
#> Model: LM w/ ARIMA(1,0,2) errors
#>
#> Coefficients:
```

```
#>          ar1      ma1     ma2  Income  intercept
#>       0.7070  -0.6172  0.2066  0.1976     0.5949
#> s.e.  0.1068   0.1218  0.0741  0.0462     0.0850
#>
#> sigma^2 estimated as 0.3113:  log likelihood=-163
#> AIC=338.1   AICc=338.5   BIC=357.8
```

Очевидно, что данные уже являются стационарными (поскольку мы рассматриваем процентные изменения, а не изначальные расходы и доходы), поэтому нет необходимости в каком-либо дифференцировании. Подогнанная модель такова:

$$
\begin{aligned}
y_t &= 0.595 + 0.198x_t + \eta_t, \\
\eta_t &= 0.707\eta_{t-1} + \varepsilon_t - 0.617\varepsilon_{t-1} + 0.207\varepsilon_{t-2}, \\
\varepsilon_t &=\sim \text{NID}\left(0, 0.311\right).
\end{aligned}
$$

Оценки для рядов $\eta_t$ и $\varepsilon_t$ можно восстановить с использованием функции `residuals()`.

```
bind_rows(
    `Regression residuals` =
        as_tibble(residuals(fit, type = "regression")),
    `ARIMA residuals` =
        as_tibble(residuals(fit, type = "innovation")),
    .id = "type"
  ) %>%
  mutate(
    type = factor(type, levels=c(
      "Остатки регрессии", "Остатки ARIMA"))
  ) %>%
  ggplot(aes(x = Quarter, y = .resid)) +
  geom_line() +
  facet_grid(vars(type))
```

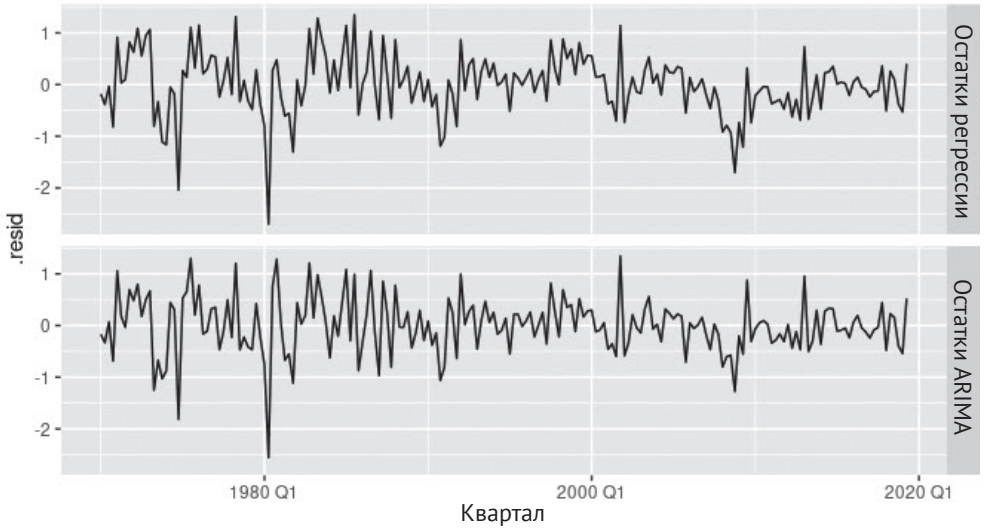


**Рисунок 10.2:** Остатки регрессии ($\eta_t$) и остатки ARIMA ($\varepsilon_t$) от подогнанной модели

Главное, что именно оценочные ошибки ARIMA (остатки инноваций) должны напоминать ряд белого шума.

```
fit %>% gg_tsresiduals()
```

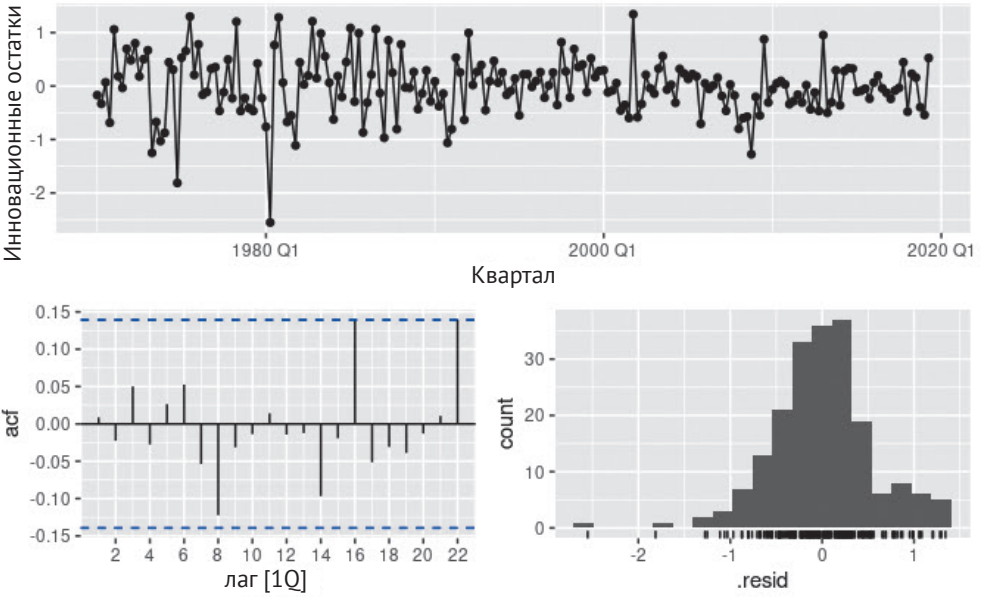


**Рисунок 10.3:** Остатки инноваций (т. е. оценочные ошибки ARIMA) не существенно отличаются от ряда белого шума

```
augment(fit) %>%
  features(.innov, ljung_box, dof = 5, lag = 8)
```

```
#> # A tibble: 1 × 3
#>   .model                       lb_stat lb_pvalue
#>   <chr>                          <dbl>     <dbl>
#> 1 ARIMA(Consumption ~ Income)    5.21     0.157
```

## 10.3 Прогнозирование

В целях прогнозирования с использованием регрессионной модели с ошибками ARIMA нам необходимо спрогнозировать регрессионную часть модели и часть модели ARIMA и скомбинировать результаты. Как и в случае с обычными регрессионными моделями, для получения прогнозов сначала необходимо спрогнозировать предсказатели. Когда предсказатели известны в будущем (например, календарные переменные, такие как время, день недели и т. д.), это просто. Но когда сами предсказатели неизвестны, мы должны смоделировать их отдельно либо использовать допускаемые будущие значения для каждого предсказателя.

### Пример: личное потребление и доход в США

Мы рассчитаем прогнозы на следующие восемь кварталов, допустив, что будущие процентные изменения в личном располагаемом доходе будут равны среднему процентному изменению за последние сорок лет.

```
us_change_future <- new_data(us_change, 8) %>%
  mutate(Income = mean(us_change$Income))
forecast(fit, new_data = us_change_future) %>%
  autoplot(us_change) +
  labs(y = "Процентное изменение")
```

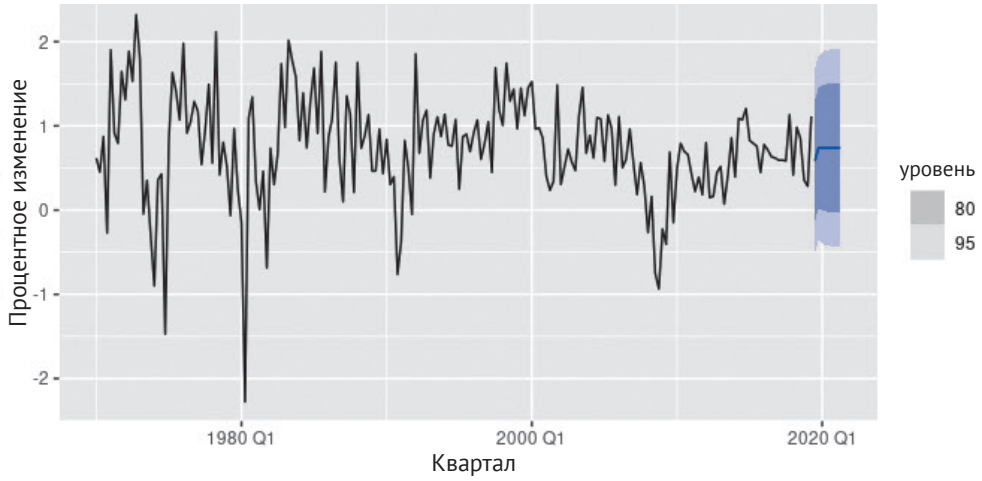


**Рисунок 10.4:** Прогнозы, полученные путем регрессирования процентного изменения в потребительских расходах на процентное изменение в располагаемом доходе с использованием модели ошибок ARIMA(1,0,2)

Предсказательные интервалы для этой модели уже, чем если бы мы использовали модель ARIMA без ковариат, потому что теперь можно объяснить некоторую вариацию в данных с помощью предсказателя дохода.

Важно понимать, что предсказательные интервалы из регрессионных моделей (с ошибками ARIMA или без них) не учитывают неопределенность в прогнозах предсказателей. И поэтому они должны интерпретироваться как обусловленные допускаемыми (или оценочными) будущими значениями предсказательных переменных.

## Пример: прогнозирование спроса на электроэнергию

Суточная потребность в электроэнергии может моделироваться как функция от температуры. Как видно из счета за электроэнергию, в холодные дни используется больше электроэнергии из-за отопления, а в жаркие – из-за кондиционирования воздуха. Более высокий спрос в холодные и жаркие дни отражен в U-образной форме на рис. 10.5, где ежедневный спрос на графике строится в сопоставлении с дневной максимальной температурой.

```
vic_elec_daily <- vic_elec %>%
  filter(year(Time) == 2014) %>%
  index_by(Date = date(Time)) %>%
  summarise(
    Demand = sum(Demand) / 1e3,
    Temperature = max(Temperature),
    Holiday = any(Holiday)
  ) %>%
  mutate(Day_Type = case_when(
    Holiday ~ "Holiday",
    wday(Date) %in% 2:6 ~ "Weekday",
    TRUE ~ "Weekend"
  ))

vic_elec_daily %>%
  ggplot(aes(x = Temperature, y = Demand, colour = Day_Type)) +
  geom_point() +
  labs(y = "Спрос на электроэнергию (ГВт)",
       x = "Максимальная дневная температура")
```

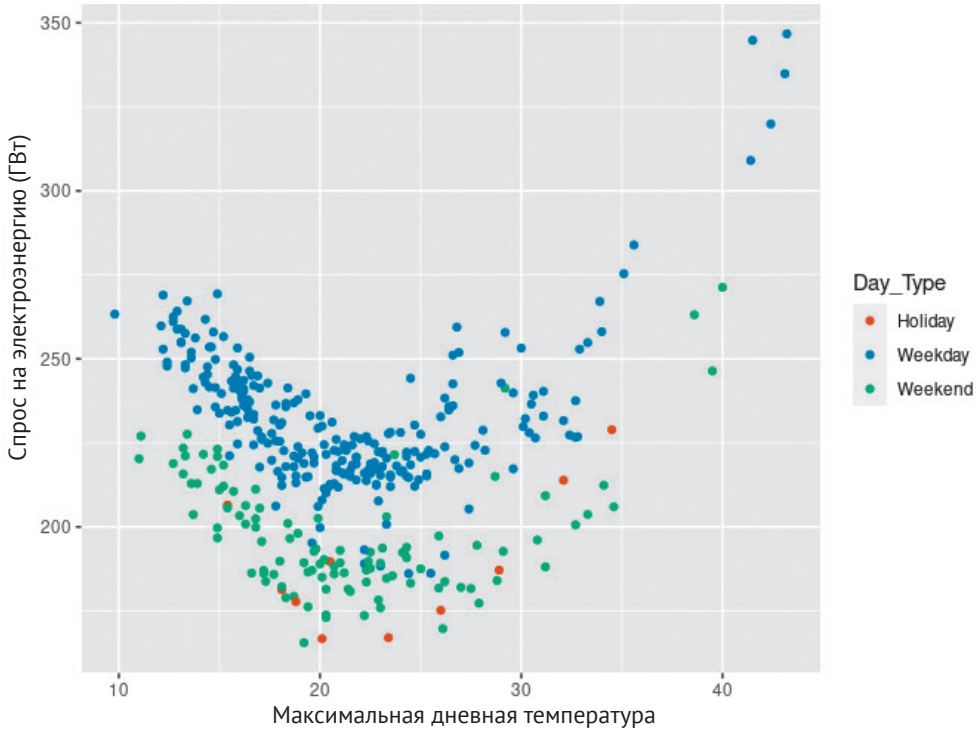


**Рисунок 10.5:** Ежедневный спрос на электроэнергию в зависимости от максимальной дневной температуры для штата Виктория в Австралии за 2014 год

Данные, хранящиеся как `vic_elec_daily`, включают суммарный ежедневный спрос, дневные максимальные температуры и индикаторную переменную, если этот день является национальным праздником. На рис. 10.6 показаны временные ряды как ежедневного спроса, так и дневных максимальных температур. Графики подчеркивают необходимость как нелинейной, так и динамической модели.

```
vic_elec_daily %>%
  pivot_longer(c(Demand, Temperature)) %>%
  ggplot(aes(x = Date, y = value)) +
  geom_line() +
  facet_grid(name ~ ., scales = "free_y") + ylab("")
```

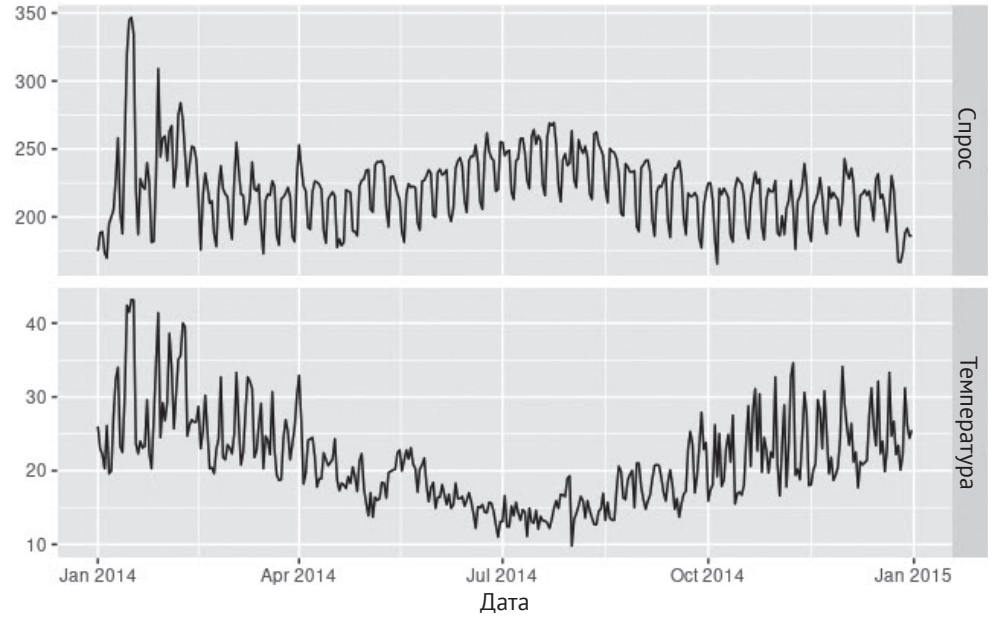


**Рисунок 10.6:** Суточная потребность в электроэнергии и максимальная дневная температура для штата Виктория в Австралии за 2014 год

В этом примере мы выполняем подгонку квадратичной регрессионной модели с ошибками ARMA с помощью функции `ARIMA()`. Модель также включает в себя индикаторную переменную для определения того, был этот день рабочим или нет.

```
fit <- vic_elec_daily %>%
  model(ARIMA(Demand ~ Temperature + I(Temperature^2) +
                (Day_Type == "Weekday")))
fit %>% gg_tsresiduals()
```

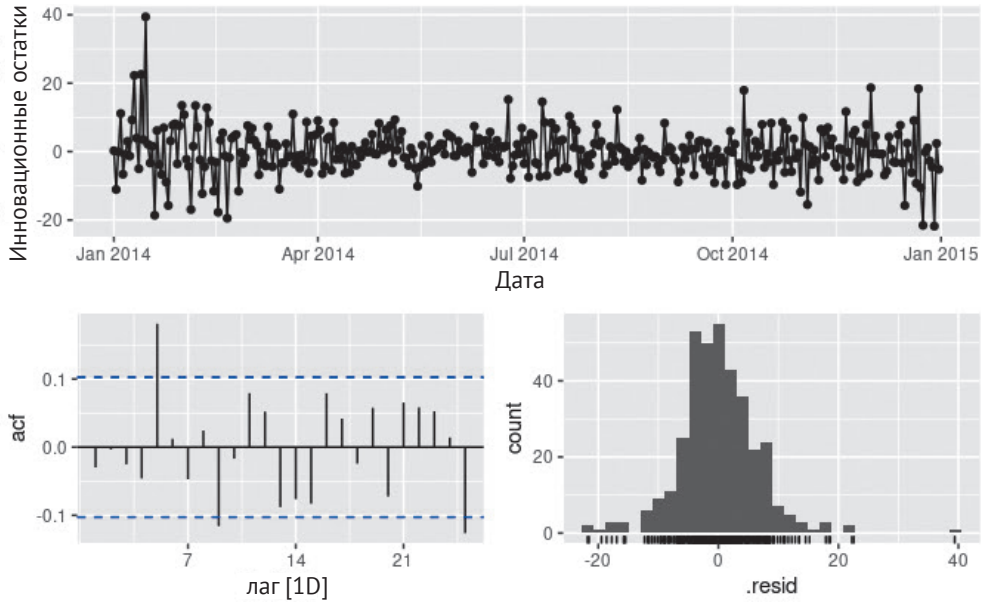


**Рисунок 10.7:** Диагностика остатков для динамической регрессионной модели для суточного спроса на электроэнергию с учетом влияния рабочего дня и квадратичной температуры

```
augment(fit) %>%
  features(.innov, ljung_box, dof = 9, lag = 14)
#> # A tibble: 1 × 3
#>   .model                                                lb_stat lb_
pvalue
#>   <chr>                                                   <dbl>
<dbl>
#> 1 "ARIMA(Demand ~ Temperature + I(Temperature^2) + (Day_Typ…    28.4
0.0000304
```

В остатках наблюдается явная гетероскедастичность: более высокая дисперсия в январе и феврале и более низкая дисперсия в мае. Модель также имеет некоторую значительную автокорреляцию в остатках, и гистограмма остатков показывает длинные хвосты. Все эти проблемы с остатками могут повлиять на охват предсказательных интервалов, но точечные прогнозы все равно должны быть в порядке.

Используя оцененную модель, мы прогнозируем на 14 дней вперед, начиная с четверга 1 января 2015 года (нерабочий день является национальным праздником в связи с Новым годом). В этом случае мы могли бы получить прогнозы погоды от бюро погоды на ближайшие 14 дней. Но в целях иллюстрации мы будем использовать сценарное прогнозирование (как описано в разделе 7.6), где мы устанавливаем температуру на следующие 14 дней на постоянном уровне 26 градусов.

```
vic_elec_future <- new_data(vic_elec_daily, 14) %>%
  mutate(
    Temperature = 26,
    Holiday = c(TRUE, rep(FALSE, 13)),
    Day_Type = case_when(
      Holiday ~ "Holiday",
      wday(Date) %in% 2:6 ~ "Weekday",
      TRUE ~ "Weekend"
    )
  )
forecast(fit, vic_elec_future) %>%
  autoplot(vic_elec_daily) +
  labs(title="Суточный спрос на электроэнергию: Виктория",
       y="ГВт")
```

**Рисунок 10.8:** Прогнозы из динамической регрессионной модели для суточного спроса на электроэнергию. Все будущие температуры были установлены равными 26 градусов, а фиктивная переменная рабочего дня была установлена равной известным будущим значениям

Точечные прогнозы выглядят разумными в первые две недели 2015 года. Замедление спроса на электроэнергию в конце 2014 года (из-за того, что многие люди ушли в летние отпуска) привело к тому, что прогнозы на следующие две недели показали столь же низкие значения спроса.

## 10.4 Стохастические и детерминированные тренды

Существует два разных способа моделирования линейного тренда. Детерминированный тренд получается с использованием регрессионной модели

$$y_t = \beta_0 + \beta_1 t + \eta_t,$$

где $\eta_t$ – это процесс ARMA. Стохастический тренд получается с использованием модели

$$y_t = \beta_0 + \beta_1 t + \eta_t,$$

где $\eta_t$ – это процесс ARIMA с $d = 1$. В последнем случае можно дифференцировать обе стороны так, чтобы $y_t' = \beta_1 + \eta_t'$, где $\eta_t'$ – это процесс ARMA. Другими словами:

$$y_t = y_{t-1} + \beta_1 + \eta_t'.$$

Это похоже на случайное блуждание с дрейфом (введенное в разделе 9.1), но здесь член ошибки – это процесс ARMA, а не просто белый шум.

Хотя эти модели выглядят довольно похожими (они отличаются только числом разниц, которые необходимо применить к $\eta_t$), их прогнозные характеристики совершенно различны.

### Пример: пассажиры воздушного транспорта Австралии

```
aus_airpassengers %>%
  autoplot(Passengers) +
  labs(y = "Пассажиры (млн)",
       title = "Суммарное число авиапассажиров в год ")
```

**Рисунок 10.9:** Суммарное число пассажиров в год (в миллионах) для австралийских авиаперевозчиков, 1970–2016 годы

На рис. 10.9 показано суммарное число пассажиров для австралийских авиаперевозчиков каждый год с 1970-го по 2016-й. Мы применим к этим данным как детерминированную, так и стохастическую трендовую модель.

Детерминированная трендовая модель получается следующим образом:

```
fit_deterministic <- aus_airpassengers %>%
  model(deterministic = ARIMA(Passengers ~ 1 + trend() +
                              pdq(d = 0)))
report(fit_deterministic)
#> Series: Passengers
#> Model: LM w/ ARIMA(1,0,0) errors
#>
#> Coefficients:
#>          ar1  trend()  intercept
#>       0.9564   1.4151     0.9014
#> s.e.  0.0362   0.1972     7.0751
#>
#> sigma^2 estimated as 4.343:  log likelihood=-100.88
#> AIC=209.77   AICc=210.72   BIC=217.17
```

Эту модель можно записать как

$$
\begin{aligned}
y_t &= 0.901 + 1.415t + \eta_t, \\
\eta_t &= 0.956\eta_{t-1} + \varepsilon_t, \\
\varepsilon_t &\sim \mathrm{NID}\left(0, 4.343\right).
\end{aligned}
$$

Оценочный рост числа посетителей составляет 1.42 млн человек в год.

В качестве альтернативы можно оценить стохастическую трендовую модель.

```
fit_stochastic <- aus_airpassengers %>%
  model(stochastic = ARIMA(Passengers ~ pdq(d = 1)))
report(fit_stochastic)
#> Series: Passengers
#> Model: ARIMA(0,1,0) w/ drift
#>
#> Coefficients:
#>       constant
#>         1.4191
#> s.e.    0.3014
#>
#> sigma^2 estimated as 4.271:  log likelihood=-98.16
#> AIC=200.31   AICc=200.59   BIC=203.97
```

Эту модель можно записать как $y_t - y_{t-1} = 1.419 + \varepsilon_t$, либо эквивалентным образом:

$$y_t = y_0 + 1.419t + \eta_t,$$
$$\eta_t = \eta_{t-1} + \varepsilon_t,$$
$$\varepsilon_t \sim \text{NID}\left(0, 4.271\right).$$

В этом случае оценочный рост числа посетителей тоже составляет 1.42 млн человек в год. Хотя оценки роста схожи, предсказательные интервалы отличаются, как показано на рис. 10.10. В частности, стохастические тренды имеют гораздо более широкие предсказательные интервалы, поскольку ошибки нестационарны.

```
aus_airpassengers %>%
  autoplot(Passengers) +
  autolayer(fit_stochastic %>% forecast(h = 20),
    colour = "#0072B2", level = 95) +
  autolayer(fit_deterministic %>% forecast(h = 20),
    colour = "#D55E00", alpha = 0.65, level = 95) +
  labs(y = "Авиапассажиры (млн)",
       title = "Прогнозы из трендовых моделей")
```

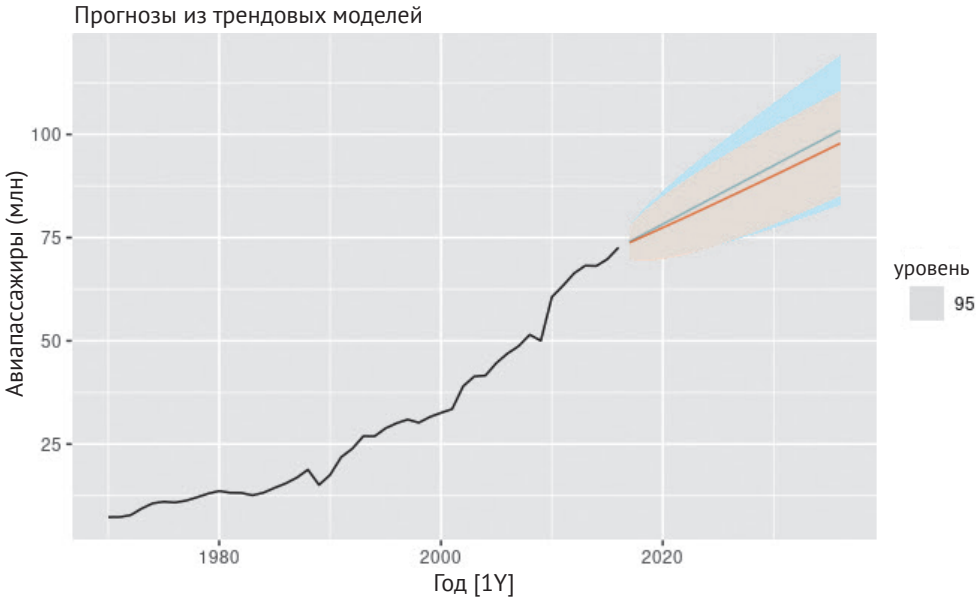


**Рисунок 10.10:** Прогнозы ежегодных пассажиропотоков для австралийских авиаперевозчиков с использованием детерминированной трендовой модели (оранжевый) и стохастической трендовой модели (синий)

В случае детерминированных трендов существует неявное допущение о том, что наклон тренда не будет меняться с течением времени. С другой стороны,

стохастические тренды могут меняться, и оценочный рост допускается только как средний рост за исторический период, а не обязательно как темп роста, который будет наблюдаться в будущем. Следовательно, безопаснее прогнозировать со стохастическими трендами, в особенности на более длительные прогнозные горизонты, поскольку предсказательные интервалы допускают более высокую неопределенность в будущем росте.

## 10.5 Динамическая гармоническая регрессия

При длительных сезонных периодах динамическая регрессия с членами Фурье часто оказывается лучше, чем другие модели, которые мы рассматривали в этой книге[1].

Например, ежедневные данные могут иметь годовую сезонность длиной 365, еженедельные данные имеют сезонный период приблизительно 52, в то время как получасовые данные могут иметь несколько сезонных периодов, самым коротким из которых является дневной период 48.

Сезонные версии моделей ARIMA и ETS рассчитаны на более короткие периоды, такие как 12 для ежемесячных данных или 4 для квартальных данных. Модель `ETS()` ограничивает сезонность максимальным периодом в 24 часа, чтобы разрешить почасовые данные, но не данные с более крупным сезонным периодом. Проблема в том, что для начальных сезонных состояний оцениванию подлежит $m - 1$ параметров, где $m$ – это сезонный период. Так что для крупных $m$ оценивание становится практически невозможным.

Функция `ARIMA()` позволяет использовать сезонный период до $m = 350$, но на практике обычно заканчивается память всякий раз, когда сезонный период превышает примерно 200. В любом случае, сезонное дифференцирование высокого порядка не имеет большого смысла – для ежедневных данных это предусматривает сравнение того, что произошло сегодня, с тем, что произошло ровно год назад, и нет никаких ограничений на то, что сезонная закономерность является плавной.

Поэтому для таких временных рядов мы предпочитаем подход на основе гармонической регрессии, в котором сезонная закономерность моделируется с использованием членов Фурье, а краткосрочная динамика временных рядов обрабатывается ошибкой ARMA.

Преимущества такого подхода заключаются в следующем:

- он допускает сезонность любой продолжительности;
- для данных с более чем одним сезонным периодом могут быть включены члены Фурье с разными частотами;
- плавность сезонной закономерности можно контролировать с помощью $K$, числа синусных и косинусных пар Фурье – сезонная закономерность более плавная при меньших значениях $K$;
- краткосрочная динамика легко обрабатывается с помощью простой ошибки ARMA.

[1] Термин «динамическая гармоническая регрессия» также используется для гармонической регрессии с изменяющимися во времени параметрами (Янг и соавт., 1999, *https://otexts.com/fpp3/dhr.html#ref-DHR99*).

Единственным реальным недостатком (по сравнению с сезонной моделью ARIMA) является то, что предполагается, что сезонность является фиксированной – сезонная закономерность не может изменяться с течением времени. Но на практике сезонность обычно удивительно постоянна, так что это не является большим недостатком, за исключением длинных временных рядов.

## Пример: расходы австралийцев на питание вне дома

В этом примере мы демонстрируем комбинирование членов Фурье для улавливания сезонности с ошибками ARIMA, улавливающими другую динамику в данных. Для простоты мы будем использовать пример с ежемесячными данными. Тот же подход к моделированию с использованием еженедельных данных обсуждается в разделе 13.1.

Мы используем суммарные ежемесячные расходы на кафе, рестораны и услуги питания навынос в Австралии (млрд долларов) с 2004 по 2018 год и прогнозируем на 24 месяца вперед. Мы варьируем $K$, число синусных и косинусных пар Фурье, с $K = 1$ до $K = 6$ (что эквивалентно включению сезонных фиктивных переменных). На рис. 10.11 показана сезонная закономерность, проецируемая вперед, по мере того как $K$ увеличивается. Обратите внимание, что по мере того, как $K$ увеличивается, члены Фурье улавливают и проецируют более «волнистую» сезонную закономерность, и для учета другой динамики требуются более простые модели ARIMA. Значение AICc минимизируется для $K = 6$, со значительным скачком, идущим от $K = 4$ до $K = 5$, следовательно, будут использоваться прогнозы, сгенерированные из этой модели.

```
aus_cafe <- aus_retail %>%
  filter(
    Industry == "Cafes, restaurants and takeaway food services",
    year(Month) %in% 2004:2018
  ) %>%
  summarise(Turnover = sum(Turnover))

fit <- model(aus_cafe,
  `K = 1` = ARIMA(log(Turnover) ~ fourier(K=1) + PDQ(0,0,0)),
  `K = 2` = ARIMA(log(Turnover) ~ fourier(K=2) + PDQ(0,0,0)),
  `K = 3` = ARIMA(log(Turnover) ~ fourier(K=3) + PDQ(0,0,0)),
  `K = 4` = ARIMA(log(Turnover) ~ fourier(K=4) + PDQ(0,0,0)),
  `K = 5` = ARIMA(log(Turnover) ~ fourier(K=5) + PDQ(0,0,0)),
  `K = 6` = ARIMA(log(Turnover) ~ fourier(K=6) + PDQ(0,0,0))
)

fit %>%
  forecast(h = "2 years") %>%
  autoplot(aus_cafe, level = 95) +
  facet_wrap(vars(.model), ncol = 2) +
```

```
  guides(colour = "none", fill = "none", level = "none") +
  geom_label(
    aes(x = yearmonth("2007 Jan"), y = 4250,
        label = paste0("AICc = ", format(AICc))),
    data = glance(fit)
  ) +
  labs(title= "Суммарные ежемесячные расходы на питание вне дома",
       y="млрд $")
```

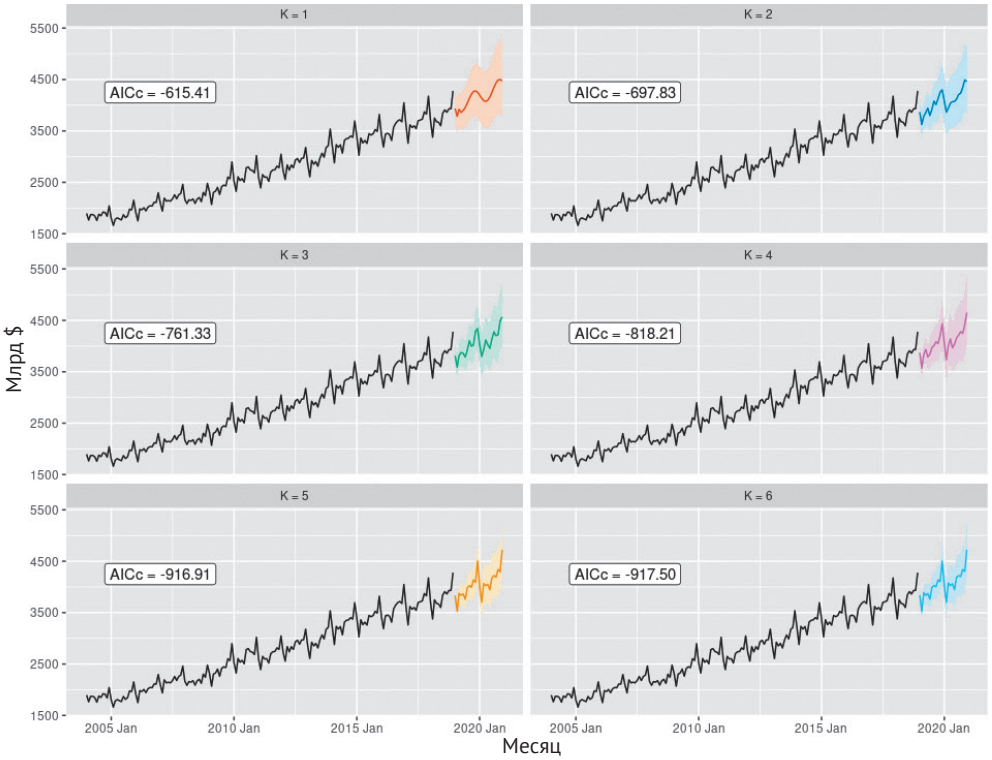


**Рисунок 10.11:** Использование членов Фурье и ошибок ARIMA для прогнозирования ежемесячных расходов на питание вне дома в Австралии

## Библиография

*Янг, П. К., Педрегал, Д. Дж. и Тич, У.* (1999). Динамическая гармоническая регрессия. Journal of Forecasting, 18, 369–394. [DOI: https://doi.org/10.1002/(SICI)1099-131X(199911)18:6%3C369::AID-FOR748%3E3.0.CO;2-K].

# 10.6 Лагированные предсказатели

Иногда влияние предсказателя, включенного в регрессионную модель, не будет простым и немедленным. Например, рекламная кампания может повлиять на продажи в течение некоторого времени после окончания кампании,

а продажи за один месяц будут зависеть от расходов на рекламу за каждый из последних нескольких месяцев. Аналогичным образом изменение политики безопасности компании может немедленно снизить число несчастных случаев, но со временем эффект будет уменьшаться, поскольку сотрудники будут проявлять меньше заботы, когда познакомятся с новыми условиями труда.

В таких ситуациях необходимо учитывать лагированные эффекты предсказателя. Предположим, что в нашей модели есть только один предсказатель. Тогда модель, которая допускает лагированные эффекты, можно записать как

$$y_t = \beta_0 + \gamma_0 x_t + \gamma_1 x_{t-1} + \cdots + \gamma_k x_{t-k} + \eta_t,$$

где $\eta_t$ – это процесс ARIMA. Значение $k$ может быть выбрано, используя AICc вместе со значениями $p$ и $q$ для ошибки ARIMA.

## Пример: телевизионная реклама и страховые котировки

Американская страховая компания дает рекламу по национальному телевидению в попытке увеличить число предоставляемых страховых котировок (и, следовательно, число новых полисов). На рис. 10.12 показано число котировок и расходы компании на телевизионную рекламу каждый месяц с января 2002 года по апрель 2005 года.

```
insurance %>%
  pivot_longer(Quotes:TVadverts) %>%
  ggplot(aes(x = Month, y = value)) +
  geom_line() +
  facet_grid(vars(name), scales = "free_y") +
  labs(y = "", title = "Страховая реклама и котировки")
```

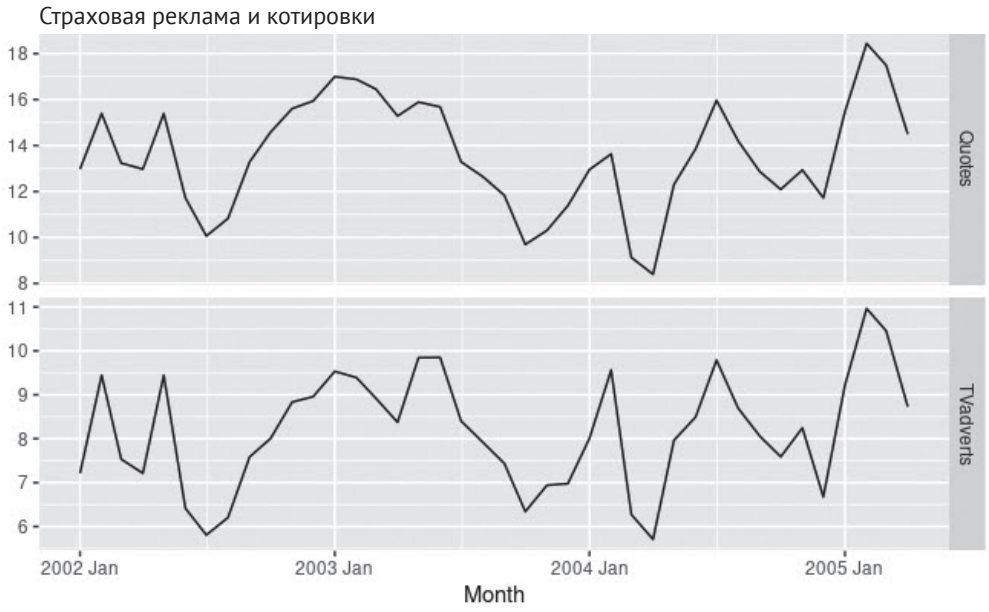


**Рисунок 10.12:** Число страховых котировок, предоставленных в месяц, и расходы на рекламу в месяц

Мы рассмотрим возможность включения расходов на рекламу на срок до четырех месяцев; то есть модель может включать расходы на рекламу в текущем месяце и за три месяца до этого. При сравнении моделей важно, чтобы в них во всех использовался один и тот же тренировочный набор. В следующем ниже исходном коде мы исключаем первые три месяца, чтобы провести объективные сравнения.

```
fit <- insurance %>%
  # Restrict data so models use same fitting period
  mutate(Quotes = c(NA, NA, NA, Quotes[4:40])) %>%
  # Estimate models
  model(
    lag0 = ARIMA(Quotes ~ pdq(d = 0) + TVadverts),
    lag1 = ARIMA(Quotes ~ pdq(d = 0) +
                 TVadverts + lag(TVadverts)),
    lag2 = ARIMA(Quotes ~ pdq(d = 0) +
                 TVadverts + lag(TVadverts) +
                 lag(TVadverts, 2)),
    lag3 = ARIMA(Quotes ~ pdq(d = 0) +
                 TVadverts + lag(TVadverts) +
                 lag(TVadverts, 2) + lag(TVadverts, 3))
  )
```

Далее мы выбираем оптимальную длину лага для рекламы, основываясь на AICc.

```
glance(fit)
#> # A tibble: 4 × 8
#>   .model sigma2 log_lik   AIC  AICc   BIC ar_roots  ma_roots
#>   <chr>   <dbl>   <dbl> <dbl> <dbl> <dbl> <list>    <list>
#> 1 lag0    0.265   -28.3  66.6  68.3  75.0 <cpl [2]> <cpl [0]>
#> 2 lag1    0.209   -24.0  58.1  59.9  66.5 <cpl [1]> <cpl [1]>
#> 3 lag2    0.215   -24.0  60.0  62.6  70.2 <cpl [1]> <cpl [1]>
#> 4 lag3    0.206   -22.2  60.3  65.0  73.8 <cpl [1]> <cpl [1]>
```

Наилучшей моделью (с наименьшим значением AICc) является `lag1` с двумя предсказателями; то есть она включает рекламу только в текущем месяце и в предыдущем месяце. Итак, теперь мы перевычисляем эту модель, но с использованием всех доступных данных.

```
fit_best <- insurance %>%
  model(ARIMA(Quotes ~ pdq(d = 0) +
              TVadverts + lag(TVadverts)))
report(fit_best)
```

```
#> Series: Quotes
#> Model: LM w/ ARIMA(1,0,2) errors
#>
#> Coefficients:
#>          ar1     ma1     ma2  TVadverts  lag(TVadverts)  intercept
#>       0.5123  0.9169  0.4591     1.2527          0.1464     2.1554
#> s.e.  0.1849  0.2051  0.1895     0.0588          0.0531     0.8595
#>
#> sigma^2 estimated as 0.2166:  log likelihood=-23.94
#> AIC=61.88   AICc=65.38   BIC=73.7
```

Выбранная модель имеет ошибки ARIMA(1,0,2). Указанную модель можно записать как

$$y_t = 2.155 + 1.253x_t + 0.146x_{t-1} + \eta_t,$$

где $y_t$ – это число котировок, предоставленных в месяце $t$, $x_t$ – расходы на рекламу в месяце $t$,

$$\eta_t = 0.512\eta_{t-1} + \varepsilon_t + 0.917\varepsilon_{t-1} + 0.459\varepsilon_{t-2},$$

и $\varepsilon_t$ – это белый шум.

Мы можем рассчитать прогнозы, используя эту модель, если примем будущие значения для переменной `advertising`. Если мы установим будущую ежемесячную рекламу в 8 единиц, то получим прогнозы, приведенные на рис. 10.13.

```
insurance_future <- new_data(insurance, 20) %>%
  mutate(TVadverts = 8)
fit_best %>%
  forecast(insurance_future) %>%
  autoplot(insurance) +
  labs(
    y = "Котировки",
    title = "Прогнозные котировки, в которых будущая реклама задана равной 8"
  )
```

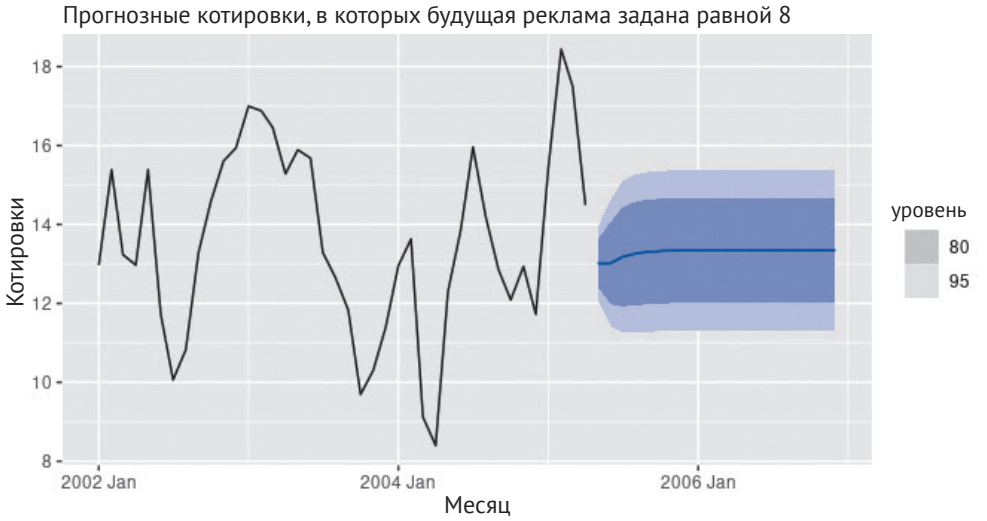


**Рисунок 10.13:** Прогнозы ежемесячных страховых котировок, предполагающие, что будущие расходы на рекламу составят 8 единиц в каждом будущем месяце

## 10.7 Упражнения

1. В этом упражнении используется набор данных LakeHuron, содержащий уровень озера Гурон за 1875–1972 годы.
   a) Конвертируйте данные в объект `tsibble` с помощью функции `as_tsibble()`.
   b) Выполните подгонку кусочно-линейной трендовой модели к данным озера Гурон с узловой точкой в 1920 и структурой ошибок ARMA.
   c) Спрогнозируйте уровень на ближайшие 30 лет. Считаете ли вы, что экстраполированный линейный тренд реалистичен?
2. Повторите упражнение 4 из раздела 7.10, но на этот раз добавьте ошибки ARIMA с целью устранения автокорреляций в остатках.
   a) Насколько сильно влияет процесс ошибки ARIMA на коэффициенты регрессии?
   b) Насколько сильно влияет процесс обработки ошибок ARIMA на прогнозы?
   c) Проверьте остатки подогнанной модели, чтобы убедиться, что процесс ARIMA адекватно учитывал автокорреляции, наблюдаемые в модели `TSLM`.
3. Повторите пример с суточным потреблением электроэнергии, но вместо использования квадратичной функции температуры используйте кусочно-линейную функцию с «узловой точкой» около 25 °C (используйте предсказатели `Temperature` и `Temp2`). Каким образом можно оптимизировать выбор узловой точки?

   Данные могут быть созданы следующим образом.

```
vic_elec_daily <- vic_elec %>%
  filter(year(Time) == 2014) %>%
  index_by(Date = date(Time)) %>%
  summarise(
    Demand = sum(Demand)/1e3,
    Temperature = max(Temperature),
    Holiday = any(Holiday)) %>%
  mutate(
    Temp2 = I(pmax(Temperature-25,0)),
    Day_Type = case_when(
      Holiday ~ "Holiday",
      wday(Date) %in% 2:6 ~ "Weekday",
      TRUE ~ "Weekend"))
```

4. Это упражнение касается `aus_accommodation`: суммарной квартальной выручки от размещения и уровня заполняемости номеров в отелях, мотелях и гостевых домах в Австралии в период с января 1998 года по июнь 2016 года. Общая квартальная выручка исчисляется миллионами австралийских долларов.
   a) Вычислите доходы с поправкой на индекс потребительских цен и постройте график результата для каждого штата.
   b) Для каждого штата выполните подгонку динамической регрессионной модели доходов с поправкой на индекс потребительских цен с сезонными фиктивными переменными, кусочно-линейным временным трендом с одной узловой точкой в 1-м квартале 2008 года и ошибками ARIMA.
   c) Убедитесь, что остатки модели выглядят как белый шум.
   d) Прогнозируйте доходы по каждому штату до конца 2017 года. (Подсказка: сначала вам нужно будет произвести прогнозы индекса потребительских цен.)
   e) Какие источники неопределенности не были учтены в предсказательных интервалах?
5. Мы выполнили подгонку модели гармонической регрессии к части ряда `us_gasoline` в упражнении 5 в разделе 7.10. Теперь вернемся к этой модели и расширим ее, включив в нее больше данных и ошибок ARMA.
   a) Используя `TSLM()`, выполните подгонку гармонической регрессии с кусочно-линейным временным трендом к полному ряду. Выберите положение узловых точек в тренде и соответствующее число членов Фурье для включения, минимизируя значение AICc или CV.
   b) Теперь выполните подгонку модели повторно с помощью `ARIMA()`, чтобы учесть коррелированные ошибки, сохраняя те же предсказательные переменные, которые вы использовали с помощью `TSLM()`.
   c) Проверьте остатки окончательной модели с помощью функции `gg_tsresiduals()` и теста Льюнга–Бокса. Достаточно ли они похожи на белый шум, чтобы продолжать? Если нет, попробуйте изменить свою модель или удалить данные за первые несколько лет.

d) Как только у вас будет модель с остатками в виде белого шума, сгенерируйте прогнозы на следующий год.

6. Потребление электроэнергии часто моделируется как функция от температуры. Температура измеряется ежедневными градусами отопления и градусами охлаждения. Градусы отопления составляют 18 °C минус среднесуточная температура, когда среднесуточная температура ниже 18 °C; в противном случае оно равно нулю. Это дает представление о нашей потребности в подогреве при падении температуры. Градусы охлаждения измеряют нашу потребность в охлаждении по мере повышения температуры. Она определяется как среднесуточная температура минус 18 °C, когда среднесуточное значение выше 18 °C; в противном случае оно равно нулю. Пусть $y_t$ обозначает ежемесячное общее число использованных киловатт-часов электроэнергии, пусть $x_{1,t}$ обозначает ежемесячное общее количество градусов отопления, и пусть $x_{2,t}$ обозначает ежемесячное общее количество градусов охлаждения.

   Аналитик выполняет подгонку следующей модели к набору таких данных:

$$y_t^* = \beta_1 x_{1,t}^* + \beta_2 x_{2,t}^* + \eta_t,$$

   где

$$\left(1-\Phi_1 B^{12}-\Phi_2 B^{24}\right)\left(1-B\right)\left(1-B^{12}\right)\eta_t = \left(1+\theta_1 B\right)\varepsilon_t$$

   и

$$y_t^* = \log\left(y_t\right),\ x_{1,t}^* = \sqrt{x_{1,t}},\ x_{2,t}^* = \sqrt{x_{2,t}}.$$

   a) Какой тип модели ARIMA определен для $\eta_t$?
   b) Оценочные коэффициенты таковы:

| Параметр | Оценка | s. e. | $Z$ | $p$-значение |
|---|---|---|---|---|
| $\beta_1$ | 0.0077 | 0.0015 | 4.98 | 0.000 |
| $\beta_2$ | 0.0208 | 0.0023 | 9.23 | 0.000 |
| $\theta_1$ | −0.5830 | 0.0720 | 8.10 | 0.000 |
| $\Phi_1$ | −0.5373 | 0.0856 | −6.27 | 0.000 |
| $\Phi_2$ | −0.4667 | 0.0862 | −5.41 | 0.000 |

   Объясните, что говорят оценки $\beta_1$ и $\beta_2$ о потреблении электроэнергии.

   a) Запишите уравнение в форме, более подходящей для прогнозирования.
   b) Опишите, как эта модель может быть использована для прогнозирования спроса на электроэнергию на следующие 12 месяцев.
   c) Объясните, почему $\eta_t$-член следует моделировать с помощью модели ARIMA, а не моделировать данные с использованием стандартного регрессионного пакета. В своем обсуждении прокомментируйте свойства оценок, валидность результатов стандартной регрессии и важность $\eta_t$-модели при продуцировании прогнозов.

7. Для временных рядов розничной торговли, рассмотренных в предыдущих главах:
   a) разработайте соответствующую динамическую регрессионную модель с членами Фурье для сезонности. Используйте AICc, чтобы отобрать число членов Фурье для включения в модель (вероятно, вам потребуется использовать то же преобразование Бокса–Кокса, которое вы определили ранее);
   b) проверьте остатки подогнанной модели. Выглядит ли ряд остатков как белый шум?
   c) сравните прогнозы с теми, которые вы получили ранее, используя альтернативные модели.

## 10.8 Дальнейшее чтение

Подробное обсуждение моделей динамической регрессии приведено в Панкрац (1991, *https://otexts.com/fpp3/dynamic-reading.html#ref-Pankratz91*).

Обобщение моделей динамической регрессии, именуемых «моделями передаточных функций», обсуждается в Бокс и соавт. (2015, *https://otexts.com/fpp3/dynamic-reading.html#ref-BJRL15*).

## Библиография

*Бокс, Дж. Е. П., Дженкинс, Дж. М., Райнсел, Дж. К. и Льюнг, Дж. М.* (2015). Анализ временных рядов: прогнозирование и контроль (5-е изд.). John Wiley & Sons. [Amazon, *http://buy.geni.us/Proxy.ashx?TSID=140570&GR_URL=http%3A%2F%2Fwww.amazon.com%2Fdp%2F1118675029*].

*Панкрац, А. Э.* (1991). Прогнозирование с помощью динамических регрессионных моделей. John Wiley & Sons. [Amazon, *http://buy.geni.us/Proxy.ashx?TSID=140570&GR_URL=http%3A%2F%2Fwww.amazon.com%2Fdp%2F0471615285*].

# Глава 11

# Прогнозирование иерархических и сгруппированных временных рядов

Временные ряды часто могут быть естественным образом дезагрегированы по различным представляющим интерес признакам. Например, суммарное число велосипедов, проданных производителем велосипедов, может быть дезагрегировано по видам продукции, таким как дорожные велосипеды, горные велосипеды и гибриды. Каждая из них может быть дезагрегирована на более мелкие категории. Например, гибридные велосипеды можно разделить на городские, для пригородных поездок, комфортные и треккинговые велосипеды и т. д. Эти категории вложены в категории более крупных групп, и, значит, коллекция временных рядов соответствует иерархической агрегационной структуре. Поэтому мы называем их «иерархическими временными рядами».

Иерархические временные ряды часто возникают из-за географического деления. Например, суммарный объем продаж велосипедов может быть дезагрегирован по странам, затем внутри каждой страны по штатам, внутри каждого штата по регионам и так далее вплоть до уровня торговых точек.

Альтернативные агрегационные структуры возникают, когда интересующие атрибуты пересекаются, а не вложены. Например, производитель велосипедов может быть заинтересован в таких атрибутах, как размер рамы, пол, ценовой диапазон и т. д. Такие атрибуты не дезагрегируются легко в уникальном иерархическом ключе, поскольку атрибуты не являются вложенными. Мы называем результирующий временной ряд пересекающихся атрибутов «сгруппированным временным рядом».

Более сложные структуры возникают, когда представляющие интерес атрибуты являются как вложенными, так и пересекающимися. Например, для производителя велосипедов было бы естественно интересоваться продажами по видам продукции, а также по географическому делению. Тогда группировки продуктов и географическая иерархия смешиваются вместе. Мы вводим альтернативные агрегационные структуры в разделе 11.1.

Прогнозы часто требуются для всех дезагрегированных и агрегированных рядов, и возникает естественная потребность в том, чтобы прогнозы суммировались таким же образом, как и данные. Например, прогнозы региональных продаж должны суммироваться с прогнозами продаж в штатах, которые, в свою очередь, должны суммироваться, чтобы дать прогноз национальных продаж.

В этой главе мы обсуждаем прогнозирование крупных коллекций временных рядов, которые каким-то образом агрегируются. Проблема заключается в том, что нам требуются прогнозы, которые были бы **когерентными** по всей агрегационной структуре[1]. То есть требуется, чтобы прогнозы суммировались таким образом, чтобы это соответствовало агрегационной структуре иерархии или группы, которая определяет коллекцию временных рядов.

# 11.1 Иерархические и сгруппированные временные ряды

## Иерархические временные ряды

На рис. 11.1 показана простая иерархическая структура. На вершине иерархии находится «Общий», наиболее агрегированный уровень данных. $t$-е наблюдение *Общего* ряда обозначается через $y_t$ для $t = 1, \ldots, T$. Общий ряд разбивается на два ряда, которые, в свою очередь, делятся соответственно на три и два ряда на нижнем уровне иерархии. Ниже верхнего уровня мы используем $y_{j,t}$ для обозначения $t$-го наблюдения ряда, соответствующего узлу $j$. Например, $y_{\text{A},t}$ обозначает $t$-е наблюдение ряда, соответствующего узлу A, $y_{\text{AB},t}$ обозначает $t$-е наблюдение ряда, соответствующего узлу AB, и т. д.

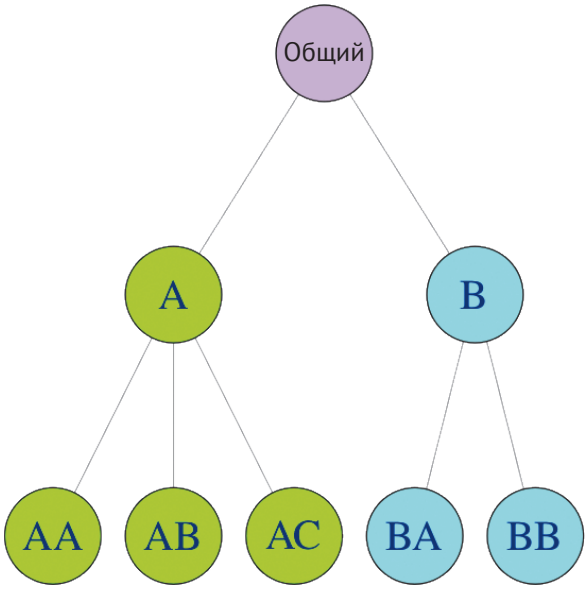


**Рисунок 11.1:** Двухуровневая иерархическая древовидная диаграмма

[1] В общем случае когерентный прогноз (coherent forecast) – это прогноз, который удовлетворяет ограничениям агрегирования. – *Прим. перев.*

В этом небольшом примере суммарное число рядов в иерархии равно $n = 1 + 2 + 5 = 8$, в то время как число рядов на нижнем уровне равно $m = 5$. Обратите внимание, что во всех иерархиях $n > m$.

В течение любого времени $t$ наблюдения на нижнем уровне иерархии будут суммироваться с наблюдениями из вышестоящего ряда. Например:

$$y_t = y_{\mathrm{AA},t} + y_{\mathrm{AB},t} + y_{\mathrm{AC},t} + y_{\mathrm{BA},t} + y_{\mathrm{BB},t}, \tag{11.1}$$

$$y_{\mathrm{A},t} = y_{\mathrm{AA},t} + y_{\mathrm{AB},t} + y_{\mathrm{AC},t} \;\&\; y_{\mathrm{B},t} = y_{\mathrm{BA},t} + y_{\mathrm{BB},t}. \tag{11.2}$$

Подставляя (11.2) в (11.1), мы также получаем $y_t = y_{\mathrm{A},t} + y_{\mathrm{B},t}$.

## Пример: иерархия туризма в Австралии

Австралия поделена на шесть штатов и две территории, каждый(ая) из которых имеет свое собственное правительство и некоторую экономическую и административную автономию. Для простоты мы называем как штаты, так и территории «штатами». Каждый штат может быть дополнительно поделен на регионы, как показано на рис. 11.2 и в табл. 11.1. Всего таких регионов 76. Специалисты по бизнес-планированию и туристические ведомства заинтересованы в прогнозах для всей Австралии, для каждого штата и территории, а также для регионов.

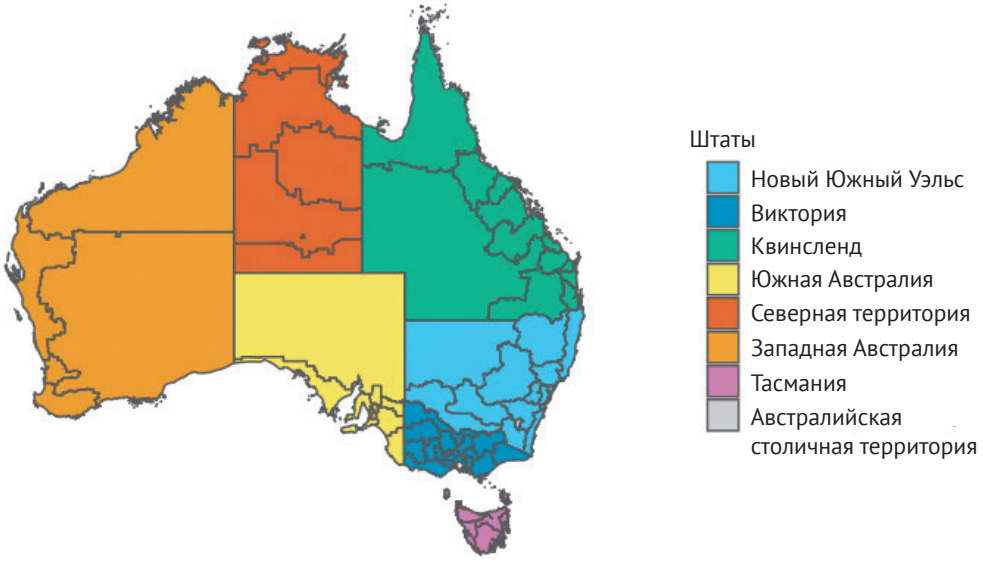


**Рисунок 11.2:** Австралийские штаты и туристические регионы

**Таблица 11.1:** Туристические регионы Австралии

| Штат | Регион |
|---|---|
| Австралийская столичная территория | Канберра |
| Новый Южный Уэльс | Голубые горы, Столица страны, Центральное побережье, Центральный Новый Южный Уэльс, Хантер, Северо-Запад Новой Англии, Северное побережье Нового Южного Уэльса, Глубинка Нового Южного Уэльса, Риверина, Снежные горы, Южное побережье, Сидней, Мюррей |
| Северная территория | Алис-Спрингс, Баркли, Дарвин, Какаду Арнем, Кэтрин Дейли, Лассетер, Макдоннелл |
| Квинсленд | Брисбен, Бандаберг, Центральный Квинсленд, Дарлинг-Даунс, Фрейзер-Кост, Голд-Кост, Маккей, Северная Глубинка, Саншайн-Кост, Тропический Северный Квинсленд, Уитсандейс |
| Южная Австралия | Аделаида, Холмы Аделаиды, Баросса, долина Клэр, полуостров Эйр, полуостров Флерье, Хребты Флиндерс и Аутбэк, остров Кенгуру, Известняковое побережье, Мюррейлендс, Риверленд, полуостров Йорк |
| Тасмания | Восточное побережье, Хобарт и Юг, Лонсестон-Тамар и Север, Северо-Запад, Дикий Запад |
| Виктория | Балларат, Бендиго-Лоддон, Сентрал-Хайлендс, Сентрал-Мюррей, Джилонг и Белларин, Гиппсленд, Гоулберн, Грейт-Оушен-Роуд, Хай-Кантри, Лейкс, Македон, Малли, Мельбурн, Мельбурн-Ист, Мюррей-Ист, Полуостров, остров Филлип, Спа-Кантри, Аппер-Ярра, Вестерн-Грампианс, Виммера |
| Западная Австралия | Коралловое побережье Австралии, Золотая глубинка Австралии, Северо-Запад Австралии, Юго-Запад Австралии, Туристический Перт |

Объект twibble под названием `tourism` содержит данные о ежеквартальном спросе на внутренний туризм, измеряемом как число поездок с ночевкой, которые австралийцы осуществляют, чтобы провести время вдали от дома. Переменные-ключи `State` и `Region` обозначают географические районы, в то время как еще один ключ `Purpose` описывает цель поездки. На данный момент мы проигнорируем цель поездки и просто рассмотрим географическую иерархию. С целью упрощения графиков и таблиц мы перекодируем `State`, чтобы использовать аббревиатуры.

```
tourism <- tsibble::tourism %>%
  mutate(State = recode(State,
    `New South Wales` = "NSW",
    `Northern Territory` = "NT",
    `Queensland` = "QLD",
    `South Australia` = "SA",
    `Tasmania` = "TAS",
    `Victoria` = "VIC",
    `Western Australia` = "WA"
  ))
```

Применяя функцию `aggregate_key()`, можно создать иерархический временной ряд с поездками в регионах на нижнем уровне иерархии, агрегированный по штатам, которые агрегируются в суммарное число в национальном масштабе. Иерархический временной ряд, соответствующий вложенной структуре, создается с использованием спецификации «родительский элемент / дочерний элемент».

```
tourism_hts <- tourism %>%
  aggregate_key(State / Region, Trips = sum(Trips))
tourism_hts
#> # A tsibble: 6,800 x 4 [1Q]
#> # Key:       State, Region [85]
#>    Quarter State        Region        Trips
#>      <qtr> <chr*>       <chr*>        <dbl>
#>  1 1998 Q1 <aggregated> <aggregated> 23182.
#>  2 1998 Q2 <aggregated> <aggregated> 20323.
#>  3 1998 Q3 <aggregated> <aggregated> 19827.
#>  4 1998 Q4 <aggregated> <aggregated> 20830.
#>  5 1999 Q1 <aggregated> <aggregated> 22087.
#>  6 1999 Q2 <aggregated> <aggregated> 21458.
#>  7 1999 Q3 <aggregated> <aggregated> 19914.
#>  8 1999 Q4 <aggregated> <aggregated> 20028.
#>  9 2000 Q1 <aggregated> <aggregated> 22339.
#> 10 2000 Q2 <aggregated> <aggregated> 19941.
#> # … и еще 6 790 строк
```

В новом объекте twibble теперь есть несколько дополнительных строк, соответствующих агрегациям по штатам и в национальном масштабе за каждый квартал. На рис. 11.3 показаны совокупные числа поездок с ночевкой по всей Австралии, а также по штатам, демонстрируя разнообразную и богатую динамику. Например, с 2010 года наблюдается заметный рост в национальном масштабе, а также в некоторых штатах, таких как Австралийская столичная территория, Новый Южный Уэльс, Квинсленд, Южная Австралия и Виктория. Похоже, что в 2014 году в Западной Австралии произойдет значительный скачок.

```
tourism_hts %>%
  filter(is_aggregated(Region)) %>%
  autoplot(Trips) +
  labs(y = "Поездки (тыс.)",
       title = "Туризм в Австралии: в национальном масштабе и по штатам") +
  facet_wrap(vars(State), scales = "free_y", ncol = 3) +
  theme(legend.position = "none")
```

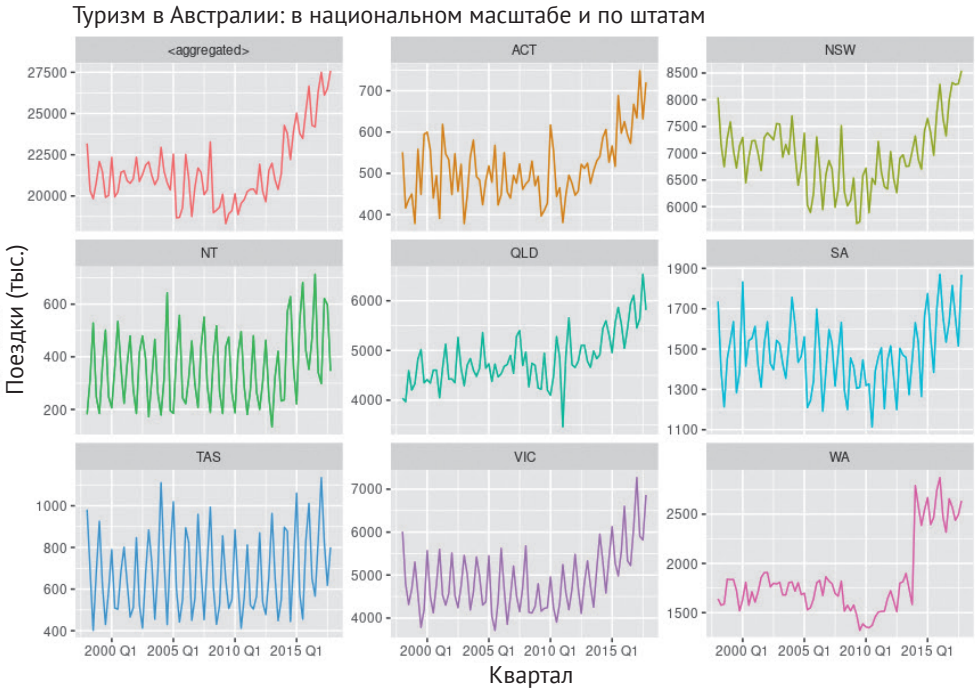


**Рисунок 11.3:** Внутренние поездки с ночевкой за период 1998Q1–2017Q4, агрегированные по штатам

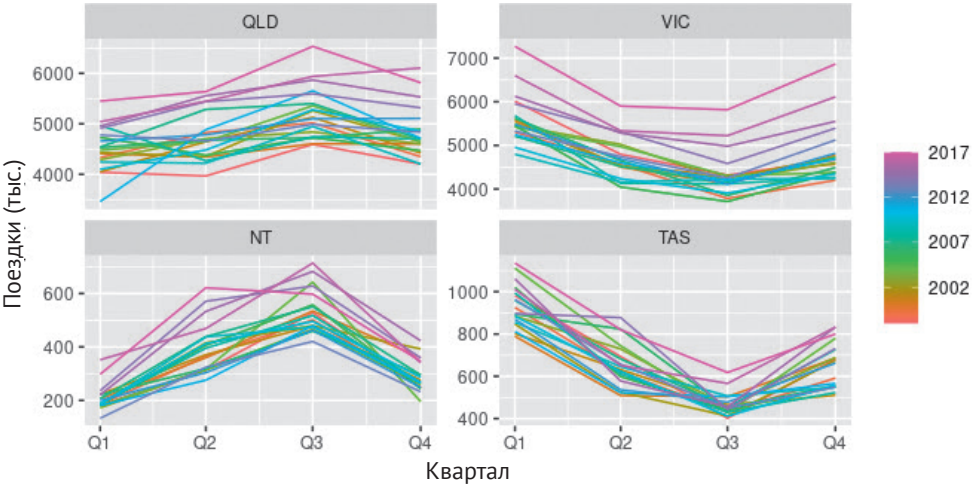


**Рисунок 11.4:** Сезонные графики поездок с ночевкой для Квинсленда и Северной территории, а также Виктории и Тасмании, подчеркивающие контраст в сезонных закономерностях между северными и южными штатами Австралии

Сезонная закономерность северных штатов, таких как Квинсленд и Северная территория, приводит к пику посещений зимой (соответствует 3-му кварталу) из-за тропического климата и дождливых летних месяцев. На-

против, в южных штатах, как правило, пик приходится на лето (соответствует 1-му кварталу). Это подчеркивается на сезонных графиках, показанных на рис. 11.4 для Квинсленда и Северной территории (см. левую колонку) по сравнению с самыми южными штатами Виктория и Тасмания (см. правую колонку).

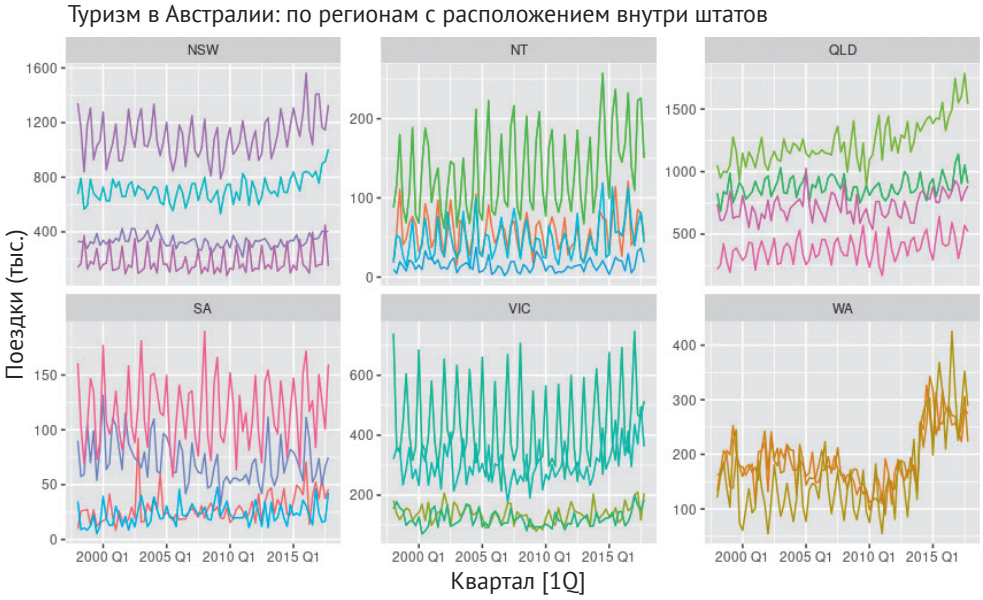


**Рисунок 11.5:** Внутренние поездки с ночевкой за период 1998Q1–2017Q4 для некоторых отдельных регионов

Графики на рис. 11.5 показывают данные для некоторых выбранных регионов. Это помогает визуализировать разнообразную региональную динамику в каждом штате: некоторые ряды демонстрируют сильные тренды или сезонность, некоторые демонстрируют контрастную сезонность, в то время как другие ряды кажутся просто шумом.

## Сгруппированные временные ряды

При использовании сгруппированных временных рядов структура данных не дезагрегируется легко в уникальном иерархическом ключе. На рис. 11.6 показана простая сгруппированная структура. В верхней части сгруппированной структуры находится *Общий*, наиболее агрегированный уровень данных, снова представленный $y_t$. *Общий* может быть дезагрегирован по признакам (A, B), образующим ряды $y_{A,t}$ и $y_{B,t}$, или по атрибутам (X, Y), образующим ряды $y_{X,t}$ и $y_{Y,t}$. На нижнем уровне данные дезагрегированы по обоим признакам.

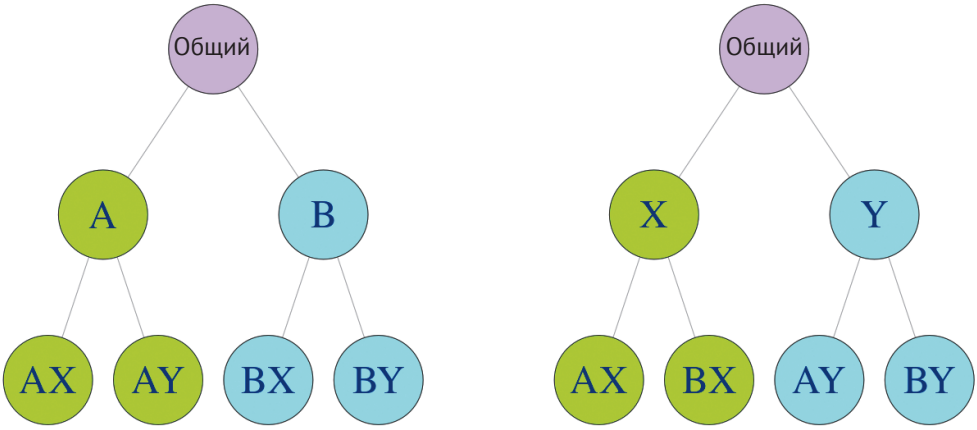


**Рисунок 11.6:** Альтернативные представления двухуровневой сгруппированной структуры

Приведенный пример показывает, что для сгруппированных структур существуют альтернативные агрегационные пути. Для любого времени $t$, как и в случае с иерархической структурой:

$$y_t = y_{\mathrm{AX},t} + y_{\mathrm{AY},t} + y_{\mathrm{BX},t} + y_{\mathrm{BY},t}.$$

Однако для первого уровня сгруппированной структуры:

$$y_{\mathrm{A},t} = y_{\mathrm{AX},t} + y_{\mathrm{AY},t} \qquad y_{\mathrm{B},t} = y_{\mathrm{BX},t} + y_{\mathrm{BY},t} \tag{11.3}$$

но также и

$$y_{\mathrm{X},t} = y_{\mathrm{AX},t} + y_{\mathrm{BX},t} \qquad y_{\mathrm{Y},t} = y_{\mathrm{AY},t} + y_{\mathrm{BY},t}. \tag{11.4}$$

Сгруппированные временные ряды иногда можно рассматривать как иерархические временные ряды, которые не налагают уникальную иерархическую структуру, в том смысле, что порядок, в котором ряды могут быть сгруппированы, не является уникальным.

## Пример: тюремное население Австралии

В этом примере мы рассмотрим данные о тюремном населении Австралии, представленные в главе 2. Верхняя панель на рис. 11.7 показывает суммарную численность заключенных в Австралии за период 2005Q1–2016Q4. Оно представляет собой верхнеуровневый ряд в структуре группировки. На приведенных ниже панелях показано тюремное население, дезагрегированное или сгруппированное по (а) штату, (б) правовому статусу (были ли заключенные уже осуждены или находятся в предварительном заключении в ожидании приговора) и (в) полу. Эти три фактора пересекаются, но ни один из них не вложен в другие.

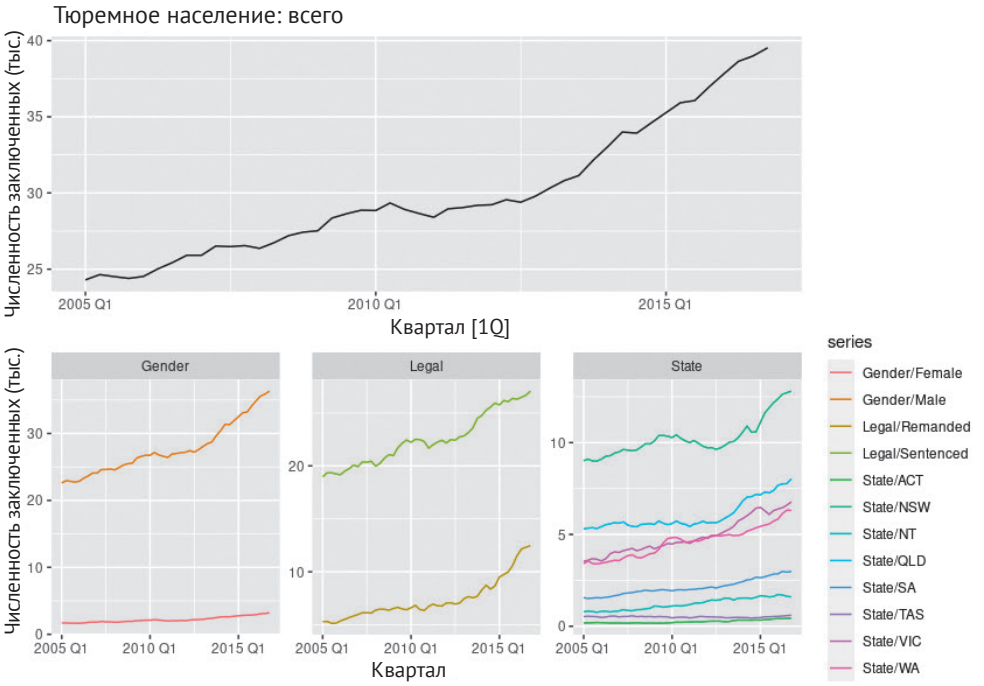


**Рисунок 11.7:** Суммарное взрослое тюремное население Австралии поквартально в разбивке по штатам, правовому статусу и полу

Следующий ниже исходный код, представленный в разделе 2.1, создает объект twiddle для тюремных данных.

```
prison <- readr::read_csv("https://OTexts.com/fpp3/extrafiles/prison_population.
csv") %>%
  mutate(Quarter = yearquarter(Date)) %>%
  select(-Date)  %>%
  as_tsibble(key = c(Gender, Legal, State, Indigenous),
             index = Quarter) %>%
  relocate(Quarter)
```

Мы создаем сгруппированный временной ряд с помощью `aggregate_key()` с представляющими интерес атрибутами или группировками, которые теперь пересекаются с использованием синтаксиса «атрибут1*атрибут2» (в отличие от синтаксиса «родительский элемент / дочерний элемент», используемого для иерархических временных рядов). Следующий ниже исходный код создает сгруппированный объект twibble для тюремных данных с пересеченными атрибутами: пол, правовой статус и штат.

```
prison_gts <- prison %>%
  aggregate_key(Gender * Legal * State, Count = sum(Count)/1e3)
```

Использование `is_aggregated()` в `filter()` полезно для проведения разведывательного анализа или построения графиков главных групп, показанных на нижних панелях рис. 11.7. Например, следующий ниже исходный код выводит на экран суммарную численность заключенных женского и мужского пола по всей Австралии.

```
prison_gts %>%
  filter(!is_aggregated(Gender), is_aggregated(Legal),
         is_aggregated(State)) %>%
  autoplot(Count) +
  labs(y = "Численность заключенных (тыс.)")
```

Графики других групповых комбинаций могут быть получены аналогичным образом. На рис. 11.8 показано тюремное население Австралии, сгруппированное по всем возможным комбинациям двух атрибутов одновременно: штат и пол, штат и правовой статус, а также правовой статус и пол. Следующий ниже исходный код воспроизведет первый график на рис. 11.8.

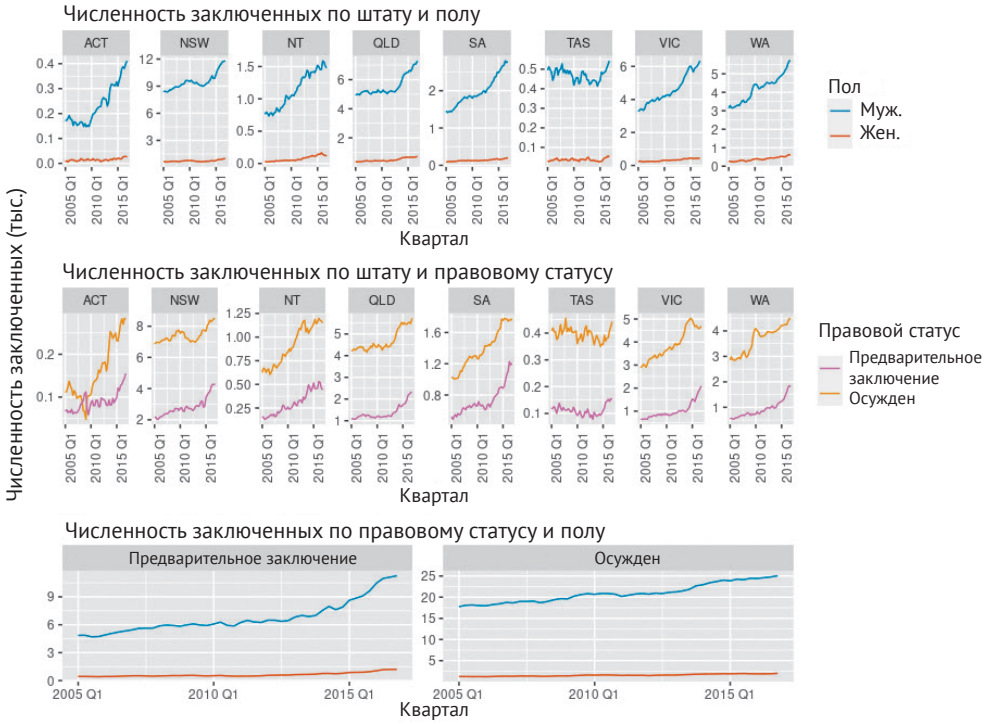


**Рисунок 11.8:** Взрослое тюремное население Австралии в разбивке по парам признаков

```
prison_gts %>%
  filter(!is_aggregated(Gender), !is_aggregated(Legal),
         !is_aggregated(State)) %>%
  mutate(Gender = as.character(Gender)) %>%
```

```
ggplot(aes(x = Quarter, y = Count,
           group = Gender, colour=Gender)) +
stat_summary(fun = sum, geom = "line") +
labs(title = "Тюремное население по штату и полу",
     y = "Численность заключенных (тыс.)") +
facet_wrap(~ as.character(State),
           nrow = 1, scales = "free_y") +
theme(axis.text.x = element_text(angle = 90, hjust = 1))
```

На рис. 11.9 показано взрослое тюремное население Австралии в разбивке по всем трем признакам: штат, правовой статус и пол. Они образуют нижнеуровневые ряды сгруппированной структуры.

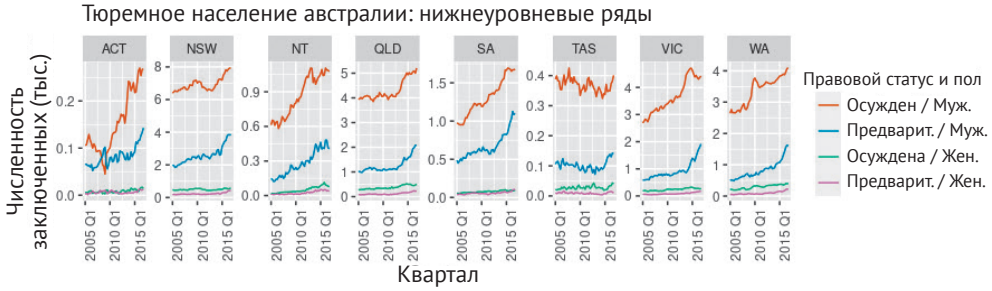


**Рисунок 11.9:** Временные ряды нижнего уровня для взрослого тюремного населения Австралии, сгруппированные по штатам, правовому статусу и полу

## Смешанная иерархическая и групповая структура

Дезагрегирующие факторы нередко являются как вложенными, так и перекрестными. Например, данные о туризме в Австралии также могут быть дезагрегированы по четырем целям поездки: отдых, деловые поездки, посещение друзей и родственников и др. Эта группирующая переменная не входит ни в одну из географических переменных. На самом деле можно было бы рассмотреть поездки в разбивке по целям поездки, для всей Австралии, для каждого штата и для каждого региона. Мы описываем такую структуру как «вложенную» географическую иерархию, «пересеченную» с атрибутом цели поездки. Используя `aggregate_key()`, это можно задать, просто скомбинировав факторы.

```
tourism_full <- tourism %>%
  aggregate_key((State/Region) * Purpose, Trips = sum(Trips))
```

Таблица `tourism_full` содержит 425 рядов, включая 85 рядов из иерархической структуры, а также еще 340 рядов, полученных путем пересечения каждого ряда иерархической структуры с атрибутом цели поездки.

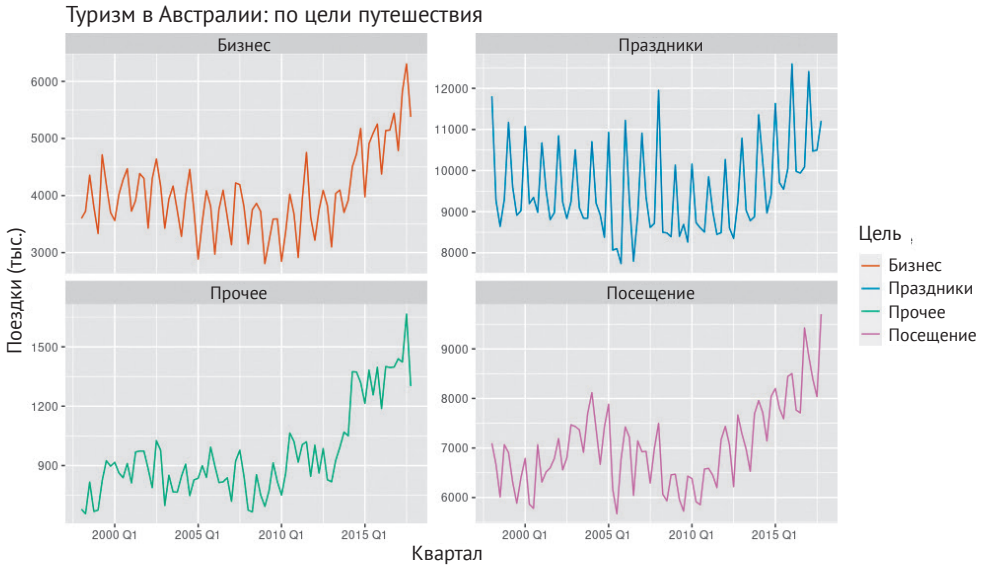


**Рисунок 11.10:** Внутренние поездки с ночевкой в Австралии за период 1998Q1–2017Q4 в разбивке по целям поездок

**Рисунок 11.11:** Внутренние поездки с ночевкой в Австралии за период 1998Q1–2017Q4 в разбивке по целям поездок и штатам

На рис. 11.10 и 11.11 показаны агрегатные ряды, сгруппированные по цели поездки, и ряды, сгруппированные по цели поездки и штату, обнаруживая дальнейшую богатую и разнообразную динамику в этих рядах.

## 11.2 Одноуровневые подходы

Традиционно прогнозирование на иерархических или сгруппированных временных рядах предусматривало выбор одного уровня агрегации и генерирование прогнозов для этого уровня. Затем они либо агрегируются для более высоких уровней, либо дезагрегируются для более низких уровней, чтобы получить набор когерентных прогнозов для остальной части структуры.

### Подход «снизу вверх»

Простым методом формирования когерентных прогнозов является подход «снизу вверх», или восходящий подход. Указанный подход предусматривает сначала генерирование прогнозов для каждого ряда на нижнем уровне, а затем их суммирование с целью получения прогнозов для всех рядов в структуре.

Например, для иерархии, показанной на рис. 11.1, мы сначала генерируем прогнозы на $h$ шагов вперед для каждого ряда нижнего уровня:

$$\hat{y}_{\mathrm{AA},h}, \hat{y}_{\mathrm{AB},h}, \hat{y}_{\mathrm{AC},h}, \hat{y}_{\mathrm{BA},h} \text{ и } \hat{y}_{\mathrm{BB},h}$$

(для краткости мы упростили ранее использовавшуюся нотацию $\hat{y}_{T+h|T}$).

Суммируя их, мы получаем когерентные прогнозы на $h$ шагов вперед для остальной части ряда:

$$\begin{aligned}
\tilde{y}_h &= \hat{y}_{\mathrm{AA},h} + \hat{y}_{\mathrm{AB},h} + \hat{y}_{\mathrm{AC},h} + \hat{y}_{\mathrm{BA},h} + \hat{y}_{\mathrm{BB},h}, \\
\tilde{y}_{\mathrm{A},h} &= \hat{y}_{\mathrm{AA},h} + \hat{y}_{\mathrm{AB},h} + \hat{y}_{\mathrm{AC},h}, \\
\tilde{y}_{\mathrm{B},h} &\hat{y}_{\mathrm{BA},h} + \hat{y}_{\mathrm{BB},h}.
\end{aligned}$$

(В этой главе мы будем использовать нотацию «тильда» для обозначения когерентных прогнозов.)

Преимущество указанного подхода заключается в том, что мы прогнозируем на нижнем уровне структуры, и поэтому никакая информация не теряется из-за агрегации. С другой стороны, данные нижнего уровня бывают довольно шумными, и нередко на них сложно моделировать и прогнозировать.

### Пример: генерирование восходящих прогнозов

Предположим, нам нужны прогнозы для данных о туризме в Австралии в национальном масштабе и в разбивке по штатам, но нас не интересуют дезагрегации по регионам или цели поездки. Итак, сначала мы создаем простой объект twiddle, содержащий только суммарные поездки по штатам и в национальном масштабе за каждый квартал.

```
tourism_states <- tourism %>%
  aggregate_key(State, Trips = sum(Trips))
```

Мы могли бы сначала сгенерировать нижнеуровневые прогнозы по штатам, а затем их просуммировать, чтобы получить национальные прогнозы.

```
fcasts_state <- tourism_states %>%
  filter(!is_aggregated(State)) %>%
  model(ets = ETS(Trips)) %>%
  forecast()

# Суммировать нижнеуровневые прогнозы, чтобы получить верхнеуровневые прогнозы
fcasts_national <- fcasts_state %>%
  summarise(value = sum(Trips), .mean = mean(value))
```

Однако нам нужен более общий подход, который будет работать со всеми методами прогнозирования, обсуждаемыми в этой главе. Поэтому мы будем использовать функцию `reconcile()`, чтобы указать, как мы хотим вычислять когерентные прогнозы.

```
tourism_states %>%
  model(ets = ETS(Trips)) %>%
  reconcile(bu = bottom_up(ets)) %>%
  forecast()
#> # A fable: 144 x 5 [1Q]
#> # Key:     State, .model [18]
#>    State  .model Quarter         Trips .mean
#>    <chr*> <chr>    <qtr>        <dist> <dbl>
#>  1 ACT    ets    2018 Q1  N(701, 7651)  701.
#>  2 ACT    ets    2018 Q2  N(717, 8032)  717.
#>  3 ACT    ets    2018 Q3  N(734, 8440)  734.
#>  4 ACT    ets    2018 Q4  N(750, 8882)  750.
#>  5 ACT    ets    2019 Q1  N(767, 9368)  767.
#>  6 ACT    ets    2019 Q2  N(784, 9905)  784.
#>  7 ACT    ets    2019 Q3 N(800, 10503)  800.
#>  8 ACT    ets    2019 Q4 N(817, 11171)  817.
#>  9 ACT    bu     2018 Q1  N(701, 7651)  701.
#> 10 ACT    bu     2018 Q2  N(717, 8032)  717.
#> # … и еще 134 строки
```

Шаг `reconcile()` создал новую «модель» для продуцирования восходящих прогнозов. Объект fable содержит прогнозы `ets`, а также когерентные прогнозы `bu` для 8 штатов и национального агрегата. На национальном уровне эти прогнозы идентичны, но национальные прогнозы `ets` будут отличаться от национальных прогнозов `bu`.

Для прогнозирования снизу вверх это довольно неэффективно, поскольку нас не интересует модель ETS для общенационального показателя, и результирующий объект fable содержит много дубликатов. Но позже мы представим более продвинутые методы, где нам понадобятся модели для всех уровней агрегации и где когерентные прогнозы отличаются от любого из изначальных прогнозов.

## Рабочий поток прогнозирования агрегационных структур

Приведенный выше исходный код иллюстрирует общий рабочий поток для иерархических и сгруппированных прогнозов. Мы используем следующий ниже конвейер функций.

```
data %>% aggregate_key() %>% model() %>%
  reconcile() %>% forecast()
```

1. Начать с объекта twiddle (здесь обозначенного как `data`), содержащего индивидуальные ряды нижнего уровня.
2. Определить в `aggregate_key()` агрегационную структуру и построить объект `tiddle`, который также содержит агрегатный ряд.
3. Идентифицировать `model()` для каждого ряда на всех уровнях агрегации.
4. Указать в `reconcile()`, как должны генерироваться когерентные прогнозы из отобранных моделей.
5. Использовать функцию `forecast()`, чтобы сгенерировать прогнозы для всей агрегационной структуры.

## Подходы «сверху вниз»

Подходы «сверху вниз», или нисходящие подходы, предполагают сначала генерирование прогнозов для *Общего* ряда $y_t$, а затем их дезагрегирование вниз по иерархии.

Обозначим через $p_1, \ldots, p_m$ набор дезагрегационных пропорций, которые определяют, как должны распределяться прогнозы *Общего* ряда, чтобы получить прогнозы для каждого ряда на нижнем уровне структуры. Например, для иерархии на рис. 11.1, используя пропорции $p_1, \ldots, p_5$, мы получаем:

$$\tilde{y}_{\mathrm{AA},t} = p_1 \ddot{y}_t,\ \tilde{y}_{\mathrm{AB},t} = p_2 \ddot{y}_t,\ \tilde{y}_{\mathrm{AC},t} = p_3 \ddot{y}_t,\ \tilde{y}_{\mathrm{BA},t} = p_4 \ddot{y}_t \quad \text{и} \quad \tilde{y}_{\mathrm{BB},t} = p_5 \ddot{y}_t\,.$$

Как только были сгенерированы нижнеуровневые прогнозы на $h$ шагов вперед, они агрегируются, чтобы получить когерентные прогнозы для остальной части ряда.

Нисходящие прогнозы могут генерироваться с помощью `top_down()` внутри функции `reconcile()`.

Можно указать несколько возможных нисходящих методов. Два наиболее распространенных подхода «сверху вниз» определяют дезагрегационные пропорции на основе исторических пропорций данных. Они показали хорошую результативность в исследовании Гросса и Сола (1990, *https://otexts.com/fpp3/single-level.html#ref-GroSoh1990*).

## Средние исторические пропорции

$$p_j = \frac{1}{T}\sum_{t=1}^{T}\frac{y_{j,t}}{y_t}$$

для $j = 1, \ldots m$. Каждая пропорция $p_j$ отражает среднее значение исторических пропорций нижнеуровневых рядов $y_{j,t}$ за период $t = 1, \ldots T$ относительно сум-

марного агрегата $y_t$. Этот подход имплементирован в функции `top_down()` путем установки аргумента `method = "average_proportions"`.

## Пропорции исторических средних

$$p_j = \sum_{t=1}^{T} \frac{y_{j,t}}{T} / \sum_{t=1}^{T} \frac{y_t}{T}$$

для $j = 1, \ldots m$. Каждая пропорция $p_j$ отражает среднее историческое значение нижнеуровневого ряда $y_{j,t}$ относительно среднего значения суммарного агрегата $y_t$.

Этот подход имплементирован в функции `top_down()` путем установки аргумента `method = "proportion_averages"`.

Удобным свойством таких нисходящих подходов является их простота. Нужно только смоделировать и сгенерировать прогнозы для наиболее агрегированных верхнеуровневых рядов. В целом эти подходы, возможно, дают довольно надежные прогнозы для агрегатных уровней, и они полезны при использовании данных с малым числом счетных данных. С другой стороны, одним из их недостатков является потеря информации из-за агрегирования. Используя такие нисходящие подходы, мы не в состоянии улавливать и использовать преимущества индивидуальных характеристик ряда, таких как временная динамика, специальные события, разные сезонные закономерности и т. д.

## Прогнозные пропорции

Поскольку используемые для дезагрегирования исторические пропорции не учитывают то, как эти пропорции могут изменяться с течением времени, нисходящие подходы, основанные на исторических пропорциях, как правило, дают менее точные прогнозы на более низких уровнях иерархии, чем восходящие подходы. Для решения этой проблемы можно использовать пропорции, основанные не на исторических данных, а на прогнозах (Дж. Атанасопулос и соавт., 2009, *https://otexts.com/fpp3/single-level.html#ref-AthEtAl2009*).

Рассмотрим одноуровневую иерархию. Сначала мы генерируем прогнозы на $h$ шагов вперед для всех рядов. Мы не используем эти прогнозы напрямую, и они не являются когерентными (они не складываются правильно). Давайте назовем эти прогнозы «начальными». Мы рассчитываем долю каждого такого начального прогноза на нижнем уровне в агрегате всех начальных прогнозов на $h$ шагов вперед на этом уровне. Мы называем эти пропорции прогнозными и используем их для дезагрегирования верхнеуровневых начальных прогнозов на $h$ шагов вперед, чтобы сгенерировать когерентные прогнозы для всей иерархии целиком.

Для K-уровневой иерархии этот процесс повторяется для каждого узла, переходя от верхнего уровня к нижнему. Применение указанного процесса приводит к следующему ниже общему правилу получения прогнозных пропорций:

$$p_j = \prod_{\ell=0}^{K-1} \frac{\hat{y}_{j,h}^{(\ell)}}{\hat{S}_{j,h}^{(\ell+1)}},$$

где для $j = 1,2, \ldots m$ $\hat{y}^{(\ell)}_{j,h}$ – это начальный прогноз ряда на $h$ шагов вперед, соответствующий узлу, который находится $l$ уровней выше $j$, и $\hat{S}^{(\ell)}_{j,h}$ – сумма начальных прогнозов на $h$ шагов вперед ниже узла, который находится на $l$ уровней выше узла $j$ и напрямую связан с этим узлом. Указанные прогнозные пропорции дезагрегируют начальный прогноз *общего* ряда, чтобы получить когерентные прогнозы на $h$ шагов вперед для нижнеуровневых рядов.

Мы будем использовать иерархию на рис. 11.1, чтобы объяснить приведенное выше обозначение и продемонстрировать, как достигается это общее правило. Допустим, что мы сгенерировали начальные прогнозы для каждого ряда в иерархии. Напомним, что для верхнеуровневого «*общего*» ряда $\tilde{y}_h = \hat{y}_h$ для любого нисходящего подхода. Ниже приведено несколько примеров использования приведенных выше обозначений:

- $\hat{y}^{(1)}_{\mathrm{A},h} = \hat{y}^{(1)}_{\mathrm{B},h} = \hat{y}_h = \tilde{y}_h$;
- $\hat{y}^{(1)}_{\mathrm{AA},h} = \hat{y}^{(1)}_{\mathrm{AB},h} = \hat{y}^{(1)}_{\mathrm{AC},h} = \hat{y}_{\mathrm{A},h}$;
- $\hat{y}^{(2)}_{\mathrm{AA},h} = \hat{y}^{(2)}_{\mathrm{AB},h} = \hat{y}^{(2)}_{\mathrm{AC},h} = \hat{y}^{(2)}_{\mathrm{BA},h} = \hat{y}^{(2)}_{\mathrm{BB},h} = \hat{y}_h = \tilde{y}_h$;
- $\hat{S}^{(1)}_{\mathrm{AA},h} = \hat{S}^{(1)}_{\mathrm{AB},h} = \hat{S}^{(1)}_{\mathrm{AC},h} = \hat{y}_{\mathrm{AA},h} + \hat{y}_{\mathrm{AB},h} + \hat{y}_{\mathrm{AC},h}$;
- $\hat{S}^{(2)}_{\mathrm{AA},h} = \hat{S}^{(2)}_{\mathrm{AB},h} = \hat{S}^{(2)}_{\mathrm{AC},h} = \hat{S}^{(1)}_{\mathrm{A},h} = \hat{S}^{(1)}_{\mathrm{B},h} = \hat{S}_h = \hat{y}_{\mathrm{A},h} + \hat{y}_{\mathrm{B},h}$.

Двигаясь вниз по самой дальней левой ветви иерархии, когерентные прогнозы задаются формулами

$$\tilde{y}_{\mathrm{A},h} = \left(\frac{\hat{y}_{\mathrm{A},h}}{\hat{S}^{(1)}_{\mathrm{A},h}}\right)\tilde{y}_h = \left(\frac{\hat{y}^{(1)}_{\mathrm{AA},h}}{\hat{S}^{(2)}_{\mathrm{AA},h}}\right)\tilde{y}_h$$

и

$$\tilde{y}_{\mathrm{AA},h} = \left(\frac{\hat{y}_{\mathrm{AA},h}}{\hat{S}^{(1)}_{\mathrm{AA},h}}\right)\tilde{y}_{\mathrm{A},h} = \left(\frac{\hat{y}_{\mathrm{AA},h}}{\hat{S}^{(1)}_{\mathrm{AA},h}}\right)\left(\frac{\hat{y}^{(1)}_{\mathrm{AA},h}}{\hat{S}^{(2)}_{\mathrm{AA},h}}\right)\tilde{y}_h .$$

Следовательно:

$$p_1 = \left(\frac{\hat{y}_{\mathrm{AA},h}}{\hat{S}^{(1)}_{\mathrm{AA},h}}\right)\left(\frac{\hat{y}^{(1)}_{\mathrm{AA},h}}{\hat{S}^{(2)}_{\mathrm{AA},h}}\right).$$

Другие пропорции могут быть получены аналогичным образом.

Указанный подход имплементирован в функции `top_down()` путем установки аргумента `method = "forecast_proportions"`. Поскольку этот подход, как правило, работает лучше, чем другие нисходящие методы, в функции `top_down()` он выбирается по умолчанию, когда не указан аргумент `method`.

Одним из недостатков всех нисходящих подходов является то, что они не продуцируют несмещенных когерентных прогнозов (Хайндман и соавт., 2011, *https://otexts.com/fpp3/single-level.html#ref-HynEtAl2011*), даже если базовые прогнозы являются несмещенными.

### Подход «от середины наружу»

Подход «от середины наружу» сочетает в себе подходы «снизу вверх» и «сверху вниз». Опять же, он может использоваться только для строго иерархических агрегационных структур.

Сначала выбирается «срединный» уровень и генерируются прогнозы для всех рядов на этом уровне. Для рядов выше «срединного уровня» когерентные прогнозы формируются с использованием восходящего подхода путем агрегирования «срединно-уровневых» прогнозов вверх. Для рядов ниже «срединного уровня» когерентные прогнозы формируются с использованием нисходящего подхода путем агрегирования «срединно-уровневых» прогнозов вниз.

Этот подход имплементирован в функции `middle_out()` путем указания соответствующего среднего уровня с помощью аргумента `level` и выбора нисходящего подхода с помощью аргумента `method`.

### Библиография

*Атанасопулос, Дж., Ахмед, Р. А. и Хайндман, Р. Дж.* (2009). Иерархические прогнозы для внутреннего туризма Австралии. International Journal of Forecasting, 25, 146–166. [DOI: https://doi.org/10.1016/j.ijforecast.2008.07.004].

*Гросс, С. В. и Сол, Дж. Е.* (1990). Дезагрегационные методы для ускорения прогнозирования продуктовой линейки. Journal of Forecasting, 9, 233–254. [DOI: https://doi.org/10.1002/for.3980090304].

*Хайндман Р. Дж., Ахмед Р. А., Атанасопулос Дж. и Шанг Х. Л.* (2011). Оптимальные комбинированные прогнозы для иерархических временных рядов. Computational Statistics and Data Analysis, 55 (9), 2579–2589. [DOI: https://doi.org/10.1016/j.csda.2011.03.006].

## 11.3 Увязывание прогнозов

Обратите внимание, что остальная часть этой главы является более продвинутой и предполагает знание базовой матричной алгебры.

### Матричная нотация

Напомним, что уравнения (11.1) и (11.2) представляют то, как агрегируются данные, которые соответствуют иерархической структуре на рис. 11.1. Аналогичным образом (11.3) и (11.4) представляют то, как агрегируются данные, которые соответствуют сгруппированной структуре на рис. 11.6. Эти уравнения можно рассматривать как агрегационные ограничения или суммирующие равенства, и их можно эффективнее представить с помощью матричной нотации.

Для любой агрегационной структуры мы строим $n \times m$-матрицу $\mathbf{S}$ (именуемую «суммирующей матрицей»), которая определяет способ агрегирования рядов нижнего уровня.

Для иерархической структуры на рис. 11.1 можно записать:

$$\begin{bmatrix} y_t \\ y_{\mathrm{A},t} \\ y_{\mathrm{B},t} \\ y_{\mathrm{AA},t} \\ y_{\mathrm{AB},t} \\ y_{\mathrm{AC},t} \\ y_{\mathrm{BA},t} \\ y_{\mathrm{BB},t} \end{bmatrix} = \begin{bmatrix} 1 & 1 & 1 & 1 & 1 \\ 1 & 1 & 1 & 0 & 0 \\ 0 & 0 & 0 & 1 & 1 \\ 1 & 0 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} y_{\mathrm{AA},t} \\ y_{\mathrm{AB},t} \\ y_{\mathrm{AC},t} \\ y_{\mathrm{BA},t} \\ y_{\mathrm{BB},t} \end{bmatrix},$$

или в более компактной нотации:

$$\boldsymbol{y}_t = \boldsymbol{S}\boldsymbol{b}_t, \tag{11.5}$$

где второй и третий ряды **S** представляют уравнение (11.3), а четвертая и пятая строки представляют уравнение (11.4).

## Отображающие матрицы

Указанная матричная нотация позволяет представлять все методы прогнозирования иерархических или сгруппированных временных рядов, используя общую нотацию.

Предположим, мы делаем прогнозы всех рядов, игнорируя любые агрегационные ограничения. Мы называем такие прогнозы **базовыми прогнозами** и обозначаем их через $\hat{\boldsymbol{y}}_h$, где $h$ – это прогнозный горизонт. Они укладываются в том же порядке, что и данные $\boldsymbol{y}_t$.

Тогда все подходы к когерентному прогнозированию для иерархических или сгруппированных структур могут быть представлены как[1]

$$\tilde{\boldsymbol{y}}_h = \boldsymbol{S}\boldsymbol{G}\hat{\boldsymbol{y}}_h, \tag{11.6}$$

где **G** – это матрица, которая отображает базовые прогнозы на нижний уровень, а суммирующая матрица **S** суммирует их, используя агрегационную структуру, для продуцирования набора **когерентных прогнозов** $\tilde{\boldsymbol{y}}_h$.

Матрица **G** определяется в соответствии с имплементированным подходом. Например, если для прогнозирования иерархии, показанной на рис. 11.1, используется подход «снизу вверх», то

[1] На самом деле некоторые недавние методы нелинейной увязки требуют немного более сложного уравнения. Это уравнение предназначено для общих методов линейной увязки.

$$\boldsymbol{G} = \begin{bmatrix} 0 & 0 & 0 & 1 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 1 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 1 \end{bmatrix}.$$

Обратите внимание, что **G** содержит два раздела. В первых трех столбцах обнуляются базовые прогнозы ряда выше нижнего уровня, в то время как $m$-размерная матрица тождественности выбирает базовые прогнозы только нижнего уровня. Затем они суммируются с помощью матрицы **S**.

Если бы использовался какой-либо из нисходящих подходов, то

$$\boldsymbol{G} = \begin{bmatrix} p_1 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ p_2 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ p_3 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ p_4 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ p_5 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \end{bmatrix}.$$

Первый столбец включает в себя набор пропорций, которые распределяют базовые прогнозы верхнего уровня на нижний уровень. Затем они суммируются с помощью матрицы **S**. В остальных столбцах обнуляются базовые прогнозы ниже самого высокого уровня агрегации.

Для подхода «от середины наружу» матрица **G** будет комбинацией двух вышеперечисленных. Используя набор пропорций, базовые прогнозы некоторого предварительно выбранного уровня будут дезагрегированы до нижнего уровня, все остальные базовые прогнозы будут обнулены, а прогнозы нижнего уровня затем будут суммированы по иерархии посредством суммирующей матрицы.

## Увязывание

Уравнение (11.7) показывает, что предварительное умножение любого набора базовых прогнозов на **SG** будет возвращать набор когерентных прогнозов.

Рассмотренные до сих пор традиционные методы ограничены тем, что в них используются базовые прогнозы только с одного уровня агрегации, который был агрегирован либо дезагрегирован с целью получения прогнозов на всех других уровнях. Следовательно, в них используется ограниченная информация. Однако в общем случае мы могли бы применять другие матрицы **G**, и тогда **SG** комбинирует и увязывает все базовые прогнозы, чтобы получить когерентные прогнозы[1].

На самом деле для получения наиболее точных увязанных прогнозов можно найти оптимальную матрицу **G**.

[1] Увязывание прогнозов (forcast reconciliation), или согласование прогнозов, – это процесс корректировки прогнозов с целью сделать их когерентными. См. *https://robjhyndman.com/publications/mint/*. – *Прим. перев.*

## Метод оптимальной увязки MinT

Викрамасурия и соавт. (2019, *https://otexts.com/fpp3/reconciliation.html#ref-Mint*) нашли матрицу **G**, которая минимизирует суммарную прогнозную дисперсию набора когерентных прогнозов, приводя к методу оптимальной увязки MinT (Минимальная трасса, от англ. Minimum Trace).

Предположим, мы генерируем когерентные прогнозы, используя уравнение (11.7). Сначала мы хотим убедиться, что имеем несмещенные прогнозы. Если базовые прогнозы $\hat{\boldsymbol{y}}_h$ не смещены, то когерентные прогнозы $\tilde{\boldsymbol{y}}_h$ будут несмещенными при условии[1], что **SGS = S**. Данное условие обеспечивает ограничение на матрицу **G**. Интересно, что ни один нисходящий метод не удовлетворяет указанному ограничению, и поэтому все нисходящие подходы приводят к смещенным когерентным прогнозам.

Далее необходимо найти ошибки в наших прогнозах. Викрамасурия и соавт. (2019, *https://otexts.com/fpp3/reconciliation.html#ref-Mint*) показывают, что дисперсионно-ковариационная матрица ошибок когерентных прогнозов на $h$ шагов вперед задается формулой

$$\boldsymbol{V}_h = \mathrm{Var}\left[\boldsymbol{y}_{T+h} - \tilde{\boldsymbol{y}}_h\right] = \boldsymbol{S}\boldsymbol{G}\boldsymbol{W}_h\boldsymbol{G}'\boldsymbol{S}',$$

где $\boldsymbol{W}_h = \mathrm{Var}\left[\left(\boldsymbol{y}_{T+h} - \hat{\boldsymbol{y}}_h\right)\right]$ – это дисперсионно-ковариационная матрица ошибок соответствующих базовых прогнозов.

Целевая задача состоит в том, чтобы найти матрицу **G**, которая минимизирует дисперсии ошибок у когерентных прогнозов. Эти дисперсии ошибок находятся на диагонали матрицы $\boldsymbol{V}_h$, и поэтому сумма всех дисперсий ошибок задается трассой матрицы $\boldsymbol{V}_h$. Викрамасурия и соавт. (2019) показывают, что матрица **G**, которая минимизирует трассу матрицы $\boldsymbol{V}_h$ таким образом, что **SGS = S**, задается формулой

$$\boldsymbol{G} = (\boldsymbol{S}'\boldsymbol{W}_h^{-1}\boldsymbol{S})^{-1}\boldsymbol{S}'\boldsymbol{W}_h^{-1}.$$

Следовательно, оптимально увязанные прогнозы задаются формулой

$$\tilde{\boldsymbol{y}}_h = \boldsymbol{S}(\boldsymbol{S}'\boldsymbol{W}_h^{-1}\boldsymbol{S})^{-1}\boldsymbol{S}'\boldsymbol{W}_h^{-1}\hat{\boldsymbol{y}}_h. \tag{11.8}$$

Мы называем эту процедуру методом оптимальной увязки MinT (или методом минимальной трассы). MinT имплементирован с помощью `min_trace()` внутри функции `reconcile()`.

В целях его применения на практике необходимо оценить $\boldsymbol{W}_h$, прогнозную дисперсию ошибки у базовых $h$-шаговых прогнозов. Это бывает сложно сделать, и поэтому мы приводим четыре упрощающие аппроксимации, которые, как было показано, хорошо работают как в симуляциях, так и на практике.

---

[1] Это ограничение «сохранения несмещенности» было впервые введено в работе Хайндмана и соавт. (2011, *https://otexts.com/fpp3/reconciliation.html#ref-HynEtAl2011*). Панайотис и соавт. (2021, *https://otexts.com/fpp3/reconciliation.html#ref-PanEtAl2020_Geometry*) показывают, что оно эквивалентно тому, что **SG** является проекционной матрицей на $m$-мерное когерентное подпространство, для которого соблюдаются агрегационные ограничения.

1. Установить $\boldsymbol{W}_h = k_h \boldsymbol{I}$ для всех $h$, где $k_h > 0$[1]. Это наиболее упрощающее допущение, которое можно сделать, и оно означает, что **G** не зависит от данных, обеспечивая существенную экономию вычислений. Недостатком, однако, является то, что указанная формулировка не учитывает различия в шкале между уровнями структуры или взаимосвязи между рядами.

   Установка $\boldsymbol{W}_h = k_h \boldsymbol{I}$ в (11.8) дает оценщика по методу обычных наименьших квадратов (OLS), которую мы ввели в разделе 7.9 с $\mathbf{X} = \mathbf{S}$ и $\mathbf{y} = \hat{\mathbf{y}}$. Следовательно, данный подход обычно называют OLS-увязкой. Он имплементирован в `min_trace()` путем установки аргумента `method = "ols"`.

2. Установить $\boldsymbol{W}_h = k_h \text{diag}\left(\boldsymbol{W}_1\right)$ для всех $h$, где $k_h > 0$,

$$\widehat{\boldsymbol{W}}_1 = \frac{1}{T}\sum_{t=1}^{T} \boldsymbol{e}_t \boldsymbol{e}_t'$$

   и $e_t$ – это $n$-размерный вектор остатков моделей, сгенерировавших базовые прогнозы, уложенные в том же порядке, что и данные.

   Указанная формулировка шкалирует базовые прогнозы, используя дисперсию остатков, и поэтому она называется WLS-оценкой (т. е. оценкой на основе взвешенных наименьших квадратов) с использованием *дисперсионного шкалирования*. Данный подход имплементирован в `min_trace()` путем установки аргумента `method = "wls_var"`.

3. Установить $\boldsymbol{W}_h = k_h \Lambda$ для всех $h$, где $k_h > 0$, $\Lambda = \text{diag}\left(\boldsymbol{S}\mathbf{1}\right)$ и $\mathbf{1}$ – единичный вектор размерности $m$ (число рядов нижнего уровня). Эта формулировка основана на допущении о том, что каждая ошибка базового прогноза нижнего уровня имеет дисперсию $k_h$, и они не коррелированы между узлами. Следовательно, каждый элемент диагонали матрицы $\boldsymbol{\Lambda}$ содержит число дисперсий прогнозных ошибок, влияющих на каждый узел. Этот оценщик зависит только от структуры агрегаций, а не от фактических данных. Поэтому он называется *структурным шкалированием*. Применение формулировки структурного шкалирования особенно полезно в случаях, когда остатки недоступны, и поэтому дисперсное шкалирование применить невозможно; например, в случаях, когда базовые прогнозы генерируются путем сусденческого прогнозирования (глава 6). Указанный подход имплементирован в `min_trace()` путем установки атрибута `method = "wls_struct"`.

4. Установить $\boldsymbol{W}_h = k_h \boldsymbol{W}_1$ для всех $h$, где $k_h > 0$. Здесь мы только исходим из допущения, что матрицы ковариаций ошибок пропорциональны друг другу, и мы непосредственно оцениваем полную одношаговую матрицу ковариаций $\boldsymbol{W}_1$. Наиболее очевидным и простым способом было бы использовать выборочную ковариацию. Это имплементировано в `min_trace()` путем установки аргумента `method = "mint_cov"`.

[1] Обратите внимание, что $k_h$ – это константа пропорциональности. Ни оценивать, ни детализировать ее здесь не нужно, поскольку она аннулируется в (11.8).

Однако для случаев, когда число $m$ рядов нижнего уровня велико по сравнению с длиной ряда $T$, это не очень хорошая оценка. Вместо нее мы используем усадочную оценку, которая сжимает выборочную ковариацию до диагональной матрицы. Это имплементировано в `min_trace()` путем установки аргумента `method = "mint_shrink"`.

Подводя итог, в отличие от любого другого существующего подхода, оптимально увязанные прогнозы формируются с использованием всей информации, доступной в рамках иерархической или сгруппированной структуры. Это важно, поскольку те или иные агрегационные уровни либо группировки могут выявлять признаки данных, которые представляют интерес для пользователя и важны для моделирования. Эти признаки могут быть полностью скрыты, или их бывает нелегко идентифицировать на других уровнях.

Например, рассмотрим данные о туризме в Австралии, представленные в разделе 11.1, где иерархическая структура соответствует географическому делению страны на штаты и регионы. Некоторые районы будут в основном летними направлениями, в то время как другие могут быть зимними направлениями. На рис. 11.4 мы видели контрастные сезонные закономерности между северными и южными штатами. Эти различия будут сглажены на страновом уровне благодаря агрегированию.

## Библиография

*Хайндман Р. Дж., Ахмед Р. А., Атанасопулос Дж. и Шанг Х. Л.* (2011). Оптимальные комбинированные прогнозы для иерархических временных рядов. Computational Statistics and Data Analysis, 55 (9), 2579–2589. [DOI: https://doi.org/10.1016/j.csda.2011.03.006].

*Панайотелис А., Атанасопулос Дж., Гамакумара П. и Хайндман Р. Дж.* (2021). Увязка прогнозов: геометрическая перспектива с новым пониманием поправки на смещение. International Journal of Forecasting, 37 (1), 343–359. [DOI: https://doi.org/10.1016/j.ijforecast.2020.06.004].

*Викрамасурия, С. Л., Атанасопулос, Дж. и Хайндман, Р. Дж.* (2019). Оптимальное увязывание прогнозов для иерархических и сгруппированных временных рядов посредством минимизации трасс. Journal of the American Statistical Association, 114 (526), 804–819. [DOI: https://doi.org/10.1080/01621459.2018.1448825].

# 11.4 Прогнозирование внутреннего туризма в Австралии

Мы рассчитаем прогнозы для данных о туризме в Австралии, которые были описаны в разделе 11.1. Данные вплоть до конца 2015 года будут использованы в качестве тренировочного набора, при этом мы отложим последние два года (восемь кварталов, 2016Q1–2017Q4) в качестве тестового набора для оценивания. Приведенный ниже исходный код демонстрирует полный рабочий поток генерирования когерентных прогнозов с использованием методов «снизу вверх», OLS и MinT.

```
tourism_full <- tourism %>%
  aggregate_key((State/Region) * Purpose, Trips = sum(Trips))
```

```
fit <- tourism_full %>%
  filter(year(Quarter) <= 2015) %>%
  model(base = ETS(Trips)) %>%
  reconcile(
    bu = bottom_up(base),
    ols = min_trace(base, method = "ols"),
    mint = min_trace(base, method = "mint_shrink"),
  )
```

Здесь он содержит базовую модель ETS (обсуждаемую в главе 8) для каждого ряда в `tourism_full`, а также три метода получения когерентных прогнозов, как указано в функции `reconcile()`.

```
fc <- fit %>% forecast(h = "2 years")
```

Передача `fit` в `forecast()` генерирует базовые и когерентные прогнозы по всем рядам в агрегационной структуре. На рис. 11.12 и 11.13 показаны четырехточечные прогнозы для поездок с ночевкой в целом по Австралии, штатам и целям поездки, а также фактические наблюдения тестового набора.

```
fc %>%
  filter(is_aggregated(Region), is_aggregated(Purpose)) %>%
  autoplot(
    tourism_full %>% filter(year(Quarter) >= 2011),
    level = NULL
  ) +
  labs(y = "Поездки (тыс.)") +
  facet_wrap(vars(State), scales = "free_y")
```

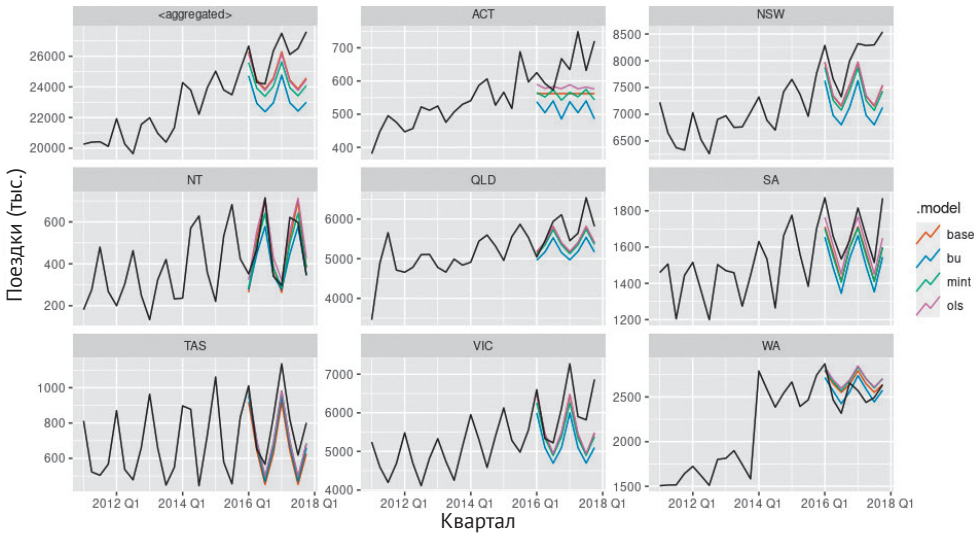


**Рисунок 11.12:** Прогнозы поездок с ночевкой для Австралии и ее штатов за тестовый период 2016Q1–2017Q4

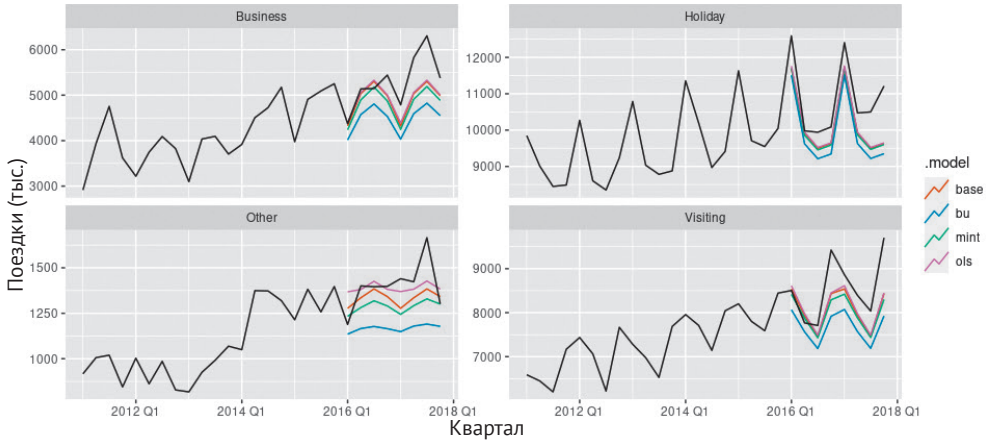


**Рисунок 11.13:** Прогнозы поездок с ночевкой в разбивке по целям поездок за тестовый период 2016Q1–2017Q4

Для того чтобы было легче увидеть различия, в тренировочные данные были включены только последние пять лет и были опущены предсказательные интервалы. В большинстве групп увеличение числа поездок, в особенности во второй половине тестового набора, превышает то, что прогнозируется точечными прогнозами. Это особенно заметно для материковых восточных штатов Австралийской столичной территории, Нового Южного Уэльса, Квинсленда и Виктории, а также для всех целей поездки.

Точность прогнозов на тестовом наборе можно оценить с помощью функции `accuracy()`. Мы суммируем некоторые результаты в табл. 11.2 с использованием RMSE и MAKE.

**Таблица 11.2:** Точность прогнозов для поездок с ночевкой в Австралии за тестовый период 2016Q1–2017Q4

| | RMSE | | | | MASE | | | |
|---|---|---|---|---|---|---|---|---|
| | Базовые | Снизу вверх | MinT | OLS | Базовые | Снизу вверх | MinT | OLS |
| Всего | 1720.72 | 3070.41 | 2157.29 | 1803.52 | 1.53 | 3.16 | 2.09 | 1.63 |
| Цель | 533.02 | 802.46 | 586.35 | 513.18 | 1.33 | 2.32 | 1.51 | 1.25 |
| Штаты | 306.85 | 417.15 | 329.73 | 294.66 | 1.40 | 1.88 | 1.45 | 1.27 |
| Регионы | 52.64 | 55.12 | 47.39 | 46.95 | 1.13 | 1.18 | 1.02 | 1.00 |
| Нижние | 19.38 | 19.38 | 17.97 | 18.32 | 0.98 | 0.98 | 0.94 | 1.02 |
| Все ряды | 45.96 | 55.27 | 45.61 | 43.20 | 1.04 | 1.08 | 0.98 | 1.03 |

Шкалы рядов на разных уровнях агрегации сильно различаются из-за агрегирования. Следовательно, необходимо быть осторожными при сравнении или вычислении зависящих от шкалы мер ошибок, таких как RMSE, по уровням, поскольку агрегатный ряд будет доминировать. Поэтому мы сравниваем меры ошибок на каждом уровне агрегации и только потом предоставляем меры ошибок по всем рядам в нижней строке. Обратите внимание, что RMSE увеличивается по мере того, как мы переходим от нижнего уровня к агрегатным уровням выше.

Следующий ниже исходный код генерирует показатели точности для агрегатного ряда, показанного в первой строке таблицы. Аналогичный исходный код используется для оценивания прогнозов для других уровней.

```
fc %>%
  filter(is_aggregated(State), is_aggregated(Purpose)) %>%
  accuracy(
    data = tourism_full,
    measures = list(rmse = RMSE, mase = MASE)
  ) %>%
  group_by(.model) %>%
  summarise(rmse = mean(rmse), mase = mean(mase))
#> # A tibble: 4 × 3
#>   .model  rmse  mase
#>   <chr>  <dbl> <dbl>
#> 1 base   1721.  1.53
#> 2 bu     3070.  3.16
#> 3 mint   2157.  2.09
#> 4 ols    1804.  1.63
```

Увязка базовых прогнозов с использованием OLS и MinT приводит к более точным прогнозам по сравнению с подходом «снизу вверх». Этот результат обычно наблюдается в приложениях, поскольку в методах увязки используется информация со всех уровней структуры, что приводит к более точным когерентным прогнозам по сравнению со старыми традиционными методами, в которых используется ограниченная информация. Кроме того, увязка обычно улучшает некогерентные базовые прогнозы почти для всех уровней.

## 11.5 Увязанные распределительные прогнозы

До сих пор мы обсуждали увязку только точечных прогнозов. Однако обычно нас также интересуют распределения прогнозов, чтобы иметь возможность вычислять предсказательные интервалы.

Панайотис и соавт. (2020, *https://otexts.com/fpp3/rec-prob.html#ref-PanEtAl2020_Probabilistic*) представляют несколько важных результатов для получения увязанных вероятностных прогнозов. Здесь мы сосредоточимся на двух фундаментальных результатах, которые имплементируются в функции `reconcile()`.

1. Если базовые прогнозы распределены нормально, т. е.

$$\hat{\boldsymbol{y}}_h \sim N\left(\hat{\mu}_h, \hat{\Sigma}_h\right),$$

то увязанные прогнозы тоже распределены нормально:

$$\tilde{\boldsymbol{y}}_h \sim N\left(\boldsymbol{SG}\hat{\mu}\mu_h, \boldsymbol{SG}\hat{\Sigma}_h\boldsymbol{G}'\boldsymbol{S}'\right).$$

2. Если неразумно допускать нормальность базовых прогнозов, то можно использовать бутстрапирование. Бутстрапированные предсказательные интервалы были введены в разделе 5.5. Ту же идею можно использовать и здесь. Мы можем просимулировать будущие пути выборки из модели (моделей), которые продуцируют базовые прогнозы, а затем увязать эти пути выборки. Интервалы когерентных прогнозов можно вычислять из увязанных путей выборки.

   Предположим, что $\left(\hat{\boldsymbol{y}}_h^{[1]}, \ldots, \hat{\boldsymbol{y}}_h^{[B]}\right)$ – это множество **B** просимулированных путей выборки, сгенерированных независимо от моделей, используемых для продуцирования базовых прогнозов. Тогда $\left(\boldsymbol{SG}\hat{\boldsymbol{y}}_h^{[1]}, \ldots, \boldsymbol{SG}\hat{\boldsymbol{y}}_h^{[B]}\right)$ предоставляет набор увязанных путей выборки, из которых можно вычислять процентили для построения интервалов когерентных предсказаний.

   В целях генерирования бутстрапированных предсказательных интервалов в таком ключе мы просто устанавливаем аргумент `bootstrap = TRUE` в функции `forecast()`.

## Библиография

*Панайотелис, А., Гамакумара, П., Атанасопулос, Дж. и Хайндман, Р. Дж.* (2020). Увязывание вероятностных прогнозов: свойства, оценивание и балльная оптимизация (Рабочий документ № 26/20). Факультет эконометрики и бизнес-статистики Университета Монаш. *http://robjhyndman.com/publications/coherentprob/*.

# 11.6 Прогнозирование тюремного населения Австралии

Возвращаясь к данным о тюремном населении Австралии (раздел 11.1), мы сравним прогнозы, основанные на методах «снизу вверх» и MinT, применяемых к базовым моделям ETS, используя тестовый набор, включающий последние два года или восемь кварталов 2015Q1–2016Q4 из имеющихся данных.

```
fit <- prison_gts %>%
  filter(year(Quarter) <= 2014) %>%
  model(base = ETS(Count)) %>%
  reconcile(
    bottom_up = bottom_up(base),
    MinT = min_trace(base, method = "mint_shrink")
  )
```

```
fc <- fit %>% forecast(h = 8)
fc %>%
  filter(is_aggregated(State), is_aggregated(Gender),
         is_aggregated(Legal)) %>%
  autoplot(prison_gts, alpha = 0.7, level = 90) +
  labs(y = "Численность заключенных (тыс.)",
       title = "Тюремное население Австралии (суммарно)")
```

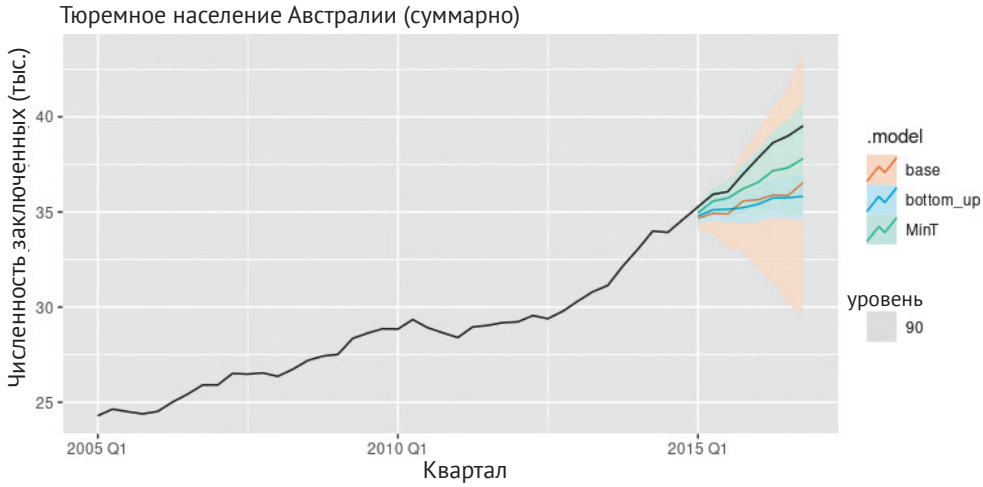


**Рисунок 11.14:** Прогнозы суммарного взрослого тюремного населения Австралии поквартально за период 2015Q1–2016Q4

На рис. 11.14 показаны три набора прогнозов численности суммарного тюремного населения Австралии. Базовые и восходящие прогнозы из моделей ETS, по-видимому, недооценивают тренд в течение тестового периода. Метод MinT комбинирует информацию из всех базовых прогнозов в агрегационной структуре; в этом случае базовые прогнозы на верхнем уровне корректируются вверх.

Интервалы увязанных прогнозов MinT намного жестче, чем у базовых прогнозов, из-за того, что MinT основан на оценщике, который минимизирует дисперсии. Распределения базовых прогнозов также являются некогерентными и, следовательно, несут с собой дополнительную неопределенность ошибки некогерентности.

Мы исключаем восходящие прогнозы из оставшихся графиков, чтобы упростить визуальный разведывательный анализ. Тем не менее мы возвращаемся к их точности в результатах оценивания, представленных позже.

На рис. 11.15–11.17 показаны прогнозы MinT и базовые прогнозы на различных уровнях агрегации. Для того чтобы было легче увидеть эффект, мы показываем тренировочные данные только за последние пять лет. В целом MinT корректирует базовые прогнозы в направлении тестового набора, тем самым повышая точность прогноза. Нет никакой гарантии, что увязанные прогнозы MinT будут точнее базовых прогнозов для каждого ряда, но в среднем они будут точнее (см. *Панагиотелис и соавт.*, 2021, *https://otexts.com/fpp3/prison.html#ref-PanEtAl2020_Geometry*).

```
fc %>%
  filter(
    .model %in% c("base", "MinT"),
    !is_aggregated(State), is_aggregated(Legal),
    is_aggregated(Gender)
  ) %>%
  autoplot(
    prison_gts %>% filter(year(Quarter) >= 2010),
    alpha = 0.7, level = 90
  ) +
  labs(title = "Тюремное население (по штатам)",
       y = "Численность заключенных (тыс.)") +
  facet_wrap(vars(State), scales = "free_y", ncol = 4) +
  theme(axis.text.x = element_text(angle = 90, hjust = 1))
```

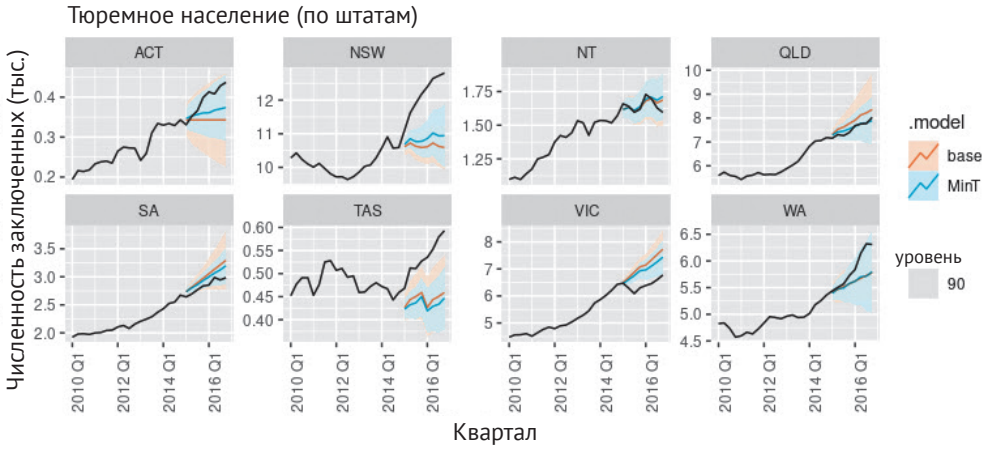


**Рисунок 11.15:** Прогнозы численности взрослого тюремного населения Австралии поквартально в разбивке по штатам

На рис. 11.15 показаны прогнозы для каждого из восьми штатов. В течение периода тестового набора наблюдается общий тренд к росту во всех штатах. Однако, по-видимому, наблюдается относительно большой и внезапный всплеск в Новом Южном Уэльсе и Тасмании, что означает, что наблюдения тестового набора находятся далеко за пределами верхней границы предсказательных интервалов для этих обоих штатов. Поскольку Новый Южный Уэльс является штатом с самой большой численностью заключенных, этот всплеск окажет существенное влияние на суммарное тюремное население. Напротив, Виктория демонстрирует существенное падение за период 2015Q2–2015Q3, прежде чем вернуться к восходящему тренду. Это падение не отражено ни в одном из прогнозов для Виктории.

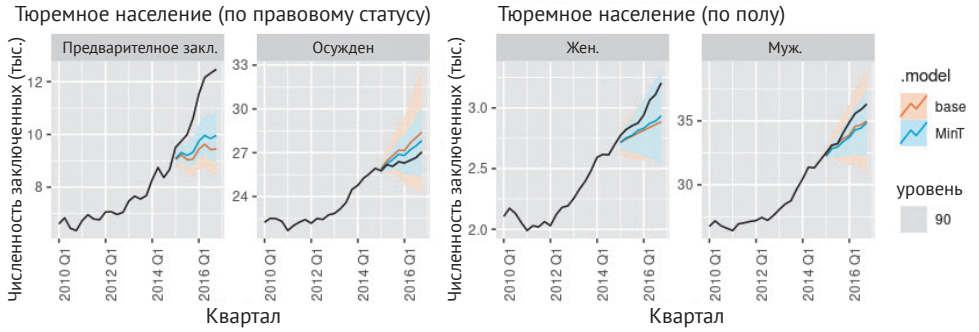


**Рисунок 11.16:** Прогнозы численности взрослого тюремного населения Австралии поквартально в разбивке по правовому статусу и полу

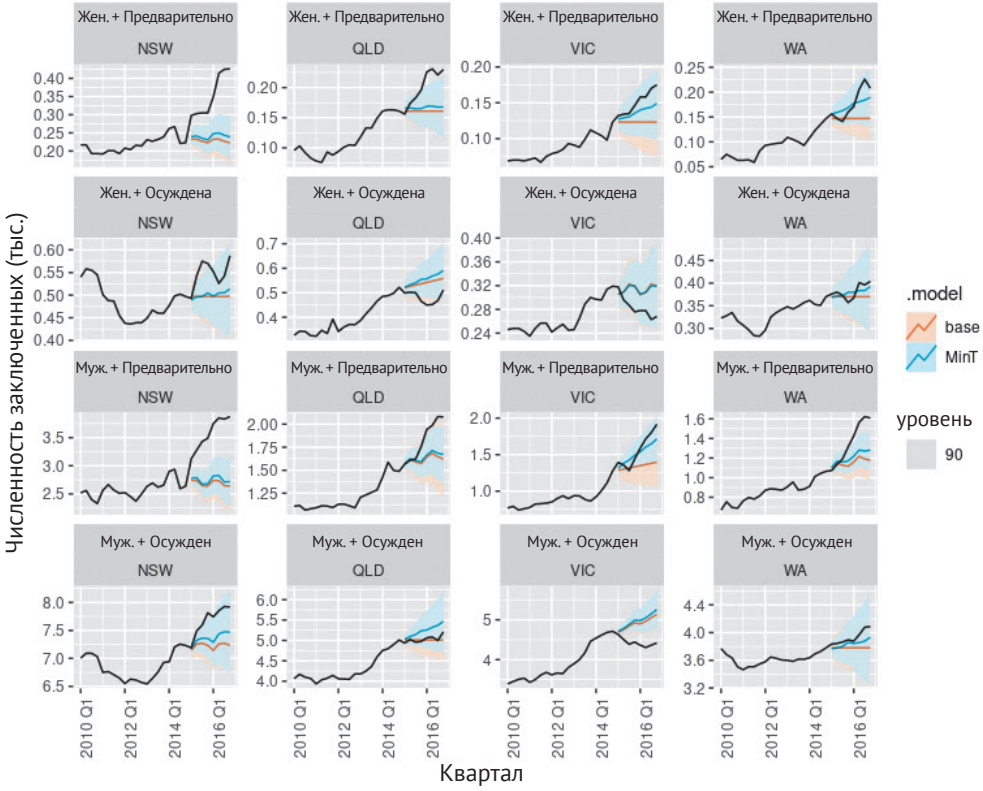


**Рисунок 11.17:** Прогнозы численности взрослого тюремного населения Австралии для нижнеуровневых рядов поквартально в разбивке по штатам, правовому статусу и полу

На рис. 11.17 показаны прогнозы численности тюремного населения Австралии для некоторых избранных нижнеуровневых рядов. Четыре крупнейших штата представлены в столбцах, а правовой статус и пол расположены в строках. Это позволяет провести некоторый интересный анализ и наблюдения, которые имеют политические последствия. Значительный рост, наблюдаемый по

штатам в течение тестового периода 2015Q1–2016Q4, по-видимому, обусловлен значительным увеличением числа заключенных в следственных изоляторах. Эти увеличения, по всей видимости, в целом не учитываются в обоих прогнозах. В отличие от других штатов, в Новом Южном Уэльсе также наблюдается значительный рост численности осужденного тюремного населения. В частности, увеличение численности осужденных мужчин в Новом Южном Уэльсе вносит существенный вклад в увеличение числа тюрем штата и страны.

Используя функцию `accuracy()`, мы оцениваем точность прогноза по всей сгруппированной структуре. Приведенный ниже исходный код оценивает прогнозную точность только для верхнеуровневого национального агрегата временных рядов с численностью тюремного населения Австралии. Аналогичный исходный код используется для остальных результатов, приведенных в табл. 11.3.

```
fc %>%
  filter(is_aggregated(State), is_aggregated(Gender),
         is_aggregated(Legal)) %>%
  accuracy(data = prison_gts,
           measures = list(mase = MASE,
                           ss = skill_score(CRPS)
                           )
           ) %>%
  group_by(.model) %>%
  summarise(mase = mean(mase), sspc = mean(ss) * 100)
#> # A tibble: 3 × 3
#>   .model     mase  sspc
#>   <chr>     <dbl> <dbl>
#> 1 base      1.72   55.9
#> 2 bottom_up 1.84   33.5
#> 3 MinT      0.895  76.8
```

В табл. 11.3 резюмируется точность базовых, восходящих и увязанных прогнозов MinT за тестовый период 2015Q1–2016Q4 по каждому уровню сгруппированной агрегационной структуры, а также по всем уровням.

**Таблица 11.3:** Точность прогнозов численности тюремного населения Австралии для различных групп рядов

| | MASE | | | Балл навыков (CRPS) | | |
|---|---|---|---|---|---|---|
| | Базовые | Снизу вверх | MinT | Базовые | Снизу вверх | MinT |
| Всего | 1.72 | 1.84 | 0.90 | 55.91 | 33.46 | 76.80 |
| Штаты | 2.12 | 1.88 | 1.78 | 6.40 | 24.10 | 22.46 |

[1] Непрерывный рангово-вероятностный балл навыков (Continuous Ranked Probability Skill Score, аббр. CRPSS) – это показатель того, насколько хорошие прогнозы соответствуют наблюдаемым результатам. – *Прим. перев.*

*Окончание табл. 11.3*

| | MASE | | | Балл навыков (CRPS) | | |
|---|---|---|---|---|---|---|
| | Базовые | Снизу вверх | MinT | Базовые | Снизу вверх | MinT |
| Правовой статус | 2.89 | 2.68 | 2.32 | 22.22 | 50.27 | 45.23 |
| Пол | 0.89 | 1.76 | 0.91 | 68.98 | 27.49 | 71.06 |
| Нижние | 2.23 | 2.23 | 2.06 | 0.93 | 0.93 | –3.23 |
| Все ряды | 2.19 | 2.16 | 1.96 | 6.70 | 11.29 | 8.69 |

Мы используем шкалированные меры, потому что численность заключенных существенно различается в разных группах. MASE дает шкалированную меру точности точечного прогноза (см. раздел 5.8), в то время как балл навыков CRPS дает шкалированную меру точности распределительного прогноза (см. раздел 5.9). Низкое значение MASE и, в отличие от него, высокое значение балла навыков указывают на хороший прогноз.

Результаты показывают, что увязанные прогнозы MinT улучшают точность базовых прогнозов, а также являются точнее восходящих прогнозов. Поскольку в методе оптимальной увязки MinT используется информация со всех уровней структуры, он генерирует более точные прогнозы, чем традиционные подходы (такие как восходящий подход), в которых используется ограниченная информация.

## Библиография

*Панайотелис А., Атанасопулос Дж., Амакумара П. и Хайндман Р. Дж.* (2021). Увязывание прогнозов: геометрическая перспектива с новым пониманием поправки на смещение. International Journal of Forecasting, 37 (1), 343–359. [DOI: https://doi.org/10.1016/j.ijforecast.2020.06.004].

# 11.7 Упражнения

1. Рассмотрите данные `PBS`, которые имеют агрегационную структуру ATC1/ATC2 * Концессия * Тип.
   a) Постройте графики агрегированных данных рецептов по ATC1/ATC2, концессии и типу.
   b) Спрогнозируйте данные рецептов PBS с использованием моделей ETS, ARIMA и SNAIVE, применяемых ко всем данным, кроме последних трех лет.
   c) Увяжите каждый прогноз с помощью MinT.
   d) Какой тип модели работает лучше всего на тестовом наборе?
   e) Улучшает ли увязка прогнозную точность?
   f) Почему увязывание не имеет никакого значения для прогнозов SNAIVE?
2. Повторите пример `tourism` из раздела 11.4, но также оцените точность распределения прогнозов, используя баллы навыков CRPS. Какой метод работает лучше всего на этой мере?

3. Повторите пример `prison` из раздела 11.6, но с использованием бутстрапа с целью генерирования распределений прогнозов вместо взятия нормальности в качестве допущения. Имеет ли это большое значение для балла навыков CRPS?

## 11.8 Дальнейшее чтение

Подробное освещение темы иерархического прогнозирования в статистической литературе в настоящее время отсутствует, поэтому для получения дополнительной информации заинтересованным читателям придется обратиться к оригинальным исследовательским работам.

Гросс и Сол (1990, *https://otexts.com/fpp3/hierarchical-reading.html#ref-GroSoh1990*) дают хорошее представление о нисходящих подходах.

Недавний обзор увязывания прогнозов представлен Джорджем Атанасопулосом и соавт. (2020, *https://otexts.com/fpp3/hierarchical-reading.html#ref-macrohts*).

Методы увязывания были разработаны в серии статей. Более поздние статьи обобщают предыдущие результаты и представляют наиболее общую теорию: Викрамасурия и соавт. (2019, *https://otexts.com/fpp3/hierarchical-reading.html#ref-Mint*), Панайотелис и соавт. (2021, *https://otexts.com/fpp3/hierarchical-reading.html#ref-PanEtAl2020_Geometry*), Панайотелис и соавт. (2020, *https://otexts.com/fpp3/hierarchical-reading.html#ref-PanEtAl2020_Probabilistic*).

Дж. Атанасопулос и соавт. (2017, *https://otexts.com/fpp3/hierarchical-reading.html#ref-AthEtAl2017*) расширяют метод увязывания на обработку временных иерархий.

Пример с туризмом подробнее обсуждается в Дж. Атанасопулос и соавт. (2009, *https://otexts.com/fpp3/hierarchical-reading.html#ref-AthEtAl2009*), Викрамасурия и соавт. (2019, *https://otexts.com/fpp3/hierarchical-reading.html#ref-Mint*) и Курентзес и Атанасопулос (2019, *https://otexts.com/fpp3/hierarchical-reading.html#ref-KouAth2019*).

## Библиография

*Атанасопулос, Дж., Ахмед, Р. А. и Хайндман, Р. Дж.* (2009). Иерархические прогнозы для внутреннего туризма в Австралии. International Journal of Forecasting, 25, 146–166. [DOI: https://doi.org/10.1016/j.ijforecast.2008.07.004].

*Атанасопулос, Дж., Гамакумара, П., Панайотелис, А., Хайндман, Р. Дж. и Аффан, М.* (2020). Иерархическое прогнозирование. В кн.: *Фулеки П.* (ред.). Макроэкономическое прогнозирование в эпоху больших данных (стр. 689–719). Springer. [DOI: https://doi.org/10.1007/978-3-030-31150-6_21].

*Атанасопулос, Дж., Хайндман, Р. Дж., Куренцес, Н. и Петропулос, Ф.* (2017). Прогнозирование с использованием временных иерархий. European Journal of Operational Research, 262 (1), 60–74. [DOI: https://doi.org/10.1016/j.ejor.2017.02.046].

*Гросс, К. В. и Сол, Дж. Е.* (1990). Дезагрегационные методы для ускорения прогнозирования продуктовой линейки. Journal of Forecasting, 9, 233–254. [DOI: https://doi.org/10.1002/for.3980090304].

*Куренцес, Н. и Атанасопулос, Дж.* (2019). Перекрестно-темпоральные когерентные прогнозы австралийского туризма. Annals of Tourism Research, 75, 393–409. [DOI: https://doi.org/10.1016/j.annals.2019.02.001].

*Панайотелис А., Атанасопулос Дж., Гамакумара П. и Хайндман Р. Дж.* (2021). Увязывание прогнозов: геометрическая перспектива с новым пониманием поправки на смещение. International Journal of Forecasting, 37 (1), 343–359. [DOI: https://doi.org/10.1016/j.ijforecast.2020.06.004].

*Панайотелис, А., Гамакумара, П., Атанасопулос, Дж. и Хайндман, Р. Дж.* (2020). Увязывание вероятностных прогнозов: свойства, оценивание и балльная оптимизация (Рабочий документ № 26/20). Факультет эконометрики и бизнес-статистики Университета Монаш. *http://robjhyndman.com/publications/coherentprob/*.

*Викрамасурия, С. Л., Атанасопулос, Дж. и Хайндман, Р. Дж.* (2019). Оптимальное увязывание прогнозов для иерархических и сгруппированных временных рядов посредством минимизации трасс. Journal of the American Statistical Association, 114 (526), 804–819. [DOI: https://doi.org/10.1080/01621459.2018.1448825].

# Глава 12

# Продвинутые методы прогнозирования

В этой главе мы кратко обсудим более продвинутые методы прогнозирования, основанные на моделях, рассмотренных в предыдущих главах.

## 12.1 Сложная сезонность

До сих пор мы в основном рассматривали относительно простые сезонные закономерности, такие как ежеквартальные и ежемесячные данные. Однако высокочастотные временные ряды нередко демонстрируют более сложные сезонные закономерности. Например, ежедневные данные могут иметь недельную закономерность, а также годовую закономерность. Почасовые данные обычно имеют три типа сезонности: дневную закономерность, недельную закономерность и годовую закономерность. Порой бывает сложно прогнозировать даже еженедельные данные, поскольку в году не существует целого числа недель, так что годовая закономерность в среднем имеет сезонный период $365.25 / 7 \approx 52.179$. Большинство методов, которые мы рассматривали до сих пор, не способны справляться с этими сезонными сложностями.

Не обязательно включать в наши модели все возможные сезонные периоды – только те, которые, вероятно, будут присутствовать в данных. Например, если мы располагаем данными лишь за 180 дней, то можно проигнорировать годовую сезонность. Если данные представляют собой измерения природного явления (например, температуры), то мы, вероятно, сможем смело проигнорировать любую еженедельную сезонность.

На рис. 12.1 показана численность звонков в североамериканский коммерческий банк в разбивке на 5-минутные интервалы между 7:00 утра и 9:05 вечера каждый будний день в течение 33 недель. На нижней панели показаны первые четыре недели того же самого временного ряда. Имеется сильная дневная сезонная закономерность с периодом 169 (169 пятиминутных интервалов в день) и слабая недельная сезонная закономерность с периодом $169 \times 5 = 845$. (Численность звонков по понедельникам, как правило, выше, чем в остальное время недели.) Если бы имелся более длинный ряд данных, то мы могли бы также наблюдать годовую сезонную закономерность.

```
bank_calls %>%
  fill_gaps() %>%
  autoplot(Calls) +
  labs(y = "Звонки",
       title = "Численность звонков в банк в разбивке на пятиминутные интервалы")
```

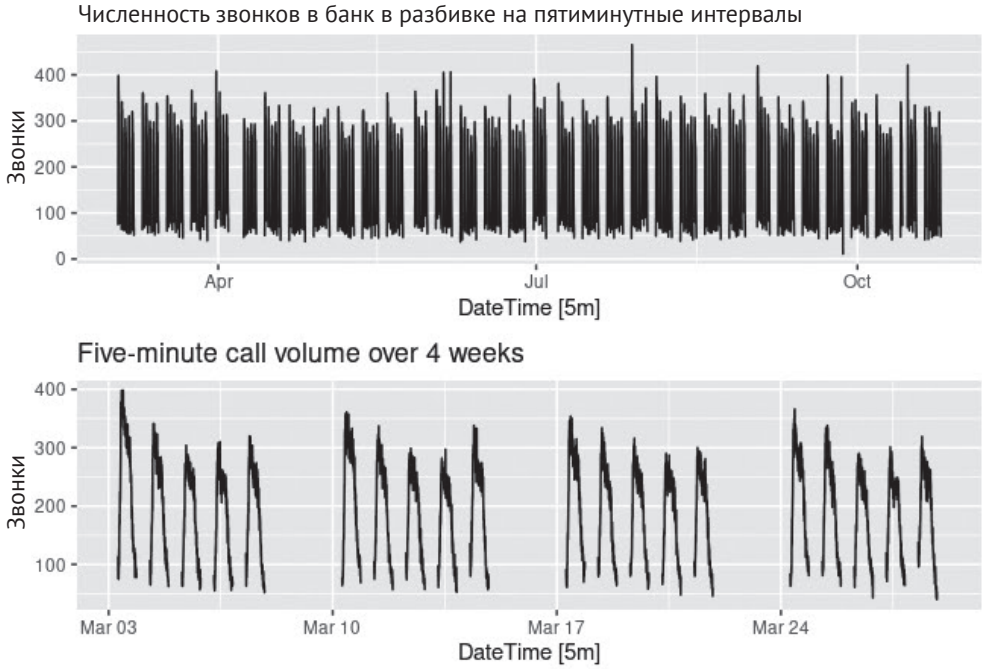


**Рисунок 12.1:** Численность звонков в разбивке на пятиминутные интервалы, обрабатываемых в будние дни с 7:00 утра до 9:05 вечера в крупном североамериканском коммерческом банке. Верхняя панель: данные за период с 3 марта по 24 октября 2003 года. Нижняя панель: данные за первые четыре недели

Помимо нескольких сезонных периодов, этот ряд имеет дополнительную сложность в виде пропущенных значений между рабочими периодами.

## STL с несколькими сезонными периодами

Функция `STL()` предназначена для работы с множественной сезонностью. Она будет возвращать несколько сезонных компонент, а также трендовую и остаточную компоненты. В данном случае необходимо переиндексировать объект `twiddle`, чтобы избежать пропущенных значений, а затем явно указать сезонные периоды.

```
calls <- bank_calls %>%
  mutate(t = row_number()) %>%
  update_tsibble(index = t, regular = TRUE)
calls %>%
```

```
model(
  STL(sqrt(Calls) ~ season(period = 169) +
                    season(period = 5*169),
      robust = TRUE)
) %>%
components() %>%
autoplot() + labs(x = "Наблюдение")
```

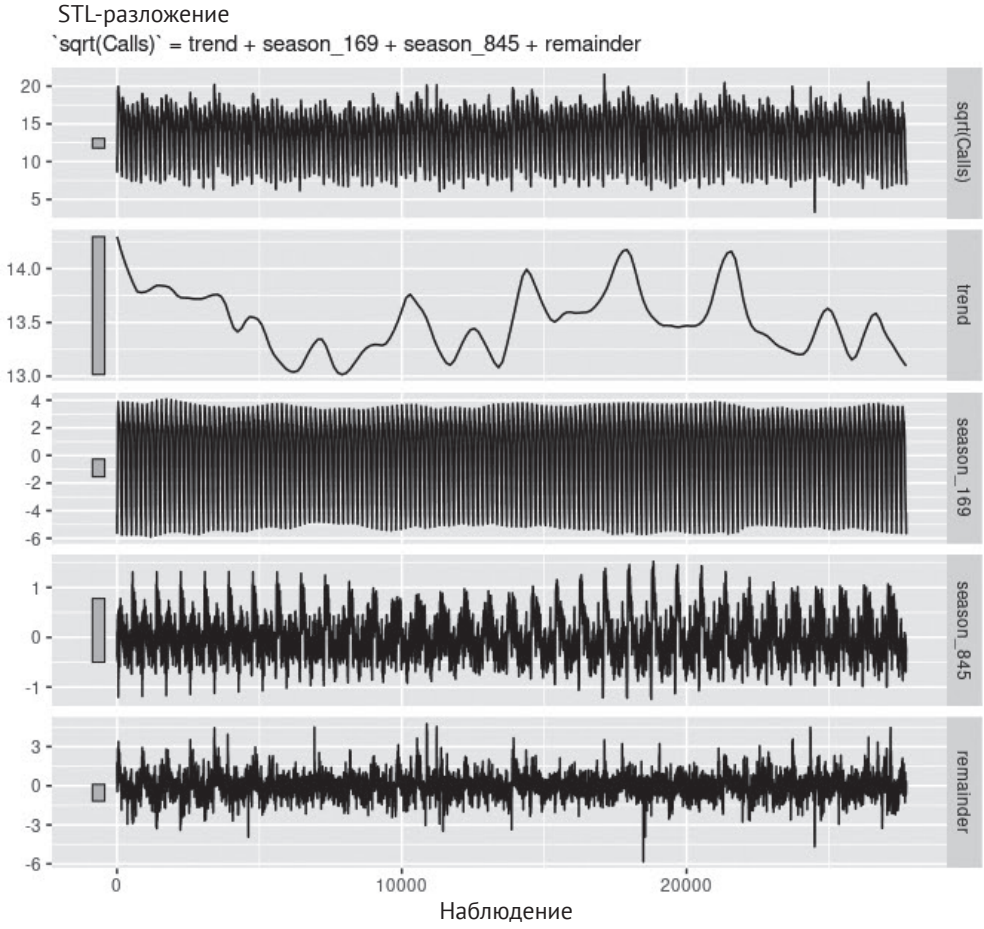


**Рисунок 12.2:** STL-разложение с множественной сезонностью для данных о численности звонков

Показаны две сезонные закономерности: одна для времени суток (третья панель) и одна для времени недели (четвертая панель). В целях правильной интерпретации этого графика важно обратить внимание на вертикальные шкалы. В этом случае тренд и недельная сезонность имеют более широкие столбики (и, следовательно, относительно более узкий размах) по сравнению с другими компонентами, поскольку в данных наблюдается незначительный тренд, а недельная сезонность – слабая.

Разложение также может использоваться в прогнозировании, при этом каждая сезонная компонента прогнозируется с использованием сезонного наивного метода, а прогноз сезонно скорректированных данных – с использованием ETS.

Исходный код получается немного сложнее, чем обычно, потому что мы должны добавить обратно временные метки, которые были потеряны, когда мы реиндексировали объект tsibble, чтобы обрабатывать периоды пропущенных наблюдений. Используемое при STL-разложении квадратичное преобразование[1] обеспечило сохранение положительных прогнозов.

```
# Прогнозы в результате разложения STL+ETS
my_dcmp_spec <- decomposition_model(
  STL(sqrt(Calls) ~ season(period = 169) +
                    season(period = 5*169),
      robust = TRUE),
  ETS(season_adjust ~ season("N"))
)
fc <- calls %>%
  model(my_dcmp_spec) %>%
  forecast(h = 5 * 169)

# Добавить правильные временные метки в fable
fc_with_times <- bank_calls %>%
  new_data(n = 7 * 24 * 60 / 5) %>%
  mutate(time = format(DateTime, format = "%H:%M:%S")) %>%
  filter(
    time %in% format(bank_calls$DateTime, format = "%H:%M:%S"),
    wday(DateTime, week_start = 1) <= 5
  ) %>%
  mutate(t = row_number() + max(calls$t)) %>%
  left_join(fc, by = "t") %>%
  as_fable(response = "Calls", distribution = Calls)

# Построить результаты с данными за 3 недели на графике
fc_with_times %>%
  fill_gaps() %>%
  autoplot(bank_calls %>% tail(14 * 169) %>% fill_gaps()) +
  labs(y = "Звонки",
       title = "Численность звонков в банк в разбивке на пятиминутные интервалы")
```

[1] Квадратичное преобразование (square-root transformation) – процедура преобразования набора данных, в которой каждое значение $x_i$ заменяется его квадратным корнем. – *Прим. перев.*

**Рисунок 12.3:** Прогнозы данных численности звонков на основе STL-разложения с прогнозом сезонных компонент с использованием сезонного наивного метода и прогноз сезонно скорректированных данных с использованием ETS

## Динамическая гармоническая регрессия с несколькими сезонными периодами

При наличии нескольких сезонностей можно использовать члены Фурье, как это делалось в предыдущих главах (см. разделы 7.4 и 10.5). Поскольку сезонностей несколько, необходимо добавить члены Фурье для каждого сезонного периода. В этом случае сезонные периоды равны 169 и 845, поэтому члены Фурье имеют вид

$$\sin\left(\frac{2\pi kt}{169}\right),\ \cos\left(\frac{2\pi kt}{169}\right),\ \sin\left(\frac{2\pi kt}{845}\right)\ u\ \cos\left(\frac{2\pi kt}{845}\right)$$

для $k = 1, 2, \ldots$. Как обычно, функция `fourier()` может сгенерировать их за вас.

Мы выполним подгонку модели динамической гармонической регрессии со структурой ошибок ARIMA. Суммарное число членов Фурье для каждого сезонного периода может быть выбрано таким образом, чтобы минимизировать AICc. Однако в периоды высокой сезонности это приводит к завышению числа требующихся членов, поэтому мы будем использовать более субъективный выбор с 10 членами для ежедневной сезонности и 5 для недельной сезонности. Опять же, мы будем использовать квадратичное преобразование в целях обеспечения того, чтобы прогнозы и предсказательные интервалы оставались положительными. Мы устанавливаем $D = d = 0$, для того чтобы учесть нестационарность посредством регрессионных членов, и $P = Q = 0$, чтобы учесть сезонность посредством регрессионных членов.

```
fit <- calls %>%
  model(
    dhr = ARIMA(sqrt(Calls) ~ PDQ(0, 0, 0) + pdq(d = 0) +
                  fourier(period = 169, K = 10) +
                  fourier(period = 5*169, K = 5)))

fc <- fit %>% forecast(h = 5 * 169)

# Добавить правильные временные метки в fable
fc_with_times <- bank_calls %>%
  new_data(n = 7 * 24 * 60 / 5) %>%
  mutate(time = format(DateTime, format = "%H:%M:%S")) %>%
  filter(
    time %in% format(bank_calls$DateTime, format = "%H:%M:%S"),
    wday(DateTime, week_start = 1) <= 5
  ) %>%
  mutate(t = row_number() + max(calls$t)) %>%
  left_join(fc, by = "t") %>%
  as_fable(response = "Calls", distribution = Calls)
# Построить результаты с данными за 3 недели на графике
fc_with_times %>%
  fill_gaps() %>%
  autoplot(bank_calls %>% tail(14 * 169) %>% fill_gaps()) +
  labs(y = "Звонки",
       title = "Численность звонков в банк в разбивке на пятиминутные интервалы")
```

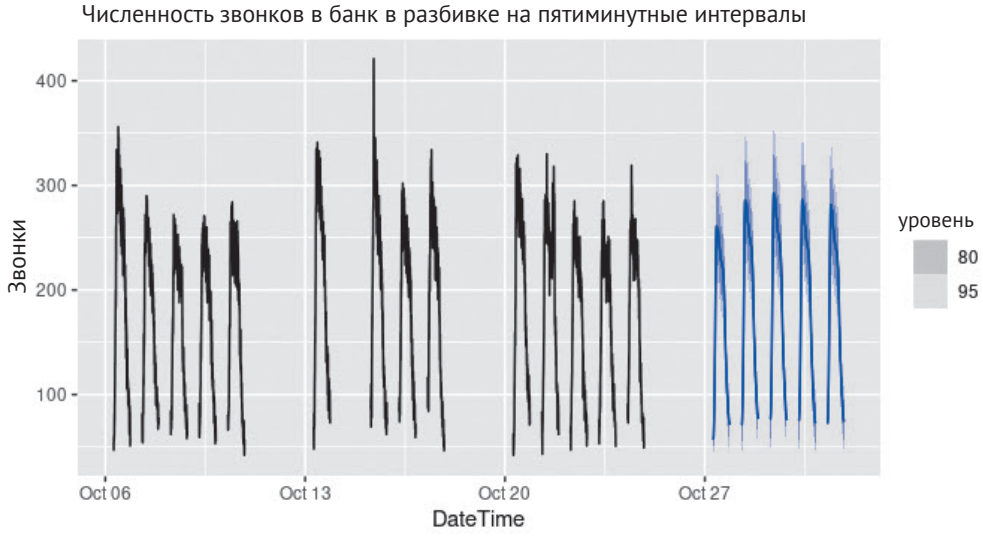


**Рисунок 12.4:** Прогнозы, полученные из динамической гармонической регрессии, применительно к данным о численности звонков

Это большая модель, которая содержит 33 параметра: 4 коэффициента ARMA, 20 коэффициентов Фурье для периода 169 и 8 коэффициентов Фурье для периода 845. Для периода 845 используются не все члены Фурье, т. к. существует некоторое совпадение с членами периода 169 (поскольку 845 = 5 × 169).

## Пример: спрос на электроэнергию

Одним из распространенных применений таких моделей является моделирование спроса на электроэнергию. На рис. 12.5 показан получасовой спрос на электроэнергию (МВтч) в штате Виктория, Австралия, в 2012–2014 годах, а также температура (градусы Цельсия) за тот же период в Мельбурне (крупнейшем городе шт. Виктория).

```
vic_elec %>%
  pivot_longer(Demand:Temperature, names_to = "Series") %>%
  ggplot(aes(x = Time, y = value)) +
  geom_line() +
  facet_grid(rows = vars(Series), scales = "free_y") +
  labs(y = "")
```

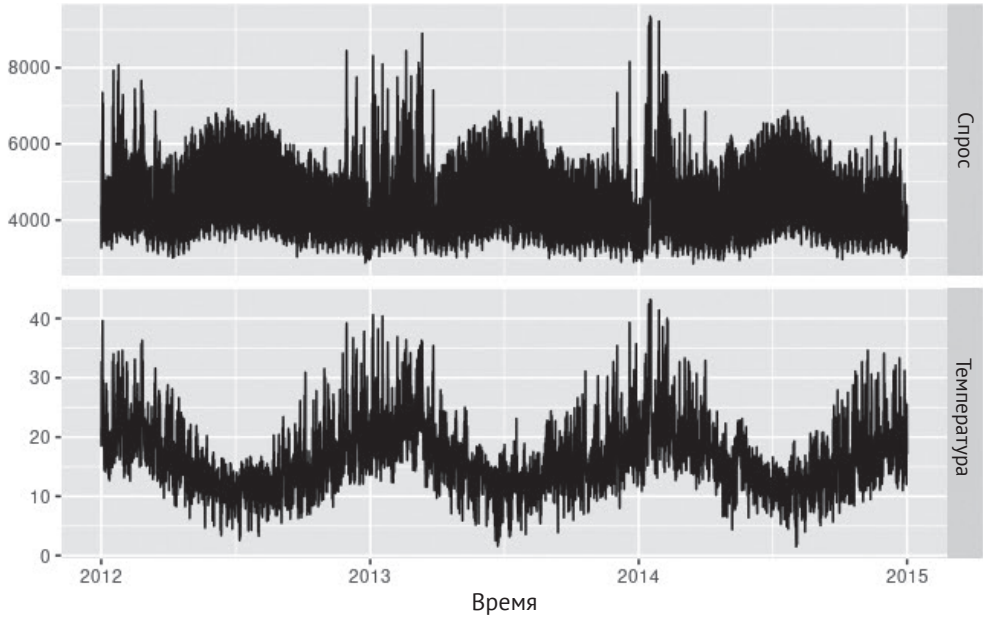


**Рисунок 12.5:** Получасовой спрос на электроэнергию и соответствующие температуры в 2012–2014 годах, шт. Виктория, Австралия

Построение графика спроса на электроэнергию в сопоставлении с температурой (рис. 12.6) показывает, что между ними существует нелинейная взаимосвязь: спрос увеличивается при низких температурах (из-за обогрева) и увеличивается при высоких температурах (из-за охлаждения).

```
elec <- vic_elec %>%
```

```
  mutate(
    DOW = wday(Date, label = TRUE),
    Working_Day = !Holiday & !(DOW %in% c("Sat", "Sun")),
    Cooling = pmax(Temperature, 18)
  )
elec %>%
  ggplot(aes(x=Temperature, y=Demand, col=Working_Day)) +
  geom_point(alpha = 0.6) +
  labs(x="Температура (градусы Цельсия)", y="Спрос (МВтч)")
```

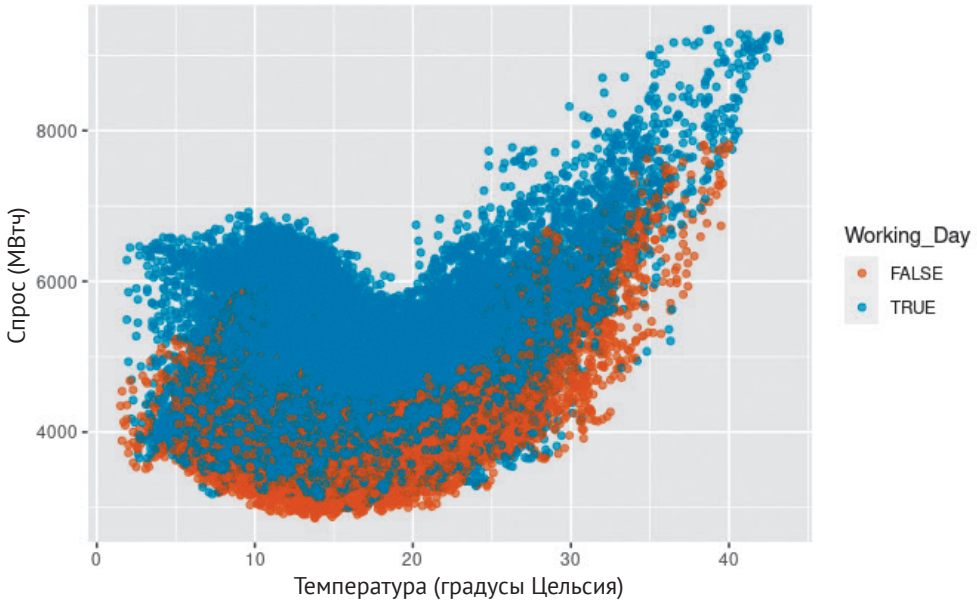


**Рисунок 12.6:** График получасового потребления электроэнергии в шт. Виктория в сопоставлении с температурой за то же время в Мельбурне, крупнейшем городе шт. Виктория

Мы выполним подгонку регрессионной модели с кусочно-линейной функцией температуры (содержащей узловую точку в 18 градусах) и членами гармонической регрессии, чтобы учесть суточную сезонную закономерность. Опять же, мы устанавливаем степень членов Фурье субъективно, используя AICc для выбора порядка ошибок ARIMA.

```
fit <- elec %>%
  model(
    ARIMA(Demand ~ PDQ(0, 0, 0) + pdq(d = 0) +
          Temperature + Cooling + Working_Day +
          fourier(period = "day", K = 10) +
          fourier(period = "week", K = 5) +
          fourier(period = "year", K = 3))
  )
```

Прогнозировать с помощью таких моделей трудно, поскольку нам требуются будущие значения предсказательных переменных. Будущие значения членов Фурье легко вычислить, но будущие температуры, разумеется, неизвестны. Если мы заинтересованы в прогнозировании только на неделю вперед, то мы могли бы использовать температурные прогнозы, полученные из метеорологической модели. В качестве альтернативы можно было бы применить сценарное прогнозирование (раздел 6.5) и включить возможные температурные закономерности. В следующем ниже примере в целях получения будущих возможных значений спроса мы использовали повтор температур за последние два дня.

```
elec_newdata <- new_data(elec, 2*48) %>%
  mutate(
    Temperature = tail(elec$Temperature, 2 * 48),
    Date = lubridate::as_date(Time),
    DOW = wday(Date, label = TRUE),
    Working_Day = (Date != "2015-01-01") &
                  !(DOW %in% c("Sat", "Sun")),
    Cooling = pmax(Temperature, 18)
  )
fc <- fit %>%
  forecast(new_data = elec_newdata)

fc %>%
  autoplot(elec %>% tail(10 * 48)) +
  labs(title="Получасовой спрос на электроэнергию: Виктория",
       y = "Спрос (МВтч)", x = "Время [30м]")
```

**Рисунок 12.7:** Прогнозы из динамической гармонической регрессионной модели применительно к получасовым данным спроса на электроэнергию

Хотя краткосрочные прогнозы и выглядят разумными, для сложного процесса такая модель является грубой. Изображенные на рис. 12.8 остатки демонстрируют, что эта модель не смогла уловить много информации.

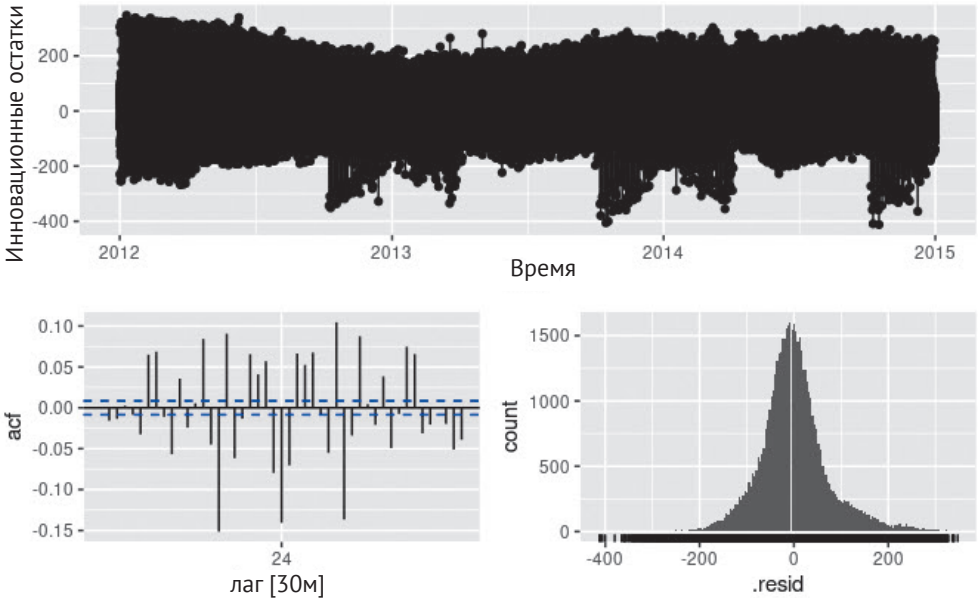


**Рисунок 12.8:** Диагностика остатков динамической гармонической регрессионной модели

Более сложные версии этой модели, которые обеспечивают гораздо более качественные прогнозы, описаны в работах Хайндман и Фан (2010, *https://otexts.com/fpp3/complexseasonality.html#ref-HF2010*) и Фан и Хайндман (2012, *https://otexts.com/fpp3/complexseasonality.html#ref-FH2012*).

## Библиография

*Фан, С. и Хайндман, Р. Дж.* (2012, *https://otexts.com/fpp3/complexseasonality.html#ref-HF2010*). Краткосрочное прогнозирование нагрузки из полупараметрической аддитивной модели. IEEE Transactions on Power Systems, 27 (1), 134–141. [DOI: https://doi.org/10.1109/TPWRS.2011.2162082].

*Хайндман, Р. Дж. и Фан, С.* (2010, *https://otexts.com/fpp3/complexseasonality.html#ref-FH2012*). Прогнозирование плотности для долгосрочного пикового спроса на электроэнергию. IEEE Transactions on Power Systems, 25 (2), 1142–1153. [DOI: https://doi.org/10.1109/TPWRS.2009.2036017].

# 12.2 Модель Prophet

Недавно была предложена модель Prophet[1], доступная благодаря пакету fable.prophet. Эта модель была введена компанией Facebook (С. Дж. Тэйлор и Летэм, 2018, *https://otexts.com/fpp3/prophet.html#ref-prophet*) первоначально для прогнозирования ежедневных данных с учетом сезонности за неделю и год, а также праздничных эффектов. Позже она была расширена, чтобы охватывать больше типов сезонных данных. Лучше всего она работает с временными рядами, которые имеют сильную сезонность и несколько сезонов исторических данных.

Prophet можно рассматривать как нелинейную регрессионную модель (глава 7) вида

$$y_t = g(t) + s(t) + h(t) + \varepsilon_t,$$

где $g(t)$ описывает кусочно-линейный тренд (или «член роста»), $s(t)$ описывает различные сезонные закономерности, $h(t)$ улавливает праздничные эффекты и $\varepsilon_t$ – это член ошибки белого шума.

- Узловые точки (или точки изменения) для кусочно-линейного тренда выбираются автоматически, если они не указаны явно. При необходимости для установки верхней границы тренда можно использовать логистическую функцию.
- Сезонная компонента состоит из членов Фурье соответствующих периодов. По умолчанию для годовой сезонности используется порядок 10, а для недельной сезонности – порядок 3.
- Праздничные эффекты добавляются в виде простых фиктивных переменных.
- Модель оценивается с использованием байесового подхода, позволяющего выбирать точки изменения и другие характеристики модели автоматически.

Мы проиллюстрируем этот подход, используя два набора данных: простой квартальный пример, а затем данные спроса на электроэнергию, описанные в предыдущем разделе.

## Пример: ежеквартальное производство цемента

Для простого квартального примера мы повторим анализ из раздела 9.10, в котором мы сравнили модели ARIMA и ETS, но для сравнения добавим модель Prophet.

```
library(fable.prophet)
cement <- aus_production %>%
  filter(year(Quarter) >= 1988)
train <- cement %>%
  filter(year(Quarter) <= 2007)
```

[1] Prophet – это процедура прогнозирования данных временного ряда из аддитивной модели, в которой подгонка нелинейных трендов осуществляется с помощью годовой, недельной и дневной сезонностей, а также праздничных эффектов.

```
fit <- train %>%
  model(
    arima = ARIMA(Cement),
    ets = ETS(Cement),
    prophet = prophet(Cement ~ season(period = 4, order = 2,
                                      type = "multiplicative"))
  )
```

Обратите внимание, что сезонный член должен иметь период, полностью специфицированный для квартальных и ежемесячных данных, поскольку дефолтные значения (значения, установленные по умолчанию) предполагают, что данные наблюдаются по меньшей мере ежедневно.

```
fc <- fit %>% forecast(h = "2 years 6 months")
fc %>% autoplot(cement)
```

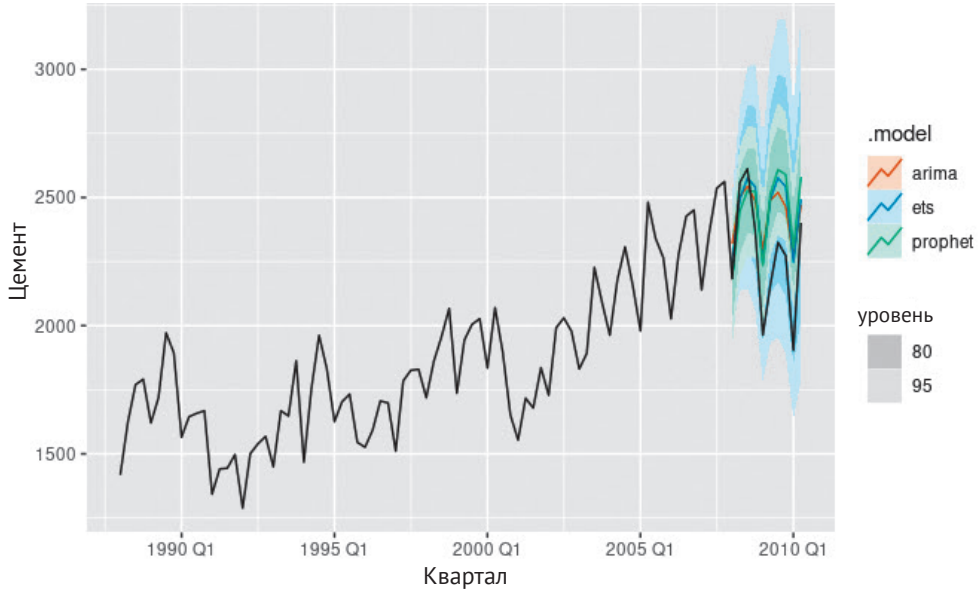


**Рисунок 12.9:** Prophet в сравнении с ETS и ARIMA по данным производства цемента с использованием 10-квартального тестового набора

В этом примере прогнозы модели Prophet хуже, чем прогнозы ETS или ARIMA.

```
fc %>% accuracy(cement)
#> # A tibble: 3 × 10
#>   .model  .type    ME  RMSE   MAE   MPE  MAPE  MASE RMSSE  ACF1
#>   <chr>   <chr> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl>
#> 1 arima   Test  -161.  216.  186. -7.71  8.68  1.27  1.26 0.387
#> 2 ets     Test  -171.  222.  191. -8.07  8.85  1.30  1.29 0.579
#> 3 prophet Test  -176.  248.  216. -8.36  9.89  1.47  1.44 0.699
```

## Пример: получасовой спрос на электроэнергию

Мы выполним подгонку аналогичной модели к модели динамической гармонической регрессии (модели DHR) из предыдущего раздела, но на этот раз с использованием модели Prophet. Для ежедневных и субдневных данных дефолтные периоды указаны правильно, вследствие чего можно просто указать период, используя символьную строку следующим образом.

```
fit <- elec %>%
  model(
    prophet(Demand ~ Temperature + Cooling + Working_Day +
              season(period = "day", order = 10) +
              season(period = "week", order = 5) +
              season(period = "year", order = 3))
  )
fit %>%
  components() %>%
  autoplot()[1]
```

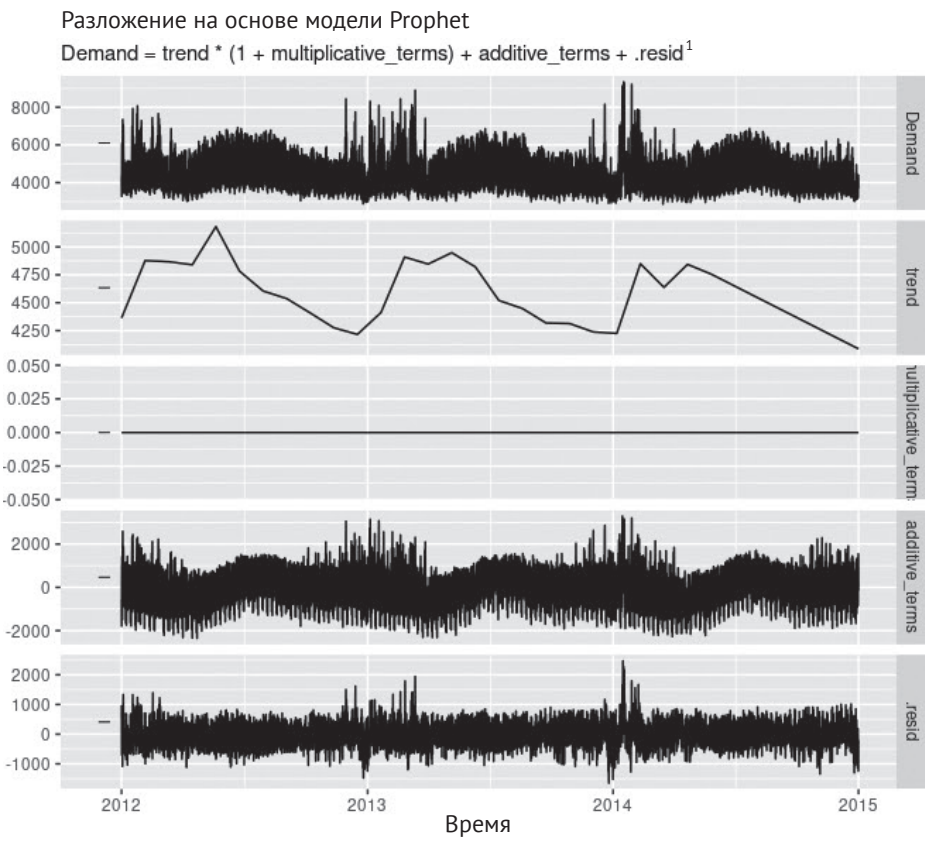


**Рисунок 12.10:** Компоненты модели Prophet, подогнанные к данным спроса на электроэнергию в Виктории

[1] Спрос = тренд * (1 + мультипликативные члены) + аддитивные члены + остатки - *Прим. перев.*

На рис. 12.10 показаны трендовые и сезонные компоненты модели.

Формулировка модели очень похожа на описанную в предыдущем разделе модель DHR, хотя результат отличается несколькими важными аспектами. Модель Prophet добавляет кусочно-линейный временной тренд, который здесь не совсем уместен, поскольку мы не ожидаем, что долгосрочные прогнозы будут продолжать следовать нисходящему линейному тренду в конце ряда.

Кроме того, остается существенная автокорреляция в остатках:

```
fit %>% gg_tsresiduals()
```

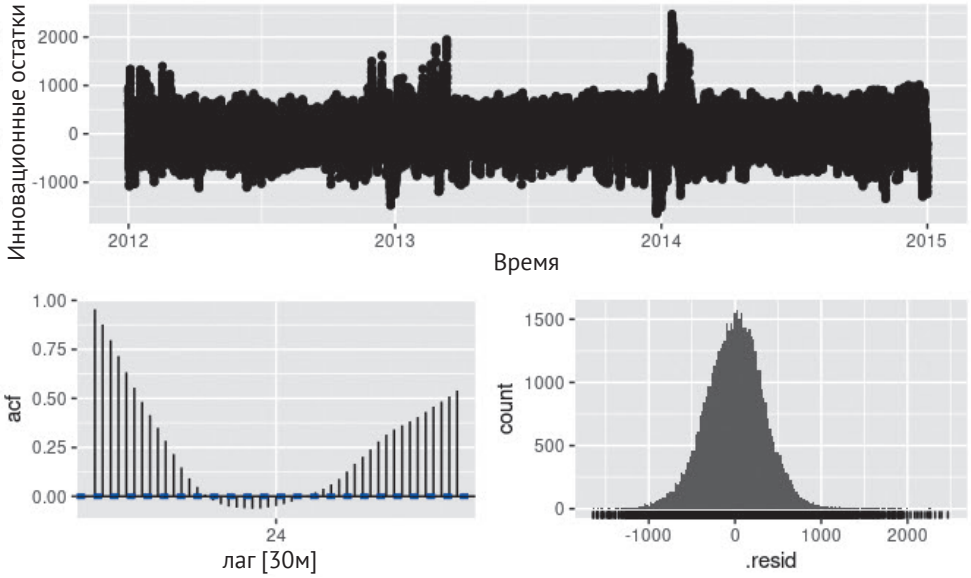


**Рисунок 12.11:** Остатки от модели Prophet для спроса на электроэнергию в шт. Виктория

Вследствие этого предсказательные интервалы, вероятно, получатся слишком узкими.

```
fc <- fit %>%
  forecast(new_data = elec_newdata)
fc %>%
  autoplot(elec %>% tail(10 * 48)) +
  labs(x = "Дата", y = "Спрос (МВтч)")
```

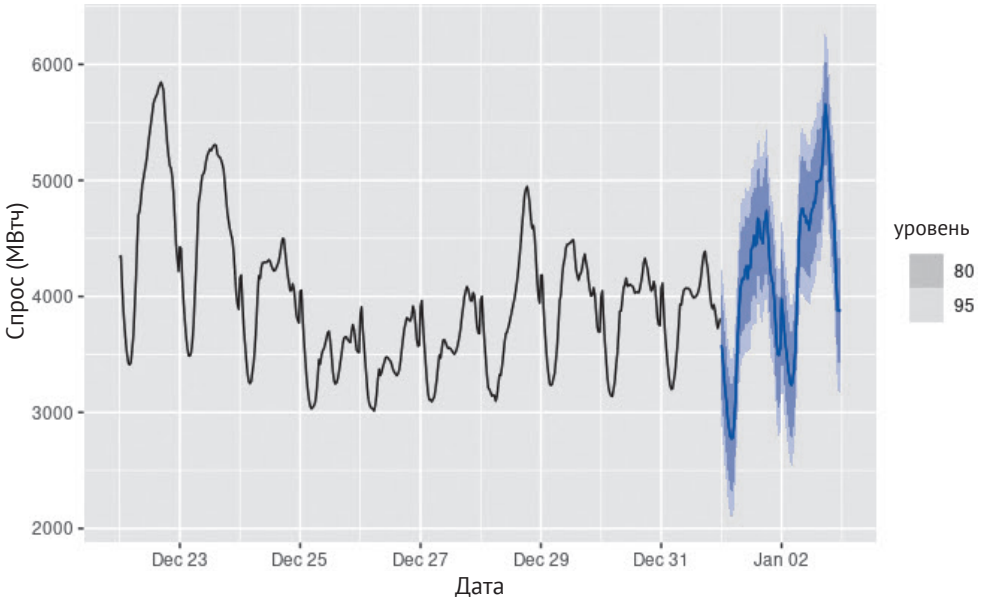


**Рисунок 12.12:** Двухдневные прогнозы по модели Prophet для спроса на электроэнергию в шт. Виктория

Преимущество модели Prophet заключается в том, что ее оценивание выполняется намного быстрее, чем моделей DHR, которые мы рассматривали ранее, и оно полностью автоматизировано. Однако, как показали эти два примера, указанная модель редко дает более высокую точность прогноза, чем альтернативные подходы.

## Библиография

*Тейлор, С. Дж. и Летэм, Б.* (2018). Прогнозирование в масштабе. The American Statistician, 72(1), 37–45. [DOI: https://doi.org/10.1080/00031305.2017.1380080].

# 12.3 Векторные авторегрессии

Одним из ограничений моделей, которые мы рассматривали до сих пор, является то, что они налагают однонаправленную взаимосвязь – предсказательные переменные влияют на прогнозную переменную, но не наоборот. Однако есть много случаев, когда следует учитывать и обратное – когда все переменные влияют друг на друга. В разделе 10.2 изменения в расходах на личное потребление ($C_t$) были спрогнозированы на основе изменений личного располагаемого дохода ($I_t$). Однако в этом случае двунаправленная взаимосвязь бывает более подходящей: увеличение $I_t$ будет приводить к увеличению $C_t$ и наоборот.

Пример такой ситуации произошел в Австралии во время Глобального финансового кризиса 2008–2009 годов. Австралийское правительство выпустило пакеты стимулирующих мер, которые включали денежные выплаты в декабре 2008 года, как раз к рождественским тратам. В результате розничные тор-

говцы отчитались о высоких продажах, и экономика была простимулирована. Следовательно, доходы увеличились.

Такие отношения обратной связи разрешены в векторно-авторегрессионном каркасе (VAR). В указанном каркасе все переменные обрабатываются симметрично. Все они моделируются так, как если бы все они влияли друг на друга одинаково. В более формальной терминологии все переменные теперь рассматриваются как «эндогенные». Для того чтобы это обозначить, мы теперь изменим нотацию и запишем все переменные как $y$ с соответствующими подстрочными знаками: $y_{1,t}$ обозначает $t$-е наблюдение переменной $y_1$, $y_{2,t}$ обозначает $t$-е наблюдение переменной $y_2$ и т. д.

Модель VAR представляет собой обобщение одномерной (однопеременной) авторегрессионной модели для прогнозирования вектора временных рядов[1]. Она содержит по одному уравнению на каждую переменную в системе. Правая часть каждого уравнения включает константу и лаги всех переменных в системе. В целях упрощения задачи мы рассмотрим VAR с двумя переменными и одним лагом. Мы запишем 2-мерную модель VAR(1) как

$$y_{1,t} = c_1 + \phi_{11,1} y_{1,t-1} + \phi_{12,1} y_{2,t-1} + \varepsilon_{1,t}, \tag{12.1}$$

$$y_{2,t} = c_2 + \phi_{21,1} y_{1,t-1} + \phi_{22,1} y_{2,t-1} + \varepsilon_{2,t}, \tag{12.2}$$

где $\varepsilon_{1,t}$ и $\varepsilon_{2,t}$ – это процессы белого шума, которые могут быть коррелированы одновременно. Коэффициент $\phi_{ij,l}$ отражает влияние $\ell$-го лага переменной $y_i$ на себя, в то время как коэффициент $\phi_{ij,l}$ отражает влияние $\ell$-го лага переменной $y_j$ на $y_i$.

Если ряды стационарны, то мы прогнозируем их, подгоняя VAR непосредственно к данным (такая подгонка называется «VAR в уровнях»). Если ряды нестационарны, то мы дифференцируем данные, чтобы сделать их стационарными, а затем выполняем подгонку модели VAR (такая подгонка называется «VAR в разницах»). В обоих случаях модели оценивается уравнение за уравнением с использованием принципа наименьших квадратов. Для каждого уравнения параметры оцениваются путем минимизации суммы значений $\varepsilon_{i,t}$, возведенных в квадрат.

Другая возможность, которая выходит за рамки этой книги и поэтому мы ее здесь не рассматриваем, заключается в том, что ряды могут быть нестационарными, но коинтегрированными. Это означает, что существует их линейная комбинация, которая является стационарной. В этом случае следует использовать формулировку VAR, которая включает механизм исправления ошибок (обычно именуемый векторной моделью исправления ошибок), и следует использовать методы оценивания, альтернативные оцениванию методом наименьших квадратов[2].

---

[1] Более гибким обобщением был бы векторный процесс ARMA. Однако относительная простота моделей VAR привела к их доминированию в прогнозировании. Заинтересованные читатели могут обратиться к *Дж. Атанасопулос и соавт.* (2012, *https://otexts.com/fpp3/VAR.html#ref-AthEtAl2012*).

[2] Заинтересованным читателям следует обратиться к *Гамильтон* (1994, *https://otexts.com/fpp3/VAR.html#ref-Ham1994*) и *Люткеполь* (2007, *https://otexts.com/fpp3/VAR.html#ref-Lut2007*).

Прогнозы генерируются из переменной рекурсивно. VAR генерирует прогнозы для *каждой* переменной, включенной в систему. В целях иллюстрации процесса предположим, что мы применили 2-мерную модель VAR(1), описанную в уравнениях (12.1)–(12.2), для всех наблюдений вплоть до времени $T$. Тогда прогнозы на один шаг вперед генерируются формулами

$$\begin{aligned}\hat{y}_{1,T+1|T} &= \hat{c}_1 + \hat{\phi}_{11,1} y_{1,T} + \hat{\phi}_{12,1} y_{2,T},\\ \hat{y}_{2,T+1|T} &= \hat{c}_2 + \hat{\phi}_{21,1} y_{1,T} + \hat{\phi}_{22,1} y_{2,T}.\end{aligned}$$

Это та же форма, что и (12.1)–(12.2), за исключением того, что ошибки были заданы равными нулю, а параметры были заменены их оценками. Для $h = 2$ прогнозы задаются формулами

$$\begin{aligned}\hat{y}_{1,T+2|T} &= \hat{c}_1 + \hat{\phi}_{11,1} \hat{y}_{1,T+1|T} + \hat{\phi}_{12,1} \hat{y}_{2,T+1|T},\\ \hat{y}_{2,T+2|T} &= \hat{c}_2 + \hat{\phi}_{21,1} \hat{y}_{1,T+1|T} + \hat{\phi}_{22,1} \hat{y}_{2,T+1|T}.\end{aligned}$$

Опять же, это та же форма, что и (12.1)–(12.2), за исключением того, что ошибки были заданы равными нулю, параметры – их оценками, а неизвестные значения $y_1$ и $y_2$ были заменены их прогнозами. Процесс может повторяться в таком ключе для всех будущих периодов времени.

При использовании VAR для прогнозирования нужно принять два решения, а именно сколько переменных (обозначается через $K$) и сколько лагов (обозначается через $p$) должно быть включено в систему. Число коэффициентов, подлежащих оценке в VAR, равно $K + pK^2$ (или $1 + pK$ для каждого уравнения). Например, для VAR с $K = 5$ переменными и $p = 3$ лагами в уравнении имеется 16 коэффициентов, что в общей сложности дает 80 коэффициентов, подлежащих оценке. Чем больше коэффициентов необходимо оценить, тем больше входящая в прогноз ошибка оценивания.

На практике обычно принято держать значение $K$ малым и включать только те переменные, которые коррелируют друг с другом и поэтому полезны для прогнозирования друг друга. Информационные критерии обычно используются для выбора числа подлежащих включению лагов. При применении критерия AICc следует соблюдать осторожность, поскольку он тяготеет к выбору большого числа лагов; вместо этого критерия для моделей VAR мы нередко используем BIC. Более сложной версией модели является «разреженная VAR» (где многие коэффициенты равны нулю); еще один подход заключается в использовании «усадочного оценивания» (где коэффициенты меньше).

Модели VAR сталкиваются с критикой, которая заключается в том, что они атеоретичны; то есть они не построены на какой-то экономической теории, которая накладывает теоретическую структуру на уравнения. Предполагается, что каждая переменная влияет на каждую другую переменную в системе, что затрудняет прямую интерпретацию оценочных коэффициентов. Несмотря на это, переменные полезны в нескольких контекстах:

1) прогнозирование набора родственных переменных, для которых не требуется явной интерпретации;

2) проверка полезности одной переменной для прогнозирования другой (основа тестов Грейнджера на наличие причинно-следственной взаимосвязи);
3) анализ импульсной характеристики, при котором анализируется реакция одной переменной на внезапное, но временное изменение другой переменной;
4) разложение прогнозной дисперсии ошибок, при которой доля прогнозной дисперсии каждой переменной приписывается влиянию других переменных.

## Пример: модель VAR для прогнозирования потребления в США

```
fit <- us_change %>%
  model(
    aicc = VAR(vars(Consumption, Income)),
    bic = VAR(vars(Consumption, Income), ic = "bic")
  )
fit
#> # A mable: 1 x 2
#>                aicc              bic
#>             <model>          <model>
#> 1 <VAR(5) w/ mean> <VAR(1) w/ mean>

glance(fit)
#> # A tibble: 2 × 6
#>   .model sigma2        log_lik   AIC  AICc   BIC
#>   <chr>  <list>          <dbl> <dbl> <dbl> <dbl>
#> 1 aicc   <dbl [2 × 2]>   -373.  798.  806.  883.
#> 2 bic    <dbl [2 × 2]>   -408.  836.  837.  869.
```

Модель VAR(5) отбирается с помощью критерия AICc (по умолчанию), в то время как модель VAR(1) отбирается с помощью критерия BIC. В этом нет ничего необычного – BIC всегда отбирает модель с меньшим числом параметров, чем AICc, поскольку он налагает более строгий штраф за число параметров.

```
fit %>%
  augment() %>%
  ACF(.innov) %>%
  autoplot()
```

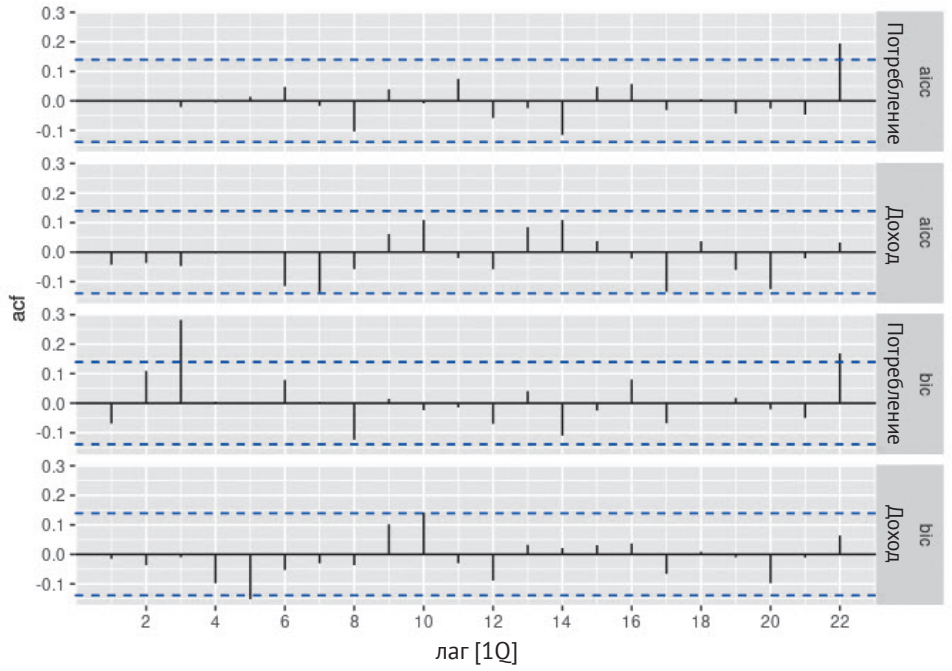


**Рисунок 12.13:** ACF остатков от двух моделей VAR. Модель VAR(5) отбирается с помощью AICc, в то время как модель VAR(1) отбирается с помощью BIC

Мы видим, что остатки от модели VAR(1) (`bic`) имеют значительную автокорреляцию касательно потребления, в то время как модель VAR(5) эффективно уловила всю информацию в данных.

Прогнозы, сгенерированные с помощью модели VAR(5), показаны на рис. 12.14.

```
fit %>%
  select(aicc) %>%
  forecast() %>%
  autoplot(us_change %>% filter(year(Quarter) > 2010))
```

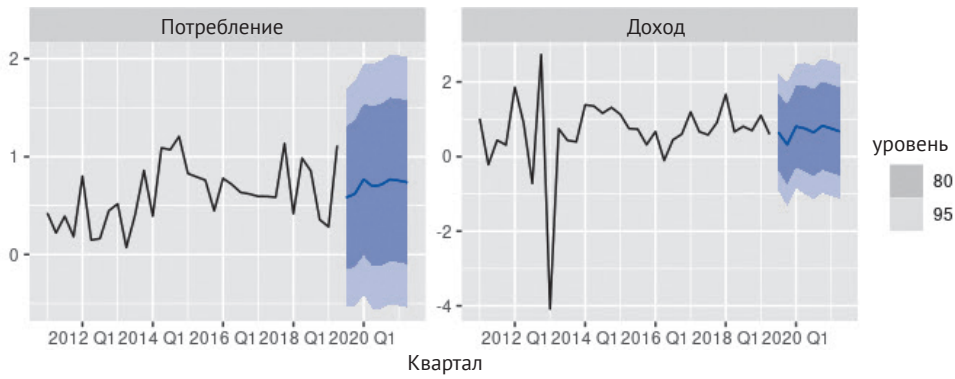


**Рисунок 12.14:** Прогнозы потребления и доходов в США из модели VAR(5)

## Библиография

*Атанасопулос, Дж., Поскитт, Д. С. и Вахид, Ф.* (2012). Две канонические формы VAR: скалярные компонентные модели по отношению к эшелонной форме. Econometric Reviews, 31 (1), 60–83. [DOI: https://doi.org/10.1080/07474938.2011.607088].

*Гамильтон, Дж. Д.* (1994). Анализ временных рядов. Princeton University Press, Princeton. [Amazon, *http://buy.geni.us/Proxy.ashx?TSID=140570&GR_URL=http%3A%2F%2Fwww.amazon.com%2Fdp%2F0691042896*].

*Люткеполь, Х.* (2007). Моделирование от общего к конкретному или от конкретного к общему? Мнение о современной эконометрической терминологии. Journal of Econometrics, 136 (1), 234–319. [DOI https://doi.org/10.1016/j.jeconom.2005.11.014].

# 12.4 Нейросетевые модели

Искусственные нейронные сети – это методы прогнозирования, основанные на простых математических моделях мозга. Они допускают сложные нелинейные взаимосвязи между переменной отклика и ее предсказателями.

## Архитектура нейронной сети

Нейронная сеть может рассматриваться как сеть «нейронов», которые организованы слоями. Предсказатели (или входные данные) формируют нижний слой, а прогнозы (или выходные данные) образуют верхний слой. Также могут существовать промежуточные слои, содержащие «скрытые нейроны».

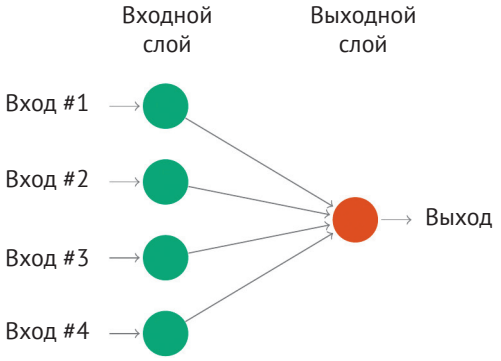


**Рисунок 12.15:** Простая нейронная сеть, эквивалентная линейной регрессии

Простейшие сети не содержат скрытых слоев и эквивалентны линейным регрессиям. На рис. 12.15 показана нейросетевая версия линейной регрессии с четырьмя предсказателями. Привязанные к этим предсказателям коэффициенты называются «весами». Прогнозы получаются с помощью линейной комбинации входных данных. Веса отбираются в нейросетевом каркасе с использованием «обучающегося алгоритма», который минимизирует «функцию стоимости», такую как MSE. Разумеется, в данном простом примере можно использовать линейную регрессию, которая является гораздо более эффективным методом тренировки модели.

Как только мы добавляем промежуточный слой со скрытыми нейронами, нейронная сеть становится нелинейной. Простой пример показан на рис. 12.16.

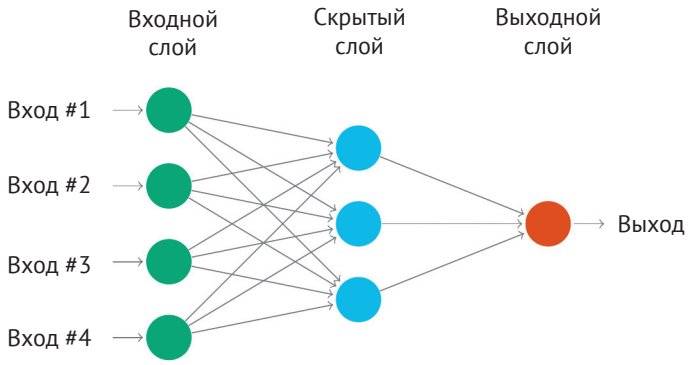


**Рисунок 12.16:** Нейронная сеть с четырьмя входами и одним скрытым слоем с тремя скрытыми нейронами

Такая сеть называется *многослойной сетью прямого распространения*, где каждый слой узлов получает входные данные из предыдущих слоев. Выходные данные узлов одного слоя являются входными данными для следующего слоя. Данные на входе в каждый узел комбинируются с использованием взвешенной линейной комбинации. Затем результат модифицируется нелинейной функцией на выходе. Например, входные данные в каждый скрытый нейрон на рис. 12.16 комбинируются линейно, генерируя

$$z_j = b_j + \sum_{i=1}^{4} w_{i,j} x_i .$$

В скрытом слое этот выходной результат затем модифицируется с использованием нелинейной функции, такой как сигмоида:

$$s(z) = \frac{1}{1+e^{-z}},$$

чтобы задать входные данные для следующего слоя. За счет этого, как правило, уменьшается влияние экстремальных входных значений, тем самым делая сеть в некоторой степени устойчивой к выбросам.

Параметры $b_1$, $b_2$, $b_3$ и $w_{1.1}$, …, $w_{4.3}$ «усваиваются» (или оцениваются) из данных. Значения весов часто ограничиваются, чтобы они не становились слишком крупными. Ограничивающий веса параметр называется «параметром затухания» и часто устанавливается равным 0.1.

Вначале веса принимают случайные значения, а затем они обновляются с использованием наблюдаемых данных. Следовательно, в продуцируемых нейронной сетью прогнозах присутствует элемент случайности. Поэтому сеть обычно тренируют несколько раз с использованием разных случайных начальных точек, а результаты усредняются.

Число скрытых слоев и число узлов в каждом скрытом слое должны быть указаны заранее. Позже в этой главе мы рассмотрим, как их можно выбирать с помощью перекрестной валидации.

## Нейросетевая авторегрессия

Сдвинутые во времени значения (лаги) временных рядов можно использовать с остальными данными временных рядов в качестве входов в нейронную сеть, точно так же, как мы использовали лагированные значения в линейной авторегрессионной модели (глава 9). Такая модель называется нейросетевой авторегрессией, или моделью NNAR (от англ. neural network autoregression).

В этой книге мы рассматриваем сети только прямого распространения с одним скрытым слоем и будем использовать нотацию NNAR($p$, $k$), указывая, что в скрытом слое имеется $p$ лагированных входов и $k$ узлов. Например, модель NNAR(9,5) представляет собой нейронную сеть, последние девять наблюдений $y_{t-1}, y_{t-2}, \ldots, y_{t-9}$ которой используются в качестве входов для прогнозирования выхода $y_t$ и в скрытом слое которой имеется пять нейронов. Модель NNAR($p$,0) эквивалентна модели ARIMA($p$,0,0), но без ограничений на параметры для обеспечения стационарности.

При использовании сезонных данных полезно также добавлять последние наблюдаемые значения за тот же сезон, что и входные данные. Например, модель NNAR(3, 1, 2)$_{12}$ имеет входы $y_{t-1}$, $y_{t-2}$ и $y_{t-12}$ и два нейрона в скрытом слое. В более общем случае модель NNAR($p$,$P$,$k$)$_{\text{m}}$ имеет входы ($y_{t-1}, y_{t-2}, \ldots, y_{t-p}, y_{t-m}, y_{t-2m}, \ldots, y_{t-Pm}$) и $k$ нейронов в скрытом слое. Модель NNAR($p$,$P$,0)$_{\text{m}}$ эквивалентна модели ARIMA($p$,0,0), но без ограничений на параметры, обеспечивающие стационарность.

Функция `NNETAR()` выполняет подгонку модели NNAR($p$,$P$,$k$)$_{\text{m}}$. Если значения $p$ и $P$ не указаны, то они отбираются автоматически. Для несезонных временных рядов по умолчанию используется оптимальное число лагов (в соответствии с AIC) для линейной модели AR($p$). Для сезонных временных рядов дефолтные значения равны $P = 1$, а $p$ выбирается из оптимальной линейной модели, подогнанной к сезонно скорректированным данным. Если $k$ не указано, то оно устанавливается равным $k = (p + P + 1)/2$ (округленно до ближайшего целого числа).

Если говорить о прогнозировании, то сеть применяется итеративно. Для прогнозирования на шаг вперед мы просто используем имеющиеся исторические изначальные данные. Для прогнозирования на два шага вперед мы используем одношаговый прогноз в качестве входных данных вместе с историческими данными. Этот процесс продолжается до тех пор, пока мы не вычислим все необходимые прогнозы.

## Пример: пятна на Солнце

Поверхность Солнца содержит магнитные области, которые выглядят как темные пятна. Они влияют на распространение радиоволн, и поэтому телекоммуникационные компании любят прогнозировать активность пятен на Солнце, чтобы планировать любые будущие трудности. Пятна на Солнце следуют циклу продолжительностью от 9 до 14 лет. На рис. 12.17 показаны прогнозы

NNAR(9,5) на ближайшие 30 лет. Мы использовали квадратичное преобразование в целях обеспечения того, чтобы прогнозы оставались положительными.

```
sunspots <- sunspot.year %>% as_tsibble()
fit <- sunspots %>%
  model(NNETAR(sqrt(value)))
fit %>%
  forecast(h = 30) %>%
  autoplot(sunspots) +
  labs(x = "Год", y = "Количества", title = "Годовые пятна на Солнце")
```

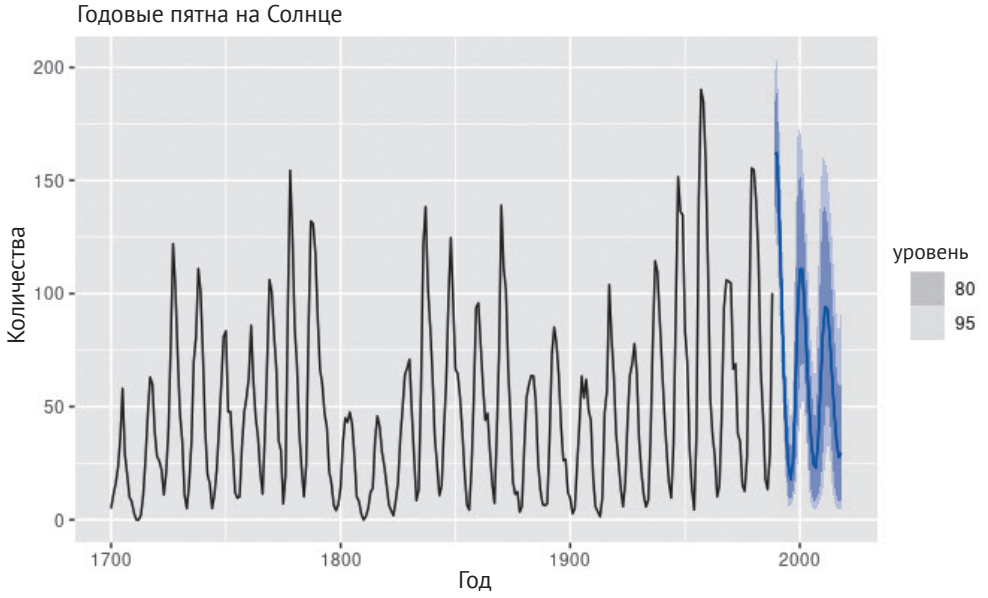


**Рисунок 12.17:** Прогнозы нейронной сети с девятью лагированными (сдвинутыми во времени) входами и одним скрытым слоем, содержащим пять нейронов

Здесь в качестве предсказателей используются последние 9 наблюдений, а в скрытом слое находится 5 нейронов. Цикличность данных была хорошо смоделирована. Мы также видим, что модель уловила асимметрию циклов, причем увеличивающаяся часть цикла круче, чем уменьшающаяся часть цикла. Это одно из различий между моделью NNAR и линейной моделью AR – хотя линейные модели AR и могут моделировать цикличность, моделируемые циклы всегда симметричны.

## Предсказательные интервалы

В отличие от большинства методов, рассмотренных в этой книге, нейронные сети не основаны на четко определенной стохастической модели, и поэтому вывести предсказательные интервалы для результирующих прогнозов не так-то просто. Тем не менее мы все же можем вычислять предсказательные ин-

тервалы с помощью симулирования, где будущие пути выборки генерируются с использованием бутстрапированных остатков (как описано в разделе 5.5).

Нейронную сеть, подогнанную к данным о пятнах на Солнце, можно записать как

$$y_t = f\left(\mathbf{y}_{t-1}\right) + \varepsilon_t,$$

где $\mathbf{y}_{t-1} = (y_{t-1}, y_{t-2}, \ldots, y_{t-9})$ – это вектор, содержащий лагированные значения ряда, а $f$ – нейронная сеть с 5 скрытыми узлами в одном слое. Предполагается, что ряд ошибок $\{\varepsilon_t\}$ гомоскедастичен (и, возможно, также нормально распределен).

Мы можем просимулировать будущие пути выборки из этой модели итеративно, случайно генерируя значение $\varepsilon_t$ из нормального распределения либо путем повторного отбора из исторических значений. Так что если $\varepsilon^*_{T+1}$ – это случайное значение, извлеченное из распределения ошибок во время $T + 1$, тогда

$$y^*_{T+1} = f\left(\mathbf{y}_T\right) + \varepsilon^*_{T+1}$$

является одним из возможных значений, извлеченных из прогнозного распределения для $y_{T+1}$. Установив $\mathbf{y}^*_{T+1} = (y^*_{T+1}, y_T, \ldots, y_{T-7})'$, затем можно повторить процесс, получив

$$y^*_{T+2} = f\left(\mathbf{y}^*_{T+1}\right) + \varepsilon^*_{T+2}.$$

В таком ключе можно симулировать будущий путь выборки итеративно. Многократно симулируя пути выборки, мы накапливаем знания о распределении для всех будущих значений из подогнанной нейронной сети.

Ниже приведено симулирование 9 возможных будущих путей выборки для данных о пятнах на Солнце. Каждый путь выборки охватывает следующие 30 лет после получения наблюдаемых данных.

```
fit %>%
  generate(times = 9, h = 30) %>%
  autoplot(.sim) +
  autolayer(sunspots, value) +
  theme(legend.position = "none")
```

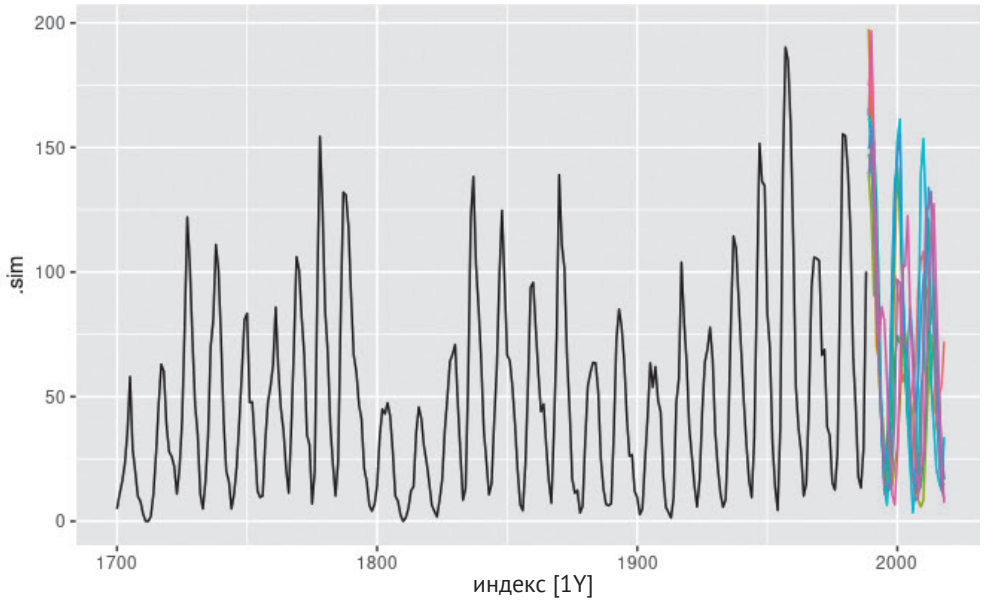


**Рисунок 12.18:** Будущие пути выборки для ежегодных данных о пятнах на Солнце

Если мы проделаем это много раз, то сможем получить хорошую картину прогнозных распределений. Именно так функция `forecast()` создает предсказательные интервалы для моделей NNAR. Аргумент `times` в `forecast()` определяет число выполняемых симуляций (по умолчанию 1000). По умолчанию ошибки берутся из нормального распределения. Аргумент `bootstrap` позволяет «бутстрапировать» ошибки (т. е. случайно извлекать их из исторических ошибок).

# 12.5 Бутстрапирование и бутстрап-агрегирование

## Бутстрапирование временного ряда

В предыдущем разделе и в разделе 5.5 мы бутстрапировали остатки временного ряда, чтобы просимулировать будущие значения ряда с использованием модели.

В более общем случае существует возможность генерировать новые временные ряды, похожие на наши наблюдаемые ряды, используя еще один тип бутстрапирования.

Сначала при необходимости временной ряд преобразовывается, а потом разлагается на трендовую, сезонную и остаточную компоненты с использованием STL. Затем мы получаем перетасованные версии компоненты остатков, чтобы получить бутстрапированный ряд остатков. Поскольку в STL-ряду остатков может присутствовать автокорреляция, нельзя просто использовать процедуру повторного извлечения, которая была описана в разделе 5.5. Вместо этого мы используем процедуру «блокированного бутстрапа», в которой смежные участки временного ряда отбираются случайным образом и соединяются

вместе. Эти бутстрапированные ряды остатков добавляются в трендовую и сезонную компоненты, и преобразование выполняется в обратном порядке, чтобы получить вариации изначального временного ряда.

Рассмотрим квартальное производство цемента в Австралии за период 1988Q1–2010Q2. Сначала мы проверяем, см. рис. 12.19, что разложение адекватно отражает тренд и сезонность и что в ряду остатков не остался очевидный сигнал.

```
cement <- aus_production %>%
  filter(year(Quarter) >= 1988) %>%
  select(Quarter, Cement)
cement_stl <- cement %>%
  model(stl = STL(Cement))
cement_stl %>%
  components() %>%
  autoplot()
```

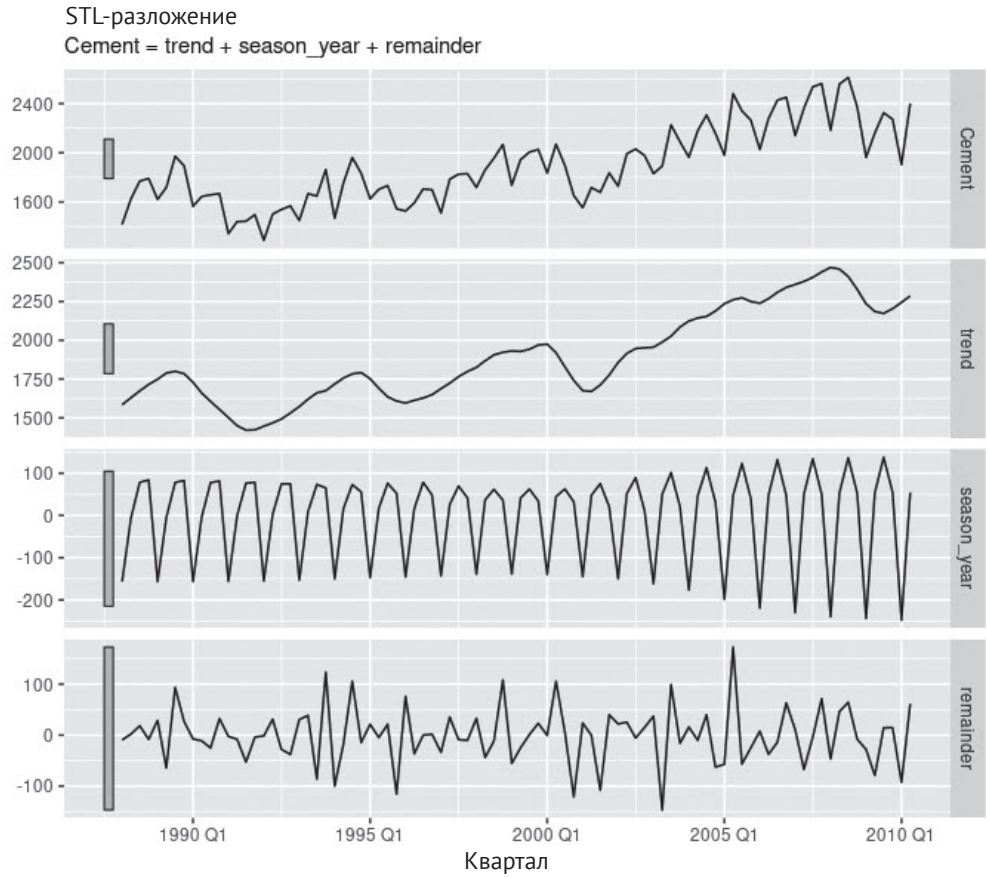


**Рисунок 12.19:** STL-разложение квартального производства цемента в Австралии

Теперь можно сгенерировать несколько бутстрапированных версий данных. Обычно функция `generate()` продуцирует симуляции будущего из модели. Но здесь нужны симуляции для периода исторических данных. Поэтому мы используем аргумент `new_data` для передачи изначальных данных, чтобы для смоделированных данных использовались одни и те же временные периоды. Мы будем использовать размер блока 8, чтобы охватить данные за два года.

```
cement_stl %>%
  generate(new_data = cement, times = 10,
           bootstrap_block_size = 8) %>%
  autoplot(.sim) +
  autolayer(cement, Cement) +
  guides(colour = "none") +
  labs(title = "Производство цемента: бутстрапированные ряды",
       y="Тонны (тыс.)")
```

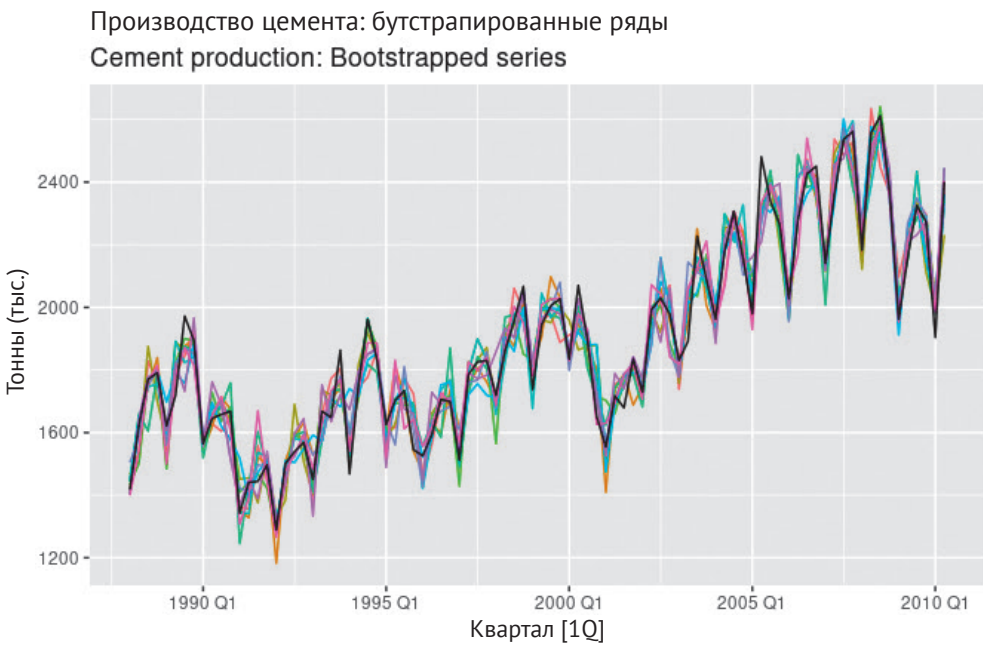


**Рисунок 12.20:** Десять бутстрапированных версий ежеквартального производства цемента в Австралии (цветные кривые) вместе с изначальными данными (черная кривая)

## Бутстрап-агрегированные прогнозы

Одним из применений этих бутстрапированных временных рядов является повышение точности прогноза. Если мы составим прогнозы из каждого дополнительного временного ряда и усредним результирующие прогнозы, то получим более качественные прогнозы, чем если бы мы просто прогнозирова-

ли изначальный временной ряд напрямую. Такой подход называется «бэггингом», от англ. **b**ootstrap **agg**regat**ing**», что означает «агрегирование бутстраповских выборок», или просто бутстрап-агрегирование.

Продемонстрируем эту идею, используя данные о цементе (`cement`). Сначала мы симулируем множество временных рядов, похожих на изначальные данные, используя описанный выше блочный бутстрап.

```
sim <- cement_stl %>%
  generate(new_data = cement, times = 100,
           bootstrap_block_size = 8) %>%
  select(-.model, -Cement)
```

Для каждого из этих рядов мы выполняем подгонку модели ETS. В каждом случае может быть отобрана другая модель ETS, хотя, скорее всего, будет отобрана та же самая модель, поскольку ряды похожи. Однако оценочные параметры будут отличаться, поэтому прогнозы будут отличаться, даже если отобранная модель та же самая. Это трудоемкий процесс, поскольку существует большое число рядов.

```
ets_forecasts <- sim %>%
  model(ets = ETS(.sim)) %>%
  forecast(h = 12)
ets_forecasts %>%
  update_tsibble(key = .rep) %>%
  autoplot(.mean) +
  autolayer(cement, Cement) +
  guides(colour = "none") +
  labs(title = "Производство цемента: бутстрапированные прогнозы",
       y="Тонны (тыс.)")
```

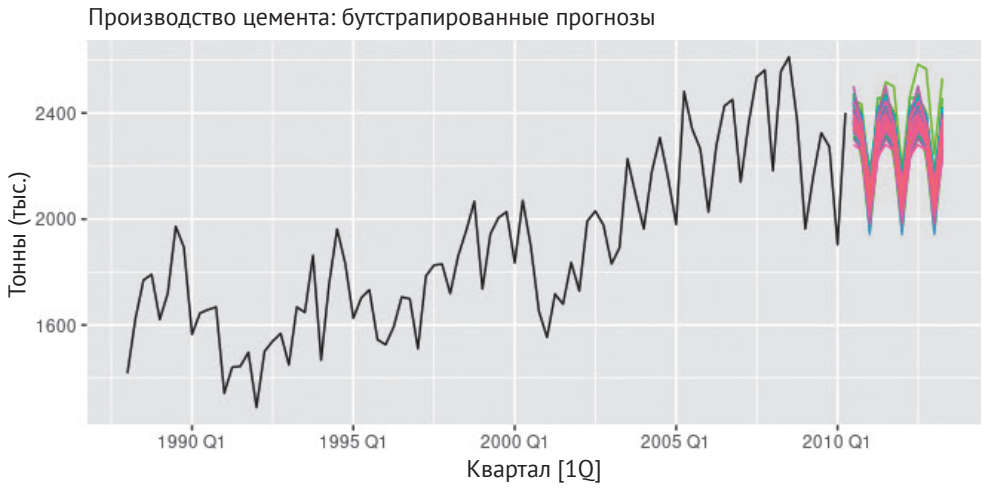


**Рисунок 12.21:** Прогнозы 100 бутстрапированных рядов, полученные с использованием моделей ETS

Наконец, мы усредняем эти прогнозы для каждого периода времени, получая «бутстрап-агрегированные» прогнозы для изначальных данных.

```
bagged <- ets_forecasts %>%
  summarise(bagged_mean = mean(.mean))
cement %>%
  model(ets = ETS(Cement)) %>%
  forecast(h = 12) %>%
  autoplot(cement) +
  autolayer(bagged, bagged_mean, col = "#D55E00") +
  labs(title = "Производство цемента в Австралии",
       y="Тонны (тыс.)")
```

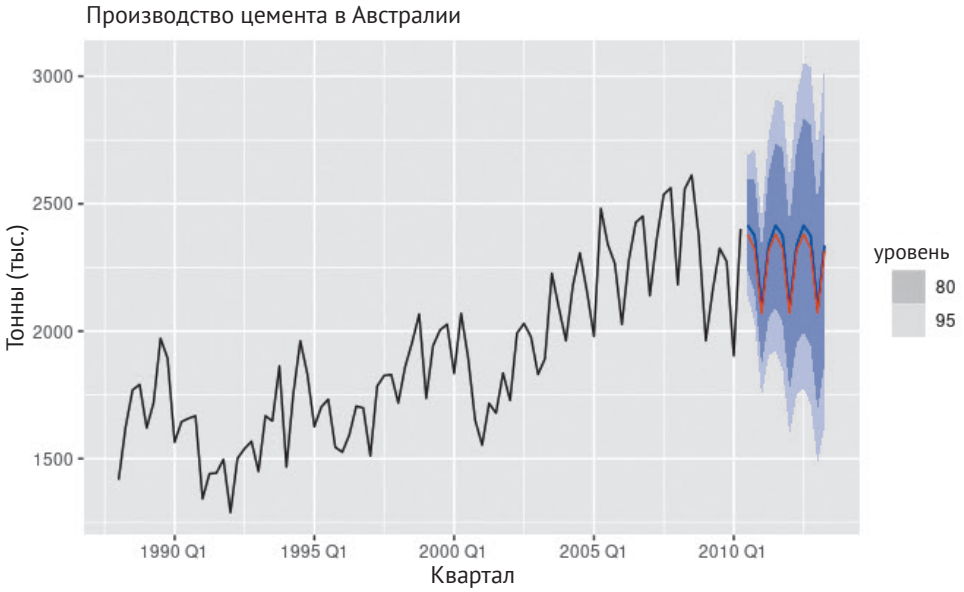


**Рисунок 12.22:** Сравнение бутстрап-агрегированных ETS-прогнозов (среднее значение из 100 бутстрапированных прогнозов оранжевым цветом) и ETC применительно непосредственно к данным (синим цветом)

Бергмейер и соавт. (2016, *https://otexts.com/fpp3/bootstrap.html#ref-baggedETS*) показывают, что в среднем бутстрап-агрегирование дает более качественные прогнозы, чем простое прямое применение `ETS()`. Конечно же, оно выполняется медленнее, потому что требуется гораздо больше вычислений.

## Библиография

*Бергнер, К., Хайндман, Р. Дж. и Бенитес, Дж. М.* (2016). Бутстрап-агрегирование методов экспоненциального сглаживания с использованием STL-разложения и преобразования Бокса–Кокса. International Journal of Forecasting, 32 (2), 303–312. [DOI: https://doi.org/10.1016/j.ijforecast.2015.07.002].

## 12.6 Упражнения

1. Сравните прогнозы STL и динамической гармонической регрессии для одного из рядов в наборе данных `pedestrian`.
   a) Попробуйте изменить степень членов Фурье, чтобы минимизировать значение AICc.
   b) Проверьте остатки каждой модели. Улавливают ли они имеющуюся в данных информацию?
   c) Какой из двух наборов прогнозов является наилучшим? Объясните.
2. Рассмотрите еженедельные данные о поставках готовых автомобильных бензинов в США (миллионы баррелей в день) (ряд `us_gasoline`).
   a) Выполните подгонку модели динамической гармонической регрессии к этим данным. Как она соотносится с регрессионной моделью, которую вы использовали в упражнении 5 в разделе 7.10?
   b) Проверьте остатки обеих моделей и прокомментируйте то, что вы видите.
   c) Не могли бы вы смоделировать эти данные, используя любой из других методов, которые мы рассматривали в этой книге? Объясните, почему да / почему нет.
3. Поэкспериментируйте с использованием функции `NNETAR()` на ваших розничных данных и других данных, которые мы рассмотрели в предыдущих главах.

## 12.7 Дальнейшее чтение

Модель Пророка описана в С. Дж. Тейлор и Летэм (2018, *https://otexts.com/fpp3/advanced-reading.html#ref-prophet*).

Пфафф (2008, *https://otexts.com/fpp3/advanced-reading.html#ref-Pfaff2008*) представляет объемный обзор VAR-моделирования и других моделей многомерных временных рядов.

Текущий обзор использования рекуррентных нейронных сетей для прогнозирования представлен Hewamalage и соавт. (2021, *https://otexts.com/fpp3/advanced-reading.html#ref-HBB2021rnn)*.

Бутстрапирование для временных рядов обсуждается в Лахири (2003, *https://otexts.com/fpp3/advanced-reading.html#ref-Lahiri2013*).

Бутстрап-агрегирование для прогнозирования временных рядов является относительно новым явлением. Бергмейер и соавт. (2016, *https://otexts.com/fpp3/advanced-reading.html#ref-baggedETS*) – одна из немногих работ, в которой рассматривается эта тема.

## Библиография

*Бергмейер, К., Хайндман, Р. Дж. и Бенитес, Дж. М.* (2016). Бутстрап-агрегирование методов экспоненциального сглаживания с использованием STL-разложения и преобразования Бокса–Кокса. International Journal of Forecasting, 32 (2), 303-312. [DOI: https://doi.org/10.1016/j.ijforecast.2015.07.002].

*Хьюаманаж, Дж., Бергмейер, С. и Бандара, К.* (2021). Рекуррентные нейронные сети для прогнозирования временных рядов: текущее состояние и будущие направления. International Journal of Forecasting, 37 (1), 388–427. [DOI: https://doi.org/10.1016/j.ijforecast.2020.06.008].

*Лахири, С. Н.* (2003). Методы повторного отбора для зависимых данных. Springer Science & Business Media. [Amazon, *http://buy.geni.us/Proxy.ashx?TSID=140570&GR_URL=http%3A%2F%2Fwww.amazon.com%2Fdp%2F0387009280*].

*Пфафф, Б.* (2008). Анализ интегрированных и коинтегрированных временных рядов с помощью R. Springer Science & Business Media. [Amazon, *http://buy.geni.us/Proxy.ashx?TSID=140570&GR_URL=http%3A%2F%2Fwww.amazon.com%2Fdp%2F0387759662*].

*Тейлор, С. Дж. и Летэм, Б.* (2018). Прогнозирование в масштабе. The American Statistician, 72 (1), 37–45. [DOI: https://doi.org/10.1080/00031305.2017.1380080].

# Глава 13

# Некоторые практические вопросы прогнозирования

В этой заключительной главе мы рассмотрим многие практические вопросы, возникающие при прогнозировании, и обсудим некоторые возможные решения.

## 13.1 Еженедельные, ежедневные и субдневные данные

Прогнозировать на еженедельных, ежедневных и субдневных данных бывает довольно трудно, хотя и по разным причинам.

### Еженедельные данные

С еженедельными данными трудно работать, поскольку сезонный период (число недель в году) является одновременно большим и нецелым числом. Среднее число недель в году составляет 52.18. Большинство рассмотренных нами методов требуют, чтобы сезонный период был целым числом. Даже если аппроксимировать его числом 52, большинство методов не будут эффективно обрабатывать такой большой сезонный период.

Самый простой подход заключается в использовании STL-разложения вместе с несезонным методом, применяемым к сезонно скорректированным данным (как обсуждается в главе 3). Ниже приведен пример, в котором используются еженедельные данные о поставках готовых автомобильных бензинов в США (в миллионах баррелей в день) с февраля 1991 г. по май 2005 г.

```
my_dcmp_spec <- decomposition_model(
  STL(Barrels),
  ETS(season_adjust ~ season("N"))
)
us_gasoline %>%
  model(stl_ets = my_dcmp_spec) %>%
  forecast(h = "2 years") %>%
  autoplot(us_gasoline) +
  labs(y = "Миллионы баррелей в день",
       title = "Еженедельное производство бензина в США")
```

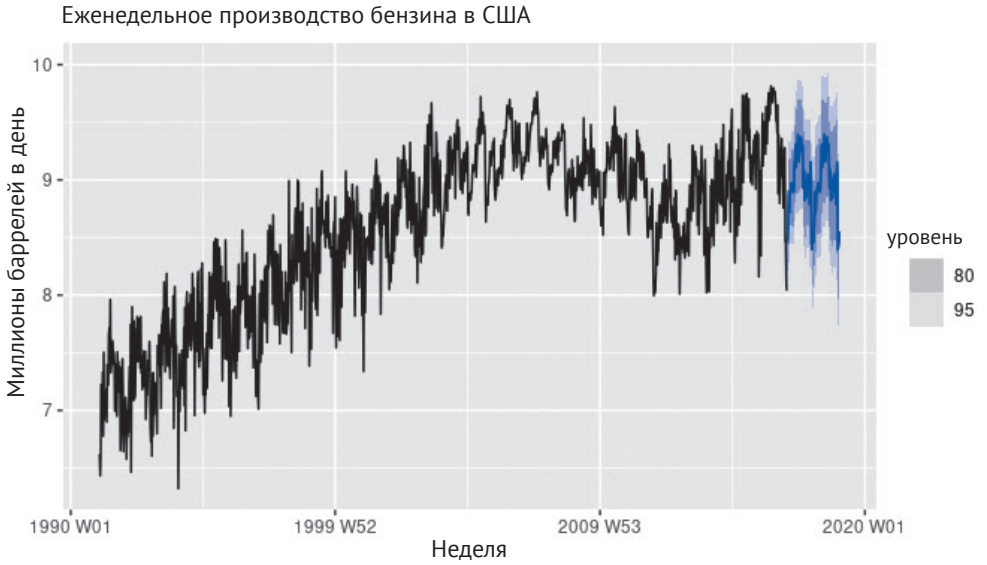


**Рисунок 13.1:** Прогнозы недельного производства бензина в США на основе STL-разложения с использованием модели ETS для сезонно скорректированных данных

Альтернативный подход заключается в использовании модели динамической гармонической регрессии, как описано в разделе 10.5. В следующем ниже примере число членов Фурье было выбрано путем минимизации AICc. Порядок модели ARIMA также отбирается путем минимизирования AICc, хотя это делается с помощью функции `ARIMA()`. Мы используем `PDQ(0,0,0)`, чтобы предотвратить попытку `ARIMA()` обработать сезонность с помощью сезонных компонент ARIMA.

```
gas_dhr <- us_gasoline %>%
  model(dhr = ARIMA(Barrels ~ PDQ(0, 0, 0) + fourier(K = 6)))
gas_dhr %>%
  forecast(h = "2 years") %>%
  autoplot(us_gasoline) +
  labs(y = "Миллионы баррелей в день",
       title = "Еженедельное производство бензина в США")
```

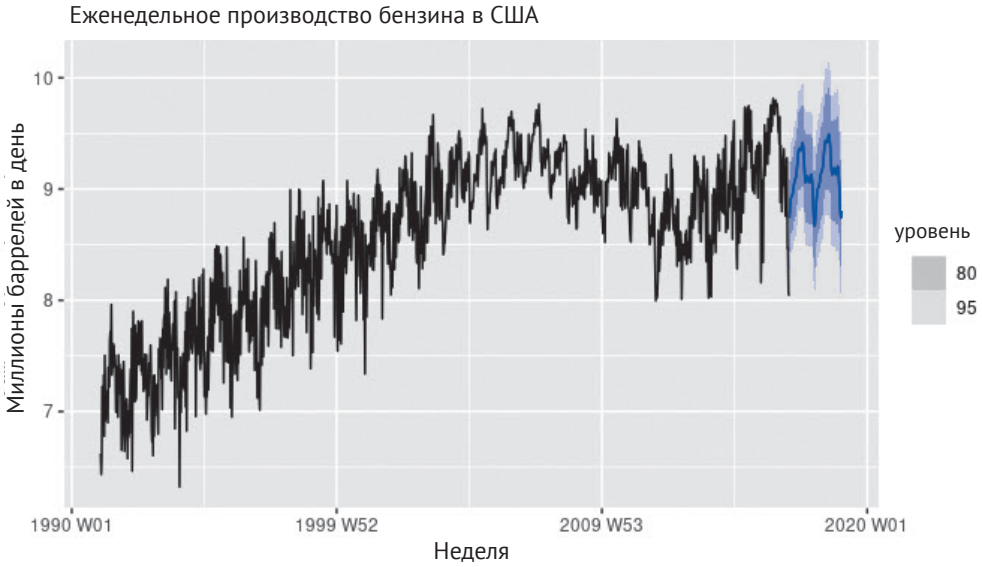


**Рисунок 13.2:** Прогнозы еженедельного производства бензина в США с использованием модели динамической гармонической регрессии

Подогнанная модель имеет 6 пар членов Фурье, и ее можно записать как

$$y_t = bt + \sum_{j=1}^{6}\left[\alpha_j \sin\left(\frac{2\pi jt}{52.18}\right) + \beta_j \cos\left(\frac{2\pi jt}{52.18}\right)\right] + \eta_t,$$

где $\eta_t$ – это процесс ARIMA(0,1,1). Поскольку $\eta_t$ нестационарно, модель фактически оценивается по разницам переменных с обеих сторон этого уравнения. Для определения сезонности имеется 12 параметров, тогда как суммарное число степеней свободы равно 14 (две другие исходят из параметра MA и параметра дрейфа).

Подход с применением STL предпочтительнее, когда сезонность меняется с течением времени. Подход с применением динамической гармонической регрессии предпочтительнее, если существуют ковариаты, которые являются полезными предсказателями, поскольку они могут добавляться в качестве дополнительных регрессоров.

## Ежедневные и субдневные данные

Ежедневные и субдневные (например, почасовые) данные сложны по другой причине – они часто включают в себя несколько сезонных закономерностей, и поэтому необходимо использовать метод, который обрабатывает такую сложную сезонность.

Разумеется, если временной ряд относительно короток, вследствие чего присутствует только один тип сезонности, то можно будет использовать один из односезонных методов, которые мы обсуждали в предыдущих главах (например, ETS или сезонную модель ARIMA). Но когда временной ряд достаточно

длинный, в результате чего некоторые более длительные сезонные периоды становятся очевидными, необходимо будет использовать STL, динамическую гармоническую регрессию или Prophet, как описано в разделе 12.1.

Однако эти методы допускают только регулярную сезонность. Уловить сезонность, связанную с такими движущимися событиями, как Пасха, Уразабайрам или Китайский Новый год, сложнее. Даже с ежемесячными данными это бывает непросто, поскольку праздники могут приходиться на март или апрель (Пасха), январь или февраль (Китайский Новый год) или в любое время года (Ураза-байрам).

Самый лучший способ справиться с движущимися праздничными эффектами – включать в модель фиктивные переменные. Это можно сделать, например, с помощью функций `ARIMA()` или `prophet()`, но не с помощью `ETS()`. На самом деле у `prophet()` есть функция `holiday()`, позволяющая легко включать праздничные эффекты.

## 13.2 Временные ряды счетных данных

Все методы, обсуждаемые в этой книге, предполагают, что данные имеют непрерывное выборочное пространство. Но нередко данные поступают в виде количеств. Например, может возникнуть потребность спрогнозировать число покупателей, которые заходят в магазин каждый день. У нас могло бы быть 0, 1, 2, … клиентов, но у нас не может быть 3.45693 клиента.

На практике это редко играет существенную роль, при условии что наши счетные данные достаточно велики. Если минимальное число клиентов составляет не менее 100, то разница между непрерывным выборочным пространством $[100, \infty]$ и дискретным выборочным пространством {100, 101, 102, …} не оказывает заметного влияния на прогнозы. Однако если данные содержат малые количества (0, 1, 2, …), то необходимо использовать методы прогнозирования, которые более подходят для выборочного пространства неотрицательных целых чисел.

Подобные модели выходят за рамки данной книги. Однако в этом контексте используется один простой метод, о котором мы хотели бы упомянуть. Это «метод Кростона», названный в честь его британского изобретателя Джона Кростона и впервые описанный в книге Кростона (1972, *https://otexts.com/fpp3/counts.html#ref-Croston72*). На самом деле этот метод тоже не справляется со счетной природой данных надлежащим образом, но он используется так часто, что о нем стоит знать.

С помощью метода Кростона из изначального временного ряда строится два новых ряда, отмечая при этом, какие периоды времени содержат нулевые значения, а какие периоды содержат ненулевые значения. Обозначим через $q_i$ $i$-ю ненулевую величину и через $a_i$ – время между $q_{i-1}$ и $q_i$. Метод Кростона предусматривает отдельные простые прогнозы на основе экспоненциального сглаживания на двух новых рядах $a$ и $q$. Поскольку этот метод обычно применяется к временным рядам спроса на товары, $q$ нередко называют «спросом», а $a$ – «временем между поступлениями».

Если, основываясь на данных вплоть до спроса $i$, $\hat{q}_{i+1|i}$ и $\hat{a}_{i+1|i}$ – это одношаговые прогнозы соответственно $(i + 1)$-го спроса и времени между поступлениями, то метод Кростона дает

$$\hat{q}_{i+1|i} = \left(1-\alpha_q\right)\hat{q}_{i|i-1} + \alpha_q q_i, \tag{13.1}$$

$$\hat{a}_{i+1|i} = \left(1-\alpha_a\right)\hat{a}_{i|i-1} + \alpha_a a_i. \tag{13.2}$$

Параметры сглаживания $\alpha_a$ и $\alpha_q$ принимают значения от 0 до 1. Обозначим через $j$ время последнего наблюдаемого положительного наблюдения. Тогда прогноз на $h$-й шаг вперед во времени $T + h$ задается соотношением

$$\hat{y}_{T+h|T} = \hat{q}_{j+1|j} / \hat{a}_{j+1|j}. \tag{1}$$

Никаких алгебраических результатов, позволяющих вычислять предсказательные интервалы, для этого метода не существует, поскольку указанный метод не соответствует какой-либо статистической модели (Шенстоун и Хайндман, 2005, *https://otexts.com/fpp3/counts.html#ref-SH05*).

Функция `CROSTON()` создает прогнозы с использованием метода Кростона. Два параметра сглаживания $\alpha_a$ и $\alpha_q$ оцениваются из данных. Это отличается от того, как сам Кростон представлял себе используемый метод. Он просто использовал $\alpha_a = \alpha_q = 0.1$ и устанавливал $a_0$ и $q_0$ равными первому наблюдению в каждом ряду.

## Пример: продажа фармацевтических препаратов

На рис. 13.3 показано число рецептов, продававшихся каждый месяц на иммунные сыворотки и иммуноглобулиновые препараты в Австралии. Данные содержат малые количества, причем во многих месяцах продажи не регистрировались вообще, а в иные месяцы продавалось лишь небольшое число рецептов.

```
j06 <- PBS %>%
  filter(ATC2 == "J06") %>%
  summarise(Scripts = sum(Scripts))

j06 %>% autoplot(Scripts) +
  labs(y="Число рецептов",
       title = "Продажи иммунных сывороток и иммуноглобулиновых препаратов")
```

**Рисунок 13.3:** Число проданных рецептов на иммунные сыворотки и иммуноглобулины в рамках Австралийской программы фармацевтических льгот

В табл. 13.1 и 13.2 показаны первые 10 ненулевых значений спроса с соответствующим им временем между поступлениями.

**Таблица 13.1:** Первые 10 ненулевых значений спроса

| Месяц | Рецепты |
|---|---|
| 1991 Июль | 1 |
| 1991 Август | 1 |
| 1991 Сентябрь | 1 |
| 1991 Октябрь | 0 |
| 1991 Ноябрь | 0 |
| 1991 Декабрь | 1 |
| 1992 Январь | 3 |
| 1992 Февраль | 1 |
| 1992 Март | 1 |
| 1992 Апрель | 1 |
| 1992 Май | 1 |
| 1992 Июнь | 1 |

**Таблица 13.2:** Первые 10 ненулевых значений спроса показаны в виде рядов спроса и промежуточных поступлений

| i | 1 | 2 | 3 | 4 | 5 | 6 | 7 | 8 | 9 | 10 |
|---|---|---|---|---|---|---|---|---|---|---|
| $q_i$ | 1 | 1 | 1 | 1 | 3 | 1 | 1 | 1 | 1 | 1 |
| $a_i$ | | 1 | 1 | 3 | 1 | 1 | 1 | 1 | 1 | 1 |

В данном примере параметры сглаживания оцениваются как $\alpha_a = 0.08$, $\alpha_q = 0.71$, $\hat{q}_{1|0} = 4.17$ и $\hat{a}_{1|0} = 3.52$. Окончательные прогнозы для двух рядов равны $\hat{q}_{T+1|T} = 2.419$ и $\hat{a}_{T+1|T} = 2.484$. Таким образом, все прогнозы равны $\hat{y}_{T+h|T} = 2.419 / 2.484 = 0.974$.

На практике пакет fable выполняет эти вычисления за вас:

```
j06 %>%
  model(CROSTON(Scripts)) %>%
  forecast(h = 6)
#> # A fable: 6 x 4 [1M]
#> # Key:     .model [1]
#>   .model              Month Scripts .mean
#>   <chr>               <mth>  <dist> <dbl>
#> 1 CROSTON(Scripts) 2008 Jul  0.9735 0.974
#> 2 CROSTON(Scripts) 2008 Aug  0.9735 0.974
#> 3 CROSTON(Scripts) 2008 Sep  0.9735 0.974
#> 4 CROSTON(Scripts) 2008 Oct  0.9735 0.974
#> 5 CROSTON(Scripts) 2008 Nov  0.9735 0.974
#> 6 CROSTON(Scripts) 2008 Dec  0.9735 0.974
```

Столбец Scripts (Рецепты) не предоставляет полного распределения, а вместо этого повторяет среднее значение, поскольку не существует базовой стохастической модели.

Модели прогнозирования, которые более непосредственно связаны со счетной природой данных и позволяют прогнозировать распределение, описаны в Кристоу и Фокианос (2015, *https://otexts.com/fpp3/counts.html#ref-christou2015count*).

## Библиография

*Кристоу, В. и Фокианос, К.* (2015). О прогнозировании временных рядов счетных данных. Journal of Statistical Computation and Simulation, 85 (2), 357–373. [DOI: https://doi.org/10.1080/00949655.2013.823612].

*Кростон, Дж. Д.* (1972). Прогнозирование и контроль запасов для прерывистого спроса. Operational Research Quarterly, 23 (3), 289–303. [DOI: https://doi.org/10.2307/3007885].

*Шенстоун, Л. и Хайндман, Р. Дж.* (2005). Стохастические модели в основе метода Кростона для прогнозирования прерывистого спроса. Journal of Forecasting, 24 (6), 389–402. [DOI: https://doi.org/10.1002/for.963].

## 13.3 Обеспечение того, чтобы прогнозы оставались в пределах допустимых значений

Обычно возникает потребность иметь положительные прогнозы либо требуется, чтобы они были в пределах некоторого определенного диапазона [*a*, *b*]. Обе эти ситуации относительно легко поддаются обработке с помощью преобразований.

### Положительные прогнозы

В целях наложения ограничения на положительность можно просто работать в логарифмической шкале. Например, возьмем реальную цену дюжины яиц (1900–1993 гг.; в центах), показанную на рис. 13.4. Вследствие логарифмического преобразования прогнозные распределения вынуждены оставаться положительными, и поэтому они будут становиться все более искаженными по мере уменьшения среднего значения.

```
egg_prices <- prices %>% filter(!is.na(eggs))
egg_prices %>%
  model(ETS(log(eggs) ~ trend("A"))) %>%
  forecast(h = 50) %>%
  autoplot(egg_prices) +
  labs(title = "Годовые цены на яйца",
       y = ""$US (в центах с поправкой на инфляцию)")
```

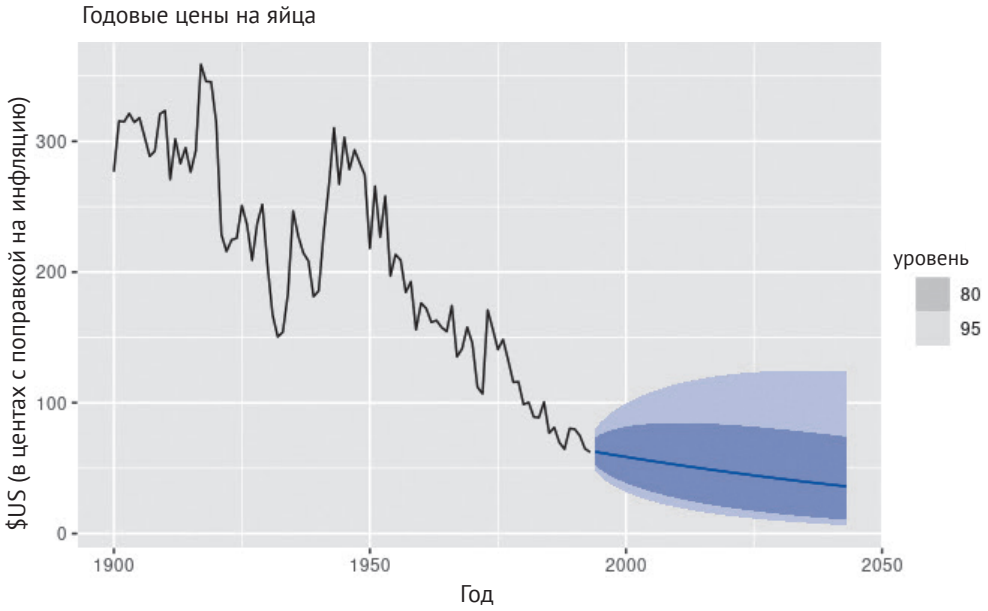


**Рисунок 13.4:** Прогнозы цены дюжины яиц, вынужденные оставаться положительными, с использованием преобразования Бокса–Кокса

## Прогнозы, ограниченные интервалом

В целях понимания того, как обрабатывать данные, ограниченные интервалом, представьте, что цены на яйца были ограничены пределами $a = 50$ и $b = 400$. Тогда можно преобразовать данные, используя масштабированное логит-преобразование, которое отображает $(a, b)$ на всю вещественную ось:

$$y = \log\left(\frac{x-a}{b-x}\right),$$

где $x$ лежит в изначальной шкале, а $y$ – это преобразованные данные. Для того чтобы обратить это преобразование вспять, мы будем использовать

$$x = \frac{(b-a)e^y}{1+e^y} + a.$$

Это не встроенное в R преобразование, поэтому сначала необходимо настроить функции преобразования.

```
scaled_logit <- function(x, lower = 0, upper = 1) {
  log((x - lower) / (upper - x))
}
inv_scaled_logit <- function(x, lower = 0, upper = 1) {
  (upper - lower) * exp(x) / (1 + exp(x)) + lower
}
```

```
my_scaled_logit <- new_transformation(
                    scaled_logit, inv_scaled_logit)
egg_prices %>%
  model(
    ETS(my_scaled_logit(eggs, lower = 50, upper = 400)
          ~ trend("A"))
  ) %>%
  forecast(h = 50) %>%
  autoplot(egg_prices) +
  labs(title = "Годовые цены на яйца",
       y = ""$US (в центах с поправкой на инфляцию)")
```

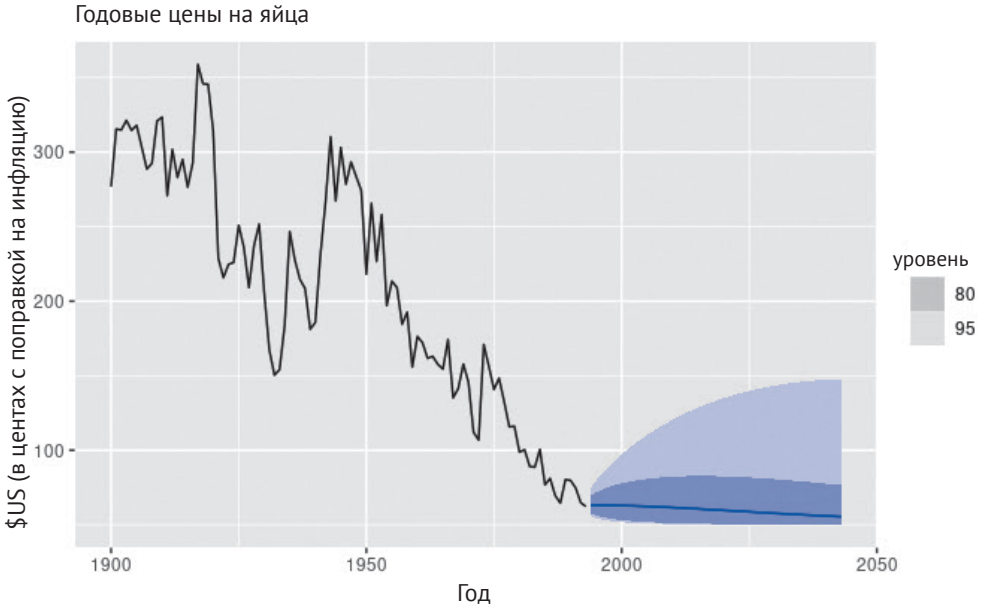


**Рисунок 13.5:** Прогнозы цены дюжины яиц, ограниченные в пределах от 50 до 400 центов США

Здесь автоматически применяется поправка на смещение, и предсказательные интервалы из этих преобразований имеют ту же вероятность покрытия, что и в преобразованной шкале, поскольку при монотонно возрастающих преобразованиях квантили сохраняются.

Вследствие преобразования предсказательные интервалы лежат выше 50. В результате этого искусственного (и нереалистичного) ограничения распределение прогнозов стало чрезвычайно искаженным.

## 13.4 Комбинации прогнозов

Простой способ повысить точность прогноза – применить несколько разных методов для одного и того же временного ряда и усреднить результирующие прогнозы. Более 50 лет назад Джон Бейтс и Клайв Грейнджер написали знаменитую статью (Бейтс и Грейнджер, 1969, *https://otexts.com/fpp3/combinations.html#ref-BatesGranger1969*), в которой показали, что комбинирование прогнозов часто приводит к повышению точности прогноза. Двадцать лет спустя Клемен (1989) отметил:

> Результаты были практически единогласны: комбинирование нескольких прогнозов приводит к повышению точности прогноза. Во многих случаях можно добиваться значительного улучшения результативности, просто усредняя прогнозы.

Несмотря на то что было проведено значительное исследование использования средневзвешенных значений или какого-либо другого более сложного комбинированного подхода, применение простого среднего оказалось труднодостижимым.

Ниже приведен пример, в котором используется ежемесячный доход от продаж продуктов питания навынос в Австралии с апреля 1982 года по декабрь 2018 года. Мы используем прогнозы из следующих моделей: ETS, STL-ETS и ARIMA – и сравниваем результаты, используя последние 5 лет (60 месяцев) наблюдений.

```
auscafe <- aus_retail %>%
  filter(stringr::str_detect(Industry, "Takeaway")) %>%
  summarise(Turnover = sum(Turnover))
train <- auscafe %>%
  filter(year(Month) <= 2013)
STLF <- decomposition_model(
  STL(log(Turnover) ~ season(window = Inf)),
  ETS(season_adjust ~ season("N"))
)
cafe_models <- train %>%
  model(
    ets = ETS(Turnover),
    stlf = STLF,
    arima = ARIMA(log(Turnover))
  ) %>%
  mutate(combination = (ets + stlf + arima) / 3)
cafe_fc <- cafe_models %>%
  forecast(h = "5 years")
```

Обратите внимание, что в функции `mutate()` мы формируем сочетание, просто беря линейную функцию от оцененных моделей. Этот очень простой синтак-

сис будет обрабатывать прогнозное распределение автоматически и надлежащим образом, принимая во внимание корреляцию между прогнозными ошибками моделей, включенных в расчеты. Однако, для того чтобы следующий ниже график оставался простым, мы опустим предсказательные интервалы.

```
cafe_fc %>%
  autoplot(auscafe %>% filter(year(Month) > 2008),
           level = NULL) +
  labs(y = "Млрд $",
       title = "Ежемесячные расходы австралийцев на питание вне дома")
```

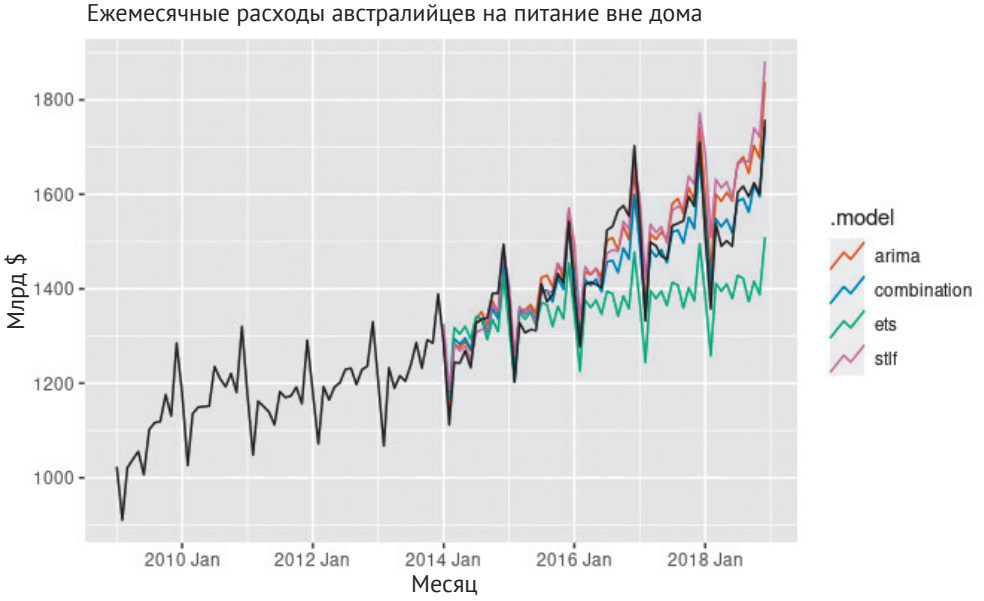


**Рисунок 13.6:** Точечные прогнозы, основанные на различных методах, применяемых к ежемесячным расходам австралийцев на питание вне дома

```
cafe_fc %>%
  accuracy(auscafe) %>%
  arrange(RMSE)
#> # A tibble: 4 × 10
#>   .model      .type     ME  RMSE   MAE    MPE  MAPE  MASE RMSSE  ACF1
#>   <chr>       <chr>  <dbl> <dbl> <dbl>  <dbl> <dbl> <dbl> <dbl> <dbl>
#> 1 combination Test    8.09  41.0  31.8  0.401  2.19 0.776 0.790 0.747
#> 2 arima       Test  -25.4   46.2  38.9 -1.77   2.65 0.949 0.890 0.786
#> 3 stlf        Test  -36.9   64.1  51.7 -2.55   3.54 1.26  1.23  0.775
#> 4 ets         Test   86.5  122.  101.   5.51   6.66 2.46  2.35  0.880
```

Модель ARIMA особенно хорошо справляется с этим рядом, в то время как комбинированный подход работает еще лучше (на основе большинства пока-

зателей, включая RMSE и MAE). Что касается других данных, то ARIMA может давать довольно слабые результаты, в то время как комбинированный подход обычно находится недалеко от лучшего компонентного метода либо лучше.

## Прогнозные распределения комбинаций

Объект `cafe_fc` содержит прогнозные распределения, из которых обычно можно вычислить любой предсказательный интервал. Давайте посмотрим на интервалы для первого периода.

```
cafe_fc %>% filter(Month == min(Month))
#> # A fable: 4 x 4 [1M]
#> # Key:     .model [4]
#>   .model         Month           Turnover .mean
#>   <chr>          <mth>             <dist> <dbl>
#> 1 ets         2014 Jan      N(1289, 1118) 1289.
#> 2 stlf        2014 Jan t(N(7.2, 0.00063)) 1326.
#> 3 arima       2014 Jan t(N(7.2, 0.00061)) 1283.
#> 4 combination 2014 Jan               1299 1299.
```

Первые три представляют собой смесь нормального и преобразованного нормального распределений. Пакет еще не объединяет такие разнообразные распределения, поэтому результатом `combination` является просто среднее значение.

Однако если мы работаем с симулируемыми путями выборки, то можно создавать прогнозные распределения и для комбинированного прогноза.

```
cafe_futures <- cafe_models %>%
  # Сгенерировать 1000 будущих путей выборки
  generate(h = "5 years", times = 1000) %>%
  # Вычислить прогнозные распределения по будущим путям выборки
  as_tibble() %>%
  group_by(Month, .model) %>%
  summarise(
    dist = distributional::dist_sample(list(.sim))
  ) %>%
  ungroup() %>%
  # Создать объект fable
  as_fable(index = Month, key = .model,
           distribution = dist, response = "Turnover")
# Прогнозные распределения для h=1
cafe_futures %>% filter(Month == min(Month))
#> # A fable: 4 x 3 [1M]
#> # Key:     .model [4]
```

```
#>      Month .model              dist
#>      <mth> <chr>              <dist>
#> 1 2014 Jan arima       sample[1000]
#> 2 2014 Jan combination sample[1000]
#> 3 2014 Jan ets         sample[1000]
#> 4 2014 Jan stlf        sample[1000]
```

Теперь все четыре модели, включая комбинацию, сохраняются в виде эмпирических распределений, и можно построить предсказательные интервалы для комбинированного прогноза, как показано на рис. 13.7.

```
cafe_futures %>%
  filter(.model == "combination") %>%
  autoplot(auscafe %>% filter(year(Month) > 2008)) +
  labs(y = "Млрд $",
       title = "Ежемесячные расходы австралийцев на питание вне дома")
```

**Рисунок 13.7:** Предсказательные интервалы для комбинированного прогноза ежемесячных расходов австралийцев на питание вне дома

В целях проверки точности 95%-ных предсказательных интервалов можно использовать бальную оценку Винклера (определенную в разделе 5.9).

```
cafe_futures %>%
  accuracy(auscafe, measures = interval_accuracy_measures,
    level = 95) %>%
  arrange(winkler)
#> # A tibble: 4 × 3
#>   .model      .type winkler
#>   <chr>       <chr>   <dbl>
```

```
#> 1 combination Test     420.
#> 2 stlf        Test     596.
#> 3 ets         Test     731.
#> 4 arima       Test     766.
```

Чем ниже, тем лучше, поэтому комбинированный прогноз снова лучше, чем любая из компонентных моделей.

## Библиография

*Бейтс, Дж. М. и Грейнджер, К. У. Дж.* (1969). Комбинирование прогнозов. Operational Research Quarterly, 20 (4), 451–468. [DOI: https://doi.org/10.1057/jors.1969.103].

*Клемен, Р.* (1989). Комбинирование прогнозов: обзор и аннотированная библиография. International Journal of Forecasting, 5 (4), 559–583. [DOI: https://doi.org/10.1016/0169-2070(89)90012-5].

# 13.5 Предсказательные интервалы для агрегатов

Нередко приходится сталкиваться с задачей прогнозирования агрегатного значения для данных за несколько периодов времени с использованием модели, подогнанной к дезагрегированным данным. Например, у нас могут быть ежемесячные данные, но мы хотим спрогнозировать совокупное значение на следующий год. Или же у нас могут быть еженедельные данные, и мы хотим спрогнозировать совокупное значение на следующие четыре недели.

Если точечные прогнозы представляют собой средние значения, то их сложение даст хорошую оценку совокупного значения. Но с предсказательными интервалами будет посложнее из-за корреляции между прогнозными ошибками.

Общее решение заключается в использовании симуляций. Ниже приведен пример использования моделей ETS применительно к австралийским продажам продуктов питания навынос, предполагая, что мы хотим спрогнозировать совокупный доход в ближайшие 12 месяцев.

```
fit <- auscafe %>%
  # Выполнить подгонку модели к данным
  model(ETS(Turnover))
futures <- fit %>%
  # Просимулировать 10 000 будущих путей выборки, длиной 12 каждый
  generate(times = 10000, h = 12) %>%
  # Просуммировать результаты для каждого пути выборки
  as_tibble() %>%
  group_by(.rep) %>%
  summarise(.sim = sum(.sim)) %>%
  # Сохранить в качестве распределения
  summarise(total = distributional::dist_sample(list(.sim)))
```

Мы можем вычислить среднее значение результатов симуляций, а также предсказательные интервалы:

```
futures %>%
  mutate(
    mean = mean(total),
    pi80 = hilo(total, 80),
    pi95 = hilo(total, 95)
  )
#> # A tibble: 1 × 4
#>           total   mean             pi80             pi95
#>          <dist>  <dbl>           <hilo>           <hilo>
#> 1 sample[10000] 19212. [18330, 20118]80 [17851, 20628]95
```

Как и ожидалось, среднее значение симулированных данных близко к сумме индивидуальных прогнозов.

```
forecast(fit, h = 12) %>%
  as_tibble() %>%
  summarise(total = sum(.mean))
#> # A tibble: 1 × 1
#>    total
#>    <dbl>
#> 1 19212.
```

## 13.6 Ретрополяция

Иногда бывает полезно «откатить» временной ряд назад, то есть спрогнозировать в обратную сторону во времени[1]. Хотя для этого нет встроенных функций R, это легко имплементируется путем создания нового индекса времени.

Предположим, мы хотим продлить наши данные расходов австралийцев на питание вне дома до начала 1981 года (фактические данные начинаются с апреля 1982 года).

```
backcasts <- auscafe %>%
  mutate(reverse_time = rev(row_number())) %>%
  update_tsibble(index = reverse_time) %>%
  model(ets = ETS(Turnover ~ season(period = 12))) %>%
  forecast(h = 15) %>%
  mutate(Month = auscafe$Month[1] - (1:15)) %>%
  as_fable(index = Month, response = "Turnover",
    distribution = "Turnover")
```

[1] Ретрополяция (backcast) – это построение прогноза для прошлого периода на базе трендов и данных ближайшего прошлого или текущего периода. – *Прим. перев.*

```
backcasts %>%
  autoplot(auscafe %>% filter(year(Month) < 1990)) +
  labs(title = "Ретрополяции расходов австралийцев на продовольствие",
       y = "$ (млрд)")
```

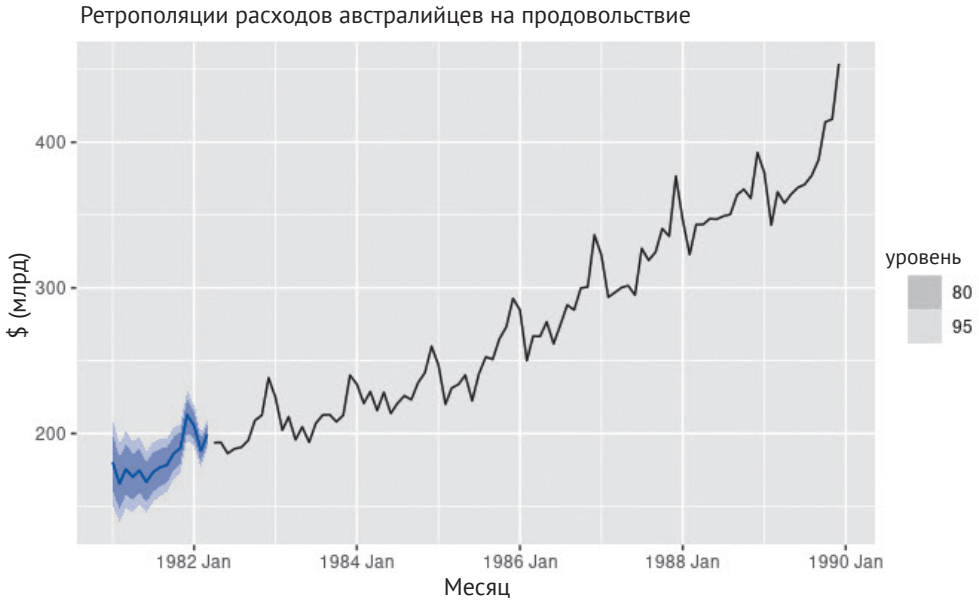


**Рисунок 13.8:** Ретрополяционные прогнозы ежемесячных расходов австралийцев на кафе, рестораны и услуги питания навынос с использованием модели ETS

Бóльшая часть работы здесь заключается в реиндексации объекта `twiddle`, а затем в реиндексации объекта `table`.

## 13.7 Очень длинные и очень короткие временные ряды

### Прогнозирование очень коротких временных рядов

Нас часто спрашивают, какое минимальное число точек данных можно использовать для подгонки модели временного ряда. Как и почти со всеми вопросами о размере выборки, здесь нет простого ответа. Все зависит от числа оцениваемых модельных параметров и степени случайности в данных. Требуемый размер выборки увеличивается с увеличением числа оцениваемых параметров и объема шума в данных.

В некоторых учебниках приводятся эмпирические правила, дающие минимальные размеры выборки для различных моделей временных рядов. Они некорректны и бездоказательны как в теории, так и на практике. Кроме того, они игнорируют лежащую в основе изменчивость данных и часто упускают из виду число подлежащих оцениванию параметров. Например, нет никакого обоснования для магического числа 30, часто приводимого в качестве минимума для моделирования ARIMA. Единственным теоретическим ограничени-

ем является то, что в прогнозной модели необходимо больше наблюдений, чем параметров. Однако на практике нам обычно требуется значительно больше наблюдений, чем это число.

В идеале мы проводим тестирование на предмет того, что выбранная нами модель показывает хорошую результативность вне выборки по сравнению с некоторыми более простыми подходами. Однако при использовании коротких рядов бывает недостаточно данных, чтобы откладывать некоторые наблюдения в сторону для целей тестирования, и даже перекрестная валидация временных рядов бывает затруднена. Критерий AICc особенно здесь полезен, поскольку он является косвенным индикатором для одношаговой прогнозной вневыборочной MSE. Выбор модели с минимальным значением AICc позволяет учитывать как число параметров, так и объем шума.

С короткими рядами обычно происходит то, что AICc предлагает простые модели, потому что все, что содержит более одного или двух параметров, будет продуцировать слабые прогнозы из-за ошибки оценивания. Мы выполним подгонку модели ARIMA к годовому ряду из набора данных M3-competition с менее чем 20 наблюдениями. Сначала необходимо создать объект tsibble, содержащий соответствующие ряды.

```
m3totsibble <- function(z) {
  bind_rows(
    as_tsibble(z$x) %>% mutate(Type = "Training"),
    as_tsibble(z$xx) %>% mutate(Type = "Test")
  ) %>%
    mutate(
      st = z$st,
      type = z$type,
      period = z$period,
      description = z$description,
      sn = z$sn,
    ) %>%
    as_tibble()
}
short <- Mcomp::M3 %>%
  subset("yearly") %>%
  purrr::map_dfr(m3totsibble) %>%
  group_by(sn) %>%
  mutate(n = max(row_number())) %>%
  filter(n <= 20) %>%
  ungroup() %>%
  as_tsibble(index = index, key = c(sn, period, st))
```

Теперь можно применить модель ARIMA к каждому ряду.

```
short_fit <- short %>%
  model(arima = ARIMA(value))
```

Из 152 рядов 21 имел модели с нулевыми параметрами (белый шум и случайные блуждания), 86 имели модели с одним параметром, 31 – модели с двумя параметрами, 13 – модели с тремя параметрами и только 1 ряд имел четыре параметра.

### Прогнозирование очень длинных временных рядов

Большинство моделей временных рядов плохо работают на очень длинных временных рядах. Проблема в том, что реальные данные поступают не из моделей, которые мы используем. Когда число наблюдений невелико (скажем, примерно до 200), модели часто хорошо работают в качестве аппроксимации любого процесса, сгенерировавшего данные. Но в конце концов у нас будет достаточно данных, чтобы разница между истинным процессом и моделью стала более очевидной. Дополнительная проблема заключается в том, что из-за большого числа наблюдений оптимизация параметров становится более трудоемкой.

Что делать с этими проблемами, зависит от предназначения модели. Можно было бы использовать более гибкую и сложную модель, но это все равно предполагает, что структура модели будет работать в течение всего периода данных. Более оптимальный подход обычно заключается в том, чтобы позволить самой модели изменяться с течением времени. Модели ETS разработаны для решения этой ситуации, позволяя тренду и сезонным условиям изменяться с течением времени. Модели ARIMA с дифференцированием обладают аналогичным свойством. Но динамические регрессионные модели не допускают никакой эволюции модельных компонент.

Если мы заинтересованы в прогнозировании только следующих нескольких наблюдений, то один простой подход состоит в том, чтобы отбросить самые ранние наблюдения и подогнать модель только к самым последним наблюдениям. Тогда негибкая модель сможет заработать хорошо, потому что будет не хватать времени, для того чтобы взаимосвязи существенно изменились.

Например, в разделе 13.1 мы применили модель динамической гармонической регрессии к 26 годам еженедельного производства бензина. Очевидно, было бы нереалистично предполагать, что сезонная закономерность останется неизменной на протяжении почти трех десятилетий. И стало быть, вместо этого мы могли бы просто выполнить подгонку модели к самым последним годам.

## 13.8 Прогнозирование на тренировочном и тестовом наборах

В типичной ситуации одношаговые прогнозы вычисляются на тренировочных данных («подогнанных значениях») и многошаговые прогнозы – на тестовых данных. Однако иногда возникает потребность вычислить многошаговые прогнозы на тренировочных данных или одношаговые прогнозы на тестовых данных.

## Многошаговые прогнозы на тренировочных данных

Обычно подогнанные значения определяются как одношаговые прогнозы на тренировочном наборе (см. раздел 5.3), но аналогичная идея может использоваться для многошаговых прогнозов. Мы проиллюстрируем этот метод с использованием модели ARIMA для расходов австралийцев на питание вне дома. Для тестового набора используются данные за последние пять лет, а прогнозы представлены на рис. 13.9.

```
training <- auscafe %>% filter(year(Month) <= 2013)
test <- auscafe %>% filter(year(Month) > 2013)
cafe_fit <- training %>%
  model(ARIMA(log(Turnover)))
cafe_fit %>%
  forecast(h = 60) %>%
  autoplot(auscafe) +
  labs(title = "Расходы австралийцев на продовольствие",
       y = "$ (млрд)")
```

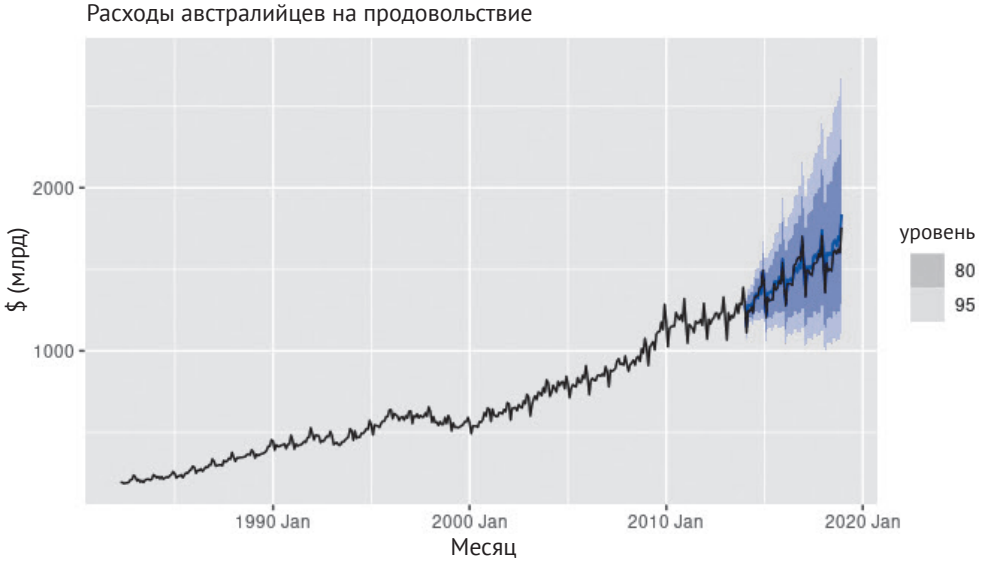


**Рисунок 13.9:** Прогнозы по модели ARIMA, подогнанной к ежемесячным расходам австралийцев на кафе, рестораны и услуги по доставке продуктов питания навынос

Функция `fitted()` имеет аргумент `h`, допускающий наличие $h$-шаговых «подогнанных значений» в тренировочном наборе. Рисунок 13.10 представляет собой график 12-шаговых (одногодичных) прогнозов на тренировочном наборе. Поскольку модель предусматривает как сезонное (с лагом 12), так и первое (с лагом 1) дифференцирование, вычислить эти прогнозы для первых нескольких наблюдений невозможно.

```
fits12 <- fitted(cafe_fit, h = 12)
```

```
training %>%
  autoplot(Turnover) +
  autolayer(fits12, .fitted, col = "#D55E00") +
  labs(title = "Расходы австралийцев на продовольствие",
       y = "$ (млрд)")
```

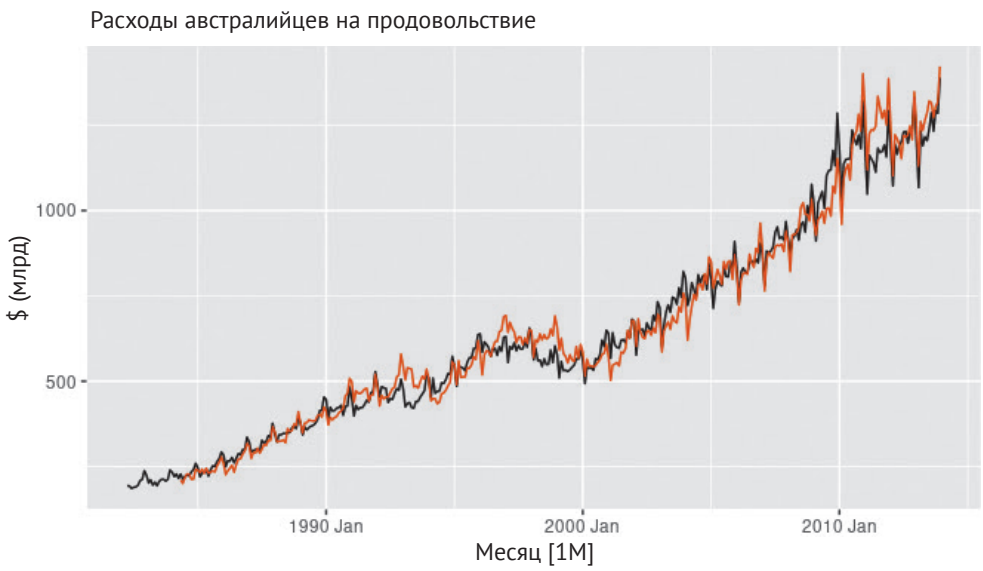


**Рисунок 13.10:** 12-шаговые подогнанные значения из модели ARIMA, подогнанной к тренировочным данным Australian café

## Одношаговые прогнозы на тестовых данных

На практике общепринято выполнять подгонку модели с использованием тренировочных данных, а затем оценивать ее результативность на тестовом наборе данных. То, как это обычно делается, означает, что для сравнения тестовых данных используются разные прогнозные горизонты. В приведенном выше примере мы применяли последние шестьдесят наблюдений для тестовых данных и оценили нашу прогнозную модель на тренировочных данных. Тогда прогнозные ошибки будут относиться к 1 шагу, 2 шагам, ..., 60 шагам вперед. Прогнозная дисперсия обычно увеличивается с увеличением прогнозного горизонта, поэтому если просто усреднять абсолютные или квадратичные ошибки из тестового набора, то результаты комбинируются с разными дисперсиями.

Одним из решений этой проблемы является получение 1-шаговых ошибок на тестовых данных. То есть мы по-прежнему используем тренировочные данные для оценивания любых параметров, но, когда мы вычисляем прогнозы на тестовых данных, мы используем все данные, предшествующие каждому наблюдению (как тренировочные, так и тестовые данные). Таким образом, наши тренировочные данные относятся к временам 1, 2, ..., $T - 60$. Мы оцениваем модель на этих данных, но затем вычисляем $\hat{y}_{T-60+h|T-61+h}$ для $h = 1, \ldots, T - 1$. По-

скольку для оценивания параметров тестовые данные не используются, это по-прежнему дает нам «объективный» прогноз.

Используя ту же модель ARIMA, что и выше, теперь мы применим эту модель к тестовым данным.

```
cafe_fit %>%
  refit(test) %>%
  accuracy()
#> # A tibble: 1 × 10
#>   .model              .type    ME  RMSE   MAE    MPE  MAPE  MASE RMSSE
ACF1
#>   <chr>               <chr> <dbl> <dbl> <dbl>  <dbl> <dbl> <dbl> <dbl>
<dbl>
#> 1 ARIMA(log(Turnover… Trai… -2.49  20.5  15.4 -0.169  1.06 0.236 0.259
-0.0502
```

Обратите внимание, что в этом случае модель не переоценивается. Вместо этого к тестовым данным применяется модель, полученная ранее (и сохраненная как `cafe_fit`). Поскольку модель не подвергалась переоценке, полученные здесь «остатки» на самом деле являются ошибками одношагового прогноза. Следовательно, результаты, полученные с помощью команды `accuracy()`, фактически взяты на тестовом наборе (несмотря на то что в выходных данных указано «Тренировочный набор»). Этот подход может использоваться для сравнения одношаговых прогнозов из разных моделей.

## 13.9 Работа с выбросами и пропущенными значениями

В реальных данных нередко пропущены значения, они могут содержать выбросные наблюдения и другие беспорядочные признаки. И работать с ними иногда бывает непросто.

### Выбросы

Выбросы – это наблюдения, которые сильно отличаются от большинства наблюдений во временных рядах. Они могут быть ошибками или просто необычными. (См. раздел 7.3 с обсуждением выбросов в контексте регрессии.) Ни один из методов, которые мы рассматривали в этой книге, не будет работать хорошо, если в данных имеются экстремальные выбросы. В этом случае мы, возможно, захотим заменить их пропущенными значениями или оценкой, которая более согласуется с большинством данных.

Практика простой замены выбросов, не задумываясь о том, почему они произошли, чревата опасными последствиями. Они могут предоставлять полезную информацию о процессе, сгенерировавшем данные, которые следует учитывать при прогнозировании. Однако если мы готовы предположить, что выбросы действительно являются ошибками или что они не произойдут в прогнозный период, то их замена может облегчить задачу прогнозирования.

На рис. 13.11 показано число посетителей региона Аделаида-Хиллз в Южной Австралии. В четвертом квартале 2002 года, по-видимому, произошло необычное наблюдение.

```
tourism %>%
  filter(
    Region == "Adelaide Hills", Purpose == "Visiting"
  ) %>%
  autoplot(Trips) +
  labs(title = "Ежеквартальные поездки с ночевкой в Аделаида-Хиллз",
       y = "Число поездок")
```

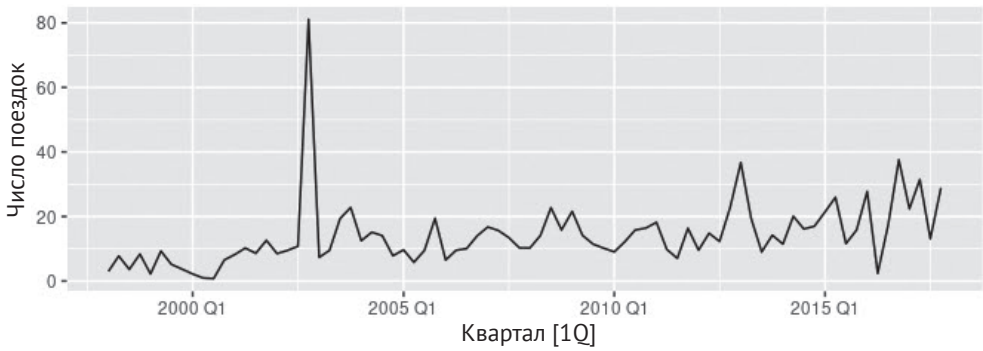


**Рисунок 13.11:** Число поездок с ночевкой в регион Аделаида-Хиллз в Южной Австралии

Один из полезных способов обнаружения выбросов заключается в применении `STL()` к ряду с аргументом `robust=TRUE`. Тогда в оставшемся ряду должны появиться любые выбросы. Данные на рис. 13.11 почти не имеют видимой сезонности, поэтому мы применим STL без сезонной составляющей, установив `period=1`.

```
ah_decomp <- tourism %>%
  filter(
    Region == "Adelaide Hills", Purpose == "Visiting"
  ) %>%
  # Выполнить подгонку несезонного STL-разложения
  model(
    stl = STL(Trips ~ season(period = 1), robust = TRUE)
  ) %>%
  components()

ah_decomp %>% autoplot()
```

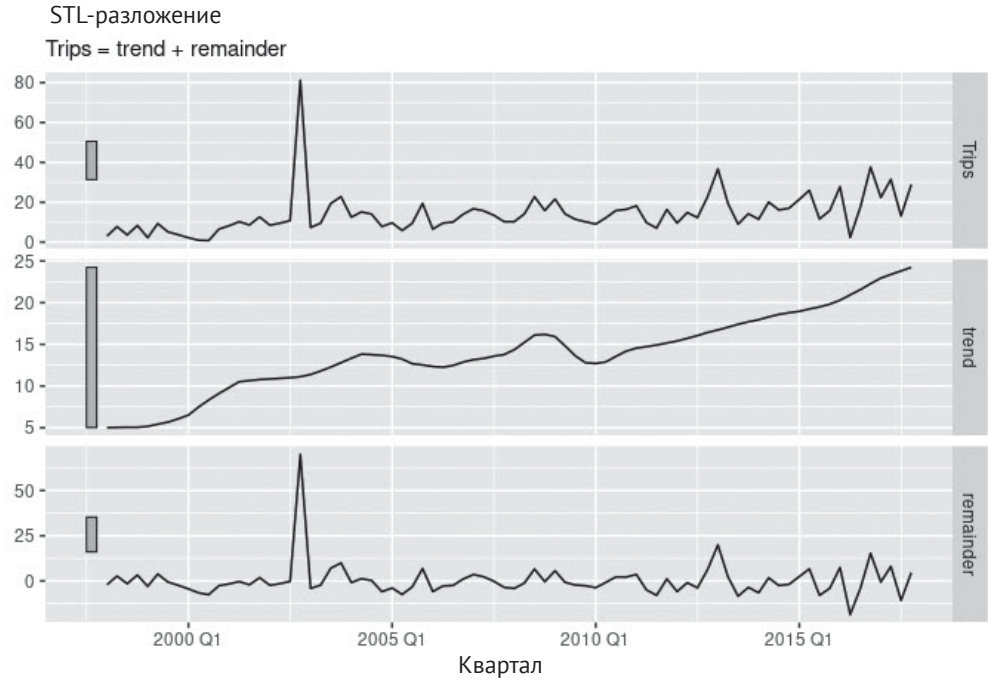


**Рисунок 13.12:** STL-разложение посетителей региона Аделаида-Хиллз в Южной Австралии, без сезонной составляющей

В приведенном выше примере выброс было легко идентифицировать. В более сложных случаях было бы полезно использовать коробчатую диаграмму оставшегося ряда. Выбросы можно трактовать как те, которые превышают 1.5 межквартильного размаха (IQR) от центральных 50 % данных. Если бы остаток был распределен нормально, то это показало бы, что 7 из каждой 1000 наблюдений являются «выбросами». Более строгое правило трактует выбросы как те, которые превышают 3 межквартильных размаха (IQR) от центральных 50 % данных, в результате чего только 1 из 500 000 нормально распределенных наблюдений является выбросом. Это именно то правило, которое мы предпочитаем использовать.

```
outliers <- ah_decomp %>%
  filter(
    remainder < quantile(remainder, 0.25) - 3*IQR(remainder) |
    remainder > quantile(remainder, 0.75) + 3*IQR(remainder)
  )
outliers
#> # A dable: 1 x 9 [1Q]
#> # Key:     Region, State, Purpose, .model [1]
#> # :        Trips = trend + remainder
#>   Region      State Purpose .model Quarter Trips trend remainder season_ad-
```

```
just
#>   <chr>       <chr> <chr>   <chr>    <qtr> <dbl> <dbl>     <dbl>
<dbl>
#> 1 Adelaide H… Sout… Visiti… stl    2002 Q4  81.1  11.1      70.0
81.1
```

Это позволяет обнаружить один выброс, который мы заподозрили на рис. 13.11. Нечто подобное можно было бы применить к полному набору данных с целью выявления необычных наблюдений в других рядах.

## Пропущенные значения

Пропущенные данные могут возникать по многим причинам, и стоит подумать о том, приведет ли их пропущенность к смещению в прогнозной модели. Например, предположим, что мы изучаем данные продаж магазина, и пропущенные значения возникают в праздничные дни, когда магазин закрыт. В результате на следующий день продажи могут увеличиться. Если мы не учтем это в нашей прогнозной модели, то мы, скорее всего, недооценим продажи в первый день после национальных праздников, но переоценим продажи в последующие дни. Справиться с подобной ситуацией можно путем применения модели динамической регрессии с фиктивными переменными, указывающими, является ли конкретный день национальным праздником или днем после национального праздника. Ни один автоматизированный метод не способен справиться с такими эффектами, поскольку они зависят от конкретного контекста прогнозирования.

В других ситуациях пропущенность может быть по существу случайной. Например, кто-то, возможно, забыл зарегистрировать данные продаж, или устройство записи данных могло выйти из строя. Если время пропущенных данных не является информативным для задачи прогнозирования, то пропущенные значения обрабатываются проще.

Наконец, мы могли бы удалить некоторые необычные наблюдения, создав таким образом пропущенные значения в ряду.

Некоторые методы допускают пропущенные значения без каких-либо проблем. Например, метод наивного прогнозирования продолжает работать, при этом самое последнее непропущенное значение обеспечивает прогноз для будущих периодов времени. Все другие эталонные методы, представленные в разделе 5.2, будут давать прогнозы аналогичным образом, когда в исторических данных есть пропуски значений. Функции пакета fable для моделей ARIMA, моделей динамической регрессии и моделей NNAR также будут работать правильно, не вызывая ошибок. Однако другие функции моделирования пропущенные значения не обрабатывают, включая `ETS()` и `STL()`.

Когда пропущенные значения приводят к ошибкам, существует по крайней мере два способа решения проблемы. Во-первых, можно просто взять раздел данных после последнего пропущенного значения, базируясь на том, что существует достаточно длинный ряд наблюдений для получения содержательных прогнозов. В качестве альтернативы можно заменить пропущенные значения оценками. Для этого мы сначала выполняем подгонку модели ARIMA

к данным, в которых есть пропуски значений, а затем используем модель для интерполяции пропущенных наблюдений.

Мы заменим выброс, указанный на рис. 13.12, оценкой с использованием модели ARIMA.

```
ah_miss <- tourism %>%
  filter(
    Region == "Adelaide Hills",
    Purpose == "Visiting"
  ) %>%
  # Удалить выбросные наблюдения
  anti_join(outliers) %>%
  # Заменить пропущенными значениями
  fill_gaps()
ah_fill <- ah_miss %>%
  # Выполнить подгонку модели ARIMA к данным с пропущенными значениями
  model(ARIMA(Trips)) %>%
  # Оценить поездки для всех периодов
  interpolate(ah_miss)
ah_fill %>%
  # Показать только выбросные периоды
  right_join(outliers %>% select(-Trips))
#> # A tsibble: 1 x 9 [?]
#> # Key:       Region, State, Purpose [1]
#>   Region      State Purpose Quarter Trips .model trend remainder season_ad-
just
#>   <chr>       <chr> <chr>     <qtr> <dbl> <chr>  <dbl>     <dbl>
<dbl>
#> 1 Adelaide H… Sout… Visiti… 2002 Q4  8.50 stl     11.1      70.0
81.1
```

Функция `interpolate()` использует модель ARIMA для оценки любых пропущенных значений в ряду. В этом случае выброс 81.1 был заменен на 8.5. Результирующий ряд показан на рис. 13.13.

Данные `ah_fill` теперь можно смоделировать с помощью функции, которая не допускает пропущенных значений.

```
ah_fill %>%
  autoplot(Trips) +
  autolayer(ah_fill %>% filter_index("2002 Q3"~"2003 Q1"),
    Trips, colour="#D55E00") +
  labs(title = "Ежеквартальные поездки с ночевкой в Аделаида-Хиллз",
       y = "Число посещений")
```

**Рисунок 13.13:** Число посещений с ночевкой в регион Аделаида-Хиллз в Южной Австралии с заменой выбросов в 4-м квартале 2002 года с использованием модели ARIMA для интерполяции

## 13.10 Дальнейшее чтение

В этой главе обсуждается так много разнообразных тем, что невозможно указать конкретные ссылки на все из них. В последней главе книги Орда и соавт. (2017, *https://otexts.com/fpp3/further-reading-1.html#ref-Ord2017*) также рассматривается «Прогнозирование на практике» и обсуждаются другие вопросы, которые могут представлять интерес для читателей.

### Библиография

*Орд, Дж. К., Филдес, Р. и Курентзес, Н.* (2017). Принципы бизнес-прогнозирования (2-е изд.). Wessex Press Publishing Co. [Amazon, *http://buy.geni.us/Proxy.ashx?TSID=140570&GR_URL=http%3A%2F%2Fwww.amazon.com%2Fdp%2F0999064916*].

# Приложение A

# Использование языка R

В этой книге используется язык R, и она предназначена для применения с языком R. Язык R бесплатен, доступен практически в любой операционной системе, и имеются тысячи дополнительных пакетов, позволяющих делать практически все, что вы когда-либо захотите. Мы рекомендуем вам использовать R с RStudio.

## Инсталлирование R и RStudio

Скачать и инсталлировать R (*https://cran.r-project.org/*).

Скачать и инсталлировать RStudio (*https://bit.ly/rstudiodownload*).

Запустить RStudio. На вкладке **Пакеты** (Packages) нажать **Инсталлировать** (Install) и инсталлировать пакет fpp3 (убедитесь, что установлен флажок **инсталлировать зависимости** (install dependencies)).

Вот и все! Теперь вы должны быть готовы к работе.

## Примеры на R в этой книге

Мы предоставляем исходный код на R для большинства примеров в затененных полях, подобных приведенному ниже:

```
# Загрузить необходимые пакеты
library(fpp3)

# Нанести на график один временной ряд
aus_retail %>%
  filter(`Series ID`=="A3349640L") %>%
  autoplot(Turnover)

# Произвести несколько прогнозов
aus_retail %>%
  filter(`Series ID`=="A3349640L") %>%
  model(ETS(Turnover)) %>%
  forecast(h = "2 years")
```

В этих примерах мы исходим из того, что у вас загружен пакет `fpp3`, как показано выше. Это необходимо делать в начале каждого сеанса R, но это не будет включено в наши примеры.

Иногда мы исходим из того, что исходный код R, который появляется ранее в той же главе книги, также был запущен; поэтому лучше всего работать с исходным кодом R в порядке, указанном в каждой главе.

## Начало работы с R

Если вы никогда ранее не использовали R, то, пожалуйста, ознакомьтесь с первым разделом (главы 1–8) книги Гаррета Гролемунда и Хэдли Уикхема «R для науки для данных» (R for Data Science, *https://r4ds.had.co.nz/*). Хотя она и не касается временных рядов или прогнозирования, она поможет вам привыкнуть к основам языка R и пакетам tidyverse. Также настоятельно рекомендуется пройти курс программирования Coursera по R (*https://www.coursera.org/learn/r-programming*).

Вы узнаете, как использовать R для прогнозирования, выполняя упражнения из этой книги.

# Приложение B

# Для преподавателей

## Решения упражнений

Решения упражнений защищены паролем и доступны только преподавателям. Пожалуйста, заполните соответствующую форму запроса. Вам нужно будет предоставить доказательства того, что вы являетесь преподавателем, а не студентом (например, ссылку на веб-сайт университета, на котором вы указаны в качестве преподавателя). Пожалуйста, также укажите в форме адрес электронной почты вашего университета.

Глава 1 Rmd (*https://otexts.com/fpp3/solutions/Chapter1.Rmd) html (https://otexts.com/fpp3/solutions/Chapter1.html*).

Глава 2 Rmd (*https://otexts.com/fpp3/solutions/Chapter2.Rmd) html (https://otexts.com/fpp3/solutions/Chapter2.html*).

Глава 3 Rmd (*https://otexts.com/fpp3/solutions/Chapter3.Rmd) html (https://otexts.com/fpp3/solutions/Chapter3.html*).

Глава 4 Rmd (*https://otexts.com/fpp3/solutions/Chapter4.Rmd) html (https://otexts.com/fpp3/solutions/Chapter4.html*)

Глава 5 Rmd (*https://otexts.com/fpp3/solutions/Chapter5.Rmd) html (https://otexts.com/fpp3/solutions/Chapter5.html*).

Глава 7 Rmd (*https://otexts.com/fpp3/solutions/Chapter7.Rmd) html (https://otexts.com/fpp3/solutions/Chapter7.html*)

Глава 8 Rmd (*https://otexts.com/fpp3/solutions/Chapter8.Rmd) html (https://otexts.com/fpp3/solutions/Chapter8.html*).

Глава 9 Rmd (*https://otexts.com/fpp3/solutions/Chapter9.Rmd) html (https://otexts.com/fpp3/solutions/Chapter9.html*).

Глава 10 Rmd (*https://otexts.com/fpp3/solutions/Chapter10.Rmd) html (https://otexts.com/fpp3/solutions/Chapter10.html*)

Глава 11 Rmd (*https://otexts.com/fpp3/solutions/Chapter11.Rmd) html (https://otexts.com/fpp3/solutions/Chapter11.html*).

Глава 12 Rmd (*https://otexts.com/fpp3/solutions/Chapter12.Rmd) html (https://otexts.com/fpp3/solutions/Chapter12.html*).

## Слайды

Слайды Роба Хайндмана для курса на основе этой книги доступны на GitHub (*https://github.com/robjhyndman/ETC3550Slides/releases/tag/2022*). Вы можете использовать и адаптировать эти слайды для своих собственных целей. Вам, по меньшей мере, нужно будет удалить логотип Университета Монаш. Если вы обнаружите ошибку, то, пожалуйста, сообщите нам об этом (*https://github.com/robjhyndman/ETC3550Slides/issues*).

# Приложение C

# Рецензии и отзывы

Рецензии из Amazon (*http://www.amazon.com/Forecasting-principles-practice-Rob-Hyndman/product-reviews/0987507109/?tag=otexts-21*).

Рецензия Сандро Сайтты в Swiss Analytics, апрель 2015 г., стр. 5. Переиздана в Data Mining Research (*https://otexts.com/fpp2/extrafiles/SwissAnalytics201501.pdf*).

Рецензия Стива Миллера по управлению информацией, апрель 2015 г. (*https://web.archive.org/web/20200220174633/https://www.information-management.com/opinion/business-analytics-and-forecasting-revisited*).

Рецензия Стефана Колассы в журнале Foresight, осень 2010 года. (*https://otexts.com/fpp3/extrafiles/Kolassa-review.pdf*)

## Отзывы коллег-преподавателей

Добавлено в августе 2020 года

«Эта книга является важным ресурсом как для студентов, так и для практиков. В ней по-новому рассматриваются важные концепции временных рядов и прогнозирования. Иллюстрация теоретических концепций на R бесценна: она не только помогает читателям получать практический опыт, но и делает изучение материала увлекательнее. Мне понравилось преподавать по этой книге, а моим ученикам понравились занятия!»

«Этот текст дает прекрасный обзор методов временных рядов для практикующего специалиста. И действительно, это отличная книга для обучения по программам MBA и MSBA основам использования моделей временных рядов, которые были факультативными занятиями в обеих программах. Примеры легко отслеживаются, а R-скрипты работают хорошо и эффективны. Объяснение методов является ясным и кратким. Я уверен, что это помогло мне выиграть награду за преподавание!»

«Я преподаю финансовую эконометрию уже более 10 лет, и книга “Прогонзирование: принципы и практика” – одна из лучших прикладных книг, с которыми я сталкивался. В ней содержится основательное введение в прогнозирование временных рядов, охватывающее статистические принципы с помощью последовательных процессов “обучения на практике” на языке R. Отзывы бывших студентов свидетельствуют о том, что эта книга всегда является для них полезным справочником, когда они начинают свою карьеру в области анализа данных и финансового прогнозирования. Наконец, авторы очень доступны и предоставили фантастическую помощь и рекомендации по обучению прогнозированию временных рядов».

«Текст является отличным ресурсом, поскольку он предоставляет практический подход к обучению прогнозированию. Я бы хотел, чтобы больше текстов соответствовало этому формату и философии».

«Это отличный онлайновый учебник. Я использовал несколько разделов для своего собственного курса, который знакомит с методами прогнозирования временных рядов в области энергетики, и я нашел материал, включая примеры и упражнения, чрезвычайно полезным. Спасибо вам за огромные усилия по составлению этого ресурса!»

«Эта книга дает студентам с небольшими знаниями в области математики или статистики понимание методов прогнозирования благодаря доступному, хорошо написанному и ориентированному на практику изложению. Эта книга обязательна для моих студентов, получающих степень магистра делового администрирования».

«Я использую этот учебник для краткого практикума по прогнозированию для практиков, и структура книги – обзор тем, сопровождаемый примерами на языке R, действительно помогает моим студентам хорошо понимать концепции. Очень рекомендую».

«После того как я сам познакомился с миром прогнозирования в студенческие годы с помощью книги “Прогнозирование: методы и приложения” (Макридакис, Уилрайт и Хайндман, 1998), я использую ее преемника “Принципы и практика прогнозирования” Роба Хайндмана и Джорджа Атанасопулоса для магистрантов в области бизнес-инженерии и бизнес-администрирования уже много лет. Это очень доступная книга, которой довольно легко пользоваться благодаря ее онлайновому формату, и она всегда обновляется. Студенты очень ценят плавное переплетение теории, множество примеров и приложений на R. Книга идеально подходит для того, чтобы познакомить студентов с наиболее важными методами прогнозирования на интересных примерах, соблюдая здоровый баланс между теоретической глубиной и соответствующими приложениями».

«Я выбрал ее в качестве обязательного учебника для курса бизнес-прогнозирования, который является основным курсом для магистров информационных технологий и аналитики в нашей бизнес-школе. Отличная книга, ИМХО».

«В книге рассматриваются основные инструменты прогнозирования, такие как экспоненциальное сглаживание, и более сложные методы прогнозирования. Все с практическими примерами на R, так что студенты после курса хорошо подготовлены к будущему в области практического прогнозирования. Книга также очень хорошо воспринимается студентами».

«Эта книга – большая поддержка для студентов и преподавателей. С ее акцентом на прогнозировании и практическом применении на R, она незаменима для студентов-бизнесменов в нашем университете. А интеграция с tidyverse высоко ценится. Спасибо Вам!»

## Отзывы практикующих специалистов и студентов

Практикующий специалист, август 2020 года

«Книга позволяет такому человеку, как я, абсолютному новичку в прогнозировании, учиться, обретать уверенность и практиковать навыки, которые не только ценны, но и очень интересны. Что касается прогнозирования, я не

уверен, где бы я был без этого замечательного ресурса, доступного для общественности».

ETC3550, студент прикладного прогнозирования, 1-й семестр 2020 года

«Прогнозирование: принципы и практика» стала приятным сюрпризом с самого начала. Очень редко можно получить такое обильное количество информации, доступной бесплатно в университетской среде. Предоставление таким студентам, как я, бесплатного доступа – это то, что побуждает людей читать и узнавать больше об этом предмете. Кроме того, простой в использовании онлайновый формат сделал этот учебник одним из (если не самым) доступных университетских учебников, которые я когда-либо читал. Более того, практичность и практический подход с прямыми примерами (и реальными данными) подкрепляют концепции приятным способом. Возможность показать применение того, что вы изучаете, побудила меня углубиться в изучение и развить любознательное отношение к каждой теме. Я также оценил лаконичный характер, который позволил мне читать, не чувствуя себя перегруженным или измученным. В целом это фантастический ресурс для тех, у кого есть хоть малейший интерес к прогнозированию и науке о данных.

ETF3231, студент курса бизнес-прогнозирования, 1-й семестр 2020 года

«Учебник, используемый в курсе бизнес-прогнозирования, представляет собой онлайновую книгу, которая содержит все материалы, рассматриваемые на занятиях. Содержание курса основано на слайдах, но книга является хорошей дополнительной поддержкой. Для меня было очень полезно иметь возможность повторить некоторые моменты, которые я менее понял во время лекции. Кроме того, книга очень хорошо построена, а содержание прекрасно взаимодействует с практическими примерами, как видно из курса, что сделало мое изучение очень плавным. Наконец, упражнения, выполняемые во время занятий, взяты из учебника. Я бы порекомендовал всем ознакомиться с книгой, чтобы освоить более сложныеи моменты материала!»

# Библиография


1. *Айзенман, А. Дж.* (2008). Современные методы многомерной статистики: регрессия, классификация и множественное обучение. Springer. [Amazon, *http://buy.geni.us/Proxy.ashx?TSID=140570&GR_URL=http%3A%2F%2Fwww.amazon.com%2Fdp%2F0387781889*].
2. *Анвин, А.* (2015). Графический анализ данных с K. Chapman; Hall/CRC. [Amazon, *http://buy.geni.us/Proxy.ashx?TSID=140570&GR_URL=http%3A%2F%2Fwww.amazon.com%2Fdp%2F1498715230*].
3. *Армстронг, Дж. С.* (1978). Долгосрочное прогнозирование: От хрустального шара до компьютера. John Wiley & Sons. [Amazon, *http://buy.geni.us/Proxy.ashx?TSID=140570&GR_URL=http%3A%2F%2Fwww.amazon.com%2Fdp%2F0471030023*].
4. *Армстронг, Дж. С.* (ред.). (2001). Принципы прогнозирования: руководство для исследователей и практиков. Kluwer Academic Publishers. [Amazon, *http://buy.geni.us/Proxy.ashx?TSID=140570&GR_URL=http%3A%2F%2Fwww.amazon.com%2Fdp%2F0792379306*].
5. *Атанасопулос, Г. и Хайндман, Р. Дж.* (2008). Моделирование и прогнозирование внутреннего туризма Австралии. Tourism Management, 29 (1), 19–31. [DOI: https://doi.org/10.1016/j.tourman.2007.04.009].
6. *Атанасопулос, Дж., Ахмед, Р. А. и Хайндман, Р. Дж.* (2009). Иерархические прогнозы для внутреннего туризма Австралии. International Journal of Forecasting, 25, 146–166. [DOI: https://doi.org/10.1016/j.ijforecast.2008.07.004].
7. *Атанасопулос, Дж., Поскитт, Д. С. и Вахид, Ф.* (2012). Две канонические формы VAR: скалярные компонентные модели по отношению к эшелонной форме. Econometric Reviews, 31 (1), 60–83. [DOI: https://doi.org/10.1080/07474938.2011.607088].
8. *Атанасопулос, Дж., Хайндман, Р. Дж., Куренцес, Н. и Петропулос, Ф.* (2017). Прогнозирование с использованием временных иерархий. European Journal of Operational Research, 262 (1), 60–74. [DOI: https://doi.org/10.1016/j.ejor.2017.02.046].
9. *Атанасопулос, Джордж, Гамакумара, П., Панайотелис, А., Хайндман, Р. Дж. и Аффан, М.* (2020). Иерархическое прогнозирование. В кн.: *Фулеки П.* (ред.) Макроэкономическое прогнозирование в эпоху больших данных (стр. 689–719). Springer. [DOI: https://doi.org/10.1007/978-3-030-31150-6_21].
10. *Бейтс, Дж. М. и Грейнджер, К. У. Дж.* (1969). Комбинирование прогнозов. Operational Research Quarterly, 20 (4), 451–468. [DOI: https://doi.org/10.1057/jors.1969.103].
11. *Бергмейр, К., Хайндман, Р. Дж. и Ку, Б.* (2018). Примечание о валидности перекрестной валидации для оценивания авторегрессионных предска-

заний для временных рядов. Computational Statistics and Data Analysis, 120, 70–83. [DOI: https://doi.org/10.1016/j.csda.2017.11.003].
12. *Бергнер, К., Хайндман, Р. Дж. и Бенитес, Дж. М.* (2016). Бутстрап-агрегирование методов экспоненциального сглаживания с использованием STL-разложения и преобразования Бокса–Кокса. International Journal of Forecasting, 32 (2), 303–312. [DOI: https://doi.org/10.1016/j.ijforecast.2015.07.002].
13. *Бикель, П. Дж., и Доксам, К. А.* (1981). Ревизия анализа преобразований. Journal of the American Statistical Association, 76 (374), 296–311. [DOI: https://doi.org/10.1080/01621459.1981.10477649].
14. *Бокс, Дж. Е. П. и Дженкинс, Дж. М.* (1970). Анализ временных рядов: прогнозирование и контроль. Holden-Day.
15. *Бокс, Дж. Е. П. и Кокс, Д. Р.* (1964). Анализ преобразований. Journal of the Royal Statistical Society. Series B, Statistical Methodology, 26 (2), 211–252. [DOI: https://doi.org/10.1111/j.2517-6161.1964.tb00553.x].
16. *Бокс, Дж. Е. П., Дженкинс, Дж. М., Райнсел, Дж. К. и Льюнг, Дж. М.* (2015). Анализ временных рядов: прогнозирование и контроль (5-е изд.). John Wiley & Sons. [Amazon, *http://buy.geni.us/Proxy.ashx?TSID=140570&GR_URL=http%3A%2F%2Fwww.amazon.com%2Fdp%2F1118675029*].
17. *Браун, Р. Г.* (1959). Статистическое прогнозирование для управления запасами. McGraw/Hill.
18. *Броквелл, П. Дж. и Дэвис, Р. А.* (2016). Введение во временные ряды и прогнозирование (3-е изд.). Springer. [Amazon, *http://buy.geni.us/Proxy.ashx?TSID=140570&GR_URL=http%3A%2F%2Fwww.amazon.com%2Fdp%2F3319298526*].
19. *Бюлер Р., Мессервей Д. и Гриффин Д.* (2005). Совместное планирование и прогнозирование: влияет ли групповое обсуждение на оптимистические отклонения в оценивании времени? Organizational Behavior and Human Decision Processes, 97 (1), 47–63. [DOI: https://doi.org/10.1016/j.obhdp.2005.02.004].
20. *Ван, Х., Смит, К. А. и Хайндман, Р. Дж.* (2006). Характеристикоориентированная кластеризация данных временных рядов. Data Mining and Knowledge Discovery, 13 (3), 335–364. [DOI: https://doi.org/10.1007/s10618-005-0039-x].
21. *Викрамасурия, С. Л., Атанасопулос, Дж. и Хайндман, Р. Дж.* (2019). Оптимальное увязывание прогнозов для иерархических и сгруппированных временных рядов посредством минимизации трасс. Journal of the American Statistical Association, 114 (526), 804–819. [DOI: https://doi.org/10.1080/01621459.2018.1448825].
22. *Винклер, Р. Л.* (1972). Теоретико-решающий подход к оцениванию интервалов. Journal of the American Statistical Association, 67 (337), 187–191. [DOI: https://doi.org/10.1080/01621459.1972.10481224].
23. *Винтерс, П. Р.* (1960). Прогнозирование продаж с помощью экспоненциально взвешенных скользящих средних. Management Science, 6 (3), 324–342. [DOI: https://doi.org/10.1287/mnsc.6.3.324].
24. *Гамильтон, Дж. Д.* (1994). Анализ временных рядов. Princeton University Press, Princeton. [Amazon, *http://buy.geni.us/Proxy.ashx?TSID=140570&GR_URL=http%3A%2F%2Fwww.amazon.com%2Fdp%2F0691042896*].

25. *Гарднер, Э. С.* (1985). Экспоненциальное сглаживание: Современное состояние. Journal of Forecasting, 4 (1), 1–28. [DOI: https://doi.org/10.1002/for.3980040103].
26. *Гарднер, Э. С.* (2006). Экспоненциальное сглаживание: Современное состояние. Часть II. International Journal of Forecasting, 22, 637–666. [DOI: https://doi.org/10.1016/j.ijforecast.2006.03.005].
27. *Гарднер, Э. С. и Маккензи, Э.* (1985). Прогнозирование трендов во временных рядах. Management Science, 31 (10), 1237–1246. [DOI: https://doi.org/10.1287/mnsc.31.10.1237].
28. *Герреро, В. М.* (1993). Анализ временных рядов, поддерживаемый степенными преобразованиями. Journal of Forecasting, 12 (1), 37–48. [DOI: https://doi.org/10.1002/for.3980120104].
29. *Гнейтинг, Т. и Кацфусс, М.* (2014). Вероятностное прогнозирование. Annual Review of Statistics and Its Application, 1 (1), 125–151. [DOI: https://doi.org/10.1146/annurev-statistics-062713-085831].
30. *Грин, К. К. и Армстронг, Дж. С.* (2007). Структурированные аналогии для прогнозирования. International Journal of Forecasting, 23 (3), 365–376. [DOI: https://doi.org/10.1016/j.ijforecast.2007.05.005].
31. *Гросс, К. В. и Сол, Дж. Е.* (1990). Дезагрегационные методы для ускорения прогнозирования продуктовой линейки. Journal of Forecasting, 9, 233–254. [DOI: https://doi.org/10.1002/for.3980090304].
32. *Гроувз, Р. М., Фаулер, Ф. Дж., Купер, М. П., Лепковски, Дж. М., Сингер, Э. и Туранго, Р.* (2009). Методология опроса (2-е изд.). John Wiley & Sons. [Amazon, *http://buy.geni.us/Proxy.ashx?TSID=140570&GR_URL=http%3A%2F%2Fwww.amazon.com%2Fdp%2F0470465468*].
33. *Гудвин П. и Райт Г.* (2009). Анализ решений для принятия управленческих решений (4-е изд.). John Wiley & Sons. [Amazon, *http://buy.geni.us/Proxy.ashx?TSID=140570&GR_URL=http%3A%2F%2Fwww.amazon.com%2Fdp%2F0470714395*].
34. *Дагум, Э. Б. и Бьянкончини, С.* (2016). Методы сезонной корректировки и оценивание тренда-цикла в реальном времени. Springer. [Amazon, *http://buy.geni.us/Proxy.ashx?TSID=140570&GR_URL=http%3A%2F%2Fwww.amazon.com%2Fdp%2F3319318209*].
35. *Джеймс, Г., Виттен, Д., Хасти, Т. и Тибширани, Р.* (2014). Введение в статистическое обучение: с приложениями на R. Springer. [Amazon, *http://buy.geni.us/Proxy.ashx?TSID=140570&GR_URL=http%3A%2F%2Fwww.amazon.com%2Fdp%2F1461471370]*.
36. *Кан, К. Б.* (2006). Прогнозирование новых продуктов: прикладной подход / М. Э. Шарп. [Amazon, *http://buy.geni.us/Proxy.ashx?TSID=140570&GR_URL=http%3A%2F%2Fwww.amazon.com%2Fdp%2F0765616092*].
37. *Кан, Ю., Хайндман, Р. Дж. и Смит-Майлз, К.* (2017). Визуализация результативности алгоритма прогнозирования с использованием пространств экземпляров временных рядов. International Journal of Forecasting, 33 (2), 345–358. [DOI: https://doi.org/10.1016/j.ijforecast.2016.09.004].
38. *Канеман Д. и Ловалло Д.* (1993). Робкий выбор и смелые прогнозы: когнитивный взгляд на принятие риска. Management Science, 39 (1), 17–31. [DOI: https://doi.org/10.1287/mnsc.39.1.17].

39. *Квятковский Д., Филлипс П. К. Б., Шмидт П. и Шин Ю.* (1992). Проверка нулевой гипотезы стационарности в сопоставлении с альтернативой в виде единичного корня: насколько мы уверены, что экономические временные ряды имеют единичный корень? Journal of Econometrics, 54 (1–3), 159–178. [DOI: https://doi.org/10.1016/0304-4076(92)90104-Y].
40. *Клемен, Р.* (1989). Комбинирование прогнозов: обзор и аннотированная библиография. International Journal of Forecasting, 5 (4), 559–583. [DOI: https://doi.org/10.1016/0169-2070(89)90012-5].
41. *Кливленд, Р. Б., Кливленд, У. С., Макрэй, Дж. Е. и Терпеннинг, И. Дж.* (1990). STL: процедура сезонно-трендового разложения на основе loess. Journal of Official Statistics, 6 (1), 3–33. *http://bit.ly/stl1990*.
42. *Кливленд, У. С.* (1993). Визуализация данных. Hobart Press. [Amazon, *http://buy.geni.us/Proxy.ashx?TSID=140570&GR_URL=http%3A%2F%2Fwww.amazon.com%2Fdp%2F0963488406*].
43. *Кристоу, В. и Фокианос, К.* (2015). О прогнозировании временных рядов счетных данных. Journal of Statistical Computation and Simulation, 85 (2), 357–373. [DOI: *https://doi.org/10.1080/00949655.2013.823612*].
44. *Кростон, Дж. Д.* (1972). Прогнозирование и контроль запасов для прерывистого спроса. Operational Research Quarterly, 23 (3), 289–303. [DOI: https://doi.org/10.2307/3007885].
45. *Куренцес, Н. и Атанасопулос, Дж.* (2019). Перекрестно-темпоральные когерентные прогнозы австралийского туризма. Annals of Tourism Research, 75, 393–409. [DOI: https://doi.org/10.1016/j.annals.2019.02.001].
46. *Лахири, С. Н.* (2003). Методы повторного отбора для зависимых данных. Springer Science & Business Media. [Amazon, *http://buy.geni.us/Proxy.ashx?TSID=140570&GR_URL=http%3A%2F%2Fwww.amazon.com%2Fdp%2F0387009280*].
47. *Лоуренс, М., Гудвин, П., О'Коннор, М. и Онкал, Д.* (2006). Сужденческое прогнозирование: обзор прогресса за последние 25 лет. International Journal of Forecasting, 22 (3), 493–518. [DOI: https://doi.org/10.1016/j.ijforecast.2006.03.007].
48. *Люткеполь, Х.* (2007). Моделирование от общего к конкретному или от конкретного к общему? Мнение о современной эконометрической терминологии. Journal of Econometrics, 136 (1), 234–319. [DOI https://doi.org/10.1016/j.jeconom.2005.11.014].
49. *Морвиц, В. Г., Штекель, Дж. Х. и Гупта, А.* (2007). Когда намерения о покупке предсказывают продажи? International Journal of Forecasting, 23 (3), 347–364. [DOI: https://doi.org/10.1016/j.ijforecast.2007.05.015].
50. *Онкал, Д., Сайим, К. З. и Генюль, М. С.* (2013). Сценарии как каналы получения рекомендаций по прогнозированию. Technological Forecasting and Social Change, 80 (4), 772–788. [DOI: https://doi.org/10.1016/j.techfore.2012.08.015].
51. *Орд, Дж. К., Филдес, Р. и Курентзес, Н.* (2017). Принципы бизнес-прогнозирования (2-е изд.). Wessex Press Publishing Co. [Amazon, *http://buy.geni.us/Proxy.ashx?TSID=140570&GR_URL=http%3A%2F%2Fwww.amazon.com%2Fdp%2F0999064916*].

52. *Панайотелис А., Атанасопулос Дж., Гамакумара П. и Хайндман Р. Дж.* (2021). Увязывание прогнозов: геометрическая перспектива с новым пониманием поправки на смещение. International Journal of Forecasting, 37 (1), 343–359. [DOI: https://doi.org/10.1016/j.ijforecast.2020.06.004].
53. *Панайотелис, А., Гамакумара, П., Атанасопулос, Дж. и Хайндман, Р. Дж.* (2020). Увязывание вероятностных прогнозов: свойства, оценивание и балльная оптимизация (Рабочий документ № 26/20). Факультет эконометрики и бизнес-статистики Университета Монаш. *http://robjhyndman.com/publications/coherentprob/*.
54. *Панкрац, А. Э.* (1991). Прогнозирование с помощью динамических регрессионных моделей. John Wiley & Sons. [Amazon, *http://buy.geni.us/Proxy.ashx?TSID=140570&GR_URL=http%3A%2F%2Fwww.amazon.com%2Fdp%2F0471615285*].
55. *Пегельс, К. С.* (1969). Экспоненциальное прогнозирование: несколько новых вариаций. Management Science, 15 (5), 311–315. [DOI: https://doi.org/10.1287/mnsc.15.5.311].
56. *Пенья, Д., Тиао, Г. К. и Цай, Р. С.* (ред.). (2001). Курс по анализу временных рядов. John Wiley & Sons. [Amazon, *http://buy.geni.us/Proxy.ashx?TSID=140570&GR_URL=http%3A%2F%2Fwww.amazon.com%2Fdp%2F047136164X*].
57. *Пфафф, Б.* (2008). Анализ интегрированных и коинтегрированных временных рядов с помощью R. Springer Science & Business Media. [Amazon, *http://buy.geni.us/Proxy.ashx?TSID=140570&GR_URL=http%3A%2F%2Fwww.amazon.com%2Fdp%2F0387759662*].
58. *Роу, Г.* (2007). Путеводитель по дельфийскому методу. Foresight: The International Journal of Applied Forecasting, 8, 11–16.
59. *Роу, Г. и Райт, Г.* (1999). Дельфийский метод как инструмент прогнозирования: проблемы и анализ. International Journal of Forecasting, 15 (4), 353–375. [DOI: https://doi.org/10.1016/S0169-2070(99)00018-7].
60. *Рэндалл, Д. М. и Вольф, Дж. А.* (1994). Временной интервал во взаимосвязи намерение–поведение: метаанализ. British Journal of Social Psychology, 33 (4), 405–418. [DOI: https://doi.org/10.1111/j.2044-8309.1994.tb01037.x].
61. *Сандерс, Н., Гудвин, П., Онкал, Д., Генюль, М. С., Харви, Н., Ли, А. и Кьолсо, Л.* (2005). Когда и как следует корректировать статистические прогнозы на основе суждений? Foresight: The International Journal of Applied Forecasting, 1 (1), 5–23.
62. *Тейлор, Дж. У.* (2003). Экспоненциальное сглаживание с демпфируемым мультипликативным трендом. International Journal of Forecasting, 19 (4), 715–725. [DOI: https://doi.org/10.1016/S0169-2070(03)00003-7].
63. *Тейлор, С. Дж. и Летэм, Б.* (2018). Прогнозирование в масштабе. The American Statistician, 72 (1), 37–45. [DOI: https://doi.org/10.1080/00031305.2017.1380080].
64. *Фан, С. и Хайндман, Р. Дж.* (2012, *https://otexts.com/fpp3/complexseasonality.html#ref-HF2010*). Краткосрочное прогнозирование нагрузки из полупараметрической аддитивной модели. IEEE Transactions on Power Systems, 27 (1), 134–141. [DOI: https://doi.org/10.1109/TPWRS.2011.2162082].
65. *Феодосиу, М.* (2011). Прогнозирование месячных и квартальных временных рядов с использованием декомпозиции STL. International

Journal of Forecasting, 27 (4), 1178–1195. [DOI: https://doi.org/10.1016/j.ijforecast.2010.11.002].

66. *Филдес, Р. и Гудвин, П.* (2007a). Вопреки твоему здравому смыслу? Как организации могут улучшить использование управленческих суждений при прогнозировании. Interfaces, 37 (6), 570–576. [DOI: https://doi.org/10.1287/inte.1070.0309].
67. *Филдес, Р. и Гудвин, П.* (2007b). Правильное и неправильное суждение в прогнозировании: уроки четырех компаний. Foresight: The International Journal of Applied Forecasting, 8, 5–10.
68. *Франсес, П. Х. и Легерсти, Р.* (2013). Выигрывают ли статистические модели прогнозирования для данных на уровне SKU от включения прошлых экспертных знаний? International Journal of Forecasting, 29 (1), 80–87. [DOI: https://doi.org/10.1016/j.ijforecast.2012.05.008].
69. *Хайндман Р. Дж., Ахмед Р. А., Атанасопулос Дж. и Шанг Х. Л.* (2011). Оптимальные комбинированные прогнозы для иерархических временных рядов. Computational Statistics and Data Analysis, 55 (9), 2579–2589. [DOI: https://doi.org/10.1016/j.csda.2011.03.006].
70. *Хайндман Р. Дж., Ванг Э. и Лаптев Н.* (2015). Крупномасштабное обнаружение необычных временных рядов. Proceedings of the IEEE International Conference on Data Mining, 1616–1619. [DOI: https://doi.org/10.1109/ICDMW.2015.104].
71. *Хайндман, Р. Дж. и Фан, С.* (2010, *https://otexts.com/fpp3/complexseasonality.html#ref-FH2012*). Прогнозирование плотности для долгосрочного пикового спроса на электроэнергию. IEEE Transactions on Power Systems, 25 (2), 1142–1153. [DOI: https://doi.org/10.1109/TPWRS.2009.2036017].
72. *Хайндман, Р. Дж. и Хандакар, Ю.* (2008). Автоматическое прогнозирование временных рядов: Пакет прогнозирования для R. Journal of Statistical Software, 27 (1), 1–22. [DOI: https://doi.org/10.18637/jss.v027.i03].
73. *Хайндман, Р. Дж., и Келер, А. Б.* (2006). Еще один взгляд на меры точности прогноза. International Journal of Forecasting, 22 (4), 679–688. [DOI: https://doi.org/10.1016/j.ijforecast.2006.03.001].
74. *Хайндман, Р. Дж., Келер, А. Б., Орд, Дж.К. и Снайдер, Р. Д.* (2008). Прогнозирование с экспоненциальным сглаживанием: подход на основе пространства состояний. Springer-Verlag. *http://www.exponentialsmoothing.net*.
75. *Харви, Н.* (2001). Улучшение суждений при прогнозировании. В кн.: *Армстронг Дж. С.* (ред.) Принципы прогнозирования: руководство для исследователей и практиков (стр. 59–80). Издательство Kluwer Academic Publishers. [DOI: https://doi.org/10.1007/978-0-306-47630-3_4].
76. *Харрелл, Ф. Э.* (2015). Стратегии регрессионного моделирования: с приложениями к линейным моделям, логистической и порядковой регрессии и анализом выживаемости (2-е изд.). Springer. [Amazon, *http://buy.geni.us/Proxy.ashx?TSID=140570&GR_URL=http%3A%2F%2Fwww.amazon.com%2Fdp%2F3319194240*].
77. *Харрис, Р. и Соллис, Р.* (2003). Прикладное моделирование и прогнозирование временных рядов. John Wiley & Sons. [Amazon, *http://buy.geni.us/Proxy.ashx?TSID=140570&GR_URL=http%3A%2F%2Fwww.amazon.com%2Fdp%2F0470844434*].

78. *Хизер, С. Дж.* (2009). Современный подход к регрессии на R. Springer. [Amazon, *http://buy.geni.us/Proxy.ashx?TSID=140570&GR_URL=http%3A%2F%2Fwww.amazon.com%2Fdp%2F0387096078*].
79. *Хольт, К. С.* (1957). Прогнозирование сезонных колебаний и трендов с помощью экспоненциально взвешенных средних (ONR Memorandum No. 52). Технологический институт Карнеги, Питтсбург, США. Перепечатано в International Journal of Forecasting, 2004 год. [DOI: https://doi.org/10.1016/j.ijforecast.2003.09.015].
80. *Хьюаманаж, Дж., Бергмейер, С. и Бандара, К.* (2021). Рекуррентные нейронные сети для прогнозирования временных рядов: текущее состояние и будущие направления. International Journal of Forecasting, 37 (1), 388–427. [DOI: https://doi.org/10.1016/j.ijforecast.2020.06.008].
81. *Шенстоун, Л. и Хайндман, Р. Дж.* (2005). Стохастические модели в основе метода Кростона для прогнозирования прерывистого спроса. Journal of Forecasting, 24 (6), 389–402. [DOI: https://doi.org/10.1002/for.963].
82. *Энскомб, Ф. Дж.* (1973). Графики в статистическом анализе. The American Statistician, 27 (1), 17–21. [DOI: https://doi.org/10.1080/00031305.1973.10478966].
83. *Эроглу, К. и Крокстон, К. Л.* (2010). Систематическое смещение в субъективных корректировках статистических прогнозов: роль индивидуальных различий. International Journal of Forecasting, 26 (1), 116–133. [DOI: https://doi.org/10.1016/j.ijforecast.2009.02.005].
84. *Янг, П. К., Педрегал, Д. Дж. и Тич, У.* (1999). Динамическая гармоническая регрессия. Journal of Forecasting, 18, 369–394. [DOI: https://doi.org/10.1002/(SICI)1099-131X(199911)18:6%3C369::AID-FOR748%3E3.0.CO;2-K].

Книги издательства «ДМК Пресс» можно заказать
в торгово-издательском холдинге «КТК Галактика» наложенным платежом,
выслав открытку или письмо по почтовому адресу:
115487, г. Москва, пр. Андропова д. 38 оф. 10.
При оформлении заказа следует указать адрес (полностью),
по которому должны быть высланы книги;
фамилию, имя и отчество получателя.
Желательно также указать свой телефон и электронный адрес.
Эти книги вы можете заказать и в интернет-магазине: **www.galaktika-dmk.com**.
Оптовые закупки: тел. **(499) 782-38-89**.
Электронный адрес: **books@alians-kniga.ru**.

**Рон Хайндман и Джордж Атанасопулос**

**Прогнозирование: принципы и практика**

Главный редактор *Мовчан Д. А.*
dmkpress@gmail.com
Зам. главного редактора *Сенченкова Е. А.*
Перевод *Логунов А. В.*
Корректор *Синяева Г. И.*
Верстка *Луценко С. В.*
Дизайн обложки *Мовчан А. Г.*

Формат 70×100 1/16.
Гарнитура «PT Serif». Печать цифровая.
Усл. печ. л. 37,21. Тираж 200 экз.

Веб-сайт издательства: *www.dmkpress.com*