Практическая работа №1

Целью практической работы является освоение начального этапа анализа данных, включающего выбор набора данных, его первичное исследование, визуализацию и подготовку к применению методов анализа данных и машинного обучения.

В результате выполнения работы студент должен получить подготовленный набор данных, пригодный для дальнейшего использования в практических работах, а также аналитический отчёт, содержащий обоснование всех выполненных этапов с использованием математического аппарата.

Задачи, которые необходимо выполнить студенту:

1.1. Сбор и первичный анализ данных

В рамках данного пункта студенту необходимо выбрать реальные открытые наборы данных из общедоступных источников (указав источник его получения), предметную область и предполагаемый тип задачи анализа данных для каждого набора данных (анализ временных рядов, классификация или кластеризация).

Далее требуется загрузить данные и выполнить их первичный анализ, включающий определение размерности выборки, количества наблюдений и признаков, а также выявление типов данных для каждого признака. Необходимо проанализировать наличие пропусков в данных, определить их количество и долю для каждого признака, а также сделать вывод о характере и качестве исходного набора данных.

В отчёте обязательно должно присутствовать математическое описание выборки с введением обозначений для матрицы данных и формальным описанием структуры признаков. Следует классифицировать признаки по шкалам измерения и указать, какие математические операции допустимы для каждого типа данных. По результатам анализа требуется сформулировать вывод о пригодности каждого выбранного набора данных для дальнейшего анализа.

1.2. Визуализация данных

На данном этапе студенту необходимо выполнить визуальный анализ данных с использованием графических методов. Для числовых признаков требуется построить гистограммы распределений и диаграммы размаха (box-plot или «ящик с усами»), позволяющие оценить форму распределения, наличие асимметрии и выбросов. Для анализа взаимосвязей между признаками следует построить диаграммы рассеяния, а для категориальных признаков - диаграммы частот.

В отчёте необходимо не только привести визуализации, но и сопроводить их математическими расчётами основных статистических характеристик, таких как математическое ожидание, дисперсия и квартили. При использовании «ящика с усами» следует формально описать критерии выявления выбросов на основе межквартильного размаха. Все графики

должны быть интерпретированы, а сделанные выводы должны быть связаны с последующими этапами предобработки данных.

1.3. Предобработка данных

В данном пункте требуется выполнить подготовку данных к дальнейшему анализу. В первую очередь студент должен обработать пропуски в данных, выбрав подходящий метод для каждого признака, например удаление наблюдений или заполнение пропусков статистическими оценками. Выбор метода должен быть аргументирован с точки зрения распределения данных и возможного влияния на результаты анализа.

В отчёте необходимо привести математическое обоснование выбранных способов обработки пропусков и указать допущения относительно механизма их возникновения.

Далее требуется выполнить кодирование категориальных признаков с использованием методов порядкового или бинарного кодирования. В отчёте должно быть формально описано, как происходит преобразование категориальных признаков в числовое представление, а также рассмотрено влияние такого преобразования на размерность пространства признаков и используемые меры расстояния.

1.4. Нормализация и стандартизация данных

В рамках данного пункта студенту необходимо привести числовые признаки к сопоставимому масштабу с использованием методов нормализации и/или стандартизации. Следует явно указать, какие признаки подвергались преобразованию и почему это необходимо для дальнейшего применения методов анализа данных. В отчёте требуется привести математические формулы используемых преобразований и пояснить их влияние на распределение признаков и вычисление расстояний в признаковом пространстве.

1.5. Разделение данных на обучающую и тестовую выборки

На этом этапе студенту необходимо разделить подготовленный набор данных на обучающую и тестовую выборки с заданной пропорцией, обеспечив случайность разбиения и воспроизводимость результатов. В отчёте должно быть приведено формальное описание разбиения выборки, а также объяснена его роль в оценке качества моделей и предотвращении переобучения.

1.6. Резюме

В заключительной части работы студенту необходимо обобщить полученные результаты и сформулировать выводы о применимости различных методов визуализации и предобработки данных для разных типов задач анализа. Следует указать, какие методы являются обязательными, желательными или нежелательными в зависимости от постановки задачи, а также оценить готовность подготовленного набора данных к использованию в последующих практических работах. Выводы должны быть логически связаны с проведённым анализом и сопровождаться аргументацией.