Практическая работа №2

Цель работы - изучить и практически освоить основные методы классификации, применяемые в анализе данных, а также научиться обосновывать выбор моделей и интерпретировать полученные результаты с использованием математического аппарата.

В рамках практической работы студент должен использовать один и тот же набор данных, подготовленный на предыдущем этапе (Практическая работа 1).

2.1. Наивный байесовский классификатор

В данном пункте необходимо реализовать наивный байесовский классификатор для решения задачи классификации. Студент должен начать с формального описания используемой модели, записав формулу апостериорной вероятности класса на основе теоремы Байеса и объяснив допущение условной независимости признаков. В отчёте следует явно указать, какая версия алгоритма используется (гауссовская, мультиномиальная или бернуллиевская), и обосновать этот выбор, исходя из типов признаков в данных.

Далее требуется выполнить обучение модели на обучающей выборке и получить прогноз для тестовой выборки. Обязательно приводятся формулы плотности распределения (для гауссовского варианта - с математическим ожиданием и дисперсией) и поясняется, каким образом оцениваются параметры распределений по выборке. В отчёте необходимо представить метрики качества классификации (accuracy, precision, recall, F1-score, матрицу ошибок) и дать их интерпретацию.

2.2. Классификация на основе логистической регрессии

В этом разделе требуется рассмотреть логистическую регрессию как вероятностную модель бинарной (или многоклассовой) классификации. Студент должен привести математическую формулировку логистической функции (сигмоиды), записать вид линейной комбинации признаков и объяснить связь модели с максимизацией функции правдоподобия.

В отчёте необходимо явно записать функцию потерь (логистическую функцию потерь или кросс-энтропию) и описать принцип её минимизации. После обучения модели следует проанализировать значения коэффициентов при признаках, объяснив их знак и относительную величину с точки зрения влияния на вероятность принадлежности классу. Также требуется оценить

качество классификации на тестовой выборке и сравнить результаты с наивным байесовским классификатором.

2.3. Метод ближайших соседей

При рассмотрении метода ближайших соседей студент должен начать с описания идеи алгоритма и указать используемую метрику расстояния (евклидово, манхэттенское и т.д.), приведя её математическую формулу. Необходимо обосновать выбор значения параметра k, в том числе через анализ качества классификации при различных значениях k.

В отчёте следует подчеркнуть роль нормализации признаков для методов, основанных на расстояниях, и показать, как изменение масштаба признаков влияет на результат. После обучения модели требуется оценить её качество и сделать выводы о вычислительной сложности метода и его чувствительности к размерности пространства признаков.

2.4. Метод опорных векторов

В данном пункте необходимо рассмотреть метод опорных векторов с точки зрения оптимизационной задачи. Студент должен привести математическую постановку задачи максимизации зазора между классами, указать ограничения и пояснить роль параметра регуляризации C. При использовании ядерного подхода требуется записать формулу выбранного ядра (линейного, полиномиального, RBF и др.) и обосновать его выбор.

В отчёте необходимо показать процесс подбора гиперпараметров и проанализировать, как они влияют на границу принятия решений. Обязательно приводятся метрики качества классификации и краткое обсуждение интерпретируемости модели и её вычислительной сложности.

2.5. Деревья решений

В этом разделе студент должен описать алгоритм построения дерева решений, указав используемый критерий разбиения (энтропия, прирост информации или индекс Джини) с обязательной записью соответствующих формул. Необходимо пояснить, каким образом выбирается оптимальное разбиение признакового пространства.

После построения дерева следует проанализировать его структуру, глубину и склонность к переобучению. В отчёте требуется рассмотреть влияние параметров ограничения сложности (максимальная глубина, минимальное число объектов в узле) и оценить качество классификации на тестовой

выборке. При возможности рекомендуется визуализировать дерево и прокомментировать наиболее важные разбиения.

2.6. Резюме

В заключительном разделе необходимо выполнить сравнительный анализ всех рассмотренных методов классификации. Студент должен свести полученные значения метрик качества в единую таблицу и проанализировать различия в результатах. В выводах требуется обсудить достоинства и недостатки каждого метода, их интерпретируемость, вычислительную сложность и чувствительность к параметрам данных.

Особое внимание следует уделить обоснованию того, какой метод и почему является наиболее подходящим для рассматриваемой задачи, с опорой на математические свойства моделей и полученные экспериментальные результаты.