Практическая работа №3

Цель практической работы - изучить и практически применить основные методы кластерного анализа, научиться выбирать алгоритм и количество кластеров в зависимости от структуры данных, а также интерпретировать полученные результаты с опорой на математический аппарат.

В качестве исходных данных студент использует набор данных, выбранный и предварительно обработанный в рамках предыдущих практических работ (нормализация, кодирование, обработка пропусков должны быть явно зафиксированы).

3.1. Метод k-средних

В данном разделе студент должен реализовать алгоритм k-средних и подробно описать его математическую постановку. Необходимо ввести понятие кластера как подмножества объектов и сформулировать целевую функцию метода — минимизацию суммы квадратов расстояний объектов до центров соответствующих кластеров.

Студент должен описать итеративную природу алгоритма: начальную инициализацию центров, шаг назначения объектов к ближайшему центру (с указанием используемой метрики расстояния), шаг пересчёта центров кластеров и критерий остановки алгоритма. В отчёте необходимо прокомментировать влияние нормализации признаков на результат кластеризации и проанализировать чувствительность алгоритма к выбору начальных центров.

Результаты работы алгоритма должны быть визуализированы (для двумерных или пониженных данных) и интерпретированы.

3.2. Агломеративная кластеризация. Метод Уорда

В этом пункте студент реализует и исследует иерархическую агломеративную кластеризацию с использованием метода Уорда. В отчёте необходимо пояснить принцип агломеративного подхода - последовательное объединение кластеров, начиная с одиночных объектов.

Особое внимание уделяется математическому смыслу метода Уорда: объединение тех кластеров, при котором минимально увеличивается внутрикластерная сумма квадратов отклонений. Следует привести формулу приращения дисперсии и объяснить, почему данный метод ориентирован на получение компактных кластеров.

Обязательным элементом является построение дендрограммы и её анализ. Студент должен обосновать выбор уровня отсечения дендрограммы для получения конечного разбиения на кластеры и сравнить полученный результат с методом k-средних.

3.3. Плотностные алгоритмы DBSCAN и OPTICS

В данном разделе студент применяет плотностные алгоритмы кластеризации DBSCAN и OPTICS. В отчёте необходимо ввести понятие плотности, ε-окрестности, core-точек, border-точек и шумовых объектов.

Следует формально описать критерии принадлежности точки к кластеру в DBSCAN, а также роль параметров. Студент должен обосновать выбор этих параметров.

Для алгоритма OPTICS необходимо объяснить его отличие от DBSCAN и преимущества при работе с кластерами переменной плотности. В отчёте должны присутствовать визуализации результатов и комментарии о способности алгоритмов выявлять шум и кластеры сложной формы.

3.4. Выбор метода в зависимости от характера кластеров данных

В этом пункте студент проводит аналитическое сравнение методов кластеризации с точки зрения формы кластеров, плотности, наличия шума и размерности пространства признаков. Необходимо аргументированно пояснить, какой метод наиболее подходит для исследуемых данных и примерить его для анализа.

Результаты и выводы по применению выбранного метода должны опираться не только на визуальный анализ, но и на свойства целевых функций, используемых метрик расстояния и предположений, заложенных в алгоритмы.

3.5. Выбор оптимального количества кластеров: методы локтя и силуэта

В данном разделе студент исследует проблему выбора числа кластеров. Для метода локтя необходимо построить зависимость значения внутрикластерной суммы квадратов от числа кластеров и математически пояснить смысл «излома» кривой.

Метод силуэта должен быть описан через коэффициент силуэта, с приведением формулы и пояснением интерпретации значений. Студент обязан рассчитать среднее значение коэффициента силуэта для разных разбиений и обосновать выбор оптимального числа кластеров.

3.6. Резюме

В заключительном разделе студент формулирует обобщающие выводы по всем рассмотренным методам. Необходимо сравнить результаты кластеризации, устойчивость алгоритмов, интерпретируемость кластеров и вычислительную сложность методов.

Резюме должно содержать аргументированный вывод о том, какой метод оказался наиболее подходящим для выбранного набора данных и почему, с опорой на математические критерии и экспериментальные результаты.