Практическая работа №6

Цель практической работы - изучить принципы построения ансамблевых моделей машинного обучения, освоить методы снижения переобучения с помощью ансамблей и регуляризации, а также научиться интерпретировать сложные модели. Все эксперименты выполняются на датасетах, использованных в практических работах 2–5. В отчёте обязательно должно присутствовать математическое описание используемых методов, формулы, пояснение используемых критериев качества и аргументированный анализ результатов.

6.1. Бэггинг

В рамках данного пункта необходимо реализовать ансамблевую модель на основе метода бэггинга (Bootstrap Aggregating) для одной из задач, рассмотренных ранее (классификация или регрессия). Следует описать процедуру бутстрэп-выборки, то есть формирование обучающих подвыборок одинакового размера путём случайного выбора объектов с возвращением из исходной выборки.

Необходимо привести математическое обоснование бэггинга как метода уменьшения дисперсии базового алгоритма, записав формулу агрегирования предсказаний (усреднение для регрессии или голосование для классификации). В качестве базовой модели рекомендуется использовать алгоритмы с высокой дисперсией (например, решающие деревья).

В отчёте требуется сравнить качество одиночной модели и ансамбля по выбранным метрикам, проанализировать влияние числа базовых моделей и сделать вывод о целесообразности применения бэггинга для рассматриваемой задачи.

6.2. Бустинг

В данном разделе необходимо построить ансамблевую модель на основе одного из методов бустинга (AdaBoost, Gradient Boosting, XGBoost, LightGBM или CatBoost). Следует подробно описать идею последовательного обучения слабых моделей с акцентом на увеличение веса ошибок предыдущих шагов либо на оптимизацию функции потерь с помощью градиентного спуска в функциональном пространстве.

В отчёте необходимо привести математическую постановку задачи минимизации функции потерь, записать формулу обновления ансамбля и пояснить роль коэффициентов (learning rate, число итераций). Требуется

провести экспериментальное сравнение бустинга с бэггингом и одиночной моделью, а также проанализировать переобучение в зависимости от глубины базовых моделей и количества итераций.

6.3. Стекинг

В рамках данного пункта необходимо реализовать ансамбль типа стекинг, используя не менее двух различных базовых моделей первого уровня (например, линейная модель, дерево решений, метод k ближайших соседей). Следует описать процедуру формирования мета-признаков с использованием кросс-валидации и обосновать необходимость раздельного обучения моделей первого и второго уровней.

В отчёте требуется привести математическое описание стекинга как композиции отображений, пояснить роль мета-модели и сравнить её качество с результатами отдельных базовых алгоритмов. Особое внимание следует уделить предотвращению утечки данных и корректной организации обучающей процедуры.

6.4. Регуляризация в ансамблях (подбор гиперпараметров)

В данном разделе необходимо исследовать влияние регуляризации на качество моделей. Для задач регрессии требуется реализовать RIDGE- и LASSO-регрессии, привести соответствующие целевые функции с L2- и L1-регуляризаторами и пояснить геометрический смысл штрафов. Для ансамблевых моделей из практической работы 4 необходимо выполнить подбор гиперпараметров, отвечающих за регуляризацию (глубина деревьев, минимальное число объектов в листе, коэффициент обучения, число базовых моделей и т.п.). Подбор следует выполнять с использованием кросс-валидации. В отчёте необходимо обосновать выбор оптимальных значений параметров, проанализировать компромисс между смещением и дисперсией и сравнить регуляризованные и нерегуляризованные модели.

6.5. Интерпретация ансамблей

В рамках данного пункта необходимо выполнить интерпретацию одной из построенных ансамблевых моделей. Требуется рассчитать и проанализировать важность признаков, а также применить метод SHAP для оценки вклада отдельных признаков в предсказание модели. В отчёте необходимо привести математическую идею SHAP-значений, пояснить связь с кооперативной теорией игр и интерпретировать полученные результаты для конкретных объектов и для модели в целом. Следует обсудить, какие

признаки оказывают наибольшее влияние и насколько интерпретация ансамблей отличается от интерпретации линейных моделей.

6.6. Резюме

В заключительном разделе необходимо обобщить результаты работы и сделать аргументированные выводы о применимости ансамблевых методов и регуляризации для задач классификации, регрессии и (при наличии экспериментов) кластеризации. Следует сравнить методы по качеству, устойчивости к шуму, интерпретируемости и вычислительной сложности. В резюме требуется указать, в каких практических ситуациях целесообразно использовать бэггинг, бустинг и стекинг, а также какую роль играет регуляризация при работе с ансамблями.