2 ЧАСА

5. АГРЕГИРОВАНИЕ И ОБРАБОТКА ЗНАЧЕНИЙ В БАЗЕ ДАННЫХ

Цель практической работы №5: изучить методы агрегирования и обработки значений в данных в СУБД Postgres Pro. Научиться применять агрегирующие функции для анализа данных, группировки и получения итоговых показателей.

Постановка задачи: изучить различные встроенные функции обработки данных в СУБД Postgres Pro.

Теоретические основы агрегирования данных

Агрегирующие функции в SQL представляют собой инструмент для статистического анализа данных, позволяющий преобразовывать множественные записи в суммарные показатели.

В отличие от базовых операций выборки, функции типа AVG(), COUNT(), VAR_SAMP() и PERCENTILE_CONT() оперируют не с отдельными строками, а с целыми группами данных, что требует от СУБД специальных алгоритмов обработки. Особую значимость приобретает понимание различий между мерами центральной тенденции: если AVG() вычисляет среднее арифметическое, чувствительное к экстремальным значениям, то PERCENTILE_CONT(0.5) определяет медиану, более устойчивую к выбросам. Для магистранта важно осознавать, что выбор агрегирующей функции напрямую влияет на интерпретацию результатов и должно быть обосновано характером анализируемых данных.

Группировка данных с помощью GROUP BY создает основу для многомерного анализа, однако эффективное ее использование требует понимания концепции функциональных зависимостей. В контексте реляционной алгебры, корректная группировка возможна только когда неагрегированные столбцы однозначно определяются группирующими атрибутами.

Выполнение практической работы

Подсчёт количества ноутбуков с объёмом ОЗУ ≥ 8GB по компаниям и вычисление средней цены

```
SELECT
   "Company",
   "Ram",
   COUNT(*) AS laptop_count,
   AVG("Price_euros") AS average_price
FROM csv_laptop
WHERE CAST(SPLIT_PART("Ram", 'GB', 1) AS INTEGER) >= 8
GROUP BY "Company", "Ram";
```

Этот SQL-запрос извлекает из таблицы csv_laptop данные о компаниях-производителях ноутбуков и объемах оперативной памяти (RAM), где объем RAM составляет не менее 8 ГБ. Для каждого сочетания компании и объема RAM подсчитывается количество ноутбуков и вычисляется их средняя цена. Результаты группируются по названиям компаний и объему оперативной памяти, как представлено на рис. 33.

	Company	Ram	laptop_count	average_price
1	Dell	32GB	7	3 150,9228515625
2	Razer	16GB	4	2 699
3	Lenovo	24GB	1	2 382
4	MSI	16GB	31	2 049,7916181011
5	HP	16GB	13	1 862,1538461538
6	Toshiba	16GB	8	1 785,25
7	Asus	32GB	3	2 656
8	Razer	32GB	2	5 799
9	Dell	8GB	161	1 133,2433520963
10	Asus	24GB	2	2 118,5
11	HP	8GB	142	1 276,6411955927
12	Lenovo	12GB	6	1 381,1666666667
13	MSI	8GB	22	1 228,1136419123
14	Dell	16GB	54	1 875,2512998228
15	Apple	8GB	10	1 423,4379943848
16	Xiaomi	16GB	1	1 399,9499511719
17	Fujitsu	8GB	2	769
18	Toshiba	8GB	25	1 279,4
19	Microsoft	8GB	3	1 668,949991862
20	Razer	8GB	1	1 029
21	MSI	32GB	1	2 799

Рисунок 33. Подсчёт количества ноутбуков с объёмом ОЗУ ≥ 8GB по компаниям и вычисление средней цены

Вычисление среднего значения и дисперсии цены ноутбуков по типу операционной системы

```
SELECT
   "OpSys",
   AVG("Price_euros") AS average_price,
   VAR_SAMP("Price_euros") AS price_variance
FROM csv_laptop
where "OpSys" is not null
GROUP BY "OpSys";
```

Этот SQL-запрос анализирует данные о ноутбуках из таблицы csv_laptop, вычисляя среднюю цену и дисперсию цен для каждой операционной системы (OpSys). Учитываются только записи, где значение поля OpSys не является пустым, а результаты группируются по операционным системам, как представлено на рис. 34.

	A-Z OpSys	123 average_price	123 price_variance
1	Mac OS X	1 298,9924926758	317 810,4971329917
2	Chrome OS	553,5851847331	220 953,6299408046
3	Windows 10 S	1 286,4799957275	620 065,6758156948
4	Linux	617,0688702983	63 866,3668380856
5	Android	434	26 450
6	Windows 7	1 686,6513237847	605 360,4656397857
7	macOS	1 815,7090787021	381 234,0941662307
8	Windows 10	1 169,8613366385	483 893,0216776204
9	No OS	587,9733320294	76 813,0591885636

Рисунок 34. Вычисление среднего значения и дисперсии цены ноутбуков по типу операционной системы

Вычисление медианы цены ноутбуков по компаниям

```
SELECT
   "Company",
```

```
    PERCENTILE_CONT(0.5) WITHIN GROUP (ORDER BY "Price_euros")
AS median_price
    FROM csv_laptop
    GROUP BY "Company";
```

Этот SQL-запрос вычисляет медианную цену ноутбуков для каждой компании из таблицы csv_laptop. Для этого используется функция PERCENTILE_CONT с параметром 0.5, которая рассчитывает медиану внутри группы, отсортированной по цене ноутбуков. Результаты группируются по названию компании, как представлено на рис. 35.

	Company	median_price
1	Acer	559
2	Apple	1 518,5500488281
3	Asus	1 012,5
4	Chuwi	449
5	Dell	985
6	Fujitsu	739
7	Google	1 559
8	HP	966,5
9	Huawei	1 424
10	LG	2 099
11	Lenovo	899
12	MSI	1 599
13	Mediacom	265
14	Microsoft	1 569,5
15	Razer	2 899
16	Samsung	1 649
17	Toshiba	1 211,5
18	Vero	206,8499984741
19	Xiaomi	1 099,450012207
20	[NULL]	0

Рисунок 35. Вычисление медианы цены ноутбуков по компаниям

Вычисление среднего размера экрана и дисперсии размера экрана по типу ноутбука

```
SELECT
  "TypeName",
  AVG("Inches") AS average_screen_size,
  VAR_SAMP("Inches") AS screen_size_variance
FROM csv_laptop
```

```
WHERE "TypeName" is not null
GROUP BY "TypeName";
```

Этот SQL-запрос вычисляет средний размер экрана и дисперсию размеров экранов ноутбуков для каждого типа устройства (TypeName) из таблицы csv_laptop. Учитываются только записи, где поле TypeName не пустое, а результаты группируются по типу устройства, как представлено на рис. 36.

	TypeName	average_screen_size	screen_size_variance
1	Ultrabook	13,6515790538	0,8318229542
2	Workstation	15,9517242826	0,4911569742
3	Gaming	16,3458535078	0,8596508741
4	2 in 1 Convertible	13,6148761954	1,8601100478
5	Netbook	11,8160002899	0,1538998695
6	Notebook	15,3297933105	0,9856855519

Рисунок 36. Вычисление среднего размера экрана и дисперсии размера экрана по типу ноутбука

Подсчёт количества ноутбуков и вычисление средней цены по типу графического процессора (GPU)

```
SELECT
   "Gpu",
   COUNT(*) AS laptop_count,
   AVG("Price_euros") AS average_price
FROM csv_laptop
GROUP BY "Gpu";
```

Этот SQL-запрос подсчитывает количество ноутбуков и вычисляет среднюю цену для каждой видеокарты (Gpu) из таблицы csv_laptop. Результаты группируются по названиям видеокарт, как представлено на рис. 37.

	Gpu	laptop_count	average_price
1	Nvidia Quadro M500M	1	2 050,3798828125
2	[NULL]	8	0
3	AMD Radeon R7 Graphics	1	629
4	AMD Radeon R5 M315	1	769,1500244141
5	AMD Radeon Pro 560	1	2 858
6	Nvidia GeForce GTX 1050	66	1 204,2248516661
7	Nvidia GeForce 920MX	5	554,8
8	Nvidia GeForce GTX 960M	14	1 084,4057094029
9	AMD Radeon R7 M465	1	1 349
10	Intel Iris Plus Graphics 650	2	1 921,799987793
11	Nvidia Quadro M3000M	1	3 949,3999023438
12	Nvidia Quadro M1000M	4	1 984,5
13	Nvidia Quadro M620	5	1 969,4
14	AMD Radeon RX 550	4	1 176,365020752
15	Nvidia GeForce GTX 1070	30	2 611,8053304036
16	AMD Radeon 530	41	864,4795130288
17	Nvidia GeForce 150MX	3	1 231

Рисунок 37. Подсчёт количества ноутбуков и вычисление средней цены по типу графического процессора (GPU)

Вычисление максимального и минимального веса ноутбуков по компаниям

```
SELECT
   "Company",
   MAX(CAST(SPLIT_PART("Weight", 'kg', 1) AS FLOAT)) AS
max_weight_kg,
   MIN(CAST(SPLIT_PART("Weight", 'kg', 1) AS FLOAT)) AS
min_weight_kg
FROM csv_laptop
where "Company" is not NULL
GROUP BY "Company";
```

Этот SQL-запрос определяет максимальный и минимальный вес ноутбуков (в килограммах) для каждой компании из таблицы csv_laptop. Для вычислений вес извлекается из строки, преобразуется в число, и учитываются только записи, где поле «Company» не пустое. Результаты группируются по названию компании, как представлено на рис. 38.

	A-Z Company	123 max_weight_kg	123 min_weight_kg
1	Microsoft	1,252	1,25
2	Fujitsu	2,3	2,2
3	LG	1,09	0,98
4	Toshiba	2,4	1,05
5	HP	3,78	0,97
6	Huawei	1,05	1,05
7	Mediacom	1,45	1,16
8	Xiaomi	1,95	1,28
9	MSI	4,5	1,6
10	Razer	3,49	1,25
11	Asus	4,7	0,91
12	Samsung	2,5	0,81
13	Vero	1,45	1,22
14	Lenovo	4,6	0,69
15	Dell	4,42	1,18
16	Acer	4,2	1,12
17	Chuwi	1,4	1,4
18	Google	1,1	1,1

Рисунок 38. Вычисление максимального и минимального веса ноутбуков по компаниям

Выполненная работа позволила освоить ключевые аспекты аналитической обработки данных средствами SQL, выходящие за рамки базового агрегирования. Практическое применение статистических функций (VAR_SAMP, PERCENTILE_CONT) в сочетании с обработкой неструктурированных атрибутов сформировало понимание комплексного подхода к извлечению значимой информации из сырых данных. Особую ценность представляет опыт работы с медианными значениями, которые в отличие от среднего арифметического обеспечивают более репрезентативную оценку в условиях асимметричных распределений, характерных для рыночных цен.

Для магистранта приобретенные навыки составляют основу для будущих исследований в области анализа данных и построения систем поддержки принятия решений. Умение корректно применять различные агрегирующие функции и методы предобработки данных напрямую влияет на достоверность аналитических выводов. Эти компетенции будут востребованы при разработке хранилищ данных, создании бизнес-отчетности и проведении статистических исследований, где качественная агрегация данных является не технической задачей, а методологической основой научного анализа.

Контрольные вопросы

1. Какие функции в PostgreSQL можно использовать для вычисления среднего значения, медианы и дисперсии, и в чем их отличия?

2. Как работают функции GROUP BY и WHERE, и как они могут использоваться совместно для фильтрации и группировки данных?

3. Каким образом можно преобразовать текстовые значения из столбца в числовой формат, чтобы использовать их в агрегирующих функциях?

4. Чем отличается использование агрегирующих функций, таких как AVG, MAX, и PERCENTILE_CONT, и в каких ситуациях их применение наиболее эффективно?