ДИСЦИПЛИНА **Интеллектуальный анализ данных**
(полное наименование дисциплины без сокращений)

ИНСТИТУТ **информационных технологий**

КАФЕДРА **Прикладной математики**
(полное наименование кафедры)

ВИД УЧЕБНОГО МАТЕРИАЛА **Материалы для практических/семинарских занятий**
(в соответствии с пп.1-11)

ПРЕПОДАВАТЕЛЬ **Парамонов Александр Александрович**
(фамилия, имя, отчество)

СЕМЕСТР **3, 2026-2027**
(указать семестр обучения, учебный год)

1. Тематическое моделирование новостей и анализ динамики тем

Цель - научиться извлекать темы из больших текстовых корпусов и анализировать их изменение во времени.

Данные - любые открытые новостные источники (приветствуется настройка через парсинг данных).

Основные этапы работы:

1. Импорт текстового корпуса в PolyAnalyst.
2. Очистка данных (удаление стоп-слов, нормализация текста).
3. Выделение ключевых терминов.
4. Кластеризация документов.
5. Формирование тем текстового корпуса.

Задачи для выполнения:

1. Реализовать импорт данных через возможности PolyAnalyst.
2. Провести очистку данных.
3. Построить не менее 10 тематических кластеров новостей, в случае узконаправленного набора данных, количество кластеров может измениться после согласования с преподавателем в меньшую сторону.
4. Определить ключевые слова каждой темы.
5. Построить график изменения популярности темы по месяцам.

Сформировать отчёт, в котором необходимо отразить все этапы работы, демонстрацию решения выполненных задач не только скриншотами, но и

текстовым описанием проведённой работы и обоснованием выбора отдельных элементов.

Дополнительное задание:

1. Выявить в динамике: новые появляющиеся темы и исчезающие темы.
2. Сравнить тематическую структуру до и после значимого события (например, пандемии или выборов), связать темы с временными метками.

2. Извлечение событий из текстовых отчетов

Цель - освоить методы извлечения информации с использованием словарей и регулярных выражений.

Данные - те же.

Основные этапы работы и задачи:

1. Импорт текстов отчетов.
2. Создание словарей:
- типы событий
- типы ошибок
3. Настройка регулярных выражений для извлечения:
- дат
- координат
- числовых параметров
4. Формирование структурированной таблицы событий.
5. Извлечь из текста:
- дату события
- место
- тип инцидента
6. Построить таблицу:

   Событие | Место | Дата | Категория

Сформировать отчёт, в котором необходимо отразить все этапы работы, демонстрацию решения выполненных задач не только скриншотами, но и текстовым описанием проведённой работы и обоснованием выбора отдельных элементов.

Дополнительное задание:

1. Построить распределение событий по типам.
2. Найти наиболее частые комбинации факторов риска.
3. Построить граф связей между типами событий.

3. Обнаружение повторяющихся текстовых шаблонов

Цель - научиться находить дубликаты и повторяющиеся структуры текста.

Данные - открытые данные по отзывам на товары, фильмы, услуги и т.д.

Этапы выполнения:

1. Импорт отзывов.
2. Очистка текста.
3. Вычисление сходства документов.
4. Выявление кластеров схожих текстов.

Задачи:

1. Найти точные дубликаты, близкие по структуре тексты.
2. Определить массовые шаблонные отзывы.
3. Построить метрику - процент повторяющихся текстов.

Сформировать отчёт, в котором необходимо отразить все этапы работы, демонстрацию решения выполненных задач не только скриншотами, но и текстовым описанием проведённой работы и обоснованием выбора отдельных элементов.

Дополнительно:

Разработать метод со сценарием по выявлению потенциальных фейковых отзывов.

4. Классификация и анализ тональности текстов (к заданию 3)

Цель - освоить методы текстового анализа и определения тональности текстов.

Данные - те же.

Этапы выполнения:

1. Подготовка обучающей выборки.
2. Извлечение признаков:
- Мешок слов;
- ключевые фразы.
3. Обучение классификатора.
4. Оценка качества модели.

Задачи:

1. Построить модель классификации:
- положительных
- отрицательных
- нейтральных отзывов.
2. Рассчитать:
- accuracy
- precision
- recall.
3. Найти наиболее значимые слова для классификации.

Сформировать отчёт, в котором необходимо отразить все этапы работы, демонстрацию решения выполненных задач не только скриншотами, но и текстовым описанием проведённой работы и обоснованием выбора отдельных элементов.

Дополнительно сравнить rule-based подход и машинное обучение.

5. Построение онтологии предметной области

Цель - извлечение терминов и построение иерархии понятий.

Данные - открытые данные по научным статьям.

Этапы работы:

1. Выделение терминов.
2. Частотный анализ словосочетаний.
3. Построение связей терминов.

Задачи

1. Выделить ключевые термины области.
2. Определить:
- родовидовые отношения;
- тематические группы.
3. Построить иерархическую структуру терминов.

Сформировать отчёт, в котором необходимо отразить все этапы работы, демонстрацию решения выполненных задач не только скриншотами, но и текстовым описанием проведённой работы и обоснованием выбора отдельных элементов.

Дополнительно:

1. Сравнить качество решения задачи на русских и английских текстах.
2. Создать словарь терминов для автоматической классификации текстов.

6. Выявление аномалий во временных рядах

Цель - научиться находить аномальные значения и редкие события.

Данные - открытые данные по временным рядам, не менее 5000 точек, наблюдения должны охватывать показатели до настоящего времени.

Этапы работы:

1. Импорт временного ряда.
2. Анализ распределения.
3. Выявление выбросов.

Задачи:

1. Найти точки с аномальными значениями.
2. Определить возможные причины аномалий.
3. Построить визуализацию аномальных периодов.

Сформировать отчёт, в котором необходимо отразить все этапы работы, демонстрацию решения выполненных задач не только скриншотами, но и текстовым описанием проведённой работы и обоснованием выбора отдельных элементов.

Дополнительно сравнить:

1. статистический метод
2. кластеризацию.

7. Прогнозирование временных рядов

Цель - построить модель прогнозирования ВР.

Данные - те же.

Этапы работы:

1. Анализ тренда.
2. Выделение колебательных составляющих.
3. Обучение модели.

Задачи:

1. Построить краткосрочный и среднесрочный прогнозы, окно прогноза зависит от общего объёма выборки.
2. Оценить ошибку прогноза.
3. Найти наиболее важные факторы.

Сформировать отчёт, в котором необходимо отразить все этапы работы, демонстрацию решения выполненных задач не только скриншотами, но и текстовым описанием проведённой работы и обоснованием выбора отдельных элементов.

Дополнительно:

1. Определить характеристики тренда через метод анаморфоз.
2. Определить характеристики колебаний с использованием почти периодического анализа.
3. Построить несколько моделей и сравнить точность.